

Volume IV | 微積分與數學分析的線性代數方法

極限 × 線性映射 × 最佳化 × 積分 × 微分方程與變分

30章 · 117,879 中文字

模型審稿完成，仍待人工審定。

模型審稿不等於人工數學驗證；所有養殖案例為合成教學資料。

內容版本：2026-10-06T18:39:06.993747

HTML／PDF 圖文出版版

Volume IV：從線性近似到分析

極限、範數、緊緻與條件



導數：線性映射＋小於一階的餘項



Hessian、約束與最佳化



積分換變數、幾何與極限交換



ODE、算子、變分與可稽核專題

目錄

1. 導讀：線性近似之外，還需要什麼？
2. 第01章 從線性代數走向分析：命題、誤差與證明
3. 第02章 數列、Cauchy條件與級數橋接
4. 第03章 向量範數、距離與算子範數
5. 第04章 多變量極限與連續性
6. 第05章 開閉集、緊緻性與一致連續
7. 第06章 單變量微積分的嚴格橋接
8. 第07章 Fréchet導數與餘項條件
9. 第08章 偏導、方向導數、梯度與Jacobian
10. 第09章 鏈式法則、JVP與VJP
11. 第10章 矩陣微分與Frobenius內積
12. 第11章 反函數定理與局部可逆
13. 第12章 隱函數定理與靈敏度
14. 第13章 Hessian、二階微分與Taylor展開
15. 第14章 駐點、二次型與退化極值
16. 第15章 凸性、強凸性與光滑性
17. 第16章 梯度下降、線搜尋與Newton法
18. 第17章 等式約束、切空間與Lagrange乘數
19. 第18章 不等式約束與KKT橋接
20. 第19章 多重積分、Riemann和與Fubini
21. 第20章 Jacobian行列式與積分換變數
22. 第21章 曲線、曲面與Gram面積元素
23. 第22章 線積分、勢函數與拓撲界線
24. 第23章 散度、旋度與積分定理
25. 第24章 函數列、一致收斂與極限交換

- 26. 第25章 線性微分方程與矩陣指數
- 27. 第26章 非線性ODE、固定點與局部存在唯一
- 28. 第27章 線性化、局部穩定與Lyapunov橋接
- 29. 第28章 有界算子與有限／無限維的差別
- 30. 第29章 變分法、第一變分與能量泛函
- 31. 第30章 整合專題：可稽核的感測校準與分析
- 32. 附錄：符號、證據與驗收索引
- 33. 參考來源

導讀：線性近似之外，還需要什麼？

第四卷以線性代數為入口，建立微積分與數學分析的條件意識。把偏導數排成矩陣還不足以說明可微性；真正的核心是：線性近似留下的誤差，除以擾動尺度後是否趨於零？本卷不只給公式，也給定義、量詞、證明、反例與數值證據的界線。

全卷五部三十章，正文初步目標十三萬五千中文字，每章至少三千、目標四千五百，含導讀、附錄及解答不超過二十萬字。公式、程式與英文不充字數。不因篇幅限制跳過必要假設，也不以重複敘述湊數。

閱讀路線

第一部建立極限、範數、緊緻性及單變量橋接；第二部將導數理解成線性映射，接到鏈式法則、反函數與隱函數；第三部由Hessian走到凸性、最佳化及約束；第四部連接積分、幾何與極限交換；第五部討論ODE、算子、變分及整合專題。

Volume I提供矩陣基礎；Volume II的幾何與Volume III的場模擬作應用對照。第三卷已完成模型審稿，仍不是人工審定；本卷不把它當成所有分析定理都已證明的先備課。Volume V尚未製作，反向傳播先從小型計算圖介紹，不需要先學完整Transformer。

教學與驗證

每章至少含一個完整小命題證明、兩個手算例、自足CPU程式、正常與故障測試，以及四類習題與解答。重要進階結果若未完整證明，明示引用與條件，不把證明省略藏在圖像或程式後面。

核心採Python標準庫／NumPy；SciPy可選，JAX僅為自動微分延伸參考，不要求GPU。有限差分可發現梯度錯誤，但不能憑幾個方向就證明Fréchet可微；有限格點不能證明緊緻或一致收斂。尚未執行的輸出目標預期。

合成案例与安全

感測映射、幾何域及校準資料都是合成教學資料。分量單位、縮放、Jacobian形狀、容差和適用範圍必須列出；局部近似不能當作全域模型。agent只讀證據，不控制真實泵浦、投餌、加藥或其他設備。

第01章 從線性代數走向分析：命題、誤差與證明

學習目標與先備知識

本章是第四卷的入口。它不重講矩陣乘法、行列式或特徵值；讀者應已通過第一卷熟悉有限維向量空間、矩陣表示、線性映射的合成與轉置。本章要做的事是把「有限維代數命題」與「分析命題」之間的落差講清楚：前者是有限個純量等式的組合，後者涉及全稱量詞轄下的無窮多個實數，兩者的證明技術、證據強度與出錯方式都不同。

讀完本章，你應該能夠：

- 分辨命題、條件句、充分條件、必要條件與充要條件，並用量詞寫出精確敘述。
- 說明為什麼有限次數值檢驗不能證明一個 $\forall \varepsilon > 0$ 型的無限命題，但一次反例即可否認它。
- 說明實數完備性在分析中扮演什麼角色，並知道 $\mathbb{Q}$ 為何不足。
- 對一個 C^2 函數寫出帶明顯餘項界的一階線性近似，並知道這個界是定理而非估計值。
- 對合成測量誤差建立單位、維度、有效範圍與證據標籤的紀錄框架。

需要的先備知識：實數的序公理、對 $\mathbb{R}$ 的絕對值、數列與極限的直覺、矩陣與線性映射的基本運算、鏈式法則的微積分印象。若對矩陣轉置、向量為列的情形仍不熟，先複習第一卷。

問題與直覺

線性代數教科書習慣用「求 $Ax = b$ 的解」或「求 A 的特徵值」這類有限問題。這些問題的答案是有限維向量或有限個純量。分析則把問題換成：對任意小的 $\varepsilon > 0$ ，是否存在 $\delta > 0$ 使得……；對所有 $n \geq N$ ，是否成立……；對任意 $x \in U$ ，是否有……。突然之間，一句話裡出現好幾個量詞，句子的真假取決於量詞的順序。

把「 $\forall \varepsilon > 0 \exists \delta > 0 \forall x$ 」誤寫成「 $\exists \delta > 0 \forall \varepsilon > 0 \forall x$ 」，會從連續性變成一致連續；把「 $\forall n \exists m$ 」與「 $\exists m \forall n$ 」搞混，會把逐點收斂與一致收斂混為一談。代數錯一項只影響答案的數值；量詞錯一個次序，命題的真假直接反轉。

第二個問題是誤差。線性代數給精確解；分析要處理「我們只算得出近似」。把 $f(x+h)$ 近似成 $f(x) + f'(x)h$ 是可行的，因為餘項對 h 是 $o(|h|)$ 。但若不寫下餘項的界，你就不知道這個近似在什麼範圍內可用。 10^{-1} 的步長往往沒問題， 10^1 就可能離譜。

第三個問題是證明與數值檢驗的界線。寫十行程式在 $[0, 1]$ 上取 10^6 個點檢查一個不等式，這是數值證據。它支持這個不等式在採樣點成立，但沒有排除採樣點之間的反例，也沒有處理實數的不可數性。這份教材會反覆用「證據標籤」把這三種東西區分開：定義、定理、數值證據。

定義、定理與推導

定義 1.1 (命題與真值)：命題是具真假的敘述。在分析中，命題通常形如

$$\forall x \in U, \exists \delta > 0, P(x, \delta).$$

其中 U 是集合， P 是僅含有限個自由變數的條件句。自由變數一經量詞綁定，整句就有真假。

定義 1.2 (充分、必要)：設 A, B 為命題。

- 若 $A \Rightarrow B$ 為真，稱 A 是 B 的充分條件， B 是 A 的必要條件。
- 若 $A \Leftrightarrow B$ 為真，稱 A 是 B 的充要條件。

需要強調：充分條件不是必要條件。 $x > 2$ 是 $x > 0$ 的充分條件，但 $x = 1$ 使 $x > 0$ 為真而 $x > 2$ 為假，所以它不是必要條件。 $x^2 = 4$ 是 $x = 2$ 的必要條件 ($x = 2 \Rightarrow x^2 = 4$)，但不是充分條件 ($x = -2$ 也滿足)。

定義 1.3 (實數完備性)：稱有序域 $\mathbb{R}$ 完備，是指：對每個非空有上界的子集 $S \subseteq \mathbb{R}$ ，存在最小的上界 $\sup S \in \mathbb{R}$ 。

這條性質是 $\mathbb{R}$ 與 $\mathbb{Q}$ 的分水嶺。後面的數列收斂、連續函數的中間值定理、Riemann 可積的判準都靠它。

命題 1.4 (有限檢驗的界限)：設 $U \subseteq \mathbb{R}$ 非空， $P: U \rightarrow \{\text{真}, \text{假}\}$ 為一敘述。若 $x_1, \dots, x_N \in U$ 有限且 $P(x_i)$ 皆為真，則不能推出 $\forall x \in U, P(x)$ 。反之，若某 $x_0 \in U$ 使 $P(x_0)$ 為假，則 $\forall x \in U, P(x)$ 為假。

證明：第一部分用反例策略。反設「有限檢驗皆真」蘊涵「全稱命題真」。取 $U = \mathbb{R}$ ， $P(x) = [x^2 \neq 2]$ 。取 $N = 1$ ， $x_1 = 0$ ， $P(0)$ 為真。若「有限檢驗皆真 $\Rightarrow$ 全稱真」成立，則對所有 $x \in \mathbb{R}$ ， $x^2 \neq 2$ 。但 $x = \sqrt{2}$ 滿足 $x^2 = 2$ ，矛盾。故一般地有限檢驗不蘊涵全稱。第二部分：全稱命題 $\forall x \in U, P(x)$ 為假，等價於 $\exists x \in U, \neg P(x)$ ； x_0 就是見證。■

第二部分的邏輯是直接的。真正要記住的是第一部分：有限檢驗一律不能替代全稱證明。這是本卷每一章的預設。

接下來是本章的主定理，它把「線性近似」與「誤差界」明確連起來。

定理 1.5 (一維線性化誤差界)：設 $-\infty < a < b < \infty$ ， $f: (a, b) \rightarrow \mathbb{R}$ 在 (a, b) 上二階連續可微 (記 $f \in C^2(a, b)$)。固定 $x_0 \in (a, b)$ ，取 $h \neq 0$ 使 $x_0 + h \in (a, b)$ 。定義餘項

$$r(h) := f(x_0 + h) - f(x_0) - f'(x_0)h.$$

則

$$|r(h)| \leq \frac{|h|^2}{2} \sup_{|t| \leq |h|} |f''(x_0 + t)|.$$

域與正則性：定理 1.5 採用 $f \in C^2(a, b)$ 作為充分假設；本卷不主張它對結論是必要的。若 f 只連續而不可微，本定理的 $f'(x_0)$ 無定義；若 f'' 在 x_0 附近無界，定理右端為無窮，界失去意義。 $x_0 + h$ 必須落在開區間 (a, b) 內。

證明：由微積分基本定理的兩次積分形式（對 C^2 函數成立），

$$f(x_0 + h) - f(x_0) - f'(x_0)h = \int_0^1 (1-t) f''(x_0 + th) h^2 dt.$$

推導：令 $g(t) = f(x_0 + th)$ ，則 $g(0) = f(x_0)$ ， $g'(t) = f'(x_0 + th)h$ ， $g''(t) = f''(x_0 + th)h^2$ 。對 g 用帶積分餘項的 Taylor 公式：

$$g(1) = g(0) + g'(0) + \int_0^1 (1-t)g''(t) dt.$$

代回即得。取絕對值，並用 $|h^2| = |h|^2$ 與積分不等式：

$$|r(h)| \leq |h|^2 \int_0^1 (1-t) |f''(x_0 + th)| dt \leq |h|^2 \sup_{|t| \leq |h|} |f''(x_0 + t)| \int_0^1 (1-t) dt.$$

而 $\int_0^1 (1-t) dt = 1/2$ ，故結論成立。■

直覺： $r(h)$ 是曲線與切線的差距。 C^2 保證差距以 $|h|^2$ 的階數縮小；係數是 $\frac{1}{2} \sup |f''|$ ，它衡量函數在該區間的「彎曲程度」。 f'' 越大，線性近似越不可靠。

推論 1.6（餘項的階）：在定理 1.5 的假設下， $\lim_{h \rightarrow 0} r(h)/|h| = 0$ ，即 $r(h) = o(|h|)$ 。

證明： $|r(h)|/|h| \leq \frac{1}{2}|h| \sup_{|t| \leq |h|} |f''(x_0 + t)|$ 。因 f'' 在 x_0 連續， $\sup \rightarrow |f''(x_0)|$ 有限， $|h| \rightarrow 0$ 時右端 $\rightarrow 0$ 。■

推論 1.6 只說餘項比 $|h|$ 高一階。若進一步假設 $f \in C^2$ 且 f'' 在 x_0 附近 Lipschitz，才可寫 $|r(h)| \leq C|h|^3$ ，這是更強的條件。本卷不接受「餘項 $o(|h|)$ 就寫成 $O(|h|^2)$ 」這類替換。

定義 1.7（單位與維度）：量 q 寫成「數值 $\times$ 單位」。 $f: U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ 一旦帶單位，Jacobian 元素 $J_{ij} = \partial f_i / \partial x_j$ 的單位是「 f_i 的單位 / x_j 的單位」。把不同單位的分量直接放進 Euclidean 範數，在物理上沒有意義；若要比較，必須先無因次化。

定義 1.8（證據標籤）：本卷每個斷言必須落在下列之一：

- **定義：**不證，只作為約定。
- **定理：**在所述域與正則性下已證為真。
- **數值證據：**在有限點上計算得到的觀察，不構成定理。
- **反例：**明確給出一點違反全稱命題。

寫報告時，每個關鍵數字旁註明標籤。這樣讀者能立刻分辨「這已經證過」與「這只是算過」。

逐步手算例題

例 1（手算線性化誤差）

設 $f(x) = e^x$ ， $x_0 = 0$ ， $h = 0.1$ 。

線性近似： $f(0) + f'(0)h = 1 + 1 \cdot 0.1 = 1.1$ 。真值： $e^{0.1} \approx 1.1051709181$ 。實際餘項： $r(h) \approx 0.0051709181$ 。

定理 1.5 的界： $\sup_{|t| \leq 0.1} |e^t| = e^{0.1} \approx 1.10517$ 。

$$\text{界} = \frac{(0.1)^2}{2} \cdot 1.10517 \approx 0.00553.$$

實際餘項確實 $\leq$ 界，且界與實際值同階，界沒有過鬆。

再取 $h = 0.01$ 。真值 $e^{0.01} \approx 1.0100501671$ ，線性近似 1.01，餘項 $\approx 5.017 \times 10^{-5}$ 。界： $0.5 \cdot 10^{-4}$ 。
 $e^{0.01} \approx 5.05 \times 10^{-5}$ 。餘項除以 $|h|$ 得 5.02×10^{-3} ，除以 $|h|^2$ 得 0.502。這與 $\frac{1}{2}f''(0) = \frac{1}{2}$ 一致，展示 $O(h^2)$ 的實際值。

例 2（域條件與 $\sup |f''|$ 無界的邊界性）

設 $f(x) = |x|^{3/2}$ ， $x_0 = 1$ ， $h = -1$ （即 $x_0 + h = 0$ ）。

$f'(x) = \frac{3}{2}x^{1/2}$ 對 $x > 0$ ，故 $f'(1) = 3/2$ 。線性近似： $f(1) + f'(1) \cdot (-1) = 1 - 1.5 = -0.5$ 。真值： $f(0) = 0$ 。餘項： $r(-1) = 0 - (-0.5) = 0.5$ 。

首先，取 $x_0 = 1, h = -1$ 時 $x_0 + h = 0$ 不在開區間 $(0, 1)$ 內，定理假設不成立。其次，若考慮 $x_0 + h$ 在 $(0, 1)$ 內的情形，雖然 $f \in C^2(0, 1)$ 成立（ $f''(x) = \frac{3}{4}x^{-1/2}$ 在 $(0, 1)$ 連續），但當區間包含靠近 0 的點時， f'' 無界， $\sup |f''| = +\infty$ ，定理的界退化為無資訊。若取 $x_0 = 1, h = -0.5$ （ $x_0 + h = 0.5$ ），則
 $\sup_{[0.5, 1]} |f''| = \frac{3}{4}(0.5)^{-1/2} \approx 1.0607$ ，界為 $\frac{1}{2}(0.25) \cdot 1.0607 \approx 0.1326$ 。真值 $f(0.5) \approx 0.35355$ ，線性近似 $1 - 0.75 = 0.25$ ，餘項 ≈ 0.10355 ，界成立。

這個例子說明：換 x_0 與 h 的範圍，同一函數可能落在定理範圍內、也可能落在定理範圍外。寫報告時要明說選定的區間。

手算步驟的證據標籤

例 1 與例 2 屬「數值證據」：計算的是具體值。定理 1.5 與推論 1.6 是「定理」：在所有 C^2 函數上成立。兩者不可混淆。

實作與程式

以下程式以標準庫 `math` 為主，展示三個功能：計算線性近似、檢查定理 1.5 的界、跑正常／邊界／故障三組情境。所有預期結果在紙上算出，不依賴未執行的外部套件。

```
import math

def linearize(f, fp, x0, h):
    """以 f(x0)+fp(x0)*h 近似 f(x0+h)，回傳近似與餘項。"""
    approx = f(x0) + fp(x0) * h
    actual = f(x0 + h)
    return approx, actual, actual - approx

def theorem_bound(fpp_sup, h):
    """定理 1.5 的界 0.5*|h|^2*fpp_sup，fpp_sup = sup |f''|。"""
    return 0.5 * (abs(h) ** 2) * fpp_sup

def run_case(name, f, fp, fpp_sup, x0, h, expect_pass=True):
    approx, actual, r = linearize(f, fp, x0, h)
    bound = theorem_bound(fpp_sup, h)
    ok = abs(r) <= bound + 1e-15 # 數值容差
    msg = "OK" if ok == expect_pass else "MISMATCH"
    print(f"[{name}] approx={approx:.10f} actual={actual:.10f} "
          f"r={r:.3e} bound={bound:.3e} tag={msg}")
    return ok

# 正常：e^x 在 x0=0, h=0.1
f = math.exp
fp = math.exp
fpp_sup = math.exp(0.1)
run_case("normal", f, fp, fpp_sup, 0.0, 0.1, expect_pass=True)

# 邊界：h=0 時餘項必為 0
run_case("boundary_h0", f, fp, fpp_sup, 0.0, 0.0, expect_pass=True)

# 故障案例：錯把 f'' 界取太小，應該使檢查失敗
run_case("failure_wrong_bound", f, fp, 0.1, 0.0, 0.3, expect_pass=False)

# 展示餘項對 |h| 的階
for h in (0.1, 0.05, 0.01):
    _, _, r = linearize(math.exp, math.exp, 0.0, h)
    print(f"h={h:.3f} r/|h|={abs(r)/h:.5e} r/|h|^2={abs(r)/(h*h):.5f}")
```

預期輸出（紙上核對）：

- 正常： $r \approx 5.1709 \times 10^{-3}$ ，界 $\approx 5.5259 \times 10^{-3}$ ，tag=OK。
- 邊界： $h = 0$ 時 $\text{approx} = \text{actual} = 1$ ， $r = 0$ ，界 $= 0$ ，tag=OK。
- 故障： $h = 0.3$ 時真值 $e^{0.3} \approx 1.34986$ ，近似 1.3， $r \approx 4.986 \times 10^{-2}$ 。用 $f''_{\text{sup}} = 0.1$ 算出的界 $= 0.5 \cdot 0.09 \cdot 0.1 = 4.5 \times 10^{-3}$ 。 $|r| > \text{界}$ ，tag=MISMATCH（因為 $\text{ok}=\text{False}$ 與 $\text{expect_pass}=\text{False}$ 相符，訊息顯示為 OK；讀者若把 `expect_pass` 改為 `True` 就會看到 MISMATCH）。這裡「故障」不是程式崩潰，而是證明界被輸入錯誤所破壞，我們希望程式把這件事標出來。
- 階檢驗： h 每減半， $r/|h|$ 大致減半， $r/|h|^2$ 大致穩定在 0.5 附近。

測試與預期結果

正常測試 (normal)：在定理 1.5 假設下取合法 x_0, h ，餘項 $\leq$ 界。用 $f = e^x$ 、 $x_0 = 0$ 、 $h = 0.1$ 驗證，期望 OK。

邊界測試 (boundary)： $h = 0$ 使餘項恰為 0，界也為 0。另一種邊界是 $x_0 + h$ 接近區間端點但仍在區間內，例如 $f(x) = \ln x$ 、 $x_0 = 1$ 、 $h = -0.9$ （即 $x_0 + h = 0.1 > 0$ ）。此時 $\sup_{[0.1, 1]} |f''| = \sup 1/x^2 = 100$ ，界 $= 0.5 \cdot 0.81 \cdot 100 = 40.5$ ，真值 $\ln(0.1) \approx -2.30259$ ，近似 $0 - 1 \cdot 0.9 = -0.9$ ，餘項 ≈ -1.40259 ，界仍成立但很鬆。這說明界是保證而非等號。

故障測試 (failure)：故意把 f'' 的上界低估（用 `fpp_sup=0.1` 對 e^x 、 $h = 0.3$ ），使實際餘項超出界。期望程式回報不一致。這正是把關：若檢查函式只看「有沒有拋錯」而不比較數字，就會漏掉這類錯誤。

故障測試 (型別故障)：把 h 由數值改成字串，Python 會拋 `TypeError`。這是語言的邊界，不是分析的邊界；報告中要區分「程式語言錯」與「數學假設不成立」。

反例與常見陷阱

陷阱 1：把充分條件當必要條件。「 f 可微則 f 連續」為真；反過來「 f 連續則 f 可微」為假（ $f(x) = |x|$ 於 0 連續卻不可微）。 f 可微是 f 連續的充分條件，不是必要條件。

陷阱 2：把 $\exists$ 和 $\forall$ 弄反。「 $\forall \varepsilon > 0, \exists N, \forall n \geq N, |a_n - L| < \varepsilon$ 」與「 $\exists N, \forall \varepsilon > 0, \forall n \geq N, |a_n - L| < \varepsilon$ 」不等價。後者要求數列最終恆等於 L ，前者只要求最終落在任意 ε 鄰域。

陷阱 3：用有限取樣「證明」全稱命題。例如用 $n = 1, \dots, 40$ 檢驗 $n^2 + n + 41$ 為質數皆為真， $n = 41$ 時 $= 41 \cdot 43$ 為合數，全稱命題被否證。取樣在前 40 點支持該命題，卻不構成任何證明。

陷阱 4：把 $o(|h|)$ 無條件升為 $O(|h|^2)$ 。 $o(|h|)$ 只說 $|r(h)|/|h| \rightarrow 0$ ；要寫成 $O(|h|^2)$ 需要更多正則性（例如 f'' 在 x_0 鄰域有界）。定理 1.5 之所以能寫 $O(|h|^2)$ ，是因為假設 $f \in C^2$ 使 f'' 局部有界。

陷阱 5：把有界閉區間與開區間混用。 $f(x) = 1/x$ 在 $(0, 1)$ 上連續但無界。定理 1.5 要求 $x_0 + h \in (a, b)$ ，若取 $a = 0$ 、 $x_0 + h = 0$ （端點）， f'' 的界在 $x \rightarrow 0^+$ 時爆掉，界失去意義。域必須明示。

陷阱 6：把不同單位的分量直接合成。若 f 的第一分量單位是 $^\circ\text{C}$ 、第二分量是 V ， $\|f(x)\|_2$ 的數值取決於單位制，不是物理量。要用 Euclidean 範數比較時，先無因次化。

AI、幾何與養殖案例

AI 向量。深度學習的誤差反向傳播就是鏈式法則的複合： $J_{g \circ f}(x) = J_g(f(x))J_f(x)$ 。若把 f 的輸出當作「特徵」、 g 的輸出當作「損失」，VJP 的形式 $J^T w$ 是反向傳播中的梯度訊號。後續卷章會用小型矩陣把這條等式從分量的角度驗算。這裡的關鍵訊息：鏈式法則是 $\forall x$ 的命題，不是「在某一批點上成立就可以」。用批次訓練集得到的損失下降曲線，是數值證據；推導鏈式法則要回到 Fréchet 導數的定義。

幾何向量。用右手座標 $X/Y/Z$ 描述剛體姿態時，旋轉矩陣 $R(t)$ 滿足 $R(t)^T R(t) = I$ 。線性化得到 $\dot{R}(t) = \omega^\wedge R(t)$ ，其中 $\omega^\wedge$ 是反對稱矩陣。這也是定理 1.5 的多維版本：在 C^2 條件下， $R(t + \Delta t) = R(t) + \dot{R}(t)\Delta t + o(|\Delta t|)$ 。一旦時間步長太大或接近奇異姿態，餘項不再是主導項，牛頓法的收斂證明就不能直接引用。

養殖案例（合成）。假設兩台感測器分別量水溫 T ($^\circ\text{C}$) 與溶氧 O (mg/L)。我們想用線性模型

$$\begin{pmatrix} \hat{T} \\ \hat{O} \end{pmatrix} = A \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} + b$$

由兩個控制輸入 u_1, u_2 預測讀值。這裡 A 的每個元素單位是「輸出 / 輸入」，例如 A_{11} 單位 $^\circ\text{C/s}$ 。若模型標稱值 A_0, b_0 與實際 A_*, b_* 不同，則預測誤差

$$e = A_* u + b_* - (A_0 u + b_0) = \Delta A u + \Delta b.$$

因為對 u 是仿射，對參數 (A, b) 是一階線性，餘項恰為零： $\Delta A u + \Delta b$ 就是全部誤差，不需要定理 1.5。但若真實響應是非線性的，例如 $\hat{T} = a_1 u_1 + a_2 u_1^2$ ，線性化就產生非零餘項，其界由二次項控制。

所有數值須附單位，明確標示是模擬。模型校準不是現場驗證，數值收斂不等於操作安全。AI agent 唯讀整理感測紀錄，不改設備、不投餌、不加藥。

習題

習題 1（手算）：設 $f(x) = \ln(1+x)$ ， $x_0 = 0$ ， $h = 0.2$ 。求 $\ln(1.2)$ 的線性近似值、真實值（可用 $\ln 1.2 \approx 0.1823216$ ）、實際餘項，並用定理 1.5 給出餘項的界。再取 $h = 0.05$ 重做一次，觀察餘項對 $|h|^2$ 的比例變化。

習題 2（程式）：改寫本章程式使它能接受任意 $f, f', f''_{\text{sup}}, x_0, h$ ，回傳 $(r, \text{bound}, r/\text{bound})$ 。對 $f(x) = \sin x$ 、 $x_0 = 0$ 、 $f''_{\text{sup}} = 1$ ，掃描 $h \in \{0.1, 0.05, 0.02, 0.01\}$ ，列出 $r/|h|^2$ 數列。你的結果是否與 $\frac{1}{2}f''(0) = 0$ 相容？請解釋 $\sin$ 在 $x_0 = 0$ 附近的特殊性。

習題 3（反例）：以下命題「若 f 在 (a, b) 內每一點可微，則 f' 在 (a, b) 連續」為假。請給出一個具體反例函數（提示：考慮 $f(x) = x^2 \sin(1/x)$ 且 $f(0) = 0$ ），說明 $f'(0)$ 之值與 $x \neq 0$ 時 $f'(x)$ 的表現，並指出此反例不違反「 f 可微則 f 連續」。若無法給出完整函數，請指出哪一個環節你無法完成。

習題 4（整合）：設兩個合成測量模型

$$\hat{y}_1 = a_1 x + a_2, \quad \hat{y}_2 = b_1 x^2 + b_2.$$

標稱 (a_1, a_2, b_1, b_2) 與實際值已知， x 為輸入。寫出誤差的一階線性近似（對參數），指出哪一項的餘項不為零，並說明若把 x 換成帶單位（例如 $^\circ\text{C}$ ）後， a_2 與 b_2 的單位分別是什麼。所有數字自擬，需附證據標籤。

習題解答

解答 1： $f(0) = 0$ ， $f'(x) = 1/(1+x)$ ， $f'(0) = 1$ 。 $h = 0.2$ 時線性近似 $= 0.2$ 。真值 ≈ 0.1823216 。餘項 ≈ -0.0176784 。 $f''(x) = -1/(1+x)^2$ ， $\sup_{[0,0.2]} |f''| = 1$ （取 $x = 0$ ），界 $= 0.5 \cdot 0.04 \cdot 1 = 0.02$ 。 $|r| \approx 0.0177 \leq 0.02$ 。

$h = 0.05$ 時線性近似 $= 0.05$ ，真值 $\ln 1.05 \approx 0.0487902$ ，餘項 ≈ -0.0012098 ，界 $= 0.5 \cdot 0.0025 \cdot 1 = 0.00125$ 。 $r/|h|^2 \approx -0.4839$ ，接近 $-\frac{1}{2}f''(0) = -0.5$ 。 $h = 0.2$ 時 $r/h^2 \approx -0.44196$ ，稍偏離因為 f'' 隨 x 變化。■

解答 2： $f = \sin$ 、 $f' = \cos$ 、 $f''_{\sup} = 1$ 。

$|h|$ 近似 $\sin h \approx h$ | 真值 $|r|$ $|r|/|h|^2$ | 0.1 | 0.1 | 0.0998334 | -1.6658×10^{-4} | -0.016658 |
 $|0.05|$ $|0.05|$ $|0.0499792|$ -2.084×10^{-5} | -0.008335 | $|0.02|$ $|0.02|$ $|0.0199987|$ -1.333×10^{-6} |
 -0.003333 | $|0.01|$ $|0.01|$ $|0.00999983|$ -1.667×10^{-7} | -0.001667 |

觀察： $r/|h|^2 \rightarrow 0$ ，與 $\frac{1}{2}f''(0) = 0$ 相容。原因是 $\sin$ 在 0 附近的三階展開 $\sin h = h - h^3/6 + O(h^5)$ ，餘項實際是 $O(h^3)$ ，所以除以 h^2 仍趨零。這說明 $O(h^2)$ 的「最高階」必須以實際函數為準， $\frac{1}{2}f''(0) = 0$ 時不能提供 h^2 級的係數。■

解答 3：令 $f(0) = 0$ ， $f(x) = x^2 \sin(1/x)$ 對 $x \neq 0$ 。在 $x = 0$ ： $\left| \frac{f(h)-f(0)}{h} \right| = |h \sin(1/h)| \leq |h| \rightarrow 0$ ，故 $f'(0) = 0$ 。對 $x \neq 0$ ， $f'(x) = 2x \sin(1/x) - \cos(1/x)$ 。取 $x_n = 1/(2\pi n)$ 則 $\cos(1/x_n) = 1$ ， $f'(x_n) = -1 + 2x_n \sin(2\pi n) = -1$ ；取 $x_n = 1/((2n+1)\pi)$ 則 $\cos(1/x_n) = -1$ ， $f'(x_n) = 1 + 2x_n \cdot 0 = 1$ 。故 $x \rightarrow 0$ 時 $f'(x)$ 無極限， f' 在 0 不連續。此反例不違反「可微則連續」： f 在 0 可微、在 0 連續，命題仍真；被否證的是「可微函數的導函數必連續」這個更強的斷言。■

解答 4：令標稱 $(a_1, a_2, b_1, b_2) = (2.0, 0.5, 1.0, -0.3)$ ，實際 $(a'_1, a'_2, b'_1, b'_2) = (2.05, 0.52, 0.98, -0.28)$ ，輸入 $x = 1.5$ 。一階線性誤差：

$$\Delta \hat{y}_1 \approx x \Delta a_1 + \Delta a_2 = 1.5(0.05) + 0.02 = 0.095,$$

$$\Delta \hat{y}_2 \approx x^2 \Delta b_1 + \Delta b_2 = 2.25(-0.02) + 0.02 = -0.025.$$

因為 $\hat{y}_1$ 對參數線性，餘項為 0； $\hat{y}_2$ 對參數也線性，餘項亦為 0。被忽略的是對 x 的非線性項：若把 $\hat{y}_2$ 在 x 處線性化，餘項為 $b_1 h^2$ （ h 為 x 的擾動），級別 $O(h^2)$ 。

單位標籤：設 x 單位 $^{\circ}\text{C}$ ， $\hat{y}_1$ 單位 mg/L ，則 a_1 單位 $\text{mg/L}/^{\circ}\text{C}$ ， a_2 單位 mg/L 。 $\hat{y}_2$ 若單位 pH ，則 b_1 單位 $\text{pH}/(^{\circ}\text{C})^2$ ， b_2 單位 pH 。將 a_2 與 b_2 相加沒有物理意義。所有數字屬合成範例，證據標籤：數值證據+對參數線性的定義性事實。■

本章小結

分析與線性代數的介面是「量詞」。有限維代數命題可以在有限步驟內算出答案；分析命題涉及全稱量詞，必須用定義與定理來確立真值。有限數值檢驗可以支持、可以否證，但不能證明全稱命題；一個反例足以否證全稱命題，這正是命題 1.4 的內容。

誤差要分清楚三層：函數的線性化餘項、帶單位與維度的一階傳播、以及把這些數字貼上定義／定理／數值證據／反例的標籤。定理 1.5 在 C^2 域與局部有界 f'' 的正則性下給出 $|r(h)| \leq \frac{1}{2}|h|^2 \sup |f''|$ ，推論 1.6 給出 $r = o(|h|)$ ，但 $o(|h|)$ 不可無條件提升為 $O(|h|^2)$ 。

實數完備性是 $\mathbb{R}$ 與 $\mathbb{Q}$ 的分界。後面幾章靠它建立數列收斂、連續函數的極值定理、積分存在性。本章的合成感測案例示範了如何把「單位、維度、有效範圍、證據標籤」放進一份可稽核的報告。程式只作數值支持，不作證明；未執行的程式輸出以預期值標示，不虛構時間、測試或收斂階。

參考來源

- [A1] Jiří Lebl: *Basic Analysis*，作者目錄與教材入口，<https://www.jirka.org/ra/>。2026-10-05 已取得作者首頁；未讀完全部教材 PDF，亦未逐條查證本書引用的定理編號。
- [A2] MIT OCW 18.100A *Real Analysis*，<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>。已取得課程概要，未觀看完整課程。
- [A3] MIT OCW 18.02SC *Multivariable Calculus*，<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>。已取得課程概要，未觀看完整課程。
- [A4] JAX *Autodiff Cookbook*: JVP 與 VJP，https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html。已取得文件頁面，未在本機安裝或執行 JAX；本卷核心不依賴 JAX。
- [A5] SciPy `linalg.expm` 文件，<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>。延伸參考，未執行 SciPy。
- [A6] SciPy `optimize.minimize` 文件，<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>。延伸參考，未執行 SciPy。

以上外部資源的線上版本可能與本機套件版本不同。本卷所有程式以標準庫與提供的小型 NumPy 環境為最小需求；未執行即標示預期結果，不虛構時間或測試。

第02章 數列、Cauchy條件與級數橋接

學習目標與先備知識

有限串列可以逐項檢查，但數列與級數包含無窮多項，不能靠前若干項完成證明。本章以量詞、尾項界及實數完備性建立無窮過程的基本語言。完成本章後，讀者應能：

1. 使用 ε - N 定義證明實數數列收斂。
2. 寫出「不收斂到指定值」的量詞否定。
3. 證明數列極限唯一。
4. 使用 Cauchy 條件描述數列尾端的內部穩定性。
5. 區分「收斂蘊含 Cauchy」與「Cauchy 蘊含收斂」所需條件。
6. 將無窮級數定義為部分和數列的極限。
7. 分辨必要條件、充分條件、絕對收斂與條件收斂。
8. 以解析尾項界控制截斷誤差，並區分截斷誤差與浮點誤差。
9. 說明有限計算不能單獨證明無窮收斂命題。
10. 解釋條件收斂級數為何不可任意重排。

先備知識包括實數、絕對值、三角不等式、有限和及等比公式。本章以實數數列為主；討論一般度量空間時會明確使用距離 d 。

問題與直覺

考慮數列

$$1, \quad 1.4, \quad 1.41, \quad 1.414, \quad 1.4142, \dots$$

它看起來逼近 $\sqrt{2}$ 。然而，「看起來接近」不是數學定義。嚴格主張必須回答：

對任意指定的正誤差，是否存在一個索引，使此後所有項都落在誤差範圍內？

關鍵是「任意誤差」與「此後所有項」。只看到第十項或第百萬項接近某值，不能排除更晚的項突然遠離。

有時候候選極限未知。例如迭代演算法產生 $x_1, x_2, \dots$ ，真解未必可直接計算。這時可詢問：後期任意兩項是否彼此接近？Cauchy 條件把這個問題寫成精確量詞。

但是，尾端彼此接近不一定保證極限仍在原空間內。有理數可以愈來愈精確地逼近 $\sqrt{2}$ ，但 $\sqrt{2} \notin \mathbb{Q}$ 。因此，Cauchy 條件與極限存在之間還需要完備性。

級數則是數列理論的重要應用。符號

$$\sum_{k=1}^{\infty} a_k$$

不是一次完成的「無窮次加法」，而是先定義部分和

$$s_n = \sum_{k=1}^n a_k,$$

再研究數列 (s_n) 是否收斂。這就是數列與級數之間的橋接。

定義、定理與推導

1. 數列與極限

定義 2.1 (實數數列)

實數數列是函數 $a: \mathbb{N} \rightarrow \mathbb{R}$ ，通常寫成 $(a_n)_{n \geq 1}$ 。

定義 2.2 (實數數列收斂)

數列 (a_n) 收斂到 $L \in \mathbb{R}$ ，若

$$\forall \varepsilon > 0, \exists N \in \mathbb{N}, \forall n \geq N, \quad |a_n - L| < \varepsilon.$$

記作 $a_n \rightarrow L$ 。

量詞順序不能交換。門檻 N 可以依賴 ε ，但一旦選定，條件必須對所有 $n \geq N$ 成立。

「 a_n 不收斂到 L 」的否定是

$$\exists \varepsilon_0 > 0, \forall N \in \mathbb{N}, \exists n \geq N, \quad |a_n - L| \geq \varepsilon_0.$$

所以要推翻候選極限 L ，必須找到一個固定正誤差，使尾端無論從何處開始，仍可找到違反誤差要求的項。

2. 極限唯一性

命題 2.1 (極限唯一)

設 (a_n) 為實數數列。若 $a_n \rightarrow L$ 且 $a_n \rightarrow M$ ，則 $L = M$ 。

證明

反設 $L \neq M$ ，令

$$\varepsilon = \frac{|L - M|}{3} > 0.$$

由 $a_n \rightarrow L$ ，存在 N_L ，使 $n \geq N_L$ 時，

$$|a_n - L| < \varepsilon.$$

由 $a_n \rightarrow M$ ，存在 N_M ，使 $n \geq N_M$ 時，

$$|a_n - M| < \varepsilon.$$

取 $N = \max\{N_L, N_M\}$ 。對任意 $n \geq N$ ，三角不等式給出

$$|L - M| \leq |L - a_n| + |a_n - M| < 2\varepsilon = \frac{2}{3}|L - M|.$$

這與 $|L - M| > 0$ 矛盾，因此 $L = M$ 。□

這是對無限尾端有效的量詞證明，不是由有限取樣猜測極限。

3. Cauchy 數列與完備性

定義 2.3 (Cauchy 數列)

設 (X, d) 為度量空間。數列 (x_n) 稱為 Cauchy 數列，若

$$\forall \varepsilon > 0, \exists N \in \mathbb{N}, \forall m, n \geq N, \quad d(x_m, x_n) < \varepsilon.$$

在 $\mathbb{R}$ 中， $d(x, y) = |x - y|$ ，故條件成為

$$|a_m - a_n| < \varepsilon.$$

Cauchy 條件不必預先知道極限，只比較尾端各項之間的距離。

定理 2.2 (收斂蘊含 Cauchy)

設 (X, d) 為度量空間。若 $x_n \rightarrow x \in X$ ，則 (x_n) 是 Cauchy 數列。

證明

給定 $\varepsilon > 0$ 。由 $x_n \rightarrow x$ ，存在 N ，使所有 $k \geq N$ 均滿足

$$d(x_k, x) < \frac{\varepsilon}{2}.$$

因此，對任意 $m, n \geq N$ ，

$$d(x_m, x_n) \leq d(x_m, x) + d(x, x_n) < \varepsilon.$$

故 (x_n) 是 Cauchy 數列。□

這個方向只需三角不等式，不要求空間完備。

定義 2.4 (完備度量空間)

若度量空間中的每個 Cauchy 數列都收斂到該空間內的一點，則稱該空間完備。

定理 2.3 (實數的 Cauchy 判準)

$\mathbb{R}$ 配備通常距離時是完備的。因此，對實數數列，

$$(a_n) \text{ 收斂} \iff (a_n) \text{ 是 Cauchy 數列}.$$

兩個方向的依據不同：

- 收斂 $\Rightarrow$ Cauchy：任意度量空間皆成立。
- Cauchy $\Rightarrow$ 收斂：需要所在空間完備。

本章引用實數完備性這項標準結果，不用有限小數展開冒充證明。相對地， $\mathbb{Q}$ 不完備；逼近 $\sqrt{2}$ 的有理小數截斷在 $\mathbb{Q}$ 中是 Cauchy 數列，卻沒有有理極限。

4. 級數是部分和數列

定義 2.5 (級數收斂)

給定實數數列 (a_k) ，令

$$s_n = \sum_{k=1}^n a_k.$$

若 (s_n) 收斂到 S ，則稱 $\sum_{k=1}^{\infty} a_k$ 收斂，並寫成

$$\sum_{k=1}^{\infty} a_k = S.$$

定理 2.4 (級數的 Cauchy 判準)

實數級數 $\sum_{k=1}^{\infty} a_k$ 收斂若且唯若

$$\forall \varepsilon > 0, \exists N, \forall m > n \geq N, \left| \sum_{k=n+1}^m a_k \right| < \varepsilon.$$

因為

$$s_m - s_n = \sum_{k=n+1}^m a_k,$$

所以這正是部分和數列的 Cauchy 條件，再由 $\mathbb{R}$ 完備性得到結論。它控制任意有限尾段和，不只是單項或相鄰兩個部分和。

命題 2.2 (項趨零是必要條件)

若 $\sum a_k$ 收斂，則 $a_n \rightarrow 0$ 。

證明

若部分和 $s_n \rightarrow S$ ，則 $s_{n-1} \rightarrow S$ ，而

$$a_n = s_n - s_{n-1}.$$

所以 $a_n \rightarrow S - S = 0$ 。□

反方向不成立。雖然 $1/n \rightarrow 0$ ，調和級數 $\sum 1/n$ 仍發散。因此項趨零只是必要條件，不是充分條件。

5. 絕對收斂與條件收斂

定義 2.6

- 若 $\sum |a_k|$ 收斂，則 $\sum a_k$ 稱為絕對收斂。
- 若 $\sum a_k$ 收斂但 $\sum |a_k|$ 發散，則稱為條件收斂。

定理 2.5 (絕對收斂蘊含收斂)

對實數或複數級數，絕對收斂足以推出原級數收斂。

證明

若 $\sum |a_k|$ 收斂，則給定 $\varepsilon > 0$ ，存在 N ，使任意 $m > n \geq N$ 均有

$$\sum_{k=n+1}^m |a_k| < \varepsilon.$$

由三角不等式，

$$\left| \sum_{k=n+1}^m a_k \right| \leq \sum_{k=n+1}^m |a_k| < \varepsilon.$$

所以原級數的部分和是 Cauchy 數列。由實數或複數的完備性，原級數收斂。□

絕對收斂級數可任意重排而不改變總和。條件收斂級數沒有這項保證。Riemann 重排定理指出，實數條件收斂級數可適當重排，使其收斂到任意指定實數，甚至使其發散。本章引用此結果，不展開完整證明。

6. 尾項與有限精度

若級數和為 S ，取到第 n 項的部分和為 s_n ，則尾項為

$$R_n = S - s_n = \sum_{k=n+1}^{\infty} a_k.$$

若程式算得浮點近似 $\hat{s}_n$ ，總誤差可分解為

$$S - \hat{s}_n = (S - s_n) + (s_n - \hat{s}_n).$$

第一項是截斷誤差，第二項是浮點表示與累加誤差。增加項數通常降低截斷誤差，但不保證總浮點誤差單調降低。

對 $|r| < 1$ 的等比級數，

$$\sum_{k=0}^{\infty} ar^k = \frac{a}{1-r},$$

且

$$R_n = \frac{ar^{n+1}}{1-r}, \quad |R_n| \leq \frac{|a||r|^{n+1}}{1-|r|}.$$

這是解析尾項界，不是由若干小數輸出猜測而來。

逐步手算例題

例題一：以定義證明有理式數列收斂

證明

$$a_n = \frac{3n-2}{n+1} \rightarrow 3.$$

先計算

$$\left| \frac{3n-2}{n+1} - 3 \right| = \frac{5}{n+1}.$$

給定 $\varepsilon > 0$ ，取

$$N = \left\lceil \frac{5}{\varepsilon} \right\rceil + 1.$$

若 $n \geq N$ ，則 $n > 5/\varepsilon$ ，所以

$$|a_n - 3| = \frac{5}{n+1} < \varepsilon.$$

因此依定義 $a_n \rightarrow 3$ 。 N 不必最小，只需對所有 $n \geq N$ 有效。

例題二：等比級數的尾項界

考慮

$$\sum_{k=0}^{\infty} \left(\frac{1}{3}\right)^k.$$

取到第 n 項的部分和為

$$s_n = \frac{3}{2} \left(1 - 3^{-(n+1)}\right),$$

所以

$$S = \frac{3}{2}, \quad R_n = \frac{1}{2 \cdot 3^n}.$$

要求 $|R_n| < 10^{-4}$ 等價於 $3^n > 5000$ 。因為

$$3^7 = 2187, \quad 3^8 = 6561,$$

所以最小可用索引為 $n = 8$ 。這由尾項公式保證，不是因顯示值暫時不變。

例題三：條件收斂級數的重排

交錯調和級數滿足

$$1 - \frac{1}{2} + \frac{1}{3} - \frac{1}{4} + \cdots = \log 2.$$

將它按「兩個正項、一個負項」排列：

$$1 + \frac{1}{3} - \frac{1}{2} + \frac{1}{5} + \frac{1}{7} - \frac{1}{4} + \cdots.$$

前 N 組的組端部分和為

$$T_N = \sum_{j=1}^{2N} \frac{1}{2j-1} - \sum_{j=1}^N \frac{1}{2j}.$$

令 $H_n = \sum_{k=1}^n 1/k$ 。則

$$\sum_{j=1}^{2N} \frac{1}{2j-1} = H_{4N} - \frac{1}{2}H_{2N},$$

以及

$$\sum_{j=1}^N \frac{1}{2j} = \frac{1}{2}H_N.$$

因此

$$T_N = H_{4N} - \frac{1}{2}H_{2N} - \frac{1}{2}H_N.$$

由標準結果 $H_n = \log n + \gamma + o(1)$ ，故

$$\begin{aligned} T_N &= H_{4N} - \frac{1}{2}H_{2N} - \frac{1}{2}H_N \\ &= (\log(4N) + \gamma + o(1)) - \frac{1}{2}(\log(2N) + \gamma + o(1)) - \frac{1}{2}(\log N + \gamma + o(1)) \\ &= \frac{3}{2}\log 2 + o(1). \end{aligned}$$

因此 $T_N \rightarrow \frac{3}{2}\log 2$ 。

還須由組端子數列推回完整部分和數列。第 N 組的三項為

$$\frac{1}{4N-3}, \quad \frac{1}{4N-1}, \quad -\frac{1}{2N}.$$

任一組內部分和與該組端部分和之差，其絕對值至多為該組三項絕對值之和：

$$\frac{1}{4N-3} + \frac{1}{4N-1} + \frac{1}{2N} \rightarrow 0.$$

因此完整重排部分和數列也收斂到 $3\log 2/2$ ，與原和 $\log 2$ 不同。這具體展示了條件收斂級數的無限重排可能改變總和；有限次交換則不會改變收斂級數的和。

實作與程式

以下程式只使用 Python 標準庫並適合 CPU。撰稿時未實際執行，後述結果均為預期或待執行核對。

```
import math

def require_nonnegative_int(n, name="n"):
    if isinstance(n, bool) or not isinstance(n, int):
```

```

        raise TypeError(f"{name} 必須為整數且不可為布林值")
    if n < 0:
        raise ValueError(f"{name} 必須為非負整數")

def geometric_partial(a, r, n):
    """直接累加  $\sum_{k=0}^n a \cdot r^{**k}$ 。"""
    require_nonnegative_int(n)
    total = 0.0
    term = float(a)
    for _ in range(n + 1):
        total += term
        term *= r
    return total

def geometric_tail_bound(a, r, n):
    """當  $|r| < 1$  時，回傳取到第  $n$  項後的絕對尾項界。"""
    require_nonnegative_int(n)
    a = float(a)
    r = float(r)
    if not math.isfinite(a) or not math.isfinite(r):
        raise ValueError("a 與 r 必須為有限數")
    if abs(r) >= 1.0:
        raise ValueError("尾項界要求  $|r| < 1$ ")
    return abs(a) * abs(r) ** (n + 1) / (1.0 - abs(r))

def alternating_harmonic(n):
    """計算  $\sum_{k=1}^n (-1)^{(k+1)}/k$ 。"""
    require_nonnegative_int(n)
    if n == 0:
        raise ValueError("n 必須至少為 1")
    return math.fsum(
        (1.0 if k % 2 else -1.0) / k
        for k in range(1, n + 1)
    )

def rearranged_two_positive_one_negative(groups):
    """計算交錯調和級數前 groups 個二正一負組。"""
    require_nonnegative_int(groups, "groups")
    terms = []
    for j in range(1, groups + 1):
        terms.append(1.0 / (4 * j - 3))
        terms.append(1.0 / (4 * j - 1))
        terms.append(-1.0 / (2 * j))
    return math.fsum(terms)

def cauchy_window(values, start, tolerance):
    """
    檢查有限視窗 values[start:] 中任意兩值是否相差小於 tolerance。
    這只提供有限證據，不證明無窮 Cauchy 條件。
    """
    if isinstance(start, bool) or not isinstance(start, int):
        raise TypeError("start 必須為整數且不可為布林值")
    tolerance = float(tolerance)
    if not math.isfinite(tolerance) or tolerance <= 0.0:

```

```

        raise ValueError("tolerance 必須為有限正數")
    if not 0 <= start < len(values):
        raise IndexError("start 超出資料範圍")

    tail = [float(x) for x in values[start:]]
    if not all(math.isfinite(x) for x in tail):
        raise ValueError("視窗資料必須全部為有限數")
    return max(tail) - min(tail) < tolerance

def run_examples():
    exact = 1.5
    for n in (0, 1, 8, 20):
        approx = geometric_partial(1.0, 1.0 / 3.0, n)
        bound = geometric_tail_bound(1.0, 1.0 / 3.0, n)
        print("geometric", n, approx, abs(exact - approx), bound)

    for n in (10, 100, 10000):
        approx = alternating_harmonic(n)
        print("alternating", n, approx, abs(approx - math.log(2.0)))

    target = 1.5 * math.log(2.0)
    for groups in (10, 100, 10000):
        approx = rearranged_two_positive_one_negative(groups)
        print("rearranged", groups, approx, abs(approx - target))

if __name__ == "__main__":
    run_examples()

```

`math.fsum` 通常比逐項使用 `total += term` 更能抑制累加誤差，但它仍是有限精度浮點運算。有限 Cauchy 視窗只能描述已提供資料，不能證明未完整提供的無窮數列是 Cauchy 數列。

重排程式只提供數值核對。重排極限的證明來自調和數漸近式及組內差趨零，而不是列印結果。

測試與預期結果

以下測試未實際執行。

正常測試

```

s = geometric_partial(1.0, 1.0 / 3.0, 8)
b = geometric_tail_bound(1.0, 1.0 / 3.0, 8)

assert abs(1.5 - s) <= b + 1e-15
assert b < 1e-4

x = alternating_harmonic(10000)
assert abs(x - math.log(2.0)) < 1.0 / 10001.0

```

預期通過。幾何尾項解析上為

$$\frac{1}{2 \cdot 3^8} \approx 7.62 \times 10^{-5}.$$

交錯調和級數測試使用交錯級數餘項界。

重排結果改列為待執行的數值檢查，不設定未推導的固定斷言門檻：

```
groups = 10000
y = rearranged_two_positive_one_negative(groups)
target = 1.5 * math.log(2.0)
print(groups, y, abs(y - target))
```

解析證明已保證實數部分和趨向 `target`；這段程式只觀察指定浮點截斷，不能反過來證明極限。

邊界測試

```
assert geometric_partial(2.0, 0.5, 0) == 2.0
assert geometric_tail_bound(2.0, 0.0, 0) == 0.0
assert rearranged_two_positive_one_negative(0) == 0.0

assert cauchy_window(
    [1.0, 0.5, 0.25, 0.125],
    2,
    0.2
)
```

預期通過。 $n = 0$ 表示只取第零項，不是空和。有限視窗 `[0.25, 0.125]` 的最大差為 0.125；這仍不是無窮 Cauchy 證明。

故障測試

```
for bad_n in ("10", 2.5, True):
    try:
        geometric_partial(1.0, 0.5, bad_n)
        raise AssertionError("應拒絕非整數或布林索引")
    except TypeError:
        pass

    try:
        geometric_tail_bound(1.0, 1.0, 10)
        raise AssertionError("應拒絕 |r| >= 1")
    except ValueError:
        pass

    try:
        alternating_harmonic(0)
        raise AssertionError("應拒絕 n = 0")
    except ValueError:
        pass

    try:
```



```

    cauchy_window([1.0, 0.5], 0, 0.0)
    raise AssertionError("應拒絕非正容許誤差")
except ValueError:
    pass

try:
    cauchy_window([1.0, float("nan")], 0, 0.1)
    raise AssertionError("應拒絕非有限資料")
except ValueError:
    pass

```

預期均捕捉指定例外。型別檢查先於範圍檢查；布林值雖是 Python 中 `int` 的子類，也被明確排除。

反例與常見陷阱

1. 有限前綴不能決定無窮尾端

假設只觀察到有限資料

$$a_1, a_2, \dots, a_N.$$

可構造收斂延伸

$$a_{N+k} = 1, \quad k \geq 1,$$

也可構造發散延伸

$$a_{N+k} = (-1)^k, \quad k \geq 1.$$

第二種延伸在 $N + 1$ 項之後輪流取 -1 與 1 ，因此含兩個分別趨向 -1 與 1 的常數子列，整列不收斂；有限前綴（包含 $N = 0$ 的無前綴情形）不影響這個尾端振盪。兩者有完全相同的已觀察前綴，卻有不同的收斂行為。因此，有限資料本身不能決定任意未知無窮延伸是否收斂。

若已知數列由特定公式、遞迴或定理產生，有限計算仍可配合解析界使用；不能做的是把圖形平坦或顯示值不變直接當成證明。

2. 相鄰差趨零不等於 Cauchy

令

$$s_n = \sum_{k=1}^n \frac{1}{k}.$$

雖然

$$s_{n+1} - s_n = \frac{1}{n+1} \rightarrow 0,$$

但

$$s_{2n} - s_n = \sum_{k=n+1}^{2n} \frac{1}{k} \geq n \frac{1}{2n} = \frac{1}{2}.$$

尾端仍能累積出固定差距。因此只檢查相鄰差不足以驗證 Cauchy 條件。

3. 項趨零不保證級數收斂

$1/n \rightarrow 0$ ，但 $\sum 1/n$ 發散。必要條件不能誤當充分條件。

4. Cauchy 收斂需要完備性

有理 Cauchy 數列可能只在實數中收斂到無理數。不能省略「極限屬於原空間」及「空間完備」的條件。

5. 浮點值停止改變不等於尾項為零

當新項小於目前浮點數附近的表示間距時，`total + term` 可能仍等於 `total`。這表示有限精度吸收了變化，不表示數學上的項或尾項為零。

6. 條件收斂不可任意拆分

條件收斂級數的正項和與負項絕對值和可能各自發散。把它們分成兩個無窮和再相減會形成未定義的 $\infty - \infty$ 。無限重排也不是有限次交換，必須另有定理支持。

AI、幾何與養殖案例

1. AI 迭代的停止條件

迭代參數可形成向量數列 $x_n \in \mathbb{R}^d$ 。常見規則

$$\|x_{n+1} - x_n\|_2 < \tau$$

只檢查一個相鄰差，不能證明 (x_n) 是 Cauchy 數列，也不能證明已到達最優解。調和部分和就是相鄰差趨零但整體不收斂的反例。

數值報告應同時列出最近視窗變化、殘差、停止容許量、最大迭代數、浮點型別，以及理論收斂條件是否成立。缺乏定理假設時，這些仍只是數值證據。

2. 幾何中的反覆縮放

設 $v \in \mathbb{R}^d$ ，位移依序為

$$v, \quad rv, \quad r^2v, \dots, \quad |r| < 1.$$

累積位置為

$$p_n = p_0 + \sum_{k=0}^n r^k v,$$

極限位置為

$$p_\infty = p_0 + \frac{1}{1-r} v.$$

在 Euclidean 範數下，

$$\|p_\infty - p_n\|_2 = \left| \frac{r^{n+1}}{1-r} \right| \|v\|_2.$$

因所有位移都沿同一向量，向量誤差可化為純量等比尾項。若 $r < 0$ ，方向交替；只看長度可能掩蓋振盪。

3. 合成養殖感測平均

假設唯讀流程每分鐘取得合成溶氧值 y_n ，單位為 mg/L。取無因次權重

$$w_k = (1-r)r^k, \quad 0 < r < 1.$$

截斷估計為

$$\hat{y}_N = \sum_{k=0}^N w_k y_{N-k}.$$

因權重無因次，估計值仍以 mg/L 為單位。若

$$|y_n| \leq M \text{ mg/L},$$

則遺漏尾端的誤差有界於

$$M \sum_{k=N+1}^{\infty} (1-r)r^k = Mr^{N+1} \text{ mg/L}.$$

這是模型條件成立時的截斷界，不是感測器校準證明，也不表示現場安全。唯讀分析不應據此直接控制曝氣、投餌或加藥。

習題

習題一：手算與定義

用 ε - N 定義證明

$$a_n = \frac{2n+7}{n+3} \rightarrow 2.$$

再對 $\varepsilon = 10^{-3}$ 求最小正整數門檻 N 。

習題二：程式與尾項

考慮

$$\sum_{k=0}^{\infty} 2 \left(\frac{1}{4} \right)^k.$$

1. 求精確總和。
2. 求最小非負整數 n ，使截斷誤差小於 10^{-6} 。
3. 說明如何以本章程式核對，以及為何程式輸出不是收斂證明。

習題三：反例

判斷下列主張真假；若為假，給出反例。

1. 若 $|a_{n+1} - a_n| \rightarrow 0$ ，則 (a_n) 是 Cauchy 數列。
2. 若 $\sum a_n$ 收斂，則 $a_n \rightarrow 0$ 。
3. 若 $a_n \rightarrow 0$ ，則 $\sum a_n$ 收斂。
4. 每個有理數 Cauchy 數列都收斂到有理數。

習題四：整合應用

設合成資料滿足 $|y_n| \leq 12 \text{ mg/L}$ ，權重為

$$w_k = 0.2(0.8)^k.$$

希望忽略 $k > N$ 的資料所造成的誤差小於 0.01 mg/L 。

1. 推導誤差上界。
2. 求最小可用整數 N 。
3. 說明結論能證明與不能證明什麼。

習題五：Cauchy 尾段

證明調和部分和

$$s_n = \sum_{k=1}^n \frac{1}{k}$$

不是 Cauchy 數列，並明確寫出固定的 ε_0 。

習題解答

解答一

$$\left| \frac{2n+7}{n+3} - 2 \right| = \frac{1}{n+3}.$$

給定 $\varepsilon > 0$ ，例如可取

$$N = \left\lceil \frac{1}{\varepsilon} \right\rceil + 1.$$

若 $n \geq N$ ，則 $n > 1/\varepsilon$ ，所以

$$|a_n - 2| = \frac{1}{n+3} < \varepsilon.$$

故 $a_n \rightarrow 2$ 。

當 $\varepsilon = 10^{-3}$ 時，對所有 $n \geq N$ 成立的條件由最早一項 $n = N$ 決定：

$$\frac{1}{N+3} < 10^{-3}.$$

因此 $N+3 > 1000$ ，即 $N > 997$ ，最小正整數門檻為

$$N = 998.$$

解答二

總和為

$$S = \frac{2}{1 - 1/4} = \frac{8}{3}.$$

尾項為

$$|R_n| = \frac{2(1/4)^{n+1}}{1 - 1/4} = \frac{8}{3} 4^{-(n+1)}.$$

當 $n = 9$ 時，

$$|R_9| = \frac{8}{3 \cdot 4^{10}} \approx 2.54 \times 10^{-6},$$

仍太大。當 $n = 10$ 時，

$$|R_{10}| = \frac{8}{3 \cdot 4^{11}} \approx 6.36 \times 10^{-7},$$

符合要求。尾項隨 n 嚴格遞減，所以 $n = 9$ 不足也排除了所有更小索引，故最小值是 $n = 10$ 。

可用下列程式核對：

```
s = geometric_partial(2.0, 0.25, 10)
b = geometric_tail_bound(2.0, 0.25, 10)
print(s, b, abs(8.0 / 3.0 - s))
```

預期 **b** 小於 10^{-6} 。收斂證明來自等比級數定理；程式只核對指定截斷。

解答三

1. 假。取 $a_n = H_n = \sum_{k=1}^n 1/k$ 。相鄰差趨零，但 (H_n) 不是 Cauchy。
2. 真。若部分和 $s_n \rightarrow S$ ，則 $a_n = s_n - s_{n-1} \rightarrow 0$ 。
3. 假。取 $a_n = 1/n$ 。項趨零，但調和級數發散。
4. 假。取一系列有理數逼近 $\sqrt{2}$ 。它在 $\mathbb{Q}$ 中是 Cauchy 數列，但沒有有理極限。

解答四

遺漏尾端的誤差滿足

$$\left| \sum_{k=N+1}^{\infty} 0.2(0.8)^k y_{n-k} \right| \leq 12 \sum_{k=N+1}^{\infty} 0.2(0.8)^k \\ = 12(0.8)^{N+1} \text{ mg/L}.$$

要求

$$12(0.8)^{N+1} < 0.01,$$

即

$$(0.8)^{N+1} < \frac{1}{1200}.$$

因 $\log 0.8 < 0$ ，取對數後不等號反向：

$$N + 1 > \frac{\log(1/1200)}{\log(0.8)} \approx 31.77.$$

所以最小整數為 $N + 1 = 32$ ，即

$$N = 31.$$

這證明資料界及權重模型成立時，數學截斷誤差小於指定值。它不能證明感測器正確、資料無缺漏、現場安全或浮點計算完全無誤。

解答五

取

$$\varepsilon_0 = \frac{1}{2}.$$

對任意 $N \in \mathbb{N}$ ，選 $n \geq N$ 並令 $m = 2n$ 。則

$$s_m - s_n = \sum_{k=n+1}^{2n} \frac{1}{k}.$$

共有 n 項，每項至少為 $1/(2n)$ ，所以

$$|s_m - s_n| \geq n \frac{1}{2n} = \frac{1}{2}.$$

因此，對每個 N ，都存在 $m, n \geq N$ 使

$$|s_m - s_n| \geq \varepsilon_0.$$

這正是 Cauchy 條件的否定，所以 (s_n) 不是 Cauchy 數列。由 $\mathbb{R}$ 完備性，它不收敛於任何實數。

本章小結

數列收敛的核心是量詞：對每個正誤差，都能找到一個門檻，使門檻後所有項接近同一極限。極限若存在便唯一。

Cauchy 條件不預先指定極限，只要求足夠晚的任意兩項彼此接近。收敛數列在任何度量空間中都是 Cauchy 數列；反方向需要完備性。 $\mathbb{R}$ 完備， $\mathbb{Q}$ 不完備。

無窮級數由部分和數列定義。項趨零是級數收敛的必要條件而非充分條件。絕對收敛足以推出收敛，並保證重排不改變總和；條件收敛級數則可能因重排而改變和。

數值計算必須分清截斷誤差與浮點誤差。解析尾項界可控制未計算的無窮尾端；有限輸出只能提供數值證據，不能單獨證明無限命題。

參考來源

1. Jiří Lebl, *Basic Analysis*, 作者教材入口：<https://www.jirka.org/ra/>
2. MIT OpenCourseWare, *18.100A Real Analysis*：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>

以上來源用於實分析主題與延伸閱讀。依既有來源紀錄，已取得作者入口與課程概要，但未宣稱逐頁核對完整教材。本程式未實際執行，所有測試結果均標為預期或待執行核對。

第03章 向量範數、距離與算子範數

學習目標與先備知識

學完本章，讀者應能依定義檢查範數、由範數建立距離，手算向量的 1、2、無窮範數，以及矩陣的誘導範數；能用算子範數寫出誤差傳播界，並分辨有限維範數等價與「各維度使用同一常數」是不同主張。讀者亦應能辨認：條件數描述的是指定範數及指定問題下的最壞相對敏感度界，不是每筆資料的實際誤差。

先備知識是實數絕對值、有限和、矩陣乘法與可逆矩陣。以下向量一律視為直向量，即列向量 (column vector)；矩陣的橫列是 row，縱行是 column。若分量帶有不同物理單位，須先選尺度轉成無因次座標，才可對其歐氏長度賦予明確的比較意義。

問題與直覺

設輸入 x 經線性模型 $y = Ax$ 轉為輸出，測量擾動 δx 造成 $\delta y = A\delta x$ 。只說「擾動很小」並不足夠：小是用哪一種長度衡量？輸出的最大可能放大倍數是多少？若由 y 反求 x ，又會不會把微小的輸出誤差放大？

範數回答第一個問題；誘導算子範數回答第二個問題；可逆矩陣的條件數協助回答第三個問題。這些量依賴座標及尺度。例如同一個幾何向量以兩支幾乎平行的基底表示時，座標係數可能很大且彼此抵銷。因此「座標的歐氏長度大」不能不經檢查就說成「物理位移大」。分析中的誤差敘述須同時交代所量度的對象、採用的範數及映射的方向。

定義、定理與推導

定義：向量範數。 實向量空間上的函數 $\|\cdot\|$ 若對所有向量 u, v 及實數 a 滿足

$$\|v\| \geq 0, \quad \|v\| = 0 \iff v = 0; \quad \|av\| = |a|\|v\|; \quad \|u + v\| \leq \|u\| + \|v\|,$$

便稱為範數。最後一項是三角不等式。範數誘導距離 $d(u, v) = \|u - v\|$ 。距離必須對稱、非負、只在兩點相同時為零，並滿足三角不等式。

在 $\mathbb{R}^n$ 上，三個常用選擇為

$$\|x\|_1 = \sum_{i=1}^n |x_i|, \quad \|x\|_2 = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}, \quad \|x\|_\infty = \max_i |x_i|.$$

下標不是向量的分量編號。以 1 範數為例，逐項使用 $|u_i + v_i| \leq |u_i| + |v_i|$ 再相加，便得到三角不等式；無窮範數則先對每個分量給出相同上界，再取最大值。對 2 範數，Cauchy-Schwarz 不等式給出 $u^T v \leq \|u\|_2 \|v\|_2$ ，因此

$$\|u + v\|_2^2 = \|u\|_2^2 + 2u^T v + \|v\|_2^2 \leq (\|u\|_2 + \|v\|_2)^2.$$

兩邊均非負，取平方根便得三角不等式。這說明三個公式確實符合關鍵公理，而不只是三種看似合理的計算規則。

小命題與證明：範數確實誘導距離。 設 $\|\cdot\|$ 是任意實向量空間上的範數，定義 $d(u, v) = \|u - v\|$ 。非負性及「為零當且僅當 $u = v$ 」直接來自第一條公理。由齊次性， $d(u, v) = \|(v - u)\| = |-1|\|v - u\| = d(v, u)$ 。又因 $u - w = (u - v) + (v - w)$ ，三角不等式給出 $d(u, w) \leq d(u, v) + d(v, w)$ 。四項距離公理均成立，證畢。這是對所有向量的證明，而非抽取幾組座標所做的檢查。

定義：誘導矩陣範數。 若輸入 $\mathbb{R}^n$ 與輸出 $\mathbb{R}^m$ 已各自選好向量範數，對 $A \in \mathbb{R}^{m \times n}$ 定義

$$\|A\|_{\text{in} \rightarrow \text{out}} = \sup_{x \neq 0} \frac{\|Ax\|_{\text{out}}}{\|x\|_{\text{in}}}.$$

這個比值測量指定輸入方向的放大率；上確界則涵蓋所有非零方向。由定義立即有 $\|Ax\|_{\text{out}} \leq \|A\|_{\text{in} \rightarrow \text{out}} \|x\|_{\text{in}}$ 。有限矩陣的此上確界為有限值。若兩端都用相同的 p 範數，簡寫為 $\|A\|_p$ 。對有限矩陣，

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \quad \|A\|_\infty = \max_i \sum_j |a_{ij}|.$$

前者是最大縱行絕對值和，後者是最大橫列絕對值和。兩式不只是方便記憶的算法，也可從定義推得。對 1 範數，先逐一估計輸出分量並交換有限求和順序：

$$\|Ax\|_1 \leq \sum_j \left(\sum_i |a_{ij}| \right) |x_j| \leq \left(\max_j \sum_i |a_{ij}| \right) \|x\|_1.$$

選擇縱行絕對值和最大的編號 j_* ，令 x 為該編號的座標基向量；此時 $\|x\|_1 = 1$ ，而 $\|Ax\|_1$ 正是該縱行之和，故上界可取到。對無窮範數，固定橫列 i ，以 $\|x\|_\infty$ 界住每個 $|x_j|$ ，即可取得最大橫列和的上界。再選取和最大的橫列 i_* ，令 x_j 與 a_{i_*j} 同號，零元素所對應的 x_j 可任選正負一；於是 $\|x\|_\infty = 1$ ，第 i_* 個輸出分量的絕對值等於該橫列和。這證成下界與上界相等。

$\|A\|_2$ 是最大奇異值；此處引用有限維矩陣的奇異值結果，不把最大元素絕對值、最大特徵值或 Frobenius 範數直接當成它。

有限維範數等價的具體版本。 對每個 $x \in \mathbb{R}^n$ ，

$$\|x\|_\infty \leq \|x\|_2 \leq \|x\|_1 \leq \sqrt{n} \|x\|_2 \leq n \|x\|_\infty.$$

其中 $\|x\|_1 \leq \sqrt{n} \|x\|_2$ 由 Cauchy-Schwarz 不等式得到；末項還使用 $\|x\|_2 \leq \sqrt{n} \|x\|_\infty$ 。這證明在**固定有限維度**，三種範數具有相同的收斂向量列：若其中一種範數下與極限之差趨零，固定的比較常數便使另外兩種範數下的差也趨零。但 $\sqrt{n}$ 和 n 隨維度增長，不能省略「固定」二字。對 $\mathbb{R}^n$ 上任意兩個範數亦存在正的比較常數，這是有限維範數等價定理；其一般證明可利用歐氏單位球的緊緻性，本章引用此結果，不把它推廣到未指定條件的無限維空間。

矩陣範數還滿足相容的乘法界。若 $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 、 $B: \mathbb{R}^k \rightarrow \mathbb{R}^n$ ，並在共同空間使用同一個中間範數，則

$$\|AB\|_{\text{in} \rightarrow \text{out}} \leq \|A\|_{\text{mid} \rightarrow \text{out}} \|B\|_{\text{in} \rightarrow \text{mid}}.$$

理由是對每個非零 x 先界住 $A(Bx)$ ，再界住 Bx ，最後取上確界。這裡的範數下標不能任意混接：若第一步用歐氏長度量 Bx ，第二步卻只給出它的無窮長度，便還需要額外的範數比較常數。

若 $A \in \mathbb{R}^{n \times n}$ 可逆，在同一向量範數下定義 $\kappa(A) = \|A\| \|A^{-1}\|$ 。對 $y = Ax \neq 0$ 及擾動 δy ，令 $\delta x = A^{-1} \delta y$ 。算子界分別給出 $\|\delta x\| \leq \|A^{-1}\| \|\delta y\|$ 及 $\|y\| \leq \|A\| \|x\|$ 。由於 x, y 均非零，後一式除以正數 $\|x\| \|y\|$ ，得到 $1/\|x\| \leq \|A\|/\|y\|$ ；再乘上前一式，便得

$$\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\delta y\|}{\|y\|}.$$

這是最壞情況的相對誤差上界，不是說每個擾動都達到右端，也不是說 $\kappa(A)$ 單獨提供了誤差的絕對單位。條件數至少為一：由 $I = A^{-1}A$ 的乘法界可得 $1 = \|I\| \leq \|A^{-1}\| \|A\|$ 。奇異矩陣沒有 A^{-1} ，不得套用上述逆算公式。

逐步手算例題

例一：三種長度與誤差傳播。 取無因次向量 $x = (3, -4)^T$ ，則 $\|x\|_1 = 7$ 、 $\|x\|_2 = 5$ 、 $\|x\|_\infty = 4$ 。令

$$A = \begin{pmatrix} 2 & -1 \\ 0 & 3 \end{pmatrix}, \quad \delta x = \begin{pmatrix} 0.01 \\ -0.02 \end{pmatrix}.$$

手算得 $\delta y = A\delta x = (0.04, -0.06)^T$ ，所以 $\|\delta y\|_\infty = 0.06$ 。由最大橫列和， $\|A\|_\infty = \max(3, 3) = 3$ ；而 $\|\delta x\|_\infty = 0.02$ ，界為 $3(0.02) = 0.06$ ，此例恰好取到等號。最大縱行和給出 $\|A\|_1 = \max(2, 4) = 4$ ，因此另有 $\|\delta y\|_1 = 0.10 \leq 4(0.03) = 0.12$ 。同一擾動在兩種範數下得到不同數字，必須把輸入與輸出的下標一併寫出；不能因第一個界取等號，就推斷第二個也取等號。

例二：病態逆算與非正交座標。 考慮

$$B = \begin{pmatrix} 1 & 1 \\ 0 & 0.01 \end{pmatrix}, \quad B^{-1} = \begin{pmatrix} 1 & -100 \\ 0 & 100 \end{pmatrix}.$$

$\|B\|_\infty = 2$ 、 $\|B^{-1}\|_\infty = 101$ ，故 $\kappa_\infty(B) = 202$ 。若真實座標 $c = (0, 1)^T$ ，物理平面中的向量為 $Bc = (1, 0.01)^T$ 。兩個基底向量 $(1, 0)^T$ 、 $(1, 0.01)^T$ 幾乎平行。給輸出加入 $\delta y = (0, 0.001)^T$ ，逆算座標誤差為 $B^{-1}\delta y = (-0.1, 0.1)^T$ ：輸出無窮範數僅變動 0.001，座標無窮範數卻變動 0.1。本例相對誤差分別是 0.001 與 0.1；條件數界給的是 $0.1 \leq 202(0.001)$ ，並未宣稱實際誤差等於 0.202。改選正交座標或為輸入、輸出建立合理尺度，會改變所報告的座標條件數；幾何向量本身並未因此改變。

實作與程式

下列程式只需 Python 標準庫，在一般 CPU 上即可使用。`vector_norm` 接收非空數值序列及範數種類，回傳非負長度；`shape` 回傳矩陣的橫列數與縱行數，並拒絕空矩陣和長短不齊的橫列；`matvec` 只接受與矩陣縱行數相同長度的輸入。兩個 `induced` 函式直接按已證公式計算，不聲稱透過取樣求出了上確界。

`finite_sign_check_inf` 是獨立的小矩陣核對：對無窮單位球中的任意 x ，每個輸出分量是各 x_j 的線性組合，其絕對值不超過對應橫列和；而指定橫列的符號選擇落在頂點集合內並可取到該和。因此只比較分量皆為正負一的頂點便足夠，並非因為一般連續區域都可以靠有限取樣證明。頂點數隨輸入維度指數增長，故此核對函式設有尺寸限制。程式不求逆，也不以浮點檢查充當範數公理的證明。

```
from itertools import product
from math import sqrt

def vector_norm(x, kind):
    if not x:
        raise ValueError("向量不得為空")
    if kind == 1:
        return sum(abs(v) for v in x)
    if kind == 2:
        return sqrt(sum(v * v for v in x))
    if kind == "inf":
        return max(abs(v) for v in x)
    raise ValueError("範數種類須為 1、2 或 'inf'")

def shape(A):
    if not A or not A[0]:
        raise ValueError("矩陣不得為空")
    width = len(A[0])
    if any(len(row) != width for row in A):
        raise ValueError("矩陣橫列長度不一致")
    return len(A), width

def matvec(A, x):
    _, n = shape(A)
    if len(x) != n:
        raise ValueError("輸入維度不符")
    return [sum(a * v for a, v in zip(row, x)) for row in A]

def induced_one(A):
    m, n = shape(A)
    return max(sum(abs(A[i][j]) for i in range(m))
               for j in range(n))

def induced_inf(A):
    shape(A)
    return max(sum(abs(a) for a in row) for row in A)

def finite_sign_check_inf(A):
    # 小矩陣核對：無窮單位球的符號頂點可取到最大橫列和。
    _, n = shape(A)
    if n > 12:
        raise ValueError("此核對函式只接受至多 12 個輸入分量")
    return max(vector_norm(matvec(A, list(s)), "inf")
```

```

        for s in product((-1.0, 1.0), repeat=n))

def close(a, b, tol=1e-12):
    return abs(a - b) <= tol * max(1.0, abs(a), abs(b))

def expect_value_error(function, *args):
    try:
        function(*args)
    except ValueError:
        return
    raise AssertionError("預期 ValueError")

def run_checks():
    A = [[2.0, -1.0], [0.0, 3.0]]
    dx = [0.01, -0.02]
    assert close(vector_norm([3.0, -4.0], 1), 7.0)
    assert close(vector_norm([3.0, -4.0], 2), 5.0)
    assert close(vector_norm([3.0, -4.0], "inf"), 4.0)
    assert close(induced_one(A), 4.0)
    assert close(induced_inf(A), 3.0)
    assert close(finite_sign_check_inf(A), induced_inf(A))
    assert vector_norm(matvec(A, dx), "inf") <= (
        induced_inf(A) * vector_norm(dx, "inf") + 1e-12
    )
    assert close(vector_norm([0.0, 0.0], 2), 0.0)
    expect_value_error(shape, [])
    expect_value_error(shape, [[1.0, 2.0], [3.0]])
    expect_value_error(matvec, A, [1.0])
    expect_value_error(vector_norm, [], 2)

if __name__ == "__main__":
    run_checks()
    print("所有檢查通過")

```

測試與預期結果

以上程式**未在此執行**。正常測試預期得到例一的三種向量範數、兩種矩陣範數，以及滿足誤差界的輸出；小矩陣的符號核對預期為 3。若執行且斷言均通過，末行預期印出「所有檢查通過」，這是預期輸出而非已取得的執行紀錄。

邊界測試中的零向量預期長度為零；這不表示可將零向量代入算子範數定義中的比值，因該比值明確要求輸入非零。故障測試中的空矩陣、不規則矩陣、矩陣乘向量時維度不符，以及空向量，預期各自拋出 `ValueError`，並由測試輔助函式核對。符號核對若超過十二個輸入分量，也預期拋出 `ValueError`，其限制出於窮舉成本，而非數學公式失效。

有限次運算可以核對實作與特定輸入，不能證明所有矩陣都滿足公式。浮點運算亦可能需要容差；容差通過表示此組輸入的數值結果相容，不表示無限精度的數學等式已由程式證立。

反例與常見陷阱

第一， $\|x\|_1$ 與 $\|x\|_\infty$ 雖在固定維度等價，卻不能宣稱存在與維度無關的常數 C ，使所有 n 的向量均滿足 $\|x\|_1 \leq C\|x\|_\infty$ 。取 $x = (1, \dots, 1)^T \in \mathbb{R}^n$ ，左右兩邊分別為 n 與 C ；令 $n > C$ 即得反例。

第二，把 $\|A\|_\infty$ 誤算為最大縱行和，會讓誤差界用錯常數。例一中兩種值是 3 與 4，即使錯誤常數碰巧給出較鬆的界，也不能證明計算方法正確。第三，特徵值小不保證算子範數小：矩陣 $\begin{pmatrix} 0 & 100 \\ 0 & 0 \end{pmatrix}$ 的特徵值全為零，但它作用於 $(0, 1)^T$ 的輸出 2 範數是 100。特徵值描述特定代數性質，算子範數則檢查所有單位輸入的最大輸出，兩者不能無條件互換。

第四，非正交座標下的巨大係數可能源於抵銷。應先問誤差量的是幾何向量、原始讀值，還是反求的座標。第五，帶單位的不同分量不得直接相加後把所得「長度」當作天然物理量；尺度與權重是模型的一部分，須公開記錄。最後，算子範數界是充分的上界，不是由觀察到一次較小輸出就能反推出矩陣範數也小；最壞方向可能尚未被觀察到。

AI、幾何與養殖案例

考慮一組合成感測讀值：溫度變化 δT 以攝氏度的差值記錄，溶氧變化 δC 以 mg/L 記錄。兩者不能直接組成有物理唯一性的 $\sqrt{(\delta T)^2 + (\delta C)^2}$ 。若為演示而選定尺度 $s_T = 1^\circ\text{C}$ 、 $s_C = 2\text{ mg/L}$ ，可定義無因次輸入 $z = (\delta T/s_T, \delta C/s_C)^T$ 。假設另一個合成的無因次雙輸出模型為 $w = Az$ ，其中 A 採例一的矩陣，則 $\|\delta w\|_\infty \leq 3\|\delta z\|_\infty$ 。例如輸入無因次擾動的兩個分量絕對值皆不超過百分之一，模型便給出輸出無因次無窮範數不超過百分之三；這仍只是一項依模型與尺度成立的界，不是對現場儀器精度的宣告。

要返回原單位，必須再以各輸出預先聲明的尺度乘回；若模型直接寫於有因次座標，其矩陣元素的單位便是「輸出單位／輸入單位」。改變尺度會改變矩陣數值與所報告的無權重條件數，所以報告必須連同尺度一起保存。在幾何或 AI 的局部線性近似中，矩陣亦可描述輸入擾動如何傳播。但本章的結論只針對所指定的線性映射或已另行論證的近似有效範圍；不能只見到一次算子範數計算，就保證非線性系統在所有狀態的行為。合成養殖資料既非現場校準，也非操作安全證據；自動化代理可唯讀整理尺度、假設和誤差界，不應據此改動設備、投餌或加藥。

習題

1. **手算**。對 $x = (-2, 1, 2)^T$ 求三種常用範數。對 $A = \begin{pmatrix} 1 & -2 \\ 3 & 0 \end{pmatrix}$ 求 $\|A\|_1$ 、 $\|A\|_\infty$ ，並以無窮範數界住 $A(0.1, -0.1)^T$ 。
2. **程式**。使用本章函式計算 $A = \begin{pmatrix} 1 & 2 \\ -1 & 1 \end{pmatrix}$ 的兩種誘導範數及 `finite_sign_check_inf(A)`。寫出預期值，並說明為何窮舉檢查不能代替一般證明。
3. **反例**。有人聲稱「所有維度皆有 $\|x\|_1 \leq 10\|x\|_\infty$ 」。給出明確反例；再指出這是否否定固定有限維的範數等價。

4. 整合。令 $B = \begin{pmatrix} 1 & 1 \\ 0 & 0.01 \end{pmatrix}$ 、 $c = (0, 1)^T$ ，輸出擾動為 $\delta y = (0, 0.001)^T$ 。求 $\|\delta y\|_\infty / \|Bc\|_\infty$ 、逆算後的相對座標誤差與 $\kappa_\infty(B)$ 。說明條件數界與實際結果的關係，並指出一項解讀非正交座標時必要的警告。

習題解答

1. $\|x\|_1 = 5$ ， $\|x\|_2 = \sqrt{4+1+4} = 3$ ， $\|x\|_\infty = 2$ 。矩陣兩個縱行的絕對值和為 4, 2，故 $\|A\|_1 = 4$ ；兩個橫列和為 3, 3，故 $\|A\|_\infty = 3$ 。擾動無窮範數為 0.1，故輸出上界為 0.3。直接乘得輸出 $(0.3, 0.3)^T$ ，確實達界。
2. 兩個縱行的絕對值和分別為 2, 3，故 $\|A\|_1 = 3$ ；兩個橫列和分別為 3, 2，故 $\|A\|_\infty = 3$ ，符號核對預期亦回傳 3。程式只檢查這個有限矩陣的有限組頂點；一般公式另須依定義與三角不等式推導。
3. 取 $\mathbb{R}^{11}$ 中全為 1 的向量，即有 $\|x\|_1 = 11 > 10\|x\|_\infty = 10$ 。這只否定「常數 10 適用所有維度」；固定維度 n 仍有 $\|x\|_1 \leq n\|x\|_\infty$ 。
4. $Bc = (1, 0.01)^T$ ，故輸出的相對擾動為 $0.001/1 = 0.001$ 。由例二的逆矩陣， $\delta c = (-0.1, 0.1)^T$ ，而 $\|c\|_\infty = 1$ ，相對座標誤差為 0.1。 $\kappa_\infty(B) = 2(101) = 202$ ，其界為 $0.1 \leq 0.202$ ，不是實際誤差的等式。基底幾乎平行，座標誤差與幾何位移的長度必須分開陳述。

本章小結

範數先規定「大小」，距離再由向量差取得；誘導算子範數則把輸入大小與線性輸出大小連接起來。有限維範數等價保證固定維度下的收斂觀念一致，卻不消除比較常數的維度依賴。條件數提供可逆線性問題的最壞相對誤差界，解讀時必須保留所用範數、座標、尺度與問題方向。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*，作者教材入口：<https://www.jirka.org/ra/>
- [A2] MIT OpenCourseWare, *18.100A Real Analysis*，課程入口：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- [A3] MIT OpenCourseWare, *18.02SC Multivariable Calculus*，課程入口：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

以上連結作為進一步學習入口；本章未聲稱已逐頁核對教材全文，也未執行外部程式。

第04章 多變量極限與連續性

學習目標與先備知識

本章建立多變量函數極限的嚴格定義，並闡明連續性的邏輯結構與幾何含義。讀者需先掌握第3章中向量範數與距離的概念，特別是 l_2 範數作為度量基礎，以及第2章中實數系完備性與序列收斂的邏輯。本章將單變量極限的 $\epsilon - \delta$ 語言推廣至 $\mathbb{R}^n$ 空間，重點在於理解「路徑依賴性」與「全域一致性」之間的張力。

學習目標包括：

1. 精確陳述多變量極限的 $\epsilon - \delta$ 定義，明確區分聚點、孤立點與定義域的關係。
2. 掌握序列判準（Sequential Criterion）作為檢驗極限存在性的工具，並理解其必要與充分條件。
3. 識別常見反例，特別是「所有直線路徑極限一致但曲線路徑不同」的陷阱，並能構造解析反例。
4. 建立數值處理中浮點零除、取樣局限性與繪圖解讀的正確認知，區分手算證明與數值驗證的界線。

本章不討論微分或積分，僅聚焦於極限與連續性的基礎邏輯。所有結論均基於有限維歐幾里得空間 $\mathbb{R}^n$ ，並明確標示有限維性對緊緻性等後續推論的影響。

問題與直覺

在單變量分析中，我們透過左極限與右極限判斷連續性。然而，當維度從 1 提升到 $n \geq 2$ 時，接近一個點的方式不再是兩側，而是無限多條路徑。這帶來根本性挑戰：**存在一個極限，必須意味著所有可能的路徑都收斂到同一個值。**

直覺上，若 $f(x, y)$ 在 $(0, 0)$ 處，沿 x 軸極限為 0，沿 y 軸極限為 0，甚至沿所有直線 $y = mx$ 的極限均為 0，我們是否能斷言 $\lim_{(x,y) \rightarrow (0,0)} f(x, y) = 0$ ？答案是否定的。直線僅佔無限多路徑中的一小部分，曲線路徑（如拋物線 $y = x^2$ ）可能展現不同的極限值。

此處的「直覺」需被嚴格化：繪圖與取樣只能提供視覺支持或反例候選，無法構成證明。若數值取樣發現函數值在靠近原點時趨近於 0，這僅是「個別主張」的證據。反之，若發現某條曲線上函數值不趨近於該值，則可構成反例候選，但仍需解析證明該路徑收斂至目標點且函數值極限不同，才能確立極限不存在。

定義、定理與推導

1. 多變量極限的 $\epsilon - \delta$ 定義

設 $f : U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ ，其中 a 為 U 的聚點（accumulation point）。 a 可以屬於或不屬於 U 。我們稱 $\lim_{x \rightarrow a} f(x) = L$ ，若對於任意 $\epsilon > 0$ ，存在 $\delta > 0$ ，使得對於所有 $x \in U$ ，若 $0 < \|x - a\| < \delta$ ，則 $\|f(x) - L\| < \epsilon$ 。

此定義的關鍵在於 $0 < \|x - a\|$ ，即排除 $x = a$ 本身。這使得極限定義不依賴 $f(a)$ 是否定義或取值為何。極限描述的是 x 趨近 a 時的行為。若 a 不是聚點（例如孤立點），則極限定義不適用，因為鄰域內可能沒有其他點。

2. 序列判準 (Sequential Criterion)

定理 4.1 (序列判準)：設 $f : U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ ， a 為 U 的聚點。以下兩者等價：

1. $\lim_{x \rightarrow a} f(x) = L$ 。
2. 對於任意序列 $\{x_k\} \subseteq U$ ，若 $x_k \neq a$ 且 $\lim_{k \rightarrow \infty} x_k = a$ ，則 $\lim_{k \rightarrow \infty} f(x_k) = L$ 。

證明：(1) $\implies$ (2)：假設 (1) 成立。給定任意 $\epsilon > 0$ ，由 (1) 的定義，存在 $\delta > 0$ 使得 $0 < \|x - a\| < \delta \implies \|f(x) - L\| < \epsilon$ 。由於 $\lim_{k \rightarrow \infty} x_k = a$ ，存在正整數 N 使得對於所有 $k \geq N$ ， $\|x_k - a\| < \delta$ 。由條件 $x_k \neq a$ ，對於 $k \geq N$ ，有 $0 < \|x_k - a\| < \delta$ 。因此 $\|f(x_k) - L\| < \epsilon$ 。故 $\lim_{k \rightarrow \infty} f(x_k) = L$ 。

(2) $\implies$ (1)：用反證法。假設 (1) 不成立，即存在 $\epsilon_0 > 0$ ，使得對於任意 $\delta > 0$ ，存在 $x \in U$ 滿足 $0 < \|x - a\| < \delta$ 但 $\|f(x) - L\| \geq \epsilon_0$ 。取 $\delta_k = 1/k$ 。則對於每個 k ，存在 $x_k \in U$ 使得 $0 < \|x_k - a\| < 1/k$ 且 $\|f(x_k) - L\| \geq \epsilon_0$ 。由 $0 \leq \|x_k - a\| < 1/k$ 且 $1/k \rightarrow 0$ ，故 $x_k \rightarrow a$ 。且 $x_k \neq a$ 對所有 k 成立。但 $\|f(x_k) - L\| \geq \epsilon_0$ 對於所有 k 成立，故 $\lim_{k \rightarrow \infty} f(x_k) \neq L$ 。這與 (2) 矛盾。故 (1) 必須成立。□

此定理的實用性在於：若要否定某個候選值 L ，只需找到一個序列 $\{x_k\} \subseteq U$ ，滿足 $x_k \neq a$ 且 $x_k \rightarrow a$ ，使得 $\{f(x_k)\}$ 不收敛至 L 。若要直接證明極限不存在，則可找到兩個序列 $\{x_k\}, \{y_k\} \subseteq U$ ，皆滿足 $x_k, y_k \neq a$ 且趨近 a ，但 $\{f(x_k)\}$ 與 $\{f(y_k)\}$ 收敛至不同值；或找到一個序列使 $\{f(x_k)\}$ 本身不收敛。要證明極限存在且等於 L ，則必須對所有此類序列驗證 $f(x_k) \rightarrow L$ ，這在構造型證明中較困難，通常回歸 $\epsilon - \delta$ 直接證明。

3. 路徑分析與充分/必要條件

考慮沿直線路徑 $y = mx$ 的極限。若 $\lim_{x \rightarrow 0} f(x, mx) = L$ 對於所有 $m \in \mathbb{R}$ 成立，這是 $\lim_{(x,y) \rightarrow (0,0)} f(x, y) = L$ 的**必要條件**，但**非充分條件**。

直覺：直線路徑僅覆蓋原點附近的「一維切片」。若函數在二維平面上的行為是各向異性的，或者依賴於 x 與 y 的高階交互作用（如 y/x^2 ），則直線路徑無法捕捉這種依賴。

推導示例：設 $f(x, y) = \frac{x^2 y}{x^4 + y^2}$ ， $(x, y) \neq (0, 0)$ 。沿直線 $y = mx$ ：

$$f(x, mx) = \frac{x^2(mx)}{x^4 + m^2x^2} = \frac{mx^3}{x^2(x^2 + m^2)} = \frac{mx}{x^2 + m^2}$$

當 $x \rightarrow 0$ ：

- 若 $m \neq 0$ ， $\lim_{x \rightarrow 0} \frac{mx}{x^2 + m^2} = 0$ 。
- 若 $m = 0$ （即 x 軸）， $f(x, 0) = 0 \rightarrow 0$ 。
- 若考慮 $x = 0$ （即 y 軸）， $f(0, y) = 0 \rightarrow 0$ 。所有直線路徑極限均為 0。

但考慮曲線 $y = x^2$ ：

$$f(x, x^2) = \frac{x^2(x^2)}{x^4 + (x^2)^2} = \frac{x^4}{2x^4} = \frac{1}{2} \quad (x \neq 0)$$

故 $\lim_{x \rightarrow 0} f(x, x^2) = 1/2 \neq 0$ 。由序列判準，取 $x_k = 1/k, y_k = 1/k^2$ ，則 $(x_k, y_k) \rightarrow (0, 0)$ 但 $f(x_k, y_k) \rightarrow 1/2$ 。因此，二維極限不存在。

此例明確展示了「所有直線極限一致」不保證二維極限存在。

4. 連續性的定義

函數 $f: U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ 在點 $a \in U$ 處連續，定義如下：

$$\forall \epsilon > 0, \exists \delta > 0, \forall x \in U, \quad \|x - a\| < \delta \implies \|f(x) - f(a)\| < \epsilon.$$

任取 $\mathbb{R}^n, \mathbb{R}^m$ 上一組範數；由第3章有限維範數等價，極限與連續性不依範數選擇而變。此定義涵蓋了聚點與孤立點兩種情形。若 a 是 U 的聚點，此定義等價於 $\lim_{x \rightarrow a} f(x) = f(a)$ （其中極限為去心極限）。若 a 是 U 的孤立點，則存在 $\delta > 0$ 使得 $U \cap B(a, \delta) = \{a\}$ 。此時，對於任意 $\epsilon > 0$ ，只要取此 δ ，對於所有 $x \in U$ ，若 $\|x - a\| < \delta$ ，則 $x = a$ ，故 $\|f(x) - f(a)\| = 0 < \epsilon$ 。因此， f 在孤立點自動連續。這並非因為去心極限條件成立（因為去心鄰域為空，極限概念在此不適用且無唯一性），而是直接由相對域的連續性定義導出。

定理 4.2（連續函數的組成）：若 $f: U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ 連續，且 $g: V \subseteq \mathbb{R}^m \rightarrow \mathbb{R}^p$ 連續，其中 $f(U) \subseteq V$ ，則 $g \circ f$ 連續。**證明：**對於 $a \in U, b = f(a) \in V$ 。給定 $\epsilon > 0$ ，由 g 在 b 連續，存在 $\delta_1 > 0$ 使得對於所有 $y \in V$ ，若 $\|y - b\| < \delta_1$ ，則 $\|g(y) - g(b)\| < \epsilon$ 。由 f 在 a 連續，存在 $\delta > 0$ 使得對於所有 $x \in U$ ，若 $\|x - a\| < \delta$ ，則 $\|f(x) - f(a)\| < \delta_1$ 。則對於所有 $x \in U$ ，若 $\|x - a\| < \delta$ ，則 $\|g(f(x)) - g(f(a))\| < \epsilon$ 。□

此定理保證了多項式、有理函數（分母非零處）、三角函數、指數函數等在定義域內的連續性。

逐步手算例題

例 4.1：極限存在性證明

考慮 $f(x, y) = \frac{xy\sqrt{|x-y|}}{x^2+y^2}$ 。求 $\lim_{(x,y) \rightarrow (0,0)} f(x, y)$ 。

步驟 1：分析量級 分母 $x^2 + y^2$ 為二階量。分子 $xy\sqrt{|x-y|}$ 中， xy 為二階量， $\sqrt{|x-y|}$ 介於 0 與 $\sqrt{|x|+|y|}$ 之間。直覺上分子階數高於分母，極限可能為 0。

步驟 2：使用 squeeze 定理（夾逼定理） 對於所有 x, y ， $|x-y| \leq |x|+|y|$ 。利用 $|x| \leq \sqrt{x^2+y^2}$ 和 $|y| \leq \sqrt{x^2+y^2}$ ，有 $|x|+|y| \leq \sqrt{2}\sqrt{x^2+y^2}$ 。故

$$\sqrt{|x-y|} \leq \sqrt{|x|+|y|} \leq 2^{1/4}(x^2+y^2)^{1/4}$$

則

$$|f(x, y)| = \left| \frac{xy\sqrt{|x-y|}}{x^2+y^2} \right| \leq \frac{|x||y| \cdot 2^{1/4}(x^2+y^2)^{1/4}}{x^2+y^2}$$

利用 $|x||y| \leq \frac{1}{2}(x^2+y^2)$ (由 $(|x|-|y|)^2 \geq 0$ 得 $|x||y| \leq \frac{x^2+y^2}{2}$) :

$$|f(x, y)| \leq \frac{\frac{1}{2}(x^2+y^2) \cdot 2^{1/4}(x^2+y^2)^{1/4}}{x^2+y^2} = 2^{-3/4}(x^2+y^2)^{1/4}$$

令 $r = \sqrt{x^2+y^2}$ 。當 $(x, y) \rightarrow (0, 0)$ 時, $r \rightarrow 0$ 。

$$|f(x, y)| \leq 2^{-3/4}r^{1/2}$$

當 $r \rightarrow 0$, $2^{-3/4}r^{1/2} \rightarrow 0$ 。由夾逼定理, $\lim_{(x,y) \rightarrow (0,0)} f(x, y) = 0$ 。

步驟 3：驗證 此證明涵蓋了所有路徑，因為 bound 僅依賴於 $r = \|(x, y)\|$ 。無論 x, y 如何變化，只要 $r \rightarrow 0$ ，函數值必趨近 0。

例 4.2：極限不存在證明

考慮 $f(x, y) = \frac{x^2-y^2}{x^2+y^2}$ 。求 $\lim_{(x,y) \rightarrow (0,0)} f(x, y)$ 。

步驟 1：測試直線路徑 沿 $y = mx$ ：

$$f(x, mx) = \frac{x^2 - m^2x^2}{x^2 + m^2x^2} = \frac{1 - m^2}{1 + m^2}$$

此值依賴於 m 。

- 若 $m = 0$ (x 軸)，極限為 $\frac{1-0}{1+0} = 1$ 。
- 若 $m = 1$ ($y = x$)，極限為 $\frac{1-1}{1+1} = 0$ 。

步驟 2：結論 由於沿不同直線路徑的極限值不同 (1 vs 0)，由序列判準，二維極限不存在。取序列 $p_k = (1/k, 0) \rightarrow (0, 0)$, $f(p_k) = 1$ 。取序列 $q_k = (1/k, 1/k) \rightarrow (0, 0)$, $f(q_k) = 0$ 。兩序列收斂至同一點，但函數值收斂至不同值。故極限不存在。

此例顯示，即使是最簡單的有理函數，若分子分母同階，極限通常不存在，除非分子分母的比值在所有方向上一致。

實作與程式

以下提供一個自足的 Python 程式，用於數值探索多變量極限。程式包含零除保護、多路徑取樣以及序列判斷的數值驗證。

```
import numpy as np

def check_limit_numeric(f, origin, num_samples=100):
    """
    數值檢查多變量極限。

    Args:
        f: 函數 f(x, y)
        origin: 目標點 (x0, y0)
        num_samples: 每種路徑類型生成的樣本數

    Returns:
        dict: 各路徑類型的最小與最大函數值，以及收斂估計
    """
    x0, y0 = origin
    results = {
        'line_0': [], 'line_1': [], 'line_2': [],
        'parabola': [], 'spiral': []
    }
    error_log = []

    # 執行取樣
    for k in range(1, num_samples + 1):
        # 處理固定斜率直線：m = 0, 1, -1
        for ptype, m in [('line_0', 0), ('line_1', 1), ('line_2', -1)]:
            x, y = x0 + 1.0/(k+1), y0 + m * (1.0/(k+1))
            if np.isclose(x, x0, atol=1e-15) and np.isclose(y, y0, atol=1e-15):
                continue
            try:
                val = f(x, y)
                if np.isfinite(val):
                    results[ptype].append((1.0/(k+1), val))
            except ZeroDivisionError:
                error_log.append(f"ZeroDivisionError at k={k}, ptype={ptype}")
            except Exception as e:
                error_log.append(f"Unexpected error {str(e)} at k={k}, ptype={ptype}")

    # 處理拋物線
    x, y = x0 + 1.0/(k+1), y0 + (1.0/(k+1))**2
    if not (np.isclose(x, x0, atol=1e-15) and np.isclose(y, y0, atol=1e-15)):
        try:
            val = f(x, y)
            if np.isfinite(val):
                results['parabola'].append((1.0/(k+1), val))
        except ZeroDivisionError:
            error_log.append(f"ZeroDivisionError at k={k}, ptype=parabola")
        except Exception as e:
            error_log.append(f"Unexpected error {str(e)} at k={k}, ptype=parabola")
```

```

# 處理螺旋線
t = 1.0/(k+1)
angle = k * np.pi / 4
x, y = x0 + t * np.cos(angle), y0 + t * np.sin(angle)
if not (np.isclose(x, x0, atol=1e-15) and np.isclose(y, y0, atol=1e-15)):
    try:
        val = f(x, y)
        if np.isfinite(val):
            results['spiral'].append((t, val))
        else:
            error_log.append(f"Non-finite value at k={k}, ptype=spiral")
    except ZeroDivisionError:
        error_log.append(f"ZeroDivisionError at k={k}, ptype=spiral")
    except Exception as e:
        error_log.append(f"Unexpected error {str(e)} at k={k}, ptype=spiral")

# 分析結果
summary = {}
for ptype, data in results.items():
    if not data:
        summary[ptype] = "No valid samples"
        continue
    count = max(1, int(len(data) * 0.1))
    last_part = data[-count:]
    vals = [v for _, v in last_part]
    if not vals:
        summary[ptype] = "No valid values"
        continue
    summary[ptype] = {
        "min": min(vals),
        "max": max(vals),
        "range": max(vals) - min(vals),
        "last_val": vals[-1]
    }

return {
    "summary": summary,
    "errors": error_log
}

# 測試函數定義
def f_test_normal(x, y):
    # 正常測試：極限不存在， $x^2y/(x^4+y^2)$ 
    if x == 0 and y == 0:
        return 0.0
    denom = x**4 + y**2
    if denom == 0:
        return 0.0
    return (x**2 * y) / denom

def f_test_boundary(x, y):
    # 邊界測試：極限存在且為1， $\sin(x^2+y^2)/(x^2+y^2)$ 
    if x == 0 and y == 0:
        return 1.0
    r2 = x**2 + y**2
    if r2 == 0:
        return 1.0
    return np.sin(r2) / r2

```

```

def f_test_fault(x, y):
    # 故障測試：極限不存在的無界函數，1/(x^2+y^2)
    if x == 0 and y == 0:
        return np.inf
    r2 = x**2 + y**2
    if r2 == 0:
        return np.inf
    return 1.0 / r2

if __name__ == "__main__":
    print("=== Normal Test: f(x,y) = x^2y/(x^4+y^2) ===")
    res1 = check_limit_numeric(f_test_normal, (0, 0))
    for k, v in res1["summary"].items():
        print(f" {k}: {v}")
    if res1["errors"]:
        print(f" Errors: {len(res1['errors'])}")

    print("\n=== Boundary Test: f(x,y) = sin(x^2+y^2)/(x^2+y^2) ===")
    res2 = check_limit_numeric(f_test_boundary, (0, 0))
    for k, v in res2["summary"].items():
        print(f" {k}: {v}")
    if res2["errors"]:
        print(f" Errors: {len(res2['errors'])}")

    print("\n=== Fault Test: f(x,y) = 1/(x^2+y^2) ===")
    res3 = check_limit_numeric(f_test_fault, (0, 0))
    for k, v in res3["summary"].items():
        print(f" {k}: {v}")
    if res3["errors"]:
        print(f" Errors: {len(res3['errors'])}")
    # 預期：值隨 k 增大 (r 減小) 而增大，但不會溢出為 inf，因為 r_min ~ 1/101
    # 1/(1/101)^2 ~ 10201，遠小於 float64 max

```

程式說明：

1. **固定路徑**：使用預先指定的固定斜率列表 `[0, 1, -1]` 以及拋物線 $y = x^2$ 和螺旋線。每個 k 對應固定的路徑幾何，避免隨機斜率導致的非路徑取樣問題。
2. **錯誤記錄**：不再使用 `pass` 吞掉錯誤，而是將錯誤訊息記錄在 `error_log` 中，並在輸出時顯示。這允許區分零除錯誤與其他異常。
3. **測試涵蓋**：`__main__` 中實際執行了三類測試函數：正常（極限不存在）、邊界（極限存在）和故障（無界）。

預期輸出（未執行，僅基於邏輯推斷）：

- **Normal Test**：`line_0` ($y=0$) 的 `last_val` 為 0；`parabola` ($y=x^2$) 的 `last_val` 接近 0.5。
`range` 在 `parabola` 中應較小且穩定在 0.5 附近，而 `line_1` ($y=x$) 的 `last_val` 接近 0。這顯示不同路徑收斂值不同。
- **Boundary Test**：所有路徑的 `last_val` 應接近 1，`range` 趨近 0。
- **Fault Test**：`last_val` 應隨 k 增大而顯著增大（例如從幾十增加到幾千），但不會出現 `inf`，因為 t 最小值約為 $1/101$ ， $1/t^2 \approx 10000$ ，在浮點範圍內。`errors` 應為空列表。

測試與預期結果

1. 正常測試

- 輸入： $f(x, y) = \frac{x^2 y}{x^4 + y^2}$ ，目標 $(0, 0)$ 。
- 預期：沿直線 $y = mx$ ($m \neq 0$) 的極限為 0，沿拋物線 $y = x^2$ 的極限為 0.5。
- 程式行為：`line_1` 路徑的 `last_val` 接近 0，`parabola` 路徑的 `last_val` 接近 0.5。
- 結論：極限不存在。程式應顯示不同路徑的收斂值不一致。

2. 邊界測試

- 輸入： $f(x, y) = \sin(x^2 + y^2)/(x^2 + y^2)$ ，目標 $(0, 0)$ 。
- 預期：令 $r = \sqrt{x^2 + y^2}$ ， $f = \sin(r^2)/r^2$ 。當 $r \rightarrow 0$ ， $\sin(r^2) \approx r^2$ ，故 $f \approx 1$ 。極限應為 1。
- 程式行為：所有路徑的 `last_val` 應接近 1，`range` 趨近 0。
- 結論：極限存在且為 1。

3. 故障測試

- 輸入： $f(x, y) = 1/(x^2 + y^2)$ ，目標 $(0, 0)$ 。
- 預期：當 $(x, y) \rightarrow (0, 0)$ ， $f \rightarrow \infty$ 。
- 程式行為：`last_val` 將隨 k 增大而增大。由於 $t = 1/(k + 1)$ ，當 $k = 100$ 時， $t \approx 0.0099$ ， $f \approx 1/(0.01)^2 \approx 10000$ 。不會溢出為 `inf`。
- 結論：極限不存在（收發散）。程式應顯示值隨半徑縮小而持續增大。

重要提醒：程式測試僅為數值證據。若程式顯示 `range` 趨近 0，這僅支持極限存在的假設，不構成證明。若程式顯示不同路徑值不一致，則提供反例候選；仍須解析證明該路徑趨近目標點且函數值極限不同，才能構成反例證明。

反例與常見陷阱

反例 1：所有直線極限一致，但極限不存在

已於「路徑分析與充分/必要條件」段落中展示。這是多變量分析中最常見的陷阱。學生常誤以為「沿所有直線極限相同」即意味著極限存在。反例 $f(x, y) = \frac{x^2 y}{x^4 + y^2}$ 明確展示了曲線路徑的重要性。

陷阱分析：直線路徑 $y = mx$ 假設了 y 與 x 成比例。但若 y 與 x^2 成比例（拋物線），則 y 遠小於 x （當 x 接近 0 時），這改變了分子分母的階數平衡。

反例 2：連續性不依賴於單一路徑

$$\text{設 } f(x, y) = \begin{cases} 1 & \text{if } x \neq 0, y = 0 \\ 0 & \text{otherwise} \end{cases}。$$

- 沿 y 軸 ($x = 0$)， $f(0, y) = 0$ (對於 $y \neq 0$)， $f(0, 0) = 0$ 。連續。
- 沿 x 軸 ($y = 0$)， $f(x, 0) = 1$ (對於 $x \neq 0$)，但 $f(0, 0) = 0$ 。不連續。
- 沿 $y = x$ ， $f(x, x) = 0$ 。連續。
- 但整體在 $(0, 0)$ 不連續，因為沿 x 軸極限為 1，而 $f(0, 0) = 0$ 。

此例強調：連續性要求在**所有**方向連續。若任一方向極限不等於函數值，則該點不連續。

反例 3：繪圖的欺騙性

考慮 $f(x, y) = \frac{xy}{x^2 + y^2}$ 。在標準視窗 $[-1, 1]^2$ 中，繪圖可能顯示函數值介於 -0.5 與 0.5 之間，且在原點附近似乎有定義或趨近某值。但實際上，沿 $y = x$ 極限為 0.5，沿 $y = -x$ 極限為 -0.5，沿 x 軸極限為 0。繪圖無法區分這些細微差異，特別是當取樣點未恰好在關鍵曲線上時。

教訓：繪圖僅用於視覺化，不能用於證明。必須配合解析證明或序列判準。

AI、幾何與養殖案例

AI 應用：自動微分與連續性檢查

在深度學習中，梯度下降依賴於損失函數 $L(\theta)$ 的連續性與可微性。若 $L(\theta)$ 在某點不連續，梯度可能不存在或行為異常。自動微分 (Autodiff) 框架如 JAX 或 PyTorch 通過計算圖追蹤函數的組成。若計算圖中包含 `where` 操作或 `min/max`，則可能引入不連續點或不可微點。

示例： $L(\theta) = \max(0, \theta - 1)$ 。在 $\theta = 1$ 處，函數連續但不可微。

- 左極限： $\lim_{\theta \rightarrow 1^-} \max(0, \theta - 1) = 0$ 。
- 右極限： $\lim_{\theta \rightarrow 1^+} \max(0, \theta - 1) = 0$ 。
- 函數值： $L(1) = 0$ 。故 L 在 $\theta = 1$ 連續。但左導數為 0，右導數為 1，故不可微。梯度下降在該點可能抖動，因為梯度不連續。數值檢查可透過序列判準：取 $\theta_k = 1 + 1/k$ 與 $\theta'_k = 1 - 1/k$ ，計算 $L(\theta_k)$ 與 $L(\theta'_k)$ ，驗證是否收斂至相同值（連續性），並檢查差分商（可微性）。

幾何應用：曲線交點與極限

考慮平面曲線 $C_1: y = x^2$ 與 $C_2: y = x$ 在原點的交點。兩曲線在原點的切線不同（ C_1 切線為 x 軸， C_2 切線為 $y = x$ ）。定義函數 $f(x, y) = \frac{y - x^2}{\sqrt{x^2 + y^2}}$ 。

- 沿 $y = x^2$ ： $f(x, x^2) = 0$ 。
- 沿 $y = x$ ： $f(x, x) = \frac{x - x^2}{\sqrt{2x^2}} = \frac{x(1-x)}{|x|\sqrt{2}}$ 。當 $x \rightarrow 0^+$ ， $f \rightarrow \frac{1}{\sqrt{2}}$ 。當 $x \rightarrow 0^-$ ， $f \rightarrow -\frac{1}{\sqrt{2}}$ 。故沿 $y = x$ 的極限不存在（左右極限不同），更不用說二維極限。此例展示了曲線路徑的複雜性，即使兩曲線相交，函數行為也可能高度依賴路徑。

養殖案例：水溫與溶解氧的交互作用

設水溫 T （單位：K）與溶解氧 DO （單位：mg/L）影響魚類生存指數 S （無因次）。為了確保 S 無因次，分子與分母必須均為無因次量。令 $T_* = 1\text{ K}$ ， $DO_* = 1\text{ mg/L}$ 。定義無因次變量 $\tau = T/T_*$ ， $\delta = DO/DO_*$ 。模型：

$$S(\tau, \delta) = \frac{\tau \cdot \delta}{\left(\frac{\tau - \tau_{opt}}{\Delta\tau}\right)^2 + \left(\frac{\delta - \delta_{opt}}{\Delta\delta}\right)^2 + \epsilon}$$

其中 τ_{opt}, δ_{opt} 為無因次最優值， $\Delta\tau, \Delta\delta$ 為特徵尺度（無因次）， ϵ 為小正無因次數以避免零除。

當 $\tau \rightarrow \tau_{opt}$ 且 $\delta \rightarrow \delta_{opt}$ 時：

$$S \rightarrow \frac{\tau_{opt}\delta_{opt}}{\epsilon}$$

此極限存在且不依賴路徑，因為分母始終正且連續。模型在該點連續。然而，若 ϵ 極小，則 S 在接近最優點時可能極大且變化劇烈（高敏感度）。數值檢查可取 $\tau = \tau_{opt} + h, \delta = \delta_{opt} + h^2$ ，計算 S 。若 S 不穩定或溢出，則提示模型在該區域高度敏感，需更精確的測量或平滑的模型。

注意：此模型為合成示例，僅用於說明極限與連續性概念。實際養殖模型需考慮生物動力學與時間延遲。模型校準不等於現場驗證，數學穩定不等於操作安全。

習題

1. 手算題

考慮 $f(x, y) = \frac{x^2 y}{x^4 + y^2}$ 。(a) 計算沿直線 $y = mx$ 的極限。(b) 計算沿拋物線 $y = x^2$ 的極限。(c) 判斷二維極限是否存在，並給出證明。

2. 程式題

修改 `check_limit_numeric` 函數，增加一種路徑類型 `parabola_k`，定義為 $y = kx^2$ （其中 k 為參數）。對函數 $f(x, y) = \frac{x^2 y}{x^4 + y^2}$ ，選擇 $k = 1$ 和 $k = 2$ ，運行程式並解釋結果。為何沿 $y = kx^2$ 的極限值取決於 k ？

3. 反例題

構造一個函數 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ，使得：

- 對於所有直線路徑 $y = mx$ ， $\lim_{(x,y) \rightarrow (0,0)} f(x, y) = 0$ 。
- 但二維極限 $\lim_{(x,y) \rightarrow (0,0)} f(x, y)$ 不存在。並驗證你的構造。

4. 整合題

考慮函數 $f(x, y) = \begin{cases} \frac{x^2 y}{x^4 + y^2} & (x, y) \neq (0, 0) \\ 0 & (x, y) = (0, 0) \end{cases}$ 。(a) 證明 f 在 $(0, 0)$ 處不連續。(b) 計算沿 $y = kx^2$ 的極限，並說明 k 如何影響極限值。(c) 若定義 $g(x, y) = xf(x, y)$ ，判斷 g 在 $(0, 0)$ 處是否連續，並給出證明。

習題解答

1. 解答

(a) 沿 $y = mx$ ：

$$f(x, mx) = \frac{x^2(mx)}{x^4 + m^2x^2} = \frac{mx}{x^2 + m^2}$$

當 $x \rightarrow 0$ ，若 $m \neq 0$ ，極限為 0。若 $m = 0$ ， $f(x, 0) = 0$ 。故所有直線極限為 0。(b) 沿 $y = x^2$ ：

$$f(x, x^2) = \frac{x^2(x^2)}{x^4 + x^4} = \frac{x^4}{2x^4} = \frac{1}{2}$$

極限為 $1/2$ 。(c) 由於沿不同路徑極限值不同（0 vs $1/2$ ），由序列判準，二維極限不存在。

2. 解答

沿 $y = kx^2$ ：

$$f(x, kx^2) = \frac{x^2(kx^2)}{x^4 + (kx^2)^2} = \frac{kx^4}{x^4 + k^2x^4} = \frac{k}{1 + k^2}$$

極限值取決於 k 。對於 $k = 1$ ，極限為 $1/(1 + 1) = 0.5$ 。對於 $k = 2$ ，極限為 $2/(1 + 4) = 0.4$ 。**解釋：**由於不同 k 值對應不同的極限值，這進一步證實了二維極限不存在。程式應顯示 `parabola_1` 的 `last_val` 接近 0.5，而 `parabola_2` 的 `last_val` 接近 0.4。

3. 解答

構造函數：

$$f(x, y) = \begin{cases} \frac{x^2 y}{x^4 + y^2} & (x, y) \neq (0, 0) \\ 0 & (x, y) = (0, 0) \end{cases}$$

驗證：

- 沿 $y = mx$ ，極限為 0（見題 1(a)）。
- 沿 $y = x^2$ ，極限為 $1/2$ （見題 1(b)）。
- 故二維極限不存在。此函數滿足條件。

4. 解答

(a) 由題 1，極限不存在，故 f 在 $(0, 0)$ 不連續。(b) 沿 $y = kx^2$ ：

$$f(x, kx^2) = \frac{k}{1 + k^2}$$

極限值取決於 k 。例如， $k = 0 \implies 0$ ， $k = 1 \implies 1/2$ ， $k \rightarrow \infty \implies 0$ 。(c) $g(x, y) = xf(x, y) = \frac{x^3y}{x^4+y^2}$ 。計算 $|g(x, y)|$ ：

$$|g(x, y)| = \left| \frac{x^3y}{x^4 + y^2} \right| = |x| \cdot \left| \frac{x^2y}{x^4 + y^2} \right|$$

利用不等式 $x^4 + y^2 \geq 2|x^2y|$ 。證明：由 $(x^2 - |y|)^2 \geq 0$ ，展開得 $x^4 - 2x^2|y| + y^2 \geq 0$ ，故 $x^4 + y^2 \geq 2x^2|y| = 2|x^2y|$ 。因此，

$$\left| \frac{x^2y}{x^4 + y^2} \right| \leq \frac{|x^2y|}{2|x^2y|} = \frac{1}{2} \quad (\text{若 } x^2y \neq 0)$$

若 $x^2y = 0$ ，則 $g(x, y) = 0$ 。故 $|g(x, y)| \leq \frac{|x|}{2}$ 。當 $(x, y) \rightarrow (0, 0)$ ， $|x| \rightarrow 0$ ，故 $|g(x, y)| \leq \frac{|x|}{2} \rightarrow 0$ 。由夾逼定理， $\lim_{(x,y) \rightarrow (0,0)} g(x, y) = 0 = g(0, 0)$ 。故 g 在 $(0, 0)$ 連續。

本章小結

本章建立了多變量極限與連續性的嚴格基礎。核心結論包括：

1. $\epsilon - \delta$ 定義是極限的基礎，要求對所有路徑一致。
2. 序列判準提供了檢驗極限存在性的工具，特別是用於證明極限不存在。
3. 路徑依賴性是多變量分析的核心挑戰。所有直線路徑極限一致不保證二維極限存在。
4. 連續性要求極限存在且等於函數值。連續函數的組成保持連續性。
5. 數值工具（繪圖、取樣）僅提供直覺支持，不能替代解析證明。
6. 反例（如 $x^2y/(x^4 + y^2)$ ）展示了直覺的局限性，並強調了曲線路徑的重要性。

本章為後續微分與積分奠定了基礎。可微性要求極限的存在性與線性近似，而積分則依賴於連續性。

參考來源

1. [A1] Jiří Lebl: Basic Analysis. <https://www.jirka.org/ra/>

2. [A2] MIT OCW 18.100A Real Analysis. <https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
3. [A3] MIT OCW 18.02SC Multivariable Calculus. <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
4. [A4] JAX Autodiff Cookbook: JVP/VJP.
https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html
5. [A5] SciPy matrix exponential expm.
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>
6. [A6] SciPy minimize parameters and methods.
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>

註：A4-A6 為延伸參考，本章核心內容不依賴於這些工具。

第05章 開閉集、緊緻性與一致連續

學習目標與先備知識

本章討論開集、閉集、緊緻性與一致連續，並說明這些概念如何把「每個點附近都有控制」提升成「整個集合上使用同一套控制」。逐點連續允許每個位置使用不同的尺度；一致連續則要求同一個輸入誤差門檻能管住所有位置。

學完本章後，你應能：

1. 以度量與鄰域定義開集、閉集及緊緻集。
2. 在有限維歐氏空間中使用 Heine–Borel 定理，並辨認它不適用的情形。
3. 解釋緊緻集合上的連續函數為何一致連續且可達最大、最小值。
4. 以序列反例區分逐點連續與一致連續。
5. 說明有限格點檢查能提供甚麼數值證據，又不能證明甚麼。
6. 使用簡短 CPU 程式檢查候選函數的增量，並辨認邊界故障。

先備知識包括實數上的極限與連續、開球與範數。除非特別註明，本章中的距離是歐氏距離；集合位於 $\mathbb{R}^n$ ，其中 n 是固定的有限整數。這些緊緻性結論不會自動延伸至無限維函數空間。

問題與直覺

同一個誤差門檻，能不能照顧整個範圍？

假設一個模型以輸入 x 預測輸出 $f(x)$ 。連續性告訴我們：在某個固定位置 a ，輸入夠接近 a ，輸出便會接近 $f(a)$ 。可是，若要在整個作業區間上保證輸入誤差不超過某值時，輸出誤差也不超過某值，逐點連續尚未足夠。不同位置所需的輸入誤差門檻可能越來越小。

例如 $f(x) = 1/x$ 在開區間 $(0, 1)$ 上連續。靠近 0 時，微小輸入變化可以引起很大的輸出變化；不存在一個固定的輸入門檻，能在整個 $(0, 1)$ 上保證輸出誤差低於指定上限。相對地， $f(x) = x^2$ 在閉區間 $[0, 1]$ 上不只連續，也一致連續。

緊緻性提供有限維的控制原理：若函數在緊緻集合上連續，則局部控制可以合併成全域一致控制。這不表示只要在一些測試點上檢查成功就足夠；關鍵是緊緻性的數學定義與覆蓋論證，而非有限格點。

開集、閉集、緊緻性各回答甚麼問題？

- **開集**：每個集合內的點是否有一個小球完全留在集合內？
- **閉集**：集合是否包含其中所有收斂數列的極限？
- **緊緻集**：是否能從任意開覆蓋中抽出有限子覆蓋？

在有限維 $\mathbb{R}^n$ 中，緊緻性等價於閉且有界。但「閉」本身不保證有界，也不保證緊緻；「有界」本身則不保證包含邊界極限。

定義、定理與推導

度量、開球與開集

度量空間由集合 X 與距離函數 $d: X \times X \rightarrow [0, \infty)$ 組成，距離須滿足非負、分離性、對稱性及三角不等式。給定 $x \in X$ 與 $r > 0$ ，半徑為 r 的開球定義為

$$B(x, r) = \{y \in X : d(x, y) < r\}.$$

集合 $U \subseteq X$ 稱為**開集**，若對每個 $x \in U$ ，存在 $r > 0$ 使 $B(x, r) \subseteq U$ 。半徑可以依點而異。

集合 $F \subseteq X$ 稱為**閉集**，若其補集 $X \setminus F$ 為開集。等價地，在度量空間中， F 閉當且僅當：只要 (x_k) 是 F 中的數列且 $x_k \rightarrow x$ ，便有 $x \in F$ 。

開與閉都相對於指定的環境空間。比如 $[0, 1)$ 在實數 $\mathbb{R}$ 中不是閉集；但若環境空間改為 $[0, 1)$ 本身，它作為全空間既開也閉。討論「閉」時不能略去環境空間。

緊緻集

集合 $K \subseteq X$ 稱為**緊緻**，若對每一個開覆蓋 $K \subseteq \bigcup_{\alpha \in A} U_\alpha$ ，都存在有限個指標 $\alpha_1, \dots, \alpha_N$ ，使

$$K \subseteq U_{\alpha_1} \cup \dots \cup U_{\alpha_N}.$$

這是一般拓撲空間中的定義。在度量空間中，緊緻性等價於每個數列都有收斂子數列，且子數列極限仍在集合內。有限維實數空間有更方便的刻畫。

Heine–Borel 定理（有限維版本）。對 $K \subseteq \mathbb{R}^n$ ，其中 $n < \infty$ ， K 緊緻若且唯若 K 閉且有界。

這項定理中的「有限維」是實質條件。不能把「閉且有界」直接當作任意無限維空間中緊緻的判準。即使有界，無限維範數空間中的閉單位球一般也不緊緻。

例：閉而不緊緻。集合 $[0, \infty) \subseteq \mathbb{R}$ 是閉集，但無界，因此依 Heine–Borel 定理不緊緻。

例：有界但不閉。集合 $(0, 1) \subseteq \mathbb{R}$ 有界但不是閉集，因此不緊緻。對 $k \geq 2$ ，數列 $x_k = 1/k$ 都在集合內，卻收斂到 $0 \notin (0, 1)$ 。

一致連續

函數 $f: A \rightarrow \mathbb{R}^m$ 稱為**一致連續**，若對每個 $\varepsilon > 0$ ，存在 $\delta > 0$ ，使對所有 $x, y \in A$ ，

$$\|x - y\| < \delta \implies \|f(x) - f(y)\| < \varepsilon.$$

逐點連續則是：對每個固定 $a \in A$ 及每個 $\varepsilon > 0$ ，存在 $\delta > 0$ ，使 $x \in A$ 且 $\|x - a\| < \delta$ 時， $\|f(x) - f(a)\| < \varepsilon$ 。這個 δ 可以依賴 a ；一致連續要求 δ 可依賴 ε ，但不能依賴位置。

Heine–Cantor 定理。 若 $K \subseteq \mathbb{R}^n$ 緊緻，且 $f : K \rightarrow \mathbb{R}^m$ 連續，則 f 在 K 上一致連續。

證明。 固定 $\varepsilon > 0$ 。對每個 $a \in K$ ，由 f 在 a 連續，可選半徑 $r_a > 0$ ，使得 $x \in K$ 且 $\|x - a\| < 2r_a$ 時有 $\|f(x) - f(a)\| < \varepsilon/2$ 。所有開球 $B(a, r_a)$ 覆蓋 K 。由緊緻性，存在有限子覆蓋 $B(a_1, r_{a_1}), \dots, B(a_N, r_{a_N})$ 。

令 $\delta = \min_{1 \leq i \leq N} r_{a_i} > 0$ 。若 $x, y \in K$ 且 $\|x - y\| < \delta$ ，選一個 i 使 $x \in B(a_i, r_{a_i})$ 。此時

$$\|y - a_i\| \leq \|y - x\| + \|x - a_i\| < \delta + r_{a_i} \leq 2r_{a_i}.$$

因此 $\|f(x) - f(a_i)\| < \varepsilon/2$ ，且 $\|f(y) - f(a_i)\| < \varepsilon/2$ 。由三角不等式， $\|f(x) - f(y)\| < \varepsilon$ 。同一個 δ 適用於所有 $x, y \in K$ ，故 f 一致連續。證畢。

證明的核心不是逐點的半徑原本相同，而是先以開覆蓋描述局部控制，再以緊緻性抽取有限個局部控制，最後取有限個半徑中的最小值。

極值定理與連續像

極值定理。 若 $K \subseteq \mathbb{R}^n$ 非空且緊緻， $f : K \rightarrow \mathbb{R}$ 連續，則存在 $x_{\min}, x_{\max} \in K$ ，使對所有 $x \in K$ ，

$$f(x_{\min}) \leq f(x) \leq f(x_{\max}).$$

因此連續函數在緊緻集合上能取得最大值與最小值，不只是具有上確界與下確界。

此定理要求定義域緊緻且函數連續。例如 $f(x) = x$ 在 $(0, 1)$ 上有上確界 1，但沒有最大值； $f(x) = x$ 在 $\mathbb{R}$ 上連續，卻沒有最大值。

若 K 緊緻而 $f : K \rightarrow Y$ 連續，則 $f(K)$ 緊緻。這項定理對一般拓撲空間也成立。取 $Y = \mathbb{R}$ 時，緊緻集合必定有界且閉；因此連續函數在緊緻定義域上的值域有界，並由極值定理取得上下界。

一致連續的數列判準

度量空間間的函數 $f : A \rightarrow Y$ 一致連續，若且唯若對任何 $x_k, y_k \in A$ ，只要 $d(x_k, y_k) \rightarrow 0$ ，就有 $d(f(x_k), f(y_k)) \rightarrow 0$ 。

必要性。 若 f 一致連續，任取 $\varepsilon > 0$ ，選相應的 $\delta > 0$ 。由 $d(x_k, y_k) \rightarrow 0$ ，足夠大的 k 會滿足 $d(x_k, y_k) < \delta$ ，於是 $d(f(x_k), f(y_k)) < \varepsilon$ 。

充分性。 反設 f 不一致連續。則存在 $\varepsilon_0 > 0$ ，使對每個正整數 k ，都能找到 $x_k, y_k \in A$ ，滿足 $d(x_k, y_k) < 1/k$ ，但 $d(f(x_k), f(y_k)) \geq \varepsilon_0$ 。這與假設的數列性質矛盾。

因此，要否定一致連續，可構造輸入距離趨近零、輸出距離卻不趨近零的兩列點。有限格點掃描只能尋找候選，不能涵蓋所有點對。

有界導數提供充分條件

若 $A \subseteq \mathbb{R}^n$ 是凸集， f 在包含 A 的開集上可微，且存在常數 $M < \infty$ 使

$$\|Df(x)\|_{\text{op}} \leq M \quad (x \in A),$$

其中算子範數依指定的向量範數定義，則 f 在 A 上滿足 Lipschitz 條件：

$$\|f(x) - f(y)\| \leq M\|x - y\|.$$

理由是沿著線段 $y + t(x - y)$ 使用一維微積分基本定理，將導數沿線段積分並以 M 界定。這是充分條件，不是一致連續的必要條件。例如 $f(x) = \sqrt{x}$ 在 $[0, 1]$ 上一致連續，但其導數在 0 附近沒有有界延伸。

逐步手算例題

例題一：閉區間上的平方函數

令 $f(x) = x^2$ ， $x \in [0, 1]$ 。對任意 $x, y \in [0, 1]$ ，

$$|f(x) - f(y)| = |x - y||x + y| \leq 2|x - y|.$$

因此若取 $\delta = \varepsilon/2$ ，只要 $|x - y| < \delta$ ，便有 $|f(x) - f(y)| < \varepsilon$ 。這直接證明 f 在 $[0, 1]$ 上一致連續，而且提供一個 Lipschitz 常數 2。

另一方面， $[0, 1]$ 在 $\mathbb{R}$ 中閉且有界，因此依 Heine–Borel 定理緊緻；一致連續也可由 Heine–Cantor 定理推出。直接估計與抽象定理給出相同結論，但前者還提供可用的誤差常數。

例題二：開區間上的倒數函數

令 $f(x) = 1/x$ ， $x \in (0, 1)$ 。對 $k \geq 2$ 選取

$$x_k = \frac{1}{k}, \quad y_k = \frac{1}{2k}.$$

由 $k \geq 2$ 可知 $0 < x_k \leq 1/2 < 1$ ，而 $0 < y_k < 1$ ，故兩點均位於 $(0, 1)$ 。此外，

$$|x_k - y_k| = \frac{1}{2k} \longrightarrow 0, \quad |f(x_k) - f(y_k)| = |k - 2k| = k \longrightarrow \infty.$$

根據一致連續的數列判準， f 不一致連續。倒數函數在區間內每一點仍然連續；失敗來自靠近缺少的端點 0 時，無法維持同一個輸入門檻。

例題三：閉集不是緊緻性證明

$F = [0, \infty)$ 包含其所有收斂列極限，故在 $\mathbb{R}$ 中閉；但正整數列沒有收斂子列， F 亦無界，所以不緊緻。反過來， $(0, 1)$ 雖有界，卻不是閉集，故也不緊緻。

有限維 Heine–Borel 需要「閉且有界」兩項同時成立，不可只記一半。

實作與程式

以下程式只使用 Python 標準庫。它以輸入距離至多為 h 的網格點對，計算有限樣本中的最大輸出增量。這是候選函數的**數值檢查**：若找到大增量，可指出某個實際點對不符合預定界；若沒有找到，則不能證明所有實數點對都符合界，更不能僅憑有限格點證明緊緻性或一致連續。

程式的取樣集合是人工建立的有限格點，和數學定義中的任意開覆蓋沒有等同關係。正常測試預期平方函數增量受 $2h$ 控制；邊界測試需明確避開倒數函數在 0 的定義域外值；故障測試則示範程式拒絕超出函數定義域的點。程式尚未執行，以下皆為預期結果。

```
from math import isfinite

def sample_pairs(f, points, max_gap, domain=None):
    """
    在有限點集中檢查距離不大於 max_gap 的點對。
    回傳有限樣本最大輸出增量；不宣稱這是全域上界。
    """
    if max_gap < 0:
        raise ValueError("max_gap must be non-negative")

    checked = []
    for x in points:
        if domain is not None and not domain(x):
            raise ValueError(f"point outside domain: {x}")
        y = f(x)
        if not isfinite(y):
            raise ValueError(f"non-finite function value at {x}")
        checked.append((x, y))

    largest = 0.0
    witness = None
    for i, (x, fx) in enumerate(checked):
        for y, fy in checked[i + 1:]:
            if abs(x - y) <= max_gap:
                change = abs(fx - fy)
                if change > largest:
                    largest = change
                    witness = (x, y)
    return largest, witness
```

```

def square(x):
    return x * x

def reciprocal(x):
    return 1.0 / x

def main():
    # 正常：x^2 在 [0, 1] 的簡單格點上。
    grid = [i / 10 for i in range(11)]
    print("square:", sample_pairs(square, grid, 0.1))

    # 邊界：倒數函數只取 (0, 1) 內的正格點，不納入 0 或 1。
    positive_grid = [i / 10 for i in range(1, 10)]
    print(
        "reciprocal:",
        sample_pairs(
            reciprocal,
            positive_grid,
            0.1,
            domain=lambda x: 0.0 < x < 1.0,
        ),
    )

    # 故障：拒絕把 x=0 當作倒數函數的合法取樣點。
    try:
        sample_pairs(
            reciprocal,
            [0.0, 0.1],
            0.1,
            domain=lambda x: 0.0 < x < 1.0,
        )
    except ValueError as error:
        print("expected domain failure:", error)

if __name__ == "__main__":
    main()

```

正常測試預期找到平方函數的最大樣本增量，並回報相應點對；在格距 0.1 的點集中，差值 $x^2 - y^2$ 的大小受 $2|x - y|$ 控制。倒數測試只在 (0, 1) 內的正取樣點上回報有限樣本值；取樣若沒有足夠靠近 0，不會呈現所有可能的最壞情況。故障測試預期回報 `expected domain failure`，因為 0 不屬於倒數函數的定義域。這些是對程式邏輯的預期，不是實際執行紀錄，也不是定理證明。

測試與預期結果

使用前述程式時，可以逐項核對：

- **正常測試：**輸入 [0, 1] 上的平方函數網格點，函數值有限，程式回報一組最大增量與見證點對。

- **邊界測試**：倒數測試取 $(0, 1)$ 內的正點而不取 0 或 1；有限網格上輸出應有限，但不能據此斷定 $(0, 1)$ 上一致連續。
- **故障測試**：把 0 加入倒數取樣點，定義域檢查應先失敗，且不應把故障偽裝成一般數值結果。
- **反覆加密的數值檢查**：縮小格距可增加找到極端點對的機會，但只產生更多有限資料。除非另有解析估計或完整證明，不能把樣本最大值當成所有點對的上確界。

數值證據有助於找錯及形成猜想；定義、證明與定理才決定無限命題的真偽。

反例與常見陷阱

逐點連續不等於一致連續

$f(x) = 1/x$ 在 $(0, 1)$ 逐點連續，但不一致連續。不能把「沒有區間內的跳躍」誤認為「存在全域一致誤差門檻」。

開區間的連續函數未必取得最大值

$f(x) = x$ 在 $(0, 1)$ 連續，值域為 $(0, 1)$ ；其上確界為 1，卻沒有任何 $x \in (0, 1)$ 滿足 $f(x) = 1$ 。極值定理要求緊緻定義域；開區間不緊緻。

非有界域上的連續函數未必有界

$f(x) = x$ 在 $\mathbb{R}$ 上連續而無界。連續本身並不保證值域有界，也不保證有最大值或最小值。

有界導數的條件方向不可倒置

凸域上有界導數給出 Lipschitz 估計，因此給出一致連續；但一致連續不必有有界導數。 $\sqrt{x}$ 在 $[0, 1]$ 上一致連續，卻不能在含 0 的區間上用一個有限的導數上界推出 Lipschitz 性。

有限格點不證明緊緻性

緊緻性要求對任意開覆蓋存在有限子覆蓋，或使用相應的數列刻畫。有限格點是事先選定的取樣方案，不能涵蓋所有尺度與所有點。格點上的「看起來有界」也不能證明全集合有界，除非另有已證明的誤差界。

不能把有限維結論搬到無限維

Heine–Borel 的「閉且有界當且僅當緊緻」適用於 $\mathbb{R}^n$ ， $n < \infty$ 。在無限維範數空間中，閉有界一般不推出緊緻。若問題中的輸入是函數，必須先交代函數空間、範數與所用緊緻性定理。

AI、幾何與養殖案例

假設一個純合成的感測模型，把已無因次化的兩個輸入 $u, v \in [0, 1]$ 對應到一個無因次輸出：

$$s(u, v) = u^2 + uv.$$

其偏導為 $\partial s / \partial u = 2u + v$ 、 $\partial s / \partial v = u$ 。在方形區域 $[0, 1]^2$ 上，兩個偏導皆有界；由中值估計，輸出變化可由輸入的歐氏距離以單一常數控制。因此，在這個緊緻作業範圍內，一致誤差控制有明確數學依據。

若改用有因次物理量，例如輸入以濃度與時間表示、輸出以感測電壓表示，Jacobian 各元素會有不同單位。不能直接將不同單位分量拼成未加說明的歐氏距離，再把其大小解讀為物理誤差。應先說明尺度與權重，或轉成無因次變數；計算後再按定義轉回物理量。

AI 或程式可以用有限點檢查模型、尋找可能的大誤差區，也可在解析界限已建立後協助整理證據。它不能把一批格點「看起來平滑」轉成對所有輸入的連續或一致連續證明。養殖相關數值均屬合成示例，不代表現場校準或安全性驗證；本章的分析工具只協助整理唯讀的數學證據，不控制設備、投餌或加藥。

習題

1. 手算：Lipschitz 控制

令 $f(x) = 3x^2 - x$ ，定義在 $[0, 2]$ 。以因式分解直接找出常數 L ，使

$$|f(x) - f(y)| \leq L|x - y| \quad (x, y \in [0, 2]).$$

再說明怎樣選 δ ，確保輸出差小於指定的 $\varepsilon > 0$ 。

2. 程式：搜尋倒數函數的失敗點對

沿用本章 `sample_pairs` 程式，以文字描述一組 x_k, y_k ，使 $|x_k - y_k| \rightarrow 0$ ，但倒數函數的輸出差不趨近 0。解釋把有限網格加密，為何仍不是一致連續性的證明。

3. 反例：閉集與有界性

分別舉出 $\mathbb{R}$ 中「閉但不緊緻」與「有界但不緊緻」的集合，並以一個數列指出各自欠缺的條件。

4. 整合：誤差控制的有效範圍

函數 $g(x) = \sqrt{x}$ 定義在 $[0, 1]$ 。

1. 證明 g 一致連續。
2. 說明 g 是否 Lipschitz。

3. 解釋閉區間上的緊緻性定理能推出甚麼，不能推出甚麼。

習題解答

1. 解答：Lipschitz 控制

有

$$f(x) - f(y) = 3(x^2 - y^2) - (x - y) = (x - y)(3(x + y) - 1).$$

因為 $x, y \in [0, 2]$ ，所以 $0 \leq x + y \leq 4$ ，從而 $|3(x + y) - 1| \leq 11$ 。因此可取 $L = 11$ ，有

$$|f(x) - f(y)| \leq 11|x - y|.$$

任給 $\varepsilon > 0$ ，取 $\delta = \varepsilon/11$ 。當 $|x - y| < \delta$ 時，輸出差小於 ε 。此 Lipschitz 常數未必是最佳常數，但足以證明一致連續。

2. 解答：倒數函數

對 $k \geq 2$ ，取 $x_k = 1/k$ 與 $y_k = 1/(2k)$ 。兩點都在 $(0, 1)$ 內，且

$$|x_k - y_k| = \frac{1}{2k} \rightarrow 0, \quad \left| \frac{1}{x_k} - \frac{1}{y_k} \right| = k \rightarrow \infty.$$

這一組點對直接違反一致連續的數列判準。網格加密最多能讓有限次取樣更接近邊界、增加找到大增量的機會；每一份計算依然只檢查有限多點對，沒有涵蓋所有 k 或所有點對，故不能取代上述證明。

3. 解答：兩種不緊緻集合

- $[0, \infty)$ 是閉但不緊緻。正整數列 (k) 位於其中，卻無界，因而沒有收斂子列；它欠缺有界性。
- $(0, 1)$ 是有界但不緊緻。對 $k \geq 2$ ，數列 $1/k$ 位於其中並收斂到 0，但 $0 \notin (0, 1)$ ；它欠缺閉性。

兩者都依賴 $\mathbb{R}$ 中的有限維 Heine–Borel 定理。

4. 解答：平方根

若 $x = y = 0$ ，則 $|\sqrt{x} - \sqrt{y}| = 0$ ，所需估計直接成立。其餘情形，令 $x \geq y$ ；此時 $\sqrt{x} + \sqrt{y} > 0$ ，所以可以相除：

$$|\sqrt{x} - \sqrt{y}| = \frac{x - y}{\sqrt{x} + \sqrt{y}} \leq \sqrt{x - y}.$$

最後一個不等式可驗證如下：因為 $x - y = (\sqrt{x} - \sqrt{y})(\sqrt{x} + \sqrt{y})$ ，且 $\sqrt{x} + \sqrt{y} \geq \sqrt{x} - \sqrt{y} \geq 0$ ，故 $x - y \geq (\sqrt{x} - \sqrt{y})^2$ 。若 $y \geq x$ ，交換兩者便得到同樣結論。因此對任意 $x, y \in [0, 1]$ ，

$$|\sqrt{x} - \sqrt{y}| \leq \sqrt{|x - y|}.$$

若 $|x - y| < \varepsilon^2$ ，便有 $|\sqrt{x} - \sqrt{y}| < \varepsilon$ ，所以 g 一致連續。

但 g 不 Lipschitz。若存在有限常數 L ，則取 $y = 0$ 、 $x > 0$ 應有 $\sqrt{x} \leq Lx$ ，亦即 $1/\sqrt{x} \leq L$ ；這對足夠小的正 x 不可能成立。

緊緻性加連續性可由 Heine–Cantor 定理推出一致連續，也可由極值定理推出函數取得最大值和最小值。緊緻性本身不能推出 Lipschitz 性；平方根函數正好說明一致連續不等於 Lipschitz。

本章小結

開集以每點都包含一個小球定義；閉集包含其收斂數列的極限；緊緻性要求每個開覆蓋都有有限子覆蓋。對有限維 $\mathbb{R}^n$ ，Heine–Borel 定理給出緊緻等價於閉且有界，但此結論不可直接搬到無限維空間。

逐點連續允許輸入門檻隨位置改變；一致連續要求同一個門檻適用於整個定義域。緊緻集上的連續函數一致連續，且連續實值函數取得最大與最小值。這些定理有嚴格的定義域與正則性條件：開區間或非有界域上的連續函數，未必一致連續，也未必取得極值。

手算估計能給出明確誤差界；反例能否定一般性主張；有限格點與程式輸出則是數值證據，不是對無限命題的證明。使用數值檢查時，要把取樣範圍、函數定義域、量綱與尚未證明的部分一併說清楚。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*，作者目錄與教材入口：<https://www.jirka.org/ra/>
- [A2] MIT OpenCourseWare, *18.100A Real Analysis*：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- [A3] MIT OpenCourseWare, *18.02SC Multivariable Calculus*：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

以上列出教材與課程入口，供讀者延伸閱讀；本章的定義、證明與例題不依賴外部程式執行結果。

第06章 單變量微積分的嚴格橋接

學習目標與先備知識

本章把讀者從第1~5章建立的極限、範數、連續性與完備性工具，接到單變量微積分最常用的三根支柱：均值定理（Mean Value Theorem, MVT）、Riemann 積分、以及微積分基本定理（Fundamental Theorem of Calculus, FTC）；再以 Taylor 定理的餘項條件把「局部展開」放回嚴格分析的框架。先在 Volume I 已建立的矩陣與線性映射語言下工作： $f: U \subset \mathbb{R}^n \rightarrow \mathbb{R}^m$ 、 $J_f(x) \in \mathbb{R}^{m \times n}$ 、輸入擾動 h 為 $n \times 1$ 、 $Df(x)[h] = J_f(x)h$ ；標量 φ 的 $D\varphi$ 是線性泛函（ $1 \times n$ ），Euclidean 梯度 $\nabla\varphi$ 是 $n \times 1$ 列向量， $D\varphi[h] = (\nabla\varphi)^T h$ 。本章刻意只處理 $n = m = 1$ 的單變量情形，卻要求每一條定理的域（domain）、正則性（regularity）與結論都被明示；有限計算只在數值證據欄標示，不冒充證明。

學習目標如下。第一，能寫出可微性的餘項定義，並與「導數存在」等價地互相推導。第二，能用 Darboux 上下和判據判定 Riemann 可積，並區分「有界」與「可積」。第三，能分別陳述 MVT、FTC 兩種形式、Taylor 三種餘項（Lagrange、積分、Peano）所需的條件；尤其必須分清 Peano 形式只需有限次可微，而 Lagrange／積分形式需要更強的正則性。第四，能用自足 CPU 程式手算並驗證梯形法、中點法與導數步長掃描，並能標示「正常、邊界、故障」三類預期結果。第五，能在合成感測器校準案例中，把一次 Taylor 近似與其餘項界寫成帶單位的可稽核證據鏈；明確指出模型校準不等於現場驗證、數學穩定不等於操作安全。

先備方面，讀者需熟悉實數完備性（supremum 存在）、數列與級數極限、單變量極限與連續性的 ε - δ 定義、閉區間上的 Heine–Borel 與極值定理，以及第5章關於開閉集與一致連續的討論。也要熟悉矩陣橫列（row）與縱行（column）的區分，以及「列向量是直向量」的約定。

問題與直覺

單變量微積分在入門課程常以圖像與公式直覺呈現：切線斜率就是導數，曲線下面積就是積分，導數與積分互逆。直覺本身沒有錯，但若用它取代條件，就會在下列四個問題上失誤：

1. MVT 說「存在 c 使割線斜率等於切線斜率」。若函數在閉區間不連續，或開區間不可微，都可能找不到這樣的 c 。例如 $f(x) = |x|$ 在 $[-1, 1]$ 上連續但不處處可微，割線斜率為 0，可是找不到內點導數為 0。
2. Riemann 可積不等於「函數有原函數」。有界且 Riemann 可積的函數未必處處有導數；反之有界導數的函數未必 Riemann 可積。FTC 第二形式必須同時要求原函數存在且可積性成立。
3. Taylor 展開的餘項有三種常用形式，各自條件不同。Peano 形式 $o(|x - a|^n)$ 只需 f 在 a 附近 n 次可微；Lagrange 與積分形式需要更強的 C^{n+1} 或等價假設。把 Peano 的假設在文字上誤記為「 $f^{(n)}$ 必須連續」，或反過來把 $o(|x - a|^n)$ 隨口升級為 $O(|x - a|^{n+1})$ ，都是常見錯誤。
4. 數值掃描步長 h 與函數值量測精度有限，前向差分的誤差 $O(h)$ 與中央差分 $O(h^2)$ 都會在 h 太小時被浮點捨入誤差 $O(\varepsilon_{\text{mach}}/h)$ 淹沒；數值結果是證據標籤，不是極限證明。

本章的基本立場是：定義先行、條件寫清、證明與反例成對、數值只在允許的範圍內提供支持或否認個別主張。

定義、定理與推導

定義 6.1（單變量可微性）

設 $I \subset \mathbb{R}$ 為開區間， $f: I \rightarrow \mathbb{R}$ ， $a \in I$ 。若存在實數 $f'(a)$ 使

$$f(a+h) = f(a) + f'(a)h + r(h), \quad \lim_{h \rightarrow 0} \frac{r(h)}{|h|} = 0,$$

則稱 f 在 a 可微， $f'(a)$ 為其導數。等價地， $f'(a) = \lim_{h \rightarrow 0} (f(a+h) - f(a))/h$ 。

注意 r 的量綱： f 與 r 同單位， h 與 a 同單位， $f'(a)$ 具有「 f 單位/ a 單位」的因次。

定義 6.2（Riemann 和與 Riemann 可積）

設 $f: [a, b] \rightarrow \mathbb{R}$ 有界。分割 $P = \{x_0 = a < x_1 < \cdots < x_n = b\}$ ，取樣點 $\xi_i \in [x_{i-1}, x_i]$ ， $\Delta x_i = x_i - x_{i-1}$ ，定義 Riemann 和

$$S(f, P, \xi) = \sum_{i=1}^n f(\xi_i) \Delta x_i.$$

若存在 $I \in \mathbb{R}$ ，對每個 $\varepsilon > 0$ 存在 $\delta > 0$ ，使任何 $\text{mesh } \|P\| = \max_i \Delta x_i < \delta$ 的分割及任取樣點 ξ 都有 $|S(f, P, \xi) - I| < \varepsilon$ ，則稱 f 在 $[a, b]$ 上 Riemann 可積， $I = \int_a^b f$ 。

定義 6.3（Darboux 上下和與振盪）

設 $M_i = \sup_{x \in [x_{i-1}, x_i]} f(x)$ 、 $m_i = \inf_{x \in [x_{i-1}, x_i]} f(x)$ ，振盪 $\omega_i = M_i - m_i$ 。定義

$$U(f, P) = \sum_i M_i \Delta x_i, \quad L(f, P) = \sum_i m_i \Delta x_i, \quad U - L = \sum_i \omega_i \Delta x_i.$$

定理 6.4（Darboux 判據）

$f: [a, b] \rightarrow \mathbb{R}$ 有界。則 f Riemann 可積若且唯若對任意 $\varepsilon > 0$ 存在分割 P 使 $U(f, P) - L(f, P) < \varepsilon$ 。

證明大綱：若可積為 I ，取 $\varepsilon > 0$ 對應的 δ ；對細分分割 P 及適當取樣， $|U - I| \leq \varepsilon/2$ 、 $|I - L| \leq \varepsilon/2$ ，相加得 $U - L < \varepsilon$ 。反之，由 $L \leq S \leq U$ 及上下和可任意接近同一值，利用完備性取 $I = \sup_P L(f, P) = \inf_P U(f, P)$ 即可。□

命題 6.5 (連續函數在閉區間上可積)

若 $f: [a, b] \rightarrow \mathbb{R}$ 連續，則 f Riemann 可積。

完整證明：因 $[a, b]$ 緊緻且 f 連續，由一致連續（第5章）對任意 $\eta > 0$ 存在 $\delta > 0$ ，當 $|x - y| < \delta$ 時 $|f(x) - f(y)| < \eta$ 。取分割 P 使 $\|P\| < \delta$ ，則每個小區間振盪 $\omega_i \leq \eta$ ，所以

$$U(f, P) - L(f, P) = \sum_i \omega_i \Delta x_i \leq \eta \sum_i \Delta x_i = \eta(b - a).$$

對任意 $\varepsilon > 0$ 取 $\eta = \varepsilon/(b - a)$ ，即得 $U - L < \varepsilon$ 。由定理 6.4 可積。■

此處使用了緊緻性與一致連續，兩者缺一不可。若只假設逐點連續而域不緊緻，一致連續可能不成立。

定理 6.6 (Mean Value Theorem, Lagrange 形式)

設 $f: [a, b] \rightarrow \mathbb{R}$ 連續，在 (a, b) 可微，則存在 $c \in (a, b)$ 使

$$f'(c) = \frac{f(b) - f(a)}{b - a}.$$

完整證明：定義

$$g(x) = f(x) - f(a) - \frac{f(b) - f(a)}{b - a}(x - a).$$

g 在 $[a, b]$ 連續且 $g(a) = g(b) = 0$ 。若 g 為常數 0，則 f 在 $[a, b]$ 上為一次函數，內點導數處處等於割線斜率，任取 c 即成立。否則存在 $x_0 \in (a, b)$ 使 $g(x_0) \neq 0$ ；不失一般性 $g(x_0) > 0$ 。因 g 在緊緻 $[a, b]$ 上連續，取最大值點 $c \in [a, b]$ 。由於 $g(a) = g(b) = 0 < g(x_0)$ ， c 為內點。由 Fermat 定理（內點極值處可微函數導數為零） $g'(c) = 0$ ，即

$$f'(c) - \frac{f(b) - f(a)}{b - a} = 0.$$

$g(x_0) < 0$ 的情形同理由最小值點得證。■

定理 6.7 (FTC 第一形式)

設 $f: [a, b] \rightarrow \mathbb{R}$ 連續，定義 $F(x) = \int_a^x f(t) dt$ ， $x \in [a, b]$ 。則 F 在 $[a, b]$ 連續，在 (a, b) 可微，且 $F'(x) = f(x)$ 。

證明大綱：對 $x \in (a, b)$ 與 $h \neq 0$ 使 $x + h \in [a, b]$ ，

$$\frac{F(x + h) - F(x)}{h} = \frac{1}{h} \int_x^{x+h} f(t) dt.$$

設 $M_h = \sup_{|t-x| \leq |h|} |f(t) - f(x)|$ ，由 f 在 x 連續， $M_h \rightarrow 0$ 。則

$$\left| \frac{1}{h} \int_x^{x+h} f(t) dt - f(x) \right| \leq M_h \rightarrow 0.$$

故 $F'(x) = f(x)$ 。□

定理 6.8 (FTC 第二形式)

設 $f: [a, b] \rightarrow \mathbb{R}$ Riemann 可積， $F: [a, b] \rightarrow \mathbb{R}$ 連續、在 (a, b) 可微且 $F'(x) = f(x)$ 對所有 $x \in (a, b)$ 。則

$$\int_a^b f = F(b) - F(a).$$

證明大綱：對分割 P ，由 MVT (定理 6.6) 在每個 $[x_{i-1}, x_i]$ 上存在 c_i 使

$$F(x_i) - F(x_{i-1}) = F'(c_i) \Delta x_i = f(c_i) \Delta x_i.$$

求和得 $F(b) - F(a) = S(f, P, \{c_i\})$ 。由於 f 可積，取 $\|P\| \rightarrow 0$ 時 $S(f, P, \{c_i\}) \rightarrow \int_a^b f$ 。□

定理 6.9 (Taylor 定理，Lagrange 餘項)

設 f 在含 a 與 x 的閉區間上 C^n (即前 n 階導數存在且連續)，在對應開區間上 $n+1$ 次可微，則

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x-a)^k + R_n(x), \quad R_n(x) = \frac{f^{(n+1)}(c)}{(n+1)!} (x-a)^{n+1},$$

其中 c 介於 a 與 x 之間。此形式需要控制的最高階導數 $f^{(n+1)}$ 在 (a, x) 上存在，且前面各階導數連續，用於把餘項寫成單一函數值。

定理 6.10 (Taylor 定理，積分餘項)

若 f 在含 a 與 x 的閉區間上 C^{n+1} (前 $n+1$ 階導數存在且連續)，則

$$R_n(x) = \int_a^x \frac{f^{(n+1)}(t)}{n!} (x-t)^n dt.$$

積分形式的優點是把餘項表為與 $f^{(n+1)}$ 的積分，不需另取中間點；代價是要求 $f^{(n+1)}$ 在整個區間上連續。

定理 6.11 (Taylor 定理，Peano 餘項)

設 f 在 a 的某鄰域上 n 次可微 (即 $f', f'', \dots, f^{(n)}$ 在該鄰域上皆存在)，則

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x-a)^k + R_n(x), \quad R_n(x) = o(|x-a|^n), \quad x \rightarrow a.$$

等價地， $\lim_{x \rightarrow a} R_n(x)/|x-a|^n = 0$ 。

條件對比：Peano 形式**不要求** $f^{(n)}$ 在 a 連續，只要求 f 在 a 附近前 n 階導數存在；這是三種餘項形式中假設最弱的一種。證明使用重複 L'Hôpital 或迭代均值定理，只需前 n 階導數在 a 附近存在即可。Peano 形式給出「餘項比 $|x-a|^n$ 更高階」的漸近資訊，但**不給** $O(|x-a|^{n+1})$ 的界；若需後者，須另加 $f^{(n+1)}$ 在相關區間上有界（Lagrange 或積分形式）等更強假設。把 Peano 餘項無條件升階為 $O(|x-a|^{n+1})$ 是常見錯誤；把 Peano 的假設誤記為「 $f^{(n)}$ 連續」則是常見的條件誤抄。

逐步手算例題

例 6.1 (MVT 手算)

$f(x) = x^3$ 在 $[0, 2]$ 上。割線斜率

$$\frac{f(2) - f(0)}{2 - 0} = \frac{8 - 0}{2} = 4.$$

解 $f'(c) = 3c^2 = 4$ ，得 $c = \pm 2/\sqrt{3}$ ，取 $c = 2/\sqrt{3} \approx 1.1547 \in (0, 2)$ 。驗算： $f'(c) = 3 \cdot 4/3 = 4$ 。割線斜率與切線斜率吻合， c 落在內點。

例 6.2 (FTC 與 Riemann 和手算)

計算 $\int_0^1 x^2 dx$ ，取右端點 Riemann 和： $x_i = i/n$ ， $\xi_i = i/n$ ，

$$S_n = \sum_{i=1}^n \left(\frac{i}{n}\right)^2 \frac{1}{n} = \frac{1}{n^3} \cdot \frac{n(n+1)(2n+1)}{6} = \frac{(n+1)(2n+1)}{6n^2}.$$

取極限 $n \rightarrow \infty$ 得 $S_n \rightarrow 1/3$ 。由定理 6.8，取 $F(x) = x^3/3$ 得 $\int_0^1 x^2 = F(1) - F(0) = 1/3$ ，兩者一致。

例 6.3 (Taylor 餘項手算)

$f(x) = e^x$ 在 $a = 0$ 展開至 $n = 3$ ， $x = 1$ ：

$$e^1 \approx 1 + 1 + \frac{1}{2} + \frac{1}{6} = \frac{8}{3} \approx 2.6667.$$

Lagrange 餘項 $R_3(1) = e^c/4!$ ， $c \in (0, 1)$ ，故 $1/24 < R_3(1) < e/24 \approx 0.1133$ 。實際 $e - 8/3 \approx 0.0516$ ，落在界內。若要更緊的界，將 n 提高到 5： $|R_5(1)| \leq e/720 \approx 0.0038$ 。

例 6.4 (分段單調性與 MVT 的界限)

$f(x) = x - \sin x$ 在 $[0, 2\pi]$ 上。割線斜率 $(f(2\pi) - f(0))/(2\pi - 0) = 1$ 。 $f'(x) = 1 - \cos x \geq 0$ ，且在 $x = 0, 2\pi$ 為 0；是否能在 $(0, 2\pi)$ 內找到 c 使 $f'(c) = 1$ ？需要 $\cos c = 0$ ，即 $c = \pi/2$ 或 $c = 3\pi/2$ ，兩者都在內點，成立。此例說明 MVT 的存在性不能只靠端點資訊，需使用內部極值或單調性分析。

例 6.5 (Peano 形式的階數限制手算)

$f(x) = x^2 \sin(1/x^2)$ ($x \neq 0$)， $f(0) = 0$ 。計算 $f'(0)$ ：

$$f'(0) = \lim_{x \rightarrow 0} \frac{f(x) - f(0)}{x} = \lim_{x \rightarrow 0} x \sin(1/x^2) = 0.$$

所以 f 在 0 一次可微，Peano 形式 $n = 1$ 給出 $f(x) = 0 + 0 \cdot x + o(|x|)$ ，即

$$\frac{|R_1(x)|}{|x|} = \frac{|x^2 \sin(1/x^2)|}{|x|} = |x| |\sin(1/x^2)| \leq |x| \rightarrow 0,$$

餘項確實是 $o(|x|)$ 。但 $f''(0)$ 不存在： $x \neq 0$ 時 $f'(x) = 2x \sin(1/x^2) - 2 \cos(1/x^2)/x$ ， $f''(0) = \lim_{x \rightarrow 0} (f'(x) - f'(0))/x = \lim_{x \rightarrow 0} (2 \sin(1/x^2) - 2 \cos(1/x^2)/x^2)$ ，第二項震盪且無界，極限不存在。故 $n = 2$ 的 Peano 展開不可用。此例在數值上也能核對：取 $x = 10^{-3}$ ， $R_1(x)/|x| = 10^{-3} |\sin(10^6)|$ 在 $[0, 10^{-3}]$ 內；取 $x = 10^{-6}$ ， $R_1(x)/|x| \leq 10^{-6}$ ，符合 $o(|x|)$ 的收斂速率，但不代表有 $O(|x|^2)$ 的界（取 $x = 1/\sqrt{(2k+1)\pi - \pi/2}$ 可使 $|R_1|/|x|^2 = |\sin(1/x^2)| = 1$ ，阻止 $O(|x|^2)$ ）。

實作與程式

以下程式僅用 NumPy 與 Python 標準庫，不呼叫 SciPy、不安裝、不執行；若實際執行，輸出以本章「測試與預期結果」欄標示為預期值。程式提供梯形法、中點法、中央差分與步長掃描。

```
import numpy as np

def trapezoid(f, a, b, n):
    x = np.linspace(a, b, n + 1)
    y = f(x)
    h = (b - a) / n
    return h * (0.5 * y[0] + np.sum(y[1:-1]) + 0.5 * y[-1])

def midpoint(f, a, b, n):
    h = (b - a) / n
    x = a + (np.arange(n) + 0.5) * h
    return h * np.sum(f(x))

def central_diff(f, x, h):
    return (f(x + h) - f(x - h)) / (2.0 * h)

def derivative_scan(f, x, hs):
    return [(h, central_diff(f, x, h)) for h in hs]
```

```

if __name__ == "__main__":
    # 例 6.2:  $\int_0^1 x^2 dx = 1/3$ 
    f = lambda x: x * x
    for n in [10, 100, 1000]:
        T = trapezoid(f, 0.0, 1.0, n)
        M = midpoint(f, 0.0, 1.0, n)
        print(f"n={n:>5d}   trapezoid={T:.12f}   midpoint={M:.12f}")

    # 導數步長掃描:  $f(x)=\sin(x)$  在  $x=1$  的真導數  $\cos(1)$ 
    import math
    g = np.sin
    hs = [1e-1, 1e-2, 1e-3, 1e-4, 1e-5, 1e-6, 1e-7, 1e-8]
    for h, d in derivative_scan(g, 1.0, hs):
        print(f"h={h:.1e}   D={d:.12f}   err={abs(d - math.cos(1.0)):.3e}")

```

程式的維度約定：`f` 接受 NumPy 一維陣列 `x`，回傳同形狀；`central_diff` 回傳純量；`derivative_scan` 回傳 (h, D) 清單。若要把導數寫成線性映射，單變量情形下 $J_f(x)$ 為 1×1 ；第7章擴展至 $n, m > 1$ 時， J_f 為 $m \times n$ 。

測試與預期結果

正常測試 (N)。 $f(x) = x^2$ ， $[0, 1]$ ， $n = 10, 100, 1000$ ：梯形與中點誤差皆為 $O(h^2)$ 。預期 $n = 10$ 時梯形 ≈ 0.335 、中點 ≈ 0.3325 ； $n = 1000$ 時兩者皆在 10^{-6} 級別接近 0.333333333333 。

邊界測試 (B)。區間退化成 $[a, a]$ 或步長 $h = 0$ ：程式不應默默回傳 NaN。預期 `trapezoid(f, 0, 0, n)` 回傳 0；`central_diff(f, 1.0, 0.0)` 引發 `ZeroDivisionError`（除零），必須由呼叫者檢查。

故障測試 (F)。步長 $h = 10^{-8}$ ， $f = \sin$ ， $x = 1$ ：中央差分理論誤差 $O(h^2) = 10^{-16}$ ，但浮點捨入最小值 $\approx \varepsilon_{\text{mach}}/(2h) \approx 1.1 \times 10^{-8}$ 。預期誤差不再隨 h 縮小而縮小，甚至可能變大。這不是定理失敗，而是數值精度限制。

證據標籤。所有數值結果標示「預期」或「實測（未執行）」；不得寫成「已驗證定理」。有限格點的誤差是對演算法行為的證據，不是 Riemann 可積或 FTC 的證明。

反例與常見陷阱

反例 6.1 (MVT 缺連續或可微)。 $f: [-1, 1] \rightarrow \mathbb{R}$ ， $f(x) = |x|$ ：在 $[-1, 1]$ 連續但不處處可微。 $f(-1) = f(1) = 1$ ，割線斜率為 0，但內點無 c 使 $f'(c) = 0$ （ $x \neq 0$ 處導數 ± 1 ， $x = 0$ 不可微）。可見「閉區間連續、開區間可微」兩條件皆不可缺。

反例 6.2 (有界但不可積)。取 $f(x) = 1$ 當 $x \in [0, 1] \cap \mathbb{Q}$ ， $f(x) = 0$ 否則（Dirichlet 型）。任何分割 P 的每個子區間都含無理數與有理數（有理數與無理數在 $\mathbb{R}$ 稠密），故 $M_i = 1$ 、 $m_i = 0$ ， $U(f, P) = 1$ 、 $L(f, P) = 0$ ， $U - L = 1$ 。對任意 $\varepsilon < 1$ 都找不到分割使 $U - L < \varepsilon$ ，由定理 6.4 不可積。可見「有界」不足以推出「Riemann 可積」。

反例 6.3 (Lagrange 條件不成立，但 Peano 形式仍成立)。取 $f(x) = x^3 \sin(1/x^2)$ ($x \neq 0$)， $f(0) = 0$ 。 f 在 0 附近一次可微， $f'(0) = 0$ ；但 $x \neq 0$ 時 $f'(x) = 3x^2 \sin(1/x^2) - 2 \cos(1/x^2)$ ， f' 在 0 附近震盪無極限， f' 在 0 不連續，故 f 在 0 的鄰域不屬 C^1 。Lagrange 餘項 $n = 1$ 的陳述需要 f 在閉區間上 C^1 且在開區間二次可微，此例不滿足，故不可套用；積分餘項 $n = 1$ 需要 C^2 ，更不適用。但 Peano 餘項 $n = 1$ 只要求 f 在 0 附近一次可微，此例滿足：

$$\frac{|R_1(x)|}{|x|} = \frac{|x^3 \sin(1/x^2)|}{|x|} = x^2 |\sin(1/x^2)| \rightarrow 0,$$

餘項確為 $o(|x|)$ 。此例說明「Lagrange 條件不成立」不等於「Peano 餘項不成立」；把三者條件混為一談會誤判可用性。

反例 6.4 (FTC 第二形式的域條件)。 $f(x) = 1/x$ 在 $[-1, 1]$ 上有原函數 $\ln|x|$ 於每個不含 0 的子區間，但 f 在 0 無界。若取 $a < 0 < b$ ， f 在 $[a, b]$ 上無界、非 Riemann 可積，FTC 第二形式不適用。即使 $F'(x) = f(x)$ 於 $(a, b) \setminus \{0\}$ 成立， F 在 0 也不連續，違反「 F 在 $[a, b]$ 連續」的前提。

反例 6.5 (Peano 形式的階數上限)。取 $f(x) = x^2 \sin(1/x^2)$ ($x \neq 0$)， $f(0) = 0$ 。 $f'(0) = \lim_{x \rightarrow 0} x \sin(1/x^2) = 0$ ，所以 f 在 0 一次可微，Peano 形式 $n = 1$ 成立： $f(x) = f(0) + f'(0)x + o(|x|)$ ，即 $R_1(x) = x^2 \sin(1/x^2) = o(|x|)$ （見例 6.5 的手算）。但 $f''(0)$ 不存在： $x \neq 0$ 時 $f'(x) = 2x \sin(1/x^2) - 2 \cos(1/x^2)/x$ ，故

$$\frac{f'(x) - f'(0)}{x} = 2 \sin(1/x^2) - \frac{2 \cos(1/x^2)}{x^2},$$

第二項震盪且無界，極限不存在。因此 $n = 2$ 的 Peano 展開 $f(x) = f(0) + f'(0)x + \frac{1}{2}f''(0)x^2 + o(|x|^2)$ 不適用。更進一步，即便有 $R_1 = o(|x|)$ ，也不代表 $R_1 = O(|x|^2)$ ：取 $x_k = 1/\sqrt{(2k+1)\pi - \pi/2}$ 使 $\cos(1/x_k^2) = 0$ 、 $\sin(1/x_k^2) = \pm 1$ ，則 $|R_1(x_k)|/|x_k|^2 = |\sin(1/x_k^2)| = 1$ 不趨零，阻止 $O(|x|^2)$ 。此例說明 Peano 的階數受 f 實際可微次數限制，也不應把 $o(|x|^n)$ 無條件升為 $O(|x|^{n+1})$ 。

AI、幾何與養殖案例

合成感測器校準。假設一個水溫感測器的輸出電壓 V （單位：V）與水溫 T （單位： $^{\circ}\text{C}$ ）在局部滿足 $V = g(T)$ ， g 在 $T_0 = 25$ 附近 C^2 。由 Taylor 定理（Lagrange 餘項）

$$V(T_0 + \Delta T) = g(T_0) + g'(T_0)\Delta T + \frac{1}{2}g''(c)\Delta T^2, \quad c \in (T_0, T_0 + \Delta T).$$

$g'(T_0)$ 單位為 $\text{V}/^{\circ}\text{C}$ ， $g''(T_0)$ 單位為 $\text{V}/^{\circ}\text{C}^2$ 。若 $|g''| \leq M_2$ 在 $[20, 30]$ 上成立，則 $|\Delta T| \leq 5$ 時餘項界為 $M_2 \cdot 25/2 \text{ V}$ 。這是局部線性化誤差的嚴格界，不是對整個量測範圍的斷言。若只知 g 在 T_0 附近二次可微而無 g'' 的界或連續性，則只能用 Peano 形式得到餘項為 $o(\Delta T^2)$ ，無法給出數值上界：這也是為何感測器校準報告必須同時記錄正則性假設與界函數 M_2 。

幾何直覺。MVT 表示割線斜率與某切線斜率相同；在圖形上，割線與切線平行。FTC 表示面積函數的變化率等於被積函數；在圖形上，細長矩形的疊加在細分極限趨近曲線下面積。AI 與自動微分的實作必須建立在此嚴格框架上：JVP 或 VJP 只是把鏈式法則與 Jacobian 乘法寫成計算圖，但它們不改變條件本身所需要的連續可微性假設。計算圖若在不可微點自動給出次梯度或震盪值，必須在其外層軟體的文件中明說，不能以「微分框架能跑」取代「函數在該點可微」。

養殖案例（合成）。假設溶氧感測器在 $T \in [20, 30]$ °C、鹽度 $S \in [25, 35]$ （合成單位）下輸出 $y = f(T, S)$ 。本章只處理單變量切片：固定 $S = 30$ ，對 T 做一次 Taylor 近似 $f(T_0 + \Delta T, 30) \approx f(T_0, 30) + \partial_T f(T_0, 30)\Delta T$ 。餘項界需 $\partial_{TT} f$ 在 $[20, 30]$ 上有界。此模型不控制設備、不改投餌、不加藥；agent 唯讀整理證據，校準誤差與安全操作是兩回事。

單位與完備性。MVT 出現割線與切線斜率，兩者單位都是「輸出／輸入」。FTC 的積分 $\int_a^b f$ 若 $f : [a, b] \rightarrow \mathbb{R}$ 有單位 U ，則積分單位為 $U \cdot (x \text{ 單位})$ 。Taylor 餘項與函數本身同單位。任何「無權重 Euclidean 長度」混合不同單位的分量時，必須先無因次化，否則數值比較沒有物理意義。

數值驗證的角色。本章的 CPU 實作用於：檢查 Riemann 和隨分割細化的收斂速率、檢查中央差分的步長掃描、檢查 Taylor 餘項是否被 Lagrange 界覆蓋。這些結果標為「數值證據」，不能改寫成「定理已證明」。

習題

習題 6.1（手算／MVT）。 $f(x) = \ln x$ 在 $[1, e]$ 上，求 MVT 中的 c ，並驗算 $f'(c)$ 等於割線斜率。

習題 6.2（程式／Riemann 和）。用上述 trapezoid 與 midpoint 計算 $\int_0^1 e^{-x^2} dx$ ，取 $n = 4, 8, 16, 32$ ，記錄誤差與倍率。真值取 $\sqrt{\pi}/2 \cdot \text{erf}(1)$ ，可用 `math.erf`。請標示這是數值證據，不是定理。

習題 6.3（反例／FTC）。證明 $f(x) = 1$ 當 $x \in [0, 1] \cap \mathbb{Q}$ ， $f(x) = 0$ 否則，不 Riemann 可積；並說明 FTC 第二形式為何不適用。

習題 6.4（整合／Taylor 與感測器）。假設 $g(T) = a_0 + a_1(T - T_0) + a_2(T - T_0)^2$ ， $a_0 = 0.5 \text{ V}$ 、 $a_1 = 0.04 \text{ V/}^\circ\text{C}$ 、 $a_2 = -1.2 \times 10^{-3} \text{ V/}^\circ\text{C}^2$ ， $T_0 = 25 \text{ }^\circ\text{C}$ 。用一次 Taylor 近似估計 $g(30)$ ，並用 Lagrange 餘項給出誤差界（取 $[25, 30]$ 上 $|g''| \leq 2|a_2|$ ）。

習題 6.5（條件辨析／Peano 與 Lagrange）。對 $f(x) = x^2 \sin(1/x^2)$ ($x \neq 0$)， $f(0) = 0$ ，說明：(a) Peano 形式 $n = 1$ 成立；(b) $f''(0)$ 不存在，故 $n = 2$ 的 Peano 形式與 $n = 1$ 的 Lagrange 形式都不可用；(c) 驗證 $R_1(x)$ 不是 $O(|x|^2)$ 。此題要求明確區分三種餘項的假設，不以文字混淆取代證明。

習題解答

解答 6.1。 $f(1) = 0$ ， $f(e) = 1$ ，割線斜率 $1/(e - 1) \approx 0.5820$ 。 $f'(x) = 1/x$ ，設 $1/c = 1/(e - 1)$ ，得 $c = e - 1 \approx 1.7183 \in (1, e)$ 。驗算： $f'(c) = 1/(e - 1)$ ，等於割線斜率，MVT 結論成立。此處 f 在 $[1, e]$ 連續、在 $(1, e)$ 可微，兩條件皆滿足。

解答 6.2。取 $f(x) = e^{-x^2}$ ，真值 $I = \int_0^1 e^{-x^2} dx \approx 0.746824132812427$ 。預期梯形與中點誤差皆為 $O(h^2)$ ： $n = 4 \rightarrow n = 8$ 時誤差約降為 $1/4$ ， $n = 8 \rightarrow 16$ 再降為 $1/4$ 。若某次結果誤差反而變大，須先檢查浮點捨入與 n 是否已足夠大；這仍是數值行為，不是收斂定理的證明。定理上的收斂由連續函數可積性（命題 6.5）與 Riemann 和收斂保證，程式只是支持。

解答 6.3。對任意分割 P ，每個子區間 $[x_{i-1}, x_i]$ 都含無理數與有理數（有理數與無理數在 $\mathbb{R}$ 稠密）。故 $M_i = 1, m_i = 0, U(f, P) = b - a = 1, L(f, P) = 0, U - L = 1$ 。對任意 $\varepsilon < 1$ 都找不到分割使 $U - L < \varepsilon$ ，由定理 6.4 不可積。由於 FTC 第二形式要求 f Riemann 可積，該定理不適用；即使嘗試找原函數，也因 f 處處不連續而無連續可微原函數可取。

解答 6.4。一次 Taylor 近似：

$$g(30) \approx g(25) + g'(25) \cdot 5 = 0.5 + 0.04 \cdot 5 = 0.70 \text{ V.}$$

$g''(T) = 2a_2 = -2.4 \times 10^{-3} \text{ V/}^\circ\text{C}^2$ ，故 $|g''| \leq 2.4 \times 10^{-3}$ 。Lagrange 餘項界：

$$|R_1(30)| \leq \frac{\max_{[25,30]} |g''|}{2!} \cdot 5^2 \leq \frac{2.4 \times 10^{-3}}{2} \cdot 25 = 0.03 \text{ V.}$$

所以 $g(30) \in [0.67, 0.73] \text{ V}$ （假設 g 確為上述二次函數，則 $g(30) = 0.5 + 0.2 - 0.03 = 0.67 \text{ V}$ ，恰在界端）。此為合成數據，不構成現場驗證；模型校準不等於操作安全。

解答 6.5。(a) 由例 6.5 已算 $f'(0) = 0$ ，且 f 在 0 附近一次可微，故 Peano 形式 $n = 1$ 適用，得 $R_1(x)/|x| = |\sin(1/x^2)| \leq |x| \rightarrow 0$ ，即 $R_1(x) = o(|x|)$ 。(b) 計算 $f''(0)$ ： $x \neq 0$ 時 $f'(x) = 2x \sin(1/x^2) - 2 \cos(1/x^2)/x$ ，故

$$\frac{f'(x) - f'(0)}{x} = 2 \sin(1/x^2) - \frac{2 \cos(1/x^2)}{x^2}.$$

第二項震盪且無界，極限不存在，故 $f''(0)$ 不存在。此例 f 在 0 附近滿足「二次可微」不成立，Peano 形式 $n = 2$ 不可用；同理 $n = 1$ 的 Lagrange 餘項 $R_1(x) = f''(c)x^2/2$ 需要 f 在相關區間上二次可微，也不適用。(c) 取 $x_k = 1/\sqrt{(2k+1)\pi - \pi/2}$ ，則 $\sin(1/x_k^2) = \sin((2k+1)\pi - \pi/2) = \sin(2k\pi + \pi/2) = 1$ 的絕對值為 1， $|R_1(x_k)|/|x_k|^2 = |\sin(1/x_k^2)| = 1 \not\rightarrow 0$ ，故不存在常數 C 使 $|R_1(x)| \leq C|x|^2$ 對足夠小的 x 成立。這說明 Peano 餘項的 o 估計與 O 估計必須分清：前者由 f 一次可微即可保證，後者則需要更強的 $f^{(2)}$ 或 $f^{(3)}$ 相關條件。

本章小結

本章以 MVT、Riemann 積分、FTC 兩種形式與 Taylor 三種餘項為骨架，建立單變量微積分的嚴格橋接。核心訊息有四點。第一，函數的域與正則性必須先寫清：MVT 要求閉區間連續、開區間可微；FTC 第二形式要求被積函數 Riemann 可積且存在連續可微原函數；Taylor 的 Lagrange 餘項要求 C^n 與 $n+1$ 次可微，積分餘項要求 C^{n+1} ，而 Peano 餘項只要求前 n 階導數在 a 附近存在。第二，證明與反例成對：命題 6.5 使用緊緻性與一致連續；反例 6.2 顯示有界不蘊含可積；反例 6.3 與例 6.5 說明 Peano 形式與 Lagrange 形式

的假設確實不同，不可混為一談。第三，數值驗證是證據而非證明；梯形法與中點法的 $O(h^2)$ 、中央差分的 $O(h^2)$ 與浮點下限，都在「測試與預期結果」欄標示為預期或實測。第四，合成感測器校準案例把一次 Taylor 近似與餘項界放入單位與量綱框架，明確標示局部線性化的有效範圍，不把校準當現場驗證，也不把數學穩定當操作安全。

第7章起把上述單變量結論推廣到 Fréchet 導數與多變量 Jacobian，把 Taylor 餘項寫成 $o(\|h\|^n)$ 或更強形式，並在向量值情形中處理 Jacobian 的形狀與轉置關係。本章的公式與程式將作為後續章節的直接參考點。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*，作者教材目錄頁：<https://www.jirka.org/ra/>。2026-10-05 已取得作者首頁入口；未逐頁閱讀全書，相關定理以本書自陳條件為準。
- [A2] MIT OCW 18.100A *Real Analysis*，課程概要：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>。作為實分析主題與習題參照。
- [A3] MIT OCW 18.02SC *Multivariable Calculus*，課程概要：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>。作為多變量主題延伸參照。
- [A4] JAX Autodiff Cookbook：JVP/VJP，https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html。作為後續自動微分章節的介面概念參照；本章核心不要求 JAX。
- [A5] SciPy `expm` 文件：<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>。作為後續矩陣指數章節的選用工具參照；本章不執行 SciPy。
- [A6] SciPy `minimize` 文件：<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>。作為後續最佳化章節的選用工具參照。

來源狀態：以上頁面已於 2026-10-05 取得概要；未讀完教材 PDF、未執行任何外部程式，也不代表全卷定理逐條查證。線上 API 版本可能與本機不同。SciPy、JAX 為延伸參考，核心僅使用 Python 標準庫與 NumPy 小型 CPU 運算；不安裝套件、不啟動 GPU、不執行未審核生成程式。

第07章 Fréchet導數與餘項條件

學習目標與先備知識

本章把單變量的「導數是斜率」推廣為多變量的「導數是最佳一階線性映射」。完成本章後，讀者應能：

1. 對 $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}^m$ 寫出 Fréchet 可微的精確定義。
2. 區分函數增量、線性主部與非線性餘項：

$$f(x+h) = f(x) + Df(x)[h] + r(h).$$

3. 使用指定範數驗證

$$\frac{\|r(h)\|}{\|h\|} \rightarrow 0.$$

4. 證明 Fréchet 導數若存在則唯一，並證明可微必連續。
5. 理解可微性要求對所有充分小的允許擾動成立，而不只是沿有限條路徑成立。
6. 以解析式求導數矩陣，並以矩陣擬合與方向殘差比作有限精度核對。
7. 辨識偏導存在或所有方向導數存在但仍不可微的情況。
8. 在有物理單位的問題中標示導數元素的單位，並以無因次尺度比較擾動。

先備知識包括有限維向量範數、矩陣乘法、多變量極限、連續性與單變量導數。除非另行說明，本章輸入與輸出空間皆使用 Euclidean 範數 $\|\cdot\|_2$ ，矩陣使用其誘導算子範數。

在有限維空間中，不同範數彼此等價，因此給出相同的 Fréchet 可微概念；但具體誤差界的常數會隨範數及維度改變。輸入擾動 h 是 $n \times 1$ 列向量。若輸出維度為 m ，則 $J_f(x) \in \mathbb{R}^{m \times n}$ ，且 $J_f(x)h$ 是 $m \times 1$ 列向量。

問題與直覺

在工作點 x 附近，希望用固定線性映射 A 預測輸出變化：

$$f(x+h) - f(x) \approx Ah.$$

定義誤差

$$r(h) = f(x+h) - f(x) - Ah.$$

僅知道 $r(h) \rightarrow 0$ 並不足夠。若 f 在 x 連續，取 $A = 0$ 時，增量也可能趨近零，但這不表示零映射是一階導數。Fréchet 可微要求更強的相對誤差條件：

$$\frac{\|r(h)\|_2}{\|h\|_2} \rightarrow 0.$$

也就是說，扣除線性主部後，餘項必須比擾動的一階尺度更快消失。若 $\|r(h)\|$ 是 $\|h\|^2$ 等級，則殘差比是 $\|h\|$ 等級，會趨近零；若餘項仍與 $\|h\|$ 同階，殘差比通常不會趨近零。

「最佳線性近似」不是指針對有限資料做最小平方後得到的最佳矩陣，而是指存在一個固定線性映射，使誤差為 $o(\|h\|)$ 。這是涵蓋所有充分小、非零且留在定義域內之擾動的極限命題。有限資料可以估計候選矩陣，也可以找到反例，但不能證明這個無限量詞命題。

定義、定理與推導

1. Fréchet 可微的定義

定義 7.1 (Fréchet 可微)

設 $U \subset \mathbb{R}^n$ 為開集， $x \in U$ ，且 $f : U \rightarrow \mathbb{R}^m$ 。若存在線性映射

$$A : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

使得

$$\lim_{\substack{h \rightarrow 0, h \neq 0 \\ x+h \in U}} \frac{\|f(x+h) - f(x) - Ah\|_2}{\|h\|_2} = 0,$$

則稱 f 在 x Fréchet 可微，並記 $Df(x) = A$ 。

因 U 開且 $x \in U$ ，存在 $\eta > 0$ 使 $B(x, \eta) \subset U$ ，所以充分小的 h 自動滿足 $x + h \in U$ 。極限中仍明寫域限制，以保留完整量詞。

等價地，

$$f(x+h) = f(x) + Df(x)[h] + r(h),$$

其中

$$\|r(h)\|_2 = o(\|h\|_2).$$

小 o 條件的量詞形式為：對每個 $\varepsilon > 0$ ，存在 $\delta > 0$ ，使得只要

$$0 < \|h\|_2 < \delta, \quad x + h \in U,$$

就有

$$\|r(h)\|_2 \leq \varepsilon \|h\|_2.$$

在標準座標下，有限維線性映射由唯一矩陣 $J_f(x) \in \mathbb{R}^{m \times n}$ 表示：

$$Df(x)[h] = J_f(x)h.$$

導數本身是線性映射；矩陣是選定基底後的表示。

2. 導數的唯一性

命題 7.2 (Fréchet 導數唯一)

設 $U \subset \mathbb{R}^n$ 開， $x \in U$ ，且 $f: U \rightarrow \mathbb{R}^m$ 。若線性映射 $A, B: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 都滿足 Fréchet 餘項條件，則 $A = B$ 。

證明。

設

$$f(x+h) - f(x) - Ah = r_A(h),$$

以及

$$f(x+h) - f(x) - Bh = r_B(h),$$

其中

$$\frac{\|r_A(h)\|_2}{\|h\|_2} \rightarrow 0, \quad \frac{\|r_B(h)\|_2}{\|h\|_2} \rightarrow 0.$$

兩式相減得

$$(A - B)h = r_B(h) - r_A(h).$$

任取非零 $v \in \mathbb{R}^n$ ，令 $h = tv$ ，其中 $t \neq 0$ 且 $t \rightarrow 0$ 。由 U 開，充分小的 t 可保證 $x + tv \in U$ 。利用線性性及三角不等式，

$$\|(A - B)v\|_2 \leq \frac{\|r_A(tv)\|_2 + \|r_B(tv)\|_2}{|t|}.$$

又因 $\|tv\|_2 = |t|\|v\|_2$ ，

$$\frac{\|r_A(tv)\|_2}{|t|} = \|v\|_2 \frac{\|r_A(tv)\|_2}{\|tv\|_2} \rightarrow 0,$$

而 r_B 的項亦趨近零。因此 $\|(A - B)v\|_2 = 0$ 。零向量的情況顯然成立，故 $(A - B)v = 0$ 對所有 v 成立，所以 $A = B$ 。證畢。

這項唯一性是由全方向餘項條件推出，不是由某個有限資料擬合結果推出。

3. 可微必連續

命題 7.3 (必要條件)

若 f 在 x Fréchet 可微，則 f 在 x 連續。

證明。

令 $A = Df(x)$ 。由定義，

$$f(x+h) - f(x) = Ah + r(h).$$

使用 Euclidean 誘導算子範數，

$$\|f(x+h) - f(x)\|_2 \leq \|A\|_{\text{op}}\|h\|_2 + \|r(h)\|_2.$$

第一項隨 $h \rightarrow 0$ 而趨零。又因 $\|r(h)\|_2/\|h\|_2 \rightarrow 0$ ，所以 $\|r(h)\|_2 \rightarrow 0$ 。因此 $f(x+h) \rightarrow f(x)$ 。證畢。

連續是可微的必要條件，但不是充分條件；例如 $t \mapsto |t|$ 在零點連續而不可微。

4. 與方向導數的關係

若 f 在 x Fréchet 可微，對任意固定 $v \in \mathbb{R}^n$ ，

$$f(x+tv) - f(x) = tDf(x)[v] + r(tv).$$

除以 $t \neq 0$ ，得到

$$\frac{f(x+tv) - f(x)}{t} = Df(x)[v] + \frac{r(tv)}{t}.$$

因為

$$\left\| \frac{r(tv)}{t} \right\|_2 = \|v\|_2 \frac{\|r(tv)\|_2}{\|tv\|_2} \rightarrow 0,$$

所以雙側方向導數存在，且

$$D_v f(x) = Df(x)[v].$$

因此 Fréchet 可微是所有方向導數存在的充分條件，並且方向導數對方向 v 的依賴必須是線性的。反向敘述一般不成立。

5. 連續偏導的充分條件

定理 7.4 (常用充分條件)

設 $U \subset \mathbb{R}^n$ 開， $f: U \rightarrow \mathbb{R}^m$ 。若所有一階偏導數在 x 的某個開鄰域存在，且在 x 連續，則 f 在 x Fréchet 可微，導數的矩陣表示為 $J_f(x)$ 。

這是充分條件，而不是可微定義本身。證明可按輸入座標逐一改變，對各輸出分量套用單變量中值定理，再以偏導在 x 的連續性控制誤差。最終得到

$$\|f(x+h) - f(x) - J_f(x)h\|_2 \leq \omega(h)\|h\|_2,$$

其中 $\omega(h) \rightarrow 0$ 。關鍵是此界對所有充分小的 h 有效，而不是只處理固定方向。

逐步手算例題

例題一：直接估計餘項

令

$$f(x, y) = \begin{bmatrix} x^2 + xy \\ \sin y \end{bmatrix}.$$

求 f 在 $(1, 0)$ 的導數，並直接驗證餘項條件。

Jacobian 候選為

$$J_f(x, y) = \begin{bmatrix} 2x + y & x \\ 0 & \cos y \end{bmatrix},$$

所以

$$J_f(1, 0) = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

令 $h = (a, b)^T$ 。直接展開得

$$f(1+a, b) - f(1, 0) = \begin{bmatrix} 2a + b + a^2 + ab \\ \sin b \end{bmatrix}.$$

線性主部為

$$J_f(1, 0)h = \begin{bmatrix} 2a + b \\ b \end{bmatrix},$$

故餘項是

$$r(h) = \begin{bmatrix} a^2 + ab \\ \sin b - b \end{bmatrix}.$$

設 $\rho = \sqrt{a^2 + b^2}$ 。則

$$|a^2 + ab| \leq |a|^2 + |a||b| \leq 2\rho^2.$$

由單變量 Taylor 餘項，對所有實數 b ，

$$|\sin b - b| \leq \frac{|b|^3}{6} \leq \frac{\rho^3}{6}.$$

所以

$$\|r(h)\|_2 \leq 2\rho^2 + \frac{\rho^3}{6},$$

進而

$$\frac{\|r(h)\|_2}{\|h\|_2} \leq 2\rho + \frac{\rho^2}{6} \rightarrow 0.$$

此估計同時涵蓋所有方向，故證明 f 在 $(1, 0)$ Fréchet 可微。

例題二：範數函數在原點不可微

令

$$g(x, y) = \sqrt{x^2 + y^2}.$$

假設 g 在原點可微，導數為線性泛函 L 。取 $e_1 = (1, 0)^T$ 。沿 $h = te_1$ 且 $t > 0$ ，餘項條件要求

$$|1 - L(e_1)| = 0,$$

所以 $L(e_1) = 1$ 。

改沿 $h = -te_1$ 且 $t > 0$ 。因 $L(-te_1) = -tL(e_1)$ ，餘項比要求

$$|1 + L(e_1)| = 0,$$

所以 $L(e_1) = -1$ ，與前式矛盾。因此 g 在原點不可 Fréchet 微分。

若只測試零映射，殘差比更直接等於

$$\frac{g(h)}{\|h\|_2} = 1,$$

不會趨近零。

例題三：所有方向導數存在仍不夠

定義

$$q(x, y) = \begin{cases} \frac{x^3}{x^2 + y^2}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

對非零方向 $v = (a, b)^T$ ，

$$\frac{q(ta, tb) - q(0, 0)}{t} = \frac{a^3}{a^2 + b^2}.$$

所以每個方向導數都存在。然而此方向導數映射在 e_1 上為 1、在 e_2 上為 0，在 $e_1 + e_2$ 上卻為 1/2，不符合線性映射應滿足的可加性。若 Fréchet 導數存在，所有方向導數必由同一線性映射給出，故 q 在原點不可 Fréchet 微分。

實作與程式

以下程式只使用 NumPy 與 CPU，以局部資料擬合矩陣並計算方向殘差比。程式未在本章撰寫過程中執行；後文只列解析推導所得的預期現象。

擬合關係為

$$\Delta F \approx H A^T,$$

其中 H 的每一方程橫列是 h^T 。函數介面明確使用 $(n, 1)$ 與 $(m, 1)$ ，不以 NumPy 一維陣列的 `.T` 冒充列、橫方向改變。

```
import numpy as np

def as_column(values, expected_size=None):
    col = np.asarray(values, dtype=float).reshape(-1, 1).copy()
    if expected_size is not None and col.shape != (expected_size, 1):
        raise ValueError("列向量維度不符")
    if not np.all(np.isfinite(col)):
        raise ValueError("輸入含 NaN 或無窮值")
    return col

def f_smooth(x_col):
    x_col = as_column(x_col, 2)
```



```

x = float(x_col[0, 0])
y = float(x_col[1, 0])
return np.array([
    [x * x + x * y],
    [np.sin(y)]
], dtype=float)

def jacobian_smooth(x_col):
    x_col = as_column(x_col, 2)
    x = float(x_col[0, 0])
    y = float(x_col[1, 0])
    return np.array([
        [2.0 * x + y, x],
        [0.0, np.cos(y)]
    ], dtype=float)

def f_nondiff(x_col):
    x_col = as_column(x_col, 2)
    x = float(x_col[0, 0])
    y = float(x_col[1, 0])
    den = x * x + y * y
    if den == 0.0:
        return np.array([[0.0]], dtype=float)
    return np.array([[x ** 3 / den]], dtype=float)

def residual_ratio(fun, x0, A, h_col):
    x0 = as_column(x0)
    h_col = as_column(h_col, x0.shape[0])
    A = np.asarray(A, dtype=float)

    h_norm = float(np.linalg.norm(h_col, ord=2))
    if h_norm == 0.0:
        raise ValueError("h 必須非零; h=0 時殘差比不定義")
    if not np.all(np.isfinite(A)):
        raise ValueError("矩陣含 NaN 或無窮值")

    f0 = fun(x0)
    f1 = fun(x0 + h_col)
    if A.shape != (f0.shape[0], x0.shape[0]):
        raise ValueError("線性映射矩陣形狀不符")

    remainder = f1 - f0 - A @ h_col
    return float(np.linalg.norm(remainder, ord=2) / h_norm)

def fit_local_matrix(fun, x0, radius, directions):
    x0 = as_column(x0)
    if not np.isfinite(radius) or radius <= 0.0:
        raise ValueError("radius 必須為有限正數")
    if len(directions) == 0:
        raise ValueError("至少需要一個擾動方向")

    f0 = fun(x0)
    h_rows = []
    df_rows = []

    for direction in directions:
        v_col = as_column(direction, x0.shape[0])
        v_norm = float(np.linalg.norm(v_col, ord=2))
        if v_norm == 0.0:

```

```

        raise ValueError("方向向量不可為零")

    h_col = radius * v_col / v_norm
    delta_col = fun(x0 + h_col) - f0
    h_rows.append(h_col[:, 0].copy())
    df_rows.append(delta_col[:, 0].copy())

H = np.vstack(h_rows)
dF = np.vstack(df_rows)

# 解  $H @ A.T \approx dF$ 
A_transpose, _, rank, singular_values = np.linalg.lstsq(
    H, dF, rcond=None
)
return A_transpose.T, int(rank), singular_values

def maximum_sampled_ratio(fun, x0, A, radius, directions):
    x0_col = as_column(x0)
    ratios = []
    for direction in directions:
        v_col = as_column(direction, x0_col.shape[0])
        v_norm = float(np.linalg.norm(v_col, ord=2))
        if v_norm == 0.0:
            raise ValueError("方向向量不可為零")
        h_col = radius * v_col / v_norm
        ratios.append(residual_ratio(fun, x0_col, A, h_col))
    return max(ratios)

def expected_error(callable_object):
    try:
        callable_object()
    except ValueError as exc:
        print("預期捕捉:", type(exc).__name__, str(exc))
    else:
        raise AssertionError("本測試預期 ValueError")

def run_all_tests():
    x0 = np.array([[1.0], [0.0]], dtype=float)
    A_exact = jacobian_smooth(x0)
    directions = [
        [1.0, 0.0], [-1.0, 0.0],
        [0.0, 1.0], [0.0, -1.0],
        [1.0, 1.0], [1.0, -2.0]
    ]

    print("正常測試")
    print("解析 Jacobian:\n", A_exact)
    for radius in [1e-1, 1e-2, 1e-3, 1e-4]:
        A_fit, rank, singular_values = fit_local_matrix(
            f_smooth, x0, radius, directions
        )
        op_error = np.linalg.norm(A_fit - A_exact, ord=2)
        max_ratio = maximum_sampled_ratio(
            f_smooth, x0, A_exact, radius, directions
        )
        print(radius, A_fit, op_error, max_ratio,
              rank, singular_values)

    print("邊界測試：極小但非零步長")

```

```

tiny = np.finfo(float).eps
print(residual_ratio(
    f_smooth, x0, A_exact,
    np.array([[tiny], [0.0]], dtype=float)
))

print("故障測試：零擾動")
expected_error(lambda: residual_ratio(
    f_smooth, x0, A_exact, np.zeros((2, 1))
))

print("故障測試：輸入維度錯誤")
expected_error(lambda: f_smooth(
    np.array([[1.0], [0.0], [2.0]])
))

print("故障測試：NaN 擾動")
expected_error(lambda: residual_ratio(
    f_smooth, x0, A_exact,
    np.array([[np.nan], [0.0]])
))

print("故障測試：方向數值秩不足")
collinear = [[1.0, 0.0], [-1.0, 0.0], [2.0, 0.0]]
_, rank, singular_values = fit_local_matrix(
    f_smooth, x0, 1e-3, collinear
)
print("rank =", rank, "singular values =", singular_values)

print("故障測試：非可微映射")
origin = np.zeros((2, 1))
zero_map = np.zeros((1, 2))
direction = np.array([[1.0], [2.0]], dtype=float)
direction = direction / np.linalg.norm(direction, ord=2)
for radius in [1e-1, 1e-2, 1e-3, 1e-4]:
    print(radius, residual_ratio(
        f_nondiff, origin, zero_map, radius * direction
    ))

if __name__ == "__main__":
    run_all_tests()

```

`np.linalg.lstsq` 回傳的 `rank` 是依浮點容差判定的數值秩，不是抽象線性代數中的精確秩證明。奇異值可協助判斷方向是否接近線性相關；即使回報滿秩，若最小奇異值非常小，擬合仍可能病態。

測試與預期結果

以下均為未執行的預期結果。

正常測試

在 $x_0 = (1, 0)^T$ ，解析矩陣是

$$A = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

六個方向在精確算術下張成 $\mathbb{R}^2$ ，預期數值程序回報 `rank == 2`。在捨入誤差尚未主導的尺度內，擬合矩陣應接近 A ，解析矩陣的採樣殘差比應隨半徑縮小而下降。

由解析餘項可知此例的殘差比為 $O(\|h\|)$ 。程式結果只能與此結論相容，不能單獨證明漸近階。

邊界測試

以機器精度附近的非零步長計算時，餘項是由數個接近數值相減後得到，可能受到捨入誤差影響；是否出現明顯相消，依函數、工作點及浮點運算細節而定。本例不預先宣稱一定觀察到嚴重相消。若殘差比停止下降，也不能據此推翻解析可微性。

故障測試：零、維度與非有限輸入

傳入 $h = 0$ 時，預期拋出 `ValueError`，因為殘差比分母為零。傳入三維輸入給二維函數時，預期拋出維度錯誤。傳入含 `NaN` 的擾動時，也預期在進行函數運算前被拒絕。

故障測試：方向秩不足

若方向全部平行於第一座標軸，預期 `lstsq` 回報 `rank == 1`。這表示程式判定方向資料數值秩不足，第二輸入方向無法由該批資料辨識。

反過來，即使回報 `rank == 2`，仍須檢查奇異值。近乎平行的方向可能被判定為滿秩，卻使估計對捨入及資料誤差高度敏感。

故障測試：非可微映射

對 $q(x, y) = x^3 / (x^2 + y^2)$ 使用零映射作候選，若單位方向為 $v = (a, b)^T$ ，則

$$\frac{|q(tv)|}{\|tv\|_2} = \frac{|a|^3}{a^2 + b^2},$$

與半徑無關。因此預期各尺度的輸出大致不變，而不是趨近零。這只能否定零映射；排除所有線性候選仍依賴例題三的解析論證。

反例與常見陷阱

1. 只要求餘項趨零

正確條件是 $r(h) = o(\|h\|)$ 。對 $f(t) = |t|$ 與候選導數零映射，餘項雖趨零，但

$$\frac{|r(t)|}{|t|} = 1.$$

2. 把 Jacobian 候選當成可微性證明

偏導存在時可排列出候選矩陣，但偏導存在不保證可微。若滿足定理 7.4 的鄰域條件，可引用充分條件；否則仍須直接控制餘項。

3. 只檢查有限方向

有限方向掃描可以否定候選，不能證明全方向極限。即使所有固定方向導數存在，也可能不形成線性映射。

4. 讓線性映射隨方向改變

Fréchet 導數是一個固定線性映射。不能沿不同方向分別挑選不同斜率，再把它們稱為同一個導數。

5. 把有限尺度現象當作極限定理

在幾個步長上看到殘差比下降，只能視為數值證據。有限計算未涵蓋任意小尺度，也未涵蓋所有方向。

6. 把數值秩視為精確秩

數值秩依賴浮點容差。檢查回報秩之外，還應觀察奇異值尺度與方向資料的條件性。

7. 混合單位後直接計算 Euclidean 長度

若 $h = (\Delta T, \Delta S)^T$ 的分量分別使用攝氏度與 PSU，則原始 Euclidean 長度依賴單位選擇。應先指定參考尺度 s_T, s_S ，定義

$$\hat{h} = \begin{bmatrix} \Delta T/s_T \\ \Delta S/s_S \end{bmatrix},$$

再比較無因次擾動。

AI、幾何與養殖案例

1. AI 模型的局部敏感度

對模型映射 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ， $Df(x)$ 描述輸入小擾動的一階傳播。不同方法提供的證據不同：

- 解析餘項界可以建立可微性。

- 自動微分依賴實作運算與分支語義。
- 局部矩陣擬合只反映有限尺度、有限方向及資料條件性。

若模型包含絕對值、最大值或離散分支，在切換面上可能不可微。軟體傳回某個約定值、單側值或次梯度，不表示 Fréchet 導數存在。

2. 幾何形變

考慮平面形變

$$F(x, y) = \begin{bmatrix} x + 0.1xy \\ y + 0.05x^2 \end{bmatrix}.$$

其局部線性映射為

$$DF(x, y) = \begin{bmatrix} 1 + 0.1y & 0.1x \\ 0.1x & 1 \end{bmatrix}.$$

短切向量 h 的一階變化是 $DF(x, y)h$ 。這描述的是基點附近的局部形變，不表示有限大小的整個圖形由同一矩陣精確變換；有限位移仍含餘項。

3. 合成養殖感測校準

考慮純合成模型，輸入為水溫 T （攝氏度）與鹽度 S （PSU），輸出為電壓 V （伏特）與相位 ϕ （弧度）：

$$f(T, S) = \begin{bmatrix} 0.40 + 0.012T + 0.003S + 10^{-4}TS \\ 0.10 + 0.002T^2 - 0.004S \end{bmatrix}.$$

其導數矩陣為

$$J_f(T, S) = \begin{bmatrix} 0.012 + 10^{-4}S & 0.003 + 10^{-4}T \\ 0.004T & -0.004 \end{bmatrix}.$$

第一橫列元素的單位分別為伏特／攝氏度及伏特／PSU；第二橫列元素的單位分別為弧度／攝氏度及弧度／PSU。不同位置的數值不能脫離單位直接比較。

取輸入、輸出參考尺度矩陣

$$S_x = \text{diag}(5^\circ\text{C}, 10\text{ PSU}),$$

$$S_y = \text{diag}(0.1\text{ V}, 0.1\text{ rad}),$$

則無因次導數為

$$\hat{J} = S_y^{-1} J_f S_x.$$

在無因次座標中計算 Euclidean 殘差比，才有清楚的跨分量比較意義。返回物理量時使用

$$\Delta x = S_x \Delta \hat{x}, \quad \Delta y = S_y \Delta \hat{y}.$$

局部校準矩陣只描述指定工作點附近的小擾動。合成模型校準不等於現場驗證，也不保證工作範圍外有效。唯讀分析代理只能整理單位、尺度、殘差及失效警告，不直接控制投餌、加藥或其他設備。

習題

習題一：手算與證明

令

$$f(x, y) = \begin{bmatrix} e^x \cos y \\ xy + y^2 \end{bmatrix}.$$

求 $Df(0, 0)$ ，並用餘項界證明 f 在原點 Fréchet 可微。

習題二：程式與數值秩

使用本章程式回報每個半徑下的擬合矩陣、算子範數誤差、最大採樣殘差比、數值秩及奇異值。說明為何回報滿秩仍不保證擬合問題具有良好條件性。

習題三：路徑反例

定義

$$p(x, y) = \begin{cases} \frac{x^2 y}{x^4 + y^2}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

證明沿每條直線 $y = kx$ 都有 $p(x, kx) \rightarrow 0$ ，但 p 在原點不連續，因而不可 Fréchet 微分。

習題四：整合與單位

某合成校準模型為

$$z(T, C) = \begin{bmatrix} 2T + 0.5C + 0.01TC \\ 0.1T^2 - C \end{bmatrix}.$$

其中 T 以攝氏度計， C 以毫克／公升計；第一輸出以毫伏計，第二輸出為無因次指標。

1. 求 $J_z(20, 4)$ 。

2. 對 $\Delta T = 0.1$ 、 $\Delta C = -0.2$ 求一階輸出預測。
 3. 求精確輸出增量及餘項。
 4. 解釋為何原始輸入的無權重 Euclidean 長度不具單位不變性。
-

習題解答

習題一解答

Jacobian 為

$$J_f(x, y) = \begin{bmatrix} e^x \cos y & -e^x \sin y \\ y & x + 2y \end{bmatrix},$$

所以

$$Df(0, 0) = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

令 $h = (a, b)^T$ ，餘項為

$$r(a, b) = \begin{bmatrix} e^a \cos b - 1 - a \\ ab + b^2 \end{bmatrix}.$$

為建立第一分量的統一界，在原點取一個有限半徑閉球。這是在有限維 Euclidean 空間中；依 Heine-Borel 定理，閉且有界的球為緊緻集。函數

$$G(a, b) = e^a \cos b$$

的所有二階偏導在該閉球上連續，因此有界。沿原點到 (a, b) 的線段套用二階 Taylor 定理，存在常數 $C > 0$ ，使所有充分小的 (a, b) 滿足

$$|e^a \cos b - 1 - a| \leq C(a^2 + b^2).$$

第二分量滿足

$$|ab + b^2| \leq \frac{1}{2}(a^2 + b^2) + b^2 \leq \frac{3}{2}(a^2 + b^2).$$

令 $\rho = \sqrt{a^2 + b^2}$ ，則存在 $C' > 0$ 使

$$\|r(a, b)\|_2 \leq C'\rho^2.$$

故

$$\frac{\|r(a,b)\|_2}{\rho} \leq C'\rho \rightarrow 0.$$

因此 f 在原點 Fréchet 可微。

習題二解答

程式中的 `rank` 是由 `np.linalg.lstsq` 按浮點容差估計的數值秩。若在二維問題中回報 `rank < 2`，程式判定方向資料數值秩不足，不能由該資料辨識完整導數矩陣。

若回報 `rank == 2`，也不能立刻斷言問題條件良好。設奇異值為

$$\sigma_1 \geq \sigma_2 > 0.$$

當 σ_2 遠小於 σ_1 時，方向雖被判為數值滿秩，卻接近線性相關，小量捨入或資料誤差可能造成擬合矩陣的大變化。因此須同時檢查奇異值比例，而不能只看秩。

殘差比下降只涵蓋有限方向與有限半徑，仍不能取代 Fréchet 定義中的全方向極限證明。

習題三解答

沿 $y = kx$ ，當 $x \neq 0$ 時，

$$p(x, kx) = \frac{kx^3}{x^4 + k^2x^2} = \frac{kx}{x^2 + k^2}.$$

若 $k \neq 0$ ，此式在 $x \rightarrow 0$ 時趨零；若 $k = 0$ ，函數恆為零。因此每條固定直線都給出零極限。

但沿拋物線 $y = x^2$ ，

$$p(x, x^2) = \frac{x^4}{x^4 + x^4} = \frac{1}{2}$$

對所有 $x \neq 0$ 成立。它不趨近 $p(0, 0) = 0$ ，所以 p 在原點不連續。由命題 7.3，可微必連續，因此 p 在原點不可 Fréchet 微分。

習題四解答

Jacobian 為

$$J_z(T, C) = \begin{bmatrix} 2 + 0.01C & 0.5 + 0.01T \\ 0.2T & -1 \end{bmatrix},$$

所以

$$J_z(20, 4) = \begin{bmatrix} 2.04 & 0.70 \\ 4 & -1 \end{bmatrix}.$$

令

$$h = \begin{bmatrix} 0.1 \\ -0.2 \end{bmatrix}.$$

一階輸出預測為

$$J_z(20, 4)h = \begin{bmatrix} 0.064 \\ 0.6 \end{bmatrix}.$$

第一分量的餘項為

$$0.01\Delta T\Delta C = 0.01(0.1)(-0.2) = -0.0002,$$

第二分量的餘項為

$$0.1(\Delta T)^2 = 0.001.$$

所以

$$r(h) = \begin{bmatrix} -0.0002 \\ 0.001 \end{bmatrix},$$

精確輸出增量是

$$\begin{bmatrix} 0.0638 \\ 0.601 \end{bmatrix}.$$

攝氏度與毫克／公升是不同物理量。若把濃度改以微克／公升表示，其數值會改變千倍，因此原始 Euclidean 長度不是單位不變量。應指定參考尺度 s_T, s_C ，再計算

$$\sqrt{\left(\frac{\Delta T}{s_T}\right)^2 + \left(\frac{\Delta C}{s_C}\right)^2}.$$

本章小結

Fréchet 導數把多變量導數定義為固定線性映射：

$$f(x + h) = f(x) + Df(x)[h] + r(h), \quad \frac{\|r(h)\|}{\|h\|} \rightarrow 0.$$

核心不是單純把偏導排成矩陣，而是證明扣除線性主部後，餘項相對於輸入的一階尺度消失。若導數存在，則它唯一；可微必連續，且所有方向導數由同一線性映射給出。反之，偏導存在、有限方向測試通過，甚至所有方向導數存在，都不保證 Fréchet 可微。

矩陣擬合、方向掃描與殘差比可用來核對公式、探索有效尺度與發現反例，但受到採樣、數值秩、病態性及浮點誤差限制，不能證明全方向極限。在感測問題中，還必須記錄工作點、單位、無因次尺度及局部有效範圍。

參考來源

1. Jiří Lebl, *Basic Analysis*, 作者教材入口：<https://www.jirka.org/ra/>
可供極限、連續性與嚴格證明方法的延伸閱讀。
2. MIT OpenCourseWare, *18.100A Real Analysis* :
<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
可參考極限、量詞與實分析證明架構。
3. MIT OpenCourseWare, *18.02SC Multivariable Calculus* :
<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
可參考多變量線性近似與導數矩陣的計算背景。
4. JAX, *Autodiff Cookbook* :
https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html
僅作自動微分概念的延伸參考；本章核心程式不依賴 JAX。

以上來源為延伸入口。本章未宣稱已通讀所有教材內容，也未執行所列程式；數值結果只作預期說明，不構成 Fréchet 可微性的證明。

第08章 偏導、方向導數、梯度與Jacobian

學習目標與先備知識

本章要回答四個不同問題：改動單一輸入時，輸出如何變化？沿指定方向改動時又如何？若輸出只有一個數，如何以梯度表示局部變化？若輸出有多個分量，如何以Jacobian記錄所有一階影響？讀完後，應能寫出各物件的定義、形狀與單位，並判斷算出偏導是否足以支持線性近似。

先備知識包括向量與矩陣乘法、Euclidean範數、單變量極限，以及Fréchet可微性的餘項定義。以下除特別說明外， $U \subset \mathbb{R}^n$ 是開集， $f: U \rightarrow \mathbb{R}^m$ ；向量採直立的**列向量**（column vector）。理論中的輸入與輸出餘項範數各採Euclidean範數。若分量帶不同物理單位，數值比較前須另外指定尺度，不能把未尺度化的長度直接當成物理量。

問題與直覺

設一部合成感測器接收兩個設定值，回報溫度與濃度。工程師可能問：「只增加第一個設定值，溫度讀值改變多少？」這是某個**偏導**；「兩個設定值按指定比例同時改變，兩項讀值如何變化？」這涉及**方向導數**；

「哪些微小改動令標量損失上升最快？」在Euclidean度量下可用**梯度**回答；「如何一次記錄兩個輸入對兩個輸出的全部一階影響？」則使用**Jacobian**。

這些說法中的「微小」不是指定某個足夠小的浮點數，而是極限敘述。只沿座標軸量到局部斜率，不表示任意輸入擾動都遵守同一線性模型。方向導數比偏導考察更多路徑，但它仍一次固定一條直線；Fréchet可微性要求的是**同一個**線性映射能控制所有趨近零的擾動。把已存在的偏導排成矩陣，可能得到形式正確、卻不是導數的表。

定義、定理與推導

令 e_i 為第 i 個座標基底列向量。若以下極限存在，稱為 f 在 x 對第 i 個輸入的**偏導數**：

$$\partial_i f(x) = \lim_{t \rightarrow 0} \frac{f(x + te_i) - f(x)}{t} \in \mathbb{R}^m.$$

它是輸出向量；其第 a 個分量為 $\partial_i f_a(x)$ 。給定固定方向 $v \in \mathbb{R}^n$ ，若極限存在，沿 v 的**雙側方向導數**定為

$$D_v f(x) = \lim_{t \rightarrow 0} \frac{f(x + tv) - f(x)}{t}.$$

此處不要求 v 為單位向量。若改用單位方向，結果代表「每單位Euclidean距離」的變化；有因次變數若未尺度化，這個距離通常沒有直接的物理意義。兩個定義都要求正、負的 t 趨零，因此把定義域取為開集，可確保每個固定方向在所論點附近都有容許的點。

定義：Fréchet可微。 若存在線性映射 $L: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ，使所有充分小且 $x + h \in U$ 的 h 滿足

$$f(x + h) = f(x) + Lh + r(h), \quad \lim_{\substack{h \rightarrow 0 \\ h \neq 0}} \frac{\|r(h)\|_2}{\|h\|_2} = 0,$$

則稱 f 在 x 可微，並寫 $Df(x)[h] = Lh$ 。在標準座標下， L 的矩陣為 $J_f(x) \in \mathbb{R}^{m \times n}$ 。當可微性已成立，矩陣第 a 條橫列、第 i 條縱行的元素就是 $\partial_i f_a(x)$ ；每個縱行記錄一個座標輸入方向的輸出變化。因此

$$Df(x)[h] = J_f(x)h, \quad h \in \mathbb{R}^{n \times 1}.$$

矩陣的**行空間** (column space) 是 $\mathbb{R}^m$ 的子空間，維度為矩陣的秩；**列空間** (row space) 是 $\mathbb{R}^n$ 的子空間，維度也為該秩。它們不是Jacobian的整個輸出、輸入空間，除非另有相應的滿秩條件。

命題（可微時的方向導數）。 設 U 開、 $x \in U$ ，且 $f: U \rightarrow \mathbb{R}^m$ 在 x Fréchet可微。則每個 $v \in \mathbb{R}^n$ 的方向導數均存在，且 $D_v f(x) = J_f(x)v$ 。特別地，所有偏導存在，並構成 $J_f(x)$ 。

證明。 若 $v = 0$ ，差商恆為零。若 $v \neq 0$ ，把可微性等式中的 h 換成 tv 。由 U 開知，充分小的正、負 t 都可用。於是

$$\frac{f(x + tv) - f(x)}{t} = J_f(x)v + \frac{r(tv)}{t}.$$

餘項滿足 $\|r(tv)/t\|_2 = (\|r(tv)\|_2/\|tv\|_2)\|v\|_2 \rightarrow 0$ 。故所求極限為 $J_f(x)v$ 。令 $v = e_i$ ，即得第 i 個偏導等於Jacobian的第 i 個縱行。證畢。

這是**可微的必要後果**，不能倒過來說「所有偏導存在便可微」。兩者的量詞有關鍵差別：偏導只分別考察有限個座標方向；所有方向導數雖考察每個固定 v ，卻仍容許不同方向具有互不相容的極限公式。可微性則先選定一個矩陣，要求對任意足夠小的 h ，餘項相對於 $\|h\|_2$ 一致趨零。從「對每個固定方向各有一個極限」，不能交換量詞而推得「存在一個適用所有方向的線性近似」。

一個常用的**充分條件**如下：若各分量的所有一階偏導在 x 的某個開鄰域存在，並且在 x 連續，則 f 在 x 可微。條件不要求偏導在整個定義域都連續，也不宣稱偏導連續是可微的必要條件。為看清充分性，先以二維標量函數 ϕ 說明證明輪廓。把從 (x, y) 到 $(x + h_1, y + h_2)$ 的增量，拆成先沿第一座標、再沿第二座標的兩段。對每一段使用單變量中值定理，所得增量分別是某個鄰近點的 $\partial_1 \phi$ 乘 h_1 ，以及某個鄰近點的 $\partial_2 \phi$ 乘 h_2 。減去在 (x, y) 的線性候選式後，餘項是兩個「鄰近點偏導與原點偏導之差」乘相應的 h_i 。偏導在該點連續，使兩個差都趨零；又因 $|h_i| \leq \|h\|_2$ ，餘項除以 $\|h\|_2$ 便趨零。一般有限維、向量值情形可逐座標、逐分量同樣處理。此處用到了鄰域內偏導的存在及在所論點的連續，不能只留下「偏導存在」四字。

對標量函數 $\phi: U \rightarrow \mathbb{R}$ ， $D\phi(x)$ 是作用於輸入擾動的線性泛函，矩陣形狀為 $1 \times n$ 。在標準Euclidean內積下，梯度定為 $n \times 1$ 列向量

$$\nabla \phi(x) = \begin{pmatrix} \partial_1 \phi(x) \\ \vdots \\ \partial_n \phi(x) \end{pmatrix}, \quad D\phi(x)[h] = (\nabla \phi(x))^T h.$$

所以 $D\phi(x)$ 與 $\nabla\phi(x)$ 形狀不同；前者是線性泛函，後者是經內積識別得到的向量。若選用非Euclidean內積，這項識別須隨度量修改。由Cauchy-Schwarz不等式可知，當梯度非零時，單位Euclidean方向中 $\nabla\phi/\|\nabla\phi\|_2$ 使方向導數最大；這是附有度量條件的結論，不是對混合單位輸入的無條件操作建議。

逐步手算例題

例一：多輸出映射。令

$$f(x, y) = \begin{pmatrix} x^2y \\ \sin x + y^2 \end{pmatrix}.$$

逐分量、逐輸入求偏導，得到

$$J_f(x, y) = \begin{pmatrix} 2xy & x^2 \\ \cos x & 2y \end{pmatrix}.$$

在 $(0, 1)$ ，Jacobian是 $\begin{pmatrix} 0 & 0 \\ 1 & 2 \end{pmatrix}$ 。取 $v = (1, -1)^T$ ，方向導數為 $J_f(0, 1)v = (0, -1)^T$ 。也可直接代入： $f(t, 1-t)$ 的第一分量為 $t^2(1-t)$ ，與原值相減再除以 t 後趨零；第二分量為 $\sin t + (1-t)^2$ ，與 $f(0, 1)$ 的第二分量相減再除以 t 後趨 $1 - 2 = -1$ 。兩種算法相合，原因是此函數可微；僅查一條直線並不能反過來證明可微。

例二：標量函數與形狀。令 $\phi(x, y) = 3x^2 + xy$ ，在 $(1, 2)$ 有 $\partial_x\phi = 8$ 、 $\partial_y\phi = 1$ 。因此

$$D\phi(1, 2) = \begin{pmatrix} 8 & 1 \end{pmatrix}, \quad \nabla\phi(1, 2) = \begin{pmatrix} 8 \\ 1 \end{pmatrix}.$$

若 $h = (0.01, -0.02)^T$ ，線性預測為 $D\phi(1, 2)[h] = 0.06$ 。直接展開所得實際增量為 $8h_1 + h_2 + 3h_1^2 + h_1h_2 = 0.0601$ ，餘項為 0.0001 。這個單點核對可檢查算術，不能單靠它證明餘項比的極限。對此多項式，若要作解析確認，可利用 $|h_1| \leq \|h\|_2$ 及 $|h_2| \leq \|h\|_2$ ，把餘項絕對值界在 $4\|h\|_2^2$ 以內；除以非零的 $\|h\|_2$ 後才得到趨零的證明。

實作與程式

以下NumPy程式建立**合成**雙輸入、雙輸出感測映射。輸入 T 的單位為攝氏度、 c 的單位為 mg/L；輸出第一分量 θ 的單位為攝氏度，第二分量 s 的單位為 mg/L。設定參考值 $T_0 = 20^\circ\text{C}$ 、 $c_0 = 5 \text{ mg/L}$ ，以尺度 2°C 及 1 mg/L 定義無因次輸入 u, z 。模型只供數學演示，不聲稱描述真實設備：

$$u = \frac{T - T_0}{2^\circ\text{C}}, \quad z = \frac{c - c_0}{1 \text{ mg/L}}, \quad \theta = 20 + 2u + uz, \quad s = 5 + 3z + u^2.$$

輸出式中的常數與係數分別帶有使結果成為攝氏度及 mg/L 的單位；程式儲存的是按上述單位表示的數值。完整物理Jacobian為

$$J_F(T, c) = \begin{pmatrix} (2+z)/2 & u/1 \\ 2u/2 & 3/1 \end{pmatrix}.$$

四個元素的單位依位置依次為 °C/°C、°C/(mg/L)、(mg/L)/°C、(mg/L)/(mg/L)。分母中的 2, 1 各代表對應輸入尺度的數值，不是把物理單位抹去。從無因次輸入返回物理擾動時，須分別乘回 2 °C 與 1 mg/L；輸出亦按各自單位還原。

```
import numpy as np

def sensor(x):
    x = np.asarray(x, dtype=float)
    if x.shape != (2, 1) or not np.isfinite(x).all():
        raise ValueError("input must be a finite (2, 1) column")
    u = (x[0, 0] - 20.0) / 2.0
    z = (x[1, 0] - 5.0) / 1.0
    return np.array([[20.0 + 2.0*u + u*z],
                    [5.0 + 3.0*z + u*u]])

def jacobian(x):
    x = np.asarray(x, dtype=float)
    if x.shape != (2, 1) or not np.isfinite(x).all():
        raise ValueError("input must be a finite (2, 1) column")
    u = (x[0, 0] - 20.0) / 2.0
    z = (x[1, 0] - 5.0) / 1.0
    return np.array([(2.0 + z)/2.0, u/1.0],
                    [2.0*u/2.0, 3.0/1.0])

def scaled_remainder_ratio(x, h):
    x = np.asarray(x, dtype=float)
    h = np.asarray(h, dtype=float)
    if h.shape != (2, 1) or not np.isfinite(h).all():
        raise ValueError("h must be a finite (2, 1) column")
    # 輸入尺度：(2 °C, 1 mg/L)；輸出尺度：(2 °C, 1 mg/L)。
    input_scale = np.array([[2.0], [1.0]])
    output_scale = np.array([[2.0], [1.0]])
    hn = np.linalg.norm(h / input_scale)
    if hn == 0.0:
        raise ValueError("h must be nonzero")
    r = sensor(x + h) - sensor(x) - jacobian(x) @ h
    return np.linalg.norm(r / output_scale) / hn

x = np.array([[20.0], [5.0]])
h = np.array([[0.2], [-0.1]])
print(sensor(x), jacobian(x))
print(jacobian(x) @ h, scaled_remainder_ratio(x, h))
```

程式用明確的 (2, 1) 形狀：NumPy 的一維陣列即使加上 `.T`，仍是一維陣列，不能藉此宣稱已把列向量變成橫向量。餘項測試同時尺度化輸入與輸出，避免把攝氏度與 mg/L 的原始數值直接合成一個物理長度。此處採取的尺度是明示的建模選擇，換尺度會改變比值的數值，卻不會把有限次測試提升為極限證明。

測試與預期結果

以下均為未執行的預期，不是測試紀錄。

- **正常測試**：在 $x = (20, 5)^\top$ ，預期 `sensor(x)` 為 $(20, 5)^\top$ ，`jacobian(x)` 為 $\begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix}$ 。對程式中的 h ，線性預測為 $(0.2, -0.3)^\top$ ，實際餘項為 $(-0.01, 0.01)^\top$ 。依程式的輸入、輸出尺度 $(2, 1)$ ，尺度化輸入長度為 $\sqrt{0.02}$ ，尺度化餘項長度為 $\sqrt{0.000125}$ ；故比值預期約為 0.0791。
- **邊界測試**： $h = 0$ 時比值的分母為零，函式預期明確拋出 `ValueError`。這不是「零方向的方向導數不存在」：零方向的方向導數依定義為零；不能計算的是此一餘項比。
- **故障測試**：傳入形狀為 $(2,)$ 的輸入，或含 `nan` 的擾動，預期拋出 `ValueError`，不暗中猜測其形狀或接受非有限數。

可另以逐次縮小的非零 h 檢查餘項比，但浮點捨入總會干擾結果。即使觀察到下降，有限個測試點也不能涵蓋所有方向；反之，若發現與解析預測明顯衝突的結果，則應先查公式、尺度、形狀及程式實作。

反例與常見陷阱

所有方向導數存在，仍不一定有導數矩陣。定義 $q: \mathbb{R}^2 \rightarrow \mathbb{R}$ 為

$$q(x, y) = \begin{cases} \frac{x^3}{x^2 + y^2}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

對任意固定 $v = (a, b)^\top \neq 0$ ，

$$D_v q(0, 0) = \lim_{t \rightarrow 0} \frac{q(ta, tb)}{t} = \frac{a^3}{a^2 + b^2}.$$

零方向的值為零。因此所有雙側方向導數都存在；偏導為 $\partial_x q(0, 0) = 1$ 、 $\partial_y q(0, 0) = 0$ 。若 q 在原點可微，已證命題迫使方向導數等於候選橫列矩陣 $(1, 0)v = a$ 。然而 $v = (1, 1)^\top$ 時，實際方向導數為 $1/2$ ，候選值卻為 1 ；矛盾。這是解析反證，不依賴有限路徑採樣。此例甚至在原點連續，因為 $|q(x, y)| \leq |x| \rightarrow 0$ ；問題不只是連續性缺失，而是方向變化不能組成同一線性映射。

另一種更基本的錯誤是以偏導存在推論連續。例如令 $p(x, y) = xy/(x^2 + y^2)$ 於非原點，並令 $p(0, 0) = 0$ 。兩個座標軸上的偏導皆為零，但沿 $y = x$ 趨近原點時函數值為 $1/2$ ，故它甚至不連續。兩例展示不同程度的失敗： p 表明座標軸資料不足以保證連續； q 表明即使函數連續、每個固定方向的斜率都有極限，也未必取得可微性所需的線性一致性。反例只需找到足以造成矛盾的方向；證明可微則必須控制定義要求的全部小擾動。

AI、幾何與養殖案例

若合成模型以輸入擾動 h 預測感測輸出， Jh 是局部線性預測，而實際與預測之差是應報告的餘項。報告還須附上輸入與輸出的單位、尺度，以及擾動是否位於模型擬使用的局部範圍。若只交付一個 Jacobian 而不交付評估點，讀者無法知道其係數適用於哪個狀態；若只交付有限差分數值而不交付步長，也難以稽核其誤差來源。

AI 代理可唯讀整理模型公式、尺度、Jacobian、測試擾動與殘差，並指出某些方向資料不足；它不因此取得改動設備、投餌或加藥的依據。合成模型校準不等於現場驗證，局部線性預測也不等於操作安全保證。

幾何上，Jacobian 把輸入空間的一個小位移送到輸出空間的切向變化。對本章的雙輸出映射，其第一個縱行是只改變 T 時的輸出切向量，第二個縱行是只改變 c 時的切向量。然而兩種輸出單位不同，未尺度化的箭頭長度不能直接比較。若使用右手 $X/Y/Z$ 幾何座標，方向也須先說明所屬座標系；不能把感測設定的兩個分量默認成空間的 X/Y 位移。這些區別使線性代數圖像能輔助理解，而不遮蔽模型的單位與適用範圍。

習題

1. **手算**。對 $f(x, y) = (xy, y^2 + x)^T$ ，求 $J_f(2, 1)$ 及沿 $v = (1, -2)^T$ 的方向導數；再求 $\phi(x, y) = xy + y^2$ 在同一點的梯度與標量導數橫列。
2. **程式**。不執行程式，依本章 `sensor` 公式求在 $x = (20, 5)^T$ 、 $h = (0.02, 0)^T$ 時的 Jh 、精確餘項，以及 `scaled_remainder_ratio` 的預期值。說明這個結果能否證明可微。
3. **反例**。計算上文 q 在原點沿 $(1, 0)^T$ 、 $(0, 1)^T$ 、 $(1, 1)^T$ 的方向導數。僅以這三個解析計算結果，證明不存在與全部方向導數相符的線性映射。
4. **整合**。一個無因次標量品質指標定為 $\phi(T, c) = u^2 + z^2$ ，其中 u, z 採本章尺度。求在 $(T, c) = (22, 6)$ 的物理輸入梯度、 $D\phi$ 的矩陣形狀，以及 $h = (0.2, -0.1)^T$ 的一階預測。解釋為何不能把梯度的兩個數值直接視為「兩個物理方向同樣長」的比較。

習題解答

1. 分別微分得 $J_f(x, y) = \begin{pmatrix} y & x \\ 1 & 2y \end{pmatrix}$ ，故 $J_f(2, 1) = \begin{pmatrix} 1 & 2 \\ 1 & 2 \end{pmatrix}$ ， $D_v f(2, 1) = (-3, -3)^T$ 。對 ϕ ， $\partial_x \phi = y$ 、 $\partial_y \phi = x + 2y$ ，所以 $\nabla \phi(2, 1) = (1, 4)^T$ ， $D\phi(2, 1) = (1 \ 4)$ 。
2. 此時 $J = \begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix}$ ，故 $Jh = (0.02, 0)^T$ 。相應無因次增量為 $\Delta u = 0.01$ 、 $\Delta z = 0$ ；第一輸出的交叉項與第二輸出的平方項給出精確餘項 $r = (0, 0.0001)^T$ 。尺度化輸入長度為 0.01，尺度化餘項長度為 0.0001，預期比值為 0.01。這只是一個擾動的算術結果，不能證明全方向極限；本模型可微須由其多項式形式及相應微分定理確立。
3. 三個值依次為 1, 0, 1/2。若線性映射 L 符合所有方向導數，線性必給 $L(1, 1)^T = L(1, 0)^T + L(0, 1)^T = 1$ ，與解析所得 1/2 矛盾。因此不存在這樣的線性映射。此處三個方向足以推翻線性主張，與用有限採樣證明全方向性質不同。

4. 在 $(22, 6)$, $u = z = 1$ 。由尺度及單變量鏈式計算, $\partial_T \phi = 2u/2 = 1 \text{ (}^\circ\text{C)}^{-1}$, $\partial_c \phi = 2z/1 = 2 \text{ (mg/L)}^{-1}$ 。梯度是 $(1, 2)^\top$, 形狀 2×1 ; $D\phi = \begin{pmatrix} 1 & 2 \end{pmatrix}$, 形狀 1×2 。一階預測為 $1(0.2) + 2(-0.1) = 0$ 。兩個梯度分量的單位不同, 原始數值大小依輸入單位與尺度而變; 須先指定尺度或度量, 才能比較「同樣長」的方向。

本章小結

偏導考察座標軸, 方向導數考察固定直線; Fréchet導數則要求**同一線性映射**以趨零的相對餘項控制所有小擾動。可微時, 這個映射的標準矩陣為 $m \times n$ 的 Jacobian, 並給出 $D_v f = J_f v$ 。標量函數的導數是 $1 \times n$ 的線性泛函; 其 Euclidean 梯度是 $n \times 1$ 的列向量。解析反例顯示, 即使每個方向導數都存在, 也不能省略可微性檢查。計算與測試有助於稽核公式, 極限結論仍須依定義、證明或具備條件的定理建立。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*, 作者教材入口: <https://www.jirka.org/ra/>
- [A2] MIT OpenCourseWare, *18.100A Real Analysis*, 課程概要: <https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- [A3] MIT OpenCourseWare, *18.02SC Multivariable Calculus*, 課程概要: <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

上述入口供延伸閱讀; 本章沒有宣稱逐頁查證教材全文。程式與預期測試均未執行。

第09章 鏈式法則、JVP與VJP

學習目標與先備知識

本章旨在建立多變量函數複合時導數的線性代數結構，重點在於理解 Fréchet 導數的鏈式法則、Jacobian-Vector Product (JVP) 與 Vector-Jacobian Product (VJP) 的幾何與算法意義。讀完本章後，讀者應能夠：

1. 從線性映射複合的角度推導 $J_{g \circ f}(x) = J_g(f(x))J_f(x)$ ，並明確區分輸入維度、中間維度與輸出維度。
2. 掌握 JVP 定義為 $J(x)v$ 與 VJP 定義為 $J(x)^T w$ 的維度匹配，理解「切向推送」與「轉置拉回」的對偶關係。
3. 利用內積對偶恆等式 $w^T(Jv) = v^T(J^T w)$ 驗證 JVP 與 VJP 的一致性，並透過有限差分法進行數值核對。
4. 能夠手寫小型計算圖，追蹤 Jacobian 形狀變化，識別廣播 (broadcast) 與轉置操作中的常見維度錯誤。
5. 理解 Fréchet 可微性是本章鏈式法則定理成立的充分條件；偏導數存在或所有方向導數存在不保證 Fréchet 可微，因此不可直接套用此定理。

先備知識要求讀者已掌握 Volume I 中的矩陣乘法、轉置性質、列向量/橫列約定，以及第 7 章的 Fréchet 導數定義 $f(x+h) = f(x) + Df(x)h + r(h)$ ，其中 $\|r(h)\|/\|h\| \rightarrow 0$ 。本章將直接應用其線性映射本質來處理複合函數，不再重複證明 Fréchet 導數的唯一性。

問題與直覺

考慮一個簡單的物理系統：感測器輸出 y 取決於位置 x 與溫度 T ，即 $y = h(x, T)$ 。若位置 x 本身是時間 t 的函數 $x(t)$ ，且溫度 T 是高度 $z(t)$ 的函數 $T(z)$ ，我們需要計算 y 對 t 的導數。直覺上，這是「影響沿著計算圖傳播」的過程。

在單變量微積分中，鏈式法則 $\frac{dy}{dt} = \frac{dy}{dx} \frac{dx}{dt}$ 非常直觀。但在多變量情形，每個函數的「導數」不再是一個純量，而是一個矩陣 (Jacobian)。若 $f: U \subset \mathbb{R}^n \rightarrow \mathbb{R}^m$ 且 $g: V \subset \mathbb{R}^m \rightarrow \mathbb{R}^p$ ，則複合函數 $g \circ f$ 的 Jacobian 是兩個矩陣的乘積。關鍵問題在於：這個乘積的維度如何匹配？為什麼是 J_g 左乘 J_f 而不是右乘？

另一層直覺來自「線性近似」。在點 x 附近， f 的行為由線性映射 $J_f(x)$ 決定。當輸入擾動 $h \in \mathbb{R}^n$ 進入系統時，它首先被 $J_f(x)$ 映射為中間擾動 $\delta u = J_f(x)h \in \mathbb{R}^m$ 。接著，這個中間擾動進入 g 的局部線性模型，被 $J_g(f(x))$ 映射為最終輸出擾動 $\delta y = J_g(f(x))\delta u$ 。結合兩步， $\delta y = J_g(f(x))J_f(x)h$ 。因此，總體導數就是這兩個線性映射的複合。

這種視圖揭示了 JVP 與 VJP 的本質：

- **JVP (Jacobian-Vector Product)**：計算 $J(x)v$ 。這相當於追蹤一個微小擾動 v 如何通過計算圖向前傳播到輸出。這是「前向模式」自動微分的基礎。
- **VJP (Vector-Jacobian Product)**：計算 $J(x)^T w$ 。這相當於將一個輸出端的協向量 (covector) w 通過計算圖反向傳播到輸入端。這是「反向模式」自動微分的基礎，特別適合輸出維度遠小於輸入維度的情形（如損失函數對參數的梯度）。

定義、定理與推導

線性映射複合與鏈式法則

定義 9.1 (Jacobian 矩陣) 設 $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}^m$ 在開集 U 上 Fréchet 可微。其 Fréchet 導數 $Df(x)$ 是一個線性映射 $\mathbb{R}^n \rightarrow \mathbb{R}^m$ 。在標準 Euclidean 座標下，該線性映射由 $m \times n$ 矩陣 $J_f(x)$ 表示，使得對任意 $h \in \mathbb{R}^n$ ， $Df(x)[h] = J_f(x)h$ 。其中 $J_f(x)_{ij} = \frac{\partial f_i}{\partial x_j}(x)$ 。

定理 9.2 (多變量鏈式法則) 設 $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}^m$ 在 x 處 Fréchet 可微， $g : V \subset \mathbb{R}^m \rightarrow \mathbb{R}^p$ 在 $y = f(x)$ 處 Fréchet 可微，且 U, V 為開集。假設 $f(U) \subset V$ 或至少存在 x 的鄰域 $U_x \subset U$ 使得 $f(U_x) \subset V$ 。則複合函數 $g \circ f : U_x \rightarrow \mathbb{R}^p$ 在 x 處 Fréchet 可微，且

$$J_{g \circ f}(x) = J_g(f(x))J_f(x)$$

其中 $J_g(f(x)) \in \mathbb{R}^{p \times m}$ ， $J_f(x) \in \mathbb{R}^{m \times n}$ ，乘積屬於 $\mathbb{R}^{p \times n}$ 。

證明： 以下三個有限維向量空間都使用 Euclidean 二範數，矩陣使用由對應二範數誘導的算子範數。因此 $\|Az\|_2 \leq \|A\|_2 \|z\|_2$ ；為使符號簡潔，下文省略下標。各個餘項仍屬於自己的值域，不能把不同維度的向量直接相加。輸入、過渡空間與輸出所用範數一旦固定，估計中的矩陣範數就是固定點上的有限常數。

考慮輸入擾動 $h \in \mathbb{R}^n$ ，使得 $x + h \in U_x$ 。根據 f 在 x 處的可微性定義：

$$f(x + h) = f(x) + J_f(x)h + r_f(h)$$

其中殘差項滿足 $\lim_{h \rightarrow 0} \frac{\|r_f(h)\|}{\|h\|} = 0$ 。令 $\delta u = J_f(x)h + r_f(h)$ 。注意 $f(x + h) - f(x) = \delta u$ 。由於 f 連續（可微必連續），當 $h \rightarrow 0$ 時， $f(x + h) \rightarrow f(x)$ 。設 $y = f(x)$ 。接下來考慮 g 在 y 處的可微性。將輸入改為 $y + \delta u$ 。根據 g 在 y 處的可微性：

$$g(y + \delta u) = g(y) + J_g(y)\delta u + r_g(\delta u)$$

其中 $\lim_{\delta u \rightarrow 0} \frac{\|r_g(\delta u)\|}{\|\delta u\|} = 0$ 。將 δu 的表達式代入：

$$g(f(x + h)) = g(y) + J_g(y)[J_f(x)h + r_f(h)] + r_g(\delta u)$$

$$g(f(x + h)) = g(y) + J_g(y)J_f(x)h + J_g(y)r_f(h) + r_g(\delta u)$$

整理餘項 $r_{g \circ f}(h) = J_g(y)r_f(h) + r_g(\delta u)$ 。我們需要證明 $\lim_{h \rightarrow 0} \frac{\|r_{g \circ f}(h)\|}{\|h\|} = 0$ 。利用三角不等式：

$$\frac{\|r_{g \circ f}(h)\|}{\|h\|} \leq \frac{\|J_g(y)\| \|r_f(h)\|}{\|h\|} + \frac{\|r_g(\delta u)\|}{\|h\|}$$

第一項： $\|J_g(y)\|$ 是常數（因為 y 固定）， $\frac{\|r_f(h)\|}{\|h\|} \rightarrow 0$ ，故第一項趨近 0。第二項：將分子分母同時乘以並除以 $\|\delta u\|$ （假設 $\delta u \neq 0$ ，若 $\delta u = 0$ 則項為 0）：

$$\frac{\|r_g(\delta u)\|}{\|h\|} = \frac{\|r_g(\delta u)\|}{\|\delta u\|} \frac{\|\delta u\|}{\|h\|}$$

已知 $\frac{\|r_g(\delta u)\|}{\|\delta u\|} \rightarrow 0$ 當 $\delta u \rightarrow 0$ （即 $h \rightarrow 0$ ）。對於因子 $\frac{\|\delta u\|}{\|h\|}$ ：

$$\|\delta u\| = \|J_f(x)h + r_f(h)\| \leq \|J_f(x)\| \|h\| + \|r_f(h)\|$$

$$\frac{\|\delta u\|}{\|h\|} \leq \|J_f(x)\| + \frac{\|r_f(h)\|}{\|h\|}$$

當 $h \rightarrow 0$ 時，右側趨近有限值 $\|J_f(x)\|$ 。因此第二項整體趨近 $0 \times \text{finite} = 0$ 。結論： $\lim_{h \rightarrow 0} \frac{\|r_{g \circ f}(h)\|}{\|h\|} = 0$ 。故 $g \circ f$ 在 x 處可微，且線性部分為 $J_g(f(x))J_f(x)$ 。證畢。

JVP 與 VJP 的對偶性

定義 9.3 (JVP 與 VJP) 對固定點 x ，Jacobian $J = J_f(x) \in \mathbb{R}^{m \times n}$ 。

- **JVP**：給定向量 $v \in \mathbb{R}^n$ （視為 $n \times 1$ 列向量），計算 $Jv \in \mathbb{R}^m$ （ $m \times 1$ 列向量）。
- **VJP**：給定協向量 $w \in \mathbb{R}^m$ （本卷以 $m \times 1$ column 座標表示；相應線性泛函作用為 $w^T \delta y$ ，不把 w 與 w^T 混同），計算 $J^T w \in \mathbb{R}^n$ （ $n \times 1$ 列向量）。註：在 NumPy 等庫中， w 通常存儲為 $(m,)$ 或 $(m, 1)$ 。數學上 w 是輸出空間的餘切向量， $J^T w$ 是輸入空間的餘切向量。只有當 w 對應於某個輸出端損失函數 $\ell: \mathbb{R}^m \rightarrow \mathbb{R}$ 的梯度（即 $w = \nabla \ell(f(x))$ ），且輸入空間使用標準 Euclidean 度量時， $J^T w$ 才直接等同於複合函數 $\ell \circ f$ 的梯度向量。否則， $J^T w$ 僅為輸入空間中的一個協向量（或根據度量識別後的向量），其幾何意義依賴於所選的度量結構。

命題 9.4 (內積對偶恆等式) 對任意 $v \in \mathbb{R}^n$ 和 $w \in \mathbb{R}^m$ （均視為列向量），

$$w^T(Jv) = v^T(J^T w)$$

此恆等式確保了前向傳播擾動與反向傳播協向量的數學一致性。

證明：左側 $w^T(Jv)$ 是標量（ 1×1 ）。右側 $v^T(J^T w)$ 也是標量。考慮左側轉置：

$$(w^T Jv)^T = v^T (J^T)(w^T)^T = v^T J^T w$$

因為 $w^T Jv$ 是實數標量，其轉置等於其本身，故 $w^T(Jv) = v^T(J^T w)$ 。證畢。

此命題是自動微分框架的核心：前向計算圖的線性變化與反向計算圖拉回的協向量，必須滿足這個對偶配對恆等式。只有輸出協向量來自指定標量損失的微分，且採用相應的 Euclidean 梯度識別時，才將結果稱為該複合損失的梯度。

計算時還應區分三種核對。第一是矩陣形狀，確保每個節點的輸入、輸出與轉置方向合法。第二是對偶配對，使用同一個解析 Jacobian 比較兩個標量；它能抓出方向或索引不一致，卻不能單獨證明 Jacobian 正確，因為同一個錯矩陣也滿足轉置恆等式。第三是與原函數值的有限差分比較，這才提供獨立的局部數值對照。有限差分仍有截斷與捨入誤差，應在定義域內選數個步長，而不是把單一很小的步長當作數學證明。這三層檢查互補，不能互相替代。

逐步手算例題

例 9.1: 簡單複合函數的 Jacobian 計算

設 $f: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 定義為：

$$f_1(x, y) = x^2 + y$$

$$f_2(x, y) = \sin(x)$$

$$f_3(x, y) = e^y$$

計算 $J_f(x, y)$ 。

解答：Jacobian 為 3×2 矩陣，元素為 $J_{ij} = \frac{\partial f_i}{\partial x_j}$ 。第一橫列（對應 f_1 ）： $\frac{\partial f_1}{\partial x} = 2x$ ， $\frac{\partial f_1}{\partial y} = 1$ 。第二橫列（對應 f_2 ）： $\frac{\partial f_2}{\partial x} = \cos(x)$ ， $\frac{\partial f_2}{\partial y} = 0$ 。第三橫列（對應 f_3 ）： $\frac{\partial f_3}{\partial x} = 0$ ， $\frac{\partial f_3}{\partial y} = e^y$ 。

$$J_f(x, y) = \begin{bmatrix} 2x & 1 \\ \cos(x) & 0 \\ 0 & e^y \end{bmatrix}$$

現在考慮 $g: \mathbb{R}^3 \rightarrow \mathbb{R}^1$ 定義為 $g(u, v, w) = uv + w^2$ 。計算 $J_g(u, v, w)$ ： $\frac{\partial g}{\partial u} = v$ ， $\frac{\partial g}{\partial v} = u$ ， $\frac{\partial g}{\partial w} = 2w$ 。

$$J_g(u, v, w) = [v \quad u \quad 2w] \in \mathbb{R}^{1 \times 3}$$

複合函數 $h = g \circ f: \mathbb{R}^2 \rightarrow \mathbb{R}^1$ 。根據鏈式法則， $J_h(x, y) = J_g(f(x, y))J_f(x, y)$ 。維度檢查： $(1 \times 3) \times (3 \times 2) = 1 \times 2$ 。正確。代入 $f(x, y)$ ： $u = x^2 + y$ ， $v = \sin(x)$ ， $w = e^y$ 。

$$J_g(f(x, y)) = [\sin(x) \quad x^2 + y \quad 2e^y]$$

$$J_h(x, y) = [\sin(x) \quad x^2 + y \quad 2e^y] \begin{bmatrix} 2x & 1 \\ \cos(x) & 0 \\ 0 & e^y \end{bmatrix}$$

執行矩陣乘法：第一元素（對 x 的偏導）：

$$\sin(x)(2x) + (x^2 + y)(\cos(x)) + 2e^y(0) = 2x \sin(x) + (x^2 + y) \cos(x)$$

第二元素（對 y 的偏導）：

$$\sin(x)(1) + (x^2 + y)(0) + 2e^y(e^y) = \sin(x) + 2e^{2y}$$

故

$$J_h(x, y) = [2x \sin(x) + (x^2 + y) \cos(x) \quad \sin(x) + 2e^{2y}]$$

JVP 驗證： 取 $x = 0, y = 0$ 。 $f(0, 0) = (0, 0, 1)$ 。 $J_f(0, 0) = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$ 。 $J_g(f(0, 0)) = [0 \quad 0 \quad 2]$ 。

$J_h(0, 0) = [0 \quad 0 \quad 2] \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} = [0 \quad 2]$ 。 取 $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 。 JVP: $J_h(0, 0)v = [0 \quad 2] \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 2$ 。 手動計算

JVP via chain: $\delta u = J_f(0, 0)v = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ 。 $J_g(f(0, 0))\delta u = [0 \quad 0 \quad 2] \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = 2$ 。 一致。

例 9.2: VJP 與梯度計算

考慮損失函數 $L: \mathbb{R}^2 \rightarrow \mathbb{R}$, $L(a, b) = (a - b)^2 + a^3$ 。我們想計算梯度 ∇L ，這等於 VJP with $w = 1$ 。

$J_L = [\frac{\partial L}{\partial a} \quad \frac{\partial L}{\partial b}] = [2(a - b) + 3a^2 \quad -2(a - b)]$ 。取點 $(a, b) = (1, 2)$ 。 $J_L(1, 2) =$

$[2(1 - 2) + 3(1)^2 \quad -2(1 - 2)] = [-2 + 3 \quad 2] = [1 \quad 2]$ 。 梯度 $\nabla L = J_L^T = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 。 使用 VJP 定義：

$w = [1]$ 。 $J_L^T w = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \cdot 1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 。 驗證內積對偶：取 $v = \begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix}$ 。 JVP: $J_L v = [1 \quad 2] \begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix} = 0.5 -$

$1 = -0.5$ 。 $w^T(\text{JVP}) = 1 \cdot (-0.5) = -0.5$ 。 VJP: $J_L^T w = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 。 $v^T(\text{VJP}) = [0.5 \quad -0.5] \begin{bmatrix} 1 \\ 2 \end{bmatrix} = 0.5 -$

$1 = -0.5$ 。 兩邊相等，驗證通過。

實作與程式

以下提供一個自足 Python 程式碼，實現小型計算圖、JVP 與 VJP 的計算，並使用有限差分法進行核對。程式僅使用 NumPy。為了避免狀態覆蓋錯誤，我們將前向函數設計為純函數，並獨立計算 Jacobian。此外，為了測試定義域邊界，我們引入一個包含對數運算的函數 $f_{\text{dom}}(x) = [\ln(x_1 + 1), \exp(x_2)]^T$ ，其定義域要求 $x_1 > -1$ 。

```
import numpy as np

def forward_standard(x):
    """
    f: R^2 -> R^3
    f1 = x[0] * x[1]
```

```

    f2 = sin(x[0])
    f3 = exp(x[1])
    x is shape (2,)
    returns shape (3,)
    """

    x1, x2 = x[0], x[1]
    return np.array([x1 * x2, np.sin(x1), np.exp(x2)])

def jacobian_standard(x):
    """
    Analytic Jacobian J:  $\mathbb{R}^2 \rightarrow \mathbb{R}^3$ , shape (3, 2)
    """
    x1, x2 = x[0], x[1]
    return np.array([
        [x2, x1],
        [np.cos(x1), 0.0],
        [0.0, np.exp(x2)]
    ])

def forward_domain(x):
    """
    f:  $\mathbb{R}^2 \rightarrow \mathbb{R}^2$ , with domain restriction  $x[0] > -1$ 
    f1 =  $\ln(x[0] + 1)$ 
    f2 =  $\exp(x[1])$ 
    """
    if x[0] <= -1.0:
        raise ValueError("Input x[0] must be greater than -1")
    return np.array([np.log(x[0] + 1.0), np.exp(x[1])])

def jacobian_domain(x):
    """
    Analytic Jacobian for forward_domain
    """
    if x[0] <= -1.0:
        raise ValueError("Input x[0] must be greater than -1")
    return np.array([
        [1.0 / (x[0] + 1.0), 0.0],
        [0.0, np.exp(x[1])]
    ])

def finite_diff_jvp(func, x, v, eps=1e-7):
    """
    Estimate JVP using central difference.
    x, v are 1D arrays.
    """
    x_plus = x + 0.5 * eps * v
    x_minus = x - 0.5 * eps * v
    f_plus = func(x_plus)
    f_minus = func(x_minus)
    return (f_plus - f_minus) / eps

def finite_diff_vjp(func, x, w, eps=1e-7):
    """
    Estimate VJP using central difference on scalar function  $\phi(x) = w^T f(x)$ .
     $\phi'(x) = J^T w$ .
    x is 1D array, w is 1D array.
    """
    n = len(x)
    grad = np.zeros(n)

```



```

for i in range(n):
    h = np.zeros(n)
    h[i] = eps
    x_plus = x + 0.5 * h
    x_minus = x - 0.5 * h
    phi_plus = np.dot(w, func(x_plus))
    phi_minus = np.dot(w, func(x_minus))
    grad[i] = (phi_plus - phi_minus) / eps
return grad

def test_chain_rule():
    # Base point for standard function
    x = np.array([0.5, -1.2])

    # Vectors for testing
    v = np.array([0.3, -0.7])
    w = np.array([1.0, -2.0, 0.5])

    # Analytic calculations
    J = jacobian_standard(x)
    jvp_analytic = J @ v
    vjp_analytic = J.T @ w

    # Finite difference calculations
    jvp_fd = finite_diff_jvp(forward_standard, x, v)
    vjp_fd = finite_diff_vjp(forward_standard, x, w)

    # Error checks
    err_jvp = np.linalg.norm(jvp_analytic - jvp_fd)
    err_vjp = np.linalg.norm(vjp_analytic - vjp_fd)

    print(f"Analytic JVP: {jvp_analytic}")
    print(f"FD JVP: {jvp_fd}")
    print(f"JVP Error: {err_jvp:.2e}")
    assert err_jvp < 1e-5, "JVP mismatch"

    print(f"Analytic VJP: {vjp_analytic}")
    print(f"FD VJP: {vjp_fd}")
    print(f"VJP Error: {err_vjp:.2e}")
    assert err_vjp < 1e-5, "VJP mismatch"

    # Duality test
    lhs = np.dot(w, jvp_analytic)
    rhs = np.dot(v, vjp_analytic)
    assert np.isclose(lhs, rhs), "Duality failed"
    print(f"Duality: LHS={lhs}, RHS={rhs}")

    # Special Value Test: Zero vector
    v_zero = np.zeros(2)
    jvp_zero = jacobian_standard(x) @ v_zero
    assert np.allclose(jvp_zero, 0.0), "JVP with zero v should be 0"

    w_zero = np.zeros(3)
    vjp_zero = jacobian_standard(x).T @ w_zero
    assert np.allclose(vjp_zero, 0.0), "VJP with zero w should be 0"

    # Fault Test: Dimension mismatch
    raised = False
    try:

```

```

        _ = jacobian_standard(x) @ np.array([1.0]) # Wrong shape
except ValueError:
    raised = True
assert raised, "Dimension mismatch was not rejected"

# Interior test for domain-restricted function
x_dom = np.array([0.5, -1.0])
v_dom = np.array([0.1, 0.2])
w_dom = np.array([1.0, 1.0])

J_dom = jacobian_domain(x_dom)
jvp_dom_analytic = J_dom @ v_dom
vjp_dom_analytic = J_dom.T @ w_dom

jvp_dom_fd = finite_diff_jvp(forward_domain, x_dom, v_dom)
vjp_dom_fd = finite_diff_vjp(forward_domain, x_dom, w_dom)

err_dom_jvp = np.linalg.norm(jvp_dom_analytic - jvp_dom_fd)
err_dom_vjp = np.linalg.norm(vjp_dom_analytic - vjp_dom_fd)

print(f"Domain JVP Error: {err_dom_jvp:.2e}")
assert err_dom_jvp < 1e-5, "Domain JVP mismatch"
print(f"Domain VJP Error: {err_dom_vjp:.2e}")
assert err_dom_vjp < 1e-5, "Domain VJP mismatch"

# Exact boundary: both value and Jacobian must reject x[0] == -1.
for func in (forward_domain, jacobian_domain):
    rejected = False
    try:
        func(np.array([-1.0, 0.0]))
    except ValueError:
        rejected = True
    assert rejected, "Exact domain boundary was not rejected"

# Out-of-domain test
x_invalid = np.array([-1.5, 0.0])
raised_dom = False
try:
    _ = forward_domain(x_invalid)
except ValueError:
    raised_dom = True
assert raised_dom, "Out-of-domain input was not rejected"

print("All tests passed.")

if __name__ == "__main__":
    test_chain_rule()

```

測試與預期結果

本節未提供章內程式的執行紀錄，以下均為依解析推導的預期結果。All tests passed. 只會在未來實際執行且全部斷言成立後印出，不能把程式中的這段字串當成已通過的證據。

對數例子的 $x_1 = 0.5$ 是內點，不是邊界；新增的 $x_1 = -1$ 才是精確邊界，而 $x_1 = -1.5$ 是域外點。若自行改用靠近邊界的合法點做中央差分，必須檢查正、負擾動後的兩個點都仍有 $x_1 > -1$ 。不能讓差分跨出定義域後，再把例外或非有限值解讀為導數不存在。本文的固定測試點及步長滿足這項限制，若擴充為通用測試器，還須另行驗證輸入形狀、有限值及步長合法性。

上述程式的預期數值如下（具體浮點誤差視環境而定）：

$$1. \text{JVP 核對: } x = (0.5, -1.2), J = \begin{bmatrix} -1.2 & 0.5 \\ \cos(0.5) & 0 \\ 0 & e^{-1.2} \end{bmatrix} \approx \begin{bmatrix} -1.2 & 0.5 \\ 0.87758 & 0 \\ 0 & 0.30119 \end{bmatrix} \circ v = (0.3, -0.7) \circ$$

$$Jv = \begin{bmatrix} -1.2(0.3) + 0.5(-0.7) \\ \cos(0.5)(0.3) \\ e^{-1.2}(-0.7) \end{bmatrix} = \begin{bmatrix} -0.36 - 0.35 \\ 0.26327477 \\ -0.21083524 \end{bmatrix} \approx \begin{bmatrix} -0.71 \\ 0.26327477 \\ -0.21083524 \end{bmatrix} \circ \text{預期誤差} < 10^{-5} \circ$$

$$2. \text{VJP 核對: } w = (1.0, -2.0, 0.5) \circ J^T w = \begin{bmatrix} -1.2 & \cos(0.5) & 0 \\ 0.5 & 0 & e^{-1.2} \end{bmatrix} \begin{bmatrix} 1.0 \\ -2.0 \\ 0.5 \end{bmatrix} =$$

$$\begin{bmatrix} -1.2(1) + \cos(0.5)(-2) \\ 0.5(1) + e^{-1.2}(0.5) \end{bmatrix} \approx \begin{bmatrix} -1.2 - 1.75516 \\ 0.5 + 0.15060 \end{bmatrix} = \begin{bmatrix} -2.95516 \\ 0.65060 \end{bmatrix} \circ \text{預期誤差} < 10^{-5} \circ$$

3. 對偶恆等式： $w^T(Jv)$ 與 $v^T(J^T w)$ 應在機器精度內相等。

4. 特殊值測試：

- 零向量 $v = 0$ ：JVP 應為 0。
- 零協向量 $w = 0$ ：VJP 應為 0。

5. 故障與邊界測試：

- 維度錯誤：若 v 長度不為 2，NumPy 應拋出 `ValueError`。
- 定義域邊界：對於 f_{dom} ，若 $x_1 \leq -1$ ，應拋出 `ValueError`。測試點 $x_1 = -1.5$ 應觸發此錯誤。

反例與常見陷阱

反例 1: 偏導數存在但不 Fréchet 可微

考慮 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ，

$$f(x, y) = \begin{cases} \frac{x^2 y}{x^2 + y^2} & (x, y) \neq (0, 0) \\ 0 & (x, y) = (0, 0) \end{cases}$$

在原點處，偏導數存在： $\frac{\partial f}{\partial x}(0, 0) = 0$ ， $\frac{\partial f}{\partial y}(0, 0) = 0$ 。若 f 可微，則 $J_f(0, 0) = [0, 0]$ ，且必須滿足

$\lim_{(h,k) \rightarrow (0,0)} \frac{f(h,k) - 0 - [0,0] \cdot [h,k]^T}{\sqrt{h^2 + k^2}} = 0$ 。即考察 $\lim_{(h,k) \rightarrow (0,0)} \frac{\frac{h^2 k}{h^2 + k^2}}{\sqrt{h^2 + k^2}} = \lim_{(h,k) \rightarrow (0,0)} \frac{h^2 k}{(h^2 + k^2)\sqrt{h^2 + k^2}}$ 。取路徑 $k = x$ ：

$$\frac{x^2 \cdot x}{(x^2 + x^2)\sqrt{x^2 + x^2}} = \frac{x^3}{2x^2|x|\sqrt{2}} = \frac{x}{2|x|\sqrt{2}} = \pm \frac{1}{2\sqrt{2}}$$

極限不存在。故 f 在原點偏導數存在，但不可微。**陷阱**：若在此點套用鏈式法則，假設 $J_f = 0$ ，會得出複合函數導數為 0，但實際方向導數依方向而異（例如沿 $y = x$ 方向導數為 $1/2$ ）。鏈式法則要求 Fréchet 可微，僅有偏導數存在不足以套用此定理。

陷阱 2: 維度混淆

在 NumPy 中，一維陣列 v 形狀為 $(n,)$ 。 $J @ v$ 結果形狀 $(m,)$ 。常見錯誤是混淆 Jv 和 $J^T v$ 。在反向傳播中，如果誤將 J 當作 J^T 使用，維度可能恰好匹配（當 $m = n$ 時），但數值錯誤。**對策**：明確使用 $(n, 1)$ 和 $(1, n)$ 形狀，或在程式中強制轉置並註明意圖，並利用斷言檢查輸出形狀。

陷阱 3: 非 Euclidean 內積與協向量

上述對偶性假設標準 Euclidean 內積。

- **協向量拉回**：若 w 是輸出空間的協向量（covector），其拉回定義為 $J^T w$ ，這不依賴於輸入或輸出空間的度量選擇，純粹是線性代數的對偶映射。
- **向量識別**：若我們希望將輸入空間的向量 v 視為協向量以進行內積，則需選定度量 G 。對稱正定度量 G 下， v 對應的協向量以 column 座標表示為 Gv ，其作用於擾動 h 是 $(Gv)^T h = v^T G h$ 。固定 column 表示後，不再把協向量座標本身改寫成橫向量。切勿混淆「協向量的線性拉回」與「利用度量矩陣轉換向量」。在標準訓練中，若 w 代表輸出標量損失的微分，才可用 Euclidean 度量將 $J^T w$ 識別為複合損失梯度；一般任意的 w 只指定一個拉回的協向量。

AI、幾何與養殖案例

幾何解讀

在微分幾何中， $J_f(x)$ 是切映射（differential） $df_x : T_x \mathbb{R}^n \rightarrow T_{f(x)} \mathbb{R}^m$ 。JVP 計算切向量 v 在像流形上的像 $df_x(v)$ 。VJP 計算餘切向量（cotangent） w 在源流形上的拉回 $df_x^*(w)$ 。內積對偶性反映了 Riemannian 流形上對偶基的關係：切空間與餘切空間通過度量張量同構。在 Euclidean 空間，度量为恒等矩陣，故轉置即為對應。

養殖感測校準案例（合成）

考慮一個水產養殖感測系統，輸出為溶解氧濃度 DO [mg/L] 與 pH 值 [無因次]。輸入為溫度 T [°C]、鹽度 S [ppt]。 $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2, f(T, S) = (DO(T, S), pH(T, S))$ 。Jacobian J_f 的元素單位不同： $\partial DO / \partial T$ 單位為 mg/L/°C， $\partial DO / \partial S$ 單位為 mg/L/ppt， $\partial pH / \partial T$ 單位為 1/°C。由於單位不同，**不可**直接對 J_f 計算無權重的 Euclidean 範數作為「總敏感度」。必須先進行無因次化或加權。設 $S_x = \text{diag}(s_T, s_S)$ 為輸入尺度矩陣， $S_y = \text{diag}(s_{DO}, s_{pH})$ 為輸出尺度矩陣。無因次化後的 Jacobian 為：

$$J_{\tilde{f}} = S_y^{-1} J_f S_x$$

返回物理量時，使用相反的尺度轉換。**監控**：監測 J_f 的條件數（需先尺度化為方陣或明確定義奇異值比）可提示模型在該區域不可辨識（identifiability issue）或感測器失效。條件數異常是「需進一步檢查」的信號，而非直接判定故障的證明。**鏈式法則應用**：若控制變數 P [L/min] 影響 T 和 S ，定義中間映射 $q(P) = (T(P), S(P))^T$ 。則損失 L 對 P 的梯度為：

$$\frac{dL}{dP} = J_q(P)^T J_f(q(P))^T \nabla_y L$$

其中 $J_q \in \mathbb{R}^{2 \times 1}$ ， $J_f \in \mathbb{R}^{2 \times 2}$ ， $\nabla_y L \in \mathbb{R}^2$ 。乘法形狀依次為 $(1 \times 2)(2 \times 2)(2 \times 1) = (1 \times 1)$ ，最終為標量導數。此為 VJP 鏈式應用。

習題

- 手算**：設 $f: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ 為 $f_1 = x_1 x_2 + x_3$ ， $f_2 = x_1^2 - x_3$ 。設 $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ 為 $g(u, v) = u^2 v$ 。計算 $J_{g \circ f}$ 在 $(1, 1, 1)$ 處的值。並計算當 $v = [1, 0, 1]^T$ 時的 JVP。
- 程式**：修改 forward 和 jacobian 增加第四個輸出 $f_4 = \ln(x_1 + x_2)$ 。重新計算 Jacobian，並確保 $x_1 + x_2 > 0$ 。寫出 VJP 的有限差分驗證程式，並加入邊界檢查（若 $x_1 + x_2 \leq 0$ 則拋出 `ValueError`）。
- 反例**：構造一個 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ 使得 $\frac{\partial f}{\partial x}(0, 0)$ 和 $\frac{\partial f}{\partial y}(0, 0)$ 存在，但 f 在 $(0, 0)$ 不可微。證明沿路徑 $y = x$ 的方向導數不等於 0。
- 整合**：考慮 $h(x) = \|f(x)\|^2$ ，其中 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 。使用鏈式法則證明 $\nabla h(x) = 2J_f(x)^T f(x)$ 。解釋為何這對應於 VJP with $w = 2f(x)$ 。

習題解答

- 解答**： $J_f(x) = \begin{bmatrix} x_2 & x_1 & 1 \\ 2x_1 & 0 & -1 \end{bmatrix}$ 。在 $(1, 1, 1)$ ， $J_f = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 0 & -1 \end{bmatrix}$ 。 $f(1, 1, 1) = (2, 0)$ 。
 $g(u, v) = u^2 v$ 。 $J_g(u, v) = [2uv \quad u^2]$ 。 $J_g(2, 0) = [0 \quad 4]$ 。 $J_{g \circ f} = J_g J_f =$
 $[0 \quad 4] \begin{bmatrix} 1 & 1 & 1 \\ 2 & 0 & -1 \end{bmatrix} = [8 \quad 0 \quad -4]$ 。 JVP with $v = [1, 0, 1]^T$: $[8 \quad 0 \quad -4] \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} = 4$ 。
- 解答**： $f_4 = \ln(x_1 + x_2)$ 。 $\frac{\partial f_4}{\partial x_1} = \frac{1}{x_1 + x_2}$ ， $\frac{\partial f_4}{\partial x_2} = \frac{1}{x_1 + x_2}$ 。更新 J_f 增加一行 $[\frac{1}{x_1 + x_2}, \frac{1}{x_1 + x_2}]$ 。程式中需檢查 `if x[0] + x[1] <= 0: raise ValueError("Log argument non-positive")`。使用主程式已定義的函數，可補成以下完整測試；同樣只列預期，不宣稱已執行。注意本程式的前三個輸出與手算例 9.1 不同，故以 `forward_standard` 作為基底。

```
def forward_extended(x):
    if x[0] + x[1] <= 0:
        raise ValueError("Log argument non-positive")
    return np.r_[forward_standard(x), np.log(x[0] + x[1])]
```

```
def jacobian_extended(x):
    if x[0] + x[1] <= 0:
        raise ValueError("Log argument non-positive")
    return np.vstack([jacobian_standard(x),
                      [1/(x[0]+x[1]), 1/(x[0]+x[1])]])

point = np.array([0.5, 0.8])
weight = np.array([1.0, -2.0, 0.5, 0.3])
expected = jacobian_extended(point).T @ weight
observed = finite_diff_vjp(forward_extended, point, weight)
assert np.linalg.norm(expected-observed) < 1e-5
for bad in (np.array([1.0, -1.0]), np.array([0.0, -1.0])):
    rejected = False
    try:
        forward_extended(bad)
    except ValueError:
        rejected = True
    assert rejected
```

3. 解答：取 $f(x, y) = \frac{x^2 y}{x^2 + y^2}$ 當 $(x, y) \neq (0, 0)$ ，否則 0。偏導數為 0。沿 $y = x$ ， $f(x, x) = \frac{x^3}{2x^2} = \frac{x}{2}$ 對所有 $x \neq 0$ 。方向導數（沿向量 $(1, 1)$ ，未正規化）：

$$\lim_{t \rightarrow 0} \frac{f(t, t) - f(0, 0)}{t} = \lim_{t \rightarrow 0} \frac{t/2}{t} = \frac{1}{2} \neq 0$$

由於線性近似 $J = 0$ 預測導數為 0，但實際為 $1/2$ ，故不可微。

4. 解答： $h(x) = f(x)^T f(x)$ 。令 $g(u) = u^T u : \mathbb{R}^m \rightarrow \mathbb{R}$ 。 $Dg(u)[\delta u] = 2u^T \delta u$ 。 $h(x) = g(f(x))$ 。 $\nabla h(x) = J_f(x)^T \nabla g(f(x)) = J_f(x)^T (2f(x)) = 2J_f(x)^T f(x)$ 。這對應於 VJP：將輸出空間的協向量 $w = 2f(x)$ 拉回輸入空間，即 $J_f^T(2f)$ 。

本章小結

本章建立了多變量鏈式法則的線性代數基礎，將導數視為線性映射的複合。我們定義了 JVP 與 VJP，並通過內積對偶恆等式證明了它們的一致性。手算與程式實作展示了如何計算並驗證這些量。關鍵在於嚴格遵守維度約定，並理解 Fréchet 可微性是本章鏈式法則定理成立的充分條件。在應用中，JVP 用於前向敏感度分析，VJP 用於反向梯度計算，兩者共同構成現代自動微分系統的核心。養殖案例強調了單位一致性與無因次化的重要性，並展示了如何正確應用鏈式法則於多層映射。

參考來源

1. Jiří Lebl. *Basic Analysis*. <https://www.jirka.org/ra/>
2. MIT OCW. *18.02SC Multivariable Calculus*. <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
3. JAX Documentation. *Autodiff Cookbook: JVP/VJP*. https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html

第10章 矩陣微分與Frobenius內積

學習目標與先備知識

本章把矩陣視為有限維向量空間中的元素，並以 Frobenius 內積描述矩陣變數的微分。完成本章後，你應能：

1. 說明矩陣變數的微分如何成為線性映射，並辨認微分、梯度與矩陣形狀。
2. 使用 $df = \text{tr}(G^T dX)$ ，從微分式找出與 X 同形狀的梯度 G 。
3. 推導 $\frac{1}{2}\|AX - B\|_F^2$ 對 X 的梯度與方向導數。
4. 對矩陣函數組合使用鏈式法則，並用方向擾動核對梯度。
5. 辨認轉置、維度及程式廣播造成的錯誤，並說明數值檢查能支持什麼、不能證明什麼。

先備知識包括矩陣乘法、轉置、跡、向量微分與 Fréchet 可微的定義。除非另有說明，矩陣空間採 Frobenius 範數，向量空間採 Euclidean 範數。本章的矩陣均為實矩陣。

問題與直覺

令 $X \in \mathbb{R}^{p \times q}$ 。它有 pq 個實數分量，可以列成一個長度 pq 的向量；但推導和實作時保留矩陣形狀，通常更能看清運算結構。矩陣擾動記為 $H \in \mathbb{R}^{p \times q}$ 。若純量函數 f 在 X 可微，則在 X 附近有線性近似

$$f(X + H) = f(X) + Df(X)[H] + r(H), \quad \frac{|r(H)|}{\|H\|_F} \longrightarrow 0 \quad \text{當 } \|H\|_F \rightarrow 0.$$

這裡 $Df(X)$ 是作用於矩陣擾動的線性泛函：輸入是 $p \times q$ 矩陣，輸出是純量。它描述一階變化，不是另一個與 X 同形狀的矩陣。

Frobenius 內積定義為

$$\langle U, V \rangle_F = \text{tr}(U^T V) = \sum_{i,j} U_{ij} V_{ij},$$

對應範數為

$$\|U\|_F = \sqrt{\langle U, U \rangle_F}.$$

若存在唯一矩陣 $G \in \mathbb{R}^{p \times q}$ ，使得對所有 H 都有

$$Df(X)[H] = \langle G, H \rangle_F = \text{tr}(G^T H),$$

便稱 G 為 f 在 X 的 Frobenius 梯度，記為 $\nabla_X f(X)$ 。梯度與變數同形狀，是因為此處選用 Frobenius 內積來代表線性泛函；微分和梯度仍是不同的數學物件。

方向導數提供一個直覺：沿矩陣方向 H 改變 X ，函數的一階變化率為 $\langle \nabla_X f, H \rangle_F$ 。若此值為正，沿 H 的小幅變化使函數增加；若為負，則使函數減少；若為零，只表示這個方向的一階變化為零，不表示梯度本身為零。方向導數是一個數，梯度則是一個矩陣，兩者不可互換。

定義、定理與推導

矩陣微分的定義

對 $f: \mathbb{R}^{p \times q} \rightarrow \mathbb{R}$ ，若存在線性映射 $L: \mathbb{R}^{p \times q} \rightarrow \mathbb{R}$ ，使得

$$f(X + H) = f(X) + L[H] + r(H), \quad \frac{|r(H)|}{\|H\|_F} \rightarrow 0,$$

則稱 f 在 X Fréchet 可微，並記 $L = Df(X)$ 。這個極限的意思是：當擾動縮小時，線性近似的誤差相對於擾動大小也趨近於零。只知道某個固定方向上的差商有極限，並不足以得到這個結論；Fréchet 可微要求所有小擾動一致地滿足所述餘項條件。

微分記號 df 是在固定基點 X 下對線性映射 $Df(X)$ 的簡記。若推導得到

$$df = \text{tr}(G^T dX),$$

其精確含義是：對任意方向 H ，都有 $Df(X)[H] = \text{tr}(G^T H)$ 。式中的 dX 不應被當成可獨立任意運算的數字。

Frobenius 內積表示命題

命題。 對任意線性泛函 $L: \mathbb{R}^{p \times q} \rightarrow \mathbb{R}$ ，存在唯一的 $G \in \mathbb{R}^{p \times q}$ ，使得對所有 $H \in \mathbb{R}^{p \times q}$ ，

$$L[H] = \text{tr}(G^T H).$$

證明。 設 E_{ij} 為只有第 (i, j) 個元素等於 1、其餘元素皆為 0 的矩陣。每個 H 都能寫成有限和

$$H = \sum_{i=1}^p \sum_{j=1}^q H_{ij} E_{ij}.$$

由 L 的線性，

$$L[H] = \sum_{i=1}^p \sum_{j=1}^q H_{ij} L[E_{ij}].$$

定義 $G_{ij} = L[E_{ij}]$ ，便有

$$L[H] = \sum_{i,j} G_{ij} H_{ij} = \text{tr}(G^T H),$$

故表示矩陣存在。若 G 與 $\tilde{G}$ 都能表示同一個 L ，對 $H = E_{ij}$ 代入，得到 $G_{ij} = L[E_{ij}] = \tilde{G}_{ij}$ 。這對每一個 i, j 都成立，因此 $G = \tilde{G}$ ，唯一性得證。證畢。

此命題依賴有限維矩陣空間與指定的 Frobenius 內積。它保證一個線性泛函有唯一的同形狀矩陣表示，卻不代表任何未整理的微分式都能直接把某個因子當梯度。必須先把微分寫成 $\text{tr}(G^T dX)$ ，並確認維度相容，才能讀出梯度。

跡運算與微分規則

矩陣尺寸相容時，常用恆等式包括

$$\text{tr}(U^T V) = \text{tr}(V^T U), \quad \text{tr}(PQ) = \text{tr}(QP),$$

以及循環移位

$$\text{tr}(P_1 P_2 \cdots P_k) = \text{tr}(P_2 \cdots P_k P_1).$$

循環移位要求乘積有定義，移位後的乘積也形成方陣。它不是任意交換：通常不能把矩陣乘積中的因子任意調換，更不能由跡相等推出矩陣本身相等。推導時應同時記錄乘法順序與矩陣形狀。

對固定矩陣 A, C ，令 $Y = AXC$ ，則

$$dY = A(dX)C.$$

這是因為 $Y(X + H) - Y(X) = AHC$ ，其對 H 線性，且沒有額外餘項。

若 $R = R(X)$ ，則

$$\begin{aligned} d\left(\frac{1}{2}\|R\|_F^2\right) &= d\left(\frac{1}{2}\text{tr}(R^T R)\right) \\ &= \frac{1}{2}\text{tr}((dR)^T R + R^T dR) \\ &= \text{tr}(R^T dR). \end{aligned}$$

最後一步使用前兩項的跡相等。係數 $\frac{1}{2}$ 正好抵消兩項相同的貢獻。

矩形最小平方梯度

令 $A \in \mathbb{R}^{m \times n}$ 、 $X \in \mathbb{R}^{n \times p}$ 、 $B \in \mathbb{R}^{m \times p}$ ，並定義

$$R = AX - B, \quad F(X) = \frac{1}{2}\|AX - B\|_F^2.$$

因為 A, B 固定， $dR = A dX$ 。因此

$$\begin{aligned} dF &= \text{tr}(R^T dR) \\ &= \text{tr}(R^T A dX) \\ &= \text{tr}((A^T R)^T dX). \end{aligned}$$

所以

$$\nabla_X F = A^T (AX - B) \in \mathbb{R}^{n \times p}.$$

形狀也可獨立核對： A^T 為 $n \times m$ ，殘差為 $m \times p$ ，乘積是 $n \times p$ ，與 X 同形狀。若目標函數改為 $\|AX - B\|_F^2$ ，則梯度多一個因子 2。

此處的結論對所有實矩陣 A, X, B 都成立，不要求 A 可逆，也不要求最小平方問題有唯一解。唯一解與否牽涉最佳化問題的秩與幾何性質，不影響這個梯度公式的推導。

矩陣鏈式法則

設 $Y = \Phi(X) \in \mathbb{R}^{a \times b}$ ，且 $f(Y)$ 為純量函數。對任意方向 H ，鏈式法則是

$$D(f \circ \Phi)(X)[H] = Df(Y)[D\Phi(X)[H]].$$

令 $G_Y = \nabla_Y f$ ，則

$$D(f \circ \Phi)(X)[H] = \langle G_Y, D\Phi(X)[H] \rangle_F.$$

因此， X 的梯度由 $D\Phi(X)$ 在 Frobenius 內積下的伴隨映射作用於 G_Y 得到。若 $D\Phi(X)[H] = AHC$ ，則

$$\begin{aligned} \langle G_Y, AHC \rangle_F &= \text{tr}(G_Y^T AHC) \\ &= \text{tr}(CG_Y^T AH) \\ &= \text{tr}((A^T G_Y C^T)^T H). \end{aligned}$$

所以

$$\nabla_X (f \circ \Phi) = A^T G_Y C^T.$$

此式中轉置的位置來自 Frobenius 內積與跡的整理，並非可任意套用的記憶口訣。對不熟悉的矩陣映射，最可靠的方法是先算 $D\Phi(X)[H]$ ，再將純量方向導數整理成 $\text{tr}(G_X^T H)$ 。

正則性與證據界線

本章用到的線性與多項式型矩陣映射，例如 $X \mapsto AX - B$ 、 $X \mapsto X^T X$ ，在有限維矩陣空間處處可微。以 $X^T X$ 為例，

$$(X + H)^T(X + H) = X^T X + X^T H + H^T X + H^T H.$$

前兩個新增的一階項構成線性微分；餘項 $H^T H$ 的範數可由矩陣範數不等式界定為二階量。因此餘項除以 $\|H\|_F$ 後趨於零。這說明相應微分不是只靠形式規則猜出來的。

數值檢查則回答較窄的問題。若某次方向差分與解析方向導數明顯不符，可以指出該實作在這個輸入、方向或步長附近有問題；若若干方向吻合，只能說這些測試沒有發現錯誤。有限測試不涵蓋所有方向，也不證明餘項比值在所有趨近方式下都趨於零。

逐步手算例題

例題一：內積型純量函數

令 $A, X \in \mathbb{R}^{2 \times 2}$ ，其中

$$A = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad X = \begin{bmatrix} 2 & 0 \\ 1 & -1 \end{bmatrix}, \quad f(X) = \text{tr}(A^T X).$$

先展開函數：

$$f(X) = \sum_{i,j} A_{ij} X_{ij} = 1 \cdot 2 + 2 \cdot 0 + (-1) \cdot 1 + 3 \cdot (-1) = -2.$$

對任意擾動 H ，

$$f(X + H) - f(X) = \text{tr}(A^T H).$$

此差值恰為線性函數，餘項為零，因此

$$Df(X)[H] = \text{tr}(A^T H), \quad \nabla_X f = A.$$

再取

$$H = \begin{bmatrix} 1 & -2 \\ 0 & 1 \end{bmatrix}.$$

方向導數為

$$Df(X)[H] = 1 \cdot 1 + 2 \cdot (-2) + (-1) \cdot 0 + 3 \cdot 1 = 0.$$

這個方向與 A 在 Frobenius 內積下正交。方向導數為零不表示梯度為零；梯度仍是 A ，而且與 X 同為 2×2 。

例題二：矩形最小平方目標

令

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad X = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix}, \quad F(X) = \frac{1}{2} \|AX - B\|_F^2.$$

A 為 3×2 ， X 為 2×1 ， B 為 3×1 ，故殘差 R 是 3×1 。直接相乘得到

$$AX = \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix}, \quad R = AX - B = \begin{bmatrix} -1 \\ -2 \\ -1 \end{bmatrix}.$$

因此

$$F(X) = \frac{1}{2}(1 + 4 + 1) = 3.$$

由一般公式，

$$\nabla_X F = A^T R = \begin{bmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \end{bmatrix} \begin{bmatrix} -1 \\ -2 \\ -1 \end{bmatrix} = \begin{bmatrix} -2 \\ -4 \end{bmatrix}.$$

梯度是 2×1 ，與 X 同形狀。取 $H = (1, 1)^T$ ，則

$$DF(X)[H] = \langle \nabla_X F, H \rangle_F = -2 - 4 = -6.$$

也可將目標沿此方向展開：

$$F(X + tH) = \frac{1}{2} \|R + tAH\|_2^2.$$

其中 $R^T AH = (A^T R)^T H = -6$ ，所以 t 的線性係數為 -6 ，與方向導數相符。這是代數核對，不依賴選定有限差分步長。

實作與程式

以下實作使用 Python 標準函式庫，不依賴 NumPy 或 SciPy。矩陣以巢狀列表表示，程式會檢查矩形形狀與矩陣乘法的內維度，避免形狀錯誤被廣播或不明確的運算掩蓋。程式包含轉置、矩陣乘法、加減、Frobenius 內積、最小平方目標與解析梯度，也用中心有限差分核對指定方向。

方向差分是數值診斷，不是定理證明。它有有限步長，並受到浮點捨入影響。本文未執行程式，因此下方測試均以預期結果敘述，不宣稱已通過。

```

def shape(A):
    if not isinstance(A, list) or not A:
        raise ValueError("矩陣必須是非空列表")
    if not all(isinstance(row, list) for row in A):
        raise ValueError("矩陣每一橫列必須是列表")
    width = len(A[0])
    if width == 0 or any(len(row) != width for row in A):
        raise ValueError("矩陣必須是非空矩形")
    return len(A), width

def transpose(A):
    rows, cols = shape(A)
    return [[A[i][j] for i in range(rows)] for j in range(cols)]

def matmul(A, B):
    m, n = shape(A)
    n2, p = shape(B)
    if n != n2:
        raise ValueError("矩陣乘法內維度不相容")
    return [
        [sum(A[i][k] * B[k][j] for k in range(n))
         for j in range(p)]
        for i in range(m)
    ]

def subtract(A, B):
    if shape(A) != shape(B):
        raise ValueError("相減矩陣形狀必須相同")
    return [
        [A[i][j] - B[i][j] for j in range(len(A[0]))]
        for i in range(len(A))
    ]

def add(A, B):
    if shape(A) != shape(B):
        raise ValueError("相加矩陣形狀必須相同")
    return [
        [A[i][j] + B[i][j] for j in range(len(A[0]))]
        for i in range(len(A))
    ]

def scale(c, A):
    shape(A)
    return [[c * value for value in row] for row in A]

def frobenius_inner(A, B):
    if shape(A) != shape(B):
        raise ValueError("Frobenius 內積要求矩陣形狀相同")
    return sum(
        A[i][j] * B[i][j]
        for i in range(len(A))
        for j in range(len(A[0]))
    )

```

```

)

def least_squares(A, X, B):
    if shape(A)[0] != shape(B)[0]:
        raise ValueError("A 和 B 必須有相同列數")
    residual = subtract(matmul(A, X), B)
    value = 0.5 * frobenius_inner(residual, residual)
    gradient = matmul(transpose(A), residual)
    return value, gradient, residual

def directional_finite_difference(A, X, B, H, step):
    plus = add(X, scale(step, H))
    minus = add(X, scale(-step, H))
    f_plus = least_squares(A, plus, B)[0]
    f_minus = least_squares(A, minus, B)[0]
    return (f_plus - f_minus) / (2.0 * step)

def run_checks():
    A = [[1.0, 2.0], [0.0, 1.0], [1.0, 0.0]]
    X = [[1.0], [-1.0]]
    B = [[0.0], [1.0], [2.0]]
    H = [[1.0], [1.0]]

    value, gradient, residual = least_squares(A, X, B)
    assert shape(residual) == (3, 1)
    assert shape(gradient) == (2, 1)
    assert abs(value - 3.0) < 1e-12
    assert gradient == [[-2.0], [-4.0]]

    exact_direction = frobenius_inner(gradient, H)
    fd = directional_finite_difference(A, X, B, H, 1e-5)
    assert abs(exact_direction + 6.0) < 1e-12
    assert abs(fd - exact_direction) < 1e-8

    # 邊界案例：殘差為零時，目標與梯度都應為零。
    B_exact = matmul(A, X)
    value0, gradient0, _ = least_squares(A, X, B_exact)
    assert value0 == 0.0
    assert all(abs(v) < 1e-12 for row in gradient0 for v in row)

    # 故障案例：不相容的轉置形狀應被明確拒絕。
    transpose_rejected = False
    try:
        least_squares(A, transpose(X), B)
    except ValueError:
        transpose_rejected = True
    assert transpose_rejected

    # 故障案例：不同形狀不能直接作 Frobenius 內積。
    inner_shape_rejected = False
    try:
        frobenius_inner([[1.0, 2.0]], [[1.0], [2.0]])
    except ValueError:
        inner_shape_rejected = True
    assert inner_shape_rejected

```

```

return value, gradient, exact_direction, fd

if __name__ == "__main__":
    print(run_checks())

```

若照預期執行，正常案例的目標值為 3、梯度為 $\begin{bmatrix} -2 \\ -4 \end{bmatrix}$ ，解析方向導數為 -6 ，中心有限差分應在浮點誤差範圍內接近 -6 。邊界案例令 $B = AX$ ，因此殘差與目標值為零，梯度也為零。故障案例應因形狀不相容而觸發 *ValueError*，且檢查旗標應為真。這些是預期結果，並非實際執行紀錄。

測試與預期結果

測試分為正常、邊界與故障三類，避免只檢查一個典型輸入。

類別	測試	預期
正常	用矩形 A 、 X 、 B 計算解析梯度，並與指定方向的中心差分比較	殘差為 3×1 ，梯度為 2×1 ；方向導數核對接近 -6
邊界	設 $B = AX$ ，使殘差為零	目標值與梯度皆為零
故障	把 X 轉置後輸入，或以不同形狀矩陣計算 Frobenius 內積	明確拒絕不相容形狀，不進行隱式廣播

若改變差分步長，誤差可能先因截斷誤差下降而減小，之後又受捨入誤差影響而增加。這是一般數值分析上的可能現象，不是本程式已測得的收斂曲線。單一步長的吻合只是一項有限精度證據；解析展開才是本章梯度公式的數學依據。

反例與常見陷阱

把矩陣微分當成沒有形狀的符號。 在 $A \in \mathbb{R}^{m \times n}$ 、 $X \in \mathbb{R}^{n \times p}$ 的最小平方目標中，梯度必須是 $n \times p$ 。把 $A^T R$ 寫成 RA^T ，即使某些尺寸剛好可以相乘，也不表示該式是 X 的梯度。每個中間結果都應標註形狀，而不能只靠「看起來有那些因子」判斷。

混淆梯度和微分。 $Df(X)$ 是將擾動 H 映到純量的一個線性泛函； $\nabla_X f$ 則是在指定 Frobenius 內積下代表這個泛函的矩陣。換用加權內積時，線性泛函不變，代表矩陣卻可能改變。因此梯度不只取決於函數，也取決於採用的內積慣例。

任意移動轉置或循環移位。 跡有循環性，但矩陣乘法沒有交換律。每次移動因子都應確認跡的乘積仍有定義，並檢查最後是否確實得到 $\text{tr}(G^T dX)$ 。若略去這些檢查，錯誤轉置有時會立刻造成維度不合，有時則會在方陣案例中悄悄留下錯誤數值。

把程式廣播當成數學上的對齊。 程式庫可能自動擴展形狀，例如把 $(n, 1)$ 和 $(n,)$ 的陣列組合成二維結果。這種行為不一定對應所要的矩陣乘法或 Frobenius 內積。尤其 NumPy 的一維陣列形狀是 $(n,)$ ，對它使用 `.T` 不會變成 $(1, n)$ 。若要明確表示直向量與橫列，應使用 $(n, 1)$ 與 $(1, n)$ 。

忽略單位和權重。 未加權 Frobenius 範數把每個分量的數值誤差等權計入。若矩陣包含不同物理單位或不同可靠度的資料，這代表一項需要說明的建模選擇，而不是自然成立的物理比較。可先將輸入與輸出按記錄的尺度無因次化，或在目標函數中明列權重，再重新推導梯度。不能直接把混合單位分量的 Euclidean 長度解釋成單一物理量。

AI、幾何與養殖案例

合成感測校準。 設一個線性模型以 $X \in \mathbb{R}^{2 \times 2}$ 描述兩組感測輸出對兩個無因次校準特徵的響應； $A \in \mathbb{R}^{m \times 2}$ 收集 m 筆合成設計資料， $B \in \mathbb{R}^{m \times 2}$ 是相應的合成量測摘要。殘差 $AX - B$ 的第 (i, j) 個元素，是第 i 筆合成資料中第 j 個輸出的無因次誤差。目標

$$F(X) = \frac{1}{2} \|AX - B\|_F^2$$

把各個分量的平方誤差相加，而其梯度為 $A^T(AX - B)$ 。梯度元素表示目標對相應參數元素的一階敏感度；它不是感測器輸出本身，也不自動代表可直接操作的調整量。

若原始輸入是以 SI 單位量測的溫度差、溶氧差或流速差，必須記錄各分量的單位與尺度。把不同單位的數值直接當作同尺度座標，會使距離與最小平方目標隱含不透明的權重。將輸入、輸出按明確尺度無因次化後，應保留尺度，以便把校準結果轉回物理量；Jacobian 元素的單位則是相應輸出單位除以輸入單位。無因次化能澄清尺度選擇，卻不代表模型已由現場資料驗證。

AI 輔助推導。 文字生成工具可以協助整理跡式或提出形狀檢查清單，但輸出的轉置和乘法次序仍須逐步核對。可稽核的檢查包括輸入、殘差、梯度的尺寸，從 dF 整理到 $\text{tr}(G^T dX)$ 的每一步，以及至少一個方向導數核對。數值吻合可以協助找錯，不能證明對所有矩陣擾動都成立。

養殖情境的資料與參數皆為合成案例。數學上的擬合不等於現場驗證，也不等於操作安全。分析 agent 可唯讀整理假設、單位與推導證據，不應據此改變設備、投餌或加藥。

習題

習題一：手算梯度與方向導數

令

$$F(X) = \frac{1}{2} \|AX - B\|_F^2, \quad A = \begin{bmatrix} 1 & -1 \\ 2 & 0 \\ 0 & 1 \end{bmatrix}, \quad X = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}.$$

求殘差、函數值與梯度。再取 $H = (2, -1)^T$ ，求方向導數，並用 $F(X + tH)$ 的線性項核對。

習題二：矩陣鏈式法則與轉置

設 $X \in \mathbb{R}^{2 \times 2}$ 、 $Y = 2XC$ ，其中

$$C = \begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix}, \quad f(Y) = \frac{1}{2} \|Y - D\|_F^2, \quad D = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}.$$

求 $\nabla_X f$ ，說明各矩陣形狀，並以微分與跡式推導。

習題三：有限測試能否證明梯度

有人主張：「對若干個測試方向 $H_1, \dots, H_k$ ，方向差分都接近 $\langle G, H_i \rangle_F$ ，所以 G 已被證明是梯度。」此推論是否成立？說明有限方向測試能支持的結論，並描述一種可使有限測試吻合、但仍不足以證明可微的反例構造思路。

習題四：程式測試與證據標示

提出兩項最小平方實作測試：一項檢查解析梯度與方向差分，一項檢查形狀錯誤是否明確失敗。若沒有實際執行程式，應如何描述預期結果，才不會把預期當成測試證據？

習題解答

解答一

殘差為

$$R = AX - B = \begin{bmatrix} 1 & -1 \\ 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}.$$

因此 $F(X) = \frac{1}{2}(1 + 1 + 1) = \frac{3}{2}$ ，而

$$\nabla_X F = A^T R = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

方向導數為

$$DF(X)[H] = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = 0.$$

又 $AH = (3, 4, -1)^T$ ，所以

$$F(X + tH) = \frac{1}{2} \|R + tAH\|_2^2 = \frac{1}{2} (\|R\|_2^2 + 2tR^T AH + t^2 \|AH\|_2^2).$$

其中 $R^T AH = -3 + 4 - 1 = 0$ ，故線性項為零，與方向導數相符。二次項為 $13t^2$ ，不影響 $t = 0$ 的一階導數。

解答二

令 $R = Y - D = 2XC - D$ ，則

$$dR = 2(dX)C, \quad df = \text{tr}(R^T dR) = 2 \text{tr}(R^T (dX)C).$$

循環移位並整理成與 dX 的 Frobenius 內積：

$$\begin{aligned} df &= 2 \text{tr}(CR^T dX) \\ &= \text{tr}((2RC^T)^T dX). \end{aligned}$$

所以

$$\nabla_X f = 2RC^T = 2(2XC - D)C^T.$$

X, C, D, R 都是 2×2 ，而 dX 與梯度亦為 2×2 。 C^T 不能省略；它是跡式整理與梯度表示共同決定的。

解答三

推論不成立。有限方向只測試有限多個矩陣擾動，沒有檢查所有趨近零的方向，也沒有證明餘項相對於 $\|H\|_F$ 趨零。可以構造一個函數，使它在有限個已測方向上與候選線性近似一致，卻在未測方向或某條曲線路徑上有不符合該線性近似的變化。這說明有限測試吻合不等於 Fréchet 可微。若某個測試方向明顯不吻合，則能否定該輸入與方向下的實作主張；若測試吻合，只能說目前測試沒有發現錯誤。

解答四

正常測試可選尺寸相容的 A, X, B, H ，用 $G = A^T(AX - B)$ 求解析方向導數 $\langle G, H \rangle_F$ ，再和中心差分比較。若未執行，應寫明「預期中心差分在浮點誤差範圍內接近解析值」，不能寫成「測試已通過」，也不能編造誤差數字。

故障測試可將 X 改成與 A 內維度不相容的形狀，或對形狀不同的矩陣呼叫 Frobenius 內積函式。預期程式明確拒絕輸入。沒有執行時，只能交代測試設計、預期錯誤路徑與判斷理由，不能聲稱實際觀察到特定例外。這些測試檢查程式的防護，不取代解析推導。

本章小結

矩陣微分將矩陣擾動映射到函數的一階變化。Fréchet 可微要求線性近似餘項相對於 $\|H\|_F$ 趨於零。在 Frobenius 內積下，任意有限維矩陣空間上的線性泛函可唯一表示為 $\text{tr}(G^T H)$ ；因此，純量函數的 Frobenius 梯度 G 與變數 X 同形狀。

對半平方殘差目標 $\frac{1}{2}\|AX - B\|_F^2$ ，微分為 $\text{tr}((AX - B)^T A dX)$ ，梯度則是 $A^T(AX - B)$ 。矩陣鏈式法則可由方向微分與伴隨映射推導；轉置的位置應由跡運算和尺寸檢查決定。

解析推導、形狀檢查與方向差分的作用不同：推導提供數學依據，形狀檢查排除不相容運算，差分則協助發現實作錯誤。有限次數值測試不是微分極限的證明。遇到實際資料時，還要記錄單位、尺度與目標函數中的權重，避免把未加權的數值長度誤解為物理上可直接比較的距離。

參考來源

1. Jiří Lebl, *Basic Analysis*, 作者教材入口。 <https://www.jirka.org/ra/>
2. MIT OpenCourseWare, *18.02SC Multivariable Calculus*。 <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
3. JAX 文件, *Autodiff Cookbook: JVP and VJP*, 作為方向推送與伴隨拉回的延伸參考。
https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html

本章推導以有限維 Frobenius 內積、矩陣代數及 Fréchet 微分定義為基礎。外部資源提供延伸閱讀，不代表已逐條核查教材全文。程式未執行，測試結果均以預期方式標示。

第11章 反函數定理與局部可逆

學習目標與先備知識

本章要把「一個 C^1 映射的局部行為，可以由其 Jacobian 這個線性映射來決定」說清楚。這條線路的中心結果是反函數定理：只要 Jacobian 在某點可逆， f 在該點的某個鄰域上就是可逆的，且逆映射仍然 C^1 。這個結論看似自然，卻牽涉三個必須分開處理的層次：可逆 Jacobian 只提供**局部**資訊、局部可逆不保證**全域**一對一、以及「可逆 Jacobian 只是 C^1 局部可逆的**充分**條件而非必要條件」。本章把這三層界線逐一寫明，並給出可以手算、可以寫成 CPU 程式、可以拿極端輸入測試的實例。

先備知識方面，讀者需要：第7章 Fréchet 導數的餘項定義 $f(x+h) = f(x) + J_f(x)h + r(h)$ 且 $\|r(h)\|/\|h\| \rightarrow 0$ ；第8章 Jacobian 的形狀 $J_f(x) \in \mathbb{R}^{m \times n}$ 與偏導的關係；第3章的算子範數、有限維範數等價與收縮映射；以及 Volume I 的矩陣可逆、行列式與條件數。若某一步引用到「壓縮映射原理」或「 C^1 下 Jacobian 範數的局部控制」，本節會明確標示引用來源，而不以有限次計算取代證明。

問題與直覺

假設 $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 在 a 處可微，且 $\varphi'(a) \neq 0$ 。單變量微積分告訴我們 φ 在 a 的某鄰域上嚴格單調，因而局部有反函數，且反函數導數為 $1/\varphi'$ 。把這個事實推到 $f: U \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$ ：若 $J_f(a)$ 可逆，是否可以期待 f 在 a 附近可逆？答案是肯定的，這就是反函數定理。但「附近」到底多大？由什麼決定？是否全空間都保持一一對應？ $J_f(a)$ 可逆是否也是**必要**條件？

直覺上， $J_f(a)$ 是 f 在 a 處的最佳線性近似。線性映射可逆代表「在 a 附近沒有方向被壓扁」。若某方向被壓扁， f 會把不同 h 映到幾乎相同的位置，局部就無法一一對應。反之，若每個方向都被保留， f 在足夠小的尺度上仍能維持一一對應。這個圖像可以透過把 f 寫成 $A + \phi$ （其中 $A = J_f(a)$ 可逆、 ϕ 在 a 附近是導數為零的小擾動）而化為一個收縮映射問題——這是本章證明的核心想法。

需要強調的兩個限制。第一，局部可逆不等於全域一對一：極座標映射 $F(r, \theta) = (r \cos \theta, r \sin \theta)$ 在 $r > 0$ 上到處 Jacobian 行列式為 $r \neq 0$ ，但它周期性重複 θ ，不是全域一對一。第二，可逆 Jacobian 是可逆的充分條件，不是必要條件： $f(x) = x^3$ 在全域是雙射，但 $f'(0) = 0$ ，逆映射在 0 處不可微，因此它不可能是 C^1 微分同胚。這兩點在手算與程式測試中會反覆出現。

定義、定理與推導

定義 11.1 (局部微分同胚) 設 $U \subset \mathbb{R}^n$ 為開集， $f: U \rightarrow \mathbb{R}^n$ 。若存在 $a \in U$ 、 a 的開鄰域 $V \subset U$ 、 $f(a)$ 的開鄰域 $W \subset \mathbb{R}^n$ ，使得 $f|_V: V \rightarrow W$ 是雙射，且其逆 $g: W \rightarrow V$ 亦為 C^1 ，則稱 f 在 a 處是**局部 C^1 微分同胚**。

定義 11.2 (可逆 Jacobian) 對 f 在 a 處的 Jacobian $J_f(a) \in \mathbb{R}^{n \times n}$ ，若 $\det J_f(a) \neq 0$ ，就說 Jacobian 在 a 處可逆；此時 $J_f(a)$ 作為線性映射 $\mathbb{R}^n \rightarrow \mathbb{R}^n$ 是雙射。

定理 11.3 (反函數定理, C^1 版本) 設 $U \subset \mathbb{R}^n$ 為開集, $f: U \rightarrow \mathbb{R}^n$ 在 U 上 C^1 , $a \in U$ 且 $J_f(a)$ 可逆。則：

1. 存在 a 的開鄰域 $V \subset U$ 與 $f(a)$ 的開鄰域 W , 使得 $f|_V: V \rightarrow W$ 為雙射, 故 f 在 a 處是局部 C^1 微分同胚。
2. 記 $g = (f|_V)^{-1}$, 則 g 在 W 上 C^1 , 且對每個 $y \in W$,

$$J_g(y) = [J_f(g(y))]^{-1}. \quad (11.1)$$

定理條件與正則性： f 必須在 a 的整個鄰域 C^1 , 只在一點可微並不足以讓收縮映射常數在附近受到控制。 $J_f(a)$ 可逆是充分條件, 不是必要條件。當 $J_f(a)$ 奇異時, 定理不提供局部可逆的保證, 也不排除局部可逆, 須另作分析。

證明：以下給出存在性與逆映射微分公式的完整證明。為使符號清楚, 記 $A = J_f(a)$ 、 $L = A^{-1}$ 。

自 f 在 a 處可微, $f(x) = f(a) + A(x - a) + r(x - a)$ 且 $\|r(h)\|/\|h\| \rightarrow 0$ ($h \rightarrow 0$); C^1 條件進一步保證 $x \mapsto J_f(x)$ 在 a 附近連續。構造 $T: U \rightarrow \mathbb{R}^n$:

$$T(x) = x - L(f(x) - f(a)). \quad (11.2)$$

則 $T(a) = a$ 且 $J_T(a) = I - LJ_f(a) = I - I = 0$ 。由 $J_T(x) = I - LJ_f(x)$ 在 a 的連續性, 取 $\varepsilon > 0$ 使對所有 $\|x - a\| \leq \varepsilon$ 有 $\|J_T(x)\| \leq \frac{1}{2}$ (使用固定的一個向量範數及其誘導算子範數)。於是對 $\|x - a\|, \|x' - a\| \leq \varepsilon$, 由均值不等式 (本卷 Ch.6 引用; 多變量向量值函數的版本記為 $\|T(x) - T(x')\| \leq \sup_{\theta \in [0,1]} \|J_T(x + \theta(x' - x))\| \|x - x'\|$):

$$\|T(x) - T(x')\| \leq \frac{1}{2}\|x - x'\|. \quad (11.3)$$

特別地 $\|T(x) - a\| = \|T(x) - T(a)\| \leq \frac{1}{2}\|x - a\| \leq \frac{1}{2}\varepsilon$, 故 T 把 $\overline{B}(a, \varepsilon)$ 映入 $\overline{B}(a, \frac{1}{2}\varepsilon)$ 。

對固定的 $y \in \mathbb{R}^n$, 定義

$$T_y(x) = x - L(f(x) - y) = T(x) + L(y - f(a)). \quad (11.4)$$

對 $\|x - a\| \leq \varepsilon$:

$$\|T_y(x) - a\| \leq \frac{1}{2}\varepsilon + \|L\| \|y - f(a)\|. \quad (11.5)$$

取 $\delta = \varepsilon/(2\|L\|)$ (若 $\|L\| = 0$ 則不可能, 因 L 可逆), 則對 $\|y - f(a)\| \leq \delta$ 有 $\|T_y(x) - a\| \leq \varepsilon$, 即 T_y 映 $\overline{B}(a, \varepsilon)$ 入自身; 又由 (11.3), T_y 為 $\frac{1}{2}$ -Lipschitz。由壓縮映射原理 (本卷 Ch.3 引用), T_y 在 $\overline{B}(a, \varepsilon)$ 上有唯一固定點 x_y , 滿足 $T_y(x_y) = x_y$, 即 $f(x_y) = y$ 。取 $V = B(a, \varepsilon)$ 、 $W = f(V)$, 則 $f|_V$ 為滿射到 W 。

單射性：若 $f(x) = f(x')$ ， $x, x' \in V$ ，由 (11.2) 得 $T(x) - T(x') = x - x'$ ，配合 (11.3) 即有 $\|x - x'\| = \|T(x) - T(x')\| \leq \frac{1}{2}\|x - x'\|$ ，故 $x = x'$ 。又 (11.5) 顯示 $B(f(a), \delta) \subset W$ ，因此 W 是 $f(a)$ 的開鄰域（ $W = f(V)$ 為開集，因 V 開且 f 為開映射——此開映射性可由上式對 y 的小鄰域討論得到，此處直接採用 $B(f(a), \delta) \subset W$ 作為鄰域存在性的依據）。

逆映射的可微性：記 $g: W \rightarrow V$ 為逆映射。對 $y \in W$ 、 $y + \ell \in W$ ，寫 $x = g(y)$ 、 $x + k = g(y + \ell)$ 。由 f 在 x 處可微：

$$\ell = f(x + k) - f(x) = J_f(x)k + r(k), \quad \frac{\|r(k)\|}{\|k\|} \rightarrow 0.$$

上式中 $k \neq 0$ 對應 $\ell \neq 0$ （ g 為單射）。又由 (11.4) 得 $\|k\| \leq 2\|L\|\|\ell\|$ （因 $T_y(x + k) - T_y(x) = k - L\ell$ ，配合 $\frac{1}{2}$ -Lipschitz 即得），故 $k \rightarrow 0 \iff \ell \rightarrow 0$ 。整理：

$$k = J_f(x)^{-1}\ell - J_f(x)^{-1}r(k).$$

於是

$$\frac{\|g(y + \ell) - g(y) - J_f(x)^{-1}\ell\|}{\|\ell\|} \leq \|J_f(x)^{-1}\| \cdot \frac{\|r(k)\|}{\|k\|} \cdot \frac{\|k\|}{\|\ell\|} \leq 2\|L\| \|J_f(x)^{-1}\| \cdot \frac{\|r(k)\|}{\|k\|} \xrightarrow{\ell \rightarrow 0} 0.$$

因此 g 在 y 處可微且 $J_g(y) = J_f(g(y))^{-1}$ 。由 g 連續、 J_f 連續、矩陣求逆在 GL_n 上連續， $y \mapsto J_g(y)$ 連續，故 $g \in C^1$ 。證畢。□

命題 11.4（充分非必要） 定理 11.3 中「 $J_f(a)$ 可逆」是 f 在 a 局部 C^1 微分同胚的充分條件，但不是必要條件。

證明：取 $f(x) = x^3$ ， $a = 0$ 。 f 在 $\mathbb{R}$ 上嚴格遞增且為雙射，反函數 $g(y) = y^{1/3}$ 存在且連續，故 f 在 0 是局部（其實全域）雙射。但 $J_f(0) = 0$ 不可逆，且 $g'(0)$ 不存在（ g 在 0 處不可微），故 f 不是 C^1 微分同胚。若命題斷言「必要」，就會得出矛盾。□

命題 11.4 給出一個重要的操作原則：當 $J_f(a)$ 奇異時，反函數定理不適用，但不可據此否定局部可逆。實務上必須另以直接分析（例如代數求解、對稱性或單調性論證）判斷。

逐步手算例題

手算例 11.A 設 $f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ， $f(x, y) = (x^2 - y^2, 2xy)$ （即複數映射 $z \mapsto z^2$ 的實形式）。求 f 在哪些點局部可逆，並判斷它是否全域一對一。

先寫 Jacobian：

$$J_f(x, y) = \begin{pmatrix} \partial_x(x^2 - y^2) & \partial_y(x^2 - y^2) \\ \partial_x(2xy) & \partial_y(2xy) \end{pmatrix} = \begin{pmatrix} 2x & -2y \\ 2y & 2x \end{pmatrix}.$$

行列式 $\det J_f(x, y) = 4x^2 + 4y^2 = 4(x^2 + y^2)$ 。因此 J_f 在除原點之外的任何點都可逆。由定理 11.3， f 在每個 $(x, y) \neq (0, 0)$ 附近是局部 C^1 微分同胚。

另一方面，對任意 (x, y) ：

$$f(-x, -y) = ((-x)^2 - (-y)^2, 2(-x)(-y)) = (x^2 - y^2, 2xy) = f(x, y).$$

所以 $f(x, y) = f(-x, -y)$ ，除原點外並非一對一，更不是全域微分同胚。這正是「局部可逆不等於全域一對一」的最小二維實例，也是本節核心的示範。

在 $a = (1, 1)$ 處， $J_f(1, 1) = \begin{pmatrix} 2 & -2 \\ 2 & 2 \end{pmatrix}$ 。由 (11.1)，局部逆的 Jacobian 為

$$J_g(f(1, 1)) = [J_f(1, 1)]^{-1} = \frac{1}{8} \begin{pmatrix} 2 & 2 \\ -2 & 2 \end{pmatrix} = \begin{pmatrix} \frac{1}{4} & \frac{1}{4} \\ -\frac{1}{4} & \frac{1}{4} \end{pmatrix}.$$

其 Frobenius 範數為 $\sqrt{4 \cdot \frac{1}{16}} = \frac{1}{2}$ 。檢查條件數： $J_f(1, 1)^T J_f(1, 1) = \begin{pmatrix} 8 & 0 \\ 0 & 8 \end{pmatrix}$ ，兩個奇異值都是 $\sqrt{8}$ ，故 $\kappa_2(J_f(1, 1)) = 1$ 。這正是「 $J_f(1, 1) = \sqrt{8}Q$ 、 Q 為正交矩陣」的直接後果：純旋轉縮放映射的條件數為 1。因此該點附近是「數值上最良性」的可逆情形。

手算例 11.B 設 $f(x, y) = (x + y^2, y + x^2)$ 在 $a = (0, 0)$ 附近。計算 Jacobian，判定局部可逆性，並在給定 $y^* = (0.5, 0.5)$ 處用手算牛頓一次迭代估計解。

Jacobian：

$$J_f(x, y) = \begin{pmatrix} 1 & 2y \\ 2x & 1 \end{pmatrix}, \quad J_f(0, 0) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I.$$

故 $\det J_f(0, 0) = 1 \neq 0$ ， f 在 0 附近局部 C^1 微分同胚。

設想要求 $f(x, y) = (0.5, 0.5)$ 的解，以 $x_0 = (0, 0)$ 為初值。牛頓迭代為 $x_{k+1} = x_k - \Delta_k$ ，其中 $J_f(x_k)\Delta_k = f(x_k) - y^*$ （**不顯式求逆**，用線性解算）。第一步： $f(0, 0) = (0, 0)$ ，殘差 $r_0 = (-0.5, -0.5)$ ， $J_f(0, 0) = I$ ，得 $\Delta_0 = (-0.5, -0.5)$ ，故 $x_1 = (0.5, 0.5)$ 。檢核： $f(0.5, 0.5) = (0.5 + 0.25, 0.5 + 0.25) = (0.75, 0.75) \neq (0.5, 0.5)$ ，殘差 $\|r_1\|_2 = \sqrt{2} \cdot 0.25 \approx 0.354$ 。

第二步： $J_f(0.5, 0.5) = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ 是奇異的！這正是本手算例的關鍵示警：牛頓迭代在非奇異點 $a = (0, 0)$

附近的第一步仍然可以跨出原點後落入 J_f 奇異的位置。此時從 x_1 繼續進行標準牛頓須先處理奇異 Jacobian（本章實作會有偵測與容錯）。這說明「 $J_f(a)$ 可逆」是**局部**條件；一旦步長越出可逆區域，方法的合法性就不再由定理 11.3 保證。若以阻尼或更具限制性的初值（例如以 $x_0 = 0$ 並縮小步長至 0.1 級別），可以得到收斂，但這須另作分析。手算至此停止以保留定理與數值的邊界。

實作與程式

以下程式使用 Python 標準庫與 NumPy（小型 CPU，可選用 SciPy 但不必要）。Newton 求逆一律以 `np.linalg.solve` 解線性方程，避免任何顯式求逆；程式同時記錄殘差、步長、Jacobian 的可逆性標記。若實際執行環境沒有 NumPy，可將 `np.linalg.solve` 換成自行撰寫的高斯消去，但依課程契約，本節程式核心依賴 NumPy，不在本章重新實作線性代數。

```
import numpy as np

def f(x):
    # f: R^2 -> R^2, x shape (2,)
    return np.array([x[0] + x[1]**2, x[1] + x[0]**2], dtype=float)

def J(x):
    # Jacobian matrix J_f(x), shape (2,2)
    return np.array([[1.0, 2.0*x[1]],
                    [2.0*x[0], 1.0]], dtype=float)

def newton_inverse(y, x0, tol=1e-12, maxit=60, tiny=1e-14):
    """
    Solve f(x) = y from initial guess x0.
    Never forms an explicit inverse; uses np.linalg.solve.
    Returns (x, history, status).
    status: 'converged' | 'singular' | 'no_progress'
    history: list of dict(k, x, res, step, jac_det)
    """
    x = np.array(x0, dtype=float)
    history = []
    for k in range(maxit):
        r = f(x) - y
        nrm_r = float(np.linalg.norm(r, 2))
        Jx = J(x)
        det_Jx = float(np.linalg.det(Jx))
        rec = {"k": k, "x": x.copy(), "res": nrm_r, "jac_det": det_Jx}
        if nrm_r < tol:
            history.append(rec)
            return x, history, "converged"
        scale = max(1.0, float(np.linalg.norm(Jx, 2)))
        if abs(det_Jx) < tiny * scale * scale:
            history.append(rec)
            return x, history, "singular"
        try:
            delta = np.linalg.solve(Jx, r)
        except np.linalg.LinAlgError:
            history.append(rec)
            return x, history, "singular"
        step_norm = float(np.linalg.norm(delta, 2))
        rec["step"] = step_norm
        history.append(rec)
        x = x - delta
        if step_norm < tol * max(1.0, float(np.linalg.norm(x, 2))):
            # 步長太小，檢查殘差後停止
            r2 = f(x) - y
            history.append({"k": k+1, "x": x.copy(),
                          "res": float(np.linalg.norm(r2, 2)),
                          "jac_det": float(np.linalg.det(J(x)))})
```



```

        if float(np.linalg.norm(r2, 2)) < tol:
            return x, history, "converged"
        return x, history, "no_progress"
    return x, history, "no_progress"

# 正常情境
y_target = f(np.array([0.3, -0.4]))
x_sol, hist, st = newton_inverse(y_target, x0=[0.35, -0.35])
print("status:", st)
print("x_sol:", x_sol)
print("residual:", float(np.linalg.norm(f(x_sol) - y_target, 2)))

```

程式設計要點：

- `np.linalg.solve(Jx, r)` 解 $J_f(x_k)\Delta_k = f(x_k) - y$ ，再令 $x_{k+1} = x_k - \Delta_k$ 。從未對 J_f 取逆。
- 記錄 `jac_det`：奇異 Jacobian 是定理 11.3 不允許的情境，程式必須偵測。
- `tiny=1e-14` 的判斷使用相對尺度 `scale = max(1, ||J||_2)`，避免尺度依賴。真正的生產環境應改用最小奇異值或條件數判準；本章以 `det` 為教學示範。
- 步長停機條件 `step_norm < tol*max(1, ||x||_2)` 是相對步長檢查；若步長收斂而殘差未收斂，回報 `no_progress` 而不硬說收斂。

測試與預期結果

以下以預期輸出方式陳述；未在本環境執行，因此所有數值為**預期值**，讀者執行時可能因機器精度稍有差異。

正常測試 (Normal)：以上面程式呼叫， $y^* = f(0.3, -0.4) = (0.3 + 0.16, -0.4 + 0.09) = (0.46, -0.31)$ 。初值 $x_0 = (0.35, -0.35)$ 。預期 `status=="converged"`， $x_{\text{sol}} \approx (0.3, -0.4)$ ，殘差 $\|f(x_{\text{sol}}) - y^*\|_2 < 10^{-12}$ ，迭代步數 ≤ 8 。`jac_det` 在收斂點的期望值為 $\det J_f(0.3, -0.4) = 1 - 4 \cdot 0.3 \cdot (-0.4) = 1.48$ ，符號為正。

邊界測試 (Boundary)：取 $y^* = f(0, 0) = (0, 0)$ 、 $x_0 = (0, 0)$ 。預期第一次殘差 $= 0 < 10^{-12}$ ，即刻回報 `converged`，歷史長度為 1。另一邊界：取初值 $x_0 = (0.5, 0.5)$ ，此處 $J_f(0.5, 0.5) = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ ， $\det = 0$ 。預期程式在第一次迭代前 `jac_det` 判為奇異，回報 `status=="singular"`，並以 `res` 給出當前殘差；這是重要邊界，因為它是「 f 未必真的無解、只是當前 Jacobian 奇異」。

故障測試 (Failure)：設定 `maxit=2` 而初值離解很遠，例如 $y^* = (5, 5)$ 、 $x_0 = (2, 2)$ 。預期 `status=="no_progress"`；同時前兩步的殘差未必單調下降，這是牛頓法在非凸路徑上的正常行為。若把 `tol` 設為 10^{-30} （不可達成），預期尾端落入 `no_progress`，而不應無限迭代。

奇異點反例測試：呼叫 `newton_inverse(y=f(0,0), x0=[5e-9, 5e-9])`。此時 J_f 的 $\det$ 約為 $4(x^2 + y^2) \approx 2 \times 10^{-16}$ ，與 10^{-14} 的量級相比已相當接近；因 `scale` 為 1 級，`abs(det_Jx) < 1e-14` 為真，判為 `singular`。這示範了原點附近 Jacobian 的條件數爆炸會如何讓「看似可解」的問題在數值上崩潰。

反例與常見陷阱

反例 11.1 (局部可逆卻非全域一對一) 例 11.A 的 $f(x, y) = (x^2 - y^2, 2xy)$ ；局部可逆但 $f(x, y) = f(-x, -y)$ 。

反例 11.2 (可逆 Jacobian 非必要) $f(x) = x^3$ 在 0 處 $f'(0) = 0$ ，卻為全域雙射，只是其逆在 0 處不可微。故定理 11.3 的假設不能反向使用。

反例 11.3 (多分支反函數) $f(x, y) = (e^x \cos y, e^x \sin y)$ 。 $\det J_f(x, y) = e^{2x} > 0$ ，故處處局部可逆。但 $y \mapsto y + 2\pi$ 不改變 f ，全域非一對一；局部反函數是多值分支（主值分支需人工限制 θ 範圍），這正是「局部」二字的操作意義。

常見陷阱：(1) 用 $\det J_f(a) \neq 0$ 斷言 f 全域可逆。(2) 用「在某鄰域 $J_f \neq 0$ 」代替「在 a 的鄰域 C^1 」，忽略 C^1 在證明中用於控制 $\|J_T\|$ 的必要性。(3) 誤以為在 $J_f(a)$ 奇異時 f 就無解或不能局部求逆： x^3 即是反例。(4) 用有限次牛頓迭代替換定理存在性的論證，這在離散數值上是檢查，不是存在性證明。

AI、幾何與養殖案例

幾何層面：反函數定理是「座標變換」的基礎。要在 a 附近用 $u = f(x)$ 作為新座標，要求 $J_f(a)$ 可逆；在不同座標系之間換變數時，Jacobian 元素按矩陣乘法重組。局部可逆保證 u 是一個合法的局部座標系；但不同分支可能覆蓋同一幾何點，需選擇局部圖卡。這與第19章的 Jacobian 行列式換變數、第20章的參數曲面直接接軌。

AI 層面：正規化流 (normalizing flows) 的核心要求是每一層映射都是 C^1 微分同胚，才能用 (11.1) 把 Jacobian 行列式從輸出傳到輸入；訓練時不以顯式反函數求逆，而是以 $J_g = (J_f)^{-1}$ 的方式透過矩陣解算維持數值穩定。可逆神經網路 (invertible neural networks) 的設計事實正是把「局部可逆」提升為「全域可逆」，代價是架構受限。

養殖校準合成案例：考慮一個合成的雙參數感測器校準問題。 $x = (x_1, x_2)$ 為感測器的兩個物理常數，單位分別為 mV/mg 與時間常數 ms； $y = f(x)$ 為在兩個測試條件下的讀數向量。若 $J_f(x^*)$ 可逆，則在 x^* 附近給定讀數 y ，參數 x 可以由局部反函數唯一決定。此即為小範圍的**可辨識性**。若 J_f 在某方向退化，則該方向上的參數無法由讀數區分，是典型的結構不可辨識。切勿把本章的局部結果推廣為「參數永遠可從讀數還原」；這只是**局部**一對一保證。所有數值案例均為合成資料；模型校準不等於現場驗證，數學可逆不等於設備已可安全操作；本章的 AI 輔助僅整理證據，不觸及投餌、加藥或設備控制。

習題

習題 11.1 (手算) 設 $f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ， $f(x, y) = (e^x \cos y, e^x \sin y)$ 。

(a) 計算 $J_f(x, y)$ 與 $\det J_f$ 。

(b) 判斷 f 在哪些點局部 C^1 微分同胚。

(c) 證明 f 不是全域一對一；並說明在 $f(0, 0) = (1, 0)$ 附近選取何種局部反函數分支。

(d) 由 (11.1) 寫出 g 在主值分支上的 Jacobian。

習題 11.2 (程式) 修改本程式 `newton_inverse`，加入：

(a) 每次迭代記錄 $\|J_f(x_k)\Delta_k - r_k\|_2$ ，驗證線性解算器的殘差。

(b) 若某次 Δ_k 的步長 $\|\Delta_k\|_2$ 超過限制 $R = 1.0$ ，回報 `step_too_large` 並停止。

(c) 給定 $f(x, y) = (x^3 + y, y + x^3)$ 、 $y^* = f(0.1, 0.2)$ 、 $x_0 = (0.05, 0.25)$ 執行。報告 `status`、最終殘差、迭代次數、迭代過程中 $\det J_f(x_k)$ 的變化。

習題 11.3 (反例，量詞與維度) 本題要檢驗「Jacobian 處處可逆」與「全域單射」之間的關係。

(a) 先證明：若 $f: \mathbb{R} \rightarrow \mathbb{R}$ 為 C^1 且 $f'(a) \neq 0$ 對所有 a 成立，則 f 是 $\mathbb{R}$ 上的嚴格單調函數，因而為單射。

(b) 構造一個 C^1 映射 $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$ ，其中 $n > 1$ ，使得 $J_F(a)$ 對所有 a 可逆，但 F 不是全域單射。

(c) 綜合 (a)(b)，說明命題「 F 全域雙射 $\iff J_F(a)$ 可逆對所有 a 」為偽，並指出它是在哪一維度上失敗的。

(d) 舉出一個 $f: \mathbb{R} \rightarrow \mathbb{R}$ 為雙射，但在某點 a 有 $f'(a) = 0$ ，且 f^{-1} 在 $f(a)$ 處不可微的例子。

習題 11.4 (整合) 考慮合成校準映射 $f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ：

$$f(x_1, x_2) = (x_1 + 0.5x_2^2, x_2 + 0.5x_1^2).$$

兩個分量對應讀數，單位為 mV。

(a) 在 $a = (0, 0)$ 處確認 $J_f(a)$ 可逆，並由 (11.1) 寫出 $J_g(f(a))$ 。

(b) 用本章牛頓程式以 $y^* = f(0.2, 0.1)$ 求解，起點 $x_0 = (0.15, 0.12)$ 。報告 `status`、最終殘差、迭代次數。

(c) 檢驗：(b) 中所求的局部解是否唯一？（提示：分析方程 $f(x) = y^*$ 的可能分支。）若不唯一，說明本章定理的限制。

(d) 從 (c) 的結果，寫出一段不超過 120 字的小結論，說明「局部可逆」在此合成校準中的實務意義。

習題解答

解答 11.1

(a) 直接求偏導：

$$J_f(x, y) = e^x \begin{pmatrix} \cos y & -\sin y \\ \sin y & \cos y \end{pmatrix}.$$

$\det J_f = e^{2x}(\cos^2 y + \sin^2 y) = e^{2x} > 0$ 對所有 (x, y) 成立。

(b) 因 J_f 在 $\mathbb{R}^2$ 上 C^∞ 且處處可逆，由定理 11.3， f 在每點局部 C^1 微分同胚。

(c) 對任意 $k \in \mathbb{Z}$ ， $f(x, y + 2k\pi) = f(x, y)$ ，故非一對一。在 $f(0, 0) = (1, 0)$ 附近選主值分支 $\{(x, y) : -\pi < y < \pi\}$ ， $g(u, v)$ 由 $\rho = \sqrt{u^2 + v^2}$ 、 $\theta = \text{atan2}(v, u)$ 給出： $g(u, v) = (\ln \rho, \theta)$ 。

(d) 由 (11.1) 及 J_f 的顯示式：

$$J_g(f(x, y)) = [J_f(x, y)]^{-1} = e^{-x} \begin{pmatrix} \cos y & \sin y \\ -\sin y & \cos y \end{pmatrix},$$

即極座標到笛卡兒式 Jacobian 的逆，與直接對 g 求偏導一致。

解答 11.2

(a) 程式片段：

```
lin_res = float(np.linalg.norm(Jx.dot(delta) - r, 2))
rec["lin_res"] = lin_res
```

在正常收斂時，`lin_res` 應為 $\mathcal{O}(\epsilon_{\text{mach}})\|J\|\|x\|$ 量級（約 10^{-15} 至 10^{-13} ）。若 `lin_res` 意外偏大，代表解算器有問題或 Jacobian 已接近奇異。

(b) 加入判斷：

```
if step_norm > R:
    history.append({"k": k, "x": x.copy(), "res": nrm_r,
                  "step": step_norm, "status": "step_too_large"})
    return x, history, "step_too_large"
```

(c) 預期 $x_\star = (0.1, 0.2)$ ，`status=="converged"`，最終殘差 $< 10^{-12}$ ，迭代次數約 5 至 8。

$\det J_f(x, y) = 1 - 9x^2y^2$ 。在 $x_0 = (0.05, 0.25)$ 時 $|\det| \approx 1 - 9 \cdot 0.0025 \cdot 0.0625 \approx 0.9986$ ，收斂過程中 $|\det|$ 維持在 1 附近；若某次 x 落至 $|x||y| = 1/3$ 附近則 $\det \rightarrow 0$ ，程式會以 `singular` 停下。

解答 11.3

(a) 因 f' 為連續函數且處處非零， f' 在 $\mathbb{R}$ 上不變號（若變號，由介值定理存在零點）。故 $f' > 0$ 處處或 $f' < 0$ 處處， f 為嚴格單調，因而單射。

(b) 取 $n = 2$ 並令 $F(r, \theta) = (r \cos \theta, r \sin \theta)$ ，定義域限制在 $r > 0$ 的開集。 $J_F(r, \theta) = \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix}$ ， $\det J_F = r > 0$ 處處可逆。但 $F(r, \theta) = F(r, \theta + 2\pi)$ ，故 F 非全域單射。

(c) 兩個方向都不成立：由 (a)，單維 C^1 下「 $f' \neq 0$ 處處 $\Rightarrow$ 雙射」不成立（可逆性是單射的充分條件但並非必要，雙射不必 $f' \neq 0$ ）；由 (b)，多維下「 J_F 處處可逆 $\Rightarrow$ 全域單射」在 $n \geq 2$ 直接失敗。故等價「 $\Longleftrightarrow$ 」在 $n = 1$ 與 $n \geq 2$ 都不成立。

(d) 取 $f(x) = x^3$ 。 f 是全域雙射， $f'(0) = 0$ ，逆 $g(y) = y^{1/3}$ 在 0 處導數不存在（ $g'(0)$ 的雙側極限為 $+\infty$ ）。

解答 11.4

(a) $J_f(x_1, x_2) = \begin{pmatrix} 1 & x_2 \\ x_1 & 1 \end{pmatrix}$ ，故 $J_f(0, 0) = I$ 可逆。由 (11.1)， $J_g(f(0, 0)) = I^{-1} = I$ 。

(b) $y^* = f(0.2, 0.1) = (0.2 + 0.005, 0.1 + 0.02) = (0.205, 0.12)$ 。以 $x_0 = (0.15, 0.12)$ 執行，預期 `status="converged"`， $x_* \approx (0.2, 0.1)$ ，殘差 $< 10^{-12}$ ，迭代約 4 至 6 次。

(c) 方程 $x_1 + 0.5x_2^2 = 0.205$ 、 $x_2 + 0.5x_1^2 = 0.12$ 是非線性代數方程組，一般可能有另一組解，例如在 x_1 較大、 x_2 為負的解分支附近。牛頓法從不同初值可能收斂到不同分支。本章定理只保證在 $a = (0, 0)$ 附近的局部唯一解；全域唯一性不在定理結論中。

(d) 在小範圍（ $a = (0, 0)$ 附近）內，感測讀數 y 能唯一決定參數 x ，誤差量級受 Jacobian 條件數控制；一旦離開該小範圍，多分支可能出現，須以初值策略或額外資訊選出物理上合理的那一支，不能僅憑「 $J_f(a)$ 可逆」推論全域可辨識。

本章小結

反函數定理把「 f 在 a 附近像它的 Jacobian」由直覺提升為可證的結論。定理的三個支柱是： f 在 a 的鄰域 C^1 、 $J_f(a)$ 可逆、以及以 $T(x) = x - J_f(a)^{-1}(f(x) - f(a))$ 為收縮映射的構造。這條線路同時給出逆映射的微分公式 $J_g(y) = [J_f(g(y))]^{-1}$ ，與「以線性解算代替顯式求逆」的數值實踐。

需要記住的三條界線。第一，充分而非必要： $f(x) = x^3$ 告訴我們可逆 Jacobian 不是局部可逆的必要條件。第二，局部而非全域： $(x, y) \mapsto (x^2 - y^2, 2xy)$ 與極座標映射告訴我們，處處可逆的 Jacobian 不代表全域一對一；而單維 C^1 下 f' 處處非零必強制全域單調，因此「處處可逆但非單射」只能發生在 $n \geq 2$ 。第三， C^1 正則性是證明中控制 $\|J_T\|$ 的關鍵，不能只在單點可微。

數值上，牛頓求逆是本章定理的離散對應。程式中透過 `np.linalg.solve` 解 $J_f(x_k)\Delta_k = r_k$ ，並偵測奇異 Jacobian 與過大步長。有限次的收斂紀錄構成**數值檢查**，不是定理證明；是否真的存在局部反函數，仍由定理 11.3 的條件承擔。奇異點附近條件數爆炸會使「看似可解」的問題在雙精度下崩潰，這也正是合成校準與 AI 可逆架構在實務中必須正視的限制。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*（作者教材入口）<https://www.jirka.org/ra/>
- [A2] MIT OCW 18.100A Real Analysis <https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>

- [A3] MIT OCW 18.02SC Multivariable Calculus <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
- [A4] JAX Autodiff Cookbook：JVP／VJP
https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html
- [A5] SciPy 矩陣指數 `expm`
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>
- [A6] SciPy `minimize` 參數與方法
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>

來源說明：2026-10-05 已取得 A1 作者目錄頁、A2／A3 課程概要與 A4 至 A6 API 文件。未讀完教材 PDF 或完整課程，未執行外部程式，亦不代表本章所有定理逐條查證。A1 舊 `htmlv2` 路徑 404，僅以作者首頁為入口。JAX 與 SciPy 為延伸參考，本章核心實作不依賴 JAX、自動微分框架或 GPU；線上 API 版本可能與本機不同。

第12章 隱函數定理與靈敏度

學習目標與先備知識

許多模型不直接給出 $y = g(x)$ ，而是以平衡條件

$$F(x, y) = 0$$

間接決定未知狀態 y 。本章研究三個問題：何時能在某個解附近把 y 唯一表示成 x 的函數？參數 x 改變時，解 y 有多敏感？當關鍵 Jacobian 失去秩時，哪些結論會失效？

完成本章後，讀者應能：

1. 正確陳述有限維 C^1 隱函數定理。
2. 區分解存在、局部唯一分支與全域唯一解。
3. 推導靈敏度公式

$$Dg(x) = -(D_y F(x, g(x)))^{-1} D_x F(x, g(x)).$$

4. 檢查 Jacobian 的形狀、秩與物理單位。
5. 以線性方程求取靈敏度，而不顯式形成逆矩陣。
6. 以最小奇異值解釋接近秩失效時的靈敏度放大。
7. 使用殘差、步長與有限差分稽核數值實作，但不把有限測試誤當證明。

先備知識包括 Fréchet 導數、Jacobian、鏈式法則、矩陣可逆性、算子範數與反函數定理。設

$$F : U \subset \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^m,$$

其中 U 為開集。偏 Jacobian 的形狀為

$$D_x F(x, y) \in \mathbb{R}^{m \times n}, \quad D_y F(x, y) \in \mathbb{R}^{m \times m}.$$

輸入擾動是 $n \times 1$ 直向量，狀態擾動是 $m \times 1$ 直向量。除非另有說明，範數採 Euclidean 範數及其誘導矩陣二範數。

問題與直覺

考慮單位圓

$$F(x, y) = x^2 + y^2 - 1 = 0.$$

在 $(0, 1)$ 附近，圓的上方局部弧可寫成

$$y = g(x) = \sqrt{1 - x^2}.$$

但整個圓不能由單一函數 $y = g(x)$ 表示，因為同一個 $x \in (-1, 1)$ 通常對應正、負兩個 y 。隱函數定理是局部定理，不自動提供全域唯一性。

在 $(0, 1)$ ，

$$D_y F(0, 1) = 2 \neq 0.$$

固定 x 並稍微改變 y 時，方程值會以非零的一階速率改變。因此，當 x 有小擾動時，可望調整 y 抵銷該變化。

在右端點 $(1, 0)$ ，

$$D_y F(1, 0) = 0.$$

在 $x < 1$ 一側，上半弧可寫成 $y = \sqrt{1 - x^2}$ ；但它不能延伸為定義於包含 $x = 1$ 的開區間、且在整個區間滿足圓方程的實值分支，因為該區間必包含沒有圓上實點的 $x > 1$ 。包含端點的完整局部曲線須改選座標表示。因為

$$D_x F(1, 0) = 2 \neq 0,$$

交換角色後可寫成

$$x = h(y) = \sqrt{1 - y^2}.$$

左端點 $(-1, 0)$ 的情形相似，但須分清單側公式與開域分支：在 $x > -1$ 一側，上、下半弧分別可寫成 $y = \pm\sqrt{1 - x^2}$ ；任何包含 $x = -1$ 的開區間卻都包含 $x < -1$ ，該側沒有圓上實點，因此不存在整個開區間上的圓方程實值分支 $y = g(x)$ 。若要表示包含端點的完整局部曲線鄰域，可改以 $x = -\sqrt{1 - y^2}$ 表示，且此函數在 $y = 0$ 附近定義於開區間。由此可見， $D_y F$ 失去秩不表示曲線消失；它只使選定的 x 作輸入、 y 作輸出之隱函數定理不能使用。換用 y 作輸入後，須重新檢查相應偏導是否非零，不能把原公式中的分母直接設為零後繼續計算。

若 (x_0, y_0) 是解，Fréchet 可微性給出

$$F(x_0 + \Delta x, y_0 + \Delta y) = F(x_0, y_0) + D_x F \Delta x + D_y F \Delta y + r(\Delta x, \Delta y),$$

其中

$$\frac{\|r(\Delta x, \Delta y)\|_2}{\|(\Delta x, \Delta y)\|_2} \rightarrow 0.$$

忽略高階餘項並使用 $F(x_0, y_0) = 0$ ，得到

$$D_y F \Delta y = -D_x F \Delta x.$$

若 $D_y F$ 可逆，則

$$\Delta y \approx -(D_y F)^{-1} D_x F \Delta x.$$

這是靈敏度公式的線性代數直覺。不過，形式上的移項不證明附近確實存在唯一函數分支；存在性、唯一性與可微性必須由定理建立。

定義、定理與推導

零集合與局部分支

定義（零集合）。

映射 F 的零集合為

$$\mathcal{Z} = \{(x, y) \in U : F(x, y) = 0\}.$$

定義（局部隱函數分支）。

若 $(a, b) \in \mathcal{Z}$ ，且存在 a 的開鄰域 V 、 b 的開鄰域 W 及函數 $g : V \rightarrow W$ ，使

$$\mathcal{Z} \cap (V \times W) = \{(x, g(x)) : x \in V\},$$

則稱 g 是通過 (a, b) 的局部隱函數分支。

此處的唯一性限定在所選的 $V \times W$ 中。它不排除同一個 x 在 W 外另有解。

有限維隱函數定理

定理（ C^1 隱函數定理）。

令 $U \subset \mathbb{R}^n \times \mathbb{R}^m$ 為開集，且

$$F : U \rightarrow \mathbb{R}^m$$

為 C^1 映射。設 $(a, b) \in U$ 滿足

$$F(a, b) = 0,$$

並假設

$$D_y F(a, b) \in \mathbb{R}^{m \times m}$$

可逆。則存在 a 的開鄰域 V 與 b 的開鄰域 W ，以及唯一的 C^1 函數 $g: V \rightarrow W$ ，滿足

$$g(a) = b$$

且

$$F(x, g(x)) = 0, \quad x \in V.$$

此唯一性是指：在適當縮小並固定的 V, W 上，滿足 $g(a) = b$ 且圖形位於 $V \times W$ 的分支唯一；更精確地，

$$\mathcal{Z} \cap (V \times W) = \{(x, g(x)) : x \in V\}.$$

由 $D_y F$ 的連續性及其在 (a, b) 可逆，再縮小 V ，可使 $D_y F(x, g(x))$ 對每個 $x \in V$ 仍可逆。此外，

$$Dg(x) = -(D_y F(x, g(x)))^{-1} D_x F(x, g(x)).$$

形狀檢查為

$$Dg(x) \in \mathbb{R}^{m \times n},$$

而右側為

$$(m \times m)(m \times n) = m \times n.$$

$D_y F(a, b)$ 可逆是此定理的**充分條件**，不是局部函數存在的必要條件。不可逆時只能說這個定理不能直接使用，不能斷言分支必定不存在。

從反函數定理推導存在性

定義

$$H(x, y) = (x, F(x, y)).$$

其 Jacobian 是分塊下三角矩陣：

$$DH(a, b) = \begin{pmatrix} I_n & 0 \\ D_x F(a, b) & D_y F(a, b) \end{pmatrix}.$$

因 I_n 與 $D_y F(a, b)$ 可逆， $DH(a, b)$ 亦可逆。由反函數定理，存在 (a, b) 的鄰域 N 與 $(a, 0)$ 的鄰域 M ，使

$$H: N \rightarrow M$$

為 C^1 微分同胚。

局部反函數可寫成

$$H^{-1}(x, z) = (x, \psi(x, z)).$$

令

$$g(x) = \psi(x, 0),$$

便有

$$H(x, g(x)) = (x, 0),$$

所以 $F(x, g(x)) = 0$ 。

還須明確處理鄰域：先選取 b 的足夠小的開鄰域 W ，再利用 g 的連續性選取 a 的開鄰域 V ，使 $V \times W \subset N$ ，對每個 $x \in V$ 都有 $(x, 0) \in M$ ，並且 $g(V) \subset W$ 。若 $(x, y) \in V \times W$ 且 $F(x, y) = 0$ ，則

$$H(x, y) = (x, 0) = H(x, g(x)).$$

由 H 在 N 上的單射性，

$$y = g(x).$$

故該鄰域中的所有零點恰為此分支。完整存在性證明在此引用有限維反函數定理；適用範圍是有限維 Euclidean 空間中的 C^1 映射。

靈敏度公式

由

$$F(x, g(x)) = 0$$

與鏈式法則，

$$D_x F(x, g(x)) + D_y F(x, g(x)) Dg(x) = 0.$$

因此

$$D_y F(x, g(x)) Dg(x) = -D_x F(x, g(x)).$$

利用可逆性，

$$Dg(x) = -\left(D_y F(x, g(x))\right)^{-1} D_x F(x, g(x)).$$

數學公式使用逆矩陣描述結果，但數值實作應解

$$D_y F S = -D_x F, \quad S = Dg(x),$$

而不是先計算 $(D_y F)^{-1}$ 。若只需要方向 d 的靈敏度，可直接解

$$D_y F s = -D_x F d, \quad s = Dg(x)d.$$

小命題：分支導數的唯一性

命題。

設 F 在 (a, b) 可微， $F(a, b) = 0$ 。若 g_1, g_2 在 a 可微，且在 a 附近滿足

$$g_1(a) = g_2(a) = b, \quad F(x, g_i(x)) = 0,$$

並且 $D_y F(a, b)$ 可逆，則

$$Dg_1(a) = Dg_2(a).$$

證明。

對兩個恆等式使用鏈式法則：

$$D_x F(a, b) + D_y F(a, b) Dg_i(a) = 0.$$

兩式相減得

$$D_y F(a, b) (Dg_1(a) - Dg_2(a)) = 0.$$

左乘 $(D_y F(a, b))^{-1}$ ，得到

$$Dg_1(a) - Dg_2(a) = 0.$$

故 $Dg_1(a) = Dg_2(a)$ 。證畢。

此命題只證明「若分支存在且可微，其導數必須一致」，並未證明分支存在。

一階誤差與條件放大

分支的 Fréchet 可微性表示

$$g(x + \delta x) = g(x) + Dg(x)\delta x + r_g(\delta x),$$

其中

$$\frac{\|r_g(\delta x)\|_2}{\|\delta x\|_2} \rightarrow 0.$$

所以

$$\|\delta y\|_2 \leq \|Dg(x)\|_2 \|\delta x\|_2 + o(\|\delta x\|_2).$$

又有

$$\|Dg(x)\|_2 \leq \|D_y F^{-1}\|_2 \|D_x F\|_2.$$

若 $D_y F$ 可逆，

$$\|D_y F^{-1}\|_2 = \frac{1}{\sigma_{\min}(D_y F)}.$$

因此，小的最小奇異值可能造成大的靈敏度上界。但此上界不表示每個方向都達到最大放大；最敏感方向與奇異向量有關。

裸行列式並非尺度不變。整個矩陣乘上常數會大幅改變行列式，卻不改變二範數條件數。因此，數值判斷應使用經適當尺度化的奇異值或條件數，不能只看行列式大小。

逐步手算例題

例一：圓、局部分支與垂直切線

對

$$F(x, y) = x^2 + y^2 - 1$$

有

$$D_x F = 2x, \quad D_y F = 2y.$$

在上半圓 $y > 0$ 上，

$$g'(x) = -\frac{D_x F}{D_y F} = -\frac{x}{y}.$$

在

$$(x, y) = \left(\frac{3}{5}, \frac{4}{5}\right)$$

處，

$$g'\left(\frac{3}{5}\right) = -\frac{3}{4}.$$

若 $\Delta x = 0.01$ ，則一階預測為

$$\Delta y \approx -0.0075.$$

直接微分 $g(x) = \sqrt{1-x^2}$ 也得到

$$g'(x) = -\frac{x}{\sqrt{1-x^2}}.$$

當 $x \rightarrow 1^-$ 時， $|g'(x)| \rightarrow \infty$ 。這是從上半圓內部單側接近右端點的敘述。在端點本身，包含端點的完整圓弧不能表示成定義於開區間上的可微 $y = g(x)$ ；改用

$$x = h(y) = \sqrt{1-y^2}$$

則可局部表示完整曲線鄰域，且

$$h'(0) = 0.$$

例二：二元耦合平衡方程

令

$$x = \begin{pmatrix} p \\ q \end{pmatrix}, \quad y = \begin{pmatrix} u \\ v \end{pmatrix},$$

並定義

$$F(x, y) = \begin{pmatrix} u + v + p - 3 \\ u^2 + 2v - q - 6 \end{pmatrix}.$$

在

$$x_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad y_0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

有 $F(x_0, y_0) = 0$ 。偏 Jacobian 為

$$D_x F = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}, \quad D_y F = \begin{pmatrix} 1 & 1 \\ 2u & 2 \end{pmatrix}.$$

在基準點，

$$D_y F = \begin{pmatrix} 1 & 1 \\ 4 & 2 \end{pmatrix}, \quad \det(D_y F) = -2 \neq 0.$$

令 $S = Dg(x_0)$ ，則

$$\begin{pmatrix} 1 & 1 \\ 4 & 2 \end{pmatrix} S = \begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix}.$$

解得

$$S = \begin{pmatrix} 1 & 1/2 \\ -2 & -1/2 \end{pmatrix}.$$

若

$$\Delta x = \begin{pmatrix} 0.01 \\ -0.02 \end{pmatrix},$$

則

$$\Delta y \approx S \Delta x = \begin{pmatrix} 0 \\ -0.01 \end{pmatrix}.$$

這是局部一階預測。由第一式得 $v = 3 - p - u$ ，代入第二式：

$$u^2 - 2u - 2p - q = 0.$$

若 $(p, q) = \varepsilon(1, -2)$ ，則通過 $u = 2$ 的分支恰有

$$u = 2, \quad v = 1 - \varepsilon.$$

所以此方向的解恰為線性，不適合用來觀察一般前向差分的截斷誤差。

例三：兩個候選分支與合併點

由上式可得

$$u = 1 \pm \sqrt{1 + 2p + q}.$$

上述根式給出實數解的條件是 $1 + 2p + q \geq 0$ ；嚴格大於零時兩根不同，等於零時兩根合併，小於零時沒有實平衡解。在 $(p, q) = (0, 0)$ ，兩個解為 $u = 2$ 與 $u = 0$ 。由本例的 $\det(D_y F) = 2 - 2u$ ，在兩個基準解處行列式分別為 -2 與 2 ，均非零。因此隱函數定理分別保證：選取各自的參數與狀態鄰域後，零集合在該乘積鄰域內恰為一條唯一的光滑分支。兩個狀態鄰域可以彼此分開；同一參數在較大的狀態範圍內仍對應兩個平衡解。這說明「局部唯一」中的鄰域限制不可省略。

當

$$1 + 2p + q = 0$$

時，兩根合併為 $u = 1$ 。此時

$$\det(D_y F) = 2 - 2u = 0.$$

本例可由明確代數式證明分支合併。一般黑箱模型中，觀察到小奇異值只能作為秩失效警示，不能單獨證明折疊或分岔類型。

實作與程式

以下自足程式只使用 NumPy，在 CPU 上求解例二。Newton 步驟與靈敏度都使用 `numpy.linalg.solve`。程式記錄殘差、步長、最小奇異值與條件數。

```
import numpy as np

def F(x, y):
    x = np.asarray(x, dtype=float).reshape(2)
    y = np.asarray(y, dtype=float).reshape(2)
    p, q = x
    u, v = y
    return np.array([
        u + v + p - 3.0,
        u*u + 2.0*v - q - 6.0
    ])

def DxF(x, y):
    return np.array([[1.0, 0.0],
                    [0.0, -1.0]])

def DyF(x, y):
    y = np.asarray(y, dtype=float).reshape(2)
    u, v = y
    return np.array([[1.0, 1.0],
                    [2.0*u, 2.0]])

def diagnostics(A):
    sv = np.linalg.svd(A, compute_uv=False)
    smax, smin = float(sv[0]), float(sv[-1])
    cond = np.inf if smin == 0.0 else smax / smin
    return smin, cond
```



```

def solve_equilibrium(x, y0, residual_tol=1e-12,
                     step_tol=1e-12, max_iter=30,
                     singular_tol=1e-10):
    x = np.asarray(x, dtype=float).reshape(2)
    y = np.asarray(y0, dtype=float).reshape(2).copy()
    history = []

    for k in range(max_iter):
        r = F(x, y)
        rnorm = float(np.linalg.norm(r, 2))
        A = DyF(x, y)
        smin, cond = diagnostics(A)

        if rnorm <= residual_tol:
            return y, history, {
                "status": "converged",
                "residual": rnorm,
                "sigma_min": smin,
                "condition": cond
            }

        if smin <= singular_tol:
            raise np.linalg.LinAlgError(
                "DyF is singular or below accepted scale"
            )

        step = np.linalg.solve(A, -r)
        step_norm = float(np.linalg.norm(step, 2))
        history.append((k, rnorm, step_norm, smin, cond))
        y = y + step

        if step_norm <= step_tol * (1.0 + np.linalg.norm(y, 2)):
            final_r = float(np.linalg.norm(F(x, y), 2))
            smin, cond = diagnostics(DyF(x, y))
            return y, history, {
                "status": "small_step",
                "residual": final_r,
                "sigma_min": smin,
                "condition": cond
            }

    smin, cond = diagnostics(DyF(x, y))
    return y, history, {
        "status": "max_iter",
        "residual": float(np.linalg.norm(F(x, y), 2)),
        "sigma_min": smin,
        "condition": cond
    }

def sensitivity(x, y, residual_tol=1e-9,
               singular_tol=1e-10):
    if np.linalg.norm(F(x, y), 2) > residual_tol:
        raise ValueError("candidate is not an accepted equilibrium")
    A = DyF(x, y)
    smin, cond = diagnostics(A)
    if smin <= singular_tol:
        raise np.linalg.LinAlgError(
            "sensitivity is not certified near singular DyF"
        )

```

```

    )
    S = np.linalg.solve(A, -DxF(x, y))
    return S, {"sigma_min": smin, "condition": cond}

def finite_difference_check(x, y, direction, epsilon):
    x = np.asarray(x, dtype=float).reshape(2)
    y = np.asarray(y, dtype=float).reshape(2)
    d = np.asarray(direction, dtype=float).reshape(2)

    S, info_s = sensitivity(x, y)
    predicted = S @ d
    yp, _, info_p = solve_equilibrium(
        x + epsilon*d, y, residual_tol=1e-13
    )
    observed = (yp - y) / epsilon
    error = float(np.linalg.norm(observed - predicted, 2))
    return predicted, observed, error, info_s, info_p

if __name__ == "__main__":
    x0 = np.array([0.0, 0.0])
    y, history, info = solve_equilibrium(
        x0, np.array([2.1, 0.9])
    )
    S, sinfo = sensitivity(x0, y)

    print("solution =", y)
    print("solver =", info)
    print("sensitivity =\n", S)
    print("diagnostics =", sinfo)

    for eps in [1e-2, 1e-4, 1e-6]:
        result = finite_difference_check(
            x0, y, np.array([1.0, 0.0]), eps
        )
        print("epsilon =", eps, "result =", result)

```

數學上， x 、 y 與方向向量皆視為 2×1 直向量；NumPy 的 `(2,)` 只是儲存表示。程式沒有使用一維陣列的 `.T` 假裝改變形狀。

Newton 法是局部數值求解器。它收斂到候選解，不證明所有初值都收斂，也不證明全域沒有其他解。有限差分只能稽核特定點、方向與步長。

測試與預期結果

以下均為解析推導或程式的**預期結果**；本章未執行程式。

正常測試

使用基準參數與初值

```
x0 = np.array([0.0, 0.0])
```

```
y0 = np.array([2.1, 0.9])
```

預期收斂到接近

```
solution = [2. 1.]
```

靈敏度預期為

```
[[ 1.   0.5]  
 [-2.  -0.5]]
```

對 $d = (1, 0)^T$ ，

$$Dg(x_0)d = \begin{pmatrix} 1 \\ -2 \end{pmatrix}.$$

有限差分應接近此值。

步長掃描

對 $\varepsilon = 10^{-2}, 10^{-4}, 10^{-6}$ 計算

$$E(\varepsilon) = \left\| \frac{g(x + \varepsilon d) - g(x)}{\varepsilon} - Dg(x)d \right\|_2.$$

沿 $d = (1, 0)^T$ 的明確分支為

$$u = 1 + \sqrt{1 + 2p}, \quad v = 2 - p - \sqrt{1 + 2p},$$

並非精確線性。在求解誤差與浮點誤差尚未主導時，預期前向差分誤差隨步長下降；本章未執行，故不宣稱實測收斂階。

邊界測試

當 $u \rightarrow 1$ 時，

$$D_y F = \begin{pmatrix} 1 & 1 \\ 2u & 2 \end{pmatrix}$$

的兩條方程橫列趨於線性相關，最小奇異值趨近零。預期條件數上升，靈敏度放大，最終觸發奇異門檻。

故障測試：非平衡點

呼叫

```
sensitivity(
    np.array([0.0, 0.0]),
    np.array([1.0, 2.0])
)
```

時，該點不是可接受的平衡解，預期先拋出 `ValueError`。這避免在沒有滿足 $F = 0$ 的點上錯誤解讀靈敏度。

故障測試：奇異平衡點

取

$$p = -\frac{1}{2}, \quad q = 0, \quad u = 1, \quad v = \frac{5}{2}.$$

可驗證 $F = 0$ ，但 $D_y F$ 奇異。呼叫 `sensitivity` 預期拋出 `LinAlgError`。

若輸入長度不是二，例如 `x=[0,0,0]`，則預期由 `reshape(2)` 拋出 `ValueError`。這是介面故障，不是數學秩失效。

反例與常見陷阱

局部唯一不等於全域唯一

圓在 $(0, 1)$ 附近有唯一上分支，但 $x = 0$ 在全域上對應 $y = \pm 1$ 。定理只排除所選鄰域內的其他分支。

可逆條件不是必要條件

令

$$F(x, y) = (y - x)^3.$$

零集合恰為 $y = x$ ，所以存在唯一光滑分支；但在零集合上，

$$D_y F = 3(y - x)^2 = 0.$$

因此「 $D_y F$ 不可逆便必無隱函數」是錯誤命題。不可逆只表示標準定理不提供保證。

秩失效可能伴隨無解側與多分支側

令

$$F(x, y) = y^2 - x.$$

在原點 $F_y = 0$ 。不存在定義於原點某個開鄰域、並對其中所有實數 x 滿足 $F(x, g(x)) = 0$ 的實值函數，因為任何原點開鄰域都包含負 x ，而負 x 時沒有實解。對 $x > 0$ 則有兩個分支

$$y = \pm\sqrt{x}.$$

所以本例同時呈現一側無解、另一側多分支。它不應只被籠統描述為「完整零集合不是函數」。

不可在奇異點直接除法

公式

$$\frac{dy}{dx} = -\frac{F_x}{F_y}$$

只在存在相應可微分支且 $F_y \neq 0$ 時成立。 $F_y = 0$ 時不能直接相除。

小殘差不等於可靠靈敏度

小殘差只表示候選點近似滿足方程。若 $D_y F$ 接近奇異，解仍可能對量測誤差與舍入誤差高度敏感。報告應同時列出殘差、步長、尺度化奇異值或條件數。

行列式小不等於尺度化病態

行列式隨單位與縮放改變。正式判斷應使用適當無因次化後的奇異值或條件數，而非只比較裸行列式。

AI、幾何與養殖案例

AI 隱式層

某些模型以平衡條件定義隱藏狀態：

$$F(\theta, z) = z - \tanh(W(\theta)z + b(\theta)) = 0.$$

若 $D_z F$ 可逆，局部上存在 $z = z(\theta)$ ，且

$$Dz(\theta) = -(D_z F)^{-1} D_\theta F.$$

若最終只需要標量損失的參數導數，實作常解轉置線性系統，而不形成完整逆矩陣。求解器找到固定點不代表固定點全域唯一；接近奇異時，自動微分產生的數值也可能高度敏感。

幾何中的座標圖

對曲線 $F(x, y) = 0$ ，若 $F_y \neq 0$ ，可用 x 作局部座標；若 $F_x \neq 0$ ，可改用 y 。圓的左右端點不能把包含端點的完整曲線鄰域寫成開區間上的可微 $y = g(x)$ ，但能寫成 $x = h(y)$ 。這是局部座標選擇問題。

合成養殖平衡模型

以下模型只供教學。令參數

$$x = \begin{pmatrix} T \\ R \end{pmatrix},$$

其中水溫 T 的單位為 $^{\circ}\text{C}$ ，合成曝氣設定 R 的單位為 L min^{-1} 。令狀態

$$y = \begin{pmatrix} O \\ C \end{pmatrix},$$

其中溶氧 O 的單位為 mg L^{-1} ， C 為無因次合成指標。指定第一個方程分量的單位為 mg L^{-1} ，第二個為無因次。為使各項可相加， O_* 與 O 、 C_* 與 C 、 R_* 與 R 、 T_* 與 T 分別同單位； k_O 無因次， α 為 mg L^{-1} ， β 為 mg min L^{-2} ， γ 為 L mg^{-1} ， η 為 $(^{\circ}\text{C})^{-1}$ ， ρ 無因次。這些指定只保證合成方程的量綱一致，不表示係數已由現場資料校準。考慮

$$F = \begin{pmatrix} k_O(O - O_*) + \alpha(C - C_*) - \beta(R - R_*) \\ (C - C_*)^2 + \gamma(O - O_*) - \eta(T - T_*) - \rho \end{pmatrix}.$$

則

$$D_y F = \begin{pmatrix} k_O & \alpha \\ \gamma & 2(C - C_*) \end{pmatrix}, \quad D_x F = \begin{pmatrix} 0 & -\beta \\ -\eta & 0 \end{pmatrix}.$$

Jacobian 每個元素的單位都是「方程分量單位除以輸入分量單位」。混合單位下，原始 Euclidean 長度沒有直接物理解釋。可引入尺度矩陣 S_x, S_y ，定義

$$\hat{x} = S_x^{-1}(x - x_*), \quad \hat{y} = S_y^{-1}(y - y_*).$$

無因次靈敏度為

$$D\hat{g} = S_y^{-1} Dg S_x.$$

還須為兩個方程分量各選一個正尺度，組成可逆的方程尺度矩陣 S_F ：其第一個對角尺度具有 mg L^{-1} 單位，第二個為無因次；兩者的數值大小須依所分析的殘差範圍明示。以無因次狀態表示方程時，應分析無因次矩陣 $S_F^{-1} D_y F S_y$ 的奇異值或條件數；只縮放參數和狀態，仍不能消除方程分量可能具有的不同單位。這些可逆尺度不改變精確秩，卻會影響「接近奇異」的數值判斷。若該無因次矩陣的最小奇異值相對其最

大奇異值很小，即二範數條件數很大，便須警惕局部求解和靈敏度計算對擾動的放大。條件數描述線性系統的最壞方向相對敏感性，不保證每一種參數擾動都會造成同樣幅度的狀態變化；仍應結合實際擾動方向與靈敏度矩陣判讀。此處未尺度化的行列式為

$$\det(D_y F) = 2k_O(C - C_*) - \alpha\gamma.$$

它等於零可判定精確秩失效，但其數值大小受單位與尺度影響。比較接近秩失效的程度時，須先固定並交代方程與狀態尺度，以無因次矩陣 $S_F^{-1} D_y F S_y$ 的奇異值和條件數為準。

這種靈敏度只是合成模型的局部預測，不等於現場驗證或安全結論。agent 只能唯讀整理證據，不能據此控制曝氣、投餌或加藥。

習題

習題一：手算

設

$$F(x, y) = e^y + xy - 2.$$

在 $(0, \ln 2)$ ：

1. 判斷隱函數定理是否適用。
2. 求 $g'(0)$ 。
3. 以一階近似估計 $g(0.01)$ 。

習題二：程式

使用本章程式及 $d = (1, 0)^T$ ，對三個步長計算前向差分誤差。說明預期趨勢，以及有限測試為何不能證明 Fréchet 可微。

習題三：反例

比較

$$F_1(x, y) = (y - x)^3, \quad F_2(x, y) = y^2 - x.$$

兩者在原點均有 $D_y F_i = 0$ 。判斷是否存在定義於原點開鄰域的唯一可微實值分支。

習題四：整合

令

$$F(p, u, v) = \left(\frac{u + v - p}{u^2 + v - 2} \right).$$

在 $(p, u, v) = (2, 1, 1)$ ：

1. 驗證平衡。
2. 檢查 $D_{(u,v)}F$ 。
3. 求 du/dp 與 dv/dp 。
4. 找出可能接近秩失效的 u 。
5. 說明結論是局部還是全域。

習題解答

解答一

有

$$F_x = y, \quad F_y = e^y + x.$$

在基準點，

$$F_y(0, \ln 2) = 2 \neq 0.$$

定理適用，且

$$g'(0) = -\frac{\ln 2}{2}.$$

所以

$$g(0.01) \approx \ln 2 - \frac{\ln 2}{2}(0.01) = 0.995 \ln 2 \approx 0.68968.$$

這是一階估計，不是精確值。

解答二

可使用：

```
x = np.array([0.0, 0.0])
y = np.array([2.0, 1.0])
d = np.array([1.0, 0.0])

for eps in [1e-2, 1e-4, 1e-6]:
```



```
result = finite_difference_check(x, y, d, eps)
print(eps, result[2])
```

沿此方向的分支不是精確線性，故在浮點與求解誤差尚未主導時，預期前向差分誤差隨步長下降。有限測試只涵蓋三個步長與一個方向；Fréchet 可微要求餘項對所有小擾動滿足極限條件，所以有限計算不是證明。

解答三

對 F_1 ，

$$F_1(x, y) = 0 \iff y = x.$$

故存在唯一光滑分支 $g(x) = x$ ，儘管 $D_y F_1(0, 0) = 0$ 。

對 F_2 ，任何原點開鄰域都包含負 x ，但負 x 時 $y^2 = x$ 沒有實解。因此不存在定義於原點開鄰域且處處滿足方程的實值函數。對 $x > 0$ 又有 $y = \pm\sqrt{x}$ 兩支。這證明 $D_y F = 0$ 本身不能決定結論。

解答四

代入得 $F(2, 1, 1) = 0$ 。對 $y = (u, v)^T$ ，

$$D_y F = \begin{pmatrix} 1 & 1 \\ 2u & 1 \end{pmatrix}.$$

在 $u = 1$ ，其行列式為 -1 ，故可逆。又

$$D_p F = \begin{pmatrix} -1 \\ 0 \end{pmatrix}.$$

靈敏度滿足

$$\begin{pmatrix} 1 & 1 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} du/dp \\ dv/dp \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

解得

$$\frac{du}{dp} = -1, \quad \frac{dv}{dp} = 2.$$

因

$$\det(D_y F) = 1 - 2u,$$

所以 $u \rightarrow 1/2$ 時可能接近秩失效。這些是通過指定平衡點之分支的局部結論，不能由隱函數定理推出全域唯一性。

本章小結

對隱式方程 $F(x, y) = 0$ ，若 F 在解附近為 C^1 ，且 $D_y F$ 可逆，則存在通過該解的唯一局部 C^1 分支 $y = g(x)$ 。其靈敏度滿足

$$D_y F Dg = -D_x F,$$

亦即

$$Dg = -(D_y F)^{-1} D_x F.$$

數值上應解線性方程，不顯式形成逆矩陣。尺度化最小奇異值下降時，條件數與靈敏度可能上升。可逆性是標準定理的充分條件，不是局部函數存在的必要條件。

必須持續區分：局部與全域、殘差與條件、數值證據與數學證明、單側曲線公式與包含基準點的完整曲線鄰域。對有因次模型，還須先處理單位及尺度，才可合理解釋奇異值與靈敏度。

參考來源

1. Jiří Lebl, *Basic Analysis* : <https://www.jirka.org/ra/>
2. MIT OpenCourseWare, *18.100A Real Analysis* : <https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
3. MIT OpenCourseWare, *18.02SC Multivariable Calculus* : <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
4. JAX, *Autodiff Cookbook: JVP/VJP* : https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html

以上資料供分析、多變量微積分與隱式微分延伸閱讀。核心實作不依賴 JAX、SciPy 或 GPU；本章未執行外部程式。線上文件版本可能更新，使用時應重新核對定理條件與 API。

第13章 Hessian、二階微分與Taylor展開

學習目標與先備知識

讀完本章，應能把 Hessian 理解為二階導數的矩陣表示，而不只是「把偏導數排成表格」；能區分二階方向導數、二階微分與有限步長差分；能在明確條件下寫出二階 Taylor 展開，並辨別 $o(\|h\|^2)$ 與 $O(\|h\|^3)$ ；還能檢查交叉項係數，以及用實驗觀察餘項，而不把有限次實驗當作極限定理的證明。

先備知識包括 Fréchet 可微、Jacobian、矩陣乘法、Euclidean 範數及單變量 Taylor 定理。本章只研究局部二階近似；Hessian 如何用於極值判別，留待下一章。除特別註明外，向量均為直立的列向量 (column vector)， $\|h\|$ 表示 Euclidean 範數。

問題與直覺

一階近似以切平面描述函數在 x 附近的變化：

$$f(x+h) \approx f(x) + \nabla f(x)^T h.$$

它描述斜率，卻沒有描述斜率如何改變。二階近似再加入一個關於 h 的二次型：

$$f(x+h) \approx f(x) + \nabla f(x)^T h + \frac{1}{2} h^T H_f(x) h.$$

其中 $H_f(x)$ 是 Hessian。若 $h = (h_1, h_2)^T$ ，二次項展開為

$$\frac{1}{2} h^T H_f h = \frac{1}{2} H_{11} h_1^2 + \frac{1}{2} (H_{12} + H_{21}) h_1 h_2 + \frac{1}{2} H_{22} h_2^2.$$

在 Hessian 對稱時，交叉項係數是 H_{12} ，**不是** $\frac{1}{2} H_{12}$ 。前面的 $\frac{1}{2}$ 同時作用於矩陣乘積中出現的兩個交叉項。

「二次近似」也有精確的誤差意思。若誤差是 $o(\|h\|^2)$ ，則誤差除以 $\|h\|^2$ 會在 $h \rightarrow 0$ 時趨於零；這並不自動給出誤差小於某個常數乘 $\|h\|^3$ 。兩者所需的正則性不同，不能從幾次漂亮的數值結果推斷較強結論。

還須分清「方向」與「大小」。沿某個固定方向縮短步長，能研究該方向上的函數變化；二階 Taylor 展開卻要求同一個餘項條件適用於所有趨近零的擾動。因此，一條方向上的精確計算既有用，也有明確的適用邊界。

定義、定理與推導

設 $U \subset \mathbb{R}^n$ 為開集， $f: U \rightarrow \mathbb{R}$ 。標量導數 $Df(x)$ 是 $1 \times n$ 線性泛函；在 Euclidean 內積下，其表示為 $\nabla f(x)^T$ ，其中梯度是 $n \times 1$ 。若 Df 在 x Fréchet 可微，則二階導數 $D^2 f(x)$ 是把兩個輸入擾動映至實數的雙線性映射：

$$D^2 f(x)[u, v] = D(Df)(x)[u][v].$$

方括號的次序指出：先以 u 擾動導數，再將得到的線性泛函作用於 v 。

這裏的「 Df 可微」有比「列出二階偏導數」更完整的意思。以線性泛函的算子範數衡量，存在一個把 u 映至線性泛函的線性映射，使

$$Df(x+u) = Df(x) + D(Df)(x)[u] + R(u), \quad \frac{\|R(u)\|_{\text{op}}}{\|u\|} \rightarrow 0.$$

對每個固定的 v ， $D(Df)(x)[u]$ 再作用於 v ，便得到 $D^2 f(x)[u, v]$ 。由於前一步對 u 線性、後一步對 v 線性，這個物件是雙線性的。它不是「先挑一個方向作兩次有限差分」的數值操作。

選定標準座標後，定義矩陣元素為

$$(H_f(x))_{ij} = D^2 f(x)[e_i, e_j] = \partial_i(\partial_j f)(x), \quad D^2 f(x)[u, v] = u^T H_f(x) v.$$

最後一式可由 $u = \sum_i u_i e_i$ 、 $v = \sum_j v_j e_j$ 及雙線性逐項展開得到。它也說明形狀：左邊是純量，右邊依次為 $1 \times n$ 、 $n \times n$ 、 $n \times 1$ 的乘積。若採用不同的混合偏導書寫慣例，須留意微分次序；本章在 C^2 條件下兩個次序相等。

Hessian 因而是雙線性映射在所選座標下的矩陣，維度為 $n \times n$ ；二階方向導數 $D^2 f(x)[h, h]$ 則是一個純量。對向量值映射，其二階導數有向量輸出，不能不加說明便稱為單一 Hessian 矩陣。換座標時，雙線性映射仍是同一個局部變化資訊，矩陣中的數字卻可能不同。

定理一：混合偏導的對稱性（充分條件）。 若 $f \in C^2(U)$ ，即所有二階偏導在開集 U 連續，則對每個 $x \in U$ ，

$$H_f(x)^T = H_f(x), \quad D^2 f(x)[u, v] = D^2 f(x)[v, u].$$

這是常用的充分條件，不是說「二階偏導只要在一點存在就必然相等」。此處引用混合偏導交換定理；其適用條件包含所述鄰域上的連續性。 C^2 也保證本章所用的導數與連續 Hessian 均有定義；反過來說，二階導數在某一點存在，不等於宣稱整個鄰域都是 C^2 。

定理二：二階 Taylor 展開。 若 $f \in C^2(U)$ ，且 $x \in U$ ，則當 $h \rightarrow 0$ 且 $x+h \in U$ 時，

$$f(x+h) = f(x) + \nabla f(x)^T h + \frac{1}{2} h^T H_f(x) h + r_2(h), \quad \frac{r_2(h)}{\|h\|^2} \rightarrow 0.$$

這個極限要求所有充分小的非零 h ，不是只沿一條直線或一組取樣方向成立。式中的二次多項式只使用基點 x 的函數值、梯度和 Hessian；附近其他點的 Hessian 如何變化，則反映在餘項內。

小命題與完整證明：積分餘項及其二階界。 假設 $f \in C^2(U)$ ，且線段 $\{x+th : 0 \leq t \leq 1\}$ 包含於 U 。記 $g(t) = f(x+th)$ 。則

$$f(x+h) = f(x) + \nabla f(x)^T h + \int_0^1 (1-t) h^T H_f(x+th) h dt,$$

並且，若線段上滿足 $\|H_f(x+th) - H_f(x)\|_2 \leq \varepsilon$ ，則

$$|r_2(h)| \leq \frac{\varepsilon}{2} \|h\|^2.$$

證明。鏈式法則給出 $g'(t) = \nabla f(x+th)^T h$ 及 $g''(t) = h^T H_f(x+th) h$ 。由微積分基本定理，

$$g(1) - g(0) - g'(0) = \int_0^1 \int_0^s g''(t) dt ds = \int_0^1 (1-t) g''(t) dt.$$

這得到積分公式。扣除 $\frac{1}{2} h^T H_f(x) h$ ，並利用 $\int_0^1 (1-t) dt = \frac{1}{2}$ ，可得

$$r_2(h) = \int_0^1 (1-t) h^T [H_f(x+th) - H_f(x)] h dt.$$

由算子範數不等式 $|h^T A h| \leq \|A\|_2 \|h\|^2$ ，立刻得到所宣稱的界。證畢。

此證明也解釋定理二的餘項： x 是開集內點，故充分短的線段仍在 U ； H_f 在 x 連續，使整條短線段上的差異上界能隨 $\|h\| \rightarrow 0$ 而趨零。因此所得恰是 $o(\|h\|^2)$ 。這是由連續性與積分不等式作出的全方向論證，並非從有限條路徑歸納而來。

較強界的充分條件。 若上述線段所在鄰域內的 Hessian 滿足

$$\|H_f(y) - H_f(z)\|_2 \leq L \|y - z\|,$$

則積分餘項進一步給出

$$|r_2(h)| \leq L \|h\|^3 \int_0^1 t(1-t) dt = \frac{L}{6} \|h\|^3.$$

因此，局部 Lipschitz 的 Hessian 足以保證三階界；例如連續三階導數在適當的小閉球上有界時，可取得這類界。僅有 C^2 不保證它。這裏的 L 必須對所討論的鄰域有效，不能從單點 Hessian 的數值憑空指定。

逐步手算例題

例一：完整 Hessian 與交叉項。 令

$$f(x, y) = x^2 + 3xy + 2y^2 + x^3, \quad a = (1, -1)^T.$$

逐項微分得

$$\nabla f(x, y) = \begin{pmatrix} 2x + 3y + 3x^2 \\ 3x + 4y \end{pmatrix}, \quad H_f(x, y) = \begin{pmatrix} 2 + 6x & 3 \\ 3 & 4 \end{pmatrix}.$$

在 a ， $f(a) = 1 - 3 + 2 + 1 = 1$ 、 $\nabla f(a) = (2, -1)^T$ ，且

$$H_f(a) = \begin{pmatrix} 8 & 3 \\ 3 & 4 \end{pmatrix}.$$

令 $h = (s, t)^T$ ，二階項是

$$\frac{1}{2}h^T H_f(a)h = \frac{1}{2}(8s^2 + 6st + 4t^2) = 4s^2 + 3st + 2t^2.$$

直接將 $(1 + s, -1 + t)$ 代入原函數並展開，可核對

$$f(a + h) = 1 + 2s - t + 4s^2 + 3st + 2t^2 + s^3.$$

因此此例的**精確**餘項是 s^3 。方向不同會改變餘項：沿 $s = 0$ 它恆為零，但這不表示所有方向都沒有三階誤差。

例二：二階方向差分與有限步長誤差。 令

$$q(x, y) = x^2 + 2xy + 3y^2, \quad v = (2, -1)^T.$$

其 Hessian 恆為

$$H_q = \begin{pmatrix} 2 & 2 \\ 2 & 6 \end{pmatrix}, \quad H_q v = (2, -2)^T, \quad v^T H_q v = 6.$$

在任意基點 a ，直接展開 $q(a + tv)$ 與 $q(a - tv)$ ：常數項合成 $2q(a)$ ，一次項互相抵消，兩個二次項合計為 $t^2 v^T H_q v$ 。因此

$$\frac{q(a + tv) - 2q(a) + q(a - tv)}{t^2} = 6 \quad (t \neq 0).$$

這是二次多項式的代數恆等式，與「一般光滑函數於有限 t 必定精確」不同。中心差分也會消去三次多項式沿直線展開所得的奇次項：本章例一最高為三次，所以其中心二階方向差分對任意基點與方向同樣精確。一般光滑函數若沿所選直線含四次或更高偶次項，有限步長才可能留下偏差；縮小步長可觀察趨勢，但仍須留意浮點捨入。先寫出 $g(t) + g(-t)$ ，再判斷哪些項保留，比籠統地把所有高次項都稱作差分誤差更可靠。

實作與程式

以下程式只使用 Python 標準庫，在 CPU 上計算二變量多項式。它同時檢查完整 Hessian、交叉項、Taylor 餘項，以及中心二階方向差分。hessian_fd 用函數值重建矩陣：對角元使用中心二階差分，非對角元使用四角混合差分。這些公式在有限步長與有限精度下是估計，並非 Hessian 存在性的定義或證明。

```
from math import hypot, isfinite

def f(x, y):
    return x*x + 3*x*y + 2*y*y + x*x*x

def grad(x, y):
    return (2*x + 3*y + 3*x*x, 3*x + 4*y)

def hessian(x, y):
    return ((2 + 6*x, 3.0), (3.0, 4.0))

def quadratic(H, v):
    s, t = v
    return s*(H[0][0]*s + H[0][1]*t) + \
        t*(H[1][0]*s + H[1][1]*t)

def taylor_error(a, h):
    x, y = a
    s, t = h
    g = grad(x, y)
    H = hessian(x, y)
    model = f(x, y) + g[0]*s + g[1]*t + 0.5*quadratic(H, h)
    return f(x+s, y+t) - model

def directional_fd(a, v, step):
    if not isfinite(step) or step <= 0:
        raise ValueError("step must be finite and positive")
    x, y = a
    s, t = v
    return (f(x+step*s, y+step*t) - 2*f(x, y)
            + f(x-step*s, y-step*t)) / (step*step)

def hessian_fd(a, step):
    if not isfinite(step) or step <= 0:
        raise ValueError("step must be finite and positive")
    x, y = a
    z = f(x, y)
    dxx = (f(x+step, y) - 2*z + f(x-step, y)) / step**2
    dyy = (f(x, y+step) - 2*z + f(x, y-step)) / step**2
    dxy = (f(x+step, y+step) - f(x+step, y-step)
            - f(x-step, y+step) + f(x-step, y-step)) / (4*step**2)
    return ((dxx, dxy), (dxy, dyy))

a = (1.0, -1.0)
v = (1.0, 2.0)
H = hessian(*a)
print("Hessian:", H)
print("v^T H v:", quadratic(H, v))
print("function-value Hessian estimate:", hessian_fd(a, 1e-3))
for step in (0.2, 0.1, 0.05):
```

```

h = (step*v[0], step*v[1])
error = taylor_error(a, h)
scale = hypot(*h)
print("step, error, error/norm^2:",
      step, error, error/(scale*scale))
print("directional estimate:", directional_fd(a, v, 1e-3))

```

此程式的輸入座標與函數值均視為無因次。若實際輸入帶不同單位，必須先指定各分量尺度，或逐一追蹤 Hessian 元素的「輸出單位／兩個輸入單位之積」；不能直接把混合單位的 Euclidean 長度當作物理誤差尺度。

兩種數值檢查的目的亦不同。`directional_fd` 把函數限制在一條直線上，只估計該方向的單一二階量；`hessian_fd` 則分別擾動兩個座標，以估計整個二乘二矩陣。即使前者與解析答案吻合，仍可能有非對角元寫錯而未被察覺；因此應同時檢查矩陣元素及至少一個含兩個非零分量的方向。步長過大可能掩蓋非多項式函數的局部行為，極小步長則可能使相近函數值相減而損失有效數字。掃描步長應包含中等值，不以「越小越準」作無條件規則。

測試與預期結果

以下皆為**未執行程式的預期**，不是測試通過紀錄。

類別	操作	預期與判讀
正常	取 $a = (1, -1)^T$ 、 $v = (1, 2)^T$	$H_f(a) = \begin{pmatrix} 8 & 3 \\ 3 & 4 \end{pmatrix}$ ， $v^T H_f(a) v = 36$ ；步長 10^{-3} 的差分估計應接近這些解析值。
餘項	依程式用 $h = \text{step } v$	精確餘項為 step^3 ，而 $ h ^2 = 5\text{step}^2$ ；故比值依次預期為 0.04, 0.02, 0.01，容許浮點捨入。
邊界	取 $h = (0, 0)^T$	<code>taylor_error</code> 為零；但不可計算 $\text{error}/\text{norm}^2$ ，因分母為零。程式的比值迴圈刻意只用非零步長。
故障	呼叫 <code>directional_fd(a, v, 0)</code> 或 <code>hessian_fd(a, -1)</code>	應拋出 <code>ValueError</code> ，而不是做零除或默默接受無效步長。

有限差分的正常輸出可核對實作、揭露交叉係數錯誤；即使一系列比值下降，也不能證明任意函數在所有方向滿足二階 Taylor 定理。對本例而言，餘項比值的預期數字先由精確代數式推出，程式只是核對該推導。

反例與常見陷阱

首先， C^2 所給的 $o(\|h\|^2)$ 不能擅自升級為三階界。在實數線上令 $F(z) = |z|^{5/2}$ 。它在零附近有連續的二階導數，且 $F(0) = F'(0) = F''(0) = 0$ ，所以零點的二階 Taylor 多項式為零，餘項是 $|h|^{5/2} = o(h^2)$ 。然而

$$\frac{|h|^{5/2}}{|h|^3} = |h|^{-1/2} \rightarrow \infty;$$

因此該餘項不是 $O(|h|^3)$ 。

其次，二階偏導的符號及順序必須與定義一致。若只在某一點取得幾個偏導數，卻沒有足以交換混合偏導的鄰域條件，不能直接宣稱 Hessian 對稱；也不能拿數值矩陣的近似對稱作解析證明。

再者，對稱 Hessian 的交叉項在 $h^T H h$ 中出現兩次。把 $\frac{1}{2}h^T H h$ 誤寫成「每個非對角元各乘 $\frac{1}{2}$ 後只留一項」，會少算一半。另一方面，中心二階差分消去奇次項；不能把三次項說成它在有限步長下必然留下的偏差。

最後，對固定方向 v 觀察

$$\frac{f(x + tv) - 2f(x) + f(x - tv)}{t^2}$$

只是在檢查該方向的二階行為。若已有本章定理的條件，其極限才可辨識為 $v^T H_f(x)v$ ；有限個方向的吻合不足以建立全空間的二階可微性。

AI、幾何與養殖案例

考慮純合成的雙參數感測校準量：溫度偏移 ΔT 以 K 計，鹽度代理量偏移 ΔS 以指定的無因次單位計，輸出 ϕ 是無因次模型分數。先選尺度 $T_* = 1 \text{ K}$ 、 $S_* = 0.1$ ，定義 $z_1 = \Delta T/T_*$ 、 $z_2 = \Delta S/S_*$ ，再令

$$\phi(z_1, z_2) = z_1^2 + 3z_1z_2 + 2z_2^2 + z_1^3.$$

這只是展示局部計算的合成函數，不是感測器物理定律。在 $z = (1, -1)^T$ 附近，本章例一的 Hessian 可直接描述分數對無因次擾動的二階變化。若返回原輸入 $p = (\Delta T, \Delta S)^T$ ，寫 $z = S p$ ，其中 $S = \text{diag}(1/T_*, 1/S_*)$ ，則

$$H_p = S^T H_z S.$$

因此不能把無因次 Hessian 的數字原樣貼到有因次參數上；混合元素的單位與兩個輸入尺度都相關。這個變換式適用於此處線性的尺度變換；若座標變換本身是非線性的，二階鏈式法則還會有額外項，不能直接照抄。

幾何上， $h^T H h$ 描述指定方向的局部二次變化，但若座標改變，矩陣表示也須相應改變。AI 輔助整理時，可以列出解析式、尺度、差分步長、預期輸出及失效條件；不得把合成校準說成現場驗證，更不得據此控制設備、投餌或加藥。這裏的 agent 角色僅是唯讀整理證據，數學近似不等於操作安全結論。

習題

1. **手算**。對 $p(x, y) = 2x^2 - 4xy + y^2$ ，求 Hessian，並計算 $h = (s, t)^T$ 時的 $\frac{1}{2}h^T H_p h$ 。另求 $v = (1, 2)^T$ 的二階方向導數。
2. **程式**。修改本程式，使其列印 $v = (1, 2)^T$ 、步長依次為 0.2, 0.1, 0.05 時的 `directional_fd`。先不用執行程式，解析求出每個預期值；並說明為何步長極小時不宜要求逐位精確相等。
3. **反例**。對 $F(z) = |z|^{5/2}$ ，直接求零點附近的一、二階導數，證明其零點二階 Taylor 餘項是 $o(h^2)$ ，卻不是 $O(|h|^3)$ 。
4. **整合**。設無因次校準模型 $\psi(z) = z_1^2 + 2z_1z_2 + 3z_2^2$ ，其中 $z_1 = \Delta T/(2\text{ K})$ 、 $z_2 = \Delta S/0.5$ 。求對 z 的 Hessian、對有因次輸入 $p = (\Delta T, \Delta S)^T$ 的 Hessian，以及 p 沿 $(0.2\text{ K}, 0.05)^T$ 擾動時，從 $p = 0$ 算起的精確函數增量。說明所用公式為何在此沒有餘項。

習題解答

1. 逐項微分得到

$$H_p = \begin{pmatrix} 4 & -4 \\ -4 & 2 \end{pmatrix}.$$

因此

$$\frac{1}{2}h^T H_p h = 2s^2 - 4st + t^2.$$

對 $v = (1, 2)^T$ ， $H_p v = (-4, 0)^T$ ，故 $D^2 p(x)[v, v] = v^T H_p v = -4$ 。二次多項式的 Hessian 不依賴基點。

2. 可在現有程式末尾加入：

```
for step in (0.2, 0.1, 0.05):  
    print(step, directional_fd(a, v, step))
```

對本章的 f ，在 $a = (1, -1)^T$ ， $v^T H_f(a)v = 36$ 。沿 $a + tv$ 的 Taylor 展開含三次項 t^3 ；中心相加時， t^3 與 $(-t)^3$ 抵消，所以三個步長的解析預期值全是 36。實際浮點計算會將相近函數值相減再除以 step^2 ，可能產生捨入誤差；步長過小時尤其不應要求逐位精確相等。

3. 當 $z > 0$ ， $F'(z) = \frac{5}{2}z^{3/2}$ 、 $F''(z) = \frac{15}{4}z^{1/2}$ ；當 $z < 0$ ， $F'(z) = -\frac{5}{2}|z|^{3/2}$ 、 $F''(z) = \frac{15}{4}|z|^{1/2}$ 。利用差商可得 $F'(0) = F''(0) = 0$ ，且 $F'''(z) \rightarrow 0$ ，故 $F \in C^2$ 。零點二階多項式為零，餘項比 h^2 是 $|h|^{1/2} \rightarrow 0$ ；餘項比 $|h|^3$ 則是 $|h|^{-1/2} \rightarrow \infty$ ，所以不存在所需的局部固定上界常數。

4. 無因次 Hessian 為

$$H_z = \begin{pmatrix} 2 & 2 \\ 2 & 6 \end{pmatrix}.$$

取 $S = \text{diag}(1/(2K), 1/0.5)$ ，由 $H_p = S^T H_z S$ 得到以指定輸入單位記數的矩陣

$$H_p = \begin{pmatrix} 0.5 & 2 \\ 2 & 24 \end{pmatrix}.$$

其元素的單位須按各輸入分量分別解讀，不能視為相同量綱。給定擾動對應的無因次向量是 $(0.1, 0.1)^T$ ，所以

$$\psi(0.1, 0.1) - \psi(0, 0) = 0.01 + 0.02 + 0.03 = 0.06.$$

ψ 恰為二次多項式，沒有三次或更高次項；從原點作二階 Taylor 展開因而是精確等式。

本章小結

二階導數本質上是雙線性映射；Hessian 是它在座標中的表示，二階方向變化由 $h^T H h$ 給出。在 C^2 鄰域條件下，Hessian 對稱，二階 Taylor 餘項為 $o(\|h\|^2)$ 。若另有局部 Lipschitz Hessian，才可由本章的積分餘項取得明確的三階界。手算展開能核對交叉項，CPU 差分能檢查實作與觀察趨勢；兩者都不能取代涵蓋所有充分小擾動的證明。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*, 作者教材入口：<https://www.jirka.org/ra/>
- [A2] MIT OCW, *18.100A Real Analysis*：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- [A3] MIT OCW, *18.02SC Multivariable Calculus*：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

以上列為分析與多變量微積分的延伸入口；本章證明及程式均已在文內寫出，並未聲稱逐條核對教材全文或執行程式。

第14章 駐點、二次型與退化極值

學習目標與先備知識

本章聚焦於多變量可微函數在無約束情況下尋找局部極值（local extrema）的嚴格方法。我們不再依賴單變量微積分中簡單的二階導數符號判斷，而是引入**Hessian矩陣**（Hessian matrix）與**二次型**（quadratic form）的概念。

學習者需具備以下先備知識：

- Fréchet導數與Jacobian**：理解 $f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + Df(\mathbf{x})[\mathbf{h}] + o(\|\mathbf{h}\|)$ 的結構。特別是當 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 時，Fréchet導數 $Df(\mathbf{x})$ 是一個線性泛函，對應一個 $1 \times n$ 的矩陣 $J_f(\mathbf{x}) = (\nabla f(\mathbf{x}))^T$ 。其中 $\nabla f(\mathbf{x}) \in \mathbb{R}^{n \times 1}$ 是Euclidean梯度（列向量）。
- Taylor展開的幾何意義**：理解 f 在點 $\mathbf{x}_0$ 附近的行為主要由一階項（切平面）和二階項（拋物面近似）決定。
- 線性代數基礎**：熟悉對稱矩陣的特徵值分解、正定（positive definite）、半正定（positive semi-definite）、負定（negative definite）及不定（indefinite）矩陣的定義與判別方法。
- 必要條件與充分條件的邏輯區別**：
 - 必要條件（Necessary Condition）**：若性質 Q 成立，則必須滿足條件 P （即 $Q \implies P$ ）。若 P 不成立，則 Q 必不成立。
 - 充分條件（Sufficient Condition）**：若條件 P 成立，則保證性質 Q 成立（即 $P \implies Q$ ）。

本章的核心目標是建立一套完整的邏輯鏈條：

- 從 $\nabla f(\mathbf{x}_0) = \mathbf{0}$ （駐點必要條件）出發。
- 分析二階變分（二次型） $\mathbf{h}^T \nabla^2 f(\mathbf{x}_0) \mathbf{h}$ 的符號。
- 處理Hessian矩陣奇異（singular）或半正定/半負定時的「退化極值」（degenerate extrema）問題。
- 透過具體反例說明為何半正定Hessian不能保證極值，以及為何相同的Hessian結構（如零矩陣）可能對應不同的極值型態，取決於高階項。

問題與直覺

在單變量微積分中，若 $f'(x_0) = 0$ 且 $f''(x_0) > 0$ ，則 x_0 是局部極小值。若 $f''(x_0) < 0$ ，則是局部極大值。若 $f''(x_0) = 0$ ，我們往往無法判斷，需檢查更高階導數。

在多變量情況下，一階必要條件是向量 $\nabla f(\mathbf{x}_0) = \mathbf{0}$ 。此時，函數在 $\mathbf{x}_0$ 附近的變化率主要由Hessian矩陣 $H = \nabla^2 f(\mathbf{x}_0)$ 控制。直覺上，如果 H 在所有方向上都產生正的曲率，則 $\mathbf{x}_0$ 應為局部極小值；如果 H 在所有方向上都產生負的曲率，則為局部極大值。

然而，多變量的複雜性在於：

1. **方向的多樣性**： $\mathbf{h}$ 可以指向 $\mathbb{R}^n$ 中的任意方向。即使Hessian在兩個主軸方向上為正，若在某個斜交方向上為負，則該點只能是**鞍點** (saddle point)。
2. **退化情況**：當Hessian半正定（某些方向曲率為零）時，二階近似失效。此時，決定極值型態的將是更高階的Taylor項（如三階、四階項）或餘項 $r(\mathbf{h})$ 。這意味著，僅憑二階資訊無法下結論，必須分析高階項或函數結構。

直覺比喻：

- **正定Hessian**：就像站在碗底。無論朝哪個方向走，高度都上升。
- **負定Hessian**：就像站在碗頂（倒扣的碗）。無論朝哪個方向走，高度都下降。
- **不定Hessian**：就像站在馬鞍上。沿著馬背方向走高度下降，沿著馬脊方向走高度上升。
- **半正定Hessian**：就像站在平坦的桌上。二階角度看是平的，但桌面上可能有極微小的起伏（由三階及以上項決定），這些起伏可能導致局部極小、局部極大，或者既非極小也非極大。

定義、定理與推導

1. 駐點的必要條件

定義 14.1 (駐點/Critical Point) 設 $f : U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ 在開集 U 上可微，且 $\mathbf{x}_0 \in U$ 。若 $\nabla f(\mathbf{x}_0) = \mathbf{0}$ （即 $Df(\mathbf{x}_0)$ 為零映射），則稱 $\mathbf{x}_0$ 為 f 的**駐點**或**臨界點**。

定理 14.1 (一階必要條件) 若 f 在 $\mathbf{x}_0$ 處取得局部極值（極小或極大），且 f 在 $\mathbf{x}_0$ 處可微，則 $\nabla f(\mathbf{x}_0) = \mathbf{0}$ 。

證明：設 $\mathbf{x}_0$ 是局部極小值點。則存在 $\delta > 0$ ，使得對任意 $\mathbf{x}$ 滿足 $\|\mathbf{x} - \mathbf{x}_0\| < \delta$ ，有 $f(\mathbf{x}) \geq f(\mathbf{x}_0)$ 。考慮方向 $\mathbf{u} \in \mathbb{R}^n$ 且 $\|\mathbf{u}\| = 1$ 。定義單變量函數 $\phi(t) = f(\mathbf{x}_0 + t\mathbf{u})$ 。對於足夠小的 t ， $\mathbf{x}_0 + t\mathbf{u}$ 仍在 $\mathbf{x}_0$ 的鄰域內。因此， $\phi(t)$ 在 $t = 0$ 處取得局部極小值。由單變量微積分定理， $\phi'(0) = 0$ 。由鏈式法則， $\phi'(0) = Df(\mathbf{x}_0)[\mathbf{u}] = \nabla f(\mathbf{x}_0)^T \mathbf{u}$ 。由於 $\mathbf{u}$ 是任意單位向量，若 $\nabla f(\mathbf{x}_0) \neq \mathbf{0}$ ，我們可以選擇 $\mathbf{u} = -\frac{\nabla f(\mathbf{x}_0)}{\|\nabla f(\mathbf{x}_0)\|}$ ，此時 $\phi'(0) = -\|\nabla f(\mathbf{x}_0)\| < 0$ ，這意味著在 $t > 0$ 且足夠小時 $f(\mathbf{x}_0 + t\mathbf{u}) < f(\mathbf{x}_0)$ ，與極小值定義矛盾。故 $\nabla f(\mathbf{x}_0) = \mathbf{0}$ 。■

注意：此定理僅針對**內點**。若 $\mathbf{x}_0$ 在邊界上，必要條件變為 KKT 條件（見後續章節）。本章僅討論無約束內點。

2. Hessian、二次型與二階必要/充分條件

設 $f \in C^2(U)$ 。根據二階Taylor定理，存在餘項 $r(\mathbf{h})$ 使得：

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^T \mathbf{h} + \frac{1}{2} \mathbf{h}^T \nabla^2 f(\mathbf{x}_0) \mathbf{h} + r(\mathbf{h})$$

其中 $\lim_{\|\mathbf{h}\| \rightarrow 0} \frac{r(\mathbf{h})}{\|\mathbf{h}\|^2} = 0$ 。

若 $\mathbf{x}_0$ 是駐點， $\nabla f(\mathbf{x}_0) = \mathbf{0}$ ，則：

$$f(\mathbf{x}_0 + \mathbf{h}) - f(\mathbf{x}_0) = \frac{1}{2} \mathbf{h}^T H \mathbf{h} + r(\mathbf{h})$$

其中 $H = \nabla^2 f(\mathbf{x}_0)$ 是Hessian矩陣。定義二次型 $q(\mathbf{h}) = \mathbf{h}^T H \mathbf{h}$ 。

定義 14.2 (矩陣的正定性) 設 $H \in \mathbb{R}^{n \times n}$ 為對稱矩陣。

- H 是**正定** (PD) 的，若對所有 $\mathbf{h} \neq \mathbf{0}$ ， $\mathbf{h}^T H \mathbf{h} > 0$ 。
- H 是**負定** (ND) 的，若對所有 $\mathbf{h} \neq \mathbf{0}$ ， $\mathbf{h}^T H \mathbf{h} < 0$ 。
- H 是**半正定** (PSD) 的，若對所有 $\mathbf{h} \in \mathbb{R}^n$ ， $\mathbf{h}^T H \mathbf{h} \geq 0$ 。
- H 是**半負定** (NSD) 的，若對所有 $\mathbf{h} \in \mathbb{R}^n$ ， $\mathbf{h}^T H \mathbf{h} \leq 0$ 。
- 若 H 既不為半正定也不為半負定，則稱 H 為**不定** (Indefinite)。

命題 14.2 (二階必要條件) 設 $f \in C^2(U)$ 且 $\mathbf{x}_0$ 是 f 的局部極小值點（或極大值點）。

1. 若 $\mathbf{x}_0$ 是局部極小值，則 $H = \nabla^2 f(\mathbf{x}_0)$ 是半正定的。
2. 若 $\mathbf{x}_0$ 是局部極大值，則 H 是半負定的。

證明：以局部極小值為例。對任意方向 $\mathbf{u} \in \mathbb{R}^n$ ，定義 $\phi(t) = f(\mathbf{x}_0 + t\mathbf{u})$ 。由於 $\mathbf{x}_0$ 是局部極小值， $\phi(0)$ 是 ϕ 的局部極小值。因此， $\phi''(0) \geq 0$ 。由鏈式法則：

$$\phi'(t) = \nabla f(\mathbf{x}_0 + t\mathbf{u})^T \mathbf{u}$$

$$\phi''(t) = \mathbf{u}^T \nabla^2 f(\mathbf{x}_0 + t\mathbf{u}) \mathbf{u}$$

在 $t = 0$ 時：

$$\phi''(0) = \mathbf{u}^T \nabla^2 f(\mathbf{x}_0) \mathbf{u} = \mathbf{u}^T H \mathbf{u} \geq 0$$

由於 $\mathbf{u}$ 任意，故 H 半正定。局部極大推出Hessian半負定的證明類同。■

定理 14.3 (二階充分條件) 設 $f \in C^2(U)$ 且 $\mathbf{x}_0$ 是駐點 ($\nabla f(\mathbf{x}_0) = 0$)。

1. 若 H 是正定的，則 $\mathbf{x}_0$ 是 f 的**嚴格局部極小值點**。
2. 若 H 是負定的，則 $\mathbf{x}_0$ 是 f 的**嚴格局部極大值點**。
3. 若 H 是不定的，則 $\mathbf{x}_0$ 既不是局部極小值點也不是局部極大值點（即為鞍點）。

證明：由譜定理，對稱矩陣 H 可正交對角化： $H = Q\Lambda Q^T$ ，其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 。

$$\mathbf{h}^T H \mathbf{h} = \mathbf{h}^T Q \Lambda Q^T \mathbf{h} = (Q^T \mathbf{h})^T \Lambda (Q^T \mathbf{h}) = \sum_{i=1}^n \lambda_i y_i^2$$

其中 $\mathbf{y} = Q^T \mathbf{h}$ 。由於 Q 是正交矩陣， $\|\mathbf{y}\| = \|\mathbf{h}\|$ 。

1. **正定情況：** $\lambda_i > 0$ 對所有 i 。設 $\lambda_{\min} = \min_i \lambda_i > 0$ 。

$$\frac{1}{2}\mathbf{h}^T H \mathbf{h} = \frac{1}{2} \sum \lambda_i y_i^2 \geq \frac{\lambda_{\min}}{2} \sum y_i^2 = \frac{\lambda_{\min}}{2} \|\mathbf{h}\|^2$$

由Taylor餘項性質，存在 $\delta_1 > 0$ 使得當 $0 < \|\mathbf{h}\| < \delta_1$ 時， $|r(\mathbf{h})| < \frac{\lambda_{\min}}{4} \|\mathbf{h}\|^2$ 。因 U 開且 $\mathbf{x}_0 \in U$ ，取 $\rho > 0$ 使 $B(\mathbf{x}_0, \rho) \subset U$ 。令 $\delta = \min(\delta_1, \rho)$ ，則對 $0 < \|\mathbf{h}\| < \delta$ ：

$$f(\mathbf{x}_0 + \mathbf{h}) - f(\mathbf{x}_0) \geq \frac{\lambda_{\min}}{2} \|\mathbf{h}\|^2 - \frac{\lambda_{\min}}{4} \|\mathbf{h}\|^2 = \frac{\lambda_{\min}}{4} \|\mathbf{h}\|^2 > 0$$

故 $f(\mathbf{x}_0 + \mathbf{h}) > f(\mathbf{x}_0)$ ，即嚴格局部極小。

2. 負定情況： $\lambda_i < 0$ 。設 $\lambda_{\max} = \max_i \lambda_i < 0$ 。

$$\mathbf{h}^T H \mathbf{h} \leq \lambda_{\max} \|\mathbf{h}\|^2$$

類似地， $f(\mathbf{x}_0 + \mathbf{h}) - f(\mathbf{x}_0) \leq \frac{\lambda_{\max}}{2} \|\mathbf{h}\|^2 + o(\|\mathbf{h}\|^2)$ 。對足夠小的 $\mathbf{h}$ ，差值 < 0 ，故為嚴格局部極大。

3. 不定情況：存在 $\mathbf{u}, \mathbf{v}$ 使得 $q(\mathbf{u}) = \mathbf{u}^T H \mathbf{u} > 0$ 且 $q(\mathbf{v}) = \mathbf{v}^T H \mathbf{v} < 0$ 。令 $\hat{\mathbf{u}} = \mathbf{u}/\|\mathbf{u}\|$ 、 $\hat{\mathbf{v}} = \mathbf{v}/\|\mathbf{v}\|$ ，設 $c_1 = \hat{\mathbf{u}}^T H \hat{\mathbf{u}} > 0$ 、 $c_2 = \hat{\mathbf{v}}^T H \hat{\mathbf{v}} < 0$ 。餘項性質給出 $r(t\hat{\mathbf{u}})/t^2 \rightarrow 0$ 與 $r(s\hat{\mathbf{v}})/s^2 \rightarrow 0$ 。對所有充分小的非零 t ，有 $|r(t\hat{\mathbf{u}})| < c_1 t^2/4$ ，所以

$$f(\mathbf{x}_0 + t\hat{\mathbf{u}}) - f(\mathbf{x}_0) > \frac{c_1}{4} t^2 > 0.$$

同理，對所有充分小的非零 s ，有 $|r(s\hat{\mathbf{v}})| < (-c_2)s^2/4$ ，所以

$$f(\mathbf{x}_0 + s\hat{\mathbf{v}}) - f(\mathbf{x}_0) < \frac{c_2}{4} s^2 < 0.$$

在任意 δ -鄰域內，既有 $f > f(\mathbf{x}_0)$ 也有 $f < f(\mathbf{x}_0)$ 的點，故 $\mathbf{x}_0$ 非極值點。■

3. 退化極值與不確定性

定理 14.4 (二階不確定性) 若 H 是半正定但非正定（即存在 $\mathbf{h}_0 \neq \mathbf{0}$ 使得 $\mathbf{h}_0^T H \mathbf{h}_0 = 0$ ），或半負定但非負定，則僅憑二階條件無法判斷 $\mathbf{x}_0$ 是否為局部極值。需另行分析餘項 $r(\mathbf{h})$ 、可用的高階Taylor項或函數具體結構。

直覺解釋：在零曲率方向 $\mathbf{h}_0$ 上，二階項 $\frac{1}{2}\mathbf{h}_0^T H \mathbf{h}_0$ 為零。函數值的變化完全取決於 $r(\mathbf{h})$ 或更高階項。若三階項主導，函數可能呈現非對稱變化；若四階項主導，可能呈現緩慢上升或下降，或者甚至因為正負四階項的存在而成為鞍點。

逐步手算例題

例題 14.1：二次函數與鞍點

考慮 $f(x, y) = x^2 - y^2$ 。

1. 找駐點： $\nabla f = \begin{pmatrix} 2x \\ -2y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x = 0, y = 0$ 。駐點為 $(0, 0)$ 。
2. 計算Hessian： $H = \begin{pmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$ 。
3. 判斷性質：特徵值為 $\lambda_1 = 2, \lambda_2 = -2$ 。一正一負，故 H 不定。根據定理 14.3(3)， $(0, 0)$ 是鞍點。
驗證：沿 $y = 0$ ， $f(x, 0) = x^2 \geq 0$ ；沿 $x = 0$ ， $f(0, y) = -y^2 \leq 0$ 。在原點附近既有更大值也有更小值。

例題 14.2：半正定Hessian與高階項影響（相同Hessian不同極值）

考慮 $f(x, y) = x^4$ 。

1. 找駐點： $\nabla f = \begin{pmatrix} 4x^3 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x = 0, y$ 任意。駐點集合為整個 y 軸。取 $\mathbf{x}_0 = (0, 0)$ 。
2. 計算Hessian： $H(0, 0) = \begin{pmatrix} \frac{\partial^2(x^4)}{\partial x^2} & \frac{\partial^2(x^4)}{\partial x \partial y} \\ \frac{\partial^2(x^4)}{\partial y \partial x} & \frac{\partial^2(x^4)}{\partial y^2} \end{pmatrix}_{(0,0)} = \begin{pmatrix} 12x^2 & 0 \\ 0 & 0 \end{pmatrix}_{(0,0)} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$ 。 H 是零矩陣，既半正定也半負定（且非正定/負定）。
3. 判斷性質：二階測試失敗。需看高階項。 $f(x, y) = x^4$ 。對任意 $x \neq 0$ ， $x^4 > 0$ 。且 $f(0, y) = 0$ 。因此，對所有 (x, y) ， $f(x, y) \geq f(0, 0)$ 。故 $(0, 0)$ 是局部極小值點（實際上是全局極小值點），儘管Hessian為零。

對照反例：考慮 $g(x, y) = -x^4$ 。

- 駐點： $(0, 0)$ （及 $x = 0$ 軸）。
- Hessian： $H_g(0, 0) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$ 。
- 性質： $g(x, y) = -x^4 \leq 0$ ，故 $(0, 0)$ 是局部極大值點。
- 結論： f 和 g 在 $(0, 0)$ 處擁有完全相同的Hessian（零矩陣），但極值型態不同（一個極小，一個極大）。這證明了退化情況下必須分析高階項。

例題 14.3：混合項與正定性檢查

考慮 $f(x, y) = x^2 + 2xy + 3y^2$ 。

1. 找駐點： $\nabla f = \begin{pmatrix} 2x + 2y \\ 2x + 6y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x = -y, x + 3y = 0 \implies 2y = 0 \implies y = 0, x = 0$ 。
駐點 $(0, 0)$ 。
2. 計算Hessian： $H = \begin{pmatrix} 2 & 2 \\ 2 & 6 \end{pmatrix}$ 。

3. **判斷正定性**：使用Sylvester判據 (Lead principal minors)： $D_1 = 2 > 0$ 。 $D_2 = \det(H) = 2(6) - 2(2) = 12 - 4 = 8 > 0$ 。所有主階行列式為正，故 H 正定。結論： $(0, 0)$ 是**嚴格局部極小值點**。

實作與程式

以下提供一段自足的 Python 程式，使用 NumPy 實現：

1. 驗證輸入矩陣是否為有限值的方陣。
2. 檢查對稱性；若偏差超過容差則報錯，若小於容差則對稱化。
3. 計算特徵值並判斷正/負/半定。
4. 處理退化情況（特徵值接近零）並發出警告。

```
import numpy as np

def classify_hessian(H, tol=1e-8):
    """
    根據特徵值分類Hessian矩陣的性質。
    H: (n, n) 矩陣
    tol: 判定零值及對稱偏差的容差
    返回: 字串 "positive definite", "negative definite",
          "indefinite (saddle point)",
          "numerically indeterminate (opposite signs near zero)",
          "numerically indeterminate (eigenvalue near zero)"，或 "error: ..."
    近零分類只表示依指定容差無法可靠判別，不是精確半定性的證明。
    """
    # 1. 檢查形狀與有限性
    if H.ndim != 2 or H.shape[0] != H.shape[1]:
        return "error: Hessian must be a square matrix"
    if not np.all(np.isfinite(H)):
        return "error: Hessian contains non-finite values"

    # 2. 檢查對稱性
    sym_diff = np.linalg.norm(H - H.T)
    if sym_diff > tol:
        # 如果偏差大，可能是不對稱的錯誤輸入或數值不穩定，不自動修正
        return f"error: Hessian is not symmetric (norm diff {sym_diff:.2e}). Check gradient calculation."

    # 3. 對稱化（僅在偏差極小時）
    H_sym = (H + H.T) / 2

    # 4. 容差帶內的特徵值不證明精確半定性
    eigvals = np.linalg.eigvalsh(H_sym)
    eig_tol = tol * max(1.0, np.linalg.norm(H_sym, ord=2))
    if np.any(np.abs(eigvals) <= eig_tol):
        if np.any(eigvals > 0) and np.any(eigvals < 0):
            return "numerically indeterminate (opposite signs near zero)"
        return "numerically indeterminate (eigenvalue near zero)"
    if np.all(eigvals > 0):
        return "positive definite"
    if np.all(eigvals < 0):
        return "negative definite"
    return "indefinite (saddle point)"
```

```

def analyze_critical_point(func, grad, hess, x0, tol=1e-8):
    """
    分析給定點 x0 的極值性質。
    """
    g = grad(x0)
    if np.linalg.norm(g) > tol:
        return "Not a critical point"

    H = hess(x0)
    status = classify_hessian(H, tol)

    if status == "positive definite":
        return "Strict local minimum"
    elif status == "negative definite":
        return "Strict local maximum"
    elif status == "indefinite (saddle point)":
        return "Saddle point"
    elif status.startswith("error"):
        return f"Analysis Failed: {status}"
    else:
        return f"Indeterminate (Hessian {status}), need higher-order analysis"

# 測試函數
def f1(x): return x[0]**2 - x[1]**2
def g1(x): return np.array([2*x[0], -2*x[1]])
def h1(x): return np.array([[2, 0], [0, -2]])

def f2(x): return x[0]**4
def g2(x): return np.array([4*x[0]**3, 0])
def h2(x): return np.array([[12*x[0]**2, 0], [0, 0]])

def f3(x): return x[0]**2 + 2*x[0]*x[1] + 3*x[1]**2
def g3(x): return np.array([2*x[0]+2*x[1], 2*x[0]+6*x[1]])
def h3(x): return np.array([[2, 2], [2, 6]])

if __name__ == "__main__":
    # Case 1: Saddle point
    res1 = analyze_critical_point(f1, g1, h1, np.array([0.0, 0.0]))
    print(f"Case 1 (x^2 - y^2): {res1}")
    assert res1 == "Saddle point", f"Expected Saddle point, got {res1}"

    # Case 2: Degenerate minimum
    res2 = analyze_critical_point(f2, g2, h2, np.array([0.0, 0.0]))
    print(f"Case 2 (x^4): {res2}")
    assert "Indeterminate" in res2, f"Expected Indeterminate, got {res2}"

    # 預期故障與近零異號測試；尚未執行
    bad = classify_hessian(np.array([[1.0, 2.0], [0.0, 1.0]]))
    assert bad.startswith("error: Hessian is not symmetric")
    tiny = classify_hessian(np.diag([-5e-9, 5e-9]))
    assert tiny.startswith("numerically indeterminate")

    # Case 3: Positive Definite
    res3 = analyze_critical_point(f3, g3, h3, np.array([0.0, 0.0]))
    print(f"Case 3 (Quad): {res3}")
    assert res3 == "Strict local minimum", f"Expected Min, got {res3}"

```

```
print("All tests passed (expected results).")
```

程式說明：

- 本程式僅執行本地邏輯驗證，不涉及外部API。
- `classify_hessian` 中加入了對稱性檢查。若 H 嚴重不對稱，則回報錯誤，避免掩蓋潛在的梯度計算錯誤。
- 測試斷言 (assert) 確保了程式邏輯符合預期。由於未實際執行，這裡標註為「預期結果」。

測試與預期結果

以下列出正常、鞍點、退化邊界與故障四類預期測試。程式未經執行；列出的結果是依分支邏輯推算，不能代替實際執行紀錄或極值定理的證明。

1. 正常情況 (Positive Definite)：

- 函數： $f(x) = x^T A x$ ，其中 $A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$ 。
- 駐點： $(0, 0)$ 。
- Hessian： $2A = \begin{pmatrix} 4 & 0 \\ 0 & 6 \end{pmatrix}$ 。
- 特徵值：4, 6。
- 預期輸出：Strict local minimum。

2. 邊界情況 (Saddle Point)：

- 函數： $f(x, y) = x^2 - y^2$ 。
- 駐點： $(0, 0)$ 。
- Hessian： $\begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$ 。
- 特徵值：2, -2。
- 預期輸出：Saddle point。

3. 退化邊界測試 (合法輸入)：

- 函數： $f(x, y) = x^4 + y^4$ 。
- 駐點： $(0, 0)$ 。
- Hessian： $\begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$ 。
- 特徵值：0, 0。
- 預期輸出：Indeterminate (Hessian numerically indeterminate (eigenvalue near zero)), need higher-order analysis。
- 注意：雖然此處實際是極小值，但僅憑 Hessian 無法得出此結論。程式的「數值不確定」標籤也不表示零矩陣在數學上無法分類。
- 對照函數： $f(x, y) = x^4 - y^4$ 。

- 原點的Hessian同為 $\begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$ ，預期輸出同上；然而沿兩條座標軸分別取得正負值，原點並非極值。相同Hessian無法決定高階項的效果。

4. 故障測試（非對稱輸入）：

- 將 `np.array([[1.0, 2.0], [0.0, 1.0]])` 傳給 `classify_hessian`。它與自身轉置之差的範數大於預設容差，預期回傳以 `error: Hessian is not symmetric` 開頭的字串，而非極值分類；程式中的斷言檢查此前綴。

反例與常見陷阱

陷阱 1：將半正定 Hessian 誤認為極小值

反例： $f(x, y) = -x^4$ 。

- $\nabla f(0, 0) = \mathbf{0}$ 。
- $H(0, 0) = \mathbf{0}$ （半正定且半負定）。
- 若誤以為「半正定 implies 極小」，則會錯誤結論 $(0, 0)$ 是極小值。
- 實際： $f(x, y) = -x^4 \leq 0$ ，故 $(0, 0)$ 是**極大值點**。
- **教訓**：半定 Hessian 下，二階項為零，高階項決定符號。必須檢查高階項或函數具體形式。

陷阱 2：忽略 Hessian 的非對稱性

陷阱：若計算出的 Hessian 非對稱（由於數值誤差或計算錯誤），直接進行特徵值分解。**修正**：理論上，若 $f \in C^2$ ，Hessian 必對稱（Schwarz定理）。若數值計算導致非對稱，應檢查梯度計算是否正確。程式中應設置容差，若偏差過大則拒絕分析並報錯，而非盲目對稱化。

陷阱 3：混淆局部與全局

陷阱：找到正定 Hessian 的駐點，便認為是全局極小值。**反例**： $f(x) = x^2 - x^4$ 。

- 駐點： $f'(x) = 2x - 4x^3 = 2x(1 - 2x^2) = 0 \implies x = 0, x = \pm \frac{1}{\sqrt{2}}$ 。
- 在 $x = 0$ 處： $f''(0) = 2 > 0$ ，故 $x = 0$ 是**嚴格局部極小**。
- 然而， $\lim_{x \rightarrow \infty} f(x) = -\infty$ 。
- 因此， $x = 0$ 不是全局極小值。
- **教訓**：正定 Hessian 僅保證**局部**極小。全局極小需函數凸性（Hessian 全域半正定）或有界域等其他全局性質。

AI、幾何與養殖案例

幾何解讀

Hessian 矩陣描述了函數圖形在駐點附近的二階方向變化。

- **正定**：圖形像碗，所有切平面方向的二階變化為正。
- **不定**：圖形像馬鞍，一組方向二階變化為正，另一組為負。
- **退化**：圖形在某方向上是「平的」（二階變化為零），類似於長方體的一個面或高原頂部。在此方向上，二階近似無法捕捉其彎曲，需三階或更高階曲率資訊。
- **註**：對於圖形 $z = f(x, y)$ ，高斯曲率 K 與 Hessian 行列式 $\det(H)$ 相關，但兩者不等價（還涉及梯度項）。Hessian 給的是二階導數矩陣，而非單一標量曲率。

養殖案例應用：水質參數最佳化（合成模型）

假設我們有一個合成養殖模型，目標是最大化魚類生長率 G ，取決於溶氧量偏差 ΔO_2 和水溫偏差 ΔT 。為了示範**退化極大值**，取溶氧偏差 ΔO_2 （SI單位 kg m^{-3} ）與水溫偏差 ΔT （SI單位 K）。選定正尺度 O_s （ kg m^{-3} ）、 T_s （K），定義無因次變量 $u = \Delta O_2 / O_s$ 、 $v = \Delta T / T_s$ 。令合成生長率基準 G_0 與正係數 a, b 均具有生長率單位，例如 s^{-1} ，考慮：

$$G(u, v) = G_0 - au^2 - bv^4, \quad a, b > 0.$$

1. **駐點**： $(u, v) = (0, 0)$ ；由 $\Delta O_2 = O_s u$ 、 $\Delta T = T_s v$ 返回物理偏差，兩者也均為零。
2. **Hessian**：在無因次座標下， $H(0, 0) = \begin{pmatrix} -2a & 0 \\ 0 & 0 \end{pmatrix}$ 。
3. **判斷**： H 半負定，單憑二階測試無法判斷極大。但模型的完整式子給出 $G(u, v) - G_0 = -au^2 - bv^4$ 。任意非零 (u, v) 均使差值嚴格小於零，故原點是**嚴格局部極大值**，**實際也是此模型在整個 $\mathbb{R}^2$ 上的嚴格全局極大值**。

操作建議（僅限數學模型解讀）：在 Hessian 退化方向（ ΔT ），二階敏感性為零。若使用基於 Hessian 的 Newton 法，步長在該方向上可能發散或不定。此處應依賴函數值的直接監測或高階項資訊，而非單純依賴 Hessian 的逆矩陣。**註**：此處為純數學結構說明。實際養殖中，溫度影響通常複雜，不可直接套用此簡單多項式模型進行設備控制。

習題

1. **手算**：分析 $f(x, y) = x^3 - 3xy + y^3$ 的駐點性質。
2. **程式**：編寫函數計算 $f(x) = x^2y + xy^2$ 在 $(1, 1)$ 處的 Hessian 並判斷矩陣性質。
3. **反例**：構造一個函數 $f(x, y)$ ，使得 $\nabla f(0, 0) = \mathbf{0}$ ， $H(0, 0) = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ ，但 $(0, 0)$ 既非極大也非極小。

4. **整合**：設 $f(x) = \frac{1}{2}x^T Qx$ ，其中 Q 對稱。(a) 證明 f 的 Hessian 為 Q 。(b) 若 Q 正定，證明 f 有唯一全局極小值。(c) 若 Q 半正定但非正定，說明何種情況下 f 有局部極小值，並舉例說明極小值非唯一。

習題解答

1. **解答**： $\nabla f = \begin{pmatrix} 3x^2 - 3y \\ -3x + 3y^2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ 。 $x^2 = y, x = y^2$ 。代入： $(y^2)^2 = y \implies y^4 - y = 0 \implies y(y^3 - 1) = 0$ 。實數解 $y = 0 \implies x = 0$ ； $y = 1 \implies x = 1$ 。
- 點 $(0, 0)$ ： $H = \begin{pmatrix} 6x & -3 \\ -3 & 6y \end{pmatrix}_{(0,0)} = \begin{pmatrix} 0 & -3 \\ -3 & 0 \end{pmatrix}$ 。特徵值 $\lambda = \pm 3$ 。不定 $\implies$ **鞍點**。
 - 點 $(1, 1)$ ： $H = \begin{pmatrix} 6 & -3 \\ -3 & 6 \end{pmatrix}_{(1,1)}$ 。 $\det = 36 - 9 = 27 > 0$ ， $\text{tr} = 12 > 0 \implies$ 正定。 $\implies$ **嚴格局部極小值**。
2. **解答**： $f(x, y) = x^2y + xy^2$ 。 $\nabla f = \begin{pmatrix} 2xy + y^2 \\ x^2 + 2xy \end{pmatrix}$ 。在 $(1, 1)$ ， $\nabla f(1, 1) = \begin{pmatrix} 3 \\ 3 \end{pmatrix} \neq \mathbf{0}$ 。注意： $(1, 1)$ 不是駐點，因此不能直接稱為鞍點或極值點。但題目要求計算 Hessian 並判斷矩陣性質： $H = \begin{pmatrix} 2y & 2x + 2y \\ 2x + 2y & 2x \end{pmatrix}$ 。在 $(1, 1)$ ： $H = \begin{pmatrix} 2 & 4 \\ 4 & 2 \end{pmatrix}$ 。 $\det = 4 - 16 = -12 < 0$ 。特徵值異號 $\implies$ **Hessian 矩陣不定**。結論：該點非駐點，Hessian 不定僅說明曲面在該點的局部形狀類似馬鞍，但不構成極值判別。
3. **解答**：考慮 $f(x, y) = \frac{1}{2}x^2 + y^3$ 。 $\nabla f = \begin{pmatrix} x \\ 3y^2 \end{pmatrix}$ 。在 $(0, 0)$ 為 $\mathbf{0}$ 。 $H = \begin{pmatrix} 1 & 0 \\ 0 & 6y \end{pmatrix}_{(0,0)} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ 。符合題目要求的 Hessian。沿 x 軸： $f(x, 0) = \frac{1}{2}x^2 > 0$ ($x \neq 0$)。沿 y 軸： $f(0, y) = y^3$ 。 $y > 0 \implies f > 0$ ， $y < 0 \implies f < 0$ 。因此，在 $(0, 0)$ 附近既有 $f > 0$ 也有 $f < 0$ 的點。故 $(0, 0)$ 既非極大也非極小（鞍點）。
4. **解答**：(a) $f(x) = \frac{1}{2}x^T Qx$ 。 $\nabla f = \frac{1}{2}(Q + Q^T)x$ 。因 Q 對稱， $\nabla f = Qx$ 。 $H = \nabla^2 f = Q$ 。(b) 若 Q 正定， $\lambda_{\min}(Q) > 0$ 。 $f(x) \geq \frac{1}{2}\lambda_{\min}\|x\|^2$ 。 f 是嚴格凸函數。唯一駐點 $x = 0$ （因 Q 可逆）。凸函數的局部極小即全局極小，且由嚴格凸性可知唯一。(c) 若 Q 半正定但非正定，存在零空間 $\mathcal{N}(Q) \neq \{\mathbf{0}\}$ 。 $f(x) = \frac{1}{2}x^T Qx$ 。若 $x \in \mathcal{N}(Q)$ ，則 $Qx = 0 \implies \nabla f(x) = 0$ 。對任意 $x_0 \in \mathcal{N}(Q)$ ， $\nabla f(x_0) = 0$ 。且 $f(x_0 + v) = f(x_0) + \frac{1}{2}v^T Qv$ （因 $Qx_0 = 0$ ）。若 v 也在零空間， f 不變。若 v 不在， f 增加。故零空間上的所有點都是局部極小值（實為全局極小，因 $f \geq 0$ 且 $f = 0$ 在零空間上）。極小值不唯一，形成一個仿射子空間（在此為線性子空間）。

本章小結

本章建立了多變量函數局部極值判斷的嚴格框架。核心結論如下：

- 必要條件**：內點局部極值必為駐點（ $\nabla f = 0$ ）。若二階可微，局部極小要求 Hessian 半正定，局部極大要求半負定。

2. **充分條件**：駐點處 Hessian 正定 $\implies$ 嚴格局部極小；負定 $\implies$ 嚴格局部極大；不定 $\implies$ 鞍點。
3. **退化情況**：Hessian 半定但非定時，二階測試失效。極值性質由高階項或函數結構決定。相同 Hessian（如零矩陣或半定矩陣）可對應極小、極大或鞍點。
4. **局部與全局**：正定 Hessian 僅保證局部極小。全局極小需函數凸性或其他全局性質。

在數值計算中，應小心處理 Hessian 奇異或接近奇異的情況，避免因浮點誤差將半定誤判為正定，或忽略退化方向的高階效應。

參考來源

1. Jiří Lebl： *Basic Analysis*。 <https://www.jirka.org/ra/>
2. MIT OCW 18.100A *Real Analysis*。 <https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
3. MIT OCW 18.02SC *Multivariable Calculus*。 <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
4. JAX Autodiff Cookbook：JVP／VJP。 https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html
5. SciPy minimize 參數與方法。 <https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>

第15章 凸性、強凸性與光滑性

學習目標與先備知識

本章研究凸性、強凸性與梯度光滑性，說明它們如何提供最佳化中的全域比較、曲率界與誤差資訊。主線是由凸域上的線段定義出發，推導可微函數的一階判準，再討論 Hessian 判準、強凸性與 Lipschitz 梯度的不同作用，最後用二次模型及 CPU 程式核對這些結論。

完成本章後，讀者應能：

1. 依定義判斷函數在指定凸域上是否凸或強凸。
2. 在適當的域與正則性條件下，以梯度不等式或 Hessian 證明凸性。
3. 區分強凸性與梯度 Lipschitz；知道一者不會自動推出另一者。
4. 計算二次模型的強凸常數、梯度 Lipschitz 常數與條件數。
5. 說明非凸域、局部 Hessian 資訊及有限數值實驗各自能支持什麼結論。
6. 分辨解析證明、程式測試與預期數值結果。

先備知識包括向量範數、梯度、Hessian、二階 Taylor 展開及無約束最佳化的駐點概念。本文使用 Euclidean 範數。對標量函數 $f: U \rightarrow \mathbb{R}$ ，其中 $U \subseteq \mathbb{R}^n$ ，梯度 $\nabla f(x)$ 是 $n \times 1$ 的直向量，Hessian $\nabla^2 f(x)$ 是 $n \times n$ 矩陣。

「光滑」在最佳化文獻中有不同用法。本章將「梯度為 L -Lipschitz」稱為 L -光滑，意思是梯度變化有上界；這不表示函數必定無窮次可微。

問題與直覺

凸性提供一種全域比較方式：在凸域內任取兩點，函數在連接兩點的線段上不高於端點函數值的線性插值。對可微函數而言，這等價於函數不低於任一點的切平面。因此，若凸函數在內點有梯度為零，該點就是全域最小點。對非凸函數而言，梯度為零通常只說明該點是駐點，不能據此判定全域最佳。

強凸性比凸性多一個正的二次曲率下界。它要求函數不只高於切平面，還至少多出一項與距離平方成比例的量。這能帶來唯一最小點及更強的誤差控制；但唯一性不保證最小點存在，相關結論仍須核對函數域、可微性與存在條件。

梯度 Lipschitz 控制的是另一方向：它限制梯度在兩點之間能變化多快。強凸性限制曲率不能太小，梯度 Lipschitz 則限制曲率不能太大。當兩者同時成立且函數為 C^2 時，Hessian 特徵值有上下界，其比值可作為條件數。只知道強凸，不能推得梯度全域 Lipschitz；只知道梯度 Lipschitz，也不能推得函數凸或有正的曲率下界。

這些主張都帶有域與量詞。Hessian 在少量取樣點半正定，不等於它在整個域上半正定；演算法若在有限步中令函數值下降，也不等於已證明它收斂到全域最小點。數值計算可檢查實作、發現反例或提供有限範圍的證據，不能代替全域證明。

定義、定理與推導

凸域與凸函數

定義。 集合 $C \subseteq \mathbb{R}^n$ 稱為凸集，若對所有 $x, y \in C$ 及 $t \in [0, 1]$ ，

$$(1-t)x + ty \in C.$$

定義。 函數 $f: C \rightarrow \mathbb{R}$ 稱為凸函數，若 C 為凸集，且對所有 $x, y \in C$ 及 $t \in [0, 1]$ ，

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y).$$

若對任意互異的 $x, y \in C$ 及 $t \in (0, 1)$ ，上述不等式嚴格成立，則 f 稱為嚴格凸。嚴格凸不必有固定且正的二次曲率下界，故不等同強凸。

定義。 若存在 $\mu > 0$ ，使對所有 $x, y \in C$ 及 $t \in [0, 1]$ ，

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y) - \frac{\mu}{2}t(1-t)\|x - y\|^2,$$

則 f 稱為 μ -強凸。

若 f 可微，強凸也等價於以下一階不等式對所有 $x, y \in C$ 成立：

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|^2.$$

將 μ 設為零，即得到可微凸函數的切平面判準：

$$f(y) \geq f(x) + \nabla f(x)^T(y - x).$$

強凸參數未必唯一或最佳；若某個 μ 有效，較小的正數也有效。

一階判準：凸域上的可微函數

定理。 設 $C \subseteq \mathbb{R}^n$ 為凸集， f 在包含 C 的開集上可微。則以下兩條件等價：

1. f 在 C 上凸。
2. 對所有 $x, y \in C$ ，

$$f(y) \geq f(x) + \nabla f(x)^T(y - x).$$

證明。先假設 f 凸。固定 $x, y \in C$ ，令 $d = y - x$ ，並令 $g(t) = f(x + td)$ ，其中 $t \in [0, 1]$ 。由 C 凸，整條線段都在 C 內。對 $0 < t \leq 1$ ，凸性給出

$$g(t) \leq (1-t)g(0) + tg(1).$$

移項並除以 t ，得到

$$g(1) - g(0) \geq \frac{g(t) - g(0)}{t}.$$

令 $t \downarrow 0$ 。由可微性，右側趨近 $g'(0) = \nabla f(x)^T d$ ，因此

$$f(y) - f(x) \geq \nabla f(x)^T (y - x).$$

反過來，假設切平面不等式對所有 $x, y \in C$ 成立。令 $z = (1-t)x + ty$ ，分別以 z 為基點、以 x 和 y 為比較點，得到

$$f(x) \geq f(z) + \nabla f(z)^T (x - z), \quad f(y) \geq f(z) + \nabla f(z)^T (y - z).$$

將第一式乘以 $1-t$ 、第二式乘以 t 後相加。因為

$$(1-t)(x-z) + t(y-z) = 0,$$

梯度項消去，遂有

$$(1-t)f(x) + tf(y) \geq f(z),$$

這正是凸性定義。證畢。

此定理使用「所有 x, y 」的量詞；有限個點上的檢查無法建立其條件。

Hessian 判準：必須核對定義域維度

定理。設 $U \subseteq \mathbb{R}^n$ 為凸開集，且 $f: U \rightarrow \mathbb{R}$ 為 C^2 。則 f 在 U 上凸，若且唯若對每個 $x \in U$ ，Hessian $\nabla^2 f(x)$ 半正定：

$$v^T \nabla^2 f(x) v \geq 0 \quad \text{對所有 } v \in \mathbb{R}^n.$$

若存在 $\mu > 0$ ，使對所有 $x \in U$ 及 $v \in \mathbb{R}^n$ ，

$$v^T \nabla^2 f(x) v \geq \mu \|v\|^2,$$

則 f 在 U 上 μ -強凸。反過來，若 f 在 U 上 μ -強凸，則同一 Hessian 下界在 U 每點成立。

證明與推導。 固定 $x, y \in U$ ，令 $d = y - x$ ，並定義 $g(t) = f(x + td)$ 。因 U 凸，線段位於 U 中；由鏈鎖法則，

$$g''(t) = d^T \nabla^2 f(x + td) d.$$

若 Hessian 半正定，則 $g''(t) \geq 0$ ，所以每條線段上的限制函數皆凸，得到 f 的凸性。若 Hessian 有下界 μI ，則 $g''(t) \geq \mu \|d\|^2$ 。令

$$q(t) = g(t) - \frac{\mu}{2} t^2 \|d\|^2.$$

由 $q''(t) \geq 0$ ， q 為一維凸函數。把一維凸性不等式套用於 q ，整理後即得強凸定義。

反過來，固定 $x \in U$ 及方向 $v \in \mathbb{R}^n$ 。由 U 為開集，對充分小的 s ， $x + sv \in U$ 。將強凸的一階不等式套用於 x 與 $x + sv$ ，再用二階 Taylor 展開並除以 s^2 ，令 $s \rightarrow 0$ ，便得到

$$v^T \nabla^2 f(x) v \geq \mu \|v\|^2.$$

凸性情形取 $\mu = 0$ ，即得半正定的必要條件。證畢。

低維域的限制。 若凸域不具滿維度，例如 $C = \{(s, 0) : s \in \mathbb{R}\} \subseteq \mathbb{R}^2$ ，凸性只比較域內線段上的函數值，只約束沿域內方向的曲率。令 $f(x_1, x_2) = -x_2^2$ ，則 $f|_C = 0$ ，在 C 上為凸；但環境 Hessian 是 $\text{diag}(0, -2)$ ，不是半正定。因此，任意凸集上的凸性不能推出環境 Hessian 在所有方向半正定。

若函數在包含低維集合的開鄰域中定義，可將 Hessian 條件限制於域的切方向。對線段 $x + td$ 完全位於域中的方向 d ，所需的二階條件是

$$d^T \nabla^2 f(x + td) d \geq 0.$$

若 C 有非空內部，且 f 在包含 C 的開集上為 C^2 ，則凸性推出 Hessian 在 $\text{int}(C)$ 半正定；若 Hessian 連續延拓至邊界，條件也延伸至邊界。反方向則須保證線段上所需方向的二次型非負；常見的充分條件是整個包含域上的 Hessian 半正定。

在 C^2 情形，Taylor 展開為

$$f(x + h) = f(x) + \nabla f(x)^T h + \frac{1}{2} h^T \nabla^2 f(x) h + o(\|h\|^2).$$

餘項是 $o(\|h\|^2)$ ；沒有更高階正則性與界限時，不可改稱 $O(\|h\|^3)$ 。

梯度 Lipschitz 與上方曲率界

定義。 若 f 可微，且存在 $L \geq 0$ ，使對所有 $x, y \in C$ ，

$$\|\nabla f(y) - \nabla f(x)\| \leq L \|y - x\|,$$

則稱 ∇f 在 C 上為 L -Lipschitz，或稱 f 在本章所定義的意義下為 L -光滑。

若 C 凸且梯度為 L -Lipschitz，沿線段積分得到下降引理：

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2.$$

若 f 為 C^2 ，且 Hessian 在凸域 C 上滿足

$$\|\nabla^2 f(x)\|_{\text{op}} \leq L,$$

則梯度在 C 上為 L -Lipschitz。反向亦成立於凸開域：若梯度為 L -Lipschitz，取內點的小方向差商可得 $\|\nabla^2 f(x)\|_{\text{op}} \leq L$ 。Hessian 對稱時，其算子範數等於最大絕對特徵值。

光滑性與凸性是不同性質。下降引理提供切平面上方的二次界，不表示切平面下方也有界，更不表示函數凸。若 f 在凸開域上為 C^2 ，且同時 μ -強凸及 L -光滑，則 Hessian 特徵值位於 $[\mu, L]$ ，其中 $0 < \mu \leq L$ 。常用條件數為

$$\kappa = \frac{L}{\mu}.$$

條件數概括曲率上、下界的相對差距，但不是某個演算法必然需要的步數。

命題（強凸函數的最小點唯一性）。 設 C 為凸集， $f: C \rightarrow \mathbb{R}$ 為 μ -強凸，且 $x_1, x_2 \in C$ 都是全域最小點，則 $x_1 = x_2$ 。

證明。 假設 $x_1 \neq x_2$ ，取 $t \in (0, 1)$ 。由強凸定義，

$$f((1-t)x_1 + tx_2) \leq (1-t)f(x_1) + tf(x_2) - \frac{\mu}{2}t(1-t)\|x_1 - x_2\|^2.$$

因 x_1, x_2 都是全域最小點，前兩項的加權平均等於最小值；末項嚴格為負。因此線段上的函數值比最小值還低，矛盾。故 $x_1 = x_2$ 。證畢。

唯一性不保證最小點存在。存在性可由其他條件建立，例如 C 為非空緊緻集且 f 連續；這是有限維實空間中的極值定理。另一種方法是在適當閉域上證明函數於無窮遠處趨向無窮大。

若 x^* 是可微凸函數在凸域內的內點，且 $\nabla f(x^*) = 0$ ，由一階判準可知 x^* 是全域最小點。若函數 μ -強凸，還有

$$f(y) \geq f(x^*) + \frac{\mu}{2}\|y - x^*\|^2.$$

但受限問題的最小點可能在邊界，梯度此時未必為零；不可將無約束內點的必要條件直接套用於邊界點。

逐步手算例題

例一：二次函數的 μ 、 L 與條件數

令

$$f(x_1, x_2) = \frac{1}{2}(2x_1^2 + 8x_2^2).$$

梯度及 Hessian 為

$$\nabla f(x) = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix}, \quad \nabla^2 f(x) = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}.$$

對任意 $v = (v_1, v_2)^T$ ，

$$v^T \nabla^2 f v = 2v_1^2 + 8v_2^2.$$

因為

$$2(v_1^2 + v_2^2) \leq 2v_1^2 + 8v_2^2 \leq 8(v_1^2 + v_2^2),$$

此函數在 $\mathbb{R}^2$ 上 2-強凸，且梯度為 8-Lipschitz。兩者都是最佳常數：下界由方向 $(1, 0)^T$ 達到，上界由方向 $(0, 1)^T$ 達到。因此 $\kappa = 8/2 = 4$ 。

取 $x = (1, 1)^T$ 、 $y = (2, 0)^T$ 。則 $f(x) = 5$ 、 $\nabla f(x) = (2, 8)^T$ ，強凸一階下界為

$$\begin{aligned} f(y) &\geq 5 + (2 \ 8) \begin{pmatrix} 1 \\ -1 \end{pmatrix} + \frac{2}{2} \left\| \begin{pmatrix} 1 \\ -1 \end{pmatrix} \right\|^2 \\ &= 5 - 6 + 2 = 1. \end{aligned}$$

實際上 $f(y) = 4$ ，符合下界；不等式不必取等號。

例二：光滑但非凸

令 $f(x) = \sin x$ ，定義域為 $\mathbb{R}$ 。梯度是 $\cos x$ 。由中值定理，對任意 x, y ，

$$|\cos y - \cos x| \leq |y - x|,$$

所以梯度為 1-Lipschitz。然而 $f''(x) = -\sin x$ ，在 $x = \pi/2$ 時為 -1 。故函數在包含該點的任何開鄰域上都不凸，因而不可能在 $\mathbb{R}$ 上凸。

此外，在 $[0, \pi]$ 上有 $f''(x) = -\sin x \leq 0$ ，所以 $\sin x$ 在該區間為凹函數。這說明光滑性給出的上方曲率界，與凸性要求的曲率符號不是同一件事。

實作與程式

以下程式只使用 Python 標準庫，不需要 NumPy、SciPy、GPU 或套件安裝。它以顯式公式計算二次函數與真實梯度，並執行固定步長 $1/L$ 的梯度下降。對本例的對角二次模型，每個座標誤差乘上 $1 - \lambda_i/L$ ，因此最大座標縮減因子為 $1 - \mu/L = 3/4$ 。這是解析推導，不是程式從有限輸出推測出的定理。程式紀錄只呈現有限次計算，不證明任意模型或任意初值下的收斂。

```
from math import sqrt

def value(x):
    return x[0] * x[0] + 4.0 * x[1] * x[1]

def gradient(x):
    return (2.0 * x[0], 8.0 * x[1])

def norm2(x):
    return sqrt(x[0] * x[0] + x[1] * x[1])

def run_gradient_descent(start, steps, step_size):
    x = (float(start[0]), float(start[1]))
    history = [(0, x, value(x), norm2(gradient(x)))]

    for k in range(1, steps + 1):
        g = gradient(x)
        x = (x[0] - step_size * g[0],
             x[1] - step_size * g[1])
        history.append((k, x, value(x), norm2(gradient(x))))

    return history

def main():
    mu = 2.0
    L = 8.0
    kappa = L / mu
    start = (4.0, -2.0)
    steps = 8
    history = run_gradient_descent(start, steps, 1.0 / L)

    print("mu =", mu, "L =", L, "kappa =", kappa)
    print("step =", 1.0 / L)
    print("k, x, f(x), ||grad f(x)||")
    for k, x, fx, grad_norm in history:
        print(k, x, fx, grad_norm)

    print("目標點為 (0, 0)，目標函數值為 0。")
    print("最壞座標誤差因子為", 1.0 - mu / L)

if __name__ == "__main__":
    main()
```

本例有

$$f(x) = \frac{1}{2}x^T Qx, \quad Q = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}, \quad \nabla f(x) = Qx.$$

取 $\alpha = 1/L = 1/8$ ，更新式為

$$x_{k+1} = (I - \alpha Q)x_k = \begin{pmatrix} 3/4 & 0 \\ 0 & 0 \end{pmatrix} x_k.$$

從 $(4, -2)^T$ 開始，起點函數值為 32，梯度為 $(8, -16)^T$ ，梯度範數為 $8\sqrt{5}$ 。第一步得到 $(3, 0)^T$ ，函數值降至 9，梯度範數為 6。第二步得到 $(9/4, 0)^T$ ，函數值為 81/16。這些是解析計算所得的預期輸出；本章沒有執行程式，也不報告實際測試紀錄。

測試與預期結果

以下為讀者執行程式後可核對的預期結果；此處僅列解析預期，並非實際執行紀錄。

- **正常測試：**起點 $(4, -2)^T$ 、步長 $1/8$ 。起點函數值為 32、梯度範數為 $8\sqrt{5}$ ；第一步預期到 $(3, 0)^T$ ，函數值為 9；第二步預期到 $(9/4, 0)^T$ ，函數值為 81/16。
- **邊界測試：**起點 $(0, 0)^T$ 。梯度為零，所有更新保持在原點，函數值與梯度範數皆為零。
- **單座標測試：**起點 $(0, 1)^T$ ，一步預期更新到 $(0, 0)^T$ 。第二座標曲率等於 L ，更新倍率為零。
- **步長故障測試：**改用步長 $1/2$ 。第二座標更新倍率為 $1 - (1/2)8 = -3$ ；從 $(0, 1)^T$ 開始，函數值預期依序為 4, 36, 324, ...。這只說明該步長不適用於此模型，不是所有非凸問題的通用結論。
- **輸入故障測試：**`start` 須有兩個可轉成浮點數的分量，`steps` 須為非負整數，`step_size` 須為正數。示範程式未加入通用輸入驗證；錯誤形狀或非數值資料可能觸發例外，負步長則可能造成函數值上升。正式使用時應依呼叫端需求加入檢查。

程式中的梯度是二次模型的真實梯度，不是有限差分估計。更換目標函數時，必須同步更換梯度並另行核對。此程式沒有實作通用最佳化器、線搜尋或非凸問題的全域保證。

反例與常見陷阱

低維凸域上不能要求所有環境方向的 Hessian 半正定

令 $C = \{(s, 0) : s \in \mathbb{R}\}$ ，並令 $f(x_1, x_2) = -x_2^2$ 。在 C 上， f 恆等於零，所以限制函數 $f|_C$ 為凸；但環境 Hessian 為 $\text{diag}(0, -2)$ ，不是半正定。凸性只比較域內線段，不能推出垂直於低維域的曲率符號。使用 Hessian 判準時，必須說明域是開集、滿維凸域，或只檢查域內方向。

非凸域上不能直接套用線段判準

考慮 $C = (-2, -1) \cup (1, 2)$ 上的 $f(x) = x^2$ 。每個點都有 $f''(x) = 2 > 0$ ，但 C 非凸；例如 $-3/2$ 與 $3/2$ 的中點 0 不在 C 內。凸函數的標準定義要求凸定義域，因此不能僅由各分支內的 Hessian 符號推論跨分支的線段不等式。二階推導必須確保相關線段位於函數定義域內。

嚴格凸不推出強凸

令 $f(x) = x^4$ ，定義域為 $\mathbb{R}$ 。導數 $4x^3$ 嚴格遞增，所以函數嚴格凸；但 $f''(0) = 0$ 。若它在 $\mathbb{R}$ 上 μ -強凸，二階判準會要求 $12x^2 \geq \mu$ 對所有 x 成立，與 $x = 0$ 矛盾。因此它不是強凸函數。

強凸不推出全域梯度 Lipschitz

令 $f(x) = x^2 + x^4$ ，定義域為 $\mathbb{R}$ 。其二階導數滿足 $f''(x) = 2 + 12x^2 \geq 2$ ，所以函數為 2-強凸。然而 f'' 無全域上界。若 $f'(x)$ 全域為 L -Lipschitz，在每點取差商可得 $|f''(x)| \leq L$ ，矛盾。因此強凸不推出全域梯度 Lipschitz。

梯度 Lipschitz 不推出凸或強凸

$-\cos x$ 的梯度 $\sin x$ 為 1-Lipschitz，但二階導數 $\cos x$ 在 π 為 -1 ，所以函數不凸。即使函數凸，也不必強凸； x^4 即為例子。

有限步下降不代表全域最優

演算法函數值逐步下降，只表示已計算的有限步有此數值現象。它不證明其他區域沒有更低值、不證明梯度實作正確，也不證明停止點是全域最小點。對非凸函數，下降法可能到達局部極小、鞍點附近，或因步長不適當而失敗；任何全域結論都須由問題假設及相應定理支持。

AI、幾何與養殖案例

AI：訓練目標的曲率說明

某批資料及模型參數可形成損失函數 $F(\theta)$ 。若能證明它在完整凸可行域上強凸，便可排除兩個不同的全域最小點；若同時證明梯度 Lipschitz，則可在相應假設下分析特定梯度法。然而神經網路參數化的損失通常不具備這些全域條件，不能因少量訓練步驟降低 loss 就宣稱強凸、唯一解或全域收斂。

數值 Hessian 取樣可以協助找出負曲率位置，從而反駁全域半正定的主張；但即使所有取樣點都半正定，也不能證明未取樣位置同樣如此。取樣結論與全域證明的證據強度不同。

幾何：凸性取決於座標中的線段

Euclidean 座標中的凸性以直線段為基礎。施行非線性座標變換後，原來的直線一般會成為曲線，沿曲線插值不等式不自動等同於原座標的凸性。使用凸性判準前，應先確認可行域及其線段，再決定採用哪個座標與距離。繪圖可以提示可能的曲率變化，不能取代域條件或 Hessian 證明。

合成養殖案例：校準目標的尺度與證據

假設以合成資料校準兩個無因次參數 θ_1, θ_2 ，並定義加權平方殘差目標

$$F(\theta) = \frac{1}{2} \|W^{1/2}(r(\theta) - y)\|^2,$$

其中 $r(\theta)$ 是預測感測值， y 是合成觀測值， W 是明確指定且半正定的權重矩陣。若觀測量原本有不同 SI 單位，須先說明尺度與無因次化方式；權重則代表資料尺度或測量不確定度的建模選擇，不能省略其意義。

即使參數已無因次化，殘差對參數仍可能非線性，目標函數也可能非凸。若只在校準點附近觀察 Hessian 半正定，最多得到局部數值證據。只有在凸參數域上證明所需的 Hessian 條件，才可使用相應全域判準。若參數受盒形限制，最小點可能在邊界，不能把內點條件 $\nabla F = 0$ 當作必要條件。本例是合成數學說明，不代表現場校準有效，也不構成對設備、投餌或加藥的操作指令。

習題

題一：手算一階與二階判準

令 $f(x) = 3x^2 - 6x + 5$ ，定義域為 $\mathbb{R}$ 。

1. 計算梯度及 Hessian。
2. 求最大的強凸參數 μ 。
3. 判斷 $x = 1$ 是否為全域最小點，並用切平面判準或配方證明。

題二：程式與條件數

令 $f(x) = \frac{1}{2}x^T Qx$ ，其中 $Q = \text{diag}(1, 5)$ 。

1. 求最佳 μ 、最佳 L 與條件數。
2. 從 $x_0 = (2, 1)^T$ 以步長 $1/L$ 做一步梯度下降，求 x_1 及函數值。
3. 寫出本章程式應如何修改梯度分量與函數值公式，並說明為何這項修改不證明其他函數也會收斂。

題三：反例判讀

對每個敘述判斷正確或錯誤，並給證明或反例。

1. 函數嚴格凸就一定強凸。
2. 函數梯度 Lipschitz 就一定凸。
3. C^2 函數若在凸開域每點的 Hessian 半正定，就在該域上凸。
4. 函數在若干取樣點的 Hessian 半正定，就已證明它在整個域上凸。
5. 在低維凸集合上，限制函數凸就代表環境 Hessian 必須半正定。

題四：整合分析與停止點

令 $f(x) = x^4 - x^2$ ，定義域為 $\mathbb{R}$ 。

1. 求所有駐點。
2. 分析各駐點的局部型態，並求全域最小值。
3. 說明為何不能宣稱它在整個 $\mathbb{R}$ 上凸，並判斷梯度是否全域 Lipschitz。
4. 若數值迭代由初值 0 開始且保持在 0，能證明什麼、不能證明什麼？

習題解答

題一解答

1. $f'(x) = 6x - 6$ ， $f''(x) = 6$ 。
2. 一維 Hessian 下界就是最佳強凸參數，因此 $\mu = 6$ 。
3. $f'(1) = 0$ ，且 $f''(x) = 6 > 0$ 。強凸不等式給出 $f(y) \geq f(1) + 3(y - 1)^2 \geq f(1)$ 。亦可配方：

$$f(x) = 3(x - 1)^2 + 2.$$

因此唯一全域最小點為 $x = 1$ ，最小值為 2。

題二解答

1. Hessian 為 $\text{diag}(1, 5)$ ，最佳 $\mu = 1$ 、最佳 $L = 5$ ，故 $\kappa = 5$ 。
2. $\nabla f(x) = Qx$ ，所以 $\nabla f(x_0) = (2, 5)^T$ 。步長為 $1/5$ ，因此

$$x_1 = (2, 1)^T - \frac{1}{5}(2, 5)^T = (8/5, 0)^T.$$

$$f(x_1) = \frac{1}{2}(8/5)^2 = \frac{32}{25}.$$

起點函數值為 $f(x_0) = \frac{1}{2}(4 + 5) = 9/2$ ，所以此步下降。

3. 梯度改為 $(x[0], 5.0 * x[1])$ ；函數值改為 $0.5 * (x[0]**2 + 5.0 * x[1]**2)$ 。這只實作另一個已知二次模型。要建立收斂結論，仍須證明模型的曲率條件與步長符合相應定理；程式形式本身不會替任意函數提供正則性或凸性。

題三解答

1. 錯誤。 x^4 嚴格凸，但 $f''(0) = 0$ ，不可能有正的全域強凸參數。
2. 錯誤。 $\sin x$ 的梯度 $\cos x$ 為 1-Lipschitz，但 $f''(\pi/2) = -1$ ，所以它不凸。
3. 正確。對凸開域中的任意兩點，連線留在域內；沿線段限制所得的一維函數二階導數非負，故該限制函數凸，進而得到原函數的線段不等式。
4. 錯誤。有限取樣不能涵蓋全域量詞；未取樣處可能有負曲率。除非另有解析界、區間方法或其他全域證明，取樣只能提供有限證據。
5. 錯誤。令 $C = \{(s, 0) : s \in \mathbb{R}\}$ 、 $f(x_1, x_2) = -x_2^2$ 。限制函數 $f|_C = 0$ 為凸，但環境 Hessian 為 $\text{diag}(0, -2)$ ，不是半正定。

題四解答

1. $f'(x) = 4x^3 - 2x = 2x(2x^2 - 1)$ ，駐點為 0 與 $\pm 1/\sqrt{2}$ 。
2. $f''(x) = 12x^2 - 2$ 。在 0 處 $f''(0) = -2 < 0$ ，所以是局部極大點；在 $\pm 1/\sqrt{2}$ 處 $f'' = 4 > 0$ ，所以是局部極小點。配方得

$$f(x) = \left(x^2 - \frac{1}{2}\right)^2 - \frac{1}{4}.$$

因而全域最小值為 $-1/4$ ，在 $\pm 1/\sqrt{2}$ 達到。

3. $f''(0) < 0$ ，故它在包含 0 的任何開鄰域都不凸，不能在 $\mathbb{R}$ 上宣稱凸。梯度不全域 Lipschitz，因為 $f''(x) = 12x^2 - 2$ 無上界；若梯度全域 L -Lipschitz，差商極限會迫使 $|f''(x)| \leq L$ 。
4. 只可確認該次迭代對此初值留在駐點 0。這不能證明 0 是最小點、不能證明全域收斂，也不能排除其他區域有更低值。解析計算顯示 0 是局部極大點，兩個非零駐點才是全域最小點。

本章小結

凸性是在凸域上對所有線段成立的函數值不等式；可微時，它等價於切平面全域下界。Hessian 判準需要正確的域條件：在凸開域上， C^2 函數凸等價於 Hessian 半正定；在低維凸域上，只能由凸性要求域內線段方向的曲率條件，不能要求所有環境方向半正定。

強凸性在切平面下界上增加正的二次項，並在最小點存在時確保唯一性。梯度 Lipschitz 提供上方曲率界與下降引理，不單獨推出凸性或強凸性。二次模型能讓 μ 、 L 、條件數及梯度下降更新逐步手算；但有限步下降仍是數值證據，不是全域定理。套用判準前，應核對定義域、正則性、方向條件，以及結論是局部還是全域。

參考來源

1. Jiří Lebl, *Basic Analysis*，作者目錄與教材入口：<https://www.jirka.org/ra/>

2. MIT OpenCourseWare, *18.100A Real Analysis* : <https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
3. MIT OpenCourseWare, *18.02SC Multivariable Calculus* : <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

本章涉及微分分析與多變量微積分中的凸性判準、Taylor 展開及 Hessian 概念。以上列出教材與課程入口作為延伸閱讀，不表示本章已逐條核驗其中所有內容。

第16章 梯度下降、線搜尋與Newton法

學習目標與先備知識

本章把第13至15章的二階資訊真正轉成可執行的迭代演算法。讀完本章，你應該能：

1. 用Fréchet可微的定義寫出下降引理，並分清「方向導數為負」與「函數值真的下降」的差別。
2. 說明步長條件（含Armijo充分下降）如何把無窮小的下降推廣到有限步。
3. 寫出Newton法的更新式 $x_{k+1} = x_k - H_f(x_k)^{-1} \nabla f(x_k)$ ，並指出它在哪些假設下才具有局部二次收斂。
4. 辨識不定Hessian的兩種典型後果：Newton方向可能不是下降方向、或是不穩定的跳躍步。
5. 實作一個只用NumPy的小型CPU最佳化器，含梯度下降、Armijo線搜尋與Newton法。
6. 以正常、邊界、故障三類測試驗證程式，並在報告中區分「數值觀察」與「定理結論」。

先備知識為：本卷第1~6章的極限、範數與分析基礎，前文的Fréchet導數與Jacobian，第13章的Hessian與二階Taylor展開、第14章關於正定與半正定二次型的判別、第15章凸性與 L -Lipschitz梯度的定義。本章不預設讀者已學過信賴域或內點法。

問題與直覺

無約束最佳化問題寫成

$$\min_{x \in \mathbb{R}^n} f(x)$$

直覺上，函數在 x 附近的最佳線性近似是 $f(x+h) \approx f(x) + \nabla f(x)^\top h$ 。若 $\nabla f(x) \neq 0$ ，令 $h = -t \nabla f(x)$ 、 $t > 0$ 小，則方向導數為

$$\nabla f(x)^\top h = -t \|\nabla f(x)\|^2 < 0$$

也就是「沿負梯度走一小段，函數值會下降」。把這個無窮小敘述變成演算法只需要兩步：選方向（負梯度或Newton方向），選步長（線搜尋）。第13章的餘項控制及第15章的光滑性條件，在此處成為分析迭代步長與收斂性質的依據。

但直覺會出錯。 $\nabla f(x)^\top h < 0$ 只在固定方向上保證 t 足夠小時函數下降，並不保證 $t = 1$ 下降。Newton方向 $-H_f(x)^{-1} \nabla f(x)$ 在 $H_f(x)$ 不定時甚至可能使 $\nabla f^\top d > 0$ 。此外，梯度下降的線性收斂率由 L/μ （條件數）控制，病態問題上可能極慢。

定義、定理與推導

定義 16.1（下降方向）

設 $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$ 在開集 U 上Fréchet可微， $x \in U$ 。向量 $d \in \mathbb{R}^n \setminus \{0\}$ 稱為 f 在 x 處的**下降方向**，若存在 $\bar{t} > 0$ 使得對所有 $t \in (0, \bar{t})$ 皆有 $f(x + td) < f(x)$ 。

命題 16.1（下降引理）

設 $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$ 在開集 U 上Fréchet可微， $x \in U$ 且 $\nabla f(x) \neq 0$ 。則 $d = -\nabla f(x)$ 是 f 在 x 處的下降方向。

證明. 由Fréchet可微的定義，存在餘項 $r(h)$ 滿足

$$f(x + h) = f(x) + \nabla f(x)^\top h + r(h), \quad \frac{\|r(h)\|}{\|h\|} \xrightarrow{h \rightarrow 0} 0$$

取 $h = td$ ， $t > 0$ ：

$$f(x + td) = f(x) + t \nabla f(x)^\top d + r(td) = f(x) - t \|\nabla f(x)\|^2 + r(td)$$

因為 $d = -\nabla f(x)$ 且 $\|d\| = \|\nabla f(x)\|$ ，對 $t > 0$ 有 $\|td\| = t \|\nabla f(x)\|$ ，於是

$$\left| \frac{r(td)}{t} \right| = \|d\| \cdot \frac{\|r(td)\|}{\|td\|} \xrightarrow{t \rightarrow 0^+} 0$$

因此

$$\lim_{t \rightarrow 0^+} \frac{f(x + td) - f(x)}{t} = -\|\nabla f(x)\|^2 < 0$$

取左邊極限為負值，必存在 $\bar{t} > 0$ 使得當 $0 < t < \bar{t}$ 時該商為負，即 $f(x + td) < f(x)$ 。□

評註. 證明只用到 x 點的Fréchet可微，不需要 f 在鄰域內 C^1 。但要把這個局部性質轉成「從 x_0 出發的整個迭代收斂到駐點」，就需要全域界： f 有下界、 ∇f 一致連續，或 f 為 L -光滑等。第15章介紹相關凸性與光滑性條件；這些全域收斂條件不由本命題的點態可微性自動成立。

定義 16.2（Armijo充分下降條件）

設 d 為 x 處的下降方向， $c_1 \in (0, 1)$ 。步長 $\alpha > 0$ 滿足**Armijo條件**，若

$$f(x + \alpha d) \leq f(x) + c_1 \alpha \nabla f(x)^\top d$$

若另有 $\nabla f(x)^\top d < 0$ ，則右端嚴格小於 $f(x)$ ；此時Armijo條件是「函數值下降至少與預測下降成比例」的充分條件。背後的定理是：

命題 16.2 (Armijo步長存在性)

設 $f : U \rightarrow \mathbb{R}$ 在 x 處 Fréchet 可微， d 為下降方向且 $\nabla f(x)^\top d < 0$ ， $c_1 \in (0, 1)$ 。則存在 $\bar{t} > 0$ 使得所有 $\alpha \in (0, \bar{t})$ 均滿足 Armijo 條件。

證明思路. 由可微性， $\frac{f(x + \alpha d) - f(x)}{\alpha} \rightarrow \nabla f(x)^\top d$ 當 $\alpha \rightarrow 0^+$ 。記 $g := \nabla f(x)^\top d$ ， $g < 0$ 。取 $c_1 \in (0, 1)$ ，則 $c_1 g > g$ （因 $g < 0$ 而 $c_1 < 1$ ）。由極限定義，存在 $\bar{t} > 0$ 使當 $0 < \alpha < \bar{t}$ 時 $\frac{f(x + \alpha d) - f(x)}{\alpha} < c_1 g$ ，整理即得 Armijo 條件。□

實作上常採用**回溯線搜尋**：從 $\alpha_0 = 1$ 開始，令 $\alpha \leftarrow \rho \alpha$ （ $0 < \rho < 1$ ，常取 $\rho = 1/2$ ）直到 Armijo 成立，或達最大步數後宣告線搜尋失敗。

弱 Wolfe 條件再加一項 $\nabla f(x + \alpha d)^\top d \geq c_2 \nabla f(x)^\top d$ （ $c_1 < c_2 < 1$ ）。它與 Armijo 常用於擬 Newton 法的收斂分析，但單靠線搜尋條件不能保證任意 BFGS 或 Newton 序列收斂；仍須相應的光滑性、曲率及迭代區域等假設。本章程式只示範 Armijo 回溯與故障偵測，不宣稱一般全域收斂。

定義 16.3 (Newton法)

設 $f : U \rightarrow \mathbb{R}$ 為 C^2 ， $x_k \in U$ 且 $H_f(x_k)$ 可逆。**Newton 迭代**為

$$x_{k+1} = x_k - H_f(x_k)^{-1} \nabla f(x_k)$$

在 Newton 法中，步長為 $\alpha = 1$ 、方向 $d_k = -H_f(x_k)^{-1} \nabla f(x_k)$ 。實作上不顯式求逆，而解線性方程 $H_f(x_k) d_k = -\nabla f(x_k)$ 。

命題 16.3 (Newton局部二次收斂，標準假設)

設 $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$ 在 x^* 的開鄰域 $B(x^*, r) \subset U$ 上 C^2 ， $\nabla f(x^*) = 0$ ， $H_f(x^*)$ 可逆，且 H_f 在 $B(x^*, r)$ 上 Lipschitz 連續（常數 γ ）。則存在 $\delta \in (0, r)$ 與 $C > 0$ ，使得當 $x_0 \in B(x^*, \delta)$ 時，Newton 迭代有定義且

$$\|x_{k+1} - x^*\| \leq C \|x_k - x^*\|^2$$

說明. 證明略去，屬引用結果；核心條件為： C^2 鄰域、 $H_f(x^*)$ 可逆、 H_f 局部 Lipschitz。這三者合起來使 Newton 迭代在 x^* 附近落在收斂吸引球內。 $\|H_f(x^*)^{-1}\|$ 與 γ 共同控制常數 C 。若 $H_f(x^*)$ 奇異，該結論失效（見習題）。

定義 16.4 (二次模型下降量)

給定 x 、梯度 $g = \nabla f(x)$ 、Hessian $H = H_f(x)$ 與步長 α ，二次模型

$$m_\alpha(d) = f(x) + \alpha g^\top d + \frac{\alpha^2}{2} d^\top H d$$

Newton步 d_N 恰使 $\nabla m_1(d) = 0 : Hd_N = -g$ 。若 H 正定， d_N 是 m_1 的嚴格全域極小；若 H 不定， d_N 可能是鞍點，對應的二次模型值是 $f(x) - \frac{1}{2}g^\top H^{-1}g$ ，但 H^{-1} 有負特徵值時該值可能比 $f(x)$ 高。

逐步手算例題

例16.1（梯度下降在二次目標上的精確線搜尋）

取 $f(x_1, x_2) = x_1^2 + 2x_2^2$ ，起始點 $x_0 = (2, 1)$ 。

第一步： $\nabla f(x_0) = (2x_1, 4x_2) = (4, 4)$ ， $\|\nabla f(x_0)\|^2 = 32$ ，下降方向 $d_0 = (-4, -4)$ 。

沿 d_0 的單變量函數

$$\phi(t) = f(x_0 + td_0) = (2 - 4t)^2 + 2(1 - 4t)^2 = 6 - 32t + 48t^2$$

$\phi'(t) = -32 + 96t = 0 \Rightarrow t^* = 1/3$ 。 $\phi(1/3) = 6 - 32/3 + 48/9 = 2/3$ 。新點

$$x_1 = (2, 1) + \frac{1}{3}(-4, -4) = \left(\frac{2}{3}, -\frac{1}{3}\right), \quad f(x_1) = \frac{2}{3}$$

第二步： $\nabla f(x_1) = (4/3, -4/3)$ ， $\|\nabla f(x_1)\|^2 = 32/9$ ， $d_1 = (-4/3, 4/3)$ 。單變量函數

$$\psi(t) = f\left(\frac{2}{3} - \frac{4t}{3}, -\frac{1}{3} + \frac{4t}{3}\right) = \frac{6}{9} - \frac{32t}{9} + \frac{48t^2}{9}$$

$\psi'(t) = 0 \Rightarrow t^* = 1/3$ ， $\psi(1/3) = 2/27$ ， $x_2 = (2/9, 1/9)$ 。

對這個目標， $f(x_k) = 6 \cdot 9^{-k}$ ，精確線搜尋梯度下降的收斂比為 $1/9$ 。對正定二次函數，精確線搜尋的函數值誤差 $f(x_k) - f(x^*)$ 之最壞收縮因子為

$$\left(\frac{\kappa - 1}{\kappa + 1}\right)^2,$$

其中 $\kappa = L/\mu$ 為條件數。本例 $L = 4$ 、 $\mu = 2$ ，故 $\kappa = 2$ ，此因子恰為 $1/9$ ；本例每一步的函數值比也正好達到此值。

例16.2（Newton法一步收斂與二次目標的關係）

取 $f(x_1, x_2) = x_1^2 + 3x_1x_2 + 5x_2^2$ ，起始點 $x_0 = (1, 1)$ 。

$$H = \begin{pmatrix} 2 & 3 \\ 3 & 10 \end{pmatrix}, \det H = 11, H^{-1} = \frac{1}{11} \begin{pmatrix} 10 & -3 \\ -3 & 2 \end{pmatrix}.$$

$\nabla f(1, 1) = (2 \cdot 1 + 3 \cdot 1, 3 \cdot 1 + 10 \cdot 1) = (5, 13)$ 。

Newton步

$$d_0 = -H^{-1}\nabla f(x_0) = -\frac{1}{11} \begin{pmatrix} 10 \cdot 5 - 3 \cdot 13 \\ -3 \cdot 5 + 2 \cdot 13 \end{pmatrix} = -\frac{1}{11} \begin{pmatrix} 11 \\ 11 \end{pmatrix} = (-1, -1)$$

$x_1 = (0, 0)$ ， $f(x_1) = 0$ ，確為全域最小值。對任何正定二次目標，Newton法從任意 x_0 出發一步到達唯一駐點；這是二次模型精確的結果，性質無法直接推廣到非二次目標。

例16.3（不定Hessian反例手算）

取 $f(x, y) = (x^2 - 1)^2 + y^2$ ，在 $x_0 = (0.5, 0.5)$ ：

$$\nabla f(0.5, 0.5) = (4x(x^2 - 1), 2y)|_{(0.5, 0.5)} = (-1.5, 1)。$$

$$H_f = \begin{pmatrix} 12x^2 - 4 & 0 \\ 0 & 2 \end{pmatrix}, H_f(0.5, 0.5) = \begin{pmatrix} -1 & 0 \\ 0 & 2 \end{pmatrix} \text{為不定矩陣。}$$

$$\text{Newton步 } d_N = -H^{-1}\nabla f = -\begin{pmatrix} -1 & 0 \\ 0 & 0.5 \end{pmatrix} (-1.5, 1)^\top = -(1.5, 0.5)^\top = (-1.5, -0.5)^\top。$$

方向導數 $\nabla f^\top d_N = (-1.5)(-1.5) + 1(-0.5) = 1.75 > 0$ ，所以本例的Newton方向不是下降方向；足夠小的正步長反而使函數值上升。這不代表每一個有限步都必然上升，亦不能用偶然下降的完整步掩蓋方向導數的符號。程式會在此點回傳 `newton_not_descent`，不執行這個方向。

若改從 $(0, 0.5)$ 出發，梯度為 $(0, 1)^\top$ ， $H = \text{diag}(-4, 2)$ ，Newton步 $(0, -0.5)^\top$ 的方向導數是 -0.5 。完整一步到達 $(0, 0)$ ，但該點為鞍點而非極小。這兩個初值分別說明「不定Hessian可產生非下降方向」及「梯度歸零不保證極小」。一般而言，梯度在負曲率方向的分量占優時，Newton方向可能不是下降方向，習題16.3提供另一個顯式構造。

實作與程式

下列程式只用NumPy（標準庫以外的唯一依賴），不安裝任何套件、不呼叫SciPy、不執行GPU。目標函數介面為 `f(x)->float`、`grad(x)->np.ndarray shape (n,1)`、`hess(x)->np.ndarray shape (n,n)`。

```
import numpy as np

def quad_factory(A, b):
    A = np.asarray(A, dtype=float)
    b = np.asarray(b, dtype=float).reshape(-1, 1)
    def f(x):
        x = x.reshape(-1, 1)
        return 0.5 * (x.T @ A @ x).item() - (b.T @ x).item()
    def grad(x):
        x = x.reshape(-1, 1)
        return A @ x - b
    def hess(x):
        return A.copy()
    return f, grad, hess

def armijo(f, grad, x, d, fx, alpha0=1.0, rho=0.5, c1=1e-4, max_ls=60):
```

```

g = grad(x)
gTd = (g.T @ d).item()
if gTd >= 0.0:
    return None, None, fx, "not_descent"
alpha = alpha0
for _ in range(max_ls):
    xnew = x + alpha * d
    fnew = f(xnew)
    if fnew <= fx + c1 * alpha * gTd:
        return alpha, xnew, fnew, "ok"
    alpha *= rho
return None, None, fx, "ls_exhausted"

def gradient_descent(x0, f, grad, tol=1e-10, max_iter=2000, **ls_kw):
    x = np.asarray(x0, dtype=float).reshape(-1, 1)
    fx = f(x)
    log = []
    for k in range(max_iter):
        g = grad(x)
        gn = float(np.linalg.norm(g))
        if gn < tol:
            log.append((k, fx, gn, None, "grad_tol"))
            return x, log
        d = -g
        alpha, xnew, fnew, msg = armijo(f, grad, x, d, fx, **ls_kw)
        if alpha is None:
            log.append((k, fx, gn, None, msg))
            return x, log
        x, fx = xnew, fnew
        log.append((k, fx, gn, alpha, "ok"))
    log.append((max_iter, fx, float(np.linalg.norm(grad(x))), None, "max_iter"))
    return x, log

def newton(x0, f, grad, hess, tol=1e-10, max_iter=200,
          reg=0.0, alpha0=1.0, rho=0.5, c1=1e-4):
    x = np.asarray(x0, dtype=float).reshape(-1, 1)
    fx = f(x)
    log = []
    for k in range(max_iter):
        g = grad(x)
        gn = float(np.linalg.norm(g))
        if gn < tol:
            log.append((k, fx, gn, None, "grad_tol"))
            return x, log
        H = hess(x)
        if reg > 0.0:
            H = H + reg * np.eye(H.shape[0])
        try:
            d = np.linalg.solve(H, -g)
        except np.linalg.LinAlgError:
            log.append((k, fx, gn, None, "singular_hessian"))
            return x, log
        if (g.T @ d).item() >= 0.0:
            log.append((k, fx, gn, None, "newton_not_descent"))
            return x, log
        alpha, xnew, fnew, msg = armijo(f, grad, x, d, fx,
                                       alpha0=alpha0, rho=rho, c1=c1)
        if alpha is None:
            log.append((k, fx, gn, None, msg))

```

```

        return x, log
    x, fx = xnew, fnew
    log.append((k, fx, gn, alpha, "ok"))
log.append((max_iter, fx, float(np.linalg.norm(grad(x))), None, "max_iter"))
return x, log

```

要點：`newton` 在 `np.linalg.solve` 失敗或方向非下降時立即返回並在log中標記原因；不做未定義的「修正」，留給呼叫者決定重新初始化策略。`reg>0` 時是對Hessian加 $\text{reg} \cdot I$ 的Tikhonov型正則化，屬啟發式，不提供收斂證明。

測試與預期結果

以下是本章應達到的三類測試（未在本環境實際執行，僅預期）。任何一次執行結果必須自報版本、NumPy版本與硬體環境，才能作為證據。

正常測試

$A = \begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix}$ ， $b = (1, 1)^\top$ ，唯一最小值 $x^* = A^{-1}b = \frac{1}{11}(2, 3)^\top \approx (0.1818, 0.2727)$ 。

- `gradient_descent` 從 $x_0 = (10, -5)$ 、`tol=1e-10` 應在數百步內收斂，log最後一行 `status=="grad_tol"`， f 單調不增。
- `newton` 從同一 x_0 應在2步內達到 10^{-12} 級梯度範數（一步跳到精確解附近，另一步歸零殘差）；`alpha=1.0`。

邊界測試

- 起始點 $x_0 = x^* + \varepsilon(1, 1)$ ， $\varepsilon = 10^{-12}$ ：此時梯度範數為 $\sqrt{41} \times 10^{-12} < 10^{-10}$ ，`gradient_descent` 第0步即 `grad_tol`；`newton` 同樣第0步停止。驗證停止條件在近最優點的退化行為。
- 步長 t 的邊界：設 `alpha0=1e-15`，預期 `gradient_descent` 在第一步由於步長太小、Armijo右端 $c_1 \alpha g^\top d$ 過小，可能先被接受但幾乎不移動，之後各步需累積才能接近 x^* ，日誌顯示 f 幾乎不下降。此為數值現象，不構成收斂證明。

故障測試

- 對例16.3的函數從 $(0.5, 0.5)$ 出發，預期立即回傳 `newton_not_descent`，因為 $g^\top d = 1.75 > 0$ 。單純Armijo回溯不能把此方向變成嚴格負方向導數；需另選方向或修改Hessian。加正則化也不自動保證正定，須核對最小特徵值。
- 同一函數從 $(0, 0.5)$ 出發，完整Newton步到達鞍點 $(0, 0)$ ，下一輪回傳 `grad_tol`，不是 `singular_hessian`。故 `grad_tol` 僅表示達到駐點容差，不能視為極小值認證。
- 對 $f(x, y) = x^2 - y^2$ ，從 $(1, 0.1)$ 出發， $H = \text{diag}(2, -2)$ ， $d = (-x, -y)^\top$ ， $g^\top d = -2x^2 + 2y^2 = -1.98 < 0$ 。在預設Armijo參數下，完整一步到達原點並通過條件，下一輪 `grad_tol`；不會出現原先猜測的震盪。

任何測試若未被執行，報告必須明說「僅為預期」，不得虛構時間、步數或收斂階。

反例與常見陷阱

(一) 下降方向不是下降實作. 命題16.1只保證存在 $\bar{t} > 0$ 。若直接令 $\alpha = 1$ 、 $d = -\nabla f(x)$ ，若步長相對曲率太大，函數值反而上升。例如 $f(x) = 10^{12}x^2$ ，固定步長梯度下降為 $x_{k+1} = (1 - 2 \cdot 10^{12}\alpha)x_k$ 。取 $\alpha = 1$ 會發散，但 $0 < \alpha < 10^{-12}$ 時會收斂；不能說任何固定步長都必定爆炸。

(二) Newton方向不是下降方向. 即使 H_f 可逆且不定， d_N 可能使 $g^\top d_N > 0$ 。構造如下：設 $H = \text{diag}(1, -1)$ 、 $g = (\epsilon, 1)$ 且 $0 < \epsilon \ll 1$ 。 $-H^{-1}g = (-\epsilon, 1)$ ， $g^\top d_N = -\epsilon^2 + 1 > 0$ 。這種情形對應於梯度在負曲率方向的分量占優，而正曲率方向的分量僅為小量 ϵ 。修正策略包括修正Hessian（加 τI 使 $H + \tau I$ 正定， $\tau > \max(0, -\lambda_{\min}(H))$ ）或改用信賴域方法，兩者都超出本章範圍。

(三) 把線性收斂誤當二次收斂. 只有在 x_0 足夠接近 x^* 、 $H_f(x^*)$ 可逆且 H_f 局部Lipschitz時，Newton法才有命題16.3的二次收斂。若阻尼Newton法終於進入此吸引鄰域且最終接受完整步，才可沿用局部二次收斂結論；不能對任意加Armijo的序列無條件宣稱「最終二次」。

(四) 「函數值下降」不等於「收斂到駐點」。梯度下降的 $f(x_k)$ 單調遞減且下界存在，只保證 $f(x_k)$ 有有限極限，並不保證此極限是最優值。若無其他條件（如凸性、Łojasiewicz條件或梯度一致性）， $\nabla f(x_k) \rightarrow 0$ 不成立， x_k 可能無極限點。

(五) 條件數與步長. L/μ 大時梯度下降的步長上界 $1/L$ 變小，收斂率 $1 - \mu/L$ 接近1。對不同座標施以不同倍率的縮放可能改變 L/μ ；所有座標同倍率的純量縮放則不改變此比值，因此「演算法快慢」不是座標無關的量；報告必須明示尺度與單位。感測校準的SI情境中，不同成分的Jacobian元素單位不同，直接取歐氏範數會混合單位，見第8章。

AI、幾何與養殖案例

以合成雙參數飼料校準為例。模型預測值為

$$\hat{y}(t) = \theta_1 \phi_1(t) + \theta_2 \phi_2(t), \quad t \in [0, T]$$

ϕ_1 、 ϕ_2 為兩個不同頻率的無因次激發波形， θ_1 、 θ_2 分別帶有「每公斤飼料對應應答」的單位。損失

$$f(\theta) = \frac{1}{2} \sum_{i=1}^N (\hat{y}(t_i) - y_i^{\text{obs}})^2$$

$\nabla f(\theta) = J_\phi(\theta)^\top (\hat{y} - y^{\text{obs}})$ ，此處 $J_\phi \in \mathbb{R}^{N \times 2}$ 。本例對參數為線性模型，Hessian恰為 $J_\phi^\top J_\phi$ ，殘餘的二階導數項恆為零；只有一般非線性最平方才另有殘餘加權項。 $J_\phi^\top J_\phi$ 的正定性等價於 ϕ_1 、 ϕ_2 在採樣時間點上線性無關，也就是**可辨識性**；若兩個波形在 t_i 上近似成比例， H 接近奇異，Newton方向被雜訊放大。

對此合成案例，可行的檢核鍵為：

1. 檢查 $J_\phi^\top J_\phi$ 的特徵值；小特徵值對應弱可辨識方向。
2. 對同一組 y^{obs} 分別跑梯度下降與Newton，比較迭代步數與收斂點；兩者應趨近同一個 θ^* （在凸二次情形）。
3. 對殘餘 $r(\theta) = \hat{y}(\theta) - y^{\text{obs}}$ 做尺度檢查：若單位混用， f 的數值大小不具物理意義，且預測誤差歸因會失真。

必須明示：數學上收斂與否是相對於合成模型；不等於實地飼養試驗的統計顯著性或操作安全。Agent在此角色只整理合成證據，不修改設備、投餌或加藥。

習題

習題16.1（手算） 對 $f(x_1, x_2) = 3x_1^2 + x_1x_2 + 2x_2^2$ ， $x_0 = (2, -1)$ 。(a) 寫出 H_f 並判斷正定性。(b) 用精確線搜尋沿 $d_0 = -\nabla f(x_0)$ 算 x_1 。(c) 用Newton法從 x_0 出發算 x_1 ，並與(a)比較。

習題16.2（程式） 用本章 `gradient_descent` 與 `newton`，在 $A = \text{diag}(1, 100)$ 、 $b = (1, 100)^\top$ 上從 $x_0 = (10, 10)$ 出發。記錄每個方法達到 $\|\nabla f\| < 10^{-8}$ 所需的迭代數與總函數求值次數。解釋兩者的差距為何與 L/μ 相關。

習題16.3（反例） 構造 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ 與點 x_0 使 $\nabla f(x_0) \neq 0$ 、 $H_f(x_0)$ 可逆且不定，且Newton方向 $d_N = -H_f(x_0)^{-1}\nabla f(x_0)$ 滿足 $\nabla f(x_0)^\top d_N > 0$ 。寫出顯式公式並驗證條件。

習題16.4（整合） 令 $f(x) = \frac{1}{2}\|Ax - b\|^2 + \lambda\|x\|_1$ ($\lambda > 0$ 、 $A \in \mathbb{R}^{m \times n}$ 滿行秩)。寫出 f 在 $\|x\|_1$ 可微處的梯度與Hessian，並說明為何本章Newton法在 $x_i = 0$ 處不直接適用。

習題解答

16.1解. (a) $\nabla f = (6x_1 + x_2, x_1 + 4x_2)$ ， $H_f = \begin{pmatrix} 6 & 1 \\ 1 & 4 \end{pmatrix}$ 。 $\text{tr} = 10 > 0$ 、 $\det = 23 > 0$ ，故正定。

(b) $\nabla f(2, -1) = (12 - 1, 2 - 4) = (11, -2)$ ， $d_0 = (-11, 2)$ 。沿 d_0 ：

$$\phi(t) = f(2 - 11t, -1 + 2t)$$

展開： $x_1^2 = 4 - 44t + 121t^2$ ， $x_2^2 = 1 - 4t + 4t^2$ ， $x_1x_2 = (2 - 11t)(-1 + 2t) = -2 + 4t + 11t - 22t^2 = -2 + 15t - 22t^2$ 。

$$\phi(t) = 3(4 - 44t + 121t^2) + (-2 + 15t - 22t^2) + 2(1 - 4t + 4t^2)$$

$$= 12 - 132t + 363t^2 - 2 + 15t - 22t^2 + 2 - 8t + 8t^2 = 12 - 125t + 349t^2$$

$$\phi'(t) = -125 + 698t = 0 \Rightarrow t^* = 125/698 \approx 0.1791 \circ x_1 = (2 - 11t^*, -1 + 2t^*) \approx (0.0301, -0.6418) \circ$$

(c) H_f 正定。 $H_f^{-1} = \frac{1}{23} \begin{pmatrix} 4 & -1 \\ -1 & 6 \end{pmatrix}$ 。Newton 方向

$$d_N = -H_f^{-1} \nabla f(x_0) = -\frac{1}{23} \begin{pmatrix} 4(11) - 1(-2) \\ -1(11) + 6(-2) \end{pmatrix} = -\frac{1}{23} \begin{pmatrix} 46 \\ -23 \end{pmatrix} = (-2, 1)$$

驗證下降性： $\nabla f(x_0)^\top d_N = 11 \cdot (-2) + (-2) \cdot 1 = -24 < 0$ 。Newton 步為

$$x_1 = (2, -1) + (-2, 1) = (0, 0), \quad f(0, 0) = 0$$

一步達到全域最小值，與 f 為正定二次函數的理論一致。

16.2 解 (預期)。 $A = \text{diag}(1, 100)$ ， $b = (1, 100)$ ， $x^* = (1, 1)$ 。依 `quad_factory` 所定義的 $f(x) = \frac{1}{2}x^T A x - b^T x$ ，最小值為 $f^* = -\frac{1}{2}b^T A^{-1}b = -\frac{101}{2} = -50.5$ 。條件數 $\kappa = 100$ 。

先區分固定步長估計與程式的回溯步長。若每一步固定為 $1/L = 1/100$ ，第一座標誤差為 $9(0.99)^k$ ，第二座標一步即歸零。要使梯度範數低於 10^{-8} ，需

$$k > \frac{\log(10^{-8}/9)}{\log(0.99)} \approx 2051.4643,$$

所以精確算術下首次合格為第 2052 次更新，不是 2053。若用 `alpha0=0.01`，理論上此步長符合預設 Armijo 條件；若使用預設 `alpha0=1.0`，實際接受步長不同，不能直接套用此更新數。

以下接在主程式後，實測原題的回溯版本；未執行時只視為可重現測試程序，不填入虛構次數。

`max_iter=10000` 是上限而不是收斂保證，亦檢查最終是否達標。

```
A = np.diag([1.0, 100.0])
b = np.array([1.0, 100.0])
f, grad, hess = quad_factory(A, b)
x_star = np.linalg.solve(A, b).reshape(-1, 1)
def stable_f(x):
    e = np.asarray(x).reshape(-1, 1) - x_star
    return 0.5*(e.T @ A @ e).item()

for solver, objective, label in (
    (gradient_descent, f, "original GD"),
    (newton, f, "original Newton"),
    (gradient_descent, stable_f, "shifted stable GD")):
    counts = {"f": 0, "grad": 0, "hess": 0}
    def counted(name, func):
        def call(x):
            counts[name] += 1
            return func(x)
        return call
    kwargs = dict(f=counted("f", objective), grad=counted("grad", grad),
                  tol=1e-8, max_iter=10000)
    if solver is newton:
        kwargs["hess"] = counted("hess", hess)
```

```

point, log = solver([10.0, 10.0], **kwargs)
updates = sum(row[4] == "ok" for row in log)
residual = np.linalg.norm(grad(point))
print(label, updates, counts, log[-1][4], residual)
if log[-1][4] == "grad_tol":
    assert residual < 1e-8
else:
    print("未達目標：不可把迭代上限或線搜尋失敗當作收斂步數")

```

原函數的最小值為 -50.5 ，接近最優點時，Armijo左右兩邊都接近這個非零常數，微小下降可能被浮點捨入淹沒；即使解析上有收斂率，也可能在指定上限內達不到目標。因此程式保留失敗狀態，而不是硬寫必須成功。第三組改以 $\tilde{f}(x) = \frac{1}{2}(x - x^*)^T A(x - x^*) = f(x) + 50.5$ 穩定求值，最小值變為零，但梯度、Hessian及精確算術下的Armijo條件不變。它使用本題已知的 x^* 作為診斷對照，並非一般未知解問題可直接採用的演算法。

Newton對此精確二次目標在精確算術下一步即到 x^* ，下一輪僅檢查殘差；不是必須再更新一步。每次非終止迭代中，主迴圈呼叫`grad`一次，`armijo`又呼叫一次，函數求值則包含初始值及所有回溯嘗試，不能以單純迭代數代替求值計數。條件數影響固定步長梯度下降的迭代估計，但Newton「一步」性質只適用精確二次模型，不能推廣到一般目標或無視浮點條件數。

16.3解. 令 $H = \text{diag}(1, -1)$ 、 $g = (\epsilon, 1)^\top$ ， $0 < \epsilon < 1$ 。 $-H^{-1}g = -(\epsilon, -1) = (-\epsilon, 1)$ 。

$$g^\top d_N = \epsilon \cdot (-\epsilon) + 1 \cdot 1 = 1 - \epsilon^2 > 0$$

故 d_N 非下降方向。取 $f(x_1, x_2) = \frac{1}{2}x_1^2 - \frac{1}{2}x_2^2 + \epsilon x_1 + x_2$ ，則 $\nabla f(x) = Hx + g$ ，在 $x_0 = (0, 0)$ 處 $\nabla f(x_0) = (\epsilon, 1)$ 、 $H_f(x_0) = H$ ，滿足假設。檢查： $\epsilon = 1/2$ 時 $H^{-1} = \text{diag}(1, -1)$ ， $-H^{-1}g = (-1/2, 1)$ ， $g^\top d_N = 1 - 1/4 = 3/4 > 0$ 。

16.4解. 對 $x_i \neq 0$ ， $\|x\|_1$ 沿 x_i 的偏導為 $\text{sign}(x_i)$ ；對 $x_i = 0$ 處， $\|x\|_1$ 在該座標方向右導數 $= 1$ 、左導數 $= -1$ ，不可微。故

$$\nabla f(x) = A^\top(Ax - b) + \lambda \text{sign}(x) \quad (x_i \neq 0)$$

$H_f(x) = A^\top A$ 在 $\|x\|_1$ 二次可微處；在 $x_i = 0$ 處 H_f 無定義。

Newton法在 $\|x\|_1$ 不可微點不適用，因為其更新式依賴 f 的局部二次模型；線搜尋的方向導數需要 ∇f 存在。可改用近端梯度法或座標下降，其條件與收斂論屬延伸內容，本卷後續章節未承諾完整建立這些演算法。

本章小結

1. 下降引理是Fréchet可微性的直接推論，只用一階餘項控制；「 $\nabla f(x) \neq 0 \Rightarrow -\nabla f$ 為下降方向」為局部結論（命題16.1）。

2. Armijo條件是步長存在的充分條件，其檢核式為 $f(x + \alpha d) \leq f(x) + c_1 \alpha \nabla f(x)^\top d$ ；回溯線搜尋依 $0 < \rho < 1$ 縮減 α 直到成立或耗盡允許步數。
 3. Newton法以 $-H_f(x)^{-1} \nabla f(x)$ 為方向，在 C^2 鄰域、 $H_f(x^*)$ 可逆、 H_f 局部Lipschitz下具有二次收斂；全域化需要外加線搜尋或信賴域，本節不展開。
 4. 不定Hessian有兩類後果：Newton方向可能非下降、步長可能震盪；用Hessian正則化或信賴域處理，屬延伸內容。
 5. 手算例16.1、16.2、16.3展示精確線搜尋、Newton一步與不定Hessian的最小反例。
 6. 可稽核的最佳化報告必須包含：演算法、停止條件、單位與尺度、日誌中每步 f 、 $\|\nabla f\|$ 、 α 與狀態碼；數值實驗只作為證據標籤 `evidence:numeric`，不是定理證明。
-

參考來源

- [A1] Jiří Lebl, *Basic Analysis* (作者目錄與教材入口)，<https://www.jirka.org/ra/>。
- [A2] MIT OCW 18.100A Real Analysis，<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>。
- [A3] MIT OCW 18.02SC Multivariable Calculus，<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>。
- [A4] JAX Autodiff Cookbook: JVP/VJP，
https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html。
- [A5] SciPy `scipy.linalg.expm`，
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>。
- [A6] SciPy `scipy.optimize.minimize`，
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>。

來源狀態：A1為作者首頁；A2、A3為課程概要頁；A4–A6為API文件。以上僅列來源入口，未逐條核對完整內容；A5、A6為延伸參考，本程式不依賴SciPy。

第17章 等式約束、切空間與Lagrange乘數

學習目標與先備知識

本章研究有限維實數空間中的等式約束最佳化：

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{使得} \quad c(x) = 0,$$

其中 $U \subset \mathbb{R}^n$ 為開集， $f: U \rightarrow \mathbb{R}$ ， $c: U \rightarrow \mathbb{R}^m$ 。完成本章後，讀者應能：

1. 正確寫出 $J_c(x) \in \mathbb{R}^{m \times n}$ ，並辨認每條約束對應一個方程橫列。
2. 說明 LICQ 與正則等位集合的關係。
3. 在正則條件下求切空間

$$T_x M = \ker J_c(x).$$

4. 推導 Lagrange 一階必要條件

$$\nabla f(x) + J_c(x)^T \lambda = 0.$$

5. 區分一階必要、二階必要、二階充分與全域最優條件。
6. 使用零空間基底 Z 建立受限 Hessian

$$Z^T \nabla_{xx}^2 L(x, \lambda) Z.$$

7. 正確解讀正定、負定、不定、半定及零維切空間。
8. 用 NumPy 在 CPU 上解線性等式約束二次問題，並檢查秩、殘差與二階曲率。

先備知識包括 Jacobian、梯度、Hessian、隱函數定理、零空間、正交補與二次型。全文採 Euclidean 內積；梯度是 $n \times 1$ 列向量，而標量函數的導數是 $1 \times n$ 線性泛函。

問題與直覺

無約束最佳化允許從內點朝任意小方向移動，因此可微函數在局部極值點必須滿足 $\nabla f(x) = 0$ 。有等式約束後，多數方向不再可行。例如在單位圓

$$x_1^2 + x_2^2 = 1$$

上，瞬時移動必須沿圓周切線，不能任意朝徑向移動。

設可行集合為

$$M = \{x \in U : c(x) = 0\}.$$

若 $\gamma : (-\epsilon, \epsilon) \rightarrow M$ 是 C^1 可行曲線，且 $\gamma(0) = x$ ，則

$$c(\gamma(t)) = 0.$$

由鏈式法則，

$$J_c(x)\gamma'(0) = 0.$$

因此可行曲線的速度必在 $\ker J_c(x)$ 中。在適當的滿秩條件下，每個零空間方向都可由某條可行曲線產生，因而切空間就是 Jacobian 的零空間。

若 x^* 是受限局部極值，目標函數沿每個切向 d 的一階變化應為零：

$$\nabla f(x^*)^T d = 0.$$

這表示 $\nabla f(x^*)$ 垂直於切空間。有限維線性代數給出

$$(\ker J_c(x^*))^\perp = \text{range}(J_c(x^*)^T).$$

所以存在 $\lambda \in \mathbb{R}^m$ 使

$$\nabla f(x^*) + J_c(x^*)^T \lambda = 0.$$

Lagrange 乘數的幾何意義，就是用約束梯度的線性組合平衡目標梯度。

定義、定理與推導

1. 約束 Jacobian 與 LICQ

將約束寫成列向量：

$$c(x) = \begin{bmatrix} c_1(x) \\ \vdots \\ c_m(x) \end{bmatrix}.$$

其 Jacobian 為

$$J_c(x) = \begin{bmatrix} (\nabla c_1(x))^T \\ \vdots \\ (\nabla c_m(x))^T \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

每個約束對應一個方程橫列。 $J_c(x)$ 的列空間 (row space) 是 $\mathbb{R}^n$ 的子空間，其維度為 $\text{rank } J_c(x)$ ； $J_c(x)$ 的行空間 (column space) 是 $\mathbb{R}^m$ 的子空間。Lagrange 條件使用的是 $J_c(x)^T$ 的行空間，亦即約束梯度所張成的法空間。

定義 (LICQ)。 在可行點 x ，若

$$\nabla c_1(x), \dots, \nabla c_m(x)$$

線性獨立，等價地，

$$\text{rank } J_c(x) = m,$$

則稱線性獨立約束資格 LICQ 在 x 成立。LICQ 必然要求 $m \leq n$ 。

LICQ 是保證標準 Lagrange 必要條件的充分正則性條件，但不是乘數存在的必要條件。秩退化時，乘數可能不存在，也可能存在但不唯一。

2. 曲線切空間與線性化切空間

定義 (曲線切空間)。 對 $x \in M$ ，定義

$$T_x M = \{\gamma'(0) : \gamma : (-\epsilon, \epsilon) \rightarrow M \text{ 為 } C^1, \gamma(0) = x\}.$$

對任一可行曲線使用鏈式法則，可得

$$T_x M \subseteq \ker J_c(x).$$

這個包含關係不需要 LICQ。反方向則需要正則性。

定理 (正則等位集合的切空間)。

設 $U \subset \mathbb{R}^n$ 為開集， $c : U \rightarrow \mathbb{R}^m$ 為 C^1 ， $x \in U$ 、 $c(x) = 0$ ，且

$$\text{rank } J_c(x) = m.$$

則 $M = c^{-1}(0)$ 在 x 附近是維度 $n - m$ 的 C^1 子流形，而且

$$T_x M = \ker J_c(x).$$

這是隱函數定理的局部推論。若 LICQ 失效， $\ker J_c(x)$ 只是線性化可行方向集合，可能比真實曲線切空間大很多。

3. Lagrangian 與一階必要條件

定義 Lagrangian：

$$L(x, \lambda) = f(x) + \lambda^T c(x).$$

其中 $\lambda \in \mathbb{R}^m$ 是列向量。其對 x 的梯度是

$$\nabla_x L(x, \lambda) = \nabla f(x) + J_c(x)^T \lambda.$$

因此站立條件為

$$\nabla f(x) + J_c(x)^T \lambda = 0.$$

若改採 $L = f - \lambda^T c$ ，乘數符號會相反；兩種符號約定不能在同一推導中混用。

命題（一階必要條件與乘數唯一性）。

設 $f: U \rightarrow \mathbb{R}$ 與 $c: U \rightarrow \mathbb{R}^m$ 均為 C^1 。若 x^* 是 f 在 $M = \{x: c(x) = 0\}$ 上的局部極小點或局部極大點，且 LICQ 在 x^* 成立，則存在唯一的 $\lambda^* \in \mathbb{R}^m$ 使

$$c(x^*) = 0,$$

$$\nabla f(x^*) + J_c(x^*)^T \lambda^* = 0.$$

證明。

由正則等位集合定理，

$$T_{x^*} M = \ker J_c(x^*).$$

任取 $d \in T_{x^*} M$ 。存在局部 C^1 可行曲線 γ ，使

$$\gamma(0) = x^*, \quad \gamma'(0) = d.$$

因 x^* 是受限局部極值，單變量函數 $f(\gamma(t))$ 在 $t = 0$ 有局部極值，所以

$$0 = \left. \frac{d}{dt} f(\gamma(t)) \right|_{t=0} = \nabla f(x^*)^T d.$$

此式對所有 $d \in \ker J_c(x^*)$ 成立，因此

$$\nabla f(x^*) \in (\ker J_c(x^*))^\perp.$$

有限維基本子空間關係給出

$$(\ker J_c(x^*))^\perp = \text{range}(J_c(x^*)^T).$$

故存在 $\mu \in \mathbb{R}^m$ 使

$$\nabla f(x^*) = J_c(x^*)^T \mu.$$

令 $\lambda^* = -\mu$ ，即得站立條件。

再證唯一性。若 λ_1, λ_2 都滿足站立條件，則

$$J_c(x^*)^T(\lambda_1 - \lambda_2) = 0.$$

LICQ 表示 $J_c(x^*)$ 滿橫列秩，因此 $J_c(x^*)^T$ 的零空間只有零向量，故 $\lambda_1 = \lambda_2$ 。證畢。

這是必要條件，不是充分條件。Lagrange 駐點可能是最小、最大或鞍點。

4. 二階條件與受限 Hessian

假設 $f, c_1, \dots, c_m$ 在 x^* 的鄰域為 C^2 ，且 (x^*, λ^*) 滿足一階條件。定義 Lagrangian 對 x 的 Hessian：

$$H_L = \nabla_{xx}^2 L(x^*, \lambda^*) = \nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla^2 c_i(x^*).$$

非線性約束的 Hessian 項不可省略。只檢查 $\nabla^2 f$ 通常會漏掉可行曲面的曲率。

在 LICQ 下，選取

$$Z \in \mathbb{R}^{n \times (n-m)}$$

使其縱行構成 $\ker J_c(x^*)$ 的基底：

$$J_c(x^*)Z = 0.$$

任一切向可寫為 $d = Zp$ ，所以

$$d^T H_L d = p^T (Z^T H_L Z) p.$$

矩陣

$$H_R = Z^T H_L Z$$

稱為受限 Hessian 或約化 Hessian。若 $Z^T Z = I$ ，則 H_R 的特徵值是在正交切向座標中的二階曲率。換用另一組基底會改變矩陣元素，但不會改變二次型的正定、負定或不定性。

二階必要條件。

若 x^* 是受限局部極小點、LICQ 成立且資料為 C^2 ，則

$$d^T H_L d \geq 0 \quad \text{對所有 } d \in \ker J_c(x^*).$$

若 x^* 是受限局部極大點，則必有

$$d^T H_L d \leq 0 \quad \text{對所有 } d \in \ker J_c(x^*).$$

二階充分條件。

若一階條件與 LICQ 成立，且

$$d^T H_L d > 0 \quad \text{對所有非零 } d \in \ker J_c(x^*),$$

則 x^* 是嚴格受限局部極小點。若對所有非零切向皆小於零，則是嚴格受限局部極大點。

二階分類如下：

- H_R 正定：嚴格受限局部最小的充分條件。
- H_R 負定：嚴格受限局部最大的充分條件。
- H_R 不定：同時違反局部最小的半正定必要條件與局部最大的半負定必要條件，所以在上述 C^2 、LICQ 與站立條件下，不可能是局部極值。
- H_R 正半定但不正定：與局部最小的必要條件相容，且若含正特徵值則排除局部最大；但不能保證嚴格局部最小。
- H_R 負半定但不負定：與局部最大的必要條件相容，且若含負特徵值則排除局部最小；但不能保證嚴格局部最大。
- $H_R = 0$ ：二階測試無法分類，必須研究高階項或直接分析可行曲線。
- 切空間為零維：在 LICQ 下，可行點局部孤立；不應把空矩陣解讀為觀察到正曲率。

值得特別核對：不定二次型的正、負二階項是二次階主導量，高階項不能把兩種符號都消除。因此「不定排除局部極值」是二階必要條件的直接逆否推論；它不是只有線性約束二次問題才成立。

逐步手算例題

例一：圓上的線性目標

求

$$\min f(x, y) = x + 2y \quad \text{使得} \quad c(x, y) = x^2 + y^2 - 1 = 0.$$

約束 Jacobian 為

$$J_c(x, y) = [2x \quad 2y].$$

圓上 $(x, y) \neq (0, 0)$ ，所以 Jacobian 秩為 1，LICQ 成立。Lagrangian 為

$$L = x + 2y + \lambda(x^2 + y^2 - 1).$$

一階條件是

$$1 + 2\lambda x = 0, \quad 2 + 2\lambda y = 0, \quad x^2 + y^2 = 1.$$

由前兩式，

$$x = -\frac{1}{2\lambda}, \quad y = -\frac{1}{\lambda} = 2x.$$

代入約束：

$$5x^2 = 1.$$

候選點為

$$\left(\frac{1}{\sqrt{5}}, \frac{2}{\sqrt{5}}\right), \quad \left(-\frac{1}{\sqrt{5}}, -\frac{2}{\sqrt{5}}\right).$$

其目標值分別為 $\sqrt{5}$ 與 $-\sqrt{5}$ ，所以後者是全域最小，前者是全域最大。全域結論可由直接比較或 Cauchy-Schwarz 不等式得到，不能只由 Lagrange 方程推出。

在最小點，

$$\lambda^* = \frac{\sqrt{5}}{2}, \quad H_L = 2\lambda^* I = \sqrt{5}I.$$

可取單位切向基底

$$Z = \frac{1}{\sqrt{5}} \begin{bmatrix} -2 \\ 1 \end{bmatrix}.$$

故

$$Z^T H_L Z = \sqrt{5} > 0.$$

二階充分條件確認它是嚴格受限局部最小。

在最大點，

$$\lambda^* = -\frac{\sqrt{5}}{2}, \quad Z^T H_L Z = -\sqrt{5} < 0,$$

因此是嚴格受限局部最大。

例二：線性約束二次問題

求

$$\min_{x,y} \frac{1}{2}(x^2 + 2y^2) - 2x - 6y \quad \text{使得} \quad x + y = 2.$$

令

$$Q = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}, \quad q = \begin{bmatrix} -2 \\ -6 \end{bmatrix}, \quad A = [1 \quad 1], \quad b = 2.$$

問題為

$$\min_z \frac{1}{2} z^T Q z + q^T z \quad \text{使得} \quad Az = b.$$

一階條件為

$$Qz + q + A^T \lambda = 0, \quad Az = b.$$

展開：

$$x - 2 + \lambda = 0,$$

$$2y - 6 + \lambda = 0,$$

$$x + y = 2.$$

由前兩式，

$$x = 2 - \lambda, \quad y = 3 - \frac{\lambda}{2}.$$

代入約束得 $\lambda = 2$ ，因此

$$(x^*, y^*) = (0, 2).$$

切空間為 $\ker A$ ，可取

$$Z = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

約束是線性的，所以 $H_L = Q$ 。受限 Hessian 為

$$Z^T Q Z = \frac{3}{2} > 0.$$

因此該點是嚴格受限局部最小。又因 Q 正定、目標嚴格凸且可行集合是仿射集合，所以它也是唯一全域最小。這個全域結論額外使用了凸性。

實作與程式

以下程式只依賴 NumPy，在 CPU 上解線性等式約束二次問題：

$$\min_x \frac{1}{2} x^T Q x + q^T x \quad \text{使得} \quad A x = b.$$

KKT 系統是

$$\begin{bmatrix} Q & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ \lambda \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix}.$$

程式明確區分正定、負定、不定、非零正半定、非零負半定、數值零及零維切空間。半定分類同時說明「與哪一類必要條件相容」及「不能推出哪一類充分結論」。

```
import numpy as np

def nullspace_basis(A, rtol=1e-12):
    A = np.asarray(A, dtype=float)
    if A.ndim != 2:
        raise ValueError("A must be a two-dimensional matrix")

    _, s, vt = np.linalg.svd(A, full_matrices=True)
    scale = s[0] if s.size else 1.0
    threshold = rtol * max(scale, 1.0)
    rank = int(np.sum(s > threshold))
    Z = vt[rank:, :].T
    return Z, rank

def classify_reduced_hessian(eigvals, tol=1e-10):
    eigvals = np.asarray(eigvals, dtype=float)

    if eigvals.size == 0:
        return {
            "curvature_class": "zero-dimensional tangent space",
            "second_order_conclusion":
                "locally isolated feasible point under LICQ"
        }

    all_pos = bool(np.all(eigvals > tol))
    all_neg = bool(np.all(eigvals < -tol))
    has_pos = bool(np.any(eigvals > tol))
    has_neg = bool(np.any(eigvals < -tol))
    all_near_zero = bool(np.all(np.abs(eigvals) <= tol))
```

```

if all_pos:
    return {
        "curvature_class": "positive definite",
        "second_order_conclusion":
            "sufficient for a strict local minimum"
    }

if all_neg:
    return {
        "curvature_class": "negative definite",
        "second_order_conclusion":
            "sufficient for a strict local maximum"
    }

if has_pos and has_neg:
    return {
        "curvature_class": "indefinite",
        "second_order_conclusion":
            "rules out both a local minimum and a local maximum"
    }

if all_near_zero:
    return {
        "curvature_class": "numerically zero",
        "second_order_conclusion":
            "inconclusive; higher-order analysis is required"
    }

if has_pos and not has_neg:
    return {
        "curvature_class": "positive semidefinite, not definite",
        "second_order_conclusion":
            "compatible with a minimum necessary condition, "
            "rules out a maximum, but is not sufficient for "
            "a strict minimum"
    }

return {
    "curvature_class": "negative semidefinite, not definite",
    "second_order_conclusion":
        "compatible with a maximum necessary condition, "
        "rules out a minimum, but is not sufficient for "
        "a strict maximum"
}

def solve_equality_qp(Q, q, A, b, tol=1e-10):
    Q = np.asarray(Q, dtype=float)
    q = np.asarray(q, dtype=float).reshape(-1, 1)
    A = np.asarray(A, dtype=float)
    b = np.asarray(b, dtype=float).reshape(-1, 1)

    n = q.shape[0]
    if Q.shape != (n, n):
        raise ValueError("Q must have shape (n, n)")
    if not np.allclose(Q, Q.T, atol=tol, rtol=0.0):
        raise ValueError("Q must be symmetric")
    if A.ndim != 2 or A.shape[1] != n:
        raise ValueError("A must have shape (m, n)")

```

```

m = A.shape[0]
if b.shape != (m, 1):
    raise ValueError("b must have shape (m, 1)")

Z, rank = nullspace_basis(A)
if rank < m:
    raise ValueError("LICQ fails: A lacks full row rank")

K = np.block([
    [Q, A.T],
    [A, np.zeros((m, m))]
])
rhs = np.vstack([-q, b])

try:
    solution = np.linalg.solve(K, rhs)
except np.linalg.LinAlgError as exc:
    raise ValueError("KKT matrix is singular") from exc

x = solution[:n]
lam = solution[n:]

feasibility = A @ x - b
stationarity = Q @ x + q + A.T @ lam
reduced = Z.T @ Q @ Z
eigvals = (
    np.linalg.eigvalsh(reduced)
    if reduced.size
    else np.array([], dtype=float)
)
classification = classify_reduced_hessian(eigvals, tol)

result = {
    "x": x,
    "lambda": lam,
    "rank_A": rank,
    "Z": Z,
    "reduced_hessian": reduced,
    "reduced_eigenvalues": eigvals,
    "feasibility_norm":
        float(np.linalg.norm(feasibility, 2)),
    "stationarity_norm":
        float(np.linalg.norm(stationarity, 2)),
}
result.update(classification)
return result

if __name__ == "__main__":
    Q = np.array([[1.0, 0.0],
                  [0.0, 2.0]])
    q = np.array([-2.0,
                  [-6.0]])
    A = np.array([[1.0, 1.0]])
    b = np.array([2.0])

    result = solve_equality_qp(Q, q, A, b)
    for key, value in result.items():
        print(key, value)

```

程式中的 `q`、`b`、`x` 與 `lambda` 都使用明確的二維列向量形狀，沒有以 NumPy 一維陣列的 `.T` 冒充轉置。

本章未執行程式。下一節結果均為解析推導所得的預期結果，不是實際執行紀錄。此程式直接處理線性約束二次問題；對非線性約束，必須另行計算完整的 H_L 。

測試與預期結果

正常測試：正定受限 Hessian

使用例二資料，預期

$$x = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \lambda = [2].$$

可行殘差與站立殘差預期接近浮點捨入尺度。受限 Hessian 的唯一特徵值為 1.5，預期分類為正定，並標示「嚴格局部最小的充分條件」。

SVD 所產生的 Z 可能與手算基底相差一個負號，但 $Z^T Q Z$ 不變。

正常測試：負定

取

$$Q = -I_2, \quad q = 0, \quad A = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad b = 0.$$

切空間由第二座標方向張成，受限 Hessian 為 $[-1]$ 。預期分類為負定，並標示嚴格局部最大的充分條件。

正常測試：不定

取

$$Q = \text{diag}(1, -1, 2), \quad A = \begin{bmatrix} 0 & 0 & 1 \end{bmatrix}, \quad b = 0.$$

切空間是前兩座標平面，受限 Hessian 特徵值為 $1, -1$ 。預期分類為不定，因而排除局部最小與局部最大。對此二次問題，沿可行方向 $(t, 0, 0)^T$ 目標增加，而沿 $(0, t, 0)^T$ 目標減少，可直接看出鞍型行為。

邊界測試：正半定但不正定

取零條約束，並令

$$Q = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

受限 Hessian 特徵值為 0, 1。此例須直接呼叫 `classify_reduced_hessian(np.array([0.0, 1.0]))`，才會得到預期分類「正半定但不正定」；呼叫 `solve_equality_qp` 則會在分類前因奇異 KKT 矩陣拋出 `ValueError`。即使取 $q = 0$ ，這個求解故障仍然存在。事實上，在 LICQ 下，受限 Hessian 若有零特徵值，KKT 矩陣必定奇異；不能藉增加約束，同時保留切空間中的零特徵值與非奇異 KKT 矩陣。分類結果與局部最小的二階必要條件相容，也因存在正方向而排除局部最大，但不能保證嚴格局部最小。

對這個精確二次目標，若 $q = 0$ ，原點確實是非嚴格全域最小，且沿第二座標方向有無窮多個最小點；這是利用完整二次模型得到的額外結論，不是一般半正定測試自動提供的嚴格性結論。現有求解函式不處理奇異 KKT 系統的相容性或非唯一解，不能將獨立分類函式的輸出冒稱為完整求解結果。

邊界測試：零維切空間

取 $A = I_n$ 。可行點由 $x = b$ 唯一決定， Z 的形狀為 $n \times 0$ ，受限 Hessian 是 0×0 矩陣。預期分類為「零維切空間」與「LICQ 下局部孤立可行點」，而非宣稱觀察到正曲率。

故障測試：冗餘約束

令

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

因 $\text{rank } A = 1 < 2$ ，預期程式拋出 `ValueError`，指出 LICQ 失敗。可行集合本身仍可能良好，但乘數不唯一，KKT 矩陣也可能奇異。

故障測試：不相容約束

若沿用上述 A ，但令

$$b = \begin{bmatrix} 2 \\ 5 \end{bmatrix},$$

則可行集合為空。現有程式會先因秩不足拒絕輸入，並不自行區分「冗餘且相容」與「冗餘且不相容」。實務上應另以最小平方殘差檢查 $Ax = b$ 的相容性。

反例與常見陷阱

1. 秩退化使零空間高估真實切空間

考慮

$$c(x, y) = x^2 + y^2 = 0.$$

可行集合只有原點，但

$$J_c(0, 0) = \begin{bmatrix} 0 & 0 \end{bmatrix},$$

因此

$$\ker J_c(0, 0) = \mathbb{R}^2.$$

任何可行曲線都只能是常曲線，故真實曲線切空間只有 $\{0\}$ 。沒有 LICQ 時，

$$T_x M = \ker J_c(x)$$

可能完全失效。

再令 $f(x, y) = x$ 。原點是唯一可行點，因此同時是受限最小與最大；可是 Lagrange 方程要求

$$\begin{bmatrix} 1 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} 0 \\ 0 \end{bmatrix} = 0,$$

不可能成立。這說明約束資格是必要條件定理中的實質假設。

2. 一階駐點不等於最小點

在單位圓上令 $f(x, y) = x$ 。點 $(1, 0)$ 與 $(-1, 0)$ 都滿足 Lagrange 方程，但前者是最大點，後者是最小點。站立條件只能產生候選點。

3. 不能只檢查目標 Hessian

對非線性約束，正確的二階矩陣是

$$H_L = \nabla^2 f + \sum_i \lambda_i \nabla^2 c_i.$$

圓上的線性目標滿足 $\nabla^2 f = 0$ ，但沿圓周仍有非零二階曲率；此曲率來自約束 Hessian。

4. 半定或零 Hessian 無法完整分類

在約束 $y = 0$ 上比較

$$f_1(x, y) = x^4, \quad f_2(x, y) = -x^4, \quad f_3(x, y) = x^3.$$

三者在原點的受限 Hessian 都是零，但 f_1 有嚴格局部最小， f_2 有嚴格局部最大， f_3 不是局部極值。因此零 Hessian 必須標示為未判定。

5. 不定與高階項

若受限 Hessian 不定，存在切向 d_+ 、 d_- 使

$$d_+^T H_L d_+ > 0, \quad d_-^T H_L d_- < 0.$$

沿對應的局部可行曲線，二階 Taylor 主項分別具有正負符號，而餘項是 $o(t^2)$ ，不能消除固定非零二次係數的符號。因此在 C^2 、LICQ 與站立條件下，不定確實排除局部極值。不能把「半定未判定」錯誤延伸成「不定也未判定」。

6. 數值分類不是定理證明

浮點特徵值依賴尺度與容差。接近零的特徵值可能因捨入略正或略負。程式中的 `tol` 只是數值證據門檻，不是數學正定性的證明。殘差小也不代表問題條件良好。

AI、幾何與養殖案例

考慮純合成的養殖感測校準。設兩個無因次化增益修正為

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}.$$

為固定總體增益，施加

$$c(\theta) = \theta_1 + \theta_2 = 0.$$

其 Jacobian 為

$$J_c = \begin{bmatrix} 1 & 1 \end{bmatrix},$$

切空間為

$$\ker J_c = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

可取單位基底

$$Z = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

設合成損失為

$$f(\theta) = \frac{1}{2} \|W(M\theta - r)\|_2^2.$$

若原始殘差同時包含攝氏溫度與溶氧濃度 mg/L，不同單位不能直接放進無權重 Euclidean 長度。矩陣 W 應包含各輸出的參考尺度倒數，使殘差先無因次化；返回物理值時再乘回相應尺度。

令

$$H = M^T W^T W M, \quad g = -M^T W^T W r.$$

問題成為

$$\min_{\theta} \frac{1}{2} \theta^T H \theta + g^T \theta \quad \text{使得} \quad J_c \theta = 0.$$

切向可辨識性由

$$Z^T H Z$$

衡量。若此量明顯為正，二次模型在唯一可行參數方向上有正曲率；若接近零，參數可能對資料噪音高度敏感。即使 KKT 殘差很小，也不能把弱曲率誤解為可靠辨識。

AI 系統可以整理 Jacobian、LICQ、乘數、殘差與受限 Hessian，但有限樣本不能證明整個參數域上的正則性。此處是合成案例；模型校準不等於現場驗證，數學穩定也不等於操作安全。唯讀分析不控制設備、不投餌、不加藥。

習題

1. **手算題。** 求 $f(x, y) = x^2 + y^2$ 在約束 $x + 2y = 3$ 下的最小點、乘數及受限 Hessian。
2. **程式題。** 使用本章程式解

$$Q = \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix}, \quad q = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \quad A = [1 \quad -1], \quad b = 0.$$

先手算預期值，再列出應檢查的殘差與分類。

3. 反例題。對約束

$$c(x, y) = y^2 - x^3 = 0,$$

求原點的 J_c 與零空間，並給出通過原點的可行曲線。解釋線性化為何失效。

4. 整合題。設

$$f(x, y) = x, \quad c(x, y) = x^2 + y^2 - 1.$$

求所有 Lagrange 駐點，以受限 Hessian 分類，並區分一階必要、二階充分與全域結論。

習題解答

第1題

Lagrangian 為

$$L = x^2 + y^2 + \lambda(x + 2y - 3).$$

一階條件為

$$2x + \lambda = 0, \quad 2y + 2\lambda = 0, \quad x + 2y = 3.$$

因此

$$x = -\frac{\lambda}{2}, \quad y = -\lambda.$$

代入約束得

$$\lambda = -\frac{6}{5},$$

所以

$$(x^*, y^*) = \left(\frac{3}{5}, \frac{6}{5}\right).$$

可取切向基底

$$Z = \frac{1}{\sqrt{5}} \begin{bmatrix} -2 \\ 1 \end{bmatrix}.$$

約束為線性，故 $H_L = 2I$ ，因此

$$Z^T H_L Z = 2 > 0.$$

此點是嚴格受限局部最小。由目標嚴格凸與約束仿射，亦知它是唯一全域最小。

第2題

約束 $x - y = 0$ 給出 $x = y = t$ 。代入目標：

$$\frac{1}{2} \begin{bmatrix} t & t \end{bmatrix} Q \begin{bmatrix} t \\ t \end{bmatrix} - \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} t \\ t \end{bmatrix} = 4t^2 - 2t.$$

微分得 $8t - 2 = 0$ ，故

$$x^* = y^* = \frac{1}{4}.$$

又

$$Qx^* + q = \begin{bmatrix} 1/4 \\ -1/4 \end{bmatrix},$$

所以

$$\lambda = -\frac{1}{4}.$$

切向基底可取

$$Z = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

並有

$$Z^T Q Z = 4 > 0.$$

預期程式分類為正定。應檢查

$$\|Ax^* - b\|_2$$

與

$$\|Qx^* + q + A^T \lambda\|_2$$

皆接近浮點捨入尺度。因 Q 正定，此解也是唯一全域最小。

第3題

有

$$J_c(x, y) = \begin{bmatrix} -3x^2 & 2y \end{bmatrix}.$$

因此

$$J_c(0, 0) = \begin{bmatrix} 0 & 0 \end{bmatrix}, \quad \ker J_c(0, 0) = \mathbb{R}^2.$$

可行曲線可取

$$\gamma_+(t) = (t^2, t^3), \quad \gamma_-(t) = (t^2, -t^3).$$

兩者皆滿足 $y^2 = x^3$ ，但其在原點的速度都是零。可行集合在原點形成尖點，不是正則的一維 C^1 子流形；Jacobian 零空間卻是整個平面。失效原因正是 LICQ 不成立。

第4題

Lagrangian 為

$$L = x + \lambda(x^2 + y^2 - 1).$$

一階條件為

$$1 + 2\lambda x = 0, \quad 2\lambda y = 0, \quad x^2 + y^2 = 1.$$

λ 不可能為零，所以 $y = 0$ 、 $x = \pm 1$ 。在 $(1, 0)$ ，

$$\lambda = -\frac{1}{2};$$

在 $(-1, 0)$ ，

$$\lambda = \frac{1}{2}.$$

兩點皆可取切向基底

$$Z = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

由 $H_L = 2\lambda I$ 可得：

$$Z^T H_L Z = -1$$

於 $(1, 0)$ ，所以它是嚴格受限局部最大；

$$Z^T H_L Z = 1$$

於 $(-1, 0)$ ，所以它是嚴格受限局部最小。

Lagrange 方程提供一階必要候選點；受限 Hessian 的定號提供二階充分判別。最後，由單位圓上 $-1 \leq x \leq 1$ ，可知兩點分別是全域最大與全域最小。圓的緊緻性與 f 的連續性則保證全域極值存在。

本章小結

等式約束最佳化的核心鏈條是

$$\text{LICQ} \implies T_x M = \ker J_c(x) \implies \nabla f(x) \perp T_x M \implies \nabla f(x) + J_c(x)^T \lambda = 0.$$

其中 $J_c(x) \in \mathbb{R}^{m \times n}$ ；正則情況下，切空間維度為 $n - m$ 。一階 Lagrange 條件只產生候選點。

二階判別必須使用完整的 Lagrangian Hessian：

$$H_L = \nabla^2 f + \sum_i \lambda_i \nabla^2 c_i.$$

在切空間基底 Z 下，分析

$$Z^T H_L Z.$$

正定與負定分別給出嚴格局部最小與最大的充分條件；不定違反極值的二階必要條件，因而排除局部極值；半定只提供必要條件相容性，通常不能完成分類。秩退化時，線性化切空間可能失真，乘數也可能不存在或不唯一。

數值實作應報告秩、可行殘差、站立殘差、特徵值與分類容差。有限精度計算只能提供數值證據，不能取代 LICQ、可微性與二階定理的證明。

參考來源

1. Jiří Lebl, *Basic Analysis*, 作者教材入口：<https://www.jirka.org/ra/>
2. MIT OpenCourseWare, 18.100A Real Analysis：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>

3. MIT OpenCourseWare, 18.02SC Multivariable Calculus : <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

4. SciPy, `minimize` 方法與參數文件, 作為延伸最佳化 API 參考 :

<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>

本章核心程式不依賴 SciPy, 也未執行外部程式。以上來源僅作教材與延伸入口 ; 各定理仍以正文所列的有限維、正則性與秩條件為準。

第18章 不等式約束與KKT橋接

學習目標與先備知識

完成本章後，讀者應能以一致的符號寫出不等式約束的 Karush–Kuhn–Tucker (KKT) 條件，辨認哪些條件是局部最小值的**必要條件**、哪些足以保證**全域最小值**，並用主動集枚舉核對二維盒約束問題。先備知識包括梯度、凸函數、等式約束的 Lagrange 乘數，以及矩陣秩。這裡梯度一律是直向的列向量；標量函數 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的導數 $Df(x)$ 則是 $1 \times n$ 線性泛函， $Df(x)[d] = \nabla f(x)^T d$ 。

本章的判斷順序是：先查可行性，再查局部最優所需的約束資格，最後判斷凸性是否允許把 KKT 證書提升為全域證書。計算只能核對特定候選點；有限個候選點或浮點輸出，不能自行證明一般定理。

問題與直覺

設要最小化 $f(x)$ ，同時要求 $g_i(x) \leq 0$ 。在可行域內，若某個約束嚴格小於零，它在該點尚有餘裕，通常不阻擋足夠小的移動；若等於零，該約束便稱為**主動**。在光滑邊界的局部最小值，目標函數的下降方向可能被主動約束擋住。乘數描述這種阻擋如何在梯度方程中平衡，而不直接表示現實世界的力。

符號尤其重要。採用 $g_i \leq 0$ 、最小化 f 與 $L = f + \sum_i \lambda_i g_i$ 時，乘數必須非負。若把約束改寫成相反方向卻不更換乘數規則，就可能把最大值誤判為最小值。

以盒 $a \leq x \leq b$ 為例，下界應寫成 $a - x \leq 0$ ，上界寫成 $x - b \leq 0$ 。盒角落可能同時有兩個主動面；但「主動」不等於「乘數嚴格為正」：主動約束的乘數也可以是零。

定義、定理與推導

定義：可行域與 KKT 條件。 令 $U \subset \mathbb{R}^n$ 為開集， $f, g_1, \dots, g_p: U \rightarrow \mathbb{R}$ 為連續可微函數，並令

$$F = \{x \in U : g_i(x) \leq 0, i = 1, \dots, p\}, \quad L(x, \lambda) = f(x) + \sum_{i=1}^p \lambda_i g_i(x).$$

在候選點 x^* ，KKT 條件為

$g_i(x^*) \leq 0$	原始可行性,
$\lambda_i \geq 0$	對偶可行性,
$\lambda_i g_i(x^*) = 0$	互補鬆弛,
$\nabla f(x^*) + J_g(x^*)^T \lambda = 0$	站立條件.

此處 J_g 是 $p \times n$ 矩陣， λ 是 $p \times 1$ 列向量；各維度因而相容。互補鬆弛表示非主動約束的乘數必為零，反向推論則不成立。

定義：約束資格。 在 x^* ，令主動指標集合為 $A(x^*) = \{i : g_i(x^*) = 0\}$ 。若主動梯度 $\{\nabla g_i(x^*) : i \in A(x^*)\}$ 線性獨立，稱滿足 LICQ。沒有主動約束時，LICQ 視為成立。LICQ 是保證局部最小值具有 KKT 乘數的一種**充分約束資格**，並非 KKT 成立的必要條件。

定理：非凸問題的局部必要條件。 若 $x^* \in F$ 是局部最小值， f, g_i 在其開鄰域連續可微，且 x^* 滿足 LICQ，則存在乘數 λ 使 KKT 條件成立。這是必要條件，並未聲稱該點為全域最小值；此定理在此引用，不以有限方向取樣替代證明。

LICQ 並非唯一的約束資格。例如，對只有不等式的問題，另一種條件是存在方向 $d \in \mathbb{R}^n$ ，使每條主動約束都滿足 $\nabla g_i(x^*)^T d < 0$ ；這稱為 MFCQ 的純不等式形式。它要求有一個一階方向能同時走入所有主動邊界的內側，卻不要求主動梯度彼此獨立。在連續可微與局部最小的假設下，MFCQ 也足以保障 KKT 乘數存在；此結果同樣在此引用。例如把同一條盒上界重複列出兩次，兩個相同的主動梯度使 LICQ 失效，但仍可能存在共同向內的方向。相反，若主動梯度全為零，便不能憑「該點可行」推定乘數存在。不同約束資格提供不同的**充分途徑**；未通過某一種資格測試，並不能直接判定點不是最小值。

定義：Slater 條件。 對凸最佳化問題，若可行域另含仿射等式 $Ax = b$ ，本章採用一個簡便的充分版本：存在滿足 $Ax = b$ 、每一個不等式均嚴格滿足 $g_i(x) < 0$ ，且位於相關定義域相對內部的點。對仿射不等式，常見的較一般版本允許適當放寬嚴格性；本章不需要該擴充。純盒問題若每段區間都有正長度，其內點即提供嚴格可行點。Slater 不能拿來使非凸問題的 KKT 駐點自動變成全域最優。

小命題：凸問題的 KKT 全域充分性。 設 $C \subset \mathbb{R}^n$ 為凸集， $f, g_1, \dots, g_p$ 在包含 C 的開鄰域可微且於 C 凸。若 $x^* \in C$ 與 $\lambda \geq 0$ 滿足上述 KKT 條件，則 x^* 在 $F \cap C$ 上為全域最小值。本命題只主張充分性；其證明不需要 Slater。

證明。 任取 $y \in F \cap C$ 。凸函數的一階不等式給出

$$f(y) \geq f(x^*) + \nabla f(x^*)^T (y - x^*),$$

以及對每個 i ，

$$g_i(y) \geq g_i(x^*) + \nabla g_i(x^*)^T (y - x^*).$$

以 $\lambda_i \geq 0$ 乘第二組不等式並求和，再利用站立條件，可得

$$f(y) - f(x^*) \geq - \sum_i \lambda_i \nabla g_i(x^*)^T (y - x^*) \geq \sum_i \lambda_i (g_i(x^*) - g_i(y)).$$

互補鬆弛使右端第一部分 $\sum_i \lambda_i g_i(x^*) = 0$ ；又因 $g_i(y) \leq 0$ 、 $\lambda_i \geq 0$ ，所以剩餘的 $-\sum_i \lambda_i g_i(y) \geq 0$ 。故 $f(y) \geq f(x^*)$ 。由於 y 任意，命題得證。□

在標準的可微凸問題中，適當的 Slater 條件可用來保證最優解具有乘數，使 KKT 也成為**必要**條件；其乘數存在定理在此引用。須分清兩條邏輯：凸性加 KKT 給全域充分性；凸性加約束資格協助由最優性取得 KKT。單有 Slater 而無凸性，沒有前一項保證。

盒約束還提供直接的分量判斷。對 $a_j \leq x_j \leq b_j$ ，設下界乘數 $\alpha_j \geq 0$ 、上界乘數 $\beta_j \geq 0$ ，則

$$\partial_j f(x) - \alpha_j + \beta_j = 0, \quad \alpha_j(a_j - x_j) = \beta_j(x_j - b_j) = 0.$$

因此在下界且上界未啟動時， $\partial_j f(x) = \alpha_j \geq 0$ ；在上界時， $\partial_j f(x) = -\beta_j \leq 0$ ；在內部時， $\partial_j f(x) = 0$ 。這些是候選點的 KKT 符號測試，不是對任意函數的全域最小判別。

逐步手算例題

例一：有一個主動邊界的凸二次函數。 在 $0 \leq x, y \leq 1$ 上最小化

$$f(x, y) = (x - 2)^2 + (y - \frac{1}{4})^2.$$

無約束駐點 $(2, \frac{1}{4})$ 不可行。沿 x ，當 $0 \leq x \leq 1$ 時有 $2(x - 2) < 0$ ，故增大 x 會降低目標，最優點須取 $x = 1$ ；沿 y ，平方項在 $y = \frac{1}{4}$ 最小。因此 $x^* = (1, \frac{1}{4})$ ， $f(x^*) = 1$ 。

按下界 $-x, -y$ 與上界 $x - 1, y - 1$ 的順序排列約束。此點只有 $x - 1 = 0$ ，且 $\nabla f(x^*) = (-2, 0)^T$ 、 $\nabla(x - 1) = (1, 0)^T$ 。站立條件給上界乘數 2，其他乘數為零。四種 KKT 條件均成立。目標及仿射約束皆凸，故上面的小命題另行證明它是全域最小值；這一步不是僅靠手算枚舉的猜測。

例二：角落與主動零乘數。 在同一盒上最小化

$$q(x, y) = x^2 + y.$$

因 $x^2 \geq 0, y \geq 0$ ，手算得唯一最小點 $(0, 0)$ ，值為零。其梯度為 $(0, 1)^T$ ，兩條下界 $-x \leq 0, -y \leq 0$ 均主動。站立條件

$$(0, 1)^T - \alpha_x(1, 0)^T - \alpha_y(0, 1)^T = 0$$

給 $\alpha_x = 0, \alpha_y = 1$ 。所以「主動就必有正乘數」是錯的；仍須保留零乘數與主動約束的區別。此例的全域結論也可由凸性和 KKT 取得。

實作與程式

以下程式對二維盒的三種座標狀態——下界、內部、上界——逐一組合。若某座標被固定在邊界，便解另一座標的無約束站立方程；若兩者均在內部，便解二維站立方程。它只適用於程式所寫的可分離二次目標，不是一般非線性 KKT 求解器。程式使用 Python 標準庫，CPU 即可執行；本章未執行它。

每個座標有三種標記，所以總共檢視 $3^2 = 9$ 種狀態組合。這個數目不是九個互異的可行點：若偏好中心位於盒外，某些「內部」解會先被捨棄；若偏好中心恰好等於端點，不同標記還可能指向同一幾何位置。程式保留通過位置篩選的紀錄，分別檢查原始可行、乘數符號、互補和站立，最後才選出通過 KKT 的紀錄。這種分欄記錄比僅輸出一個最低函數值更容易追查符號錯誤。

```
from itertools import product
from math import isfinite
```



```

def enumerate_box(center, weight, lo=(0.0, 0.0), hi=(1.0, 1.0)):
    """Minimize sum_j weight[j] * (x[j] - center[j])**2 on a 2D box.
    Reports feasible stationary active-set candidates and KKT checks.
    """
    if not all(len(v) == 2 for v in (center, weight, lo, hi)):
        raise ValueError("all inputs must have length two")
    try:
        finite = all(isfinite(v)
                     for seq in (center, weight, lo, hi) for v in seq)
    except TypeError as exc:
        raise ValueError("all entries must be finite numbers") from exc
    if not finite:
        raise ValueError("all entries must be finite numbers")
    if any(lo[j] >= hi[j] for j in range(2)):
        raise ValueError("each box interval must have positive length")
    if any(weight[j] <= 0 for j in range(2)):
        raise ValueError("weights must be positive")

    tol = 1e-12
    records = []
    for status in product(("lower", "free", "upper"), repeat=2):
        x = tuple(
            lo[j] if status[j] == "lower" else
            hi[j] if status[j] == "upper" else center[j]
            for j in range(2)
        )
        if any(x[j] < lo[j] - tol or x[j] > hi[j] + tol
              for j in range(2)):
            continue

        grad = tuple(2.0 * weight[j] * (x[j] - center[j])
                     for j in range(2))
        lower = tuple(grad[j] if status[j] == "lower" else 0.0
                      for j in range(2))
        upper = tuple(-grad[j] if status[j] == "upper" else 0.0
                      for j in range(2))
        primal = all(lo[j] - x[j] <= tol and x[j] - hi[j] <= tol
                     for j in range(2))
        dual = all(v >= -tol for v in lower + upper)
        comp = all(abs(lower[j] * (lo[j] - x[j])) <= tol and
                   abs(upper[j] * (x[j] - hi[j])) <= tol
                   for j in range(2))
        residual = max(abs(grad[j] - lower[j] + upper[j])
                       for j in range(2))
        stationarity = residual <= tol
        kkt = primal and dual and comp and stationarity
        value = sum(weight[j] * (x[j] - center[j])** 2
                    for j in range(2))
        records.append({
            "status": status, "x": x, "value": value,
            "lower": lower, "upper": upper,
            "primal": primal, "dual": dual,
            "complementarity": comp,
            "stationarity_residual": residual, "kkt": kkt
        })
    return records

def best_kkt(records):

```

```

valid = [r for r in records if r["kkt"]]
if not valid:
    raise ValueError("no KKT candidate found")
return min(valid, key=lambda r: r["value"])

if __name__ == "__main__":
    cases = (
        ("normal", (2.0, 0.25), (1.0, 1.0)),
        ("boundary", (0.0, -1.0), (1.0, 0.5)),
    )
    for name, center, weight in cases:
        records = enumerate_box(center, weight)
        print(name, "checked", len(records), "best", best_kkt(records))
    try:
        enumerate_box((2.0, 0.25), (1.0, 0.0))
    except ValueError as exc:
        print("failure:", exc)

```

用 $w_j > 0$ 是為了讓每一個「free」座標的站立解確實為 `center[j]`，並確保嚴格凸性。容差 $1e-12$ 是本例量級約為一時的示範性判斷門檻，並非通用的誤差保證；若把資料放大許多倍，固定的絕對容差可能不合適。程式以容差作浮點核對，不能由此推得精確等式；接近容差時應回到解析式，或依輸入尺度、計算誤差另訂檢查準則。枚舉對指定目標奏效的數學原因是可分離與正權重，而不是因為電腦「試遍了」連續盒中的所有點。

測試與預期結果

正常測試，未執行的預期： `normal` 對應例一，最好的 KKT 紀錄為 $x = (1, 0.25)$ 、目標值 1、 x 上界乘數 2。被保留但對偶乘數為負的邊界紀錄可能不是 KKT 點；不能只看其站立殘差。

邊界測試，未執行的預期： `boundary` 的目標為 $x^2 + \frac{1}{2}(y+1)^2$ ，最好的 KKT 紀錄在 $(0, 0)$ ，值為 0.5；兩個下界主動，其中 x 下界乘數為零、 y 下界乘數為 1。這也檢查了「主動但零乘數」情形。

故障測試，未執行的預期： 零權重觸發 `ValueError`，因為「free 座標必等於 center」的枚舉推導不再由嚴格凸二次項保證。顛倒的盒端點、非有限輸入與錯誤長度亦會被拒絕。拒絕輸入是程式適用範圍的聲明，不表示一般零權重問題沒有最小值。

反例與常見陷阱

首先，KKT 不保證非凸問題的最小性。在 $-1 \leq x \leq 1$ 最小化 $f(x) = -x^2$ ，內點 $x = 0$ 的梯度為零、兩個盒約束均不主動，故它符合 KKT，卻是局部最大點；全域最小值 -1 出現在兩端。於是「駐點一概是全域最小」即使加上盒約束也不成立。

其次，局部最小值可能因約束資格失效而沒有 KKT 乘數。考慮最小化 $f(x) = x$ ，要求 $g(x) = x^2 \leq 0$ 。可行域只有 $\{0\}$ ，故零點是最小值；但 $g'(0) = 0$ 、 $f'(0) = 1$ ，站立方程 $1 + \lambda \cdot 0 = 0$ 無解。此處 LICQ 失效，也沒有嚴格可行點。不能把「沒有乘數」直接解讀為「不是最小值」。

最後，從等式約束搬來的切空間二階判據不可原封套用。對不等式，邊界上可行的微小移動通常是單側的；主動梯度所定的可行方向與臨界方向需分別處理。光滑非凸問題若需判別二階局部最小性，還要考慮乘數、臨界錐及額外正則性；本章不以簡單的 $Z^T H_L Z$ 取代該理論。

AI、幾何與養殖案例

設有兩個**合成**且已無因次化的校準參數 x, y ，規格各限制在 $[0, 1]$ 。模型給出偏好的無因次位置 $(2, 0.25)$ ，並以平方偏差 $f = (x - 2)^2 + (y - 0.25)^2$ 評分。例一的 KKT 證書表明：在這個明確寫出的凸模型及盒內，最佳解為 $(1, 0.25)$ 。從幾何看，無約束最低點落在盒外；朝它前進的方向在 $x = 1$ 被上界阻擋。乘數 2 是按目前無因次目標與約束尺度計算的量，重縮放目標或約束會改變其數值，不宜直接稱為設備的物理壓力。

若原始參數是有單位的感測量，應先指定各自的 SI 單位、基準值及尺度，再用如 $x = (p - p_0)/s_p$ 、 $y = (q - q_0)/s_q$ 轉為無因次參數；返回物理值時使用 $p = p_0 + s_p x$ 、 $q = q_0 + s_q y$ 。例如可明定 p 以攝氏溫差對應的開爾文差值計、 q 以公尺計，並分別選用帶相同單位的正尺度 s_p, s_q ；實際尺度必須由案例規格提供，不能由本章的抽象盒推測。沒有這些尺度，混合不同單位的平方偏差缺乏可解釋的物理權重。盒內最優僅針對合成評分函數和指定有效範圍，既非現場驗證，也非操作安全證明。AI agent 在此只能唯讀整理模型、界限、乘數與失效條件，不據此控制設備、投餌或加藥。

習題

1. **手算**。在 $0 \leq x, y \leq 1$ 最小化 $f = (x + \frac{1}{2})^2 + (y - \frac{3}{4})^2$ 。求最小點、值及依下界 $-x, -y$ 、上界 $x - 1, y - 1$ 排列的乘數，說明全域性的依據。
2. **程式**。不修改核心函式，給習題一設定 `center` 與 `weight`，寫出呼叫式及未執行時預期的 `best_kkt` 結果。若把第一個權重改為零，預期會怎樣？
3. **反例**。在盒 $[-1, 1]$ 上，給出一個滿足 KKT 卻不是最小值的光滑函數；再給出局部最小卻無 KKT 乘數的單一不等式問題，指出失效條件。
4. **整合**。對可微凸 f 與可微凸 $g_i \leq 0$ ，已知某可行點及非負乘數滿足站立與互補。某人說：「還須先數值找到 Slater 點，才能斷言此 KKT 點全域最優。」判斷此話；並說明若要從最優性反推乘數，Slater 扮演何種角色。

習題解答

1. 無約束最低點為 $(-\frac{1}{2}, \frac{3}{4})$ ，投向盒內得 $(0, \frac{3}{4})$ ，函數值 $\frac{1}{4}$ 。該點梯度為 $(1, 0)^T$ ； x 下界乘數為 1，其餘三個為零。原始與對偶可行、站立、互補均成立。函數與盒的仿射約束凸，依已證小命題，此點為全域最小值。
2. 呼叫式為 `best_kkt(enumerate_box((-0.5, 0.75), (1.0, 1.0)))`。未執行的預期為點 $(0.0, 0.75)$ 、值 `0.25`、`lower` 為 $(1.0, 0.0)$ 、`upper` 為 $(0.0, 0.0)$ ，且 `kkt` 為 `True`。把第一個權重改成 `0.0` 會觸發 `ValueError`；這是函式的前置條件，不是該新問題不可解。

3. 可取 $f(x) = -x^2$ ，兩個盒約束寫成 $-1 - x \leq 0$ 與 $x - 1 \leq 0$ 。 $x = 0$ 可行、梯度零、乘數皆零，所以符合 KKT，但 $f(0) = 0 > -1 = f(1)$ 。另一例為最小化 x 且 $x^2 \leq 0$ ：唯一可行點零為最小值，站立方程卻是 $1 = 0$ ；主動約束梯度為零，LICQ 失效。
4. 該說法錯誤。已取得滿足條件的 KKT 點時，凸性加一階不等式便足以證全域最優，不需要先找 Slater 點，更不需要以數值搜尋代替證明。反方向若已知最優、想保證乘數存在，Slater 是凸問題常用的充分約束資格；宣稱它成立時仍須有符合嚴格不等式及定義域條件的數學依據。

本章小結

KKT 同時檢查原始可行、非負乘數、互補與站立。LICQ 等資格支撐非凸局部最小值的**必要性**；凸性使一個已成立的 KKT 證書具有**全域充分性**；凸問題中的 Slater 則常用於保障從最優解取得乘數。三種用途不能混寫。主動集枚舉能稽核指定二次盒問題，但浮點核對和有限候選輸出不是一般最佳化定理。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*, 作者教材入口：<https://www.jirka.org/ra/>
- [A2] MIT OCW, *18.100A Real Analysis*：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- [A3] MIT OCW, *18.02SC Multivariable Calculus*：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
- [A6] SciPy, `minimize` 方法與參數文件，供延伸比較最佳化器介面；本章程式未使用 SciPy：<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>

以上來源作為延伸入口，並不表示已逐條核對其完整教材或已執行任何外部程式。

第19章 多重積分、Riemann和與Fubini

學習目標與先備知識

本章將單變量的 Riemann 積分推廣到二維：從矩形分割與任意標記的 Riemann 和出發，利用 Darboux 上下和判定可積性，證明連續函數在緊矩形上可積，並說明何時能把二重積分寫成兩種迭代積分。讀完後，應能分辨「積分值存在」、「某一種格網求積有近似值」與「交換積分順序合法」是三件不同的事。

先備知識包括單變量 Riemann 積分及其上下和、連續函數在緊區間上的一致連續性，以及一元積分的基本計算。本章使用通常的歐氏距離衡量平面點的接近程度；不預設 Lebesgue 積分或測度論。核心定理以**緊矩形上的連續函數**為假設。對不連續函數或含奇異點的瑕積分，須另外檢查條件，不能把連續函數定理直接套用。

本章也會比較元胞中心取樣與網格節點加權。程式給出的有限精度數值只能核對手算並揭示可能的實作錯誤；即使多組網格的結果相近，也不能據此證明任意分割、任意取樣點的無限命題。

問題與直覺

單變量 Riemann 和把區間切成小段，以取樣值乘區間長度。二維情形則把矩形切成小格，以函數取樣值乘格子面積，再將各項相加。若網格愈來愈細時，**不論如何選擇分割與格內取樣點**，和都逼近同一數值，才得到矩形上的 Riemann 積分。當 $f \geq 0$ 時，可以把積分想成曲面下的體積；當 f 有正有負時，所得是正負相抵的代數體積。圖像有助於理解，卻不能取代極限條件。

對 $R = [a, b] \times [c, d]$ 上的連續函數，一種計算方式是先固定 x ，沿 y 方向積分，再對 x 積分；另一種方式交換兩個方向。Fubini 定理在這些條件下保證兩種計算等於同一個二重積分，但不表示任何帶有奇異點的式子都能換序。

非矩形區域又多了一項邊界問題。若把區域放進外接矩形並在區域外補零，標記 Riemann 和仍是「每格完整面積乘該格的補零函數取樣值」。另一種數值策略是求出小格與區域的交集面積，再按交集面積加權；它並非補零定義的必要步驟。有限格網如何處理邊界，會影響近似誤差，但不能只憑一張格網判定函數是否可積。

定義、定理與推導

19.1 矩形分割與 Riemann 和

先令 $R = [a, b] \times [c, d]$ 為非退化閉矩形，即 $a < b$ 且 $c < d$ 。選取分割

$$a = x_0 < x_1 < \cdots < x_m = b, \quad c = y_0 < y_1 < \cdots < y_n = d.$$

子矩形 $R_{ij} = [x_{i-1}, x_i] \times [y_{j-1}, y_j]$ 的面積為 $\Delta A_{ij} = \Delta x_i \Delta y_j$ ，其中 $\Delta x_i = x_i - x_{i-1}$ 、 $\Delta y_j = y_j - y_{j-1}$ 。
 網格細度定為 $\|P\| = \max\{\Delta x_i, \Delta y_j : 1 \leq i \leq m, 1 \leq j \leq n\}$ 。每格任取標記點 $(x_{ij}^*, y_{ij}^*) \in R_{ij}$ ，得到

$$S(P, f) = \sum_{i=1}^m \sum_{j=1}^n f(x_{ij}^*, y_{ij}^*) \Delta A_{ij}.$$

若存在 $I \in \mathbb{R}$ ，使對每個 $\epsilon > 0$ 都有 $\delta > 0$ ，而每個滿足 $\|P\| < \delta$ 的分割及其**所有**標記點選法均使 $|S(P, f) - I| < \epsilon$ ，便稱 f 在 R 上 Riemann 可積，記 $I = \iint_R f dA$ 。

若 $D \subset R$ ，可定義補零函數 $F = f1_D$ ；**僅當** F 在 R 上可積時，才以 $\iint_D f dA := \iint_R F dA$ 定義區域上的積分。一個常用充分條件是 D 有界、其邊界可由總面積任意小的有限個矩形覆蓋，且 f 是包含 D 的閉矩形上的連續函數；此時邊界附近格子的影響可受控。這類區域通常稱為 Jordan 可測區域。任意有界區域並不自動符合條件。

19.2 可積條件

定理 19.1 (Darboux 判準)。設 $f : R \rightarrow \mathbb{R}$ 有界。令 M_{ij} 、 m_{ij} 分別為 f 在 R_{ij} 上的上、下確界，並令

$$U(P, f) = \sum_{i,j} M_{ij} \Delta A_{ij}, \quad L(P, f) = \sum_{i,j} m_{ij} \Delta A_{ij}.$$

則 f Riemann 可積，當且僅當對每個 $\epsilon > 0$ ，存在分割 P 使 $U(P, f) - L(P, f) < \epsilon$ 。

證明。任意兩個分割都有共同細分；細分不增加上和，也不減少下和。因此下積分 $\underline{I} = \sup_P L(P, f)$ 不大於上積分 $\bar{I} = \inf_P U(P, f)$ 。若能使 $U(P, f) - L(P, f) < \epsilon$ ，則

$$0 \leq \bar{I} - \underline{I} \leq U(P, f) - L(P, f) < \epsilon.$$

由 ϵ 任意可知兩者相等。固定一個上下和差很小的分割後，對充分細的其他分割取共同細分；除靠近固定分割線的小格外，標記和可由固定分割的上下和夾住。因 f 有界，靠近那些分割線的小格之總面積隨細度趨零，故其貢獻亦趨零。於是所有充分細的標記和都趨於共同值。反之，若所有充分細的標記和都趨於 I ，選一個細分割，使任意兩個標記和的差小於 $\epsilon/2$ ；再逐格選點，使兩組標記和分別任意接近上和與下和，即得 $U(P, f) - L(P, f) < \epsilon$ 。□

定理 19.2 (連續函數可積性)。若 f 在非退化緊矩形 R 上連續，則 f 在 R 上 Riemann 可積。

證明。有限維空間中的閉有界矩形緊緻，故 f 一致連續。令 $A(R) = (b-a)(d-c) > 0$ 。給定 $\epsilon > 0$ ，可選 $\delta > 0$ ，使距離小於 δ 的兩點函數值相差小於 $\epsilon/A(R)$ 。取 $\|P\| < \delta/\sqrt{2}$ ，則每格直徑小於 δ ，格內振盪 $\omega_{ij} = M_{ij} - m_{ij} < \epsilon/A(R)$ 。因此

$$U(P, f) - L(P, f) = \sum_{i,j} \omega_{ij} \Delta A_{ij} < \frac{\epsilon}{A(R)} \sum_{i,j} \Delta A_{ij} = \epsilon.$$

由定理 19.1， f 可積。□

一致連續性在此使所有小格的振盪同時受控。不能把定理直接套到任意區域的補零函數：即使原函數連續，補零後也可能在邊界不連續。例如 $1_{\mathbb{Q}^2}$ 在矩形中每個非退化小格的上確界為 1、下確界為 0，故不可積；反過來說，存在不連續點也不必然使函數不可積。

19.3 連續函數的迭代積分

定理 19.3 (本章使用的 Fubini 定理)。若 f 在 $R = [a, b] \times [c, d]$ 上連續，則每條水平及垂直截面均可作一元 Riemann 積分，兩個迭代積分存在，且

$$\iint_R f(x, y) dA = \int_a^b \left(\int_c^d f(x, y) dy \right) dx = \int_c^d \left(\int_a^b f(x, y) dx \right) dy.$$

證明。 令 $g(x) = \int_c^d f(x, y) dy$ 。對任意 x, x' ，

$$|g(x) - g(x')| \leq (d - c) \sup_{y \in [c, d]} |f(x, y) - f(x', y)|.$$

由 f 在 R 上一致連續， g 連續，故外層積分存在。對矩形分割，在每個固定的 x 標記值處，以 y 方向的標記和近似內層積分；一致連續性使這項近似誤差對所有所選 x 同時趨零。乘上各 x 小段長度並相加，便與矩形標記和相差趨零；前者趨於 $\int_a^b g(x) dx$ ，後者由定理 19.2 趨於 $\iint_R f dA$ 。交換 x, y 同理。□

這個定理的連續性假設已同時保證矩形可積及各截面可積，不必再把它們當成未檢查的附加假設。對符合前述邊界條件的非矩形區域，可以研究補零函數，或依區域上下界折成迭代積分；但其截面與邊界仍須逐項核對。若 α, β 在 $[a, b]$ 上連續、 $\alpha(x) \leq \beta(x)$ ，且 f 在包含

$$D = \{(x, y) : a \leq x \leq b, \alpha(x) \leq y \leq \beta(x)\}$$

的矩形 $R = [a, b] \times [c, d]$ 上連續，則補零函數 $F = f1_D$ 在 R 上 Riemann 可積，且

$$\iint_D f dA = \int_a^b \left(\int_{\alpha(x)}^{\beta(x)} f(x, y) dy \right) dx.$$

證明如下。由連續性， α, β 在緊區間上一致連續且有界。其圖形可用總面積任意小的有限個矩形覆蓋，故分割足夠細時，與 D 邊界相交的小格總面積可任意小。令 $M = \sup_R |f|$ ；邊界格對上下和差的貢獻至多為 $2M$ 乘這些格子的總面積。完全位於 D 內的格子上， f 一致連續，故細化時振盪和趨零；完全在 D 外的格子上， $F = 0$ 。由 Darboux 判準， F Riemann 可積。對每個固定 x ， $\int_c^d F(x, y) dy = \int_{\alpha(x)}^{\beta(x)} f(x, y) dy$ ；右側隨 x 連續。對矩形分割求和時，內部格的和由一致連續性收斂，邊界格的貢獻則由上述面積估計趨零，因此補零函數的矩形積分等於這些截面積分的外層積分。這證明了簡單區域公式，並非直接把矩形版定理 19.3 套用於非矩形區域。若函數有奇異點，本定理及此推論均不適用，不能只憑形式上能寫出兩個積分符號便換序。

19.4 瑕積分與交換順序

瑕積分涉及額外的極限，與緊矩形上的普通 Riemann 積分不同。絕對收斂是常用的**充分**換序條件，不是必要條件；若未建立適用的換序定理，也未控制截斷後的尾項，不能只交換積分符號。本章不以未證明的測度論定理代替這些檢查。

具體反例限於 $[0, 1]^2$ ：在原點以外令

$$f(x, y) = \frac{x^2 - y^2}{(x^2 + y^2)^2}.$$

固定 $y > 0$ ，對 x 的原函數是 $-x/(x^2 + y^2)$ ，所以先對 x 、再對 y 作瑕迭代積分，得到

$$\int_0^1 \left(\int_0^1 f(x, y) dx \right) dy = \int_0^1 \frac{-1}{1 + y^2} dy = -\frac{\pi}{4}.$$

固定 $x > 0$ ，對 y 的原函數是 $y/(x^2 + y^2)$ ；反向迭代則得到 $\pi/4$ 。原點附近， $|f|$ 沿避開零值方向的角度區間與 $1/r^2$ 同階，而面積元含因子 r ，其絕對積分含發散的 $\int_0^\varepsilon dr/r$ 。兩種瑕迭代積分各有定義卻不相等，正說明連續緊矩形定理不能跨過原點奇異性使用。

逐步手算例題

例 19.1：解析多項式二重積分

計算 $I = \iint_D (3x^2 + 2y) dA$ ，其中 D 為矩形 $[0, 1] \times [0, 2]$ 。

解：由於被積函數 $f(x, y) = 3x^2 + 2y$ 在緊矩形上連續，故可積且可應用 Fubini。選擇先對 x 積分：

$$I = \int_0^2 \left(\int_0^1 (3x^2 + 2y) dx \right) dy$$

內層積分（視 y 為常數）：

$$\int_0^1 (3x^2 + 2y) dx = [x^3 + 2yx]_0^1 = 1 + 2y$$

代入外層積分：

$$I = \int_0^2 (1 + 2y) dy = [y + y^2]_0^2 = (2 + 4) - 0 = 6$$

驗證反向順序：

$$I = \int_0^1 \left(\int_0^2 (3x^2 + 2y) dy \right) dx$$

內層：

$$\int_0^2 (3x^2 + 2y) dy = [3x^2 y + y^2]_0^2 = 6x^2 + 4$$

外層：

$$\int_0^1 (6x^2 + 4) dx = [2x^3 + 4x]_0^1 = 2 + 4 = 6$$

結果一致， $I = 6$ 。

直覺檢查： $3x^2$ 在 $[0, 1]$ 上的平均值為 1，面積 $1 \times 2 = 2$ ，貢獻 2。 $2y$ 在 $[0, 2]$ 上的平均值為 2，面積 $1 \times 2 = 2$ ，貢獻 4。總和 $2 + 4 = 6$ 。符合。

例 19.2：非矩形區域的積分

計算 $I = \iint_D (x + y) dA$ ，其中 D 為三角形區域： $0 \leq x \leq 1, 0 \leq y \leq x$ 。

解：區域描述為 $0 \leq x \leq 1$ 且 $0 \leq y \leq x$ 。應用Fubini：

$$I = \int_0^1 \left(\int_0^x (x + y) dy \right) dx$$

內層積分：

$$\int_0^x (x + y) dy = \left[xy + \frac{1}{2}y^2 \right]_{y=0}^{y=x} = x^2 + \frac{1}{2}x^2 = \frac{3}{2}x^2$$

外層積分：

$$I = \int_0^1 \frac{3}{2}x^2 dx = \frac{3}{2} \left[\frac{x^3}{3} \right]_0^1 = \frac{1}{2}$$

結果 $I = 0.5$ 。

圖形直覺：在點 $(0, 0)$ ， $f = 0$ ；在 $(1, 1)$ ， $f = 2$ 。三角形面積為 0.5。平均高度約為 1（線性增長）。體積約 $0.5 \times 1 = 0.5$ 。符合。

實作與程式

以下程式只處理非退化矩形上的有限格網求積，不宣稱判定任意函數是否 Riemann 可積。`midpoint` 在每個元胞中心取樣，每格權重為 $\Delta x \Delta y$ ；`trapezoidal` 在包含邊界的節點取樣，沿每個座標方向的兩端各用半權重，因此角點權重為四分之一。兩者的取樣位置與資料筆數不同，不能只更換方法名稱而沿用同一組資料。

陣列遵循物理網格約定：`q[j, i]` 的 j 沿 $+Y$ 、 i 沿 $+X$ ；`X`、`Y` 及函數輸出均須具有形狀 `(ny, nx)` 或節點法的 `(ny+1, nx+1)`。本程式要求函數回傳同形狀、有限的實數陣列；常數函數也須明確產生同形狀陣列，而不依賴隱含廣播。座標端點須為有限實數且依遞增順序排列，分割數須為正整數並拒絕布林值。

```
import numpy as np

def numeric_riemann_2d(f, x_range, y_range, nx, ny,
                      method="midpoint"):
    """以元胞中點或張量積梯形規則近似矩形上的二重積分。"""
    for name, count in (("nx", nx), ("ny", ny)):
        if isinstance(count, (bool, np.bool_)) or not isinstance(
            count, (int, np.integer)
        ) or count <= 0:
            raise ValueError(f"{name} must be a positive integer")

    def checked_range(bounds, name):
        try:
            if len(bounds) != 2:
                raise ValueError
            lo, hi = (float(value) for value in bounds)
        except (TypeError, ValueError, OverflowError) as exc:
            raise ValueError(f"{name} must have two real endpoints") from exc
        if not np.isfinite(lo) or not np.isfinite(hi) or not lo < hi:
            raise ValueError(f"{name} must have finite increasing endpoints")
        return lo, hi

    a, b = checked_range(x_range, "x_range")
    c, d = checked_range(y_range, "y_range")
    if method not in ("midpoint", "trapezoidal"):
        raise ValueError("method must be 'midpoint' or 'trapezoidal'")

    dx, dy = (b - a) / nx, (d - c) / ny
    if not np.isfinite(dx * dy) or dx <= 0 or dy <= 0:
        raise ValueError("cell area is not finite and positive")

    if method == "midpoint":
        xs = a + (np.arange(nx) + 0.5) * dx
        ys = c + (np.arange(ny) + 0.5) * dy
        wx, wy = np.ones(nx), np.ones(ny)
    else:
        xs = np.linspace(a, b, nx + 1)
        ys = np.linspace(c, d, ny + 1)
        wx, wy = np.ones(nx + 1), np.ones(ny + 1)
        wx[0] = wx[-1] = 0.5
        wy[0] = wy[-1] = 0.5
```

```

X, Y = np.meshgrid(xs, ys, indexing="xy")
values = np.asarray(f(X, Y))
if values.shape != X.shape:
    raise ValueError("f must return an array matching the grid shape")
if not np.issubdtype(values.dtype, np.number) or np.iscomplexobj(values):
    raise ValueError("f must return real numeric values")
if not np.all(np.isfinite(values)):
    raise ValueError("f returned non-finite values")

result = np.sum(values * wy[:, None] * wx[None, :]) * dx * dy
if not np.isfinite(result):
    raise ValueError("quadrature result is not finite")
return float(result)

def polynomial(x, y):
    return 3.0 * x**2 + 2.0 * y

if __name__ == "__main__":
    for n in (10, 50, 100, 200):
        mid = numeric_riemann_2d(
            polynomial, (0, 1), (0, 2), n, n, "midpoint"
        )
        trap = numeric_riemann_2d(
            polynomial, (0, 1), (0, 2), n, n, "trapezoidal"
        )
        print(n, mid, trap, abs(mid - 6.0), abs(trap - 6.0))

```

此處的解析基準 6 來自前節手算，並非程式內一個未定義的「解析積分器」。對 n 等分的 x 方向，中點規則對 x^2 的一維求和比其積分少 $1/(12n^2)$ ，梯形規則則多 $1/(6n^2)$ 。函數的 y 項為一次式，兩種規則沿 y 方向均精確；把 $3x^2$ 項乘上寬度 2，便得到本例的**精確格網誤差式**

$$I_{\text{mid}} = 6 - \frac{1}{2n^2}, \quad I_{\text{trap}} = 6 + \frac{1}{n^2}.$$

因此本例的誤差為二階，而不是四階或指數下降。對其他函數，不能僅憑這個多項式的公式宣稱相同誤差階；須另列光滑性假設與求積誤差界。

測試與預期結果

下列斷言是**供讀者執行的預期測試**，不是已執行紀錄。正常測試用兩個方向均為一次式的 $x + y$ ；兩種規則理應給出 1。邊界測試用極小但非退化的正方形及常數函數，檢查面積權重； 10^{-12} 在一般雙精度表示範圍內，不應把它描述為必然下溢。故障測試則確認錯誤輸入明確失敗，而非悄悄給出一個貌似合理的數值。

```

def expect_value_error(action):
    try:
        action()
    except ValueError:
        return
    raise AssertionError("expected ValueError")

```

```

def run_expected_tests():
    linear = lambda x, y: x + y
    constant = lambda x, y: np.ones_like(x, dtype=float)

    for method in ("midpoint", "trapezoidal"):
        actual = numeric_riemann_2d(
            linear, (0, 1), (0, 1), 4, 7, method
        )
        assert np.isclose(actual, 1.0, rtol=0, atol=1e-14)

        tiny = numeric_riemann_2d(
            constant, (0, 1e-6), (0, 1e-6), 3, 5, method
        )
        assert np.isclose(tiny, 1e-12, rtol=1e-14, atol=0)

    for n in (10, 200):
        mid = numeric_riemann_2d(
            polynomial, (0, 1), (0, 2), n, n, "midpoint"
        )
        trap = numeric_riemann_2d(
            polynomial, (0, 1), (0, 2), n, n, "trapezoidal"
        )
        assert np.isclose(mid, 6 - 1 / (2 * n**2), atol=1e-12)
        assert np.isclose(trap, 6 + 1 / n**2, atol=1e-12)

    base = lambda **kwargs: numeric_riemann_2d(
        constant, (0, 1), (0, 1), 2, 2, **kwargs
    )
    expect_value_error(lambda: base(method="node"))
    expect_value_error(lambda: numeric_riemann_2d(
        constant, (0, 1), (0, 1), 0, 2
    ))
    expect_value_error(lambda: numeric_riemann_2d(
        constant, (0, 1), (0, 1), True, 2
    ))
    expect_value_error(lambda: numeric_riemann_2d(
        constant, (1, 0), (0, 1), 2, 2
    ))
    expect_value_error(lambda: numeric_riemann_2d(
        constant, (0, np.inf), (0, 1), 2, 2
    ))
    expect_value_error(lambda: numeric_riemann_2d(
        lambda x, y: 1.0, (0, 1), (0, 1), 2, 2
    ))
    expect_value_error(lambda: numeric_riemann_2d(
        lambda x, y: np.full_like(x, np.nan),
        (0, 1), (0, 1), 2, 2
    ))

```

預期 $n = 10$ 時中點值為 5.995、梯形值為 6.01； $n = 200$ 時中點誤差為 1.25×10^{-5} 、梯形誤差為 2.5×10^{-5} 。斷言的浮點容差只用於核對有限精度運算，不是積分定義中的 ϵ 。

另可用 $1_{\{x < 1/2, y < 1/2\}}$ 作數值觀察：其積分為 $1/4$ ，但網格線、節點與嚴格不等號的相對位置會改變有限網格輸出。這是**可積而有限取樣仍有誤差**的例子，不是函數不可積或演算法必然故障的證據。程式拒絕非法輸入的測試，則與這種合法函數的取樣誤差屬於不同類型。

反例與常見陷阱

瑕積分不可只交換符號。 第 19.4 節在單位正方形上給出的函數，先對 x 再對 y 為 $-\pi/4$ ，反序為 $\pi/4$ 。兩個結果來自不同的迭代極限；不能將它們當成同一個普通二重 Riemann 積分的兩種算法。絕對收斂可提供常用的換序充分條件，但「沒有證明絕對收斂」本身也不等於「必定不能換序」；須檢查所用定理及截斷極限。

可積性與截面性質不能混為一談。 緊矩形上的連續性足以保證本章 Fubini 定理的全部積分存在。若函數在一點奇異，即使某些固定座標的內層積分可以算出，也不能援引該連續函數定理。反過來，少數點或邊界上的不連續不必然破壞 Riemann 可積性；應檢查上下和的差能否任意縮小，而非只看「是否處處連續」。

元胞與節點不能共用權重。 中點資料每個值代表一個完整小格；節點梯形法則沿邊界使用半權重，角點因兩方向相乘而使用四分之一權重。若將含兩側邊界的 $(n+1) \times (n+1)$ 個節點全乘相同完整格子面積，就連常數函數的總面積都會算錯。節點亦不「天生必須」採梯形法：權重取決於所選求積規則，本章只是明確採用其中一種。

曲邊格子須交代策略。 補零取樣法以完整格面積乘 $f|_D$ 在格內的取樣值；交集面積法以格子和 D 的交集面積加權。二者不能混寫成同一個定義，也不宜對任意複雜邊界宣稱固定誤差階。若只保留完全落在區域內的小格，會遺漏邊界帶；若把所有碰到邊界的小格都當成完整內部格，則會多算邊界帶。邊界幾何及函數界限決定如何估計這些誤差。

AI、幾何與養殖案例

面積平均與單位

對有界區域 D 上的濃度場 $C(x, y)$ ，面積平均濃度定義為

$$\overline{C}_A = \frac{1}{A(D)} \iint_D C(x, y) dA, \quad A(D) > 0.$$

若 x, y 的單位為公尺、 C 的單位為 mg/L ，則積分的單位是 $\text{mg m}^2/\text{L}$ ，除以面積後才回到 mg/L 。這是**面積平均濃度**，不是水體總氧量；要推算總量還需要深度、體積分布及相應的單位換算資料。

考慮純合成模型，令 $D = [0, 10] \times [0, 5]$ ，座標以公尺計，

$$C(x, y) = 5 - 0.1x^2 - 0.05y^2 \quad \text{mg/L}.$$

常數項的單位為 mg/L ，兩個二次項係數的單位均為 $\text{mg L}^{-1}\text{m}^{-2}$ 。由矩形上的連續性及 Fubini 定理，解析面積平均為

$$\overline{C}_A = 5 - 0.1 \frac{10^2}{3} - 0.05 \frac{5^2}{3} = 1.25 \quad \text{mg/L}.$$

用 10×10 個元胞作中點求積時，對 x^2 的格點平均為 33.25 m^2 ，對 y^2 為 8.3125 m^2 ，故**預期**數值平均為

$$5 - 0.1(33.25) - 0.05(8.3125) = 1.259375 \text{ mg/L.}$$

差異是此格網的取樣誤差，而非現場測量誤差。

更重要的是模型有效性：角點給出 $C(10, 5) = -6.25 \text{ mg/L}$ ，不可能解釋為物理濃度。解析積分 1.25 雖然計算正確，卻不能使整個矩形上的合成公式成為可信的現場模型。也不能擅自將負值裁成零，再稱它仍是原模型的積分。可行的稽核紀錄應分列「依公式得到的數學結果」及「模型在部分區域失效」；沒有獨立量測與校準，就不給出曝氣或其他設備操作建議。

幾何網格與 AI 的界線

在幾何計算中，若非負高度函數定義於合適的平面底域，二重積分可表示其下方體積。對曲邊底域，首先要說明是採補零取樣，還是估計元胞與底域的交集面積。更密的格網可能有助於觀察數值差異，卻不會自動修正錯誤的區域、單位或函數模型。

唯讀的 AI 助理可以整理解析基準、格網規格、各次近似值與失效位置，並建議哪些區域值得進一步量測；它不能把合成濃度場當成已驗證感測資料，更不能根據本章的面積平均值直接控制設備。此處「數學求積正確」與「物理模型有效」是兩項必須分開呈報的證據。

習題

- 手算。** 計算 $\iint_D (2x + 3y) dA$ ，其中 $D = \{(x, y) : x \geq 0, y \geq 0, x + y \leq 1\}$ 。列出迭代積分的上下限與計算過程。
- 程式。** 使用本章兩種求積方法近似 $f(x, y) = \sin x \cos y$ 在 $[0, \pi] \times [0, \pi/2]$ 上的積分。先求解析值，再寫出呼叫程式的方式；說明有限網格值與解析值的關係，不捏造已執行輸出。
- 條件辨析。** 在 $[0, 1]^2 \setminus \{(0, 0)\}$ 令 $h(x, y) = (x - y)/(x + y)^2$ 。證明它在原點附近絕對可積，並求兩個瑕迭代積分。再與第 19.4 節的反例比較，指出「原點有奇異性」何以不足以判定換序結果。
- 整合。** 半徑 $R = 10 \text{ m}$ 的圓形區域上有合成模型 $C(x, y) = C_0 - kr^2$ ，其中 $r = \sqrt{x^2 + y^2}$ ， C_0 以 mg/L 、 k 以 $\text{mg L}^{-1}\text{m}^{-2}$ 計。利用極座標求**面積平均濃度**，並分別說明矩形格網的補零取樣法與邊界格交集面積法。極座標的面積因子可先使用，正式換變數條件留待下一章。

習題解答

- 區域可寫成 $0 \leq x \leq 1, 0 \leq y \leq 1 - x$ 。三角形有界且邊界可受控，連續函數在其上的補零積分可用此上下限計算：

$$\begin{aligned}
I &= \int_0^1 \int_0^{1-x} (2x + 3y) dy dx \\
&= \int_0^1 \left(2x(1-x) + \frac{3}{2}(1-x)^2 \right) dx \\
&= \int_0^1 \left(\frac{3}{2} - x - \frac{1}{2}x^2 \right) dx = \frac{5}{6}.
\end{aligned}$$

檢查量級時，三角形面積為 $1/2$ ，被積函數非負，結果也應非負；這項檢查不能代替上下限計算。

2. 函數在緊矩形上連續，解析值可拆為兩個一元積分：

$$\int_0^\pi \sin x dx \int_0^{\pi/2} \cos y dy = 2 \cdot 1 = 2.$$

沿用已定義函數的呼叫方式，例如：

```

wave = lambda x, y: np.sin(x) * np.cos(y)
mid = numeric_riemann_2d(
    wave, (0, np.pi), (0, np.pi / 2), 40, 40, "midpoint"
)
trap = numeric_riemann_2d(
    wave, (0, np.pi), (0, np.pi / 2), 40, 40, "trapezoidal"
)
print(mid, trap, abs(mid - 2.0), abs(trap - 2.0))

```

預期兩個有限網格值接近 2，但一般不恰好等於 2；若要主張某個誤差階，還須另行引用或推導適用於此函數的求積誤差界。此段是可執行範例，並非執行紀錄。

3. 因 $|x - y| \leq x + y$ ，在原點以外有

$$|h(x, y)| \leq \frac{1}{x + y}.$$

後者在單位正方形上的瑕積分可直接計算為

$$\int_0^1 \int_0^1 \frac{1}{x + y} dy dx = \int_0^1 (\log(x + 1) - \log x) dx = 2 \log 2 < \infty.$$

因此 h 絕對可積。為核對迭代值，固定 $x > 0$ 時先對 y 積分得到

$$\int_0^1 h(x, y) dy = 2 - \frac{2x}{x + 1} - \log \frac{x + 1}{x}.$$

其外層瑕積分為 0：前兩項的積分為 $2 - 2(1 - \log 2) = 2 \log 2$ ，最後一項的積分也為 $2 \log 2$ 。函數滿足 $h(y, x) = -h(x, y)$ ，故反向迭代積分同樣存在且為 0。在 $x = 0$ 的單獨截面，內層積分發散；這不改變上述以 $x > 0$ 的內層結果形成的外層瑕積分。這個例子與第 19.4 節的非絕對可積反例不同：有奇異點並不足以推出換序不合法，更不足以推出兩個答案不相等。

4. 使用極座標面積元 $dA = r dr d\theta$ ，圓域面積為 πR^2 ，所以

$$\begin{aligned}\overline{C}_A &= \frac{1}{\pi R^2} \int_0^{2\pi} \int_0^R (C_0 - kr^2) r dr d\theta \\ &= C_0 - \frac{kR^2}{2} = C_0 - 50k.\end{aligned}$$

最後一式須連同題設單位理解：50 來自 $R^2/2 = 50 \text{ m}^2$ ，故結果仍以 mg/L 計。這是面積平均濃度，不是圓池的總氧量；若模型在圓域某處給出負濃度，仍須另行檢查其物理有效範圍。

使用外接矩形網格時，補零取樣法在每格取一點，以完整格面積乘 C_{1D} 的取樣值；交集面積法則對邊界格使用該格與圓盤交集的面積作權重。兩者均須處理邊界，卻不是同一個權重規則，也不能說補零定義「必須」先算交集面積。

本章小結

二重 Riemann 積分要求所有充分細的矩形分割及標記選法趨於同一值；Darboux 上下和提供可積性判準。有限維緊矩形上的連續函數一致連續，因而可積，且其兩種迭代積分都存在並等於二重積分。對非矩形區域，應檢查邊界並區分補零定義與交集面積求積策略；對含奇異點的瑕積分，則須另行證明換序條件。絕對收斂是常用充分條件，並非必要條件。

格網實作還須分清元胞中心及節點權重，核對陣列方向、單位、解析值與輸入失敗行為。本章多項式的二階誤差有精確公式，但有限次數值核對不能證明一般函數的可積性或收斂階。下一章將進一步說明積分換變數及其 Jacobian 面積因子所需的條件。

參考來源

- [A1] Jiří Lebl, *Basic Analysis* 作者目錄與教材入口：<https://www.jirka.org/ra/>。作為實分析背景入口；此處不宣稱已逐條核對教材內的定理。
- [A3] MIT OpenCourseWare, *18.02SC Multivariable Calculus* 課程概要：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>。作為多變量積分主題的延伸學習入口。

本章數值程式僅用 NumPy；上述來源不構成程式已執行或章內每項推導已由外部逐條驗證的紀錄。

第20章 Jacobian行列式與積分換變數

學習目標與先備知識

在平面或空間中改用另一組座標描述同一區域時，積分中的面積或體積元素如何改變？答案由座標映射的 Jacobian 行列式控制。行列式的絕對值描述局部體積縮放；正負則記錄方向是否反轉。要把這個局部幾何結論用於積分，還須確認映射的定義域、正則性、覆蓋次數，以及邊界或奇異點如何處理。

學完本章後，讀者應能：

1. 由可微映射的線性近似，解釋 Jacobian 行列式為何表示局部面積或體積縮放。
2. 正確使用普通多重積分的換變數公式，並區分面積／體積元素與有向量。
3. 手算仿射變換、方向反轉、極座標與簡單重複覆蓋例子。
4. 判斷換變數定理的假設是否成立，辨認奇異 Jacobian、重複覆蓋與邊界例外。
5. 撰寫有限精度的 CPU 計算檢查，並清楚標示數值檢查不是定理證明。

先備知識包括向量與矩陣乘法、行列式、連續與可微函數，以及 Riemann 多重積分。本文採列向量慣例：若 $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$ ，則 Jacobian 矩陣 $J_T(u)$ 的形狀為 $n \times n$ ，輸入擾動 h 為 $n \times 1$ ，線性化為 $J_T(u)h$ 。

問題與直覺

考慮一個小正方形，經線性映射後成為平行四邊形。平行四邊形的面積由兩個方向共同決定：若映射矩陣為

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix},$$

則單位正方形映成的平行四邊形面積為 $|\det A| = |ad - bc|$ 。若 $\det A < 0$ ，平面方向反轉，但普通面積仍非負，因此普通面積積分使用 $|\det A|$ 。

對非線性映射 T ，在點 u 附近，可微性給出

$$T(u + h) = T(u) + J_T(u)h + r_u(h), \quad \frac{\|r_u(h)\|}{\|h\|} \rightarrow 0 \quad (h \rightarrow 0, h \neq 0).$$

這裡採用歐氏範數。第一項是基點， $J_T(u)h$ 是線性變形，而餘項相對於尺度趨近於零。因而愈小的區塊愈接近由 $J_T(u)$ 描述的平行多面體，其局部體積縮放因子為 $|\det J_T(u)|$ 。

這是局部幾何直覺，不是完整的積分定理證明。要將小區塊體積近似加總，必須控制映射在區域上的行為，並排除或妥善處理重複覆蓋與奇異點。

定義、定理與推導

Jacobian 與局部體積縮放

令 $U \subset \mathbb{R}^n$ 為開集， $T: U \rightarrow \mathbb{R}^n$ 為 C^1 映射。以 $u = (u_1, \dots, u_n)$ 表示參數，以 $x = T(u)$ 表示目標座標，則

$$J_T(u) = \begin{pmatrix} \frac{\partial T_1}{\partial u_1} & \dots & \frac{\partial T_1}{\partial u_n} \\ \vdots & & \vdots \\ \frac{\partial T_n}{\partial u_1} & \dots & \frac{\partial T_n}{\partial u_n} \end{pmatrix}.$$

若 $\det J_T(u) \neq 0$ ，逆函數定理保證 T 在 u 的某個鄰域內局部可逆。這是局部結論，不保證整個 U 上一對一。局部有向體積依 $\det J_T(u)$ 縮放；不帶方向的普通體積依 $|\det J_T(u)|$ 縮放。

在二維，兩個切向量 v_1, v_2 張成的平行四邊形面積為 $|\det[v_1 \ v_2]|$ 。線性映射 A 把單位正方形的兩條邊送到 Ae_1, Ae_2 ，所以面積為

$$|\det[Ae_1 \ Ae_2]| = |\det A|.$$

三維情形中，三個映射後的邊向量張成平行六面體，其體積亦為行列式絕對值。高維情形由相同的行列式體積公式描述。

換變數定理

定理（多重積分換變數，經典形式）。 設 $U, V \subset \mathbb{R}^n$ 為開集， $T: U \rightarrow V$ 是 C^1 微分同胚，也就是 T 為雙射且反函數 $T^{-1}: V \rightarrow U$ 亦為 C^1 。若 $f: V \rightarrow \mathbb{R}$ 連續且在 V 上具緊支集，則

$$\int_V f(x) dx = \int_U f(T(u)) |\det J_T(u)| du.$$

這是本章採用的定理形式。對適當的可測函數，另有更一般的換變數定理，但其可測性與可積性條件須另行說明。

定理要求 T 對整個使用區域一對一。若映射在區域內以固定有限次數 k 覆蓋目標區域，且除去適當的零測集後各分支均正則，則將各分支分開套用公式時會計入覆蓋次數；不能把這種情況直接稱為一對一換變數。邊界在一般面積積分中常可忽略，前提是邊界為零測集；若邊界有正測度或積分具奇異性，便須另行檢查。對有向積分或微分形式則保留 $\det J_T$ 的符號，不能任意以絕對值取代。

小命題與證明：非奇異線性變換的體積縮放

命題。 若 A 是 $n \times n$ 可逆矩陣， E 是有限體積的可測集合，則

$$\text{vol}(AE) = |\det A| \text{vol}(E).$$

證明。 將 A 作奇異值分解 $A = Q_1 \Sigma Q_2^T$ ，其中 Q_1, Q_2 為正交矩陣， $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$ ，且每個 $\sigma_i > 0$ 。正交變換保持歐氏距離與體積，因此 Q_2^T 和 Q_1 都不改變集合體積。對角變換 Σ 將第 i 個座標方向的長度乘以 σ_i ，故將長方體體積乘以 $\prod_i \sigma_i$ ；藉由長方體對可測集合體積的近似，這個縮放關係延伸至 E 。另一方面，

$$|\det A| = |\det Q_1| |\det \Sigma| |\det Q_2^T| = \prod_i \sigma_i,$$

因為正交矩陣行列式的絕對值為 1。合併兩個結果即得命題。證畢。

此命題證明線性變換的體積縮放。非線性換變數定理還要利用局部線性化、區域細分與積分極限，不能只憑單點的 Jacobian 就當作整體公式。

仿射情形

若 $T(u) = Au + b$ ，其中 A 可逆，則 $J_T(u) = A$ ，Jacobian 為常數。因此

$$\int_{T(E)} f(x) dx = \int_E f(Au + b) |\det A| du.$$

平移 b 不改變體積；矩陣 A 可包含旋轉、反射、剪切與伸縮。旋轉的行列式絕對值為 1；純伸縮則以各方向伸縮倍率的乘積改變體積。

極座標

極座標映射為

$$T(r, \theta) = (r \cos \theta, r \sin \theta), \quad J_T(r, \theta) = \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix}.$$

因此

$$\det J_T(r, \theta) = r.$$

在 $r > 0$ 且角度限制在不重複的區間時，映射局部正則，並可在相應區域上一對一。對適當的區域與可積函數，

$$\iint_D f(x, y) dx dy = \iint_{T^{-1}(D)} f(r \cos \theta, r \sin \theta) r dr d\theta.$$

在 $r = 0$ ，Jacobian 為零，而且所有角度都映到原點；角度區間若包含長度 2π 的兩端，兩端表示同一條射線。這些點或邊界在一般面積積分中通常是零面積集合，但在陳述一對一條件時仍須處理。因子 r 的幾何意義是：半徑較大處，每一小段角度所涵蓋的弧長較長，因此局部面積元素也較大。

逐步手算例題

例一：剪切與伸縮的仿射換元

令

$$T(u, v) = (2u + v, v), \quad S = \{(u, v) : 0 \leq u \leq 1, 0 \leq v \leq 1\}.$$

計算 $\iint_{T(S)} 1 \, dx \, dy$ 。

第一步：求 Jacobian。

$$J_T = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}, \quad \det J_T = 2.$$

第二步：使用仿射換變數公式。映射可逆，且將正方形一對一映成平行四邊形，因此

$$\iint_{T(S)} 1 \, dx \, dy = \int_0^1 \int_0^1 2 \, dv \, du = 2.$$

也可直接看兩條邊向量 $(2, 0)$ 與 $(1, 1)$ ；其平行四邊形面積為 $|2 \cdot 1 - 0 \cdot 1| = 2$ 。

例二：圓盤上的二次函數積分

計算半徑 R 的圓盤 $D = \{(x, y) : x^2 + y^2 \leq R^2\}$ 上的積分

$$\iint_D (x^2 + y^2) \, dx \, dy.$$

使用 $x = r \cos \theta$, $y = r \sin \theta$ ，其中 $0 \leq r \leq R$ 、 $0 \leq \theta \leq 2\pi$ 。被積函數變成 r^2 ，面積元素變成 $r \, dr \, d\theta$ ，故

$$\begin{aligned} \iint_D (x^2 + y^2) \, dx \, dy &= \int_0^{2\pi} \int_0^R r^3 \, dr \, d\theta \\ &= 2\pi \left[\frac{r^4}{4} \right]_0^R = \frac{\pi R^4}{2}. \end{aligned}$$

若 x, y, R 的單位是長度，積分單位為長度的四次方，與被積函數乘上面積元素的單位一致。

例三：方向反轉

令 $T(u, v) = (v, u)$ 。則

$$J_T = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \det J_T = -1.$$

此映射交換兩個座標，面積不變；普通面積積分使用 $|\det J_T| = 1$ 。若計算帶方向的積分，負號則反映方向反轉，不能忽略。

實作與程式

以下使用 Python 標準庫，對仿射例子做解析計算與中點格點求積。程式不安裝套件、不使用 GPU；有限格點只能核對特定案例，不能證明一般換變數定理。

```
from math import isfinite

def determinant_2x2(a, b, c, d):
    """回傳 [[a,b],[c,d]] 的行列式。"""
    values = (a, b, c, d)
    if not all(isfinite(x) for x in values):
        raise ValueError("矩陣元素必須是有限實數")
    return a * d - b * c

def affine_rectangle_area(a, b, c, d, width, height):
    """可逆線性映射下，矩形像的普通面積。"""
    if width < 0 or height < 0:
        raise ValueError("邊長不可為負")
    det = determinant_2x2(a, b, c, d)
    if det == 0:
        raise ValueError("奇異映射不能用此一對一面積公式")
    return abs(det) * width * height

def midpoint_integral_affine_square(a, b, c, d, n):
    """在 [0,1]^2 中點格點積分常數 |det A|。"""
    if not isinstance(n, int) or isinstance(n, bool) or n <= 0:
        raise ValueError("n 必須是正整數")
    det = determinant_2x2(a, b, c, d)
    if det == 0:
        raise ValueError("奇異映射不能用此一對一換元")

    total = 0.0
    h = 1.0 / n
    for i in range(n):
        for j in range(n):
            # 中點座標用來確認格點落在單位正方形內。
            u = (i + 0.5) * h
            v = (j + 0.5) * h
            if not (0.0 < u < 1.0 and 0.0 < v < 1.0):
                raise ArithmeticError("中點落在預期區域之外")
            total += abs(det) * h * h
    return total

if __name__ == "__main__":
    a, b, c, d = 2.0, 1.0, 0.0, 1.0
    exact = affine_rectangle_area(a, b, c, d, 1.0, 1.0)
    estimate = midpoint_integral_affine_square(a, b, c, d, 10)
    print("det =", determinant_2x2(a, b, c, d))
```

```

print("解析面積 =", exact)
print("中點格點估計 =", estimate)

reversed_det = determinant_2x2(0.0, 1.0, 1.0, 0.0)
print("交換座標的 det =", reversed_det)
print("交換座標的面積因子 =", abs(reversed_det))

```

預期輸出為行列式 2、解析面積 2、格點估計 2。交換座標的行列式預期為 -1 ，面積因子則為 1。程式未實際執行；上述是依公式與程式邏輯推得的預期結果。

若改成非線性映射或非定值被積函數，必須把 $f(T(u, v)) |\det J_T(u, v)|$ 一起納入格點加權，並另行分析求積誤差。有限格點的穩定結果不能推出積分公式在連續域成立。

測試與預期結果

下列測試未實際執行；預期結果依照程式邏輯判斷。

類別	測試輸入	預期結果	意義
正常	$A = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$ ，單位正方形	面積 2，格點估計 2	與手算一致
邊界	$n = 1$ ，邊長為零	格點合法；面積為 0	零面積區域不應產生負面積
方向反轉	$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$	行列式 -1 ，面積因子 1	檢查絕對值的使用
故障	$A = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$	拋出奇異映射錯誤	不可套用可逆換元公式
故障	$n = 0$ 或負數	拋出 <code>ValueError</code>	格點數必須為正整數
故障	$n = 1.5$	拋出 <code>ValueError</code>	非整數格點數須在進入迴圈前拒絕
故障	邊長為負	拋出 <code>ValueError</code>	拒絕不合法的幾何輸入

奇異矩陣把二維區域壓到直線或點，其像的二維面積為零；但這不表示一般的可逆換變數定理可以套用到它上面。若被積函數、積分維度或像空間改變，必須重新定義所求的量。

反例與常見陷阱

1. 把 $\det J_T$ 當成普通面積因子。映射方向反轉時，行列式可為負；普通面積元素非負，應使用 $|\det J_T|$ 。有向積分則須依積分對象與取向慣例處理符號。
2. 局部可逆就假設全域一對一。極座標在非零半徑處局部正則，但讓角度跑滿兩圈會把大部分圓環覆蓋兩次。直接積分兩圈會把普通面積算兩遍；應限制角度區間，或明確計入覆蓋次數。

3. **忽略奇異點與邊界**。在 $r = 0$ ，極座標 Jacobian 為零，而且多個參數點代表同一原點。對一般圓盤面積積分，該單點不影響結果；若奇異性或集合測度使相關集合不能忽略，就須另行驗證。
4. **把 Jacobian 當作整個區域的縮放常數**。只有仿射映射的 Jacobian 才是常數。非線性映射須在每個參數點使用 $|\det J_T(u)|$ ，不可只取中心點值乘上總面積。
5. **以數值抽樣取代定理條件**。隨機點或有限網格看不到所有可能的折疊、自交與零行列式點。數值核對能發現特定實作錯誤，不能證明映射一對一或餘項具有所需性質。
6. **在座標變換中漏掉單位**。若輸入參數的分量有不同單位，Jacobian 元素的單位是輸出分量單位除以輸入分量單位。行列式帶有相應的合成單位，不能把它誤當成無因次常數。

AI、幾何與養殖案例

設一個合成感測器座標模型，把參數 u （單位 m）和 θ （單位 rad）映到平面位置：

$$T(u, \theta) = (u \cos \theta, u \sin \theta).$$

兩個輸出分量單位都是 m。由於弧度在分析中視作無因次量，Jacobian 為

$$J_T(u, \theta) = \begin{pmatrix} \cos \theta & -u \sin \theta \\ \sin \theta & u \cos \theta \end{pmatrix}, \quad \det J_T(u, \theta) = u.$$

第一欄元素的單位為 m/m，第二欄元素的單位為 m/rad。將弧度視為無因次量時，行列式的單位是 m；再乘上單位為 m 的 du 與無因次的 $d\theta$ ，面積元素 $u du d\theta$ 的單位才是平方公尺。當 $u > 0$ 且角度範圍不重複時，參數小區塊的面積約為 $u du d\theta$ 。當 $u = 0$ ，角度無法識別位置，這不只是代數上的零行列式，也反映參數化在中心的退化。

若 AI 系統協助整理這類合成感測座標的校準資料，可以報告參數域、映射公式、單位、Jacobian、覆蓋範圍、奇異點和數值檢查方式。它不能只用幾個量測點就宣稱連續域上沒有重複覆蓋；模型校準也不等於現場驗證。本文案例是數學示範，不代表任何養殖設備的校準規格。

在右手 $X/Y/Z$ 慣例中，若平面幾何以 X 為水平軸、 Y 為縱深軸，影像顯示時可能把原點放在左上角並反轉某一軸。這會改變顯示座標的方向慣例，卻不能悄悄改寫數學映射的行列式符號。分析資料時應明列座標軸方向、原點位置、參數範圍與面積單位。AI 的角色是提供可稽核的證據摘要，不控制設備、不改變投餌或加藥設定。

習題

習題一：手算仿射換元

令 $T(u, v) = (3u - v, 2u + v)$ ，而 $S = [0, 1] \times [0, 2]$ 。

1. 求 J_T 與行列式。
2. 求 $T(S)$ 的面積。
3. 說明為什麼這裡可以直接用仿射換變數公式。

習題二：極座標與重複覆蓋

考慮 $T(r, \theta) = (r \cos \theta, r \sin \theta)$ 。

1. 計算 Jacobian 行列式。
2. 計算單位圓盤面積。
3. 若參數範圍取 $0 \leq r \leq 1$, $0 \leq \theta \leq 4\pi$ ，積分 $\iint 1 \, dx \, dy$ 的參數積分會得到多少？解釋差異。

習題三：程式與反例

考慮 $A = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$ 。

1. 計算 $\det A$ 。
2. 解釋它為何不能用本章的可逆仿射換元公式計算像區域的二維面積縮放。
3. 若用程式檢查 $\det A = 0$ ，此計算能證明一般非線性映射具有一對一性嗎？說明理由。

習題四：整合判斷

令

$$T(r, \theta) = (2r \cos \theta, r \sin \theta), \quad 0 \leq r \leq 1, \quad 0 \leq \theta \leq 2\pi.$$

1. 求 Jacobian 行列式與面積因子。
2. 描述參數域的像。
3. 計算像區域面積。
4. 指出一對一條件在哪些點或邊界上失效，並說明其對面積積分的影響。

習題解答

解答一

$$J_T = \begin{pmatrix} 3 & -1 \\ 2 & 1 \end{pmatrix}, \quad \det J_T = 3 \cdot 1 - (-1) \cdot 2 = 5.$$

映射可逆，因為行列式非零；又是仿射映射，因此在 S 上一對一。原矩形面積為 $1 \cdot 2 = 2$ ，像面積為

$$|5| \cdot 2 = 10.$$

解答二

$$J_T = \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix}, \quad \det J_T = r.$$

單位圓盤面積為

$$\int_0^{2\pi} \int_0^1 r \, dr \, d\theta = 2\pi \cdot \frac{1}{2} = \pi.$$

若讓角度跑到 4π ，除中心外每個圓盤點被覆蓋兩次，參數積分得到

$$\int_0^{4\pi} \int_0^1 r \, dr \, d\theta = 2\pi.$$

目標圓盤的幾何面積仍為 π ；多出的因子 2 是重複覆蓋所致。此參數化不符合整段參數域上的一對一假設。

解答三

$$\det A = 1 \cdot 4 - 2 \cdot 2 = 0.$$

矩陣奇異，兩個欄向量線性相關，平面被壓到一條直線上；它沒有可逆線性反變換，所以不能套用可逆仿射換元定理。計算這個特定矩陣的行列式，只能判斷這個線性映射退化，不能證明一般非線性映射一對一。一對一是整體域上的性質，必須由映射的定義與適用條件證明；有限計算或有限抽樣不足以涵蓋所有點。

解答四

$$J_T = \begin{pmatrix} 2 \cos \theta & -2r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix}, \quad \det J_T = 2r(\cos^2 \theta + \sin^2 \theta) = 2r.$$

面積因子為 $2r$ 。參數域描述半長軸為 2、半短軸為 1 的橢圓形區域。其面積為

$$\begin{aligned} \text{area}(T(S)) &= \int_0^{2\pi} \int_0^1 2r \, dr \, d\theta \\ &= 2\pi. \end{aligned}$$

在 $r = 0$ 時所有角度映到原點；在 $\theta = 0$ 和 $\theta = 2\pi$ 的邊界上，兩端角度表示同一條射線。因此參數化不是整個閉參數域上的一對一映射。然而重複點位於邊界或中心，對普通面積積分而言是零面積集合；公式可在去除這些邊界集合的區域上套用，所得面積為 2π 。

本章小結

- 可微映射在小尺度上由 Jacobian 線性化；行列式絕對值是局部普通面積或體積縮放因子。
- 仿射映射的 Jacobian 為常數；非線性映射則須在參數點逐點使用 $|\det J_T|$ 。
- 普通積分用 $|\det J_T|$ ；有向積分是否保留行列式符號，取決於所積分的對象與取向慣例。
- 經典換變數公式需要足夠正則性及適當的一對一條件；局部可逆不等於全域一對一。
- 極座標的 Jacobian 為 r ；中心退化與角度端點重複須在定理假設中交代。
- 數值程式可核對特定案例、發現實作錯誤；有限網格不能證明一般定理、一對一性或極限性質。

參考來源

- [A1] Jiří Lebl, *Basic Analysis* (作者目錄與教材入口) : <https://www.jirka.org/ra/>
- [A2] MIT OpenCourseWare, *18.100A Real Analysis* : <https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- [A3] MIT OpenCourseWare, *18.02SC Multivariable Calculus* : <https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

本章採用的換變數定理是多變量微積分的標準結果，上述來源可供進一步閱讀。程式是本章自足示例，未執行。

第21章 曲線、曲面與Gram面積元素

學習目標與先備知識

本章把第19、20章的Fréchet導數、Jacobian與換變數公式，推到曲線與曲面的幾何測度。讀者已完成第7章Fréchet導數（ $f(x+h) = f(x) + Df(x)h + r(h)$ 且 $\|r(h)\|/\|h\| \rightarrow 0$ ）、第8章Jacobian與梯度、第19章多重積分、第20章Jacobian行列式換變數。本章不再重述這些基礎，而是把它們當作工具箱。

本章結束時，學習者應能：

1. 把曲線 $\gamma: [a, b] \rightarrow \mathbb{R}^n$ 視為一個參數化映射，用速度 $\gamma'(t) \in \mathbb{R}^{n \times 1}$ 與其範數寫出弧長積分。
2. 把曲面參數化 $\Phi: U \subset \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 視為 3×2 的Jacobian $J_\Phi = [\partial\Phi/\partial u \ \partial\Phi/\partial v]$ ，並理解切映射把 $\mathbb{R}^2$ 的向量送成 $\mathbb{R}^3$ 的切向量。
3. 由Gram矩陣 $G = J_\Phi^T J_\Phi$ 寫出面積元素 $\sqrt{\det G} du dv$ ，並在有向積分時區分 $|\det J|$ 與 $\sqrt{\det G}$ 。
4. 證明Gram面積元素在重參數化下的不變性，並說明「局部滿秩」條件不可省略。
5. 用自足CPU程式數值檢核橢圓弧長、球面／環面面積、退化切向量。

先備知識還包括：實數完備性、有限維範數等價（第3章）、線性映射的複合與轉置（Volume I）、Riemann和與Fubini定理（第19章）。本章所用向量範數若未指定，均為Euclidean 2-範數；比較Jacobian與餘項時會明示所用範數。

問題與直覺

一條曲線的「長度」與一張曲面的「面積」，直覺上都該是幾何物件本身的量，不應因為我們選了哪一套參數而改變。但計算時只能沿著某個參數化去積分，於是立刻出現三個問題：

第一，參數化會拉伸或壓縮。 圓 $\gamma(t) = (\cos t, \sin t)$ ， $t \in [0, 2\pi]$ 走一圈的速度是 $\|\gamma'(t)\| = 1$ ；但同樣的圓若寫成 $\tilde{\gamma}(s) = (\cos 2s, \sin 2s)$ ， $s \in [0, \pi]$ ，則 $\|\tilde{\gamma}'(s)\| = 2$ 。速度不同，可是若把速度放進弧長積分 $\int \|\gamma'\| dt$ ，兩者都得到 2π 。速度被吸收進積分變數的縮放裡。

第二，曲面參數化的兩個方向可能不正交、長度也未必是1。 在平面上一塊平行四邊形由向量 a, b 張成，面積是 $\sqrt{\|a\|^2\|b\|^2 - (a \cdot b)^2}$ 。把它寫成 $J = [a \ b]$ ，這個量正是 $\sqrt{\det(J^T J)}$ 。推到 $\mathbb{R}^3$ 的曲面片，局部切平面由 Φ_u, Φ_v 兩向量張成，於是局部面積元素就是 $\sqrt{\det G}$ ，其中 G 是兩切向量的Gram矩陣。這不是「把 $\mathbb{R}^2$ 的結果搬過來」的類比口號，而是換變數公式在參數曲面上的具體形式。

第三，取向（orientation）與無向面積是兩件不同的事。 普通面積是正的，換變數用 $|\det DT|$ ；若做的是有向面積或微分形式積分，則保留 $\det DT$ 的正負號。本章的核心 $\sqrt{\det G}$ 只給出無向面積元素；取向要另外指定。

直覺圖像：把曲面切成很多極小的參數矩形 $[u, u + du] \times [v, v + dv]$ ，經過 J_Φ 線性化後近似成由 $\Phi_u du$ 與 $\Phi_v dv$ 張成的平行四邊形。它的面積就是 $\sqrt{\det G} du dv$ 。這個「局部平行四邊形」圖像與第20章「局部體積縮放」是同一件事，只是維度從 $n \rightarrow n$ 換成 $2 \rightarrow 3$ ，Jacobian不再是方陣，必須用 $J^T J$ 才能取行列式。

積分的幾何與取向

普通體積： $\text{abs}(\det DT)$



曲面面積： $\text{sqrt}(\det(J^T J))$



有向通量另含法向與符號



局部可逆不保證全域一對一

曲線與曲面參數化的Gram面積元素示意圖：左側為參數域 $U \subset \mathbb{R}^2$ 中的微小矩形 $[u, u + du] \times [v, v + dv]$ ，經曲面參數化 Φ 與切映射 J_Φ 推送為右側曲面上的局部平行四邊形，其面積為 $\det G du dv$ 。

圖21.1 局部平行四邊形 $[u, u + du] \times [v, v + dv]$ 經 J_Φ 線性化後的像，其面積為 $\sqrt{\det G} du dv$ ，對應於本章核心公式。

定義、定理與推導

定義 21.1（參數化曲線與弧長）

令 $I = [a, b] \subset \mathbb{R}$ ， $\gamma : I \rightarrow \mathbb{R}^n$ 為 C^1 映射。 γ 稱為一條參數化曲線，其速度向量為 $\gamma'(t) \in \mathbb{R}^{n \times 1}$ 。弧長定義為

$$L(\gamma) = \int_a^b \|\gamma'(t)\|_2 dt.$$

若處處 $\gamma'(t) \neq 0$ ，稱 γ 為正則參數化；若只在有限多點失去正則性，則可稱為分段正則。若 γ 不單射，弧長按參數區間計重，這點在重參數化核對時特別重要。

充分條件： C^1 曲線的速度範數在緊區間上連續，故依上述積分定義，其弧長有限。若將弧長推廣為所有分割之折線長度的上確界，Lipschitz 仍是有限弧長的充分條件，但不是必要條件。例如把 $\gamma(t) = \sqrt{t}$ 視為從 $[0, 1]$ 到 $\mathbb{R}$ 的純量值曲線，它不是 Lipschitz，也不屬於上述 C^1 類別；但它單調，折線長度之上確界（全變

差) 為 1。在 $(0, 1]$ 上還可用瑕積分核對：

$$\int_0^1 |\gamma'(t)| dt = \int_0^1 \frac{1}{2\sqrt{t}} dt = 1.$$

這裡不是平面圖形曲線 $(t, \sqrt{t})$ ；後者的弧長公式不同。

定義 21.2 (參數曲面與切映射)

令 $U \subset \mathbb{R}^2$ 為開集， $\Phi: U \rightarrow \mathbb{R}^3$ 為 C^1 映射。 Φ 稱為一張參數曲面。其 Jacobian 為

$$J_\Phi(u, v) = \begin{pmatrix} \frac{\partial \Phi_1}{\partial u} & \frac{\partial \Phi_1}{\partial v} \\ \frac{\partial \Phi_2}{\partial u} & \frac{\partial \Phi_2}{\partial v} \\ \frac{\partial \Phi_3}{\partial u} & \frac{\partial \Phi_3}{\partial v} \end{pmatrix} = [\Phi_u \ \Phi_v] \in \mathbb{R}^{3 \times 2}.$$

對應的切映射 $D\Phi(u, v): \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 把 $(du, dv)^T$ 送到 $\Phi_u du + \Phi_v dv$ 。

定義 21.3 (Gram 矩陣與 Gram 面積元素)

在 (u, v) 處，定義 Gram 矩陣

$$G(u, v) = J_\Phi(u, v)^T J_\Phi(u, v) = \begin{pmatrix} \Phi_u \cdot \Phi_u & \Phi_u \cdot \Phi_v \\ \Phi_v \cdot \Phi_u & \Phi_v \cdot \Phi_v \end{pmatrix}.$$

Gram 面積元素定義為

$$dA = \sqrt{\det G(u, v)} du dv.$$

若在 $\Phi(U)$ 上處處 $\text{rank } J_\Phi = 2$ (即 $\det G > 0$)，則面積元素嚴格正，稱 Φ 為正則參數曲面。

必要條件辨析： $\sqrt{\det G} > 0$ 等價於 Φ_u, Φ_v 線性獨立。但這只是「該點局部」的條件，不是「整個 Φ 是一對一」的條件。一張正則參數曲面仍可能自我重疊 (見反例 21.1)。

定理 21.4 (Gram 行列式公式)

對任意 $J \in \mathbb{R}^{3 \times 2}$ ，設 $J = [a \ b]$ ，則

$$\det(J^T J) = \|a\|^2 \|b\|^2 - (a \cdot b)^2 = \|a \times b\|^2.$$

證明：直接展開 $J^T J = \begin{pmatrix} a \cdot a & a \cdot b \\ b \cdot a & b \cdot b \end{pmatrix}$ ，其行列式即 $\|a\|^2 \|b\|^2 - (a \cdot b)^2$ 。另一方面 Lagrange 恆等式

$\|a\|^2 \|b\|^2 - (a \cdot b)^2 = \|a \times b\|^2$ 對 $\mathbb{R}^3$ 的叉積成立：將 a, b 用標準正交基展開，交叉項相消，得到外積三個分量平方和。兩式相等。□

這個恆等式說明 $\sqrt{\det G}$ 是切平面中平行四邊形的面積，也說明 $\Phi_u \times \Phi_v$ 是其法向量的長度。Gram 元素的優點是不必假設 $\mathbb{R}^3$ 有叉積；同樣公式推廣到 $\Phi: U \subset \mathbb{R}^k \rightarrow \mathbb{R}^n$ ($k \leq n$) 時， $J^T J$ 為 $k \times k$ ， $\sqrt{\det G}$ 為 k 維體積元素。要使此體積元素嚴格為正，**必要且充分條件**是 $J \in \mathbb{R}^{n \times k}$ 在該點滿縱行秩 (full column rank)，即 $\text{rank } J = k$ 。

定理 21.5 (Gram 面積元素的參數化不變性)

設 $U, V \subset \mathbb{R}^2$ 為開集， $\Phi: U \rightarrow \mathbb{R}^3$ 為 C^1 參數曲面， $\psi: V \rightarrow U$ 為 C^1 微分同胚，令 $\Psi = \Phi \circ \psi$ 。則對所有 $(s, t) \in V$ ，

$$\sqrt{\det(J_\Psi^T J_\Psi)} = |\det J_\psi| \cdot \sqrt{\det(J_\Phi^T J_\Phi)}|_{\psi(s,t)}.$$

因此若 $F: \Phi(U) \rightarrow \mathbb{R}$ 連續且 Φ 在 U 上正則，則

$$\iint_V F(\Psi(s, t)) \sqrt{\det G_\Psi} ds dt = \iint_U F(\Phi(u, v)) \sqrt{\det G_\Phi} du dv.$$

證明：由第8章鏈式法則， $\Psi = \Phi \circ \psi$ 的 Jacobian 為

$$J_\Psi(s, t) = J_\Phi(\psi(s, t)) J_\psi(s, t).$$

於是

$$G_\Psi = J_\Psi^T J_\Psi = J_\psi^T J_\Phi^T J_\Phi J_\psi = J_\psi^T G_\Phi J_\psi.$$

兩邊取行列式。對 2×2 矩陣 A 有 $\det A^T = \det A$ ，對 2×2 矩陣 B, C 有 $\det(BC) = \det B \det C$ ，故

$$\det G_\Psi = (\det J_\psi)^2 \det G_\Phi.$$

因 G_Φ 半正定， $\det G_\Phi \geq 0$ ，開根號得

$$\sqrt{\det G_\Psi} = |\det J_\psi| \sqrt{\det G_\Phi}.$$

再把此式代入 Ψ 的面積積分，作變數變換 $(u, v) = \psi(s, t)$ 。因為 ψ 是 C^1 微分同胚，普通積分的換變數公式給出

$$\iint_V F(\Psi(s, t)) \sqrt{\det G_\Psi} ds dt = \iint_U F(\Phi(u, v)) \sqrt{\det G_\Phi} |\det J_\psi| \cdot |\det J_{\psi^{-1}}| du dv.$$

此處兩個 Jacobian 行列式評估於對應點： J_ψ 評估於 $\psi^{-1}(u, v)$ ， $J_{\psi^{-1}}$ 評估於 (u, v) 。鏈式法則 $J_{\psi^{-1}}(\psi(s, t)) J_\psi(s, t) = I$ 對所有 $(s, t) \in V$ 成立；令 $(s, t) = \psi^{-1}(u, v)$ 代入，得

$$J_{\psi^{-1}}(u, v) \cdot J_\psi(\psi^{-1}(u, v)) = I.$$

兩邊取行列式：

$$\det J_{\psi^{-1}}(u, v) \cdot \det J_{\psi}(\psi^{-1}(u, v)) = 1,$$

因此 $|\det J_{\psi}(\psi^{-1}(u, v))| \cdot |\det J_{\psi^{-1}}(u, v)| = 1$ 。代回上式即得右側等於 $\iint_U F(\Phi(u, v)) \sqrt{\det G_{\Phi}} du dv$ 。
□

條件說明：證明用到了 C^1 微分同胚 (ψ 可逆且逆也 C^1)、 U, V 開、 F 連續。若 ψ 只在部分區域是一對一、或 J_{ψ} 在某點為零，則變數變換的條件不成立；面積元素公式本身的代數關係 $\sqrt{\det G_{\Psi}} = |\det J_{\psi}| \sqrt{\det G_{\Phi}}$ 仍逐點成立，但把它們的積分互換需要另行處理重疊區域。這正是「局部不變性」與「全域積分不變性」的區別。

逐步手算例題

例題 21.A（橢圓弧長的手算與級數檢核）

令 $\gamma(t) = (a \cos t, b \sin t)$ ， $t \in [0, 2\pi]$ ， $a > b > 0$ 。速度為

$$\gamma'(t) = (-a \sin t, b \cos t), \quad \|\gamma'(t)\| = \sqrt{a^2 \sin^2 t + b^2 \cos^2 t}.$$

弧長

$$L = \int_0^{2\pi} \sqrt{a^2 \sin^2 t + b^2 \cos^2 t} dt.$$

這是第二類完全橢圓積分，除 $a = b$ 外無初等原函數。取 $a = 3, b = 2$ ，把 $\sin^2 t$ 換成 $1 - \cos^2 t$ ：

$$\|\gamma'(t)\|^2 = 9 \sin^2 t + 4 \cos^2 t = 9 - 5 \cos^2 t.$$

故 $L = \int_0^{2\pi} \sqrt{9 - 5 \cos^2 t} dt$ 。用對稱性縮到四分之一：

$$L = 4 \int_0^{\pi/2} \sqrt{9 - 5 \cos^2 t} dt.$$

手算檢核： $a = b = R$ 時 $L = 2\pi R$ 。取 $R = 3$ 得 $6\pi \approx 18.8496$ 。我們的被積函數在 $\cos^2 t \in [0, 1]$ 上介於 $\sqrt{4} = 2$ 與 $\sqrt{9} = 3$ 之間： $L \in [4\pi, 6\pi] \approx [12.566, 18.850]$ 。數值上（見實作） $L \approx 15.8654$ 。注意這不是「把圓周公式拿來內插」所能得到的結果。

例題 21.B（球面參數化的Gram元素與面積）

令 $\Phi(u, v) = (R \sin u \cos v, R \sin u \sin v, R \cos u)$ ， $u \in [0, \pi]$ ， $v \in [0, 2\pi]$ ， $R > 0$ 。手算偏導：

$$\Phi_u = R(\cos u \cos v, \cos u \sin v, -\sin u), \quad \Phi_v = R(-\sin u \sin v, \sin u \cos v, 0).$$

Gram元素：

- $\Phi_u \cdot \Phi_u = R^2(\cos^2 u \cos^2 v + \cos^2 u \sin^2 v + \sin^2 u) = R^2$ 。
- $\Phi_u \cdot \Phi_v = R^2(-\cos u \sin u \cos v \sin v + \cos u \sin u \sin v \cos v + 0) = 0$ （正交！）。
- $\Phi_v \cdot \Phi_v = R^2(\sin^2 u \sin^2 v + \sin^2 u \cos^2 v) = R^2 \sin^2 u$ 。

故 $G = \text{diag}(R^2, R^2 \sin^2 u)$ ， $\det G = R^4 \sin^2 u$ ， $\sqrt{\det G} = R^2 |\sin u| = R^2 \sin u$ （因 $u \in [0, \pi]$ ）。面積

$$A = \int_0^{2\pi} \int_0^\pi R^2 \sin u \, du \, dv = 2\pi R^2 \cdot 2 = 4\pi R^2.$$

邊界檢查： $u = 0$ 與 $u = \pi$ 是極點， $\sqrt{\det G} = 0$ ，切映射秩下降為1。這不影響球面面面積積分，因為奇異集是零測度的兩點（確切地說， $u = 0$ 和 $u = \pi$ 兩條退化線各收縮為一點）。但若面積公式要逐點正則，需排除極點；這是「幾乎處處正則」的典型用法。

實作與程式

以下程式使用NumPy，僅CPU，不安裝任何套件即可以已安裝版本執行。若未執行，預期結果以註解標明。程式提供三個函數：橢圓弧長、球面面積、退化核對。

```
import numpy as np

def ellipse_arc_length(a, b, n=2_000_000):
    """橢圓 (a cos t, b sin t), t in [0, 2pi] 的弧長，
    用中點法在 n 個子區間上求積分。"""
    t = (np.arange(n) + 0.5) * (2*np.pi/n)
    speed = np.sqrt((a*np.sin(t))**2 + (b*np.cos(t))**2)
    return speed.sum() * (2*np.pi/n)

def sphere_area(R, nu=2000, nv=2000):
    """球面參數化：u in [0, pi], v in [0, 2pi]，
    sqrt(det G) = R^2 sin(u)"""
    u = (np.arange(nu) + 0.5) * (np.pi/nu)
    v = (np.arange(nv) + 0.5) * (2*np.pi/nv)
    gram = R**2 * np.sin(u)          # 一維，對 u 積分
    du = np.pi/nu
    dv = 2*np.pi/nv
    return (gram.sum()*du) * (nv*dv)

def torus_area(R, r, nu=2000, nv=2000):
    """環面  $\Phi(u,v)=((R+r \cos u)\cos v, (R+r \cos u)\sin v, r \sin u)$ 。
    sqrt(det G) = r(R + r cos u)"""
    u = (np.arange(nu) + 0.5) * (2*np.pi/nu)
    v = (np.arange(nv) + 0.5) * (2*np.pi/nv)
    gram = r * (R + r*np.cos(u))
    return (gram.sum() * (2*np.pi/nu)) * (nv*(2*np.pi/nv))

if __name__ == "__main__":
    print("ellipse a=3,b=2:", ellipse_arc_length(3.0, 2.0))
    print("sphere R=2:   ", sphere_area(2.0), "expected", 4*np.pi*4)
    print("torus R=3,r=1:", torus_area(3.0, 1.0), "expected", 4*np.pi**2*3*1)
```


預期輸出（未執行，依公式推算）：

- `ellipse a=3,b=2`: 約 15.8654（四分之一積分乘4的估計）。
- `sphere R=2`: 約 50.2655，即 16π 。
- `torus R=3,r=1`: 約 118.4353，即 $12\pi^2$ 。

演算法與誤差：橢圓弧長使用中點法，誤差為 $O(n^{-2})$ （在被積函數 C^∞ 上）；球面與環面把 u 方向的Gram因子先積掉，再乘 v 方向長度，因 G 對 v 不依賴，這是精確的降維技巧。若被積函數依賴 v ，則需二維格網。

測試與預期結果

實作需搭配以下測試。每項標明「預期」與「檢查方式」。

正常測試 T1（球面面積）：`sphere_area(2.0)` 應收斂到 $16\pi \approx 50.26548$ 。檢查方式：與解析值比較，相對誤差 $< 10^{-6}$ （中點法 $O(n^{-2})$ ， $n = 2000$ 足夠）。

正常測試 T2（環面面積）：`torus_area(3.0,1.0)` 應收斂到 $4\pi^2 Rr = 12\pi^2 \approx 118.43525$ 。Gram元素為 $r(R + r \cos u)$ ，對 v 積分得 2π ，對 u 積分得 $2\pi Rr \cdot 2\pi = 4\pi^2 Rr$ 。

邊界測試 T3（ $a = b$ 退化為圓）：`ellipse_arc_length(2,2)` 應約為 $4\pi \approx 12.56637$ 。這是橢圓退化的邊界，可檢查弧長函數在 $a = b$ 是否仍正確。

邊界測試 T4（極點附近）：`sphere_area` 在 u 格網包含 $u = \pi/2$ 時， $\sin u$ 最大；若手動令 u 取到 0 或 π ， $\sqrt{\det G} = 0$ ，數值上由於使用中點法避開端點，不會出現零除。這驗證退化點不破壞積分。

故障測試 T5（重參數化非一對一）：考慮 $\tilde{\Phi}(u, v) = \Phi(u, 2v)$ ， $v \in [0, 2\pi]$ 。此時 $\det J_\psi = 2$ ， $\sqrt{\det G_{\tilde{\Phi}}} = 2\sqrt{\det G_\Phi}$ ，但參數域也覆蓋了兩次。若仍對 $v \in [0, 2\pi]$ 積分，得到的面積是球面面積的兩倍。**預期**：這不是公式錯，而是「重疊覆蓋」；檢查方式是比對 $\iint_{\tilde{U}} \sqrt{\det G_{\tilde{\Phi}}}$ 是否為 $8\pi R^2$ 。**故障訊息**：使用者若以為「參數化不變性」等於「任何參數化都給同一面積」，就會誤判。

故障測試 T6（退化切向量）：參數化 $\Phi(u, v) = (u, 0, 0)$ ， $J_\Phi = [(1, 0, 0)^T \ (0, 0, 0)^T]$ ， $G = \text{diag}(1, 0)$ ， $\det G = 0$ ， $\sqrt{\det G} = 0$ 。預期面積為 0；檢查程式是否回傳 0 而非 NaN 或負值。

反例與常見陷阱

反例 21.1（正則但重疊的參數化）

令

$$\Phi(u, v) = (\cos(2\pi u), \sin(2\pi u), v), \quad (u, v) \in (0, 1) \times (0, 1),$$

並令同一公式定義的 $\tilde{\Phi}$ 取參數域 $(0, 2) \times (0, 1)$ 。兩者的切向量為

$$\Phi_u = 2\pi(-\sin(2\pi u), \cos(2\pi u), 0), \quad \Phi_v = (0, 0, 1),$$

故 $\det G = 4\pi^2 > 0$ ，處處正則。然而 $\tilde{\Phi}(u+1, v) = \tilde{\Phi}(u, v)$ ，所以較大的參數域把同一圓柱側面覆蓋兩次。對 Φ 積分 $\sqrt{\det G} = 2\pi$ 得面積 2π ，對 $\tilde{\Phi}$ 積分則得 4π ，但兩者的像集相同。**教訓**： $\sqrt{\det G} > 0$ 是局部滿秩，不是單射；「參數化不變性」要求參數域之間有適當的一對一坐標變換，而非僅僅要求參數化為 C^1 。

反例 21.2（切向量正交但非單位）

圓柱面 $\Phi(u, v) = (R \cos v, R \sin v, u)$ ， $u \in [0, h]$ ， $v \in [0, 2\pi]$ 。 $\Phi_u = (0, 0, 1)$ ， $\Phi_v = (-R \sin v, R \cos v, 0)$ ， $G = \text{diag}(1, R^2)$ ， $\sqrt{\det G} = R$ 。面積 $2\pi Rh$ ，正確。若有人誤把 $\sqrt{\det G}$ 一概當成 $\|\Phi_u\| \|\Phi_v\| = R$ ，在此例恰好正確。一般參數化的兩個切向量未必正交；例如平面參數化 $\Psi(u, v) = (u + v, v, 0)$ 有 $\Psi_u = (1, 0, 0)$ 、 $\Psi_v = (1, 1, 0)$ ，因此 $\|\Psi_u\| \|\Psi_v\| = \sqrt{2}$ ，但

$$G = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}, \quad \sqrt{\det G} = 1.$$

兩者相差夾角的 $\sin \theta$ 因子。上例題 21.B 的球面坐標其實有 $\Phi_u \cdot \Phi_v = 0$ ，所以其 G 是對角矩陣，不能作為非正交反例。**陷阱**：把「正交時 G 對角」誤當一般公式。

反例 21.3（叉積的取向符號）

若做有向面積積分，使用 $\Phi_u \times \Phi_v$ 時，參數重排 $(u, v) \mapsto (v, u)$ 會使叉積變號，而有向面積元素符號改變；無向面積元素 $\sqrt{\det G}$ 不變。若混用兩者，會出現「同一片曲面得到正負不同結果」的假矛盾。

反例 21.4（曲線自交不影響弧長，但影響「一對一重參數化」）

曲線 $\gamma(t) = (\cos t, \sin t)$ ， $t \in [0, 4\pi]$ 走兩圈，弧長 4π 。若誤以為「弧長應等於幾何圓周 2π 」，是把「參數區間」與「像集」混淆。任何重參數化若保持區間覆蓋一次，弧長才不變。

反例 21.5（秩退化但局部單射）

參數曲面 $\Phi(u, v) = (u^3, v, 0)$ ， $(u, v) \in (-1, 1)^2$ 。在 $u = 0$ 處 $\Phi_u = (3u^2, 0, 0)^T|_{u=0} = (0, 0, 0)^T$ ，故 $\text{rank } J_\Phi = 1$ 、 $\det G = 0$ 。但 $u \mapsto u^3$ 在 $\mathbb{R}$ 上嚴格單調且為單射， $v \mapsto v$ 亦然，故 Φ 在 $(-1, 1)^2$ 上（含 $u = 0$ 之鄰域）是全單射。這說明**秩退化不蘊含局部自交**；「退化點一定是自交」是錯誤直覺。（對照： $u \mapsto u^2$ 在 $u = 0$ 也秩退化，但在該點鄰域非單射，因為 u 與 $-u$ 映射到同一點，可見秩退化與單射性之間沒有單一方向之蘊含。）

AI、幾何與養殖案例

在合成養殖感測場景中（例如水下網箱外的三維探頭軌跡），一條曲線代表探頭移動路徑，其弧長對應移動距離；一張曲面代表網箱表面的參數化掃描。**單位說明：**網箱半徑 R 以公尺（m）為單位， Φ_u, Φ_v 的單位是 $\text{m}/(\text{參數單位})$ ，Gram 矩陣元素單位是 $\text{m}^2/(\text{參數單位})^2$ ， $\sqrt{\det G} du dv$ 單位是 m^2 ，與面積一致。若某一分量以公分輸入，需先統一為公尺，否則 $\sqrt{\det G}$ 的混合單位不具物理面積意義。

AI相關：參數曲面常被離散化為三角網格用於機器學習的幾何處理；三角形面積是 $\frac{1}{2}\|a \times b\|$ ，其連續極限正是 $\sqrt{\det G} du dv$ 的一半（局部參數四邊形平均切成兩三角）。若模型以「頂點數乘單位面積」估計表面積，當節點密度不均時會產生偏誤；這是取樣誤差，不是定理。反例21.5（秩退化但局部單射）對網格生成的意義是：參數化 Jacobian 在某點秩下降，不必然造成網格在該處自交或退化；診斷需看實際像集之拓撲，而不只看 $\det G$ 。

唯讀agent聲明：本案例合成的數據與參數僅作數學示例。agent不控制探頭、不校正設備、不改變投餌或水質，只整理數學證據。模型穩定不等於養殖操作安全。

習題

習題21.1（手算）：螺旋線 $\gamma(t) = (a \cos t, a \sin t, bt)$ ， $t \in [0, 2\pi]$ ， $a, b > 0$ 。寫出 $\gamma'(t)$ ，計算 $\|\gamma'(t)\|$ ，求弧長。

習題21.2（手算）：環面參數化 $\Phi(u, v) = ((R + r \cos u) \cos v, (R + r \cos u) \sin v, r \sin u)$ ， $u, v \in [0, 2\pi]$ ， $R > r > 0$ 。計算 Φ_u, Φ_v ，證明 $G = \text{diag}(r^2, (R + r \cos u)^2)$ ，求面積。

習題21.3（程式）：用本章實作，計算 $a = 5, b = 3$ 的橢圓弧長，並以 $a = b = 3$ 作為邊界測試。說明為何數值方法不能「證明」橢圓弧長沒有初等閉式。

習題21.4（反例）：給一個 C^1 參數曲面 Φ ，在某一點 $\text{rank } J_\Phi < 2$ （即 $\det G = 0$ ），但 Φ 在該點附近仍是一對一。說明這與「退化點一定是自交」的錯誤直覺有何不同。

習題21.5（整合）：證明：若 Φ 為 C^1 參數曲面， ψ 為 C^1 微分同胚，則 $\sqrt{\det G_\Psi} = |\det J_\psi| \sqrt{\det G_\Phi} \circ \psi$ 。並說明這個恆等式與普通換變數公式 $\iint F | \det DT |$ 的關係。

習題解答

解21.1： $\gamma'(t) = (-a \sin t, a \cos t, b)$ ， $\|\gamma'(t)\| = \sqrt{a^2 \sin^2 t + a^2 \cos^2 t + b^2} = \sqrt{a^2 + b^2}$ （常數）。故 $L = \int_0^{2\pi} \sqrt{a^2 + b^2} dt = 2\pi \sqrt{a^2 + b^2}$ 。**直覺：**螺旋線速度大小恆定，因此弧長等於速度乘參數區間長。

解21.2：計算 $\Phi_u = (-r \sin u \cos v, -r \sin u \sin v, r \cos u)$ ， $\|\Phi_u\| = r$ ； $\Phi_v = (-(R + r \cos u) \sin v, (R + r \cos u) \cos v, 0)$ ， $\|\Phi_v\| = R + r \cos u$ 。又 $\Phi_u \cdot \Phi_v = r(R + r \cos u)(\sin u \cos v \sin v - \sin u \sin v \cos v) = 0$ 。故 $G = \text{diag}(r^2, (R + r \cos u)^2)$ 。 $\det G = r^2(R + r \cos u)^2$ ， $\sqrt{\det G} = r(R + r \cos u)$ （因 $R > r$ ， $R + r \cos u > 0$ ）。面積

$$A = \int_0^{2\pi} \int_0^{2\pi} r(R + r \cos u) du dv = 2\pi r [2\pi R + 0] = 4\pi^2 Rr.$$

解21.3：理論上 $a = 5, b = 3$ 的弧長

$$L = 4 \int_0^{\pi/2} \sqrt{25 - 16 \cos^2 t} dt.$$

程式中使用中點法， $n = 2 \times 10^6$ 時預期值約 25.526 左右（具體數字依實作而異，需實際執行確認）。 $a = b = 3$ 時應得到 $6\pi \approx 18.8496$ 。數值方法**不能證明**無初等閉式：數值收斂只說明「某個積分值」存在且可逼近，閉式的不存在性屬於微分代數（例如橢圓積分理論）或 Liouville 判準的範圍，超出本章。

解21.4：取 $\Phi(u, v) = (u^3, v, 0)$ ， $(u, v) \in (-1, 1)^2$ 。在 $u = 0$ 處 $\Phi_u = (0, 0, 0)^T$ 、 $\Phi_v = (0, 1, 0)^T$ ， J_Φ 秩為 1、 $\det G = 0$ 。另一方面 $u \mapsto u^3$ 與 $v \mapsto v$ 在 $\mathbb{R}$ 上均為單射，故 Φ 在 $(-1, 1)^2$ 上（特別是在原點鄰域）為單射；欲驗證局部單射可看：若 $u_1^3 = u_2^3$ 則 $u_1 = u_2$ （三次函數嚴格單調），若 $v_1 = v_2$ 則 $v_1 = v_2$ ，故 $\Phi(u_1, v_1) = \Phi(u_2, v_2) \Rightarrow (u_1, v_1) = (u_2, v_2)$ 。**充分／必要分離：**對此 $2 \rightarrow 3$ 參數化，滿縱行秩可推出局部單射：選取 Jacobian 中行列式非零的 2×2 子式，將 Φ 投影到對應的兩個目標座標，再對所得 $2 \rightarrow 2$ 映射套用反函數定理。這也給出局部像上的 C^1 坐標反解，但不是直接對非方陣 J_Φ 使用反函數定理。局部單射不要求滿縱行秩，本題的 u^3 即為反例；它也不保證局部 C^1 反解。秩下降的例子既可局部單射（ u^3 ，如本例），也可局部非單射（ u^2 在 $u = 0$ 之任一鄰域非單射，因 u 與 $-u$ 同像）。因此「秩退化」與「局部自交」之間沒有普遍蘊含，「退化點一定是自交」是錯誤直覺。

解21.5：由鏈式法則 $J_\Psi = J_\Phi \circ \psi \cdot J_\psi$ ，所以 $G_\Psi = J_\psi^T G_\Phi J_\psi$ ，取行列式得 $\det G_\Psi = (\det J_\psi)^2 \det G_\Phi$ ，開根得恆等式。與普通換變數的關係：在平面參數域 U 內，面積元素 $\sqrt{\det G_\Phi} du dv$ 在局部坐標下是正測度， ψ 是坐標變換， $|\det J_\psi|$ 正是第20章 $\iint F |\det DT|$ 中的換變數因子。本章的公式把它放在參數域而非目標曲面，兩者等價。

本章小結

本章把「長度」與「面積」放進Fréchet導數的架構：曲線的弧長來自速度範數 $\|\gamma'(t)\|$ ；曲面的面積來自Gram行列式 $\sqrt{\det(J_\Phi^T J_\Phi)}$ 。Gram面積元素是第20章換變數公式在 $2 \rightarrow 3$ 參數曲面的直接推廣，也是後續線積分、面積分與積分定理的度量基礎。核心定理21.5證明重參數化下 $\sqrt{\det G}$ 只差 $|\det J_\psi|$ 因子，配合換變數公式即得不變性；定理條件中的 C^1 微分同胚不可換成正則參數化，否則重疊覆蓋會使積分計重。

使用時需分清：局部滿秩（ $\det G > 0$ ）與全域單射是獨立的，且秩退化既不蘊含局部自交也不排除局部單射（反例21.5）；無向面積用 $\sqrt{\det G}$ ，有向積分另留符號；邊界退化（如球面極點）可用「幾乎處處正則」處理，但需交代零測度奇異集。數值手算與CPU實作可檢核這些公式，但不是證明；證明仍需鏈式法則、行列式乘法與換變數定理的條件。

參考來源

- [A1] Jiří Lebl, *Basic Analysis* (作者目錄與教材入口)，<https://www.jirka.org/ra/>，2026-10-05 取得作者首頁。
- [A2] MIT OCW 18.100A *Real Analysis*，<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>，課程概要已取得。
- [A3] MIT OCW 18.02SC *Multivariable Calculus*，<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>，課程概要已取得。
- [A4] JAX Autodiff Cookbook：JVP／VJP，https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html，作為第8～9章延伸參考，本章核心不要求JAX。
- [A5] SciPy `linalg.expm`，<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>，延伸參考，本章未使用。
- [A6] SciPy `optimize.minimize`，<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>，延伸參考，本章未使用。

來源說明：2026-10-05已取得 A1 作者目錄頁、A2／A3 課程概要與 A4～A6 API 文件頁；未讀完教材 PDF 或完整課程，未執行外部程式。A1 的舊 `htmlv2` 路徑回報 404，合併入口未能擷取，故僅把作者首頁標為已取得。線上 API 版本可能與本機不同。本章定理21.4、21.5的陳述與證明由作者依微積分與線性代數標準結果整理，未逐條比對特定教材頁碼。

第22章 線積分、勢函數與拓撲界線

學習目標與先備知識

本章研究向量場沿曲線的線積分，以及三個相關但不能任意混同的性質：

1. 向量場是否為某個標量函數的梯度；
2. 線積分是否只依賴起點與終點；
3. 每一條閉曲線上的線積分是否皆為零。

完成本章後，讀者應能：

- 定義分段 C^1 曲線及向量場線積分；
- 分辨標量弧長積分 $\int_{\gamma} f \, ds$ 與有向線積分 $\int_{\gamma} F \cdot dr$ ；
- 證明梯度場的線積分基本定理；
- 說明勢函數、路徑獨立及閉路零積分之間的等價關係；
- 區分旋度零的必要性與附帶域條件的充分性；
- 以穿孔平面說明局部微分條件與全域拓撲之間的界線；
- 說明單連通是常用的充分域條件，但不是特定向量場保守的必要條件；
- 使用 NumPy 在 CPU 上近似閉路積分，測試取向、繞數與奇異點；
- 區分定理證明、解析計算、數值證據及有限採樣。

先備知識包括多變量微分、梯度、鏈式法則、單變量積分、曲線參數化，以及開集、連通、路徑連通與單連通的基本概念。本章主要在 $\mathbb{R}^2$ 與 $\mathbb{R}^3$ 工作，但部分定理寫成 $\mathbb{R}^n$ 的形式。

問題與直覺

設 F 是平面上的力場，粒子沿曲線 γ 從 A 移到 B 。力場所做的功為

$$\int_{\gamma} F \cdot dr.$$

一般而言，積分可能依賴實際路徑。例如旋轉型向量場可能記錄曲線繞某個奇異點幾圈。若存在標量函數 ϕ 使

$$F = \nabla \phi,$$

則由鏈式法則，

$$F(\gamma(t))^T \gamma'(t) = \nabla \phi(\gamma(t))^T \gamma'(t) = \frac{d}{dt} \phi(\gamma(t)).$$

因此積分只剩下端點勢差：

$$\int_{\gamma} F \cdot dr = \phi(B) - \phi(A).$$

梯度場可直觀地想成全域高度函數的斜率資料。若沿閉路回到起點，高度淨變化必為零。

在二維中，若 $F = (P, Q)$ ，標量旋度為

$$\text{curl } F = \frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y}.$$

旋度零表示局部交叉偏導相容。然而局部相容不必然產生全域勢函數。若域中有孔洞，某些閉路可能無法在域內縮成一點；沿這些閉路仍可能得到非零環流。

數值計算也有明確界線。找到一條合法閉路並嚴格證明其積分非零，可以推翻保守性；但檢查有限多條閉路皆接近零，不能證明所有閉路積分都等於零。無限命題需要解析構造或定理，不能由有限採樣取代。

定義、定理與推導

1. 分段光滑曲線與線積分

定義 22.1 (分段 C^1 曲線)

映射 $\gamma : [a, b] \rightarrow \mathbb{R}^n$ 若連續，且存在有限分割

$$a = t_0 < t_1 < \cdots < t_k = b$$

使 γ 在每個子區間上為 C^1 ，則稱 γ 為分段 C^1 曲線。

設 $U \subset \mathbb{R}^n$ ， $F : U \rightarrow \mathbb{R}^n$ 連續，且 $\gamma([a, b]) \subset U$ 。向量場沿 γ 的有向線積分定義為

$$\int_{\gamma} F \cdot dr = \int_a^b F(\gamma(t))^T \gamma'(t) dt.$$

在 Euclidean 內積下， $F(\gamma(t))$ 與 $\gamma'(t)$ 均視為 $n \times 1$ 的 column vector，其內積為純量。

若反向參數化為

$$\bar{\gamma}(t) = \gamma(a + b - t),$$

則

$$\bar{\gamma}'(t) = -\gamma'(a + b - t),$$

所以

$$\int_{\bar{\gamma}} F \cdot dr = - \int_{\gamma} F \cdot dr.$$

相對地，標量弧長積分為

$$\int_{\gamma} f ds = \int_a^b f(\gamma(t)) \|\gamma'(t)\|_2 dt.$$

由於弧長積分使用非負速度 $\|\gamma'(t)\|_2$ ，反向參數化不會使其變號。有向線積分與弧長積分不可混用。

2. 勢函數與保守場

定義 22.2 (勢函數與保守場)

設 $U \subset \mathbb{R}^n$ 為開集。若存在 $\phi \in C^1(U)$ 使

$$F = \nabla \phi,$$

則稱 ϕ 為 F 的勢函數，並稱 F 為保守場或梯度場。

若 U 連通，兩個勢函數 ϕ 與 ψ 滿足

$$\nabla(\phi - \psi) = 0.$$

因 $\mathbb{R}^n$ 的開連通集是路徑連通的，任取域內兩點，可用域內分段 C^1 路徑連接。沿該路徑使用鏈式法則， $\phi - \psi$ 的導數恆為零，因此 $\phi - \psi$ 沿路徑恆定。故兩個勢函數在整個 U 上只相差一個常數。若 U 不連通，每個連通分支上的常數可以不同。

3. 梯度場的線積分基本定理

定理 22.1 (線積分基本定理)

設 $U \subset \mathbb{R}^n$ 為開集， $\phi \in C^1(U)$ ，且 $F = \nabla \phi$ 。若 $\gamma: [a, b] \rightarrow U$ 是分段 C^1 曲線，則

$$\int_{\gamma} F \cdot dr = \phi(\gamma(b)) - \phi(\gamma(a)).$$

證明。

先假設 γ 為 C^1 。由多變量鏈式法則，

$$\frac{d}{dt}(\phi \circ \gamma)(t) = D\phi(\gamma(t))[\gamma'(t)] = \nabla \phi(\gamma(t))^T \gamma'(t).$$

因此由單變量微積分基本定理，

$$\begin{aligned}
\int_{\gamma} F \cdot dr &= \int_a^b \nabla \phi(\gamma(t))^T \gamma'(t) dt \\
&= \int_a^b \frac{d}{dt} \phi(\gamma(t)) dt \\
&= \phi(\gamma(b)) - \phi(\gamma(a)).
\end{aligned}$$

若 γ 只分段 C^1 ，就在每個子區間套用上述公式。各段相加時，中間端點的勢函數值兩兩消去，仍得到同一結論。證畢。

這項結果是對所有符合條件曲線的證明，不是從有限條曲線的試算歸納而來。

4. 路徑獨立與閉路積分

定義 22.3 (路徑獨立)

設 U 為開且路徑連通的集合。歐氏空間的開連通集可由域內有限段折線連接任意兩點，因此此處所需的分段 C^1 路徑確實存在。若對任意 $A, B \in U$ ，以及任意兩條由 A 到 B 的域內分段 C^1 曲線 γ_1, γ_2 ，皆有

$$\int_{\gamma_1} F \cdot dr = \int_{\gamma_2} F \cdot dr,$$

則稱線積分在 U 上路徑獨立。

命題 22.2 (三種全域性質等價)

設 $U \subset \mathbb{R}^n$ 為開且路徑連通的集合， $F : U \rightarrow \mathbb{R}^n$ 連續。下列敘述等價：

1. 存在 $\phi \in C^1(U)$ 使 $F = \nabla \phi$ ；
2. F 的線積分在 U 上路徑獨立；
3. 對每條位於 U 中的分段 C^1 閉曲線 Γ ，皆有

$$\oint_{\Gamma} F \cdot dr = 0.$$

證明。

若 $F = \nabla \phi$ ，由定理 22.1，任一條由 A 到 B 的曲線積分都是 $\phi(B) - \phi(A)$ ，故 $(1) \Rightarrow (2)$ 。

若線積分路徑獨立，一條閉曲線的起點與終點相同，其積分等於同端點常值路徑的積分，即為零。故 $(2) \Rightarrow (3)$ 。

假設所有閉路積分均為零。令 γ_1, γ_2 都由 A 走到 B 。先沿 γ_1 前進，再沿 γ_2 反向返回，得到一條閉曲線，所以

$$0 = \int_{\gamma_1} F \cdot dr - \int_{\gamma_2} F \cdot dr.$$

故 $(3) \Rightarrow (2)$ 。

最後假設路徑獨立。固定 $x_0 \in U$ ，定義

$$\phi(x) = \int_{x_0}^x F \cdot dr.$$

因路徑獨立，這個值不依賴所選路徑。由於 U 開，對每個 $x \in U$ 及座標方向 e_i ，足夠短的線段 $x + se_i$ 位於 U 。因此

$$\phi(x + he_i) - \phi(x) = \int_0^h F_i(x + se_i) ds.$$

除以 h 後得到

$$\frac{\phi(x + he_i) - \phi(x)}{h} = \frac{1}{h} \int_0^h F_i(x + se_i) ds.$$

由 F_i 在 x 的連續性，令 $h \rightarrow 0$ 可得

$$\frac{\partial \phi}{\partial x_i}(x) = F_i(x).$$

因所有 F_i 連續， $\phi \in C^1(U)$ 且 $\nabla \phi = F$ 。所以 (2) $\Rightarrow$ (1)。證畢。

5. 旋度零的必要性

在三維中，若 $F = (P, Q, R) \in C^1(U; \mathbb{R}^3)$ ，定義

$$\nabla \times F = \begin{pmatrix} R_y - Q_z \\ P_z - R_x \\ Q_x - P_y \end{pmatrix}.$$

在二維中，對 $F = (P, Q)$ 定義標量旋度

$$\text{curl } F = Q_x - P_y.$$

在一般 $\mathbb{R}^n$ 中，本章所稱的「無旋」是指

$$\frac{\partial F_i}{\partial x_j} = \frac{\partial F_j}{\partial x_i} \quad \text{對所有 } i, j.$$

若 $F = \nabla \phi$ 且 $\phi \in C^2(U)$ ，由連續混合偏導相等，

$$\frac{\partial F_i}{\partial x_j} = \frac{\partial^2 \phi}{\partial x_j \partial x_i} = \frac{\partial^2 \phi}{\partial x_i \partial x_j} = \frac{\partial F_j}{\partial x_i}.$$

所以在上述正則性下，無旋是保守性的必要條件。反方向還需要域的全域條件。

6. 星形域上的充分條件

定理 22.3 (星形域上的 Poincaré 型結論)

設 $U \subset \mathbb{R}^n$ 為開星形集，星形中心為 $a \in U$ 。設 $F \in C^1(U; \mathbb{R}^n)$ ，且

$$\frac{\partial F_i}{\partial x_j} = \frac{\partial F_j}{\partial x_i} \quad \text{對所有 } i, j.$$

則 F 在 U 上存在 C^2 勢函數。

證明。

星形性保證對每個 $x \in U$ 與 $0 \leq t \leq 1$ ，點 $a + t(x - a)$ 均位於 U 。定義

$$\phi(x) = \int_0^1 F(a + t(x - a))^T (x - a) dt.$$

寫

$$z(t, x) = a + t(x - a).$$

則

$$\phi(x) = \int_0^1 \sum_{i=1}^n F_i(z(t, x))(x_i - a_i) dt.$$

因 $F \in C^1$ ，integrand 對 (t, x) 連續可微，可在積分號下對 x_k 微分：

$$\frac{\partial \phi}{\partial x_k}(x) = \int_0^1 \left[F_k(z(t, x)) + t \sum_{i=1}^n \frac{\partial F_i}{\partial x_k}(z(t, x))(x_i - a_i) \right] dt.$$

使用交叉偏導相等，

$$\frac{\partial F_i}{\partial x_k} = \frac{\partial F_k}{\partial x_i},$$

所以 integrand 可寫成

$$F_k(z(t, x)) + t \sum_{i=1}^n \frac{\partial F_k}{\partial x_i}(z(t, x))(x_i - a_i).$$

另一方面，由單變量鏈式法則，

$$\frac{d}{dt} F_k(z(t, x)) = \sum_{i=1}^n \frac{\partial F_k}{\partial x_i}(z(t, x))(x_i - a_i).$$

因此

$$\begin{aligned} F_k(z(t, x)) + t \sum_{i=1}^n \frac{\partial F_k}{\partial x_i}(z(t, x))(x_i - a_i) \\ = \frac{d}{dt} [t F_k(z(t, x))]. \end{aligned}$$

代回積分：

$$\begin{aligned} \frac{\partial \phi}{\partial x_k}(x) &= \int_0^1 \frac{d}{dt} [t F_k(z(t, x))] dt \\ &= F_k(z(1, x)) - 0 \cdot F_k(z(0, x)) \\ &= F_k(x). \end{aligned}$$

此式對每個 k 都成立，所以

$$\nabla \phi(x) = F(x).$$

又因 $F \in C^1$ ， $\nabla \phi = F$ 的各分量為 C^1 ，故 $\phi \in C^2(U)$ 。證畢。

這個定理不只宣稱勢函數存在，也給出可直接構造的公式。

7. 單連通集合上的充分條件

定理 22.4（單連通集合上的充分條件）

設 $U \subset \mathbb{R}^n$ 為開、連通且單連通的集合， $F \in C^1(U; \mathbb{R}^n)$ 。若

$$\frac{\partial F_i}{\partial x_j} = \frac{\partial F_j}{\partial x_i} \quad \text{對所有 } i, j,$$

則 F 為保守場。

在二維，上述無旋條件是 $Q_x - P_y = 0$ ；在三維，等價於 $\nabla \times F = 0$ 。一般維度則應使用所有交叉偏導相等的條件，不能把三維的叉積記號直接搬到任意維度。

本章引用定理 22.4，不展開完整的同倫證明。開、連通與單連通均明列為假設；不能只寫「單連通」而默認其他條件。

最後必須分清：

單連通是使每個適當正則無旋場都保守的一項充分域條件，但不是某個特定向量場保守的必要條件。

逐步手算例題

例 1：由勢函數計算端點差

令

$$F(x, y) = \begin{pmatrix} 2xy + 3 \\ x^2 + 2y \end{pmatrix}.$$

由 $\phi_x = 2xy + 3$ 對 x 積分：

$$\phi(x, y) = x^2y + 3x + g(y).$$

再對 y 微分：

$$\phi_y = x^2 + g'(y).$$

與第二分量比較得 $g'(y) = 2y$ ，故可取

$$\phi(x, y) = x^2y + 3x + y^2.$$

由 $A = (0, 0)$ 到 $B = (2, 1)$ 的任意域內分段 C^1 路徑皆有

$$\int_{\gamma} F \cdot dr = \phi(2, 1) - \phi(0, 0) = 4 + 6 + 1 = 11.$$

以折線核對。第一段 $\gamma_1(t) = (t, 0)$ ， $0 \leq t \leq 2$ ：

$$\int_{\gamma_1} F \cdot dr = \int_0^2 3 \, dt = 6.$$

第二段 $\gamma_2(s) = (2, s)$ ， $0 \leq s \leq 1$ ：

$$\int_{\gamma_2} F \cdot dr = \int_0^1 (4 + 2s) \, ds = 5.$$

總和為 11。這次直接積分是解析核對；路徑獨立來自勢函數定理，不是只由一條折線證明。

例 2：穿孔平面的無旋非保守場

令

$$U = \mathbb{R}^2 \setminus \{(0, 0)\}, \quad F(x, y) = \begin{pmatrix} -\frac{y}{x^2 + y^2} \\ \frac{x}{x^2 + y^2} \end{pmatrix}.$$

寫成 $F = (P, Q)$ 。在 U 上，

$$Q_x = \frac{y^2 - x^2}{(x^2 + y^2)^2}, \quad P_y = \frac{y^2 - x^2}{(x^2 + y^2)^2}.$$

因此

$$Q_x - P_y = 0.$$

取逆時針單位圓

$$\gamma(t) = (\cos t, \sin t), \quad 0 \leq t \leq 2\pi.$$

其切向量為

$$\gamma'(t) = (-\sin t, \cos t),$$

而

$$F(\gamma(t)) = (-\sin t, \cos t).$$

所以

$$F(\gamma(t))^T \gamma'(t) = 1,$$

進而

$$\oint_{\gamma} F \cdot dr = \int_0^{2\pi} 1 \, dt = 2\pi \neq 0.$$

由命題 22.2， F 不可能在整個穿孔平面上具有單值勢函數。局部可把它看成角度函數的梯度，但角度繞原點一圈後增加 2π ，無法成為整個 U 上的單值連續函數。

例 3：單連通不是必要條件

仍令

$$U = \mathbb{R}^2 \setminus \{(0, 0)\},$$

但取

$$G(x, y) = (2x, 2y).$$

雖然 U 不是單連通，仍有全域勢函數

$$\phi(x, y) = x^2 + y^2.$$

因此對每條位於 U 中的閉曲線 Γ ，

$$\oint_{\Gamma} G \cdot dr = 0.$$

域中有孔只表示某些無旋場可能不保守，不能推出所有向量場都不保守。

實作與程式

下列自足 NumPy 程式使用複合梯形公式近似

$$\int_a^b F(\gamma(t))^T \gamma'(t) dt.$$

程式只使用 CPU。此處未執行；後文結果皆是解析推導支持的預期。

```
import numpy as np

def trapezoid(y, x):
    return np.sum(
        0.5 * (y[:-1] + y[1:]) * (x[1:] - x[:-1])
    )

def line_integral(field, curve, dcurve, a, b, n=4096):
    if not isinstance(n, int) or isinstance(n, bool) or n < 2:
        raise ValueError("n 必須是至少 2 的整數")
    if not (np.isfinite(a) and np.isfinite(b)) or a == b:
        raise ValueError("積分端點必須有限且彼此不同")

    t = np.linspace(a, b, n + 1)
    points = np.asarray(curve(t), dtype=float)
    tangents = np.asarray(dcurve(t), dtype=float)
    expected = (n + 1, 2)

    if points.shape != expected:
        raise ValueError(f"curve 必須回傳 shape {expected}")
    if tangents.shape != expected:
        raise ValueError(f"dcurve 必須回傳 shape {expected}")
    if not np.all(np.isfinite(points)):
        raise FloatingPointError("曲線包含非有限座標")
    if not np.all(np.isfinite(tangents)):
        raise FloatingPointError("切向量包含非有限數值")
```

```

values = np.asarray(field(points), dtype=float)
if values.shape != expected:
    raise ValueError(f"field 必須回傳 shape {expected}")
if not np.all(np.isfinite(values)):
    raise FloatingPointError("向量場包含非有限數值")

integrand = np.sum(values * tangents, axis=1)
return float(trapezoid(integrand, t))

def circle(radius=1.0, turns=1, clockwise=False):
    if not np.isfinite(radius) or radius <= 0.0:
        raise ValueError("radius 必須是有限正數")
    if not isinstance(turns, int) or isinstance(turns, bool) or turns == 0:
        raise ValueError("turns 必須是非零整數")

    sign = -1.0 if clockwise else 1.0

    def curve(t):
        angle = sign * turns * t
        return np.column_stack((
            radius * np.cos(angle),
            radius * np.sin(angle)
        ))

    def dcurve(t):
        angle = sign * turns * t
        factor = sign * turns * radius
        return np.column_stack((
            -factor * np.sin(angle),
            factor * np.cos(angle)
        ))

    return curve, dcurve

def potential_field(points):
    x = points[:, 0]
    y = points[:, 1]
    return np.column_stack((
        2.0 * x * y + 3.0,
        x * x + 2.0 * y
    ))

def vortex_field(points):
    x = points[:, 0]
    y = points[:, 1]
    radius_squared = x * x + y * y
    if np.any(radius_squared <= 1.0e-24):
        raise FloatingPointError("vortex_field 在原點未定義")
    return np.column_stack((
        -y / radius_squared,
        x / radius_squared
    ))

def assert_close(actual, expected, tolerance, label):

```



```

error = abs(actual - expected)
if error > tolerance:
    raise AssertionError(
        f"{label}: actual={actual}, expected={expected}, error={error}"
    )

def assert_raises(exception_type, function, label):
    try:
        function()
    except exception_type:
        return
    except Exception as error:
        raise AssertionError(
            f"{label}: 得到錯誤型別 {type(error).__name__}"
        ) from error
    raise AssertionError(f"{label}: 未丟出預期例外")

def run_tests():
    # 正常測試：保守場沿閉路積分為零。
    curve, dcurve = circle(radius=1.0)
    value = line_integral(
        potential_field, curve, dcurve, 0.0, 2.0 * np.pi
    )
    assert_close(value, 0.0, 1.0e-10, "conservative loop")

    # 正常測試：渦旋場逆時針繞原點一次。
    value = line_integral(
        vortex_field, curve, dcurve, 0.0, 2.0 * np.pi
    )
    assert_close(value, 2.0 * np.pi, 1.0e-10, "vortex ccw")

    # 邊界測試：縮小半徑不改變繞數。
    small_curve, small_dcurve = circle(radius=1.0e-4)
    value = line_integral(
        vortex_field,
        small_curve,
        small_dcurve,
        0.0,
        2.0 * np.pi
    )
    assert_close(value, 2.0 * np.pi, 1.0e-9, "small circle")

    # 邊界測試：繞兩圈，積分加倍。
    twice, dtwice = circle(radius=2.5, turns=2)
    value = line_integral(
        vortex_field, twice, dtwice, 0.0, 2.0 * np.pi
    )
    assert_close(value, 4.0 * np.pi, 1.0e-10, "two turns")

    # 取向測試：順時針變號。
    clockwise, dclockwise = circle(
        radius=1.0, clockwise=True
    )
    value = line_integral(
        vortex_field,
        clockwise,
        dclockwise,

```

```

    0.0,
    2.0 * np.pi
)
assert_close(value, -2.0 * np.pi, 1.0e-10, "clockwise")

```

故障測試：非法半徑、分割數及場值 shape。

```

assert_raises(
    ValueError,
    lambda: circle(radius=0.0),
    "zero radius"
)
assert_raises(
    ValueError,
    lambda: line_integral(
        vortex_field,
        curve,
        dcurve,
        0.0,
        2.0 * np.pi,
        n=1
    ),
    "too few panels"
)
assert_raises(
    ValueError,
    lambda: line_integral(
        lambda points: points[:, 0],
        curve,
        dcurve,
        0.0,
        2.0 * np.pi
    ),
    "wrong field shape"
)

```

故障測試：曲線在 $t=\pi$ 通過原點。

```

def through_origin(t):
    return np.column_stack((
        1.0 + np.cos(t),
        np.sin(t)
    ))

```

```

def dthrough_origin(t):
    return np.column_stack((
        -np.sin(t),
        np.cos(t)
    ))

```

```

assert_raises(
    FloatingPointError,
    lambda: line_integral(
        vortex_field,
        through_origin,
        dthrough_origin,
        0.0,
        2.0 * np.pi,
        n=1000
    ),
    "curve through singularity"
)

```

```

)

print("所有測試通過")

if __name__ == "__main__":
    run_tests()

```

程式用 $\text{shape}(N, 2)$ 儲存 N 個平面點，每個矩陣橫列是一個點。這是批次資料的儲存方式；公式中的單一向量仍視為 2×1 的 column vector。NumPy 一維陣列的 `.T` 不會改變 shape，因此程式沒有用一維 `.T` 冒充列向量與橫向量的轉換。

測試與預期結果

上述測試程式尚未執行，以下均為預期結果。

正常測試

`potential_field` 的勢函數為

$$\phi(x, y) = x^2y + 3x + y^2.$$

它沿任何閉路的精確積分均為零。對程式所用的單位圓，積分函數是頻率不超過三的三角多項式；在 4096 等分節點上，週期梯形和於精確算術中也等於零。因此第一個 assertion 預期通過。浮點運算仍有求值與累加誤差；未執行程式，不能把 10^{-10} 當成已驗證的通用誤差上界。

渦旋場沿逆時針圓的 integrand 恰為常數 1，預期值為

$$2\pi \approx 6.283185307179586.$$

順時針參數化反轉取向，預期值為 -2π 。

邊界測試

半徑縮小到 10^{-4} 時，解析積分仍為 2π 。此時場值量級約為 10^4 ，切向量量級約為 10^{-4} 。雖然內積仍為正常量級，中間量的放大可能增加浮點風險。

若曲線繞原點兩圈，預期積分為

$$4\pi.$$

一般而言，對不通過原點的分段 C^1 閉曲線 Γ ，渦旋場滿足

$$\oint_{\Gamma} F \cdot dr = 2\pi \text{ wind}(\Gamma, 0),$$

其中 $\text{wind}(\Gamma, 0)$ 是曲線對原點的繞數：沿不經原點的連續閉曲線選取隨參數連續變化的角度，將走完閉路的角度淨變化除以 2π ，所得為整數。分段 C^1 閉曲線符合這些條件；不需要在整個穿孔平面上選取單值角度函數。因此嚴格說法是：

若閉曲線不通過原點，且其對原點的繞數為零，則積分為零。

不能只用含糊的「不包圍原點」處理自交、多圈或方向相反的曲線。

故障測試

- `radius=0` 應丟出 `ValueError`；
- `n=1` 應丟出 `ValueError`；
- 通過原點的曲線應丟出 `FloatingPointError`；
- 曲線、切向量或向量場回傳錯誤 `shape` 時應丟出 `ValueError`；
- 非有限座標、切向量或場值應被拒絕。

離散節點沒有碰到奇異點，不表示連續曲線沒有碰到奇異點。程式中的故障案例特別選取偶數分割，使 $t = \pi$ 成為節點。對一般曲線，還需要解析幾何檢查、區間界或更可靠的碰撞檢測；有限節點不能證明整條曲線都位於定義域。

反例與常見陷阱

1. 把旋度零當成無條件充分條件

穿孔平面的渦旋場在每個定義點都無旋，卻有非零閉路積分。旋度零是局部條件；推出全域勢函數還需要星形、單連通或其他足以排除拓撲障礙的條件。

2. 把單連通當成必要條件

在非單連通的穿孔平面上， $\phi(x, y) = x^2 + y^2$ 仍有保守梯度場。單連通保證一類無旋場都保守，不是某個特定場保守所必須具備的條件。

3. 忽略向量場的定義域

渦旋場在原點未定義。不能在原點計算旋度，也不能把通過原點的曲線積分當成普通線積分。進行形式微分前，必須先寫明定義域。

4. 遺漏依賴其他變數的積分常數

由 $\phi_x = P$ 對 x 積分時，應寫成

$$\phi(x, y) = \int P(x, y) dx + g(y),$$

而不是只加普通常數。若用 $\phi_y = Q$ 比較後，所得 $g'(y)$ 仍依賴 x ，便表示候選場不相容，或前面的積分計算有誤。

5. 混淆必要條件與充分條件

若 $\phi \in C^2$ ，保守場 $\nabla\phi$ 必定無旋，這是必要性。無旋推出保守則需要 $F \in C^1$ 及適當域條件，這是有條件的充分性。兩個方向的假設不同。

6. 把有限數值採樣當成證明

有限條閉路積分接近零，不能證明所有閉路積分為零。另一方面，單次浮點結果非零也不自動構成反例，除非有可靠誤差界或解析計算支持。

7. 忽略取向與繞數

反向曲線使有向線積分變號，重複繞行使積分累加。對自交曲線，「內部」不一定只有一個，因此應使用繞數，而不是只說曲線是否包圍某點。

AI、幾何與養殖案例

1. 學習模型中的梯度一致性

許多最佳化方法由損失函數 $L(\theta)$ 取得更新方向 $\nabla L(\theta)$ 。若資料驅動模型聲稱輸出某個全域損失的精確梯度，理論上應有

$$\oint_{\Gamma} \nabla L(\theta) \cdot d\theta = 0$$

對每條合法閉路成立。

可以在參數空間選取小矩形或圓形閉路作數值診斷。若解析度加密後仍得到明顯非零環流，可能原因包括：

- 所學向量場並非梯度場；
- 不同路段使用不一致的正規化；

- 隨機梯度噪聲未受控制；
- 路徑穿越不可微或未定義區域；
- 參數域刪除了奇異集合；
- 程式中的切向量、取向或 broadcasting 有誤。

但閉路積分接近零仍只是數值證據。要證明存在全域損失函數，需直接構造勢函數，或驗證正則性、無旋性及域的拓撲條件。

2. 幾何觀點

在 Euclidean 內積下，梯度 $\nabla\phi$ 表示線性泛函 $D\phi$ ：

$$D\phi(x)[v] = \nabla\phi(x)^T v.$$

線積分可看成沿曲線逐點配對微分與切向量。若改用非 Euclidean 度量，將微分轉為梯度向量的方式會改變；不能無條件把協向量與向量混同。本章的 $F \cdot dr$ 使用標準 Euclidean 內積。

3. 合成養殖感測校準

考慮完全合成的溫度與鹽度校準座標

$$u = \frac{T - T_0}{s_T}, \quad v = \frac{S - S_0}{s_S},$$

其中 T 與 s_T 的單位為攝氏度， S 與 s_S 的單位為 PSU，而 u, v 均為無因次量。定義合成代價

$$\Phi(u, v) = \frac{1}{2}u^2 + uv + 2v^2.$$

其 Euclidean 梯度為

$$\nabla_{(u,v)}\Phi = \begin{pmatrix} u + v \\ u + 4v \end{pmatrix}.$$

由鏈式法則返回物理變數：

$$\frac{\partial\Phi}{\partial T} = \frac{u + v}{s_T}, \quad \frac{\partial\Phi}{\partial S} = \frac{u + 4v}{s_S}.$$

兩個分量的單位分別是代價每攝氏度與代價每 PSU，不能把未加權的物理分量直接當成同單位的 Euclidean 向量。無因次化提供明確尺度；返回物理量時必須使用相應換算。

若校準程序沿不同參數路徑從同一初值到同一終值，精確梯度積分應給出相同的 Φ 變化。閉路殘差可以作為資料管線的稽核訊號，但不能單獨證明感測器故障，更不能直接觸發投餌、加藥或設備控制。此案例完全合成，agent 只整理證據；模型一致性不等於現場安全驗證。

習題

習題 1：手算

令

$$F(x, y) = (e^x \cos y, -e^x \sin y).$$

1. 求一個勢函數。
2. 計算由 $(0, 0)$ 到 $(1, \pi)$ 的任意分段 C^1 路徑積分。
3. 說明答案為何與路徑無關。

習題 2：程式

使用本章程式計算渦旋場沿橢圓

$$\gamma(t) = (2 \cos t, \sin t), \quad 0 \leq t \leq 2\pi$$

的積分。再定義完整的反向曲線及其導數，比較兩個結果。列出預期值及一個故障測試。

習題 3：反例

判斷下列敘述真假，並證明或給出反例：

若開集 $U \subset \mathbb{R}^2$ 不是單連通，則 U 上不存在保守向量場。

習題 4：整合

令

$$U = \{(x, y) : x > 0\}, \quad F(x, y) = \left(\frac{x}{x^2 + y^2}, \frac{y}{x^2 + y^2} \right).$$

1. 驗證 F 在 U 上旋度為零。
2. 求勢函數。
3. 計算由 $(1, 0)$ 到 $(1, 1)$ 的線積分。
4. 說明域條件在此扮演的角色。

習題 5：數值證據判讀

某系統在三條閉路上得到積分近似值 10^{-8} 、 -3×10^{-7} 與 0.42 。有人宣稱前兩條已證明向量場保守，而第三條只是雜訊。分析還需要哪些資訊？目前可得什麼嚴格結論？

習題 6：概念辨析

在本題中，「無旋」明確指

$$\frac{\partial F_i}{\partial x_j} = \frac{\partial F_j}{\partial x_i} \quad \text{對所有 } i, j.$$

逐一判斷：

1. 每個 C^2 勢函數的梯度場都無旋。
 2. 每個無旋的 C^1 向量場都保守。
 3. 在開、連通且單連通的集合上，每個 C^1 無旋場都保守。
 4. 若向量場保守，則其定義域必須單連通。
 5. 若一條閉路的數值積分接近零，則向量場保守。
-

習題解答

解答 1

由第一分量對 x 積分：

$$\phi(x, y) = e^x \cos y + g(y).$$

因此

$$\phi_y = -e^x \sin y + g'(y).$$

與第二分量比較得 $g'(y) = 0$ ，故可取

$$\phi(x, y) = e^x \cos y.$$

所以

$$\int_{\gamma} F \cdot dr = \phi(1, \pi) - \phi(0, 0) = -e - 1.$$

因 $F = \nabla \phi$ 且 $\phi \in C^\infty(\mathbb{R}^2)$ ，由線積分基本定理，答案與路徑無關。

解答 2

可加入：

```
def ellipse(t):
    return np.column_stack((
        2.0 * np.cos(t),
        np.sin(t)
    ))

def dellipse(t):
    return np.column_stack((
        -2.0 * np.sin(t),
        np.cos(t)
    ))

def reverse_ellipse(t):
    return ellipse(2.0 * np.pi - t)

def dreverse_ellipse(t):
    return -dellipse(2.0 * np.pi - t)

forward = line_integral(
    vortex_field,
    ellipse,
    dellipse,
    0.0,
    2.0 * np.pi
)

backward = line_integral(
    vortex_field,
    reverse_ellipse,
    dreverse_ellipse,
    0.0,
    2.0 * np.pi
)

assert_close(
    forward, 2.0 * np.pi, 1.0e-7, "ellipse forward"
)
assert_close(
    backward, -2.0 * np.pi, 1.0e-7, "ellipse backward"
)
```

橢圓逆時針繞原點一次，故正向預期為 2π 。反向參數化時，導數必須同時乘以 -1 ，因此反向預期為 -2π 。

故障測試可使用

$$\eta(t) = (1 + \cos t, \sin t),$$

它在 $t = \pi$ 通過原點。若離散節點包含 $t = \pi$ ，程式應丟出 `FloatingPointError`。節點沒有命中奇異點時，有限取樣仍可能漏掉問題。

解答 3

敘述為假。取

$$U = \mathbb{R}^2 \setminus \{(0, 0)\}, \quad \phi(x, y) = x^2 + y^2.$$

雖然 U 不是單連通，但

$$F = \nabla \phi = (2x, 2y)$$

在 U 上是保守場。因此單連通不是特定場保守的必要條件。

解答 4

令

$$P = \frac{x}{x^2 + y^2}, \quad Q = \frac{y}{x^2 + y^2}.$$

則

$$Q_x = -\frac{2xy}{(x^2 + y^2)^2}, \quad P_y = -\frac{2xy}{(x^2 + y^2)^2},$$

所以 $Q_x - P_y = 0$ 。可取勢函數

$$\phi(x, y) = \frac{1}{2} \log(x^2 + y^2),$$

因為

$$\nabla \phi = \left(\frac{x}{x^2 + y^2}, \frac{y}{x^2 + y^2} \right).$$

因此

$$\int_{\gamma} F \cdot dr = \phi(1, 1) - \phi(1, 0) = \frac{1}{2} \log 2.$$

右半平面是凸集，因而也是星形及單連通的開連通集合，所以無旋充分條件可以套用。不過本題已直接構造勢函數，不必把單連通誤當成必要條件。事實上，同一勢函數也可定義在整個穿孔平面上。

解答 5

前兩個小值不能證明保守性，因為只測試有限條閉路。至少還需知道：

- 求積方法及解析度；
- 解析度加密後的變化；
- 場值誤差與隨機噪聲尺度；
- 曲線是否完整位於定義域；
- 曲線取向與繞數；
- 是否靠近奇異點；
- 是否存在可獨立驗證的勢函數；
- 是否有嚴格誤差上界。

若能證明第三條合法閉路的真實積分非零，即可推出場不保守。僅憑三個近似值，尚不能嚴格證明保守或非保守；但 0.42 是重要的反證候選，不能在沒有誤差模型時任意歸為雜訊。

解答 6

1. 真。若 $\phi \in C^2$ ，連續混合偏導相等，所以 $\nabla\phi$ 無旋。
2. 假。穿孔平面渦旋場為 C^1 無旋場，卻有閉路積分 2π 。
3. 真。這是定理 22.4，並且題目已明定一般維度的無旋條件。
4. 假。 $\nabla(x^2 + y^2)$ 在穿孔平面上仍為保守場。
5. 假。單一閉路的近零數值只提供有限證據，且仍受離散與浮點誤差影響。

本章小結

向量場線積分把場值與曲線切向量配對，因此依賴向量場、曲線及取向。若 $F = \nabla\phi$ ，則

$$\int_{\gamma} F \cdot dr = \phi(\gamma(b)) - \phi(\gamma(a)).$$

在開且路徑連通的集合上，對連續向量場而言，存在勢函數、路徑獨立及所有閉路積分為零彼此等價。

若勢函數具有足夠正則性，保守場必定無旋。反方向則不是無條件成立：在開星形集，或開、連通且單連通的集合上， C^1 無旋場可由相應定理推出保守性。穿孔平面渦旋場顯示，局部旋度零可以與全域非零環流並存。

單連通是常用充分條件，不是特定向量場保守的必要條件。判斷時必須分清：

- 場的局部微分條件；

- 定義域的全域拓撲；
- 曲線的取向與繞數；
- 解析證明與有限數值證據。

數值閉路積分適合尋找反例、核對取向及診斷程式，但不能用有限採樣證明無限多條閉路的命題。

參考來源

1. Jiří Lebl, *Basic Analysis*, 作者教材入口：<https://www.jirka.org/ra/>
2. MIT OpenCourseWare, *18.100A Real Analysis*：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
3. MIT OpenCourseWare, *18.02SC Multivariable Calculus*：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

以上來源用於一般實分析、多變量微積分與向量場背景。線上內容及版本可能更新；本章定理應以本文明列的域、正則性與曲線條件為準。

第23章 散度、旋度與積分定理

學習目標與先備知識

本章把局部的散度、旋度，與整個區域及其邊界上的積分連起來。讀完後，應能判斷何時可用 Green、Gauss（散度）或 Stokes 定理；為外邊界、內孔與曲面邊界指定一致取向；並以解析計算及小型 CPU 程式核對面積積分與邊界通量。更重要的是，遇到看似相等的數值時，應能說明那是定理適用後的檢查，還是尚待查明條件的觀察。

先備知識包括偏導數、二重與曲面積分、參數化曲線、法向量，以及積分換變數。本章採右手 $X/Y/Z$ 座標。****定理給出連續區域上的等式；有限網格只提供數值證據，不是證明。***本章不建立守恆方程，也不求解偏微分方程，而是研究這些方程中常見的「區域內局部量」與「邊界收支」如何在數學上相接。

問題與直覺

設平面向量場 $F = (P, Q)$ 表示某量的通量密度。取一小塊區域，流出量減去流入量，由其邊界上的外向通量描述；把許多小塊拼起來，內部共用邊上的兩次通量方向相反，因而抵消，只剩整體邊界。散度

$$\operatorname{div} F = \partial_x P + \partial_y Q$$

描述此通量差除以面積後的局部極限。若散度在某處為正，可以直覺地想成附近小區域的淨外流為正；但它不表示場的每個分量都指向外面，也不表示任意大區域的每一段邊界通量均為正。

旋度回答另一種問題：場沿小閉路的切向環流有多少。在平面上，對逆時針小閉路，相關的標量是 $\partial_x Q - \partial_y P$ 。因此**環流與外向通量**是兩個不同的邊界積分；即使都能用 Green 定理計算，也不可混為一談。「內邊抵消」的拼圖直覺有助記憶積分定理，卻不能代替對區域形狀、場的正則性及邊界取向的檢查。尤其當拼圖中留有孔洞時，孔壁也是整個區域的邊界，不能在總和中遺漏。

定義、定理與推導

令 $D \subset \mathbb{R}^2$ 為有界區域，其邊界由有限條分段 C^1 簡單閉曲線構成，各條邊界互不相交。約定「正向」為沿邊界行走時，區域在左側：外邊界逆時針，孔的邊界順時針。若正向弧長參數的單位切向為 $t = (t_x, t_y)$ ，外單位法向便是 $n = (t_y, -t_x)$ 。這是將切向順時針旋轉直角所得；所謂「外」始終相對於目前積分的區域，而不是相對於座標原點。由 $dx = t_x ds$ 、 $dy = t_y ds$ ，得到

$$F \cdot n ds = P dy - Q dx, \quad F \cdot t ds = P dx + Q dy.$$

****Green 定理。***若 P, Q 在包含 $\overline{D}$ 的開鄰域內為 C^1 ，則

$$\oint_{\partial D}^+ (P dx + Q dy) = \iint_D (\partial_x Q - \partial_y P) dA, \quad (23.1)$$

$$\oint_{\partial D}^+ (P dy - Q dx) = \iint_D (\partial_x P + \partial_y Q) dA. \quad (23.2)$$

上標 + 指上述整體邊界取向，而不是每一條曲線都逆時針。式 (23.1) 是環流形式，式 (23.2) 是通量形式。兩式不是互不相關的口訣：對式 (23.1) 中的場以 $(-Q, P)$ 取代 (P, Q) ，其左側成為 $\oint_{\partial D}^+ (P dy - Q dx)$ ，右側成為 $\iint_D (\partial_x P + \partial_y Q) dA$ ，即式 (23.2)。這個代換也提醒我們先辨認所求積分是切向還是法向，再選公式。

以下完整證明一個範圍較小、但包含取向關鍵的小命題。

****小命題（矩形的通量等式）。****設 $a < b, c < d$ ， $R = [a, b] \times [c, d]$ ，且 P, Q 在包含 R 的開鄰域為 C^1 。則式 (23.2) 對 $D = R$ 成立。

****證明。***在右邊 $x = b$ ，外向單位法向為 $(1, 0)$ ，貢獻 $\int_c^d P(b, y) dy$ ；左邊 $x = a$ 的法向為 $(-1, 0)$ ，貢獻 $-\int_c^d P(a, y) dy$ 。上邊與下邊的貢獻分別是 $\int_a^b Q(x, d) dx$ 與 $-\int_a^b Q(x, c) dx$ 。故四邊總外向通量為

$$\int_c^d [P(b, y) - P(a, y)] dy + \int_a^b [Q(x, d) - Q(x, c)] dx. \quad (23.5)$$

對每個固定的 $y \in [c, d]$ ，一變量微積分基本定理給出

$$P(b, y) - P(a, y) = \int_a^b \partial_x P(x, y) dx.$$

同理，對每個固定的 $x \in [a, b]$ ，

$$Q(x, d) - Q(x, c) = \int_c^d \partial_y Q(x, y) dy.$$

將這兩式分別代入式 (23.5)。由於兩個偏導數在緊矩形上連續，其二重積分存在，而且可用迭代積分計算。因此第一項等於 $\iint_R \partial_x P dA$ ，第二項等於 $\iint_R \partial_y Q dA$ 。二者相加，恰為 $\iint_R \operatorname{div} F dA$ 。證畢。

若把矩形切成較小矩形，對每一塊套用小命題，再將等式相加，共用內邊的外法向相反，通量便精確抵消。這對**有限個矩形的合併**提供了直接論證輪廓。然而，一般曲線邊界不是有限條矩形邊；由矩形逼近任意合條件區域時，還必須控制逼近區域及邊界積分的極限。尤其有孔時，逼近後仍須保留內邊界。本章引用一般 Green 定理，不把拼圖直覺或有限網格當作完成了這一步的證明。

在三維，對 $F = (F_x, F_y, F_z)$ 定義

$$\nabla \cdot F = \partial_x F_x + \partial_y F_y + \partial_z F_z,$$

$$\nabla \times F = (\partial_y F_z - \partial_z F_y, \partial_z F_x - \partial_x F_z, \partial_x F_y - \partial_y F_x).$$

散度是標量，三維旋度是向量。兩者都由一階偏導組成，但分別進入不同的積分定理。

****Gauss 定理。**設 $\Omega \subset \mathbb{R}^3$ 為有界實體，邊界為有限片分段 C^1 曲面，且各片有一致的幾乎處處外法向；若 F 在包含 $\overline{\Omega}$ 的開鄰域為 C^1 ，則

$$\iiint_{\Omega} \nabla \cdot F \, dV = \iint_{\partial\Omega} F \cdot n_{\text{out}} \, dS. \quad (23.3)$$

若實體有空腔，「外」是相對於**實體**而言：空腔壁的法向指向空腔。邊、角處法向未必唯一，但不影響分片曲面積分。Gauss 定理中的邊界是封閉曲面；只積分其中幾片而不計其餘部分，一般不能等於整個實體的散度積分。

****Stokes 定理。**設 S 為緊緻、可取向的分段 C^2 曲面，邊界為分段 C^1 曲線； F 在包含 S 的開鄰域為 C^1 。選定曲面單位法向 n ，並以右手規則誘導 ∂S 的取向，則

$$\iint_S (\nabla \times F) \cdot n \, dS = \oint_{\partial S} F \cdot dr. \quad (23.4)$$

從所選法向一側觀看，正向邊界繞行時曲面位於左側。反轉法向，邊界取向也須反轉；只改一邊會改變等式的一側符號。若曲面有孔，其所有邊界分量均須按同一法向誘導取向。平面圓盤朝上時，外圈從上方看是逆時針；若該圓盤有內孔，內圈從上方看便是順時針。

Green、Gauss 與 Stokes 的上述一般形式都是**引用結果**，不是由矩形小命題直接推出。它們的共同結構是局部導數在區域內積分，等於相容取向下的邊界量；但積分所在的維度、幾何對象和適用條件不同。「有一致取向」及「場在包含積分區域的開鄰域具所需導數」是可用定理的充分條件，不應在沒有另行論證時省去。

逐步手算例題

****例一：有內孔的平面通量。**取環域 $D = \{(x, y) : 1 \leq x^2 + y^2 \leq 4\}$ ，令 $F = (x, y)$ 。此場在整個平面光滑，邊界也符合 Green 定理條件。散度為 2，環域面積是外圓盤面積減去內圓盤面積，故面積端為

$$\iint_D \operatorname{div} F \, dA = 2\pi(2^2 - 1^2) = 6\pi.$$

半徑為 r 的圓上， F 的徑向長度為 r ，周長為 $2\pi r$ 。外圓法向向外，貢獻 $2\pi(2)^2 = 8\pi$ ；內圓相對於環域的外法向指向圓心，貢獻 $-2\pi(1)^2 = -2\pi$ 。邊界總量為 6π ，與面積端相同。要注意負號並非內圈的場突然變成負值，而是**所積分區域的外法向**在內孔壁上改變方向。若把內圈也當成外圈般取向或取法向，就會錯得 4π 。

****例二：上向圓盤的 Stokes 等式。**取 $F = (-y/2, x/2, 0)$ ， S 是 $z = 0$ 、 $x^2 + y^2 \leq 4$ 的圓盤，指定法向 $n = (0, 0, 1)$ 。場光滑，圓盤可取向且邊界光滑。旋度為 $(0, 0, 1)$ ，曲面端是圓盤面積 4π 。邊界以 $r(t) = (2 \cos t, 2 \sin t, 0)$ 、 $0 \leq t \leq 2\pi$ 逆時針參數化。此時 $F(r(t)) = (-\sin t, \cos t, 0)$ ， $r'(t) =$

$(-2 \sin t, 2 \cos t, 0)$ ，內積恆為 2，故環流為 $\int_0^{2\pi} 2 \, dt = 4\pi$ 。若改選下向法向，須同時使邊界改為順時針；兩端才都成為 -4π 。

兩例各自核對的是一個明確選定的場與區域。計算相等可示範如何使用定理，卻不是從個別例子推得所有符合條件情形的證明。

實作與程式

下面只用 Python 標準庫，計算例一的兩種量。面積端在包住外圓的正方形上建立格網，以每格中點判斷是否位於環域；落在環域內才累加散度乘上格子面積。這是含有區域指示條件的中點求積，靠近圓形邊界的格子不會被精確切割。邊 endpoint 以等角度節點間的弦，以及弦中點的場值近似線積分。對正向圓周 $r(t) = (x(t), y(t))$ ，使用 $F \cdot n \, ds = P \, dy - Q \, dx$ 。程式對半徑與離散數量作輸入檢查，不讀取設備資料。

```
import math

def field(x, y):
    return x, y

def divergence(x, y):
    return 2.0

def midpoint_area(inner, outer, cells):
    step = 2.0 * outer / cells
    total = 0.0
    for j in range(cells):
        y = -outer + (j + 0.5) * step
        for i in range(cells):
            x = -outer + (i + 0.5) * step
            radius2 = x*x + y*y
            if inner*inner <= radius2 <= outer*outer:
                total += divergence(x, y) * step*step
    return total

def circle_flux(radius, segments, ccw):
    sign = 1.0 if ccw else -1.0
    total = 0.0
    for k in range(segments):
        t = sign * 2.0 * math.pi * k / segments
        u = sign * 2.0 * math.pi * (k + 1) / segments
        x0, y0 = radius*math.cos(t), radius*math.sin(t)
        x1, y1 = radius*math.cos(u), radius*math.sin(u)
        p, q = field((x0+x1)/2, (y0+y1)/2)
        total += p*(y1-y0) - q*(x1-x0)
    return total

def check(inner, outer, cells=200, segments=720):
    if (isinstance(inner, bool) or isinstance(outer, bool)
        or not isinstance(inner, (int, float))
        or not isinstance(outer, (int, float))
        or not math.isfinite(inner) or not math.isfinite(outer)
        or not 0 <= inner < outer):
        raise ValueError("半徑須為有限實數，且 0 <= inner < outer")
    if (isinstance(cells, bool) or isinstance(segments, bool))
```



```

        or not isinstance(cells, int) or not isinstance(segments, int)
        or cells <= 0 or segments < 3):
            raise ValueError("cells 須為正整數，segments 須為至少 3 的整數")
    area_side = midpoint_area(inner, outer, cells)
    boundary_side = circle_flux(outer, segments, True)
    if inner > 0:
        boundary_side += circle_flux(inner, segments, False)
    exact = 2.0*math.pi*(outer*outer-inner*inner)
    return area_side, boundary_side, exact

for radii in ((1.0, 2.0), (0.0, 2.0)):
    print(radii, check(*radii))

```

取外圈逆時針、內圈順時針，是使區域始終在行進方向左側的實作方式。格網索引 j 沿 $+Y$ 、 i 沿 $+X$ ；這裏沒有影像顯示，毋須另設影像原點。

還可對這個**特定場**解析檢查邊界近似。半徑為 r 的每一條逆時針弦，其弦中點代入 $F = (x, y)$ 後，對 $P \Delta y - Q \Delta x$ 的貢獻等於 $r^2 \sin(2\pi/N)$ ，其中 N 為弦數。因此程式對單一逆時針圓所得為 $Nr^2 \sin(2\pi/N)$ ，順時針則取負號；當 N 增加，此值趨向 $2\pi r^2$ 。這是利用指定圓及指定場作的解析檢查，不是任意場上的線積分誤差定理。面積端另受邊界格子分類影響，不能把邊界的性質直接套給它。

測試與預期結果

正常測試： `check(1.0, 2.0)` 的解析值為 $6\pi \approx 18.8496$ ；預期面積和邊界估計接近它，但兩者不必相等。增加格數可能改變哪些中點被列入環域，因此面積誤差不保證每次都單調下降。檢查時宜同時報告兩個近似值與解析值，而不只報告兩個近似值彼此之差：兩種錯誤也可能偶然抵消。

邊界測試： `check(0.0, 2.0)` 沒有內孔邊界，解析值為 8π ；程式不應額外扣除半徑零的圓。`check(1.0, 1.0)` 不符合此函式要求的非退化環域，應拋出 `ValueError`。這個輸入檢查是程式的設計選擇，不是說所有數學問題都不能研究退化集合。

故障測試：若把 `circle_flux(inner, segments, False)` 錯改為 `True`，例一邊界端預期靠近 10π ，而非 6π 。因為錯誤內圈貢獻會由 -2π 變成 $+2\pi$ ，這是內孔取向故障，不能以增加取樣點修復。以上均為解析推得的預期；本章未執行程式，也不宣稱量得實際誤差或收斂階。

反例與常見陷阱

第一，不能忽略場的定義域。在穿孔平面上令

$$F(x, y) = \left(\frac{-y}{x^2 + y^2}, \frac{x}{x^2 + y^2} \right).$$

於原點以外，其平面旋度 $\partial_x Q - \partial_y P = 0$ ；但沿逆時針單位圓的環流是 2π 。單位圓所圍的完整圓盤包含奇點，故不能在該圓盤上套用 Green 定理。若改用避開原點的環域，內邊界的環流恰好抵消外邊界，與零旋度並不衝突。這說明「旋度零」在任意定義域上不足以推出路徑獨立，也說明**檢查定理條件應針對所選的整塊區域，而非只檢查積分路徑上的場值**。

第二，邊界取向不是圖上的裝飾。Green 環流形式的內圈須順時針；通量形式亦須使用相對於區域的外法向。Stokes 的法向與邊界方向是一對選擇，沒有脫離法向而固定的「永遠逆時針」。若一條曲線同時可視為不同曲面的邊界，也必須先交代目前所選曲面及其法向，才談得上由它誘導的方向。

第三， $\nabla \cdot F$ 不等於 $\nabla \times F$ ，而通量積分也不等於環流積分。兩者可從不同方向觀察同一場，但單位和幾何意義可能不同。若場、曲面或邊界不具所述正則性，不能僅因數值答案接近便斷言定理適用；反過來，數值近似不完全相等，也不能直接宣告定理失效，應先排查離散誤差及取向實作。

AI、幾何與養殖案例

考慮一個**合成**的水平水域控制區 D ，以 SI 單位記錄平面位置 x, y (m)，並令深度整合後的水平輸運場 $F = (P, Q)$ ，各分量單位為 $\text{kg m}^{-1} \text{s}^{-1}$ 。此時 $\nabla \cdot F$ 的單位是 $\text{kg m}^{-2} \text{s}^{-1}$ ；面積積分與邊界外向通量的單位同為 kg s^{-1} 。這項單位核對是必要的基本檢查：如果一側用未經深度整合的量，另一側用深度整合的量，即使數字偶然接近，也不是同一物理量的比較。

若有島狀排除區，內孔邊界的外法向指向排除區，不能按地圖上「遠離中心」的印象決定。可用 Green 通量等式作幾何與資料處理的**一致性檢查**：對同一解析或充分平滑的插值場，分別估算面積端及全部邊界端，並記錄取向、單位、格網、邊界近似方式與誤差。若兩端不一致，可能原因包括漏算內孔、法向反轉、單位不符或不同插值場被用於兩側；不能只挑其中一項作無證據的結論。

這與守恆式中的邊界收支觀念相接，但積分定理本身不會證明量測場真實，也不在此建立或求解偏微分方程。有限且有雜訊的感測讀值通常不足以確認場在閉區域鄰域為 C^1 。唯讀 AI agent 可以整理所用資料、假設與不一致之處，不據此改設備、投餌或加藥；數學一致不等於現場操作安全。

習題

1. ****手算。**對矩形 $R = [0, 2] \times [0, 1]$ 與 $F = (x^2, 3y)$ ，分別算面積散度積分及四邊外向通量。
2. ****程式。**保持程式其他部分不變，為何把 `check(1.0, 2.0, cells=400, segments=1440)` 的輸出視為 Green 定理的證明是不成立的？指出兩個可觀察的近似來源。
3. ****反例。**對上文穿孔平面的場，計算半徑 $r > 0$ 的逆時針圓之環流，並指出不能對其完整圓盤直接使用 Green 定理的哪一項假設。
4. ****整合。**取立方體 $\Omega = [0, 1]^3$ 及 $F = (x, y, z)$ 。算 Gauss 定理兩側。若另從立方體內挖去一個半徑 $\rho < 1/2$ 、完全位於內部的球，球壁法向應指向何處？挖孔後兩側的值是多少？

習題解答

1. 散度為 $2x + 3$ ，故 $\int_0^1 \int_0^2 (2x + 3) dx dy = 10$ 。右邊 $x = 2$ 貢獻 4，左邊 $x = 0$ 貢獻 0；上邊 $y = 1$ 貢獻 $3 \cdot 2 = 6$ ，下邊 $y = 0$ 貢獻 0。總通量也是 10。這同時逐邊核對了矩形小命題的符號。
2. 面積端只測格子中點是否落在環域，故圓形邊界由有限格子近似；邊界端則以有限條弦及弦中點場值近似曲線積分。即使輸出非常接近解析值，也只核對該場與所選參數的有限計算，不能證明對所有合條件場及區域的無限命題。兩個近似的差值還可能含有相互抵消的誤差。

3. 設 $r(t) = (r \cos t, r \sin t)$ ，則 $F(r(t)) = (-\sin t/r, \cos t/r)$ 、 $r'(t) = (-r \sin t, r \cos t)$ ，內積為 1，環流為 2π 。場在圓盤中心未定義，更不可能在包含整個閉圓盤的開鄰域為 C^1 ；因此不能以該圓盤套用 Green 定理。
4. $\nabla \cdot F = 3$ ，體積端為 3。三個座標為 1 的外面各貢獻 1；座標為 0 的外面各貢獻 0，故邊界端也是 3。
 - 挖孔後球壁法向指向球心，即指向被移除的空腔。移除體積為 $4\pi\rho^3/3$ ，故散度積分變成 $3 - 4\pi\rho^3$
 - 球壁通量為 $-4\pi\rho^3$ ，加上原立方體外表面的 3，兩側一致。

本章小結

散度對應外向通量，旋度對應相容取向的環流。Green、Gauss 與 Stokes 定理把局部導數連到邊界積分；使用前必須核對場的正則性、區域及邊界條件，尤其要處理內孔、空腔與法向。矩形小命題展示了通量等式中微積分基本定理的作用，但一般彎曲區域的定理仍需其完整論證。手算可驗證具體等式，程式可檢查實作與近似誤差，兩者均不可取代一般定理的證明。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*, 作者教材入口：<https://www.jirka.org/ra/>
- [A2] MIT OCW, *18.100A Real Analysis*, 課程概要：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- [A3] MIT OCW, *18.02SC Multivariable Calculus*, 課程概要：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>

上述入口與課程概要供進一步核對分析及多變量微積分背景；此處不聲稱已逐條查證其完整教材內容。

第24章 函數列、一致收斂與極限交換

學習目標與先備知識

本章旨在建立函數列收斂的嚴格定義，闡述「逐點收斂」與「一致收斂」的本質差異，並探討在極限過程下交換積分與微分運算的充分條件。讀者需具備前幾章的微積分基礎，特別是連續性的 ϵ - δ 定義、Riemann 積分的性質以及單變量微分的基本定理。

學習目標包括：

1. 精確定義函數列的逐點收斂與一致收斂，理解量詞順序（ N 是否依賴於 x ）的數學意義。
2. 證明一致收斂下極限函數的連續性與可積性，並區分這些定理中「條件」與「結論」的角色。
3. 掌握函數列積分與微分運算交換的充分條件，特別是導數一致收斂的關鍵作用。
4. 運用 Weierstrass M-判準判斷級數的一致收斂性。
5. 處理參數積分與參數級數的微分問題，理解偏導數一致連續性在證明中的重要性。
6. 通過經典反例辨析「函數值一致收斂」但「導數行為病態」的現象，避免盲目交換極限與導數。

先備知識回顧：

- 實數序列極限的 ϵ - N 定義及其唯一性。
- Riemann 積分的線性性、單調性及收斂定理（可積函數的性質）。
- 單變量導數的定義，以及可微函數必連續的反事實直覺（連續不一定可微，可微一定連續）。
- 中值定理及其在估算函數變化量時的應用。

問題與直覺

在分析學中，極限操作是核心工具。當我們面對一個函數列 $f_n(x)$ 並取其極限 $f(x) = \lim_{n \rightarrow \infty} f_n(x)$ 時，一個自然的工程與數學問題是：我們能否對極限函數 f 進行積分或微分，並將其結果等同於對每個 f_n 進行相同操作後再取極限？即，以下等式是否普遍成立？

$$\int_a^b \left(\lim_{n \rightarrow \infty} f_n(x) \right) dx \stackrel{?}{=} \lim_{n \rightarrow \infty} \int_a^b f_n(x) dx \quad (1)$$

$$\frac{d}{dx} \left(\lim_{n \rightarrow \infty} f_n(x) \right) \stackrel{?}{=} \lim_{n \rightarrow \infty} \frac{d}{dx} f_n(x) \quad (2)$$

直覺上，如果 f_n 非常「平滑」且「穩定」地趨近於 f ，這些交換似乎應該成立。然而，「逐點收斂」僅僅保證了對每一個固定的 x ， $f_n(x)$ 都趨近於 $f(x)$ 。這是一種「點對點」的收斂行為，它無法控制整個區間 $[a, b]$ 上的誤差分布。如果收斂速度在區間不同位置變化極大（例如在端點附近收斂極慢），或者導數在極限過程中發生高頻振盪或突變，上述等式可能失效。

為了解決這個問題，我們需要一個更強的收斂概念——**一致收斂**。一致收斂要求 f_n 與 f 之間的距離在整個定義域內都能被統一控制，與具體的 x 無關。這種「全局」的收斂性為極限交換提供了必要的穩健性。本章將詳細展開這些概念，給出嚴格的定理、證明與反例，並明確指出有限數值計算只能作為驗證輔助，不能替代極限的邏輯證明。

定義、定理與推導

1. 逐點收斂與一致收斂

定義 24.1 (逐點收斂) 設 $D \subseteq \mathbb{R}$ ， $\{f_n\}_{n=1}^{\infty}$ 為定義在 D 上的實值函數列。若對任意 $x \in D$ ，存在極限 $f(x) = \lim_{n \rightarrow \infty} f_n(x)$ ，則稱 $\{f_n\}$ 在 D 上**逐點收斂**於 f 。

用 ϵ - N 語言描述： $\forall x \in D, \forall \epsilon > 0, \exists N \in \mathbb{N}$ (N 依賴於 x 和 ϵ)，使得 $\forall n \geq N$ ，有 $|f_n(x) - f(x)| < \epsilon$ 。

定義 24.2 (一致收斂) 若 $\forall \epsilon > 0, \exists N \in \mathbb{N}$ (N **不依賴於** x)，使得 $\forall n \geq N$ 及 $\forall x \in D$ ，有 $|f_n(x) - f(x)| < \epsilon$ ，則稱 $\{f_n\}$ 在 D 上**一致收斂**於 f 。

關鍵差異在於量詞順序。一致收斂是一種更強的條件，它確保了收斂的「均勻性」，即整個區間上的誤差同時趨近於零。

2. 一致收斂保持連續性

定理 24.3 (一致收斂保持連續性) 若每個 f_n 在區間 I 上連續，且 $\{f_n\}$ 在 I 上一致收斂於 f ，則 f 在 I 上連續。

證明： 設 $x_0 \in I$ 。我們需要證明 $\forall \epsilon > 0, \exists \delta > 0$ 使得 $\forall x \in I, |x - x_0| < \delta \implies |f(x) - f(x_0)| < \epsilon$ 。給定 $\epsilon > 0$ 。

- 由於 f_n 一致收斂於 f ，存在 N 使得 $\forall n \geq N$ 及 $\forall x \in I$ ，有 $|f_n(x) - f(x)| < \frac{\epsilon}{3}$ 。
- 固定某個 $n_0 \geq N$ 。由於 f_{n_0} 在 x_0 連續，存在 $\delta > 0$ 使得 $\forall x \in I, |x - x_0| < \delta \implies |f_{n_0}(x) - f_{n_0}(x_0)| < \frac{\epsilon}{3}$ 。
- 利用三角不等式：

$$\begin{aligned} |f(x) - f(x_0)| &\leq |f(x) - f_{n_0}(x)| + |f_{n_0}(x) - f_{n_0}(x_0)| + |f_{n_0}(x_0) - f(x_0)| \\ &< \frac{\epsilon}{3} + \frac{\epsilon}{3} + \frac{\epsilon}{3} = \epsilon \end{aligned}$$

因此 f 在 x_0 連續。由 x_0 的任意性， f 在 I 上連續。■

注意：逐點收斂於連續函數，不足以推出一致收斂。令 $f_1 = 0$ ；對 $n \geq 2$ ，在 $[0, 1]$ 上定義連續三角尖峰：

$$f_n(x) = \begin{cases} nx, & 0 \leq x \leq 1/n, \\ 2 - nx, & 1/n < x \leq 2/n, \\ 0, & 2/n < x \leq 1. \end{cases}$$

對固定 $x > 0$ ，當 $n > 2/x$ 時 $f_n(x) = 0$ ；而所有 $f_n(0) = 0$ 。故逐點極限是連續的零函數。然而對每個 $n \geq 2$ ， $f_n(1/n) = 1$ ，所以 $\sup_{x \in [0,1]} |f_n(x)| = 1$ ，並不一致收斂。

3. 積分交換與可積性

定理 24.4 (一致收斂的可積性與積分交換) 若每個 f_n 在 $[a, b]$ 上 Riemann 可積，且 $\{f_n\}$ 在 $[a, b]$ 上一致收斂於 f ，則：

1. f 在 $[a, b]$ 上 Riemann 可積。
2. $\lim_{n \rightarrow \infty} \int_a^b f_n(x) dx = \int_a^b f(x) dx$ 。

證明：

1. **可積性：** 設 $\epsilon > 0$ 。由一致收斂，存在 N 使得 $\forall n \geq N, \forall x \in [a, b], |f(x) - f_N(x)| < \frac{\epsilon}{4(b-a)}$ (若 $a = b$ ，結論平凡)。固定此 N 。由於 f_N Riemann 可積，存在分割 P 使得 $U(f_N, P) - L(f_N, P) < \frac{\epsilon}{2}$ 。對於同一分割 P ，由 $|f - f_N| < \frac{\epsilon}{4(b-a)}$ ，我們有：

$$U(f, P) \leq U(f_N, P) + \frac{\epsilon}{4}, \quad L(f, P) \geq L(f_N, P) - \frac{\epsilon}{4}$$

因此，

$$U(f, P) - L(f, P) \leq U(f_N, P) - L(f_N, P) + \frac{\epsilon}{2} < \frac{\epsilon}{2} + \frac{\epsilon}{2} = \epsilon$$

由 Riemann 可積的充要條件， f 可積。

2. **積分交換：** 考慮誤差 $E_n = \left| \int_a^b f_n(x) dx - \int_a^b f(x) dx \right|$ 。由積分的線性性與單調性：

$$E_n = \left| \int_a^b (f_n(x) - f(x)) dx \right| \leq \int_a^b |f_n(x) - f(x)| dx$$

由一致收斂定義，對任意 $\epsilon > 0$ ，存在 N 使得 $\forall n \geq N$ 及 $\forall x \in [a, b], |f_n(x) - f(x)| < \frac{\epsilon}{b-a}$ (假設 $a < b$)。因此，

$$E_n < \int_a^b \frac{\epsilon}{b-a} dx = \epsilon$$

故 $\lim_{n \rightarrow \infty} E_n = 0$ ，即極限可交換。■

4. 微分交換

定理 24.5 (微分交換) 設 $a < b$ ，且 $\{f_n\}$ 定義在 $[a, b]$ 上，滿足：

1. 每個 f_n 在 $[a, b]$ 上可微（在端點採單側導數），且 f'_n 在 $[a, b]$ 上連續。
2. f_n 在某一點 $c \in [a, b]$ 處收斂，即 $\lim_{n \rightarrow \infty} f_n(c) = L$ 存在。
3. f'_n 在 $[a, b]$ 上一致收斂於某連續函數 g 。

則：

1. $\{f_n\}$ 在 $[a, b]$ 上一致收斂於函數 $f(x) = L + \int_c^x g(t) dt$ 。
2. f 在 (a, b) 上可微，且 $f'(x) = g(x)$ 。

證明： 由微積分基本定理，對任意 $x \in [a, b]$ ：

$$f_n(x) = f_n(c) + \int_c^x f'_n(t) dt$$

定義 $f(x) := L + \int_c^x g(t) dt$ 。考慮誤差：

$$f_n(x) - f(x) = (f_n(c) - L) + \int_c^x (f'_n(t) - g(t)) dt$$

取 supremum：

$$\sup_{x \in [a, b]} |f_n(x) - f(x)| \leq |f_n(c) - L| + (b - a) \sup_{t \in [a, b]} |f'_n(t) - g(t)|$$

由條件 2， $|f_n(c) - L| \rightarrow 0$ 。由條件 3， $\sup_t |f'_n(t) - g(t)| \rightarrow 0$ 。故 $\sup_x |f_n(x) - f(x)| \rightarrow 0$ ，即 f_n 一致收斂於 f 。

又因為 g 是連續函數（一致收斂的連續函數列之極限，由定理 24.3），根據微積分基本定理的第二部分， $f(x) = L + \int_c^x g(t) dt$ 是可微函數，且 $f'(x) = g(x)$ 。■

直覺： 導數的一致收斂保證了「斜率」在全域穩定，結合一點的收斂，足以確定整個函數的值並保持可微性。若僅有逐點收斂，導數的高頻振盪可能在極限中消失或產生不連續性，導致微分交換失敗。

5. Weierstrass M-判準

定理 24.6 (Weierstrass M-Test) 設 $\sum_{n=1}^{\infty} f_n(x)$ 定義在集合 D 上。若存在正數序列 M_n 使得：

1. $|f_n(x)| \leq M_n$ 對所有 $x \in D$ 及所有 n 成立。
2. 數列級數 $\sum_{n=1}^{\infty} M_n$ 收斂。

則函數級數 $\sum_{n=1}^{\infty} f_n(x)$ 在 D 上一致收斂（且絕對收斂）。

證明： 令 $S_n(x) = \sum_{k=1}^n f_k(x)$ 。對 $m > n$ ，

$$\left| \sum_{k=n+1}^m f_k(x) \right| \leq \sum_{k=n+1}^m |f_k(x)| \leq \sum_{k=n+1}^m M_k$$

由於 $\sum M_n$ 收斂，其尾部 $\sum_{k=n+1}^m M_k$ 隨 $n, m \rightarrow \infty$ 而趨近於 0，且與 x 無關。因此 $\{S_n\}$ 滿足一致 Cauchy 條件，故一致收斂。■

6. 參數積分與級數的微分

函數級數逐項微分定理 設 $a < b$ 。若 $u_n \in C^1([a, b])$ ，某點 $c \in [a, b]$ 上的數值級數 $\sum_{n=1}^{\infty} u_n(c)$ 收斂，且導數級數 $\sum_{n=1}^{\infty} u'_n$ 在 $[a, b]$ 上一致收斂，則原級數在 $[a, b]$ 上一致收斂；其和函數 S 在 (a, b) 上可微，且

$$S'(x) = \sum_{n=1}^{\infty} u'_n(x).$$

證明：令部分和 $S_N = \sum_{n=1}^N u_n$ 。各 S_N 屬於 $C^1([a, b])$ ， $S_N(c)$ 收斂，而 $S'_N = \sum_{n=1}^N u'_n$ 一致收斂。對函數列 S_N 套用定理 24.5 即得結論。M-判準可用來驗證導數級數一致收斂，但它只是充分條件。僅有原級數一致收斂仍不足以逐項微分：在 $[0, \pi]$ 上，令 $u_1(x) = \sin x$ ，對 $n \geq 2$ 令 $u_n(x) = \sin(nx)/n - \sin((n-1)x)/(n-1)$ 。原級數的部分和為 $\sin(Nx)/N$ ，一致趨於零；導數級數的部分和為 $\cos(Nx)$ ，在 $x = \pi$ 等於 $(-1)^N$ ，故不收斂。

定理 24.7 (參數積分微分) 設 $f(x, t)$ 定義在矩形區域 $R = [a, b] \times [c, d]$ 上。若：

1. $f(x, t)$ 在 R 上連續。
2. $\frac{\partial f}{\partial t}(x, t)$ 在 R 上存在且連續。
3. $F(t) = \int_a^b f(x, t) dx$ 。

則 $F(t)$ 在 (c, d) 上可微，且

$$F'(t) = \int_a^b \frac{\partial f}{\partial t}(x, t) dx$$

(端點 c, d 處為單側導數)。

證明：考慮差商：

$$\frac{F(t+h) - F(t)}{h} = \frac{1}{h} \int_a^b [f(x, t+h) - f(x, t)] dx$$

由微積分基本定理（對變量 t ），對每個 x ，有

$$f(x, t+h) - f(x, t) = \int_t^{t+h} \frac{\partial f}{\partial t}(x, s) ds$$

代入差商：

$$\frac{F(t+h) - F(t)}{h} = \int_a^b \left(\frac{1}{h} \int_t^{t+h} \frac{\partial f}{\partial t}(x, s) ds \right) dx$$

定義 $g_h(x) = \frac{1}{h} \int_t^{t+h} \frac{\partial f}{\partial t}(x, s) ds$ 。我們證明 $g_h(x) \rightarrow \frac{\partial f}{\partial t}(x, t)$ 一致收斂。

$$\begin{aligned} \left| g_h(x) - \frac{\partial f}{\partial t}(x, t) \right| &= \left| \frac{1}{h} \int_t^{t+h} \left(\frac{\partial f}{\partial t}(x, s) - \frac{\partial f}{\partial t}(x, t) \right) ds \right| \\ &\leq \sup_{\substack{x \in [a, b] \\ s \text{ 介於 } t \text{ 與 } t+h \text{ 之間}}} \left| \frac{\partial f}{\partial t}(x, s) - \frac{\partial f}{\partial t}(x, t) \right| \end{aligned}$$

此處只取 $h \neq 0$ 且 $t+h \in [c, d]$ 的差商，因此上確界中的 s 均在定義域內。由於 $\frac{\partial f}{\partial t}$ 在緊集 R 上連續，故一致連續；當 $h \rightarrow 0$ 時，上述上確界趨近於 0。在 $t = c, d$ 處，分別只取域內的右側、左側極限。因此 $g_h(x) \rightarrow \frac{\partial f}{\partial t}(x, t)$ 一致收斂。由定理 24.4 的精神（一致收斂交換極限與積分），

$$\lim_{h \rightarrow 0} \frac{F(t+h) - F(t)}{h} = \int_a^b \lim_{h \rightarrow 0} g_h(x) dx = \int_a^b \frac{\partial f}{\partial t}(x, t) dx$$

故 $F'(t) = \int_a^b \frac{\partial f}{\partial t}(x, t) dx$ 。■

逐步手算例題

例 1： x^n 在 $[0, 1]$ 上的收斂行為與反例分析

考慮 $f_n(x) = x^n$ 在 $[0, 1]$ 上。

1. 逐點極限：

- 若 $x \in [0, 1)$ ， $\lim_{n \rightarrow \infty} x^n = 0$ 。
- 若 $x = 1$ ， $\lim_{n \rightarrow \infty} 1^n = 1$ 。
- 故極限函數 $f(x) = \begin{cases} 0, & 0 \leq x < 1 \\ 1, & x = 1 \end{cases}$ 。

2. 連續性： $f(x)$ 在 $x = 1$ 處不連續（左極限 0 不等於函數值 1）。

3. 收斂類型：

- 由於 $f_n(x)$ 連續但極限 $f(x)$ 不連續，由定理 24.3 的逆否命題可知， $\{f_n\}$ 在 $[0, 1]$ 上不一致收斂。
- 解析驗證：計算 supremum 誤差 $\sup_{x \in [0, 1]} |x^n - f(x)|$ 。
 - 當 $x < 1$ ， $f(x) = 0$ ，誤差為 x^n 。
 - 當 $x = 1$ ， $f(x) = 1$ ，誤差為 0。
 - $\sup_{x \in [0, 1)} x^n = 1$ （雖然取不到，但任意接近 1）。
 - 故 $\sup |f_n - f| = 1$ 對所有 n 成立，不隨 $n \rightarrow \infty$ 趨近於 0。

4. **結論：**逐點收斂不等於一致收斂。有限網格取樣會顯示錯誤在 x 接近 1 處很大，但這只是數值現象；嚴格證明依賴於 supremum 不趨零的分析。

例 2：一致小但導數不小的反例

考慮 $f_n(x) = \frac{\sin(nx)}{n}$ 在 $[0, \pi]$ 上。

1. 函數值收斂：

- $|f_n(x)| \leq \frac{1}{n}$ 。
- $\sup_{x \in [0, \pi]} |f_n(x) - 0| = \frac{1}{n} \rightarrow 0$ 。
- 故 f_n 一致收斂於零函數 $f(x) = 0$ 。

2. 導數行為：

- $f'_n(x) = \cos(nx)$ 。
- 極限函數 $f(x) = 0$ 的導數 $f'(x) = 0$ 。
- 檢查 f'_n 是否一致收斂於 f' ：
 - $\sup_{x \in [0, \pi]} |f'_n(x) - 0| = \sup_{x \in [0, \pi]} |\cos(nx)| = 1$ 。
 - 誤差恆為 1，不趨近於 0。
- 此外， f'_n 甚至不收斂（逐點）。例如在 $x = \pi$ ， $\cos(n\pi) = (-1)^n$ 振盪。

3. 微分交換測試：

- 左側： $\frac{d}{dx}(\lim f_n) = \frac{d}{dx}(0) = 0$ 。
- 右側： $\lim(\frac{d}{dx} f_n) = \lim(\cos(nx))$ 不存在。
- 等式 $0 \neq \text{DNE}$ 或更準確地說，右側極限不存在，故交換無效。

4. **教訓：**即使函數值一致收斂，若導數不一致收斂（或根本無界/振盪），不能交換微分與極限。定理 24.5 要求導數一致收斂，此處條件不滿足。

實作與程式

以下 Python 程式碼使用 NumPy 進行數值驗證與測試。程式包含正常、邊界與故障測試，並明確區分「數值觀察」與「理論證明」。所有輸出為預期結果，未經實際執行驗證。

```
import numpy as np

def check_uniform_convergence(f_n, f_limit, a, b, N_max=1000, samples=10000):
    """
    數值檢查一致收斂趨勢。
    返回 sup error 列表。
    """
    if N_max < 1 or samples < 2 or a > b:
        raise ValueError("Invalid parameters: N_max>=1, samples>=2, a<=b")

    x = np.linspace(a, b, samples)
    sup_errors = []
    for n in range(1, N_max + 1):
        fn_vals = f_n(n, x)
        f_vals = f_limit(x)
        if not np.all(np.isfinite(fn_vals)) or not np.all(np.isfinite(f_vals)):
```

```

        raise ValueError(f"Non-finite values detected at n={n}")
    diff = np.abs(fn_vals - f_vals)
    sup_err = np.max(diff)
    sup_errors.append(sup_err)
    return np.array(sup_errors)

def integrate_trapz(y, dx):
    if len(y) < 2:
        raise ValueError("Insufficient points for integration")
    return np.trapz(y, dx=dx)

# --- 測試案例 1: x^n on [0, 1] ---
def f_n_power(n, x):
    return x ** n

def f_limit_power(x):
    # x < 1 -> 0, x == 1 -> 1
    return np.where(x < 1.0 - 1e-15, 0.0, 1.0)

print("--- Test 1: x^n ---")
# 理論 Sup Error 應恆為 1 (接近)
# 數值檢查：取密網格
try:
    errors_pow = check_uniform_convergence(f_n_power, f_limit_power, 0.0, 1.0, N_max=100, samples=10000)
    print(f"Sup Error n=10: {errors_pow[9]:.6f}")
    print(f"Sup Error n=100: {errors_pow[99]:.6f}")
except ValueError as e:
    print(f"Error: {e}")

# --- 測試案例 2: sin(nx)/n on [0, pi] ---
def f_n_sin(n, x):
    return np.sin(n * x) / n

def f_limit_zero(x):
    return np.zeros_like(x)

def f_prime_sin(n, x):
    return np.cos(n * x)

print("--- Test 2: sin(nx)/n ---")
try:
    errors_sin = check_uniform_convergence(f_n_sin, f_limit_zero, 0.0, np.pi, N_max=100, samples=10000)
    print(f"Function Sup Error n=10: {errors_sin[9]:.6f}") # 預期 ~0.1
    print(f"Function Sup Error n=100: {errors_sin[99]:.6f}") # 預期 ~0.01
except ValueError as e:
    print(f"Error: {e}")

# 檢查導數 Sup Error
x_grid = np.linspace(0, np.pi, 10000)
dx = x_grid[1] - x_grid[0]
for n in [10, 100]:
    diff_prime = np.abs(f_prime_sin(n, x_grid) - 0)
    print(f"Derivative Sup Error n={n}: {np.max(diff_prime):.6f}") # 預期 ~1.0

# --- 測試案例 3: Integral Exchange ---
print("--- Test 3: Integral Exchange for sin(nx)/n ---")
# Limit integral is 0.
# Integral of f_n:
try:

```

```

    for n in [10, 100, 1000]:
        y = f_n_sin(n, x_grid)
        val = integrate_trapz(y, dx)
        print(f"Integral f_{n}: {val:.6f}")
except ValueError as e:
    print(f"Error: {e}")

# --- 故障與邊界測試 ---
print("---- Boundary & Fault Tests ----")

# 1. Invalid Range
try:
    check_uniform_convergence(f_n_power, f_limit_power, 1.0, 0.0, N_max=10, samples=10)
except ValueError as e:
    print(f"Caught Expected Error: {e}")

# 2. Non-finite inputs
def f_n_bad(n, x):
    return np.sin(n*x) / x # Division by zero at x=0
# 測試包含 x=0 的網格
x_zero = np.linspace(0.0, 1.0, 100)
try:
    check_uniform_convergence(f_n_bad, f_limit_zero, 0.0, 1.0, N_max=1, samples=100)
except (ValueError, ZeroDivisionError) as e:
    print(f"Caught Expected Error: {e}")

# 3. N=0 case
try:
    check_uniform_convergence(f_n_sin, f_limit_zero, 0.0, 1.0, N_max=0, samples=100)
except ValueError as e:
    print(f"Caught Expected Error: {e}")

# 4. Consistency Check: Uniform Convergence Implies Continuous Limit
# If we test a sequence that converges uniformly to a discontinuous function,
# the function itself must be discontinuous.
# We already showed x^n -> discontinuous f.
# If we take g_n(x) = x^2 + 1/n, it converges uniformly to x^2.
# x^2 is continuous.
def f_n_smooth(n, x):
    return x**2 + 1.0/n
def f_limit_smooth(x):
    return x**2

try:
    errors_smooth = check_uniform_convergence(f_n_smooth, f_limit_smooth, -1.0, 1.0, N_max=100, samples=1000)
    print(f"Smooth Converges Sup Error n=100: {errors_smooth[99]:.6f}") # Should be 0.01
except ValueError as e:
    print(f"Error: {e}")

```

測試與預期結果

1. x^n 測試：

- **輸出：**Sup Error 接近 1.0（例如 0.9999...）。
- **解釋：**數值結果顯示誤差不隨 n 顯著下降，與「不一致收斂」的理論預測一致。注意：有限網格無法證明 supremum 恆為 1，只能觀察到接近 1 的現象。嚴格證明需分析 $\sup_{x < 1} x^n = 1$ 。

2. $\sin(nx)/n$ 測試：

- 輸出：函數誤差隨 $1/n$ 下降 ($0.1 \rightarrow 0.01$)；導數誤差恆為 1.0。
- 解釋：確認函數一致收斂，但導數不收斂。

3. 積分交換測試：

- 輸出：積分值趨近於 0。
- 解釋：符合定理 24.4，因為函數一致收斂。

4. 故障測試：

- 非法區間 ($a > b$) 應觸發 `ValueError`。
- 包含零點的除零運算應觸發 `ValueError` 或 `ZeroDivisionError` (取決於 NumPy 版本與處理方式，程式中透過 `np.isfinite` 檢查)。
- $N = 0$ 應觸發 `ValueError`。

反例與常見陷阱

1. 連續性的陷阱：

- 反例： $f_n(x) = x^n$ 在 $[0, 1]$ 。逐點收斂於不連續函數。
- 陷阱：誤以為逐點收斂保持連續性。必須是一致收斂且原函數連續，才能保證極限函數連續。

2. 微分交換的陷阱：

- 反例： $f_n(x) = \frac{\sin(nx)}{n}$ 。函數一致收斂於 0，但導數 $\cos(nx)$ 不收斂。
- 陷阱：嘗試直接對 f_n 微分再取極限。必須驗證導數序列的一致收斂性 (定理 24.5 條件)。若僅知函數收斂，不可假設導數收斂。

3. M-判準的濫用：

- 反例：級數 $\sum \frac{x}{n^2+x^2}$ 在 $\mathbb{R}$ 上。
- 分析：對 $x \geq 0$ ，最大值在 $x = n$ ，值為 $\frac{1}{2n}$ 。故 $|f_n(x)| \leq \frac{1}{2n}$ 。 $\sum \frac{1}{2n}$ 發散。M-判準失敗。
- 陷阱：若誤找一個發散的 M_n ，可能錯誤認為收斂失敗，但其實可能逐點收斂。M-判準是充分非必要條件。找不到可和的 M_n 只代表此處 M-判準不能判定，並不單獨證明級數不一致收斂。

4. 參數積分的連續性：

- 陷阱：假設 $f(x, t)$ 連續則 $F(t)$ 必可微。必須檢查 $\frac{\partial f}{\partial t}$ 的存在與連續性 (定理 24.7)。若偏導數不連續，交換可能失敗。

AI、幾何與養殖案例

合成案例：感測數據平滑與極限

在養殖環境監控中，我們可能收錄一系列時間戳記的溫度感測數據 $T_n(x)$ ，其中 n 代表採樣頻率或過濾階數， x 代表時間。假設真實溫度曲線為 $T(x)$ 。

1. 模型：假設感測系統應用了低通濾波，使得 $T_n(x)$ 是 $T(x)$ 的平滑逼近。若濾波核寬隨 n 變小，且 $T(x)$ 滿足 Lipschitz 條件，則 $T_n(x)$ 可能一致收斂於 $T(x)$ 。

2. **應用**：我們需要計算總熱量累積 $E = \int T(x)dx$ 。若 $T_n \rightarrow T$ 一致收斂，則 $\lim \int T_n = \int T$ ，允許我們用離散採樣積分的極限來估算總熱量，且誤差可控。
3. **微分應用**：若我們需要估計溫度變化率 $T'(x)$ （例如檢測急速升溫預警），直接對平滑數據 T_n 微分可能放大噪聲。若 T'_n 不一致收斂於 T' （因為噪聲高頻分量），則直接微分無效。此時應使用專門的數值微分方案或先驗證收斂性。
4. **邊界狀況**：若感測器在特定時間點（如開門時）出現瞬時尖峰，導致 T_n 逐點收斂但導數行為病態，一致收斂假設可能在尖峰附近失效。需在該區域使用更細的網格或特殊處理。

AI 角度的觀察：在深度學習中，神經網絡的輸出可視為複雜的非線性函數列。訓練過程中的權重更新可看作函數列的演化。了解一致收斂有助於理解模型泛化能力：如果訓練集上的誤差一致小，則測試集誤差通常有界（需結構風險假設）。然而，過擬合通常表現為「逐點擬合完美但泛化差」，類似於不一致收斂的行為。

習題

1. **[手算]** 證明函數列 $f_n(x) = nx(1-x)^n$ 在 $[0, 1]$ 上逐點收斂於 0，但不一致收斂。
2. **[程式]** 編寫 Python 函數，檢查 $g_n(x) = \frac{x}{n+x}$ 在 $[0, 10]$ 上是否一致收斂於 0。計算 $n = 1, 10, 100, 1000$ 時的 supremum 誤差（解析值）。
3. **[反例/證明]** 證明：若每個 $h_n \in C^1([a, b])$ ， h'_n 一致收斂於 g ，且 h_n 在 $[a, b]$ 上逐點收斂，則 h_n 必一致收斂。導數連續確保下列 Riemann 積分表示成立。提示：利用微積分基本定理將 $h_n(x)$ 表示為 $h_n(a) + \int_a^x h'_n(t)dt$ 。
4. **[整合]** 設 $f(x, t) = \frac{t}{1+x^2t^2}$ 。求 $F(t) = \int_0^\infty f(x, t)dx$ 的顯式表達式，並驗證 $\frac{d}{dt} \int_0^\infty f dx = \int_0^\infty \frac{\partial f}{\partial t} dx$ 是否成立。討論 $t = 0$ 時的行為。

習題解答

1. 解答：

- **逐點**：若 $x \in (0, 1)$ ， $\lim_{n \rightarrow \infty} nx(1-x)^n = 0$ （指數衰減快於線性增長）。若 $x = 0$ 或 $x = 1$ ， $f_n(0) = 0, f_n(1) = 0$ 。故逐點收斂於 0。
- **不一致**：求 $f_n(x)$ 的最大值。 $f'_n(x) = n(1-x)^{n-1}(1-(n+1)x)$ 。極值點在 $x = \frac{1}{n+1}$ 。
- $f_n(\frac{1}{n+1}) = \frac{n}{n+1}(\frac{n}{n+1})^n \rightarrow e^{-1}$ 。
- 因此 $\sup |f_n(x) - 0| \geq f_n(\frac{1}{n+1}) \rightarrow e^{-1} \neq 0$ 。故不一致收斂。

2. 解答：

- $g_n(x) = \frac{x}{n+x}$ 。極限 $g(x) = 0$ 。
- $|g_n(x) - 0| = \frac{x}{n+x}$ 。對 $x \in [0, 10]$ 單調遞增。
- $\sup_{x \in [0, 10]} \frac{x}{n+x} = \frac{10}{n+10}$ 。
- $n = 1 : 10/11 \approx 0.909$ 。
- $n = 10 : 10/20 = 0.5$ 。
- $n = 100 : 10/110 \approx 0.091$ 。

- $n = 1000 : 10/1010 \approx 0.010$ 。
- 誤差趨近於 0，故一致收斂。

3. 解答：

- 對任意 $x \in [a, b]$ ， $h_n(x) = h_n(a) + \int_a^x h'_n(t) dt$ 。
- $h_n(x) - h_m(x) = (h_n(a) - h_m(a)) + \int_a^x (h'_n(t) - h'_m(t)) dt$ 。
- 對每個 x 估計，再取上確界：

$$\sup_{x \in [a, b]} |h_n(x) - h_m(x)| \leq |h_n(a) - h_m(a)| + \sup_{x \in [a, b]} \left| \int_a^x (h'_n(t) - h'_m(t)) dt \right|$$

$$\sup_{x \in [a, b]} \left| \int_a^x (h'_n(t) - h'_m(t)) dt \right| \leq (b - a) \sup_{t \in [a, b]} |h'_n(t) - h'_m(t)|.$$

- 因為 h_n 逐點收斂， $h_n(a)$ 收斂，故為 Cauchy 序列。
- 因為 h'_n 一致收斂， h'_n 為一致 Cauchy 序列， $\sup_t |h'_n - h'_m| \rightarrow 0$ 。
- 故 $\sup_x |h_n - h_m| \rightarrow 0$ ，即 h_n 一致收斂。

4. 解答：

- $F(t) = \int_0^\infty \frac{t}{1+x^2 t^2} dx$ 。
- 情形 $t > 0$ ：令 $u = xt, du = t dx \implies dx = du/t$ 。 $F(t) = \int_0^\infty \frac{t}{1+u^2} \frac{du}{t} = \int_0^\infty \frac{du}{1+u^2} = [\arctan u]_0^\infty = \frac{\pi}{2}$ 。
- 情形 $t = 0$ ： $f(x, 0) = 0$ ，故 $F(0) = 0$ 。
- 情形 $t < 0$ ：令 $u = xt$ 。當 $x: 0 \rightarrow \infty$ ， $u: 0 \rightarrow -\infty$ （因為 $t < 0$ ）。 $dx = du/t$ 。 $F(t) = \int_0^{-\infty} \frac{t}{1+u^2} \frac{du}{t} = \int_0^{-\infty} \frac{du}{1+u^2} = -\int_{-\infty}^0 \frac{du}{1+u^2} = -[\arctan u]_{-\infty}^0 = -(0 - (-\frac{\pi}{2})) = -\frac{\pi}{2}$ 。
- 故 $F(t) = \operatorname{sgn}(t) \frac{\pi}{2}$ （對 $t \neq 0$ ）， $F(0) = 0$ 。
- 導數驗證：對 $t \neq 0$ ， $F(t)$ 為常數，故 $F'(t) = 0$ 。右側： $\frac{\partial f}{\partial t} = \frac{1-x^2 t^2}{(1+x^2 t^2)^2}$ 。 $\int_0^\infty \frac{1-x^2 t^2}{(1+x^2 t^2)^2} dx$ 。令 $u = xt$ ， $dx = du/t$ 。積分變為 $\frac{1}{|t|} \int_0^\infty \frac{1-u^2}{(1+u^2)^2} du$ （注意 dx 的符號，若 $t > 0$ ， du 正向；若 $t < 0$ ， du 負向，但積分變量 x 從 0 到 ∞ ， u 從 0 到 $\pm\infty$ ）。更嚴謹地， $\int_0^\infty \frac{1-(xt)^2}{(1+(xt)^2)^2} dx = \frac{1}{|t|} \int_0^\infty \frac{1-u^2}{(1+u^2)^2} du$ 。原函數 $\frac{u}{1+u^2}$ 的導數是 $\frac{1-u^2}{(1+u^2)^2}$ 。 $\int_0^\infty (\frac{u}{1+u^2})' du = [\frac{u}{1+u^2}]_0^\infty = 0$ 。故右側積分為 0。因此，對 $t \neq 0$ ， $F'(t) = \int \partial_t f = 0$ 。
- $t = 0$ 行為：左側 $F'(0)$ 不存在（ F 在 0 不連續）。右側 $\int_0^\infty \partial_t f(x, 0) dx = \int_0^\infty 1 dx = \infty$ 。兩側均無定義或發散，交換失敗。
- 註：定理 24.7 適用於緊矩形 $[a, b] \times [c, d]$ 。本題是無界區間 $[0, \infty)$ 上的瑕積分，不能直接套用該定理，需額外證明一致收斂性或收斂性條件。

本章小結

本章建立了函數列收斂的嚴格框架，區分了逐點收斂與一致收斂。我們證明了：

1. 一致收斂是保持連續性的充分條件（若原函數連續）。

2. 一致收斂允許在極限過程下交換積分運算，並保證極限函數可積。
3. 微分交換需要導數序列的一致收斂及原函數列在某點收斂。
4. Weierstrass M-判準是判斷級數一致收斂的有力工具。
5. 參數積分的微分公式依賴於偏導數的連續性及一致連續性。

通過具體例子（如 x^n 和 $\sin(nx)/n$ ），我們展示了違反這些條件時極限交換的失敗案例。這些概念是分析學的核心，廣泛應用於積分方程、微分方程及數值分析中。數值計算可作為驗證工具，但不能替代基於 ϵ - N 邏輯的嚴格證明。

參考來源

1. Lebl, J. *Basic Analysis*. (A1)
2. MIT OpenCourseWare, 18.100A Real Analysis. (A2)
3. MIT OpenCourseWare, 18.02SC Multivariable Calculus. (A3)
4. JAX Autodiff Cookbook. (A4)
5. SciPy Documentation. (A5, A6)

第25章 線性微分方程與矩陣指數

學習目標與先備知識

本章研究常係數線性系統

$$x'(t) = Ax(t), \quad x(0) = x_0,$$

其中 $x(t) \in \mathbb{R}^n$ 、 $A \in \mathbb{R}^{n \times n}$ 、 $x_0 \in \mathbb{R}^n$ 。我們將從矩陣指數得到解

$$x(t) = e^{tA}x_0,$$

並以此辨析線性系統的連續時間穩定性、離散時間穩定性，以及非正規矩陣可能造成的暫態放大。

讀者應熟悉矩陣乘法、特徵值與特徵向量、常微分方程的導數，以及基本無窮級數。這裡的結論主要在有限維實或複向量空間中討論；若矩陣含複數特徵值，計算可在 $\mathbb{C}^n$ 進行，再利用共軛對稱得到實解。

完成本章後，讀者應能：

1. 由冪級數定義矩陣指數，並說明它為何收斂。
2. 用矩陣指數表示初值問題的解，並理解解的唯一性。
3. 以 Jordan 分解處理不可對角化的矩陣。
4. 區分特徵值漸近穩定與有限時間暫態大小。
5. 判斷前向 Euler 離散格式的穩定限制，並理解連續穩定不保證任意步長的離散穩定。

本章會使用有限矩陣計算作為檢查工具，但有限次數值運算只能檢查特定輸入與特定精度下的結果，不能代替收斂、唯一性或穩定性的證明。

問題與直覺

考慮兩個互相耦合的狀態變數，例如兩個混合槽中的濃度偏差，或線性化模型中的兩個感測量。若其變化率與當前狀態成線性關係，便可寫成 $x' = Ax$ 。矩陣 A 的特徵值描述某些特殊方向上的指數增長或衰減；但當矩陣不可對角化，或特徵向量彼此不正交時，單看特徵值可能不足以預測短時間內狀態的大小。

基本直覺是：純量方程 $y' = ay$ 的解為 $y(t) = e^{ta}y(0)$ 。矩陣方程也要有一個「指數」，能同時作用於所有方向；這就是 e^{tA} 。若 A 可對角化，矩陣指數在特徵向量座標下只需對各特徵值取純量指數。若 A 有 Jordan 區塊，則還會出現多項式因子，例如 $te^{\lambda t}$ 。

穩定性需先說清楚所指的概念。對平衡解 $x = 0$ ，若每個初值解都滿足 $x(t) \rightarrow 0$ ($t \rightarrow \infty$)，稱原點漸近穩定。若只問某一段有限時間內解是否會放大，則是暫態問題。兩者不是同一件事：即使所有特徵值實部為負，非正規矩陣的解也可能先增大再衰減。

定義、定理與推導

矩陣指數

對任意方陣 $B \in \mathbb{C}^{n \times n}$ ，定義

$$e^B = \sum_{k=0}^{\infty} \frac{B^k}{k!}, \quad B^0 = I.$$

對矩陣使用任一誘導算子範數，滿足 $\|BC\| \leq \|B\|\|C\|$ 。因此

$$\left\| \frac{B^k}{k!} \right\| \leq \frac{\|B\|^k}{k!}.$$

右側純量級數對所有有限的 $\|B\|$ 絕對收斂，所以矩陣級數絕對收斂。這不依賴對角化，也適用於 Jordan 矩陣與不可對角化矩陣。

對固定矩陣 A ，映射 $t \mapsto e^{tA}$ 在每個有界時間區間上可逐項微分，得到

$$\frac{d}{dt} e^{tA} = A e^{tA} = e^{tA} A.$$

此處的逐項微分依據是冪級數在每個有限半徑內一致收斂；等價地，微分後的級數仍被純量指數級數一致控制。

初值問題解與唯一性

定理。 對任何 $A \in \mathbb{R}^{n \times n}$ 與 $x_0 \in \mathbb{R}^n$ ，初值問題

$$x' = Ax, \quad x(0) = x_0$$

在所有實數時間上有唯一解 $x(t) = e^{tA} x_0$ 。

證明。 由前述微分公式，

$$\frac{d}{dt} (e^{tA} x_0) = A e^{tA} x_0,$$

而 $e^{0A} = I$ ，所以此函數確為解。

再設 x_1, x_2 是同一初值問題的兩個可微解，令 $z = x_1 - x_2$ ，則 $z' = Az$ 且 $z(0) = 0$ 。考慮

$$w(t) = e^{-tA} z(t).$$

因為 A 與 e^{-tA} 可交換，乘積微分給出

$$w'(t) = -Ae^{-tA}z(t) + e^{-tA}Az(t) = 0.$$

故 $w(t)$ 為常向量；由 $w(0) = 0$ 得 $w(t) = 0$ 。又 $e^{-tA}e^{tA} = I$ ，所以 $z(t) = 0$ 。因此解唯一。證畢。

這個證明也說明矩陣指數提供基本解矩陣。對任意起始時間 s ，解為 $x(t) = e^{(t-s)A}x(s)$ ，並有半群關係

$$e^{(t+s)A} = e^{tA}e^{sA}.$$

對角化與 Jordan 區塊

若 $A = PDP^{-1}$ ，其中 $D = \text{diag}(\lambda_1, \dots, \lambda_n)$ ，則

$$e^{tA} = Pe^{tD}P^{-1}, \quad e^{tD} = \text{diag}(e^{t\lambda_1}, \dots, e^{t\lambda_n}).$$

這來自冪次相似變換 $A^k = PD^kP^{-1}$ ，逐項代入級數即可。

若矩陣不可對角化，Jordan 分解在複數域仍可寫成 $A = PJP^{-1}$ 。對一個 Jordan 區塊 $J = \lambda I + N$ ，其中 $N^r = 0$ ，

$$e^{tJ} = e^{\lambda t}e^{tN} = e^{\lambda t} \sum_{k=0}^{r-1} \frac{t^k N^k}{k!}.$$

因為 λI 與 N 可交換，指數可拆成乘積；而 N 的冪在 r 次後為零，所以第二個指數級數實際上是有限和。這表示 Jordan 區塊的解項可含 $t^k e^{\lambda t}$ ，不能只用特徵值的純量指數形式描述所有分量。

連續時間漸近穩定

對有限維常係數系統 $x' = Ax$ ，原點漸近穩定的充要條件是 A 的所有特徵值實部嚴格小於零。

必要性可由複特徵向量看出：若 $Av = \lambda v$ 且 $\text{Re } \lambda \geq 0$ ，則複數解 $e^{\lambda t}v$ 不趨近零；取其實部或虛部，可得到非趨零的實解。充分性則由 Jordan 形式得出：每個分量都是有限和的 $t^k e^{\lambda t}$ ，當 $\text{Re } \lambda < 0$ 時，這些項均趨近零。因此所有解都趨向零。這個判準是長時間漸近穩定判準，並未提供所有時間上 $\|e^{tA}\|$ 都小於一的結論。

非正規暫態與離散穩定

若 A 是實對稱矩陣，特徵向量可取正交，模態不會因高度非正交的座標變換而大幅混合。一般非正規矩陣則可能有 $\|e^{tA}\| > 1$ ，即使所有特徵值實部為負。譜描述的是長時間的指數率；有限時間的放大還受特徵向量幾何與矩陣非正規性影響。

前向 Euler 格式以

$$x_{k+1} = x_k + hAx_k = (I + hA)x_k$$

近似連續系統，其中 $h > 0$ 為步長。離散系統漸近穩定的條件是 $I + hA$ 的所有特徵值模長小於一。若 λ 是 A 的特徵值，對應的 Euler 放大因子為 $1 + h\lambda$ 。因此連續穩定要求 $\operatorname{Re} \lambda < 0$ ，但 Euler 穩定另要求

$$|1 + h\lambda| < 1$$

對每個特徵值成立。前者不會對任意大的 h 自動保證後者。

逐步手算例題

例一：可對角化矩陣指數

令

$$A = \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix}.$$

取 $v_1 = (1, 0)^T$ 與 $v_2 = (1, 1)^T$ ，分別對應特徵值 1 與 2。故

$$P = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}, \quad P^{-1} = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix}, \quad e^{tA} = P \begin{pmatrix} e^t & 0 \\ 0 & e^{2t} \end{pmatrix} P^{-1}.$$

先左乘得 $\begin{pmatrix} e^t & e^{2t} \\ 0 & e^{2t} \end{pmatrix}$ ，再右乘，得到

$$e^{tA} = \begin{pmatrix} e^t & e^{2t} - e^t \\ 0 & e^{2t} \end{pmatrix}.$$

例如 $x_0 = (0, 1)^T$ 時，解為

$$x(t) = \begin{pmatrix} e^{2t} - e^t \\ e^{2t} \end{pmatrix}.$$

在 $t = 0$ ，解為 $(0, 1)^T$ ；其導數為 $(1, 2)^T = A(0, 1)^T$ ，符合方程。

例二：不可對角化與 Jordan 區塊

令

$$J = \begin{pmatrix} -1 & 1 \\ 0 & -1 \end{pmatrix} = -I + N, \quad N = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}, \quad N^2 = 0.$$

所以

$$e^{tJ} = e^{-t} \begin{pmatrix} 1 & t \\ 0 & 1 \end{pmatrix}.$$

對 $x_0 = (0, 1)^T$ ，解為 $x(t) = e^{-t}(t, 1)^T$ 。其中第一分量先由零增大，再趨近零。其初始導數為

$$Jx_0 = (1, -1)^T,$$

而從解式微分，在 $t = 0$ 也得 $(1, -1)^T$ 。這是特徵值只有 -1 ，卻仍有非平凡暫態變化的簡例。

例三：前向 Euler 的步長限制

對純量方程 $x' = -x$ ，連續解為 $x(t) = e^{-t}x_0$ ，故趨近零。Euler 格式則給

$$x_{k+1} = (1 - h)x_k, \quad x_k = (1 - h)^k x_0.$$

離散解趨近零當且僅當 $|1 - h| < 1$ ，也就是 $0 < h < 2$ 。例如 $h = 3$ 時，放大因子為 -2 ，解會交替變號且幅度增加。連續系統穩定，並不等於任意 Euler 步長都穩定。

實作與程式

以下程式只使用 Python 標準庫，採用縮放冪級數近似矩陣指數。此實作以無窮範數估計大小，將輸入縮小後累加 Taylor 項，再利用 $e^B = (e^{B/2})^2$ 重複平方。它適合小型教學矩陣，不是取代成熟數值函式庫的通用高效演算法。

程式未在本章撰寫時執行；以下數值屬預期結果，須以讀者環境實際執行核對。若可選裝 SciPy，可另外以 `scipy.linalg.expm` 對照；本章不要求 SciPy，也不假設該套件存在。

```
from math import ceil, exp, factorial, log2

def matmul(a, b):
    rows, inner, cols = len(a), len(b), len(b[0])
    if len(a[0]) != inner:
        raise ValueError("矩陣維度不相容")
    return [
        [
            sum(a[i][k] * b[k][j] for k in range(inner))
            for j in range(cols)
        ]
        for i in range(rows)
    ]

def add(a, b):
    if len(a) != len(b) or any(len(x) != len(y) for x, y in zip(a, b)):
        raise ValueError("矩陣形狀不同")
    return [[x + y for x, y in zip(rx, ry)] for rx, ry in zip(a, b)]

def scale(c, a):
    return [[c * x for x in row] for row in a]
```

```

def identity(n):
    return [[1.0 if i == j else 0.0 for j in range(n)] for i in range(n)]

def norm_inf(a):
    return max(sum(abs(x) for x in row) for row in a)

def expm_taylor(a, tol=1e-14):
    """以縮放冪級數計算小型方陣的矩陣指數。"""
    n = len(a)
    if n == 0 or any(len(row) != n for row in a):
        raise ValueError("輸入必須是非空方陣")
    if tol <= 0.0:
        raise ValueError("tol 必須為正")
    magnitude = norm_inf(a)
    squarings = max(0, ceil(log2(magnitude))) if magnitude > 1.0 else 0
    b = scale(2.0 ** (-squarings), a)

    total = identity(n)
    term = identity(n)
    for k in range(1, 1000):
        term = scale(1.0 / k, matmul(term, b))
        total = add(total, term)
        if norm_inf(term) <= tol * max(1.0, norm_inf(total)):
            break
    else:
        raise ArithmeticError("級數未在限定項數內達到停止條件")

    for _ in range(squarings):
        total = matmul(total, total)
    return total

def euler_scalar(rate, step, count, initial):
    """計算  $x' = \text{rate} \cdot x$  的前向 Euler 終值及步進因子。"""
    if step <= 0.0 or count < 0:
        raise ValueError("步長須為正，步數須非負")
    factor = 1.0 + step * rate
    return initial * (factor ** count), factor

if __name__ == "__main__":
    j = [[-1.0, 1.0], [0.0, -1.0]]
    result = expm_taylor([0.5 * x for x in row] for row in j)
    expected = [[exp(-0.5), 0.5 * exp(-0.5)],
                [0.0, exp(-0.5)]]
    error = max(
        abs(result[i][k] - expected[i][k])
        for i in range(2) for k in range(2)
    )
    print("e^(0.5J) =", result)
    print("與 Jordan 解析式的最大分量差 =", error)
    print("Euler h=1.5:", euler_scalar(-1.0, 1.5, 6, 1.0))
    print("Euler h=3:", euler_scalar(-1.0, 3.0, 6, 1.0))

```

停止條件是以末項相對於部分和的大小作實用估計，並非對所有浮點輸入都提供嚴格的後向誤差保證。範圍估計與縮放可改善一般情形，但浮點捨入、極端尺度及接近溢位仍可能影響結果；正式計算應使用經分析與測試的矩陣指數演算法。

測試與預期結果

以下測試列出應檢查的性質，並非已執行結果。程式先驗算公式和數值差異；讀者實際執行後，應將印出的差異與自身平台精度一併解讀。

正常測試。 對 $J = \begin{pmatrix} -1 & 1 \\ 0 & -1 \end{pmatrix}$ 與 $t = 0.5$ ，解析式為

$$e^{0.5J} = e^{-0.5} \begin{pmatrix} 1 & 0.5 \\ 0 & 1 \end{pmatrix}.$$

預期程式所得各元素接近此值，最大分量差遠小於 10^{-10} 。

半群測試。 同一矩陣應滿足 $e^{(0.2+0.3)J} = e^{0.2J}e^{0.3J}$ 。這可以改成兩次呼叫程式後比較兩邊的分量差。浮點比較應用容許誤差，不應要求位元完全相同。半群恆等式的數值吻合是實作檢查，不是其數學證明。

邊界測試。 零矩陣的矩陣指數應為單位矩陣； $t = 0$ 時 $e^{tA} = I$ ；對角矩陣的結果應逐元素等於各對角元素的純量指數。空矩陣、非方陣或非正容許誤差應引發 `ValueError`。

故障與模型測試。 對 $x' = -x$ ，Euler 的 $h = 1.5$ 放大因子為 -0.5 ，六步後結果應為 $(-0.5)^6$ ； $h = 3$ 的因子為 -2 ，六步後結果為 $(-2)^6$ ，顯示離散不穩定。若把程式輸入改為形狀不相容的矩陣乘法，應收到維度錯誤，而非靜默產生錯誤結果。對非正規矩陣，還應比較解析解與程式結果；單看最後時間值不能排除中間時刻曾有暫態放大。

反例與常見陷阱

1. 把特徵值實部為負誤解為所有時刻都衰減。對

$$A = \begin{pmatrix} -1 & K \\ 0 & -1 \end{pmatrix}, \quad e^{tA} = e^{-t} \begin{pmatrix} 1 & Kt \\ 0 & 1 \end{pmatrix},$$

特徵值都為 -1 ，所以解漸近趨零。然而 $|K|te^{-t}$ 可在有限時間顯著大於初始尺度。特徵值判準說明長時間是否趨零，不是每一瞬間是否縮小。

2. 把不同範數的大小混為一談。矩陣指數的算子範數取決於向量範數；即使不同有限維範數彼此等價，等價常數也會影響定量化上界。若要報告增益，應明確說明使用的範數。
3. 把連續穩定推成任意步長 Euler 穩定。純量 $x' = -x$ 已提供反例：連續解指數衰減，而 Euler 只在 $0 < h < 2$ 時穩定。

4. 以有限時間取樣證明沒有暫態放大。一組離散取樣點只能描述那些時刻；兩個取樣點之間的矩陣範數可能較大。要證明整段時間的上界，必須有解析估計或可驗證的連續上界。
5. 將 Jordan 形式當成數值演算法。Jordan 分解在理論推導中清楚，但對接近缺陷的矩陣，特徵向量計算可能非常敏感。大型或病態問題不宜僅依據手算的相似變換判定數值精度。

AI、幾何與養殖案例

在合成養殖模型中，令 $x(t)$ 表示兩個水槽的溶氧濃度相對設定值的偏差，單位均為毫克／公升， t 以小時計。線性化後可用 $x' = Ax$ 表示短時間內偏差的動態。此時 A 的每個元素單位為每小時，因為濃度偏差的導數除以濃度偏差後，時間單位相消為小時的倒數。

例如

$$A = \begin{pmatrix} -1 & K \\ 0 & -1 \end{pmatrix} \text{ 小時}^{-1}$$

是合成數學例，不代表特定設備、實際水槽或經驗校準。括號內的 K 是無因次的非零耦合數值；矩陣外已統一乘上每小時，因此實際的右上元素為 $K \text{ 小時}^{-1}$ ，不可再把 K 本身標為每小時。矩陣指數 e^{tA} 無因次，將初始濃度偏差映射到同一單位的後續偏差。若兩個狀態分量改用不同單位或不同尺度，直接採用未加權的 Euclidean 長度比較狀態大小，未必有物理意義；應先說明尺度，或改用有明確單位依據的加權度量。

分析型 AI 助手可協助整理 A 、初始狀態、時間範圍、單位、解析推導與數值檢查，並提醒哪些說法是定理、哪些只是有限次計算的證據。它不應把合成參數說成現場測量結果，也不應以矩陣穩定性替代對水質、感測器、操作條件或生物安全的現場驗證。AI 與模型在此只作唯讀分析，不控制設備、不調整投餌或加藥。

習題

1. 手算：Jordan 區塊

令

$$A = \begin{pmatrix} -2 & 3 \\ 0 & -2 \end{pmatrix}.$$

(1)

2. 手算與離散穩定

對 $x' = -4x$ ，求前向 Euler 的穩定步長範圍。再計算 $h = 0.3$ 時的放大因子，並說明此步長是否穩定。

3. 程式：半群與解析核對

使用本章程式，取

$$B = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}.$$

計算 $e^{0.2B}e^{0.3B}$ 與 $e^{0.5B}$ ，比較兩者。先用手算給出精確結果，再說明浮點結果應如何判讀。不得以數值吻合取代半群恆等式的證明。

4. 反例：連續與離散概念

對 $x' = -x$ ：(1) 證明連續系統漸近穩定；(2) 證明 Euler 在 $h = 2$ 時不漸近穩定；(3) 解釋為什麼「特徵值實部為負」不足以保證給定離散方法在任意步長下穩定。

5. 整合：非正規暫態

令

$$A = \begin{pmatrix} -1 & 10 \\ 0 & -1 \end{pmatrix}, \quad x_0 = (0, 1)^T.$$

(1)

習題解答

1. 解答

寫成 $A = -2I + N$ ，其中 $N = \begin{pmatrix} 0 & 3 \\ 0 & 0 \end{pmatrix}$ 且 $N^2 = 0$ 。因此

$$e^{tA} = e^{-2t}(I + tN) = e^{-2t} \begin{pmatrix} 1 & 3t \\ 0 & 1 \end{pmatrix}.$$

所以

$$x(t) = e^{-2t} \begin{pmatrix} 1 + 3t \\ 1 \end{pmatrix}.$$

唯一特徵值為 -2 ，實部嚴格為負，故依有限維常係數線性系統的特徵值判準，原點漸近穩定。

2. 解答

Euler 放大因子為 $1 - 4h$ ，漸近穩定需要

$$|1 - 4h| < 1.$$

解得 $0 < h < \frac{1}{2}$ 。若 $h = 0.3$ ，放大因子為 $1 - 1.2 = -0.2$ ，模長為 $0.2 < 1$ ，所以離散解交替變號但幅度漸近趨零。

3. 解答

因 $B^2 = 0$ ，

$$e^{tB} = I + tB = \begin{pmatrix} 1 & t \\ 0 & 1 \end{pmatrix}.$$

手算可得

$$e^{0.2B}e^{0.3B} = \begin{pmatrix} 1 & 0.2 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0.3 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0.5 \\ 0 & 1 \end{pmatrix} = e^{0.5B}.$$

程式輸出應與此結果在浮點容許誤差內相符。誤差非零不代表半群定理失效；它通常反映浮點運算的有限精度。數學恆等式仍由矩陣指數級數與矩陣乘法的性質證明，不能只靠這一組計算確立。

4. 解答

連續解為 $x(t) = e^{-t}x_0$ ，當 $t \rightarrow \infty$ 時趨於零，故連續系統漸近穩定。Euler 格式在 $h = 2$ 時放大因子為 $1 - 2 = -1$ ，所以 $x_k = (-1)^k x_0$ ；若 $x_0 \neq 0$ ，其幅度不趨於零，故離散系統不漸近穩定。連續判準描述微分方程本身，而 Euler 的離散穩定還須檢查數值放大因子 $|1 + h\lambda|$ ；步長會改變該因子。

5. 解答

這裡 $A = -I + N$ ，其中 $N = \begin{pmatrix} 0 & 10 \\ 0 & 0 \end{pmatrix}$ 且 $N^2 = 0$ ，故

$$e^{tA} = e^{-t} \begin{pmatrix} 1 & 10t \\ 0 & 1 \end{pmatrix}, \quad x(t) = e^{-t} \begin{pmatrix} 10t \\ 1 \end{pmatrix}.$$

第一分量為 $f(t) = 10te^{-t}$ 。微分得 $f'(t) = 10e^{-t}(1 - t)$ ，因此唯一正時間臨界點為 $t = 1$ 小時；在 $0 < t < 1$ 遞增，在 $t > 1$ 遞減，最大值為 $f(1) = 10/e$ 。然而兩個分量仍在 $t \rightarrow \infty$ 時趨近零，故系統漸近穩定。最大值 $10/e$ 顯示特定初始狀態可先有有限時間放大；穩定判準不等於暫態從不放大。

本章小結

矩陣指數由絕對收斂的冪級數定義，適用於可對角化與不可對角化的有限方陣。常係數初值問題的唯一解為 $e^{tA}x_0$ ；Jordan 區塊會帶來多項式乘上指數的解項。對有限維線性系統，原點漸近穩定當且僅當所有特徵值實部為負，但這不排除非正規矩陣在有限時間內造成暫態放大。

數值時間步進有自己的穩定條件。前向 Euler 要求每個離散放大因子 $|1 + h\lambda| < 1$ ；連續系統漸近穩定，不能推出任意步長的 Euler 近似穩定。解析推導提供定理保證，程式測試則協助檢查計算；兩者應明確區分。

參考來源

以下為概念延伸來源；本章未宣稱逐條核對這些網站上的所有教材內容。

- A1. Jiří Lebl, *Basic Analysis*，作者教材入口：<https://www.jirka.org/ra/>
- A2. MIT OpenCourseWare, *18.100A Real Analysis*：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- A5. SciPy 文件，`scipy.linalg.expm`：
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>

第26章 非線性ODE、固定點與局部存在唯一

學習目標與先備知識

本章把第 25 章的矩陣指數與線性 ODE 推進到非線性初值問題

$$y'(t) = f(t, y(t)), \quad y(t_0) = y_0, \quad (26.1)$$

其中 $f : D \subseteq \mathbb{R} \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ 。目標有四：(i) 用度量完備性陳述並證明 Banach 壓縮映射定理；(ii) 用它推出 Picard–Lindelöf 局部存在唯一性；(iii) 分清「局部」、「唯一」與「延拓到最大存在區間」三個層次，並能指出 Lipschitz 條件是不可省的；(iv) 用 Picard 迭代實作並分辨「有限步數值試算」與「無限維不動點證明」的界線。

先備知識為第 12–17 章的 Fréchet 導數與 Jacobian、Jacobian 的行空間 (column space) 與 Lipschitz 估計、第 25 章的線性 ODE 與矩陣指數、以及第 5 章的緊緻性與完備性。本章只處理有限維 ODE，不涉及泛函分析中更一般的半群理論。

問題與直覺

對線性系統 $y' = Ay$ ，第 25 章已能寫出 $y(t) = e^{(t-t_0)A}y_0$ 並在全實軸上成立。非線性情形立刻變複雜： $y' = y^2$, $y(0) = 1$ 的解是

$$y(t) = \frac{1}{1-t},$$

只在 $t < 1$ 上有定義， $t \rightarrow 1^-$ 時從有限初值出發卻發散到無窮——這叫**有限時間爆破**(finite-time blow-up)。因此「存在」與「唯一」必須附上區間，不可能奢望全域結論。

同時直覺常會誤導：「 f 連續就應該有解」。這在局部確實對 (Peano 存在定理)，但唯一性會失效。典型的

$$y' = \sqrt{|y|}, \quad y(0) = 0 \quad (26.2)$$

至少包含恆為零與 $y(t) = t^2/4$ ($t \geq 0$) 兩個解。造成分歧的關鍵是 $\sqrt{|y|}$ 在 $y = 0$ 附近雖然連續，卻**不是 Lipschitz** 的。Picard–Lindelöf 的價值就在於：加一個 Lipschitz 條件後，經由 Banach 壓縮映射定理，把「有解」與「唯一」一次講清。而壓縮映射定理本身要在完備度量空間上運作，這是為什麼本章必須先修妥完備性的使用條件，而不能用「迭代看起來收斂」代替證明。

定義、定理與推導

定義 26.1 (Lipschitz 條件) 設 $D \subseteq \mathbb{R} \times \mathbb{R}^n$ 為開集、 $f : D \rightarrow \mathbb{R}^n$ 。若存在常數 $L \geq 0$ ，使得對所有 $(t, y_1), (t, y_2) \in D$ ，

$$\|f(t, y_1) - f(t, y_2)\| \leq L\|y_1 - y_2\|, \quad (26.3)$$

稱 f 在 D 上對 y **Lipschitz 連續** (y -Lipschitz), L 稱為 Lipschitz 常數。注意條件只限制 y 方向, t 方向僅要求連續。

定義 26.1' (局部 Lipschitz) 若對每個 $(t_0, y_0) \in D$ 都存在鄰域 $U \subseteq D$ 與常數 L_U , 使得 (26.3) 在 U 上成立, 則稱 f 在 D 上**局部 y -Lipschitz**。局部 Lipschitz 比全域 Lipschitz 弱: $y' = y^2$ 的 $f(t, y) = y^2$ 在 $\mathbb{R}^2$ 上並非全域 Lipschitz, 但在任何 (t_0, y_0) 的緊鄰域上由中值定理與 $\partial_y f = 2y$ 的連續性可得局部 Lipschitz。由於定理 26.4 只需在閉矩形 R 上 Lipschitz, 局部 Lipschitz 已足以支撐局部存在唯一; 這也說明「 L 全域有界」的要求是可放寬的。反之, $y' = \sqrt{|y|}$ 在 $y = 0$ 的任何鄰域上都不是 Lipschitz。

定義 26.2 (壓縮映射) 設 (X, d) 為度量空間、 $T: X \rightarrow X$ 。若存在 q 滿足 $0 \leq q < 1$ 使得對所有 $x, y \in X$

$$d(Tx, Ty) \leq q d(x, y), \quad (26.4)$$

則稱 T 為**壓縮映射**。 $q < 1$ 為本質條件; $q = 1$ 只給 Lipschitz 連續性, 未必有固定點。

命題 26.3 (Banach 壓縮映射定理) 設 (X, d) 為完備度量空間, $T: X \rightarrow X$ 為壓縮映射, 壓縮比為 $q \in [0, 1)$ 。則 T 有**唯一**不動點 $x^* \in X$; 且對任意 $x_0 \in X$, 迭代 $x_{k+1} = Tx_k$ 收斂到 x^* , 並有先驗誤差界

$$d(x_k, x^*) \leq \frac{q^k}{1-q} d(x_1, x_0). \quad (26.5)$$

證明. 先證唯一性。設 $x^*, y^* \in X$ 為不動點, 則

$$d(x^*, y^*) = d(Tx^*, Ty^*) \leq q d(x^*, y^*),$$

移項得 $(1-q)d(x^*, y^*) \leq 0$ 。因 $q < 1$, 故 $d(x^*, y^*) = 0$, 即 $x^* = y^*$ 。

再證存在性。對任意 $k \geq 1$,

$$d(x_{k+1}, x_k) = d(Tx_k, Tx_{k-1}) \leq q d(x_k, x_{k-1}) \leq \cdots \leq q^k d(x_1, x_0).$$

對 $n < m$, 用三角不等式與等比數列求和:

$$d(x_m, x_n) \leq \sum_{k=n}^{m-1} d(x_{k+1}, x_k) \leq \sum_{k=n}^{m-1} q^k d(x_1, x_0) \leq \frac{q^n}{1-q} d(x_1, x_0).$$

因 $0 \leq q < 1$, 右端當 $n \rightarrow \infty$ 時趨於零, 故 (x_k) 為 Cauchy 列。由 (X, d) 完備, 存在 $x^* \in X$ 使 $x_k \rightarrow x^*$ 。壓縮映射必 Lipschitz 連續, 因而連續; 於是

$$x^* = \lim_{k \rightarrow \infty} x_{k+1} = \lim_{k \rightarrow \infty} Tx_k = T\left(\lim_{k \rightarrow \infty} x_k\right) = Tx^*,$$

即 x^* 為不動點。最後，對固定的 n 讓 $m \rightarrow \infty$ ，由三角不等式即得 (26.5)。□

直覺. 壓縮一次，最壞誤差至少縮小一個 $q < 1$ 的倍率；反覆應用後誤差幾何式遞減，於是在完備空間中必有極限。若缺完備性（例如取 $X = \mathbb{Q} \cap [1, 2]$ 配通常距離， $T(x) = (x + 2/x)/2$ 想求 $\sqrt{2}$ ；在此區間上 $T'(x) = 1/2 - 1/x^2$ 於 $x = 1$ 取得最小值 $-1/2$ 、於 $x = 2$ 取得最大值 $1/4$ ，故 $|T'| \leq 1/2$ ， T 是 X 上的壓縮映射；又 $T([1, 2]) \subseteq [1, 2]$ ，迭代卻收斂到不屬於 X 的 $\sqrt{2}$ ，極限就可能跳出 X ，這正是完備性不可省的原因。

定理 26.4 (Picard–Lindelöf 局部存在唯一) 設 $D \subseteq \mathbb{R} \times \mathbb{R}^n$ 為開集， $(t_0, y_0) \in D$ ， $f : D \rightarrow \mathbb{R}^n$ 連續且對 y 在 D 上 y -Lipschitz（常數 L ）。取 $a, b > 0$ 使閉矩形

$$R := [t_0 - a, t_0 + a] \times \overline{B(y_0, b)} \subseteq D, \quad M := \sup_{(t,y) \in R} \|f(t, y)\|.$$

定義

$$\alpha := \begin{cases} \min\left(a, \frac{b}{M}, \frac{1}{2L}\right), & M > 0, L > 0, \\ \min\left(a, \frac{b}{M}\right), & M > 0, L = 0, \\ a, & M = 0. \end{cases} \quad (26.6)$$

則在閉區間 $I_\alpha := [t_0 - \alpha, t_0 + \alpha]$ 上，初值問題 (26.1) 恰有一個 C^1 解 $y : I_\alpha \rightarrow \overline{B(y_0, b)}$ 。

證明. 關鍵是： $y \in C^1(I_\alpha)$ 解 (26.1) 當且僅當 $y \in C^0(I_\alpha)$ 且滿足積分方程

$$y(t) = y_0 + \int_{t_0}^t f(s, y(s)) ds, \quad t \in I_\alpha. \quad (26.7)$$

（由微積分基本定理：若 $y \in C^1$ 解 ODE，積分兩端即得；反之 (26.7) 右端可微，微分後回到 ODE。）因此只需在完備空間上找不動點。

令

$$X := \{y \in C^0(I_\alpha, \mathbb{R}^n) : \|y(t) - y_0\| \leq b \forall t \in I_\alpha\}, \quad d(y, z) := \|y - z\|_\infty.$$

X 是完備度量空間中 $\overline{B(y_0, b)}$ 值連續函數的閉子集——統一收斂極限仍連續、仍落在閉球內——故 (X, d) 完備。定義 Picard 算子

$$(Ty)(t) := y_0 + \int_{t_0}^t f(s, y(s)) ds.$$

(a) T 映 X 到 X . 對 $y \in X$ 、 $t \in I_\alpha$ ，

$$\|(Ty)(t) - y_0\| \leq \left| \int_{t_0}^t \|f(s, y(s))\| ds \right| \leq M|t - t_0| \leq M\alpha \leq b,$$

最後一步用到 $\alpha \leq b/M$ ($M > 0$ 時)； $M = 0$ 時左端恆為 0，也落在閉球內。

(b) T 為壓縮. 對 $y, z \in X$,

$$\|(Ty)(t) - (Tz)(t)\| \leq \left| \int_{t_0}^t \|f(s, y(s)) - f(s, z(s))\| ds \right| \leq L|t - t_0| \|y - z\|_\infty \leq L\alpha \|y - z\|_\infty.$$

若 $L = 0$ ， f 關於 y 恆定， T 是常值映射，可直接由 (26.7) 得唯一解 $y(t) = y_0 + \int_{t_0}^t f(s) ds$ 。以下設 $L > 0$ 。由 (26.6) 的定義， $M = 0$ 時 f 在 R 上恆為零， T 為常值映射，壓縮比可取 0； $M > 0$ 時 $\alpha \leq 1/(2L)$ ，所以 $q = L\alpha \leq 1/2 < 1$ 。因此 T 在以 α 定義的 X 上是壓縮。

(c) 完備性與不動點. 由 (a)、(b) 與命題 26.3， X 上存在唯一不動點 y^* 使 $Ty^* = y^*$ ，即 (26.7) 成立。由微積分基本定理， $y^* \in C^1(I_\alpha)$ 且解 (26.1)。

(d) 局部唯一性. 設 $\tilde{y} \in C^1(I_\alpha, \overline{B(y_0, b)})$ 亦解 (26.1)，則 $\tilde{y}$ 也落在 X 中（由 $\|\tilde{y}(t) - y_0\| \leq M|t - t_0| \leq b$ ）並滿足 (26.7)，故 $\tilde{y}$ 是 T 在 X 中的不動點；由 X 中不動點唯一性， $\tilde{y} = y^*$ 。□

評註 26.5. 定理 26.4 有下列結構特徵值得明示在下游使用：

1. **局部性**： α 依賴 a, b, M, L ，可能遠小於原域 D 的尺度。存在性只在 I_α 上保證。
2. **充分而非必要**：Lipschitz 條件對存在唯一是**充分條件**。例如 $y' = -y^{1/3}$ 在 $y = 0$ 附近非 Lipschitz，但其原點初值問題仍唯一；故不能倒過來宣稱「唯一必 Lipschitz」。至於唯一的非 Lipschitz 情形之一般判定，另有 Osgood 條件等工具，本章不展開。
3. **解延拓**：若把 D 取為對 y 的整個 $\mathbb{R}^n$ 、 t 上任何開區間，解可在一片一片矩形上接續，得到**極大存在區間** (T_-, T_+) 。若有限的 T_+ 仍位於右端函數定義的時間開區間內，則必有 $\|y(t)\| \rightarrow \infty$ 當 $t \rightarrow T_+^-$ ；若只是到達時間定義域的邊界，則不能推出爆破（有限時間爆破，見例 26.7）。
4. **解的連續依賴（Grönwall 型估計）**：若 $y(t)$ 與 $z(t)$ 分別是初值 y_0, z_0 在 $[t_0, T]$ 上的兩個解， $T - t_0 \leq \alpha$ ，則由 (26.7) 相減、取範數，

$$\|y(t) - z(t)\| \leq \|y_0 - z_0\| + L \left| \int_{t_0}^t \|y(s) - z(s)\| ds \right|.$$

對 $g(t) := \|y(t) - z(t)\|$ 應用 Grönwall 引理，得

$$\|y(t) - z(t)\| \leq \|y_0 - z_0\| e^{L|t-t_0|}, \quad t \in I_\alpha. \quad (26.8)$$

這是 Lipschitz 條件的下游紅利：初值擾動被 $e^{L\alpha}$ 放大，而不是被無界放大。第 27 章討論 Lyapunov 穩定時再次使用。

逐步手算例題

例 26.6（線性：Picard 迭代即泰勒部分和） 取 $y' = y$ ， $y(0) = 1$ ， $n = 1$ ， $t_0 = 0$ ， $y_0 = 1$ 。在 $R = [-a, a] \times \overline{B(1, b)}$ 上 $L = 1$ 、 $M = 1 + b$ 。逐步迭代：

$$y_0(t) \equiv 1, \quad y_1(t) = 1 + \int_0^t y_0 = 1 + t, \quad y_2(t) = 1 + \int_0^t (1 + s) ds = 1 + t + \frac{t^2}{2}, \quad y_k(t) = \sum_{j=0}^k \frac{t^j}{j!}.$$

取 $a = b = 1$, $L = 1$, $\alpha = \min(1, 1/(1+b), 1/(2L)) = \min(1, 1/2, 1/2) = 1/2$ 。定理保證在 $[-1/2, 1/2]$ 上局部唯一解存在，且 Picard 迭代在一致範數下收斂到 e^t 。這裡定理只給到 $1/2$ ，但解析上 e^t 在全實軸有意義——這說明定理區間常比真實可延拓區間小，屬允許的保守估計。

例 26.7 (有限時間爆破： $y' = y^2$) 取 $y(0) = 1$, $f(t, y) = y^2$, L 非全域有界 ($y \mapsto y^2$ 在 $\mathbb{R}$ 上非 Lipschitz)。在 $R = [-a, a] \times [1-b, 1+b]$ 上 $L = 2(1+b)$, $M = (1+b)^2$, $\alpha = \min(a, b/M, 1/(2L))$ 。
 取 $a = 1, b = 1/2$ 得 $M = (3/2)^2 = 9/4$, $b/M = (1/2)/(9/4) = 2/9$, $L = 3$, $1/(2L) = 1/6$, 故 $\alpha = \min(1, 2/9, 1/6) = 1/6$ 。定理保證 $[0, 1/6]$ 上局部解存在唯一，實際解析解為

$$y(t) = \frac{1}{1-t}, \quad t < 1,$$

而 $t \rightarrow 1^-$ 時 $y(t) \rightarrow +\infty$ ，在 $t = 1$ 處有限時間爆破，無法延拓過去。注意解在有界時間內仍趨無窮，這說明延拓到全域極限而非必然全域。

例 26.8 (非 Lipschitz 的非唯一) 對 (26.2) 的 $f(t, y) = \sqrt{|y|}$ ，取 $y_0 = 0$ 。 f 在 $(0, 0)$ 附近對 y 不是 Lipschitz：若 $y_1 = \varepsilon > 0$, $y_2 = 0$ ，

$$\frac{|f(t, y_1) - f(t, y_2)|}{|y_1 - y_2|} = \frac{\sqrt{\varepsilon}}{\varepsilon} = \frac{1}{\sqrt{\varepsilon}} \rightarrow \infty \quad (\varepsilon \rightarrow 0^+).$$

定理 26.4 的 Lipschitz 前提不成立，而解的**非唯一**恰好發生： $y \equiv 0$ 與 $y(t) = t^2/4$ ($t \geq 0$) 皆滿足 $y(0) = 0$ 、 $y' = |t|/2 = \sqrt{t^2/4}$ 。這也從側面說明 Lipschitz 條件不可省。

例 26.9 (二維：手算局部 Lipschitz 常數) 考慮捕食-被捕食型合成模型

$$y_1' = -y_1 + y_1 y_2, \quad y_2' = y_2 - y_1 y_2,$$

$(y_1(0), y_2(0)) = (1, 2)$, $t_0 = 0$ 。取 $b = 1$, $R = [-a, a] \times \overline{B((1, 2), 1)}$ 。在 R 上 $\|y_1\| \leq 2$ 、 $\|y_2\| \leq 3$ 。Jacobian

$$J_f(y) = \begin{pmatrix} -1 + y_2 & y_1 \\ -y_2 & 1 - y_1 \end{pmatrix},$$

算子 $\|J_f(y)\|_2 \leq \sqrt{2^2 + 2^2 + 3^2 + 2^2} = \sqrt{21} \approx 4.58$ (粗略上界)，故 L 可取 $\sqrt{21}$ 。又 $\|f\| \leq \|y_1\| + \|y_1\|\|y_2\| + \|y_2\| + \|y_1\|\|y_2\| \leq 2 + 6 + 3 + 6 = 17$, M 取 17。此自治多項式系統的時間域為整個實軸，可明確選 $a = 1$ 。於是 $\alpha = \min(1, 1/17, 1/(2\sqrt{21})) = 1/17$ ，定理保證在 $[-1/17, 1/17]$ 上局部唯一解存在。 $1/17 \approx 0.0588235$ ，不能以向上四捨五入的 0.059 代替保證半徑；若另取較小的 a ，必須重新取三者最小值。這個例子提醒： L, M 取越保守， α 越小；實務計算可用更緊的界改善。

實作與程式

以下自足使用 NumPy 標準 CPU，提供本章後續測試所需的基礎函式：解 $y' = y$ 的 Picard 迭代、解純量與向量 ODE 的 RK4 步進，以及三個待測右端函數 f_{sqr} 、 f_{sq} 、 f_{lv} 。實際的呼叫、結果比較、非有限值監測與失敗點記錄須由讀者依下節測試清單自行加入；本節不宣稱已完成這些檢查。

```
import numpy as np

def picard_linear(t_grid, n_iter):
    """解  $y'=y$ ,  $y(0)=1$ 。第  $k$  次 Picard 迭代 = 次數為  $k$  的 Taylor 多項式。"""
    t = np.asarray(t_grid, dtype=float)
    y = np.ones_like(t)
    term = np.ones_like(t)
    for k in range(1, n_iter + 1):
        term = term * t / k
        y = y + term
    return y

def rk4_scalar(f, t0, y0, t_end, h):
    """一維純量 RK4，回傳  $t$  與  $y$  的陣列。"""
    n_steps = int(np.ceil((t_end - t0) / h))
    t = np.empty(n_steps + 1)
    y = np.empty(n_steps + 1)
    t[0] = t0
    y[0] = y0
    for k in range(n_steps):
        hh = min(h, t_end - t[k])
        tk, yk = t[k], y[k]
        k1 = f(tk, yk)
        k2 = f(tk + hh / 2, yk + hh / 2 * k1)
        k3 = f(tk + hh / 2, yk + hh / 2 * k2)
        k4 = f(tk + hh, yk + hh * k3)
        t[k + 1] = tk + hh
        y[k + 1] = yk + hh / 6 * (k1 + 2 * k2 + 2 * k3 + k4)
        if not np.isfinite(y[k + 1]):
            raise FloatingPointError(f"在  $t=\{t[k+1]:.6g\}$  出現非有限值")
    return t, y

def rk4_system(f, t0, y0, t_end, h):
    """ $y_0$  為 shape (n,) 的 column 向量存為 1-D array；回傳軌跡 (m, n)。"""
    y0 = np.asarray(y0, dtype=float)
    n_steps = int(np.ceil((t_end - t0) / h))
    ts = np.empty(n_steps + 1)
    ys = np.empty((n_steps + 1, y0.size))
    ts[0] = t0
    ys[0] = y0
    for k in range(n_steps):
        hh = min(h, t_end - ts[k])
        tk, yk = ts[k], ys[k]
        k1 = f(tk, yk)
        k2 = f(tk + hh / 2, yk + hh / 2 * k1)
        k3 = f(tk + hh / 2, yk + hh / 2 * k2)
        k4 = f(tk + hh, yk + hh * k3)
        ts[k + 1] = tk + hh
        ys[k + 1] = yk + hh / 6 * (k1 + 2 * k2 + 2 * k3 + k4)
        if not np.all(np.isfinite(ys[k + 1])):
```

```

        raise FloatingPointError(f"在 t={ts[k+1]:.6g} 出現非有限值")
    return ts, ys

f_sqrt = lambda t, y: np.sqrt(abs(y))
f_sq    = lambda t, y: y ** 2
f_lv    = lambda t, y: np.array([-y[0] + y[0] * y[1], y[1] - y[0] * y[1]])

```

步長選擇的說明. 對 $y' = y$ 這類光滑問題，RK4 的局部截斷誤差為 $O(h^5)$ ，全域誤差 $O(h^4)$ ；不能只憑 $h = 10^{-3}$ 就宣稱達到雙精度極限；須對照解析解、步長折半及捨入誤差的實際紀錄。對爆破型問題，固定步長會在 T_+ 前後失效： y 進入爆炸區時殘差爆增， $y[k+1]$ 可能變成 `inf`。處理原則：(1) 監測 `np.isfinite(ys[k+1]).all()`，一旦失敗即停並記錄 t ；(2) 不以「調小步長」掩蓋爆破——調小只能推遲失敗點，收斂於 T_+ ；(3) 用步長折半比對檢查切片，若兩組結果在失敗點發散則報告「疑似爆破」。這些是數值判讀準則，**不構成定理 26.4 的證明替代**。

預期結果. (i) 於 $[0, 1]$ 上以 $n = 12$ 次迭代對照 e^t ，截斷餘項為 $\sum_{j=13}^{\infty} t^j/j!$ ，其在 $t = 1$ 的絕對值約為 1.6×10^{-10} ，故最大絕對誤差應在 10^{-10} 量級，遠未達雙精度極限；欲達 10^{-15} 量級須取顯著更大的 n 。(ii) 對 $y' = \sqrt{|y|}$ ，取 $y(0) = 0$ 得 $y \equiv 0$ ；另取 $y(0) = 10^{-6}$ （不同初值，故不與 $y_0 = 0$ 的情形對比非唯一），其解析解為 $y(t) = (10^{-3} + t/2)^2$ ，RK4 在 $t = 0.1$ 上應得約 0.002601。(iii) 對 $y' = y^2$ ， $y(0) = 1$ ，RK4 在 $t = 0.9$ 得 $y \approx 10$ ； $t \rightarrow 1^-$ 急刻減少步長仍會失敗，代表數值探測「發現」了爆破但不能證明爆破。(iv) 對 f_{lv} 取初值 $(1, 2)$ 與 $(1 + \delta, 2)$ ， $\delta = 10^{-3}$ ，在 $[0, 0.1]$ 上兩條軌跡差範數應 $\leq \delta \cdot e^{Lt}$ ；以 $\delta \cdot e^{4.58 \times 0.1} \approx 1.58\delta$ 為上界。這些皆為**執行後預期**，未在此實際執行。

測試與預期結果

正常測試. $y' = y$ 、 $y(0) = 1$ ，取 $t \in [0, 1]$ 、 $n = 12$ ，與 $\exp$ 的相對誤差 $\leq 10^{-10}$ （ $t = 1$ 處截斷餘項除 e 給出約 5.9×10^{-11} ，為本區間上相對誤差的上界）。這是 Picard 迭代在解析可驗證例子上的正確性檢查；若要收緊至 10^{-15} ，須提高 n 或改用更高精度的部分和。

邊界測試. $y' = \sqrt{|y|}$ ， $y(0) = 0$ 。Picard 迭代停在 $y \equiv 0$ ：數值只能沿一條解走，**不可能**「遍歷」所有解；因此數值不能代替「非唯一」這種存在性結論，只能作為提示。改取 $y(0) = 10^{-6}$ ，RK4 給出非零解，可與解析式 $(10^{-3} + t/2)^2$ 對照；此為不同初值的對照，不證明同初值問題的非唯一性。

故障測試. $y' = y^2$ ， $y(0) = 1$ 在 $[0, 1.1]$ 上；RK4 步長 $h = 10^{-3}$ ，步數 1100。當 t 逼近 1 時 y 迅速升至 10^3 以上，RK4 誤差暴增， y 最終溢出為 `inf` 或 `nan`。**這不是求不出解**，而是解的爆破在局部定理保證區間之外；程式應在 `np.isfinite` 失敗處顯式記錄失敗點，而非靜默替換步長或吞掉 `nan`。

反例與常見陷阱

1. **把連續當成充分條件。** 連續保 Peano 存在，不保唯一；例 26.8。
2. **把「迭代看起來收斂」當成存在唯一證明。** Picard 迭代的收斂速度是幾何式的，必須配完備性 + 壓縮比 $q < 1$ ；只做若干步數值試算只能支持、不能證明 (26.7) 有解。
3. **誤將局部唯一當成全域唯一。** 定理 26.4 只在 I_α 上保證。解延拓須「重新初始條件、重新取域」逐步拼接；是否有全域解依賴 f 的增長率。

4. 誤以為 Lipschitz 是必要條件。有唯一但非 Lipschitz 的例子 (Osgood 條件 $\int_0^\varepsilon ds/\phi(s) = \infty$ 下仍唯一)，說明充分 $\neq$ 必要。
5. 誤以為延拓終點僅為 $\pm\infty$ 。有限時間爆破 (例 26.7) 為反例；此情形無法用「步長不足」掩飾。
6. 把 Lipschitz 條件寫成 $\|f(t, y)\| \leq L\|y\|$ 。這是「線性增長」條件，與 (26.3) 不同；前者給延拓到全域時有用，後者才是局部壓縮的關鍵。
7. 忽略 t 方向連續性。定理 26.4 的證明用 f 連續與緊緻性得到 $M < \infty$ ，也隱含 f 在 R 上一致連續以便積分極限的連續性； f 對 t 的跳斷破壞這個一致連續性，使積分算子 T 未必再具有定理所需的性質。以 $f(t, y) = \text{sgn}(t)$ (在 $t = 0$ 跳斷) 與 $y_0 = 0$ 舉例，即使 f 對 y 是 0-Lipschitz， $(Ty)(t) = \int_0^t \text{sgn}(s) ds = |t|$ 仍落在所述 C^0 空間中；但它在 $t = 0$ 不可微，故不能套用定理 26.4 中「積分方程解與 C^1 解等價」的推理得出本節所要求的 C^1 經典解。
8. 誤把局部 Lipschitz 當等於全域 Lipschitz。 $f(t, y) = y^2$ 是局部 Lipschitz 但非全域；推定理論上要用域上局部化，並在每個閉矩形上重新估計 L 、 M 。

AI、幾何與養殖案例

考慮合成養殖水中氨氮 $y(t)$ (單位 mg/L) 在曝氣不足下的簡化動力學

$$y'(t) = r y(t) \left(1 - \frac{y(t)}{K}\right) - \frac{u y(t)}{k + y(t)}, \quad y(0) = y_0 > 0,$$

$r, K, u, k > 0$ 為合成參數。右端為 C^1 。具體 Lipschitz 常數估計。對 y 的偏導為

$$\partial_y f = r \left(1 - \frac{2y}{K}\right) - \frac{u k}{(k + y)^2}.$$

在合理值域 $0 < y \leq K_{\max}$ (取 $K_{\max}$ 為物理上界，例如 50 mg/L) 上，

$$L \leq r + 2r \frac{K_{\max}}{K} + \frac{u}{k}.$$

取 $t_0 = 0$ h、 $y_0 = 10$ mg/L、 $a = 1$ h；此時閉球 $\overline{B(y_0, b)} = [5, 15]$ mg/L (取 $b = 5$ mg/L) 落於 $0 < y < K_{\max} = 50$ mg/L 的範圍內，且 $t_0 - a = -1$ h 之下 $k + y > k > 0$ 仍成立，故閉矩形 $R \subseteq D$ 。代入 $r = 0.5 \text{ h}^{-1}$ 、 $K = 10$ mg/L、 $u = 2$ mg/(L · h)、 $k = 1$ mg/L。在 $[5, 15]$ 上 $\partial_y f = 0.5(1 - y/5) - 2/(1 + y)^2$ ，其絕對值在 $y = 15$ 處最大，約為 1.01，故 $L \leq 1.01 \text{ h}^{-1}$ 。而 $f(y) = 0.5y(1 - y/10) - 2y/(1 + y)$ 在此區間上嚴格遞減，端點值為 $f(5) \approx -0.417$ 、 $f(15) = -5.625$ ，故 $M \leq 5.63$ mg/(L · h)。於是 $b/M \geq 5/5.63 \approx 0.888$ h， $1/(2L) \geq 1/(2 \times 1.01) \approx 0.495$ h，故 $\alpha \geq \min(1, 0.888, 0.495) = 0.495$ h。定理保證至少在 t_0 附近 0.495 小時內解存在且唯一 (讀者若以「約 0.5 小時」口語描述應留意其為一位有效數字的四捨五入，並非保證完整 0.5 小時)。這個具體 α 提醒：動態越「陡」(L 越大) 或含量變化越快 (M 越大)，保證區間就越短。

從方法論上：感測器給的 y_0 有雜訊，若 f 非 Lipschitz (例如酵素動力學簡化到 $\sqrt{y}$)，初值的不確定可能伴隨解的非唯一，這會直接影響「以模型預測為決策依據」的可信度。本章的結論只說：在 Lipschitz 假設下，初值 y_0 的小擾動造成的解差可由 (26.8) 型 Grönwall 估計控制，這才是可稽核的部分；模型是否能給

出物理正確的濃度，須另做現場驗證，不在本章範圍。混合單位的估量（例如 $\text{mg}/(\text{L} \cdot \text{h})$ ）不能直接與 h^{-1} 相加，故本例以無因次化 $K_{\max}/K$ 拆開。**模型校準不等於現場驗證；數學穩定不等於操作安全；agent 唯讀整理證據，不改設備、投餌或加藥。**

幾何上，若把 $f(t, y)$ 看成向量場，積分曲線是其流線；(26.5) 給 Banach 迭代的收斂速度；(26.8) 給解的連續依賴。任一研究若沒有先在 Lipschitz 上取得「局部良置」，進一步的穩定性、敏感度、Lyapunov 討論都缺基礎。

習題

習題 26.1 (手算) . 對 $y' = -2y$, $y(0) = 3$ ，寫出前四次 Picard 迭代，並與解析解比較在 $[0, 1]$ 上 $n = 4$ 時的最大誤差。

習題 26.2 (程式) . 實作 Picard 迭代求解 $y'(t) = \cos(t) + y(t)$, $y(0) = 0$, $t \in [0, 1]$ ，比較 $n = 0, 1, 2, 3, 5, 10$ 次與真解的誤差；說明誤差是否呈現幾何下降，並解釋 q 的角色。

習題 26.3 (反例) . 構造一個連續 $f(t, y)$ ，使得 (26.1) 在 $t_0 = 0$ 附近存在但不**唯一**；寫出兩個明顯不同的解並說明 Lipschitz 條件如何失效。

習題 26.4 (整合) . 對 $y' = 1 + y^2$, $y(0) = 0$ ，先由定理 26.4 給出保證區間下界，再求閉式解並比較兩者；最後解釋解在何處爆破。

習題解答

26.1 因 $f(t, y) = -2y$ 對 y 是 $L = 2$ 的 Lipschitz，取 $a = b = 1$, $M = 2(3 + 1) = 8$, $\alpha = \min(1, 1/8, 1/4) = 1/8$ 。

$$y_0 = 3, \quad y_1 = 3 - 6t, \quad y_2 = 3 - 6t + 6t^2, \quad y_3 = 3 - 6t + 6t^2 - 4t^3, \quad y_4 = 3 - 6t + 6t^2 - 4t^3 + 2t^4.$$

解析解 $y(t) = 3e^{-2t}$ 。在 $[0, 1]$ 上， $n = 4$ 的最大誤差約在 $t = 1$ ： $|3e^{-2} - (3 - 6 + 6 - 4 + 2)| = |3e^{-2} - 1| \approx 0.594$ 。可見「局部」 $1/8$ 上之誤差小，而延伸到 1 後 Taylor 部分和已不足。

26.2 真解為 $y(t) = \frac{1}{2}(\sin t - \cos t) + \frac{1}{2}e^t$ 。依題設 $y_0 = 0$ 及 $y_{k+1}(t) = \int_0^t (\cos s + y_k(s)) ds$ 逐次計算，得

$$y_1 = \sin t, \quad y_2 = \sin t + 1 - \cos t, \quad y_3 = t + 1 - \cos t, \quad y_4 = t + \frac{1}{2}t^2,$$

這些不是 e^t 的 Taylor 部分和。特別注意第三次迭代中，外加的 $\sin t$ 會與 $\int_0^t (-\cos s) ds$ 抵消，卻不會消去 $\int_0^t \sin s ds = 1 - \cos t$ ，因此原式 $y_3 = t + 1 - \cos t$ 正確，不能改成 t 。進一步有

$$y_5 = \sin t + \frac{t^2}{2} + \frac{t^3}{6},$$

$$y_{10} = \sin t + 1 - \cos t + \frac{t^3}{6} + \frac{t^4}{24} + \frac{t^7}{5040} + \frac{t^8}{40320}.$$

令 $e_n = y - y_n$ 。在 $[0, 1]$ 上 $y \geq 0$ 且遞增， $e_0 = y$ ，並有 $e_{n+1}(t) = \int_0^t e_n(s) ds$ 。歸納可知誤差非負且遞增，所以最大誤差恰為 $e_n(1)$ ，不是由有限網格取最大值猜測所得。真解 $y(1) \approx 1.5097252537$ ，對指定的 $n = 0, 1, 2, 3, 5, 10$ ，由解析式代值得最大誤差約為

$$1.50972525, \quad 0.66825427, \quad 0.20855657, \quad 0.05002756, \quad 0.00158760, \quad 2.71406 \times 10^{-8}.$$

下列標準庫程式用有理係數儲存 $a \sin t + b \cos t + p(t)$ ，直接做符號積分遞推，不混入數值求積誤差。係數更新來自 $\int \sin = 1 - \cos$ 、 $\int \cos = \sin$ 及多項式逐項積分。顯示值是上述解析計算的預期，浮點尾數可能稍異；本段不宜稱主章RK4程式已執行。

```
from fractions import Fraction
import math

def picard_cos_coefficients(n):
    if isinstance(n, bool) or not isinstance(n, int) or n < 0:
        raise ValueError("n must be a nonnegative integer")
    a, b, p = Fraction(0), Fraction(0), [Fraction(0)]
    for _ in range(n):
        a, b, p = 1+b, -a, [a] + [c/(j+1) for j, c in enumerate(p)]
    return a, b, p

def evaluate_picard(n, t):
    if not math.isfinite(t) or not 0 <= t <= 1:
        raise ValueError("t must be in [0,1]")
    a, b, p = picard_cos_coefficients(n)
    return math.fsum([float(a)*math.sin(t), float(b)*math.cos(t)]
                    + [float(c)*t**j for j, c in enumerate(p)])

truth = (math.sin(1)-math.cos(1)+math.exp(1))/2
for n in (0, 1, 2, 3, 5, 10):
    error = truth-evaluate_picard(n, 1)
    print(n, error)
    assert 0 <= error <= truth/math.factorial(n) + 1e-14
    assert abs(evaluate_picard(n, 0)) < 1e-14
for invalid in (-1, 1.5, True):
    try:
        picard_cos_coefficients(invalid)
    except ValueError:
        continue
    raise AssertionError("invalid iteration count accepted")
```

本題在整個 $[0, 1]$ 上，普通一致範數的估計 $q = L\alpha = 1$ 並非嚴格壓縮，不能直接用 $q < 1$ 的定理宣稱其收斂。但積分誤差遞推給出 $0 \leq e_n(t) \leq \|e_0\|_\infty t^n/n!$ ，已能證明在該區間一致收斂；這個階乘界比固定比例的幾何界更精細。縮到 $\alpha < 1$ 的區間後， $q = \alpha < 1$ 才可直接提供幾何型上界；上界並非每一步實測誤差必定等比。

26.3 取 $f(t, y) = \sqrt{|y|}$ 、 $y(0) = 0$ ，與例 26.8 同。 $y_1 \equiv 0$ 與 $y_2(t) = \frac{1}{4}t^2 \cdot \mathbf{1}_{t \geq 0}$ 皆解 $y' = \sqrt{|y|}$ 、 $y(0) = 0$ 。 y_2 在 $t \geq 0$ 時 $y'_2 = t/2 = \sqrt{t^2/4}$ ；在 $t < 0$ 若延伸 $y_2(t) \equiv 0$ 亦滿足 $y'_2 = 0 = \sqrt{0}$ ；兩版本皆為解，是足證非唯一的兩例。Lipschitz 失效處為 $y = 0$ ：比值 $|\sqrt{|y|} - 0|/|y| = 1/\sqrt{|y|}$ 在 $y \rightarrow 0$ 時無界。

26.4 $f(t, y) = 1 + y^2$ 在 $R = [-a, a] \times [-b, b]$ 上 $L = 2b$ 、 $M = 1 + b^2$ ， $\alpha = \min(a, b/(1 + b^2), 1/(2L))$ 。
 ◦ 取 $a = 1, b = 1$ ： $M = 2$ 、 $\alpha = \min(1, 1/2, 1/4) = 1/4$ 。解析解為 $y(t) = \tan t$ ，在 $t \rightarrow \pi/2^-$ 時 $y \rightarrow +\infty$ 。故定理 26.4 給的 $1/4$ 遠短於真實可延拓區間 $(0, \pi/2)$ ；爆破位置即 $T_+ = \pi/2$ 。檢驗：當 $t \rightarrow \pi/2^-$ ， $\|y\|$ 無界——正是評註 26.5 之 (3) 所述現象。此外，由 (26.8) 型估計可知初值 $y_0 = \delta$ 小擾動在 $t = 1/4$ 上的解差 $\leq \delta e^{L \cdot 1/4}$ ，但這只在局部區間有效，不能延伸到 $\pi/2$ 附近。

本章小結

本章先證 Banach 壓縮映射定理，再將初值問題轉為 Picard 積分算子的不動點問題，得到 Picard–Lindelöf 局部存在唯一性定理。關鍵結構是：**完備性** × **壓縮比** $q < 1 \Rightarrow$ **唯一不動點**； **y -Lipschitz** × **閉矩形估計** $\Rightarrow$ **積分算子的壓縮性**。四項分辨務必內化：局部／全域、充分／必要、有限步數值證據／無限維證明、 y -Lipschitz／全域線性增長。 $y' = \sqrt{|y|}$ 說明 Lipschitz 不可省， $y' = y^2$ 說明有界時間爆破真實存在，Grönwall 型估計 (26.8) 鋪墊下一章的穩定討論。往下第 27 章將以本章為前提，討論線性化、局部穩定與 Lyapunov 條件。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*，作者首頁作者目錄頁，<https://www.jirka.org/ra/>（已取得作者首頁；舊路徑 404）。
- [A2] MIT OCW 18.100A *Real Analysis*，<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>（已取得課程概要）。
- [A3] MIT OCW 18.02SC *Multivariable Calculus*，<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>（已取得課程概要）。
- [A4] JAX Autodiff Cookbook：JVP／VJP，https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html（延伸參考；本章未使用）。
- [A5] SciPy `scipy.linalg.expm` 文件，<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>（延伸參考；僅供第 25、27 章比較）。
- [A6] SciPy `scipy.optimize.minimize` 文件，<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>（延伸參考；供 Ch. 27 及最佳化章節使用）。

上述已取得者限於入口與概要頁；未讀完教材 PDF 或完整課程，也未執行外部程式。SciPy 為選用延伸參考，本章實作以 NumPy 標準 CPU 為主，並明確區分「執行後預期結果」與「已實際執行」。

第27章 線性化、局部穩定與Lyapunov橋接

學習目標與先備知識

本章研究有限維自治常微分方程

$$\dot{x} = f(x), \quad x(t) \in \mathbb{R}^n,$$

在平衡點附近的行為。完成本章後，讀者應能：

1. 區分Lyapunov穩定、局部漸近穩定、局部指數穩定與不穩定。
2. 使用Jacobian線性化非線性系統，並列明定理所需的定義域、正則性與譜條件。
3. 理解Hurwitz矩陣、Lyapunov矩陣方程與二次Lyapunov函數的關係。
4. 說明為何零實部特徵值使線性化判別不定。
5. 辨認非正規矩陣造成的暫態放大。
6. 使用NumPy檢查特徵值、Lyapunov方程殘差與數值軌跡，同時區分證明與數值證據。
7. 在混合物理單位的模型中先無因次化，再解釋矩陣範數與Lyapunov橢球。

先備知識包括Jacobian、特徵值、正定矩陣、矩陣指數、局部存在唯一性與一階Taylor展開。設 $U \subset \mathbb{R}^n$ 為開集， $f: U \rightarrow \mathbb{R}^n$ 在平衡點 x_* 附近Fréchet可微。令 $z = x - x_*$ ，則

$$\dot{z} = Az + r(z), \quad A = J_f(x_*),$$

其中使用Euclidean範數時，

$$\frac{\|r(z)\|_2}{\|z\|_2} \rightarrow 0 \quad (z \rightarrow 0, z \neq 0).$$

這個餘項條件才是非線性系統與線性化之間的分析橋梁。只算出偏導數或沿有限方向取樣，不能代替Fréchet可微性及其全方向極限。

問題與直覺

平衡點 x_* 滿足 $f(x_*) = 0$ 。受到小擾動後，可以依序提出三個問題：

- 軌跡是否一直留在平衡點附近？
- 軌跡是否最後回到平衡點？
- 回去的速度是否能被指數函數控制？

線性系統 $\dot{z} = Az$ 的解為

$$z(t) = e^{tA}z(0).$$

若 A 的所有特徵值實部都小於零，則 e^{tA} 長時間衰減。對非線性系統，若 $r(z) = o(\|z\|_2)$ ，非線性餘項在足夠小的鄰域內比線性主項低階。這導向Hurwitz線性化定理。

然而，若 A 有實部為零的特徵值，線性項可能完全看不見第一個有效非線性項。例如

$$\dot{x} = -x^3, \quad \dot{x} = x^3$$

在 $x = 0$ 的Jacobian都等於零，穩定性卻相反。因此「線性化不定」只表示該判準沒有結論，不表示系統必然穩定、必然不穩定或必然週期運動。

另一個常見誤解是把暫態放大當成不穩定。即使 A 為Hurwitz，Euclidean長度 $\|e^{tA}z_0\|_2$ 仍可能先增加再減少。非正矩陣的特徵方向可能高度非正交，使不同模態短時間疊加。適當的正定二次Lyapunov函數則提供另一種加權幾何，使其橢球子水平集沿軌跡單調收縮。

定義、定理與推導

1. 平衡點與解的存在範圍

設 f 在 x_* 附近局部Lipschitz，因此每個鄰近初值 x_0 有唯一最大解

$$x(\cdot; x_0) : [0, T_{\max}) \rightarrow U.$$

定義 (Lyapunov穩定)

平衡點 x_* 稱為穩定，若對每個 $\varepsilon > 0$ ，存在 $\delta > 0$ ，使每個滿足 $\|x_0 - x_*\|_2 < \delta$ 的解均可向前延續至所有 $t \geq 0$ ，且

$$\|x(t; x_0) - x_*\|_2 < \varepsilon \quad \text{對所有 } t \geq 0.$$

有些教材先在最大存在區間內定義穩定，再由解留在定義域內的緊子集及ODE延拓定理推出 $T_{\max} = \infty$ 。本章直接把向前全時間存在寫入定義，避免有限時間逃逸造成歧義。

定義 (局部漸近穩定)

若 x_* 穩定，且存在 $\rho > 0$ ，使所有滿足 $\|x_0 - x_*\|_2 < \rho$ 的解皆有

$$x(t; x_0) \rightarrow x_* \quad (t \rightarrow \infty),$$

則稱 x_* 局部漸近穩定。

定義 (局部指數穩定)

若存在 $M \geq 1$ 、 $\alpha > 0$ 及 $\rho > 0$ ，使所有 $\|x_0 - x_*\|_2 < \rho$ 的解均對 $t \geq 0$ 存在，並滿足

$$\|x(t; x_0) - x_*\|_2 \leq M e^{-\alpha t} \|x_0 - x_*\|_2,$$

則稱 x_* 局部指數穩定。

局部指數穩定充分推出局部漸近穩定，後者充分推出Lyapunov穩定；反向一般不成立。

2. Hurwitz矩陣與線性化間接法

定義（Hurwitz矩陣）

實方陣 $A \in \mathbb{R}^{n \times n}$ 稱為Hurwitz矩陣，若其每個複特徵值 λ 都滿足

$$\operatorname{Re} \lambda < 0.$$

定理（線性化間接法）

設 $U \subset \mathbb{R}^n$ 為開集， $x_* \in U$ ， $f \in C^1(U, \mathbb{R}^n)$ ，且 $f(x_*) = 0$ 。因此 f 在平衡點的一個開鄰域內為 C^1 ，鄰近初值的方程局部存在唯一解。

1. 若 $J_f(x_*)$ 為Hurwitz，則 x_* 局部指數穩定。
2. 若 $J_f(x_*)$ 至少有一個特徵值的實部大於零，則 x_* 不穩定。
3. 若沒有正實部特徵值，但至少有一個特徵值實部等於零，則只靠線性化一般不能判定穩定性。

前兩項是充分判準，但不構成所有情況的必要充分分類。第三種情況稱為非雙曲情況，可能需要高階項、中心流形或直接Lyapunov法。這些延伸工具另有條件，不能只寫出名稱便當成證明。

3. Lyapunov直接法與鄰域限制

令 $D \subset U$ 為包含 x_* 的開鄰域， $V \in C^1(D, \mathbb{R})$ 。沿軌跡的導數為

$$\dot{V}(x) = DV(x)[f(x)] = \nabla V(x)^T f(x).$$

此處 $DV(x)$ 是 $1 \times n$ 線性泛函，而Euclidean梯度 $\nabla V(x)$ 是 $n \times 1$ 列向量。

定理（局部Lyapunov判準）

假設 f 局部Lipschitz，且存在開鄰域 D 與 $V \in C^1(D)$ ，使

$$V(x_*) = 0, \quad V(x) > 0 \quad (x \in D \setminus \{x_*\}),$$

以及

$$\dot{V}(x) \leq 0.$$

則 x_* 穩定。若另外有

$$\dot{V}(x) < 0 \quad (x \in D \setminus \{x_*\}),$$

則 x_* 局部漸近穩定。

上述局部定理包含一個不可省略的緊子水平集論證。先取 $r > 0$ 使

$$\overline{B}_r(x_*) \subset D,$$

為證明對任意指定的 $\varepsilon > 0$ 均穩定，選 $0 < s < \min\{r, \varepsilon\}$ 。有限維Heine–Borel定理保證球面

$$S_s = \{x : \|x - x_*\|_2 = s\}$$

為緊集。因 V 連續且在 S_s 上嚴格為正，

$$m_s = \min_{\|x - x_*\|_2 = s} V(x) > 0.$$

選擇 $0 < c < m_s$ ，並定義閉子水平集

$$K_c = \{x \in \overline{B}_s(x_*) : V(x) \leq c\}.$$

K_c 是閉子水平集與緊球的交集，故為緊集；球面上的 V 至少為 $m_s > c$ ，所以 $K_c \subset B_s(x_*) \subset D$ 。由 $V(x_*) = 0$ 及連續性，可選 $0 < \delta \leq s$ ，使 $\|x_0 - x_*\|_2 < \delta$ 時同時有 $x_0 \in B_s(x_*)$ 及 $V(x_0) < c$ 。在解仍存在並留於球內時，

$$V(x(t)) \leq V(x_0) < c.$$

若軌跡離開球，連續性使它必先碰到球面 S_s ；但該處 $V \geq m_s > c$ ，與上式矛盾。因此軌跡始終留在緊集 $K_c \subset D$ ，由ODE延拓定理可排除有限時間逃逸。這同時建立正向不變性與向前全時間存在。

若 $\dot{V} < 0$ ，由 $V(x(t))$ 不增且非負，存在極限 $L \geq 0$ 。若 $L > 0$ ，取 $0 < a < L$ 。因不增函數的值不小於其極限，軌跡始終位於緊集 $\{x \in K_c : V(x) \geq a\}$ ；此集不含 x_* ，故連續的 $\dot{V}$ 在其上有嚴格負的最大值 $-\eta$ 。於是 $V(x(t)) \leq V(x_0) - \eta t$ ，矛盾。因此 $L = 0$ 。對任意 $0 < \varepsilon < s$ ，緊集 $\{x \in K_c : \|x - x_*\|_2 \geq \varepsilon\}$ 若非空， V 在其上的最小值嚴格為正；既然 $V(x(t)) \rightarrow 0$ ，軌跡最終不可能落在此集內，故 $x(t) \rightarrow x_*$ 。

若在某鄰域內存在 $c_1, c_2, c_3 > 0$ 使

$$c_1\|x - x_*\|_2^2 \leq V(x) \leq c_2\|x - x_*\|_2^2$$

及

$$\dot{V}(x) \leq -c_3\|x - x_*\|_2^2,$$

則在閉包完全包含於該鄰域的不變子水平集內，

$$\dot{V} \leq -\frac{c_3}{c_2}V.$$

由微分不等式，

$$V(t) \leq e^{-(c_3/c_2)t} V(0),$$

因此

$$\|x(t) - x_*\|_2 \leq \sqrt{\frac{c_2}{c_1}} e^{-c_3 t / (2c_2)} \|x_0 - x_*\|_2.$$

這才給出對所有 $t \geq 0$ 成立的局部指數估計。若未先建立不變子水平集，則此估計只能宣稱在解仍留於有效鄰域的時間內成立。

4. Lyapunov矩陣方程

對線性系統 $\dot{z} = Az$ ，考慮

$$V(z) = z^T P z, \quad P = P^T \succ 0.$$

沿解有

$$\dot{V}(z) = z^T (A^T P + P A) z.$$

若存在 $Q = Q^T \succ 0$ 使

$$A^T P + P A = -Q,$$

則

$$\dot{V}(z) = -z^T Q z < 0 \quad (z \neq 0).$$

小命題：Hurwitz矩陣產生正定Lyapunov解

命題

設 $A \in \mathbb{R}^{n \times n}$ 為Hurwitz，且 $Q = Q^T \succ 0$ 。則

$$P = \int_0^\infty e^{A^T t} Q e^{At} dt$$

收斂， $P = P^T \succ 0$ ，並滿足

$$A^T P + P A = -Q.$$

此外，此對稱解唯一。

證明

有限維Hurwitz條件保證存在 $M \geq 1$ 及 $\alpha > 0$ 使

$$\|e^{At}\|_2 \leq Me^{-\alpha t}.$$

因此

$$\|e^{A^T t} Q e^{At}\|_2 \leq M^2 \|Q\|_2 e^{-2\alpha t}.$$

右側在 $[0, \infty)$ 可積，所以定義 P 的矩陣瑕積分絕對收斂。每個被積矩陣均對稱，故 P 對稱。對任意非零列向量 z ，

$$z^T P z = \int_0^\infty (e^{At} z)^T Q (e^{At} z) dt.$$

被積函數非負，且 $t = 0$ 時等於 $z^T Q z > 0$ 。由連續性，積分嚴格為正，所以 $P \succ 0$ 。

接著保持矩陣乘法次序。因 A^T 與其矩陣指數 $e^{A^T t}$ 交換，且 A 與 e^{At} 交換，

$$A^T P + P A = \int_0^\infty (A^T e^{A^T t} Q e^{At} + e^{A^T t} Q e^{At} A) dt.$$

另一方面，先依乘積法則按原次序求導：

$$\frac{d}{dt} (e^{A^T t} Q e^{At}) = e^{A^T t} A^T Q e^{At} + e^{A^T t} Q A e^{At}.$$

第一項利用 $e^{A^T t} A^T = A^T e^{A^T t}$ ，第二項利用 $A e^{At} = e^{At} A$ ，便分別等於上式積分中的兩項；兩次交換都沒有讓矩陣跨越 Q 。因此

$$A^T P + P A = \left[e^{A^T t} Q e^{At} \right]_0^\infty.$$

Hurwitz條件使上限趨於零，而 $t = 0$ 時矩陣為 Q ，故

$$A^T P + P A = -Q.$$

最後，若 P_1, P_2 都是方程的解，令 $R = P_1 - P_2$ ，則

$$A^T R + R A = 0.$$

考慮 $e^{A^T t} R e^{At}$ ，其導數為零，故它恆等於 R 。但 $t \rightarrow \infty$ 時，Hurwitz條件使該矩陣趨於零，因此 $R = 0$ ，解唯一。證畢。

量詞完整的等價敘述是：

- 若 A 為Hurwitz，則對每個 $Q = Q^T \succ 0$ ，方程皆有唯一的對稱正定解 P 。
- 若存在某一組 $Q = Q^T \succ 0$ 及 $P = P^T \succ 0$ 滿足 $A^T P + P A = -Q$ ，則 A 為Hurwitz。

第二點可由複特徵向量驗證。若 $Av = \lambda v$ 且 $v \neq 0$ ，則

$$v^*(A^T P + P A)v = 2 \operatorname{Re}(\lambda) v^* P v = -v^* Q v < 0.$$

因 $v^* P v > 0$ ，必有 $\operatorname{Re} \lambda < 0$ 。這是必要充分判準，而不是有限採樣所得的經驗規則。

逐步手算例題

例1：相同零Jacobian，不同穩定性

考慮

$$\dot{x} = -x^3.$$

對 $x_0 \neq 0$ 分離變數可得

$$x(t) = \frac{x_0}{\sqrt{1 + 2x_0^2 t}}.$$

因此 $|x(t)| \leq |x_0|$ 且 $x(t) \rightarrow 0$ 。取

$$V(x) = \frac{x^2}{2},$$

則

$$\dot{V} = x\dot{x} = -x^4 < 0 \quad (x \neq 0).$$

原點漸近穩定，但不是局部指數穩定。固定非零 x_0 時，精確解只以 $t^{-1/2}$ 階衰減，不可能對所有 $t \geq 0$ 被固定常數倍的 $e^{-\alpha t}$ 控制。

再考慮

$$\dot{x} = x^3.$$

其非零解為

$$x(t) = \frac{x_0}{\sqrt{1 - 2x_0^2 t}},$$

並在

$$T_{\max} = \frac{1}{2x_0^2}$$

發生有限時間爆破。任意小的非零初值最終都離開固定小鄰域，因此原點不穩定。兩個系統都有 $f'(0) = 0$ ，說明零Jacobian沒有判別力。

例2：非正規暫態與二次Lyapunov函數

令

$$A = \begin{pmatrix} -1 & 8 \\ 0 & -2 \end{pmatrix}.$$

A 為上三角矩陣，特徵值為 $-1, -2$ ，故為Hurwitz。直接計算得

$$e^{At} = \begin{pmatrix} e^{-t} & 8(e^{-t} - e^{-2t}) \\ 0 & e^{-2t} \end{pmatrix}.$$

取 $z_0 = (0, 1)^T$ 。在 $t = \log 2$ 時，

$$z(t) = \begin{pmatrix} 2 \\ 1/4 \end{pmatrix}, \quad \|z(t)\|_2 = \frac{\sqrt{65}}{4} > 1 = \|z_0\|_2.$$

Euclidean長度曾經增加，但這不否定漸近穩定。

取 $Q = I$ 並設

$$P = \begin{pmatrix} p_{11} & p_{12} \\ p_{12} & p_{22} \end{pmatrix}.$$

由 $A^T P + P A = -I$ 逐項比較得

$$p_{11} = \frac{1}{2}, \quad p_{12} = \frac{4}{3}, \quad p_{22} = \frac{67}{12}.$$

其首要主子式為 $1/2 > 0$ ，且

$$\det P = \frac{1}{2} \frac{67}{12} - \left(\frac{4}{3}\right)^2 = \frac{73}{72} > 0.$$

故 $P \succ 0$ 。雖然 $\|z(t)\|_2$ 可能暫時增加，

$$V(z) = z^T P z, \quad \dot{V} = -\|z\|_2^2$$

仍嚴格下降。Lyapunov函數改變的是衡量距離的橢球幾何，不是實際軌跡。

實作與程式

以下自足程式只使用NumPy與CPU。它求解Lyapunov方程、執行RK4積分，並輸出離散Lyapunov增量。程式未在本章執行；所有輸出描述均為預期結果。

```
import numpy as np

def is_hurwitz(A, tol=1e-12):
    A = np.asarray(A, dtype=float)
    if A.ndim != 2 or A.shape[0] != A.shape[1]:
        raise ValueError("A 必須是方陣")
    eig = np.linalg.eigvals(A)
    return bool(np.all(np.real(eig) < -tol)), eig

def solve_lyapunov(A, Q):
    """解  $A.T @ P + P @ A = -Q$ ，使用 column-major vec。"""
    A = np.asarray(A, dtype=float)
    Q = np.asarray(Q, dtype=float)

    if A.ndim != 2 or A.shape[0] != A.shape[1]:
        raise ValueError("A 必須是方陣")
    n = A.shape[0]
    if Q.shape != (n, n):
        raise ValueError("Q 的形狀必須與 A 相同")
    if not np.allclose(Q, Q.T):
        raise ValueError("Q 必須對稱")

    I = np.eye(n)
    K = np.kron(I, A.T) + np.kron(A.T, I)
    rhs = -Q.reshape(n * n, order="F")
    p = np.linalg.solve(K, rhs)
    P = p.reshape((n, n), order="F")
    if not np.allclose(P, P.T, rtol=1e-10, atol=1e-12):
        raise ArithmeticError("求解結果的對稱誤差過大")
    if not np.allclose(A.T @ P + P @ A, -Q,
                       rtol=1e-10, atol=1e-12):
        raise ArithmeticError("求解結果的 Lyapunov 殘差過大")
    P = 0.5 * (P + P.T)
    if not np.allclose(A.T @ P + P @ A, -Q,
                       rtol=1e-10, atol=1e-12):
        raise ArithmeticError("對稱化後的 Lyapunov 殘差過大")
    return P

def rk4(f, x0, dt, steps):
    if dt <= 0:
        raise ValueError("dt 必須為正")
    if not isinstance(steps, int) or steps < 0:
        raise ValueError("steps 必須為非負整數")

    x = np.asarray(x0, dtype=float).copy()
    if x.ndim != 1:
        raise ValueError("程式儲存的 x0 必須是一維陣列")

    out = np.empty((steps + 1, x.size), dtype=float)
    out[0] = x

    for k in range(steps):
```

```

    k1 = np.asarray(f(x), dtype=float)
    k2 = np.asarray(f(x + 0.5 * dt * k1), dtype=float)
    k3 = np.asarray(f(x + 0.5 * dt * k2), dtype=float)
    k4 = np.asarray(f(x + dt * k3), dtype=float)

    if not all(v.shape == x.shape for v in (k1, k2, k3, k4)):
        raise ValueError("f(x) 的形狀必須與 x 相同")

    x = x + dt * (k1 + 2*k2 + 2*k3 + k4) / 6.0
    if not np.all(np.isfinite(x)):
        raise FloatingPointError("軌跡出現非有限值")
    out[k + 1] = x

return out

def numerical_report(A, P, Q, x0, dt, final_time):
    if dt <= 0:
        raise ValueError("dt 必須為正")
    if final_time < 0:
        raise ValueError("final_time 必須非負")
    steps = int(round(final_time / dt))
    traj = rk4(lambda x: A @ x, x0, dt, steps)

    V = np.einsum("bi,ij,bj->b", traj, P, traj)
    norms = np.linalg.norm(traj, axis=1)
    residual = A.T @ P + P @ A + Q

    return {
        "dt": dt,
        "actual_final_time": steps * dt,
        "eig_A": np.linalg.eigvals(A),
        "eig_P": np.linalg.eigvalsh(P),
        "residual_inf": np.linalg.norm(residual, ord=np.inf),
        "peak_norm": np.max(norms),
        "max_discrete_V_increment": (
            np.max(np.diff(V)) if steps > 0 else 0.0
        ),
        "final_norm": norms[-1]
    }

if __name__ == "__main__":
    A = np.array([[ -1.0, 8.0],
                  [ 0.0, -2.0]])
    Q = np.eye(2)
    x0 = np.array([0.0, 1.0])

    ok, eig = is_hurwitz(A)
    P = solve_lyapunov(A, Q)

    assert ok
    assert np.min(np.linalg.eigvalsh(P)) > 0.0
    assert np.linalg.norm(
        A.T @ P + P @ A + Q, ord=np.inf
    ) < 1e-10

    for dt in (0.1, 0.05, 0.01, 0.001):
        print(numerical_report(
            A, P, Q, x0, dt=dt, final_time=5.0
        ))

```



```
one = rk4(lambda x: A @ x, x0, dt=0.1, steps=0)
assert one.shape == (1, 2)
assert np.allclose(one[0], x0)

print("eigenvalues =", eig)
print("P =\n", P)
```

NumPy一維陣列的形狀是 $(n,)$ ，只是儲存格式；數學上的 x 仍被視為 $n \times 1$ 列向量。不可利用一維陣列的 `.T` 聲稱已改成橫向量。

一般有限步長RK4不保證保存連續系統的Lyapunov單調性。因此程式不斷言離散 V_k 必定下降，而只輸出 `max_discrete_V_increment`。即使該值非正，也只支持指定步長、初值與時間窗內的觀察。

測試與預期結果

正常測試

對例2的 A 與 $Q = I$ ，預期：

- 特徵值在浮點誤差內接近 $-1, -2$ ；
- P 接近手算矩陣；
- P 的數值特徵值皆為正；
- Lyapunov方程殘差接近浮點捨入尺度；
- `peak_norm` 大於1，顯示暫態放大；
- 長時間後 `final_norm` 小於暫態峰值。

步長掃描可能顯示較小步長下的離散結果更接近連續軌跡，但本章未執行程式，故不宣稱具體數值或觀察到的收斂階。程式以 `round(final_time / dt)` 決定步數；若終止時間不是步長的整數倍，實際末端時間為 `steps * dt`，不一定等於要求的 `final_time`。

邊界測試

對 $\dot{x} = -x^3$ ，Jacobian為 $[0]$ 。 `is_hurwitz` 預期回傳 `False`，但這不表示原點不穩定；直接Lyapunov分析已證明原點漸近穩定。

`steps=0` 時， `rk4` 應只回傳初值。輸出陣列的一個橫列只是資料表中的單筆紀錄，不代表數學列向量變成橫向量。

故障測試

1. 非方陣 A 應引發 `ValueError`。
2. 非對稱 Q 應引發 `ValueError`。
3. `dt<=0`、負步數或負 `final_time` 應引發 `ValueError`。

4. 對 $A = \text{diag}(0, -1)$ 及 $Q = I$ 求解時，Kronecker 線性系統奇異，預期 `np.linalg.solve` 引發例外。
 5. 對 $\dot{x} = x^3$ 積分接近爆破時間時，數值可能急速增大或出現非有限值。這只能作故障警訊，不能精確認定爆破時間。
 6. 接近虛軸的特徵值容易受浮點誤差影響；固定容差不能替代解析譜判定。
-

反例與常見陷阱

1. 把非Hurwitz等同不穩定。

$\dot{x} = -x^3$ 的 Jacobian 不是 Hurwitz，原點仍漸近穩定。

2. 把零實部等同中性穩定。

$\dot{x} = x^3$ 在線性層次為 $\dot{x} = 0$ ，原非線性系統卻不穩定。

3. 只檢查 $V > 0$ 。

正定函數未必沿軌跡下降，還必須計算 $\dot{V} = \nabla V^T f$ 。

4. 由 $\dot{V} \leq 0$ 直接宣稱漸近穩定。

旋轉系統

$$\dot{x} = -y, \quad \dot{y} = x$$

取 $V = x^2 + y^2$ 時有 $\dot{V} = 0$ 。原點穩定但不是漸近穩定。

5. 忽略閉子水平集與延拓。

局部不等式只在指定鄰域有效。必須把軌跡限制在閉包留於該鄰域內的緊子水平集，才能排除有限時間逃逸。

6. 把Euclidean暫態增長當成不穩定。

指數穩定估計容許 $M > 1$ ；非正規系統可以先放大再衰減。

7. 把局部結論升格為全域結論。

全域漸近穩定通常還要求條件在全空間成立、解全域存在，並常配合徑向無界的 V 。

8. 混合不同物理單位。

溫度與濃度不能直接以無權重Euclidean長度作物理解釋，應先無因次化或說明 P 的單位。

9. 把數值軌跡當成定理。

有限初值、有限時間及有限精度不能證明對整個鄰域與所有 $t \geq 0$ 成立的命題。

AI、幾何與養殖案例

AI局部動態

學習參數的連續時間近似有時寫成

$$\dot{\theta} = F(\theta).$$

若平衡參數 θ_* 附近的 $J_F(\theta_*)$ 為Hurwitz，可推出該連續模型的局部指數穩定；但這不代表損失函數全域凸，也不保證遠處初始化收斂。神經網路常因參數置換或尺度對稱而出現零特徵值，此時線性化可能不定。

離散更新 $\theta_{k+1} = G(\theta_k)$ 的局部線性穩定條件則是Jacobian特徵值位於單位圓內，不能直接套用連續時間Hurwitz條件。

Lyapunov橢球的幾何

若 $P \succ 0$ ，則

$$V(z) = z^T P z$$

的子水平集 $V(z) \leq c$ 是橢球。其主軸由 P 的正交特徵向量給出，半軸長與對應特徵值平方根的倒數成正比。非正規系統中，Euclidean圓可能被流動暫時拉長，但某個Lyapunov橢球仍可向內收縮。

合成養殖感測模型

令水溫偏差 ΔT 以 $^{\circ}\text{C}$ 計，溶氧偏差 ΔO 以 mg/L 計。直接令

$$x = (\Delta T, \Delta O)^T$$

並使用 $\|x\|_2$ ，會把不同單位的平方相加。選尺度

$$T_s = 2^{\circ}\text{C}, \quad O_s = 1 \text{ mg/L},$$

並定義無因次狀態

$$z_1 = \frac{\Delta T}{T_s}, \quad z_2 = \frac{\Delta O}{O_s}.$$

考慮合成局部模型

$$\dot{z} = \begin{pmatrix} -0.4 & 1.2 \\ 0 & -0.7 \end{pmatrix} z + r(z),$$

其中時間單位為小時，且

$$\frac{\|r(z)\|_2}{\|z\|_2} \rightarrow 0.$$

線性矩陣的特徵值為 -0.4 與 -0.7 每小時，所以在 C^1 模型成立的充分小鄰域內，可推出局部指數穩定。非對角元素表示無因次狀態間的局部耦合，不應脫離尺度定義解讀。

返回物理量時，

$$\Delta T = T_s z_1, \quad \Delta O = O_s z_2.$$

此案例完全是合成模型。數學穩定不等於現場操作安全；感測偏差、延遲、致動飽和與未建模外擾都可能使實際狀態離開證明有效的鄰域。唯讀分析不控制曝氣、投餌或加藥。

習題

1. 手算題

對 $\dot{x} = -2x + x^3$ 判斷原點的局部穩定性，並以 $V = x^2/2$ 找出 $\dot{V} < 0$ 的區域。

2. 程式題

對

$$A_k = \begin{pmatrix} -1 & k \\ 0 & -2 \end{pmatrix}, \quad k = 0, 2, \dots, 20,$$

計算初值 $(0, 1)^T$ 的有限時間峰值範數，以及 $Q = I$ 所得 P 的條件數。說明輸出能與不能證明什麼。

3. 反例題

找出一個正定 V 滿足 $\dot{V} \leq 0$ ，但原點不是漸近穩定的系統。驗證條件並指出缺少哪項充分條件。

4. 整合題

設

$$\dot{z} = Az + g(z), \quad A = \begin{pmatrix} -1 & 0 \\ 0 & -3 \end{pmatrix},$$

且在 $\|z\|_2 \leq \rho$ 內有 $\|g(z)\|_2 \leq c\|z\|_2^2$ 。使用 $V = \|z\|_2^2/2$ 找出保證 $\dot{V} < 0$ 的半徑，並建立不離開有效鄰域的初值集合。

習題解答

1. 手算題

因 $f'(0) = -2 < 0$ ，線性化定理給出原點局部指數穩定。直接計算

$$\dot{V} = x(-2x + x^3) = x^2(x^2 - 2).$$

因此 $0 < |x| < \sqrt{2}$ 時 $\dot{V} < 0$ 。若縮小到 $|x| \leq 1$ ，則

$$\dot{V} \leq -x^2 = -2V.$$

區間 $[-1, 1]$ 正向不變，故對 $|x_0| < 1$ 有

$$V(t) \leq e^{-2t}V(0), \quad |x(t)| \leq e^{-t}|x_0|.$$

2. 程式題

可使用：

```
for k in range(0, 21, 2):
    A = np.array([[ -1.0, float(k)],
                  [ 0.0, -2.0]])
    P = solve_lyapunov(A, np.eye(2))
    report = numerical_report(
        A, P, np.eye(2),
        np.array([0.0, 1.0]),
        dt=0.001, final_time=5.0
    )
    print(k, report["peak_norm"], np.linalg.cond(P))
```

預期較大的 k 通常帶來較強的暫態放大及較狹長的Lyapunov橢球，但程式未執行，不能宣稱具體數值。有限參數表只能支持所列 k 及時間窗內的觀察，不能證明對所有實數 k 的單調關係。每個 A_k 為Hurwitz則可由其精確特徵值 $-1, -2$ 證明。

3. 反例題

取

$$\dot{x} = -y, \quad \dot{y} = x,$$

以及

$$V(x, y) = x^2 + y^2.$$

V 正定，且

$$\dot{V} = 2x(-y) + 2y(x) = 0.$$

每條非零軌跡都位於圓 $x^2 + y^2 = \text{常數}$ 上，因此不收敛至原點。原點穩定但不是漸近穩定。缺少的是 $x \neq 0$ 時 $\dot{V} < 0$ 的負定條件。

4. 整合題

沿軌跡有

$$\dot{V} = z^T A z + z^T g(z).$$

因 $A = \text{diag}(-1, -3)$ ，

$$z^T A z \leq -\|z\|_2^2.$$

由Cauchy-Schwarz不等式，

$$z^T g(z) \leq \|z\|_2 \|g(z)\|_2 \leq c \|z\|_2^3.$$

所以

$$\dot{V} \leq -\|z\|_2^2 (1 - c\|z\|_2).$$

若 $c > 0$ ，則在

$$0 < \|z\|_2 < \min\{\rho, 1/c\}$$

內有 $\dot{V} < 0$ 。選

$$r < \min\{\rho, 1/c\},$$

並限制 $\|z(0)\|_2 < r$ 。因 V 下降，

$$\|z(t)\|_2 \leq \|z(0)\|_2 < r,$$

所以軌跡留在有效球內，局部不等式可持續使用；其閉包是定義域內的緊集，故可由延拓定理得到向前全時間存在。若 $c = 0$ ，則不需要 $1/c$ 限制。

本章小結

非線性系統在平衡點附近可寫成

$$\dot{z} = Az + r(z), \quad r(z) = o(\|z\|_2).$$

若 A 為 Hurwitz，平衡點局部指數穩定；若 A 有正實部特徵值，平衡點不穩定；若有零實部特徵值，線性化一般不能判定。 $\dot{x} = -x^3$ 與 $\dot{x} = x^3$ 展示了相同零 Jacobian 可能對應完全不同的行為。

Lyapunov 直接法以正定函數及沿軌跡導數研究穩定性。局部條件必須配合留在有效鄰域內的緊閉子水平集與解的延拓，才能得到對所有 $t \geq 0$ 的結論。Hurwitz 矩陣與 Lyapunov 矩陣方程則連接了譜判準、能量下降與橢球幾何。

非正規 Hurwitz 系統可以有 Euclidean 暫態放大。有限模擬、浮點特徵值與離散 Lyapunov 下降都只是數值證據，不能取代具有完整量詞與鄰域條件的分析證明。

參考來源

1. Hassan K. Khalil, *Nonlinear Systems*, 第3版, Prentice Hall。可參考平衡點穩定性、Lyapunov 直接法與線性化間接法。
2. Lawrence Perko, *Differential Equations and Dynamical Systems*, Springer。可參考平衡點、線性化與局部動力系統。
3. Jiří Lebl, *Basic Analysis*, 作者教材入口：<https://www.jirka.org/ra/>
4. MIT OpenCourseWare, 18.100A Real Analysis：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
5. MIT OpenCourseWare, 18.02SC Multivariable Calculus：<https://ocw.mit.edu/courses/18-02sc/multivariable-calculus-fall-2010/>
6. SciPy, `scipy.linalg.expm` 文件：
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.linalg.expm.html>

前兩項直接對應本章的 ODE 穩定性與 Lyapunov 理論；其餘來源提供分析、微積分及矩陣指數背景。來源列舉不表示已逐頁核對所有版本。本章未執行程式，SciPy 亦非核心程式依賴。

第28章 有界算子與有限／無限維的差別

學習目標與先備知識

讀完本章，應能指定線性算子的定義域、值域與範數，判斷「有界」究竟指哪一個不等式；證明線性算子有界等價於連續；並說明為何有限維中的熟悉結論不能直接搬到函數空間。讀者需要範數、線性映射、數列收斂與有限維緊緻性的基本知識。本章只建立進入泛函分析所需的幾條界線，**不等於已教完泛函分析**。

問題與直覺

矩陣把有限維列向量映成列向量。固定一個矩陣後，輸入足夠小，輸出也會小；矩陣的誘導範數能量化這種控制。可是「把函數微分」也是線性運算，卻可能把振幅極小、振盪極快的函數變成振幅不小的導函數。兩者並不矛盾：它們的定義域、範數及維度不同。

因此，閱讀「微分算子無界」時，第一個問題不是如何計算，而是：**以甚麼範數衡量輸入和輸出？**「無界」也不表示每個輸入都產生無限大的輸出；它表示不存在一個對所有容許輸入通用的有限放大倍數。對固定輸入計算出有限答案，與找不到通用誤差界，可以同時成立。

定義、定理與推導

設 X, Y 是實數賦範線性空間， $T: X \rightarrow Y$ 為**定義在整個 X 上的**線性映射。稱 T 為有界線性算子，是指存在有限常數 $C \geq 0$ ，使每個 $x \in X$ 都滿足

$$\|Tx\|_Y \leq C\|x\|_X.$$

其算子範數定義為

$$\|T\|_{X \rightarrow Y} = \sup_{\|x\|_X \leq 1} \|Tx\|_Y = \sup_{x \neq 0} \frac{\|Tx\|_Y}{\|x\|_X}.$$

上確界容許為 $+\infty$ ；只有有限時， T 才有界。這裏「有界」不是說集合 $\{Tx : x \in X\}$ 有界：例如恆等算子有界，但它在非零線性空間上的整體像通常無界。若算子只定義在某個線性子空間 $D \subset X$ ，應寫 $T: D \rightarrow Y$ ，並用 D 所採用的範數計算上確界；不能暗中把定義域改成整個 X 。定義中的量詞也值得逐字檢查：常數 C 必須先選定，再對**每個**容許輸入成立。讓 C 隨輸入改變，便沒有取得算子範數所要求的控制。

小命題：對上述任意實數賦範線性空間 X, Y 及線性映射 $T: X \rightarrow Y$ ，下列條件等價：① T 有界；② T 在零點連續；③ T 在每一點連續。不要求 X, Y 完備。

證明。若①成立，對任意 $a, x \in X$ ，線性給出 $\|Tx - Ta\|_Y = \|T(x - a)\|_Y \leq C\|x - a\|_X$ 。因此 T 在每一點連續，③成立；③顯然推出②。反過來，若 T 在零點連續，取輸出容差 1，存在 $\delta > 0$ ，使 $\|z\|_X < \delta$ 時 $\|Tz\|_Y < 1$ 。對 $x \neq 0$ ，令 $z = \delta x / (2\|x\|_X)$ ，則 $\|z\|_X = \delta/2 < \delta$ 。由線性及範數齊次性，

$$\|Tx\|_Y = \frac{2\|x\|_X}{\delta} \|Tz\|_Y < \frac{2}{\delta} \|x\|_X.$$

$x = 0$ 時不等式也成立，故①成立。證畢。這是定理證明，而非從有限筆數值觀察作出的推測。證明中最關鍵的步驟，是把零點附近的局部連續性，透過線性的縮放性，變成適用於整個空間的同一個常數；一般非線性連續映射不能照抄這一步。

在 $\mathbb{R}^n$ 、 $\mathbb{R}^m$ 各選一個範數後，每個線性映射 $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 都有界。理由之一是有限維範數等價，再配合矩陣逐項估計；等價常數通常依賴維度與所選範數。以 Euclidean 範數為例，若 $A = (a_{ij})$ ，Cauchy-Schwarz 不等式給出

$$\|Ax\|_2 \leq \left(\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2 \right)^{1/2} \|x\|_2.$$

右方是可用的上界，未必等於真正的算子範數。固定大小矩陣有有限範數，並不保證大小不斷增加的一串矩陣具有共同上界。

維度依賴可從熟悉的向量範數直接看見。對 $x \in \mathbb{R}^n$ ，

$$\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n} \|x\|_\infty, \quad \|x\|_2 \leq \|x\|_1 \leq \sqrt{n} \|x\|_2.$$

第一組右側的不等式來自每個分量的絕對值均不超過最大分量；第二組右側可由 Cauchy-Schwarz 得到。這些不等式足以說明：固定 n 時，改用三種範數不會改變收斂與連續的判斷。然而，當 n 增加時， $\sqrt{n}$ 並非共同固定的常數。例如所有分量都是 1 的列向量，其無窮範數為 1、Euclidean 範數為 $\sqrt{n}$ 。因此「每個有限維空間的範數都等價」不應被誤讀成「所有維度共享一組等價常數」。

範數的選擇在函數空間尤其關鍵。對區間 $[0, 2\pi]$ 上的函數，記 $\|f\|_\infty = \sup_{x \in [0, 2\pi]} |f(x)|$ 。考慮微分

$$D: C^1([0, 2\pi]) \longrightarrow C([0, 2\pi]), \quad Df = f'.$$

若定義域採用由 $C([0, 2\pi])$ 繼承的 $\|\cdot\|_\infty$ ，值域也採用 $\|\cdot\|_\infty$ ，則 D 無界。這不妨礙它在每個個別 C^1 函數上有定義。若改在定義域採用 $\|f\|_{C^1} = \|f\|_\infty + \|f'\|_\infty$ ，同一規則便滿足 $\|Df\|_\infty \leq \|f\|_{C^1}$ ，因而有界。兩種說法的算子規則相同，但賦範空間不同。前一種定義域在該範數下不完備，也不是無界結論成立的障礙；上面的小命題本來就沒有完備性假設。

有限維還有另一個容易誤用的性質：閉且有界的集合是緊緻的。無限維賦範空間一般不能照搬此結論。例如在 $C([0, 2\pi])$ 的一致範數下，函數列 $f_n(x) = \sin(nx)$ 全部位於閉單位球，卻沒有一致收斂的子列。由 $\sin(nx)$ 在區間上的均方正交性可知，不同正整數 m, n 滿足

$$\int_0^{2\pi} |\sin(nx) - \sin(mx)|^2 dx = 2\pi.$$

又因 $\int_0^{2\pi} |u(x)|^2 dx \leq 2\pi \|u\|_\infty^2$ ，兩項的一致範數距離至少為 1，故連一致 Cauchy 子列也不存在。在度量空間中，緊緻集的每個序列均有收斂子列；這裏展示了閉單位球不緊緻所需的明確反例，而不是把「維度無限」四字本身當作證明。

逐步手算例題

例一：固定矩陣的放大倍數。 令 $A = \begin{pmatrix} 2 & 0 \\ 0 & -3 \end{pmatrix}$ ，輸入及輸出都使用 Euclidean 範數。對 $x = (x_1, x_2)^T$ ，

$$\|Ax\|_2^2 = 4x_1^2 + 9x_2^2 \leq 9(x_1^2 + x_2^2) = 9\|x\|_2^2.$$

故 $\|A\|_{2 \rightarrow 2} \leq 3$ 。代入 $e_2 = (0, 1)^T$ ，比值正好為 3，所以 $\|A\|_{2 \rightarrow 2} = 3$ 。這既有上界，也有達到上界的輸入，不是僅試幾個向量所得的猜測。若輸入誤差的 Euclidean 範數不超過 ε ，相應輸出誤差便不超過 3ε ；這是對所有該範數下的輸入誤差成立的界。

例二：高頻函數。 令 $u_n(x) = \sin(nx)/n$ ，其中 n 為正整數。在一致範數下， $\|u_n\|_\infty = 1/n$ ，而 $Du_n(x) = \cos(nx)$ 、 $\|Du_n\|_\infty = 1$ 。因此

$$\frac{\|Du_n\|_\infty}{\|u_n\|_\infty} = n.$$

若存在通用有限常數 C 使 $\|Df\|_\infty \leq C\|f\|_\infty$ ，便須對每個 n 有 $n \leq C$ ，矛盾。注意 $u_n \rightarrow 0$ 是一致收斂，但 Du_n 不一致收斂至零；微分不能在此範數下任意穿過極限。這個反例用的是一族精確寫出的函數，其結論不依賴取樣密度。

再用一個有限截斷看差別。令 $V_N = \text{span}\{1, \sin x, \cos x, \dots, \sin Nx, \cos Nx\}$ 。微分把 V_N 映回 V_N ；每個固定 N 都得到有限矩陣。若用係數的 Euclidean 範數，把 $\sin(kx), \cos(kx)$ 的係數排成一對，微分在該對上的區塊是 $\begin{pmatrix} 0 & -k \\ k & 0 \end{pmatrix}$ ，其範數為 k 。例如依照 $1, \sin x, \cos x, \sin 2x, \cos 2x$ 排列， V_2 的矩陣是

$$D_2 = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -2 \\ 0 & 0 & 0 & 2 & 0 \end{pmatrix}.$$

首個零區塊對應常數；後兩個區塊的範數分別為 1 和 2，所以 $\|D_2\|_{2 \rightarrow 2} = 2$ 。整個 V_N 截斷矩陣的算子範數同理為 N 。**每個 N 有限和這些範數沒有共同有限上界**，是兩個不同命題；此處的係數範數亦不可不加說明地當作一致範數。

實作與程式

以下是自足的 NumPy CPU 範例。它建立上述係數空間的微分矩陣，另在網格上量測函數及導函數的一致範數近似。網格最大值只是數值證據；高頻無界性已由手算證明。程式不安裝套件、不使用 GPU；此處未執行，輸出均屬預期。

```
import numpy as np

def derivative_matrix(N):
    """Basis: 1, sin(x), cos(x), ..., sin(Nx), cos(Nx)."""
    if not isinstance(N, int) or N < 0:
        raise ValueError("N must be a nonnegative integer")
    A = np.zeros((2 * N + 1, 2 * N + 1), dtype=float)
    for k in range(1, N + 1):
        s, c = 2 * k - 1, 2 * k
        A[c, s] = k      # (sin kx)' = k cos kx
        A[s, c] = -k     # (cos kx)' = -k sin kx
    return A

def sampled_amplitudes(n, points=4096):
    if not isinstance(n, int) or n < 1:
        raise ValueError("n must be a positive integer")
    if not isinstance(points, int) or points < 2:
        raise ValueError("points must be an integer at least 2")
    x = np.linspace(0.0, 2.0 * np.pi, points, endpoint=False)
    u = np.sin(n * x) / n
    du = np.cos(n * x)
    return float(np.max(np.abs(u))), float(np.max(np.abs(du)))

for N in (0, 1, 2, 8):
    A = derivative_matrix(N)
    print("N =", N, "shape =", A.shape,
          "coefficient operator norm =", np.linalg.norm(A, 2))

for n in (1, 2, 8):
    amp, derivative_amp = sampled_amplitudes(n)
    print("n =", n, "sampled amplitudes =", amp, derivative_amp)

try:
    derivative_matrix(-1)
except ValueError as exc:
    print("expected invalid-input error:", exc)
```

矩陣的形狀是 $(2N + 1, 2N + 1)$ ；其橫列代表輸出係數，縱行代表輸入係數。程式中的一維陣列只儲存取樣值，不拿一維 `.T` 冒充列向量與橫列向量之間的轉置。矩陣範數由數值函式計算，解析上的 $\|D_N\|_{2 \rightarrow 2} = N$ 則來自區塊結構：這兩種證據應分別標示。

測試與預期結果

正常測試（預期）： $N = 1, 2, 8$ 的係數算子範數依次為 $1, 2, 8$ ，容許浮點誤差。對 $n = 1, 2, 8$ ，導函數在 $x = 0$ 的取樣值絕對值恰為 1 ；函數振幅的網格估計不超過 $1/n$ 。就這三個指定頻率及網格而言，峰值亦落在取樣點上，故預期得到接近 $1/n$ 的數值；對任意其他頻率不能沿用這項命中峰值的保證。

邊界測試（預期）： $N = 0$ 時只有常數基底，矩陣形狀為 $(1, 1)$ ，唯一元素及算子範數都是零。這不表示完整函數空間的微分算子為零。

故障測試（預期）： `derivative_matrix(-1)` 明確拋出 `ValueError`，由示範程式捕捉。若網格點太少，取樣最大值也可能嚴重低估真實峰值；輸入檢查只處理格式，並不能把有限取樣提升成數學證明。實際使用時還須核對所輸入的頻率是否符合模型，以及係數範數是否對應所要控制的物理誤差。

反例與常見陷阱

「線性」不是無條件的「連續」：有界等價於連續，但在無限維賦範空間，必須核對有界條件。對本章的 D ，輸入 u_n 一致趨零而輸出不一致趨零，直接顯示它在零點不連續。

「換個範數不影響結論」也只能在適當條件下說。固定有限維空間中的兩個範數等價；無限維函數空間的 $\|\cdot\|_\infty$ 與 $\|\cdot\|_{C^1}$ 並不等價。甚至使用同一個符號 D ，一旦定義域範數變了，有界性就可能改變。指出算子在某個較強範數下有界，不能據此宣稱它在較弱範數下也有界。

「閉且有界所以有最大值」缺少維度與緊緻性條件。有限維閉球緊緻，無限維閉單位球一般不緊緻；不能只憑閉、有界便引用極值定理。反過來，本章並未斷言無限維中一切集合都不緊緻，更未討論各種不同的緊算子概念。

AI、幾何與養殖案例

在幾何計算或 AI 模型中，把一個連續訊號表示成前 N 個頻率的係數列向量，是常見的有限化步驟。本章的截斷矩陣指出：即使每一版模型都能計算，求導步驟對係數誤差的最壞放大倍數仍會隨 N 增長。若係數誤差的 Euclidean 範數最多是 ε ，則固定 N 時，導數係數誤差最多是 $N\varepsilon$ ；沒有對所有 N 通用的這種上界。這是依模型與範數成立的推論，不是任意實際訊號的誤差保證。增加截斷階數可以容納更多細節，卻也改變了誤差放大界；選階數時不能只看表示能力。

以合成養殖感測序列為例，可把時間 t （單位秒）的水溫擾動寫作 $u_n(t) = a \sin(2\pi nt/T)/n$ ，其中 $a > 0$ 的單位是攝氏度、 $T > 0$ 的單位是秒。擾動的最大幅度為 a/n 攝氏度，但變化率的最大幅度是 $2\pi a/T$ 攝氏度每秒。小振幅不必然代表小變化率；求導前應交代時間尺度、量測誤差與所選函數範數。若改用無因次時間 $s = t/T$ ，對 s 求導後要再除以 T ，才能返回攝氏度每秒的物理變化率。這只是合成模型，不是現場感測器的驗證，也不授權 agent 改動設備或操作設定。

習題

1. **手算**。對 $B = \text{diag}(1, -4, 2)$ ，求 Euclidean 誘導算子範數，並給出達到它的單位列向量。
2. **程式**。修改本章程式中的測試清單，加入 $N = 3$ 與 $N = 0$ ；寫出預期的矩陣形狀與係數算子範數，說明為何執行結果不能證明所有 N 的公式。
3. **反例**。有人聲稱：「若 $f_n \rightarrow 0$ 一致收斂且每個 f_n 可微，則 $f'_n \rightarrow 0$ 一致收斂。」在 $[0, 2\pi]$ 上構造反例，列出兩個一致範數。
4. **整合**。考慮 $D : C^1([0, 2\pi]) \rightarrow C([0, 2\pi])$ 。分別為定義域選用 $\|\cdot\|_\infty$ 及 $\|\cdot\|_{C^1}$ ，判斷有界性；再解釋為何 V_5 上的微分矩陣有界並不推翻第一項判斷。

習題解答

1. 對任意 x ， $\|Bx\|_2^2 = x_1^2 + 16x_2^2 + 4x_3^2 \leq 16\|x\|_2^2$ 。取單位列向量 $e_2 = (0, 1, 0)^T$ ，有 $\|Be_2\|_2 = 4$ ，故範數為 4。
2. $N = 3$ 的預期形狀為 $(7, 7)$ 、範數為 3； $N = 0$ 的預期形狀為 $(1, 1)$ 、範數為 0。有限次執行只覆蓋所試的輸入。對一般 N 的結論須利用各個互不混合的二維區塊：第 k 塊把係數 Euclidean 長度乘以 k ，所以總長度至多乘以 N ，而只在最高頻塊取非零係數即可達到 N ； $N = 0$ 另行處理。
3. 取 $f_n(x) = \sin(nx)/n$ 。每項可微，且 $\|f_n\|_\infty = 1/n \rightarrow 0$ ；但 $f'_n(x) = \cos(nx)$ ， $\|f'_n\|_\infty = 1$ ，故導函數不一致收斂至零。
4. 採一致範數時，第三題的函數使輸出範數與輸入範數之比為 n ，故無界。採 C^1 範數時，對每個輸入都有 $\|Df\|_\infty \leq \|f\|_{C^1}$ ，故有界。 V_5 只含截至頻率 5 的有限維函數，使用題定係數 Euclidean 範數時，矩陣範數為 5；它沒有控制任意高頻輸入，也不是在原來整個定義域上取得通用常數。

本章小結

有界性是「指定定義域範數、值域範數後，存在通用線性誤差界」的性質；對線性算子，它恰好等價於連續。固定有限維矩陣必有界，但有限截斷的一串範數可以不一致有界。微分的高頻例子與閉單位球的非緊緻例子，指出從有限維走向函數空間時，必須重新查驗範數、極限與緊緻性假設。

參考來源

- [A1] Jiří Lebl, *Basic Analysis*，作者教材入口：<https://www.jirka.org/ra/>
- [A2] MIT OCW, *18.100A Real Analysis*，課程入口：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>

以上列為延伸閱讀入口；本章的證明與計算已在文內給出，並不聲稱已逐條核對教材全文。

第29章 變分法、第一變分與能量泛函

學習目標與先備知識

本章把有限維的「沿方向改變變數」推廣為「沿容許函數改變函數」。學完後應能：指定泛函的定義域與範圍；計算第一、第二變分；從容許擾動推導 Euler-Lagrange 方程及自由端的自然邊界條件；區分駐點、局部極小與全域極小。後續離散能量的座標梯度，仍須由離散泛函本身求導，不能直接把連續方程當成梯度。

先備知識包括一維積分與分部積分、Fréchet 導數、對稱二次型，以及有限維梯度依賴內積的觀念。本節先在 $C^1([0, 1])$ 上工作，使用

$$\|u\|_{C^1} = \max_{[0,1]} |u| + \max_{[0,1]} |u'|.$$

固定兩端值時，容許集合是具有指定端點值的仿射集合；其擾動空間為 $X_0 = \{v \in C^1([0, 1]) : v(0) = v(1) = 0\}$ 。若只固定左端，則改用 $X_L = \{v \in C^1([0, 1]) : v(0) = 0\}$ 。這些空間的區別會決定右端能否產生自然邊界條件。

處理弱解時，可另選 $H^1(0, 1) = \{u \in L^2(0, 1) : u' \text{ 的弱導數屬於 } L^2(0, 1)\}$ ，範數為 $\|u\|_{H^1} = (\|u\|_{L^2}^2 + \|u'\|_{L^2}^2)^{1/2}$ ； $H_0^1(0, 1)$ 是光滑緊支撐函數在此範數下的閉包。一維的端點跡、連續代表與 Poincaré 不等式屬於此處引用的結果，不能把光滑函數的逐點推導不加條件地套到任意弱解。

問題與直覺

有限維函數在內點取得局部極小時，每個可行方向的一階導數為零。對能量 $J[u]$ 而言，可行方向是函數 v ：先考察 $J[u + tv]$ 這個單變量函數，再問其在 $t = 0$ 的導數。若端點值已固定，擾動必須在該端點為零；若端點自由，該處的擾動可以非零，分部積分留下的端點項便提供額外條件。

此類問題有三個容易混淆的層次。沿每個固定方向存在導數，只是方向導數的敘述；Fréchet 可微還要求同一個線性泛函能以所選範數一致控制所有足夠小的擾動。第一變分為零只表示駐點，不能判定它是最小值。最後，連續泛函的導數是作用於擾動的線性泛函；把函數取樣成網格向量後，歐氏座標梯度又是另一個對象，兩者的對應取決於離散能量與所選內積。

以拉伸細線的模型為例， $\int_0^1 (u')^2 / 2 \, dx$ 懲罰斜率，外力項 $-\int_0^1 f u \, dx$ 則偏好某些位移。兩項競爭後形成的平衡方程，可以由第一變分導出；但能否斷言平衡是最小值，仍要另查能量差、凸性或有充分條件的第二變分。

定義、定理與推導

第一變分、範數與交換積分

令 X 為上述擾動空間， u 屬於相應的容許仿射集合。若極限存在，第一變分定義為

$$\delta J[u; v] = \left. \frac{d}{dt} J[u + tv] \right|_{t=0}.$$

若存在有界線性泛函 $DJ(u) \in X^*$ ，使

$$J[u + h] = J[u] + DJ(u)[h] + r(h), \quad \frac{|r(h)|}{\|h\|_X} \longrightarrow 0$$

($h \neq 0$ 且 $u + h$ 容許)，則稱 J 在 u 處相對於 X 的範數 Fréchet 可微；此時 $\delta J[u; v] = DJ(u)[v]$ 。反過來，所有方向導數存在並不足以保證這種一致餘項。

考慮

$$J[u] = \int_0^1 L(x, u(x), u'(x)) dx.$$

若 L 及其對後兩個變數的一階偏導在包含所考察函數值與導數值的鄰域連續，則對固定的 $u, v \in C^1([0, 1])$ ， t 限於足夠小的閉區間時，被積函數及其 t 導數在緊集合上連續且有界。因此可交換對 t 的微分與積分，得到

$$\delta J[u; v] = \int_0^1 (L_u(x, u, u')v + L_p(x, u, u')v') dx.$$

在非緊域或改用弱函數空間時，單憑偏導連續不足以作此交換，還須另給可積支配及確保泛函有限的增長條件。

Euler-Lagrange 方程與邊界

必要條件。 假設 u 是容許集合中的局部極小點，上述方向導數對每個容許擾動存在，且 $u + tv$ 對充分小的正、負 t 均容許。單變量函數 $t \mapsto J[u + tv]$ 在零處有局部極小，故 $\delta J[u; v] = 0$ 。特別取 $v \in C_c^\infty(0, 1)$ ，便得到弱形式

$$\int_0^1 (L_u v + L_p v') dx = 0 \quad (v \in C_c^\infty(0, 1)).$$

若合成函數 $x \mapsto L_p(x, u(x), u'(x))$ 可連續微分，且 $L_u(x, u, u')$ 連續，分部積分及變分法基本引理給出經典方程

$$L_u - \frac{d}{dx}L_p = 0 \quad (0 < x < 1).$$

僅說 $u \in C^2$ 並不足夠；還須有使合成函數可微的 L 的正則性。若只有弱形式，方程先按分布意義理解，不預設弱解已有二階經典導數。

對任意 $v \in X_L$ ，分部積分後的端點項是 $[L_p v]_0^1 = L_p(1, u(1), u'(1))v(1)$ 。內部方程成立且右端擾動值可任意選取時，必要的自然條件為

$$L_p(1, u(1), u'(1)) = 0.$$

左端已固定，不能再從同一變分推出左端的自然條件。若兩端均固定，兩個端點項都因擾動為零而消失；若邊界另含端點能量，其導數也必須計入端點條件。

第二變分與極小的充分條件

若二階導數存在，定義 $\delta^2 J[u; v] = D^2 J(u)[v, v]$ 。局部極小且可沿正、負方向擾動時，一階變分必為零，第二變分必為非負；這些是必要條件，單靠它們通常不能反推極小。

小命題。 設 X 為賦範線性空間， $u \in X$ 中的 u 為內點， $DJ(u) = 0$ ，並有相對於 $\|\cdot\|_X$ 的二階展開

$$J[u + h] - J[u] = \frac{1}{2}D^2 J(u)[h, h] + o(\|h\|_X^2).$$

若存在與 h 無關的 $c > 0$ ，使 $D^2 J(u)[h, h] \geq c\|h\|_X^2$ 對所有 $h \in X$ 成立，則 u 為嚴格局部極小。

證明。 依小 o 的定義，存在 $\rho > 0$ ，使 $0 < \|h\|_X < \rho$ 時餘項的絕對值不超過 $c\|h\|_X^2/4$ 。因此

$$J[u + h] - J[u] \geq \frac{c}{2}\|h\|_X^2 - \frac{c}{4}\|h\|_X^2 = \frac{c}{4}\|h\|_X^2 > 0.$$

這證明了充分性，並未聲稱每個局部極小的第二變分都須一致強制。無限維中「對每個非零 h 為正」與「存在共同的正下界 c 」尤其不能混用；若 $DJ(u) \neq 0$ ，一階項也不能從展開中刪去。

逐步手算例題

例一：零端點的受力細線

取 $f(x) = \pi^2 \sin(\pi x)$ ，在零端點的容許集合上考慮

$$J[u] = \frac{1}{2} \int_0^1 (u')^2 dx - \int_0^1 f u dx.$$

對 $v \in X_0$ ，第一變分是 $\int_0^1 (u'v' - fv) dx$ 。對光滑解分部積分，端點項因 $v(0) = v(1) = 0$ 消失，故 $-u'' = f$ 。積分兩次可得 $u = \sin(\pi x) + C_1 x + C_2$ ；兩個零端點依次給出 $C_2 = C_1 = 0$ ，所以候選解為 $u^*(x) = \sin(\pi x)$ 。

直接計算能量時， $\int_0^1 \cos^2(\pi x) dx = \int_0^1 \sin^2(\pi x) dx = 1/2$ ，因此

$$J[u^*] = \frac{\pi^2}{2} \cdot \frac{1}{2} - \pi^2 \cdot \frac{1}{2} = -\frac{\pi^2}{4}.$$

此例還可不依賴局部二階判據，直接證明全域性：將任何同端點函數寫成 $u^* + v$ ，展開後的交叉項是 $\int_0^1 (u^{*'}v' - fv) dx = 0$ ，從而

$$J[u^* + v] - J[u^*] = \frac{1}{2} \int_0^1 (v')^2 dx \geq 0.$$

等號要求 v' 為零；配合零端點即得 $v = 0$ 。在 $H_0^1(0, 1)$ 中同一結論亦成立，其中使用弱導數及端點跡的性質；若要相對完整 H^1 範數表述強制性，則須引用此區間的 Poincaré 不等式。

例二：固定左端、自由右端

在 $u(0) = 0$ 而 $u(1)$ 不指定的集合上，考慮

$$J[u] = \int_0^1 \left(\frac{1}{2}(u')^2 + \frac{1}{4}u^4 - gu \right) dx.$$

對 $v \in X_L$ ，第一變分為 $\int_0^1 \{u'v' + (u^3 - g)v\} dx$ 。分部積分後，內部方程與自由端條件分別是

$$-u'' + u^3 - g = 0, \quad u'(1) = 0.$$

選取明確的資料 $u^*(x) = x(2-x)$ 及 $g(x) = 2 + [x(2-x)]^3$ 。逐項代回可見 $u^{*'} = 2 - 2x$ 、 $u^{*''} = -2$ ，故 $u^*(0) = 0$ 、 $u^{*'}(1) = 0$ ，而

$$-u^{*''} + (u^*)^3 - g = 2 + [x(2-x)]^3 - (2 + [x(2-x)]^3) = 0.$$

這不只是形式上列出方程，還給出符合混合端點條件的解。由 $s \mapsto s^4/4$ 的凸性及平方項的展開，對任意同樣滿足左端條件的擾動 v ，一階交叉項因駐點條件為零，其餘部分非負；平方導數項為零時 v 為常數，再由 $v(0) = 0$ 得 $v = 0$ 。因此此特定資料下的 u^* 也是嚴格全域最小值，而「滿足 Euler-Lagrange 方程」本身並不是一般問題的全域最小證明。

實作與程式

令 $N \geq 2$ 為 $[0, 1]$ 的分段數， $h = 1/N$ 。零 Dirichlet 端點為 $U_0 = U_N = 0$ ，自由向量 $U = (U_1, \dots, U_{N-1})$ 只有 $N-1$ 個分量； f 亦只在這些內點取樣。離散能量定義為

$$J_h(U) = \frac{1}{2h} \sum_{i=0}^{N-1} (U_{i+1} - U_i)^2 - h \sum_{j=1}^{N-1} f_j U_j.$$

逐一收集含 U_j 的兩段平方項，可得歐氏座標梯度

$$(\nabla_{\mathbf{E}} J_h)_j = \frac{2U_j - U_{j-1} - U_{j+1}}{h} - hf_j.$$

因此對同形狀方向 V ， $DJ_h(U)[V] = (\nabla_{\mathbf{E}} J_h)^T V$ ，**不再額外乘 h** 。若選離散內積 $\langle V, W \rangle_M = V^T M W$ 、 $M = hI$ ，其梯度 g_M 則滿足 $Mg_M = \nabla_{\mathbf{E}} J_h$ 。連續導數、歐氏座標梯度及依質量矩陣定義的梯度，必須連同各自的內積一起標記。

為連接相場能量，再取 $n \geq 3$ 個週期節點，下標按模 n 計算，並定義

$$F_h(\phi) = h \sum_{i=0}^{n-1} \frac{(\phi_i^2 - 1)^2}{4} + \frac{\kappa}{2h} \sum_{i=0}^{n-1} (\phi_{i+1} - \phi_i)^2, \quad \kappa \geq 0.$$

設 $(L_h \phi)_i = (\phi_{i-1} - 2\phi_i + \phi_{i+1})/h^2$ ，則

$$\nabla_{\mathbf{E}} F_h = h(\phi^3 - \phi - \kappa L_h \phi).$$

這裡的 h 來自已定義的離散能量，而不是可任意套用的「連續梯度轉換係數」。下面只核對靜態能量及方向導數，沒有執行相場的時間演化。

```
import numpy as np

def vector(name, values, size=None, minimum=1):
    a = np.asarray(values, dtype=float)
    if a.ndim != 1 or a.size < minimum:
        raise ValueError(f"{name} must be a 1-D array of length >= {minimum}")
    if size is not None and a.size != size:
        raise ValueError(f"{name} has the wrong length")
    if not np.all(np.isfinite(a)):
        raise ValueError(f"{name} must contain finite values")
    return a

def positive_h(h):
    h = float(h)
    if not np.isfinite(h) or h <= 0:
        raise ValueError("h must be finite and positive")
    return h

def dirichlet_data(U, f, h):
    h = positive_h(h)
    U = vector("U", U)
    f = vector("f", f, size=U.size)
    return U, f, h

def energy(U, f, h):
    U, f, h = dirichlet_data(U, f, h)
    full = np.r_[0.0, U, 0.0]
    return float(np.dot(np.diff(full), np.diff(full)) / (2*h)
                - h*np.dot(f, U))

def gradient(U, f, h):
```

```

    U, f, h = dirichlet_data(U, f, h)
    full = np.r_[0.0, U, 0.0]
    return (2*U - full[:-2] - full[2:]) / h - h*f

def solve_dirichlet(f, h):
    h = positive_h(h)
    f = vector("f", f)
    m = f.size
    A = np.diag(np.full(m, 2.0/h))
    A += np.diag(np.full(m-1, -1.0/h), 1)
    A += np.diag(np.full(m-1, -1.0/h), -1)
    return np.linalg.solve(A, h*f)

def phase_data(phi, h, kappa):
    phi = vector("phi", phi, minimum=3)
    h = positive_h(h)
    kappa = float(kappa)
    if not np.isfinite(kappa) or kappa < 0:
        raise ValueError("kappa must be finite and nonnegative")
    return phi, h, kappa

def phase_energy(phi, h, kappa):
    phi, h, kappa = phase_data(phi, h, kappa)
    differences = np.roll(phi, -1) - phi
    return float(h*np.sum((phi**2 - 1)**2)/4
        + kappa*np.dot(differences, differences)/(2*h))

def phase_gradient(phi, h, kappa):
    phi, h, kappa = phase_data(phi, h, kappa)
    lap = (np.roll(phi, 1) - 2*phi + np.roll(phi, -1))/h**2
    return h*(phi**3 - phi - kappa*lap)

def central_direction(energy_fn, x, direction, epsilon):
    x = vector("x", x)
    direction = vector("direction", direction, size=x.size)
    epsilon = positive_h(epsilon)
    return (energy_fn(x + epsilon*direction)
        - energy_fn(x - epsilon*direction))/(2*epsilon)

# 以下為可自行執行的核對範例；本章沒有宣稱已執行。
N = 20
h = 1.0/N
x = np.arange(1, N)*h
f = np.pi**2*np.sin(np.pi*x)
solution = solve_dirichlet(f, h)
U = 0.2 + 0.1*np.sin(2*np.pi*x) # 非駐點
V = np.cos(3*np.pi*x)          # 與 U 同形狀
fd = central_direction(lambda z: energy(z, f, h), U, V, 1e-5)
analytic = np.dot(gradient(U, f, h), V)
print("solution residual:", np.linalg.norm(gradient(solution, f, h)))
print("Dirichlet directional discrepancy:", abs(fd - analytic))

phi = np.array([-0.8, -0.1, 0.4, 0.9, 0.2])
W = np.array([1.0, -2.0, 0.5, 1.5, -1.0])
hp, kappa = 1.0/phi.size, 0.03
fd_phase = central_direction(
    lambda z: phase_energy(z, hp, kappa), phi, W, 1e-5)

```

```
print("phase directional discrepancy:",
      abs(fd_phase - np.dot(phase_gradient(phi, hp, kappa), W)))
```

陣列在程式中以 NumPy 一維形狀儲存，`np.dot(gradient(...), V)` 表示數學上的行向量作用於方向列向量；一維陣列的 `.T` 並不會改變形狀。程式刻意選非駐點核對方向導數，避免在兩邊都近零時得到缺乏辨識力的比較。

測試與預期結果

以下是**未執行的預期檢查**，不是測試紀錄。正常測試先檢查 `solution` 與 `f` 均長 $N - 1$ ，再檢查 `gradient(solution, f, h)` 的範數在合理浮點容差內接近零。解析解的節點值為 $\sin(\pi x_j)$ ；可隨分段數增加比較最大節點誤差，但有限次比較不能證明收斂階。方向導數測試應比較兩個有符號數值，再觀察其差額；中央差分的截斷誤差與浮點消去誤差都會受步長影響，不能要求每個步長都愈小愈好。週期相場測試同樣須確認 `W.shape == phi.shape`，並把差分結果與 `np.dot(phase_gradient(phi, hp, kappa), W)` 比較。

邊界測試方面，Dirichlet 的最小支援分段數是 $N = 2$ ：只有一個內點，

`solve_dirichlet(np.array([2.0]), 0.5)` 對應一階矩陣，`gradient` 仍須正確計入兩個零端點。週期相場只支援至少三個節點，以免本例的左右鄰點配置退化；常數 $\phi_i = 1$ 時，兩項的導數均為零，可用作另一個邊界核對，但不應只用這個駐點檢查差分。

故障測試可逐一向公開函數提供負 h 、零 h 、含 NaN 的資料、二維 `U`、與 `U` 長度不同的 `f`、長度少於三的 `phi`，以及負 κ ；預期均拋出 `ValueError`。例如 `energy(np.array([1.0]), np.array([1.0, 2.0]), 0.5)` 必須拒絕長度不合，而非讓陣列廣播掩蓋錯誤。即使這些輸入檢查與方向差分都符合預期，也只能支持指定實作的一致性，不能取代連續 Euler-Lagrange 推導或離散收斂證明。

反例與常見陷阱

駐點可能是最大值或鞍點。 在零端點擾動空間上， $J[u] = -\frac{1}{2} \int_0^1 (u')^2 dx$ 於 $u = 0$ 的第一變分為零，但任何非零擾動都令能量下降，所以它是嚴格全域最大值，而非最小值。若二階形式同時有正、負方向，駐點甚至沒有單一的極值型態；習題將給出可直接計算的例子。

逐方向正定不是一致下界。 無限維空間中，即使對每個非零方向都有 $D^2 J(u)[v, v] > 0$ ，其與 $\|v\|_X^2$ 的比值仍可能沿某些方向序列趨近零。此時不能套用本章的小命題。另一方面，一致強制性只是該命題的充分假設，並非所有嚴格極小值的必要條件；例如四次能量在原點可以嚴格極小，第二變分卻為零。

梯度不能脫離內積。 $DJ_h(U)[V]$ 是一個數； $\nabla_E J_h$ 是在歐氏內積下代表它的座標向量；若改選 $M = hI$ ，代表向量成為 $g_M = M^{-1} \nabla_E J_h$ 。因此錯誤的式子 $DJ_h(U)[V] = h(\nabla_E J_h)^T V$ 會重複計入權重。連續 L^2 或 H^1 梯度也須先證明相應 Riesz 代表存在，不能宣稱任何泛函的 L^2 梯度「就是函數本身」。

邊界與格點不可混用。 固定左端的例子只在右端推出自然條件。零 Dirichlet 節點配置有 $N - 1$ 個未知量；零通量的 cell 中心配置則把未知量放在每個 cell 中心，端點通量由邊界面指定。兩種配置的矩陣、求積權重與可解性條件不同，不能只改矩陣首末對角元卻保留原本的節點資料解釋。

AI、幾何與養殖案例

第三卷的相場應用可把本章的週期能量視為一個靜態離散泛函。局部勢能偏好 ϕ 靠近 1 或 -1 ，相鄰差分項懲罰劇烈空間變化。其歐氏梯度由每一個網格自由度的偏導組成；若用離散 L^2 內積 $h \sum_i a_i b_i$ ，梯度則是歐氏梯度除以 h 。計算第一變分或驗證這兩種表示的對應，並未證明任何 Allen–Cahn 或 Cahn–Hilliard 時間步進的穩定性、質量守恆或物理適用性。

一個與養殖資料有關、但完全合成且無因次的例子，是以平滑場 $u(x)$ 表示某項已標準化的空間偏差，令

$$J[u] = \frac{1}{2} \int_0^1 ((u - d)^2 + \alpha(u')^2) dx, \quad \alpha > 0.$$

這裡 x 是除以池段長度後的無因次位置， u 與目標 d 都已除以同一個參考尺度； α 是模型設定，不是已量測的物理常數。若兩端固定，容許擾動在兩端為零；若端點自由且解足夠光滑，第一變分給出內部方程 $u - d - \alpha u'' = 0$ 及兩端的自然條件 $u' = 0$ 。由平方項可見這是凸能量，但模型的數學性質不等於現場校準、設備控制能力或操作安全。

AI 工具在此最多唯讀整理所採用的無因次尺度、端點假設、能量式、方向導數核對與未驗證項目。若原始感測量帶有不同 SI 單位，須先分別記錄單位及參考尺度，才可形成上述無因次量；不能把不同單位的偏差直接相加，也不能讓模型輸出自行改變設備、投餌或加藥。

習題

1. **手算**。在 $u(0) = u(1) = 0$ 下，求 $J[u] = \int_0^1 ((u')^2 - u) dx$ 的 Euler–Lagrange 方程與光滑駐點，再用能量差判定其極值型態。
2. **程式與邊界**。改用 $N \geq 2$ 個等寬 cell 的中心值 U_i ，離散零通量問題 $-u'' = f$ 。寫出左右邊界面零通量所對應的矩陣 A 、相容條件，以及固定離散平均為零的增廣系統。提供自足程式，並說明對常數非零右端應如何處理；不得用加入 ϵI 冒充原問題。
3. **反例**。在 $H_0^1(0, 1)$ 上令 $J[u] = \frac{1}{2} \int_0^1 ((u')^2 - 2\pi^2 u^2) dx$ 。證明 $u = 0$ 是駐點，並找出一個使第二變分為負、另一個使其為正的方向。
4. **整合**。固定零端點，取 $J[u] = \frac{1}{2} \int_0^1 (u')^2 dx$ 。對足夠光滑且零端點的 u ，分別在 L^2 內積與 $\langle a, b \rangle_{H^1} = \int_0^1 (ab + a'b') dx$ 下定義梯度。寫出兩個 Riesz 表示所滿足的關係，並說明為何不能無條件把兩個梯度視為同一函數。

習題解答

1. 因 $L_u = -1$ 、 $L_{u'} = 2u'$ ，Euler–Lagrange 方程是 $-1 - 2u'' = 0$ ，即 $u'' = -1/2$ 。積分並代入兩個零端點，得到 $u^*(x) = x(1-x)/4$ 。對任意零端點擾動 v ，展開能量並用駐點方程消去交叉項：
 $J[u^* + v] - J[u^*] = \int_0^1 (v')^2 dx$ 。非零 v 不可能在零端點條件下導數恆為零，因此這是嚴格全域最小值。

2. 設 $h = 1/N$ ，未知數 $U_0, \dots, U_{N-1}$ 位於 cell 中心。內部面的通量由相鄰中心差分表示，兩個外邊界的通量指定為零。於是 $A = K/h^2$ ，其中 K 的首末對角元為 1、其餘對角元為 2、相鄰非對角元為 -1 ；例如 $N = 3$ 時

$$K = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{pmatrix}.$$

每一橫列的元素和為零，故 $A\mathbf{1} = 0$ ；對 $AU = f$ 求和，必要條件是 $h \sum_i f_i = 0$ 。由 $U^T K U = \sum_{i=0}^{N-2} (U_{i+1} - U_i)^2$ 可知零空間恰為常數向量，因此相容條件亦充分。平均零條件 $h\mathbf{1}^T U = 0$ 選出唯一代表。下列程式採用容差判定浮點資料的相容性；超過容差時明確拒絕，而不暗中改動右端：

```
import numpy as np

def solve_neumann_cells(f, h, tolerance=1e-12):
    a = np.asarray(f, dtype=float)
    if a.ndim != 1 or a.size < 2 or not np.all(np.isfinite(a)):
        raise ValueError("f must be a finite 1-D cell array, length >= 2")
    h = float(h)
    tolerance = float(tolerance)
    if not np.isfinite(h) or h <= 0:
        raise ValueError("h must be finite and positive")
    if not np.isfinite(tolerance) or tolerance < 0:
        raise ValueError("tolerance must be finite and nonnegative")
    if not np.isclose(a.size*h, 1.0, rtol=0, atol=tolerance):
        raise ValueError("cells must cover [0, 1]")
    if abs(h*np.sum(a)) > tolerance:
        raise ValueError("zero-flux right-hand side is incompatible")
    n = a.size
    K = np.diag(np.r_[1.0, np.full(n-2, 2.0), 1.0])
    K += np.diag(np.full(n-1, -1.0), 1)
    K += np.diag(np.full(n-1, -1.0), -1)
    A = K/h**2
    c = np.full(n, h)
    augmented = np.block([[A, c[:, None]],
                          [c[None, :], np.zeros((1, 1))]])
    answer = np.linalg.solve(augmented, np.r_[a, 0.0])
    return answer[:-1]

# 預期：零平均、相容的右端可求解。
u = solve_neumann_cells(np.array([1.0, -1.0]), 0.5)
# 預期：常數非零右端被拒絕，而不是產生原問題的解。
try:
    solve_neumann_cells(np.array([1.0, 1.0]), 0.5)
except ValueError as error:
    print(error)
```

增廣系統的最後一個方程是 $c^T U = 0$ 。對**精確相容**的資料，第一組方程中的乘數為零；使用浮點容差時仍應另外檢查 $\|AU - f\|$ 與 $|c^T U|$ ，不可只因線性求解器返回向量就宣稱滿足原方程。加入 ϵI 會改變方程，並不是另一種施加平均零條件的方法。

3. 此泛函是二次型，所以 $DJ(0)[v] = 0$ 對所有 $v \in H_0^1(0, 1)$ 成立，且 $D^2J(0)[v, v] = \int_0^1 ((v')^2 - 2\pi^2 v^2) dx$ 。取 $v_1 = \sin(\pi x)$ ，利用正弦、餘弦平方的積分均為 $1/2$ ，得到 $D^2J(0)[v_1, v_1] = -\pi^2/2$ 。取 $v_2 = \sin(2\pi x)$ ，則結果為 π^2 。由 $J[tv_i] - J[0] = t^2 D^2J(0)[v_i, v_i]/2$ ，任意小的非零 t 都能分別產生較低與較高的能量，故零函數是鞍點。
4. 在零端點擾動空間中， $DJ(u)[v] = \int_0^1 u'v' dx$ 。若 u 夠光滑且 $u'' \in L^2$ ，分部積分給出 $\int_0^1 (-u'')v dx$ ，所以此條件下的 L^2 代表元為 $g_{L^2} = -u''$ 。另一方面， H_0^1 配上題定的 H^1 內積是 Hilbert 空間；Riesz 表示給出唯一 $g_{H^1} \in H_0^1$ ，滿足

$$\int_0^1 (g_{H^1}v + g'_{H^1}v') dx = \int_0^1 u'v' dx \quad (v \in H_0^1(0, 1)).$$

若再有足夠正則性，可把它寫成弱邊值方程 $(I - \partial_{xx})g_{H^1} = -u''$ 、 $g_{H^1}(0) = g_{H^1}(1) = 0$ 。兩個代表元作用於方向後給出相同導數，但定義它們的內積不同；對一般 $u \in H_0^1$ ， $-u''$ 甚至未必屬於 L^2 ，此時不能先假設 L^2 梯度存在。

本章小結

變分推導必須先指定容許函數、擾動空間與範數。第一變分在所有容許方向為零，是內點極小的必要條件；分部積分給出內部 Euler-Lagrange 方程，自由端才另外給出自然邊界條件。第二變分的一致強制性連同駐點及二階小餘項，提供嚴格局部極小的充分條件；特定凸能量的全域性則可由能量差直接證明。

離散實作應從所寫下的能量重新求導：歐氏方向導數是座標梯度與同形狀方向的內積，改用離散 L^2 內積則要改變梯度代表。正常、邊界與故障輸入及非駐點方向差分均有明確的預期檢查，但本章沒有執行程式；有限次數值核對也不構成連續定理或收斂性的證明。

參考來源

- Daniel Liberzon, *Calculus of Variations and Optimal Control Theory*, 〈First variation〉、〈Euler-Lagrange equation〉與 〈Variable-endpoint problems〉。主編已取得所列網頁並局部核對自由端點的容許擾動與自然條件；此處不表示已逐條查核全書。
- Jiří Lebl, *Basic Analysis* 教材入口；用於分析先備概念的延伸閱讀，未宣稱已查核完整教材內容。
- MIT OCW 18.100A Real Analysis 與 MIT OCW 18.02SC Multivariable Calculus：先備分析與多變量微積分的課程入口；已取得的是課程概要，非逐條定理查證。

第30章 整合專題：可稽核的感測校準與分析

學習目標與先備知識

本章把局部微分、可辨識性、約束最佳化、積分單位與動態敏感度，組成一條可檢查、可重現的校準證據鏈。案例是完全合成的雙參數感測校準，不代表任何現場設備的性能，也不構成操作建議。

完成本章後，讀者應能：

1. 以明確的輸入、輸出和單位，寫出校準模型與殘差。
2. 以 Jacobian 的秩和奇異值判斷局部可辨識性的條件與限制。
3. 區分局部線性近似、有限差分核對與可微性證明。
4. 在參數界限下描述最小平方問題，並辨認約束活躍時的必要條件。
5. 追蹤時間積分的單位，並分清儀器讀值、模型預測與累積量。
6. 設計只讀分析流程，保存假設、尺度、誤差和失敗訊號，而不控制設備。

先備知識包括向量與矩陣、偏導與 Jacobian、梯度、Taylor 線性近似、最小平方和定積分。所有資料與參數均為合成值；SI 單位依量綱書寫。

問題與直覺

設有兩個無因次校準參數 θ_1, θ_2 ，以及兩支輸出單位為 mg/L 的感測通道。讀值不只由參數決定，也會隨合成環境量 T 改變。模型取為

$$s(T) = \begin{pmatrix} s_1(T) \\ s_2(T) \end{pmatrix} = \begin{pmatrix} 1 \\ 0.8 \end{pmatrix} + \begin{pmatrix} 1 + 0.1T & 0.2 \\ 0.3 & 0.9 - 0.05T \end{pmatrix} \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}, \quad T \text{ 的單位為 } ^\circ\text{C}.$$

其中矩陣元素皆按輸出單位 mg/L 解讀；0.1 與 0.05 的單位為 mg/(L · °C)。參數 θ_1, θ_2 無因次。

為了避免把量測直接當成真值，另外給定獨立合成參考值 $y(T) \in \mathbb{R}^2$ 。多個校準時刻的資料為 (T_k, y_k) ，模型殘差定義為

$$r_k(\theta) = s(T_k; \theta) - y_k.$$

參數以無因次尺度表示，兩個通道則同以 mg/L 表示，因此本例中的 Euclidean 殘差範數具有一致的輸出單位。若通道單位不同或量測不確定度不同，應先明示標準化或權重；不能直接把混雜物理單位的數字當成有意義的距離。

直覺上，若兩參數對輸出的影響方向幾乎相同，改變一個參數便能由另一個抵消，校準會對雜訊很敏感。增加資料點並非必然解決問題：重複同一環境下的同一種訊息，可能只降低隨機誤差，卻沒有提供新的參數方向。可稽核分析因此不只問「最小平方值多少」，還要問「資料在什麼條件下能區分參數」、「近似在哪個範圍有效」與「失敗時能否被辨認」。

定義、定理與推導

校準映射、Jacobian 與單位

對一般映射 $f: U \subset \mathbb{R}^n \rightarrow \mathbb{R}^m$ ，若 U 開， f 在 θ 可微是指存在線性映射 $J_f(\theta) \in \mathbb{R}^{m \times n}$ ，使得

$$f(\theta + h) = f(\theta) + J_f(\theta)h + \rho(h), \quad \frac{\|\rho(h)\|_2}{\|h\|_2} \rightarrow 0 \quad (h \rightarrow 0, h \neq 0).$$

這裡的 h 是 $n \times 1$ 直向量。Jacobian 的第 i, j 元單位為「第 i 個輸出單位／第 j 個輸入單位」。本例參數無因次，所以 J_s 每一元素的單位為 mg/L；環境量的偏導數則另帶有每攝氏度的單位。

令

$$A(T) = \begin{pmatrix} 1 + 0.1T & 0.2 \\ 0.3 & 0.9 - 0.05T \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 0.8 \end{pmatrix}.$$

模型 $s(T; \theta) = b + A(T)\theta$ 對 θ 是仿射函數，故其參數 Jacobian 為

$$J_\theta s(T; \theta) = A(T).$$

對不同 T_k 堆疊資料，定義

$$F(\theta) = \begin{pmatrix} s(T_1; \theta) \\ \vdots \\ s(T_N; \theta) \end{pmatrix}, \quad Y = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix}.$$

則 $F(\theta) = B\theta + c$ ，其中 B 是把各個 $A(T_k)$ 依序縱向堆疊而成的 $2N \times 2$ 矩陣， c 則堆疊相同的基準向量 b 。無權重平方損失為

$$L(\theta) = \frac{1}{2} \|F(\theta) - Y\|_2^2, \quad \nabla L(\theta) = B^T(F(\theta) - Y), \quad \nabla^2 L(\theta) = B^T B.$$

若有可信的誤差標準差 $\sigma_i > 0$ ，可令 $W = \text{diag}(\sigma_i^{-2})$ ，使用 $L_W = \frac{1}{2}(F - Y)^T W (F - Y)$ 。此時權重提供無因次的加權殘差平方；其意義取決於標準差模型是否合理，不能只為改善數值結果而任意調整。

定義：局部可辨識性的線性化檢查

若 $J_F(\theta_*)$ 對參數具有滿列秩 n ，則在 θ_* 附近，參數的小變化會產生彼此可區分的線性化輸出變化。這是局部可辨識的常用充分檢查，不等於整個非線性模型在全域一對一。

本章案例對參數是仿射的，因此若 B 滿列秩，映射 $\theta \mapsto B\theta + c$ 在全域一對一。反過來，若 B 不滿列秩，存在非零 v 使 $Bv = 0$ ，於是所有 θ 與 $\theta + tv$ 都有同一預測輸出，參數便無法由這批資料唯一決定。對一般非線性模型，即使某點 Jacobian 可逆，也只支持該點附近的局部結論，不排除遠處存在另一組參數得到相

同輸出。

秩是定性的；奇異值則描述穩定性。最小奇異值很小時，資料雖可能在精確算術下滿秩，反演仍可能放大測量誤差。須一併報告參數尺度、輸出尺度、單位與所用範數，才可解讀奇異值與條件數。

命題：滿列秩保證本例無約束平方損失有唯一極小點

命題。 若合成設計矩陣 $B \in \mathbb{R}^{m \times n}$ 滿列秩，則對任意 $Y, c \in \mathbb{R}^m$ ，

$$L(\theta) = \frac{1}{2} \|B\theta + c - Y\|_2^2$$

有唯一全域極小點 $\hat{\theta}$ ，且滿足 $B^T(B\hat{\theta} + c - Y) = 0$ 。

證明。 對任意非零直向量 $v \in \mathbb{R}^n$ ，因 B 滿列秩， $Bv \neq 0$ 。故

$$v^T B^T B v = \|Bv\|_2^2 > 0.$$

所以 $B^T B$ 正定，損失的 Hessian 正定。由 L 是有限維二次函數可知其梯度為 $B^T(B\theta + c - Y)$ 。正定 Hessian 表示 L 嚴格凸，且二次項沿每個非零方向均正；因此損失在遠離原點時趨向無窮，必有極小點，嚴格凸性又保證該點唯一。極小點的梯度必為零，得到所述方程。這是本模型下的解析結論；若 B 不滿列秩，該命題的關鍵前提失效，不能沿用唯一性結論。□

參數界限與約束最佳化

若參數具有合成容許範圍，例如

$$0 \leq \theta_1 \leq 2, \quad 0 \leq \theta_2 \leq 2,$$

則問題是在線段組成的閉矩形上最小化 L 。由於該集合在有限維歐氏空間中閉且有界，故緊緻；連續函數 L 在其上取得最小值。但全域最小點可能位於邊界，不能只解無約束梯度方程。

可以列舉內部、四條邊與四個角落候選點，或使用具界限的最佳化方法。所得結果須核對參數是否可行、梯度是否符合邊界方向的必要條件、損失是否未增加，以及是否遭遇病態或數值失敗。求解器回報成功不會自動證明資料合理、模型正確或解是全域最佳。

積分量與動態敏感度的證據界線

若某通道的濃度讀值 $C(t)$ 以 mg/L 表示，水量 $Q(t)$ 以 L/s 表示，則流量加權輸送率

$$p(t) = C(t)Q(t)$$

的單位為 mg/s ，其時間積分 $\int_{t_0}^{t_1} p(t) dt$ 的單位為 mg 。若要把讀值換成區間總量，必須說明時間單位、取樣代表方式、缺值處理，以及 C, Q 是否在區間內經過適當校準。梯形法只是給定端點資料下的一種近似；未有光滑性或誤差界條件時，有限網格的答案不能冒充真實積分的證明。

對動態狀態 $z(t)$ ，若狀態方程和輸入也依參數 θ 改變，動態敏感度 $S(t) = \partial z(t)/\partial \theta$ 通常須由變分方程、差分近似或其他有明確假設的方法取得。有限時間模擬或參數有限差分只能提供數值證據。它不能單獨證明對所有時間穩定，也不能把數學模型的穩定性等同操作安全。

逐步手算例題

例一：單一環境點的局部可辨識性

取 $T = 0^\circ\text{C}$ ，則

$$A(0) = \begin{pmatrix} 1 & 0.2 \\ 0.3 & 0.9 \end{pmatrix}, \quad \det A(0) = 0.9 - 0.06 = 0.84 \neq 0.$$

因此兩個通道的線性變化方向獨立，這一環境下的兩參數線性模型滿秩。在本例的仿射模型中，若無雜訊且兩個輸出參考值一致，參數能唯一反解。

例如取 $\theta = (0.5, 1)^T$ ，預測為

$$s(0; \theta) = \begin{pmatrix} 1 \\ 0.8 \end{pmatrix} + \begin{pmatrix} 1 & 0.2 \\ 0.3 & 0.9 \end{pmatrix} \begin{pmatrix} 0.5 \\ 1 \end{pmatrix} = \begin{pmatrix} 1.7 \\ 1.85 \end{pmatrix} \text{ mg/L}.$$

小參數擾動 $h = (0.01, -0.02)^T$ 造成輸出變化

$$A(0)h = \begin{pmatrix} 0.006 \\ -0.015 \end{pmatrix} \text{ mg/L}.$$

因為模型對參數恰為仿射，這個線性變化不是近似，而是精確變化。不能將此精確性推廣到未寫進模型的真實感測過程。

例二：兩個時刻的合成平方損失

取 $T_1 = 0^\circ\text{C}$ 、 $T_2 = 10^\circ\text{C}$ 。堆疊設計矩陣為

$$B = \begin{pmatrix} 1 & 0.2 \\ 0.3 & 0.9 \\ 2 & 0.2 \\ 0.3 & 0.4 \end{pmatrix}.$$

取合成參數 $\theta_* = (0.5, 1)^T$ ，並假設參考值正好等於模型值，則 $Y = B\theta_* + c$ 。對估計值 $\theta = (0.6, 0.9)^T$ ，誤差為 $h = (0.1, -0.1)^T$ ，堆疊殘差為

$$Bh = \begin{pmatrix} 0.08 \\ -0.06 \\ 0.18 \\ -0.01 \end{pmatrix} \text{ mg/L.}$$

因此

$$L(\theta) = \frac{1}{2}(0.08^2 + 0.06^2 + 0.18^2 + 0.01^2) = 0.0225 \text{ (mg/L)}^2.$$

手算顯示損失是加總所有輸出殘差平方，不是先把各輸出平均後再平方。若不同通道的誤差尺度不同，需先說明權重。

此設計的兩個欄向量為 $u = (1, 0.3, 2, 0.3)^T$ 、 $v = (0.2, 0.9, 0.2, 0.4)^T$ 。其 Gram 矩陣為

$$B^T B = \begin{pmatrix} 5.18 & 0.99 \\ 0.99 & 1.05 \end{pmatrix}.$$

行列式為

$$5.18(1.05) - 0.99^2 = 4.4589 > 0.$$

首項為正且行列式為正，故此對稱矩陣正定；這再次核對滿列秩與命題中的唯一性條件。

實作與程式

以下程式只使用 Python 標準函式庫與 NumPy，在 CPU 上計算本章的合成模型、解析 Jacobian、中心有限差分核對、殘差比、梯形積分與簡單的盒限制投影梯度下降。此程式不是通用最佳化器，不檢查真實儀器，也不連接任何設備。此處未執行程式；結果是理論預期，須在實際執行環境獨立核對。

```
import numpy as np

# theta: 無因次; s: mg/L; T: 攝氏度。
def A_of_T(T):
    T = float(T)
    return np.array([
        [1.0 + 0.1 * T, 0.2],
        [0.3, 0.9 - 0.05 * T],
    ], dtype=float)

def predict(theta, T):
    theta = np.asarray(theta, dtype=float).reshape(2, 1)
    base = np.array([[1.0], [0.8]])
    return (base + A_of_T(T) @ theta).reshape(2)

def stacked_prediction(theta, temperatures):
    return np.concatenate([predict(theta, T) for T in temperatures])

def design_matrix(temperatures):
```

```

    return np.vstack([A_of_T(T) for T in temperatures])

def residual_vector(theta, temperatures, references):
    references = np.asarray(references, dtype=float).reshape(-1)
    return stacked_prediction(theta, temperatures) - references

def loss_and_gradient(theta, temperatures, references):
    B = design_matrix(temperatures)
    r = residual_vector(theta, temperatures, references)
    loss = 0.5 * float(r @ r)
    gradient = B.T @ r
    return loss, gradient

def central_jacobian(fun, x, step=1e-6):
    x = np.asarray(x, dtype=float).reshape(-1)
    y0 = np.asarray(fun(x), dtype=float).reshape(-1)
    J = np.empty((y0.size, x.size), dtype=float)
    for j in range(x.size):
        e = np.zeros_like(x)
        e[j] = step
        J[:, j] = (
            np.asarray(fun(x + e)).reshape(-1)
            - np.asarray(fun(x - e)).reshape(-1)
        ) / (2.0 * step)
    return J

def projected_gradient_descent(
    temperatures, references, initial, lower, upper,
    step_size=0.05, max_iter=2000, grad_tol=1e-10
):
    theta = np.clip(
        np.asarray(initial, dtype=float),
        np.asarray(lower, dtype=float),
        np.asarray(upper, dtype=float),
    )
    lower = np.asarray(lower, dtype=float)
    upper = np.asarray(upper, dtype=float)
    history = []

    for _ in range(max_iter):
        loss, grad = loss_and_gradient(theta, temperatures, references)
        trial = np.clip(theta - step_size * grad, lower, upper)
        trial_loss, _ = loss_and_gradient(trial, temperatures, references)
        history.append((loss, float(np.linalg.norm(grad)), theta.copy()))

        # 固定步長版本遇到不下降便停止並回報，不暗中稱為收斂。
        if trial_loss > loss + 1e-14:
            return theta, history, "step_rejected"
        if np.array_equal(trial, theta):
            return theta, history, "projected_step_zero"
        theta = trial
        if np.linalg.norm(grad) <= grad_tol:
            return theta, history, "gradient_tolerance"

    return theta, history, "iteration_limit"

def trapezoid_integral(time_s, rate_mg_per_s):
    time_s = np.asarray(time_s, dtype=float)
    rate_mg_per_s = np.asarray(rate_mg_per_s, dtype=float)

```

```

if time_s.ndim != 1 or rate_mg_per_s.ndim != 1:
    raise ValueError("輸入必須是一維時間序列")
if time_s.size != rate_mg_per_s.size or time_s.size < 2:
    raise ValueError("時間與率必須等長，且至少含兩點")
if not np.all(np.isfinite(time_s)) or not np.all(np.isfinite(rate_mg_per_s)):
    raise ValueError("不接受 NaN 或無限值")
dt = np.diff(time_s)
if np.any(dt <= 0):
    raise ValueError("時間必須嚴格遞增")
return float(np.sum(0.5 * (rate_mg_per_s[:-1] + rate_mg_per_s[1:]) * dt))

if __name__ == "__main__":
    temperatures = np.array([0.0, 10.0])
    true_theta = np.array([0.5, 1.0])
    references = stacked_prediction(true_theta, temperatures)

    theta0 = np.array([0.6, 0.9])
    B = design_matrix(temperatures)
    analytic_J = B
    numeric_J = central_jacobian(
        lambda th: stacked_prediction(th, temperatures), theta0
    )
    jacobian_error = np.linalg.norm(analytic_J - numeric_J, ord=2)

    residual = residual_vector(theta0, temperatures, references)
    loss, gradient = loss_and_gradient(theta0, temperatures, references)
    linear_prediction = stacked_prediction(theta0, temperatures) + B @ (
        true_theta - theta0
    )
    remainder = (
        stacked_prediction(true_theta, temperatures) - linear_prediction
    )
    denominator = np.linalg.norm(true_theta - theta0)
    remainder_ratio = np.linalg.norm(remainder) / denominator

    fit, history, status = projected_gradient_descent(
        temperatures, references,
        initial=np.array([0.0, 0.0]),
        lower=np.array([0.0, 0.0]),
        upper=np.array([2.0, 2.0]),
    )

    area_mg = trapezoid_integral(
        np.array([0.0, 1.0, 2.0]),
        np.array([2.0, 2.0, 2.0]),
    )

    print("解析 Jacobian:\n", analytic_J)
    print("有限差分 Jacobian 誤差:", jacobian_error)
    print("參數擾動:", true_theta - theta0)
    print("殘差:", residual)
    print("損失:", loss)
    print("梯度:", gradient)
    print("局部近似餘項比:", remainder_ratio)
    print("估計參數、狀態:", fit, status)
    print("常率積分預期為 4 mg；程式值:", area_mg)

```

在這個線性參數模型中，只要浮點誤差可忽略，參數方向的餘項應接近零；在任意步長與有限精度下，不應要求浮點結果恰為零。有限差分 Jacobian 誤差也受步長與捨入影響，不宜只挑一個步長就宣稱導數已被證明。程式中的固定步長投影法只適合此小型教學案例；若回報 `step_rejected` 或 `iteration_limit`，應記為失敗訊號，而不是略過。

測試與預期結果

類別	測試	預期與判讀
正常	以兩個時刻建立 B ，比較解析 Jacobian 與中心差分	Jacobian 形狀應為 4×2 ；差異應受浮點精度與差分步長影響
正常	使用例二的 θ_* 作參考，再由界限內初值估計	損失應下降並接近零；不能以「接近」取代參數可辨識條件的檢查
正常	對常率 2 mg/s，在 $[0, 2]$ 秒作梯形積分	預期為 4 mg
邊界	令初值超出參數界限	投影後的初值應落在界限上；若解位於邊界，應報告活躍界限
邊界	只用單一通道且設計矩陣只有一列	兩個參數不可能由一個純量方程唯一決定；檢查程序不得假稱滿列秩
故障	時間點重複、倒序、資料含 NaN	積分函數預期明確拒絕輸入，不應回傳看似有效的總量
故障	固定步長令試探步造成損失增加	最佳化器應回報 <code>step_rejected</code> ；應調整演算法或檢查尺度，不能偽報成功
故障	用多組高度相似的敏感度欄向量校準	矩陣即使形式上滿秩，最小奇異值仍可能很小；應標記病態與對雜訊敏感

表列的是預期測試，不是已執行的紀錄。實際報告應保留程式版本、資料、參數界限、停止狀態、Jacobian 檢查方法、損失定義與未通過測試，不得事後刪除不利結果。

反例與常見陷阱

1. **有限個方向不能證明可微。** 即使沿多條線測得的導數吻合，也不能推出所有趨近方向的餘項比都趨零。必須證明所需的極限，或清楚標示結果僅是數值支持。
2. **偏導存在不等於可辨識。** 可微模型在某點的 Jacobian 若不滿列秩，線性化有不可區分的參數方向；即便殘差為零，也可能有多組參數。

3. **滿秩不等於穩定**。例如兩欄幾乎平行的設計矩陣仍可能滿秩，但微小量測誤差足以造成很大的參數改變。應檢查尺度化後的奇異值與條件數。
4. **局部可逆不等於全域唯一**。對一般非線性校準模型，可逆 Jacobian 保證的是適當鄰域內的局部結論，不足以排除其他相距甚遠的可行解。
5. **梯度為零不代表受限最小**。在參數盒的邊界，需檢查可行方向上的一階條件；只將無約束梯度解截斷，不等於解了受約束問題。
6. **積分近似不等於積分真值**。若以不規則取樣資料套用梯形法，漏掉資料缺口或時間單位換算，結果即使數值精確也可能量綱錯誤。沒有誤差估計時須標為近似。
7. **模型穩定不等於現場安全**。離散資料上的殘差、敏感度或狀態軌跡，只支持指定模型和指定範圍內的數學檢查，不能替代儀器驗證、風險評估或合格人員判斷。
8. **用未加權 Euclidean 範數混合單位**。若一個分量以攝氏度、另一個以毫克每升表示，直接平方相加沒有一致的物理意義。應依量測不確定度標準化，並同時保留原始單位報告。
9. **把差分吻合說成解析證明**。數值導數取決於步長、捨入與實際程式路徑；差分只能核對特定點附近的實作，不能證明全域性質。

AI、幾何與養殖案例

可稽核證據鏈

合成養殖案例可假設通道輸出是某種濃度指標，環境量是水溫，參數是兩個無因次校準係數。應將下列資訊一併保存：

- 原始讀值、參考值、單位、時間戳記與資料缺失標記。
- 前處理、模型公式、參數尺度與參數界限。
- Jacobian 的解析式或計算方式、數值核對方法與測試步長。
- 殘差、損失、秩、奇異值與病態警訊。
- 積分的被積函數、時間單位、取樣間隔與近似方法。
- 求解器停止狀態、失敗測試、人工覆核狀態與限制說明。

AI agent 在此案例中是**唯讀分析器**：可以整理資料、重新計算診斷量、產生差異報告，並指出證據不足的環節；不可以直接寫入儀器參數、啟動控制程序、改變投餌或加藥。當校準結果異常、模型不一致、資料缺失，或程式測試未通過時，應停止自動結論並交由適當人員覆核。

幾何與數值尺度

在此問題中， B 的每個欄向量代表一個參數對多個輸出的影響方向，屬於輸出空間 $\mathbb{R}^{2N}$ 。兩欄的夾角越小，參數越難區分；但夾角與條件數會受參數及輸出的尺度選擇影響。因此，應先說明參數如何無因次化、輸出如何按誤差尺度標準化，再解讀行空間（column space，位於 $\mathbb{R}^{2N}$ 的子空間）或奇異值。若採用變數替換 $\theta = Dq$ ，則新 Jacobian 為 BD ；這會改變數值尺度，不會憑空增加實際量測資訊。

動態敏感度

若校準映射取用一段時間的讀值而非單一時刻，觀測映射可寫為 $F(\theta) = \mathcal{O}(z(\cdot; \theta))$ ，其中 z 是動態狀態， $\mathcal{O}$ 是取樣或積分觀測方式。此時 Jacobian 的每欄可解讀為一個參數擾動對觀測序列的局部影響。要使這個解讀成立，須先明確說明狀態方程、初始條件、觀測時間和參數依賴關係。有限差分軌跡只能核對所選參數與時間範圍，不能替代動態方程的存在唯一條件或穩定性證明。

習題

1. **手算**。對 $T = 0$ ，求模型在 $\theta = (0.5, 1)^T$ 的預測。再計算參數擾動 $h = (0.02, 0)^T$ 對兩個輸出的變化，並解釋其單位。
2. **手算與可辨識性**。單獨使用 $T = 10$ 時刻的兩個通道，求 $A(10)$ 的行列式，判斷本例仿射模型能否唯一辨認兩個參數。
3. **反例**。假設觀測模型明確為仿射方程 $d = \theta_1 + 2\theta_2$ ，其中 d 是一筆精確讀值。證明這筆讀值仍不能唯一決定兩參數，並指出其 Jacobian 的秩條件為何失敗。
4. **程式分析**。說明中心差分 Jacobian 為何要逐個輸入座標擾動。若把差分步長從 10^{-6} 改成極小數，結果一定更準嗎？列出兩個相反方向的誤差來源。
5. **整合與單位**。假設 $C(t)$ 以 mg/L 表示、 $Q(t)$ 以 L/s 表示，求 $C(t)Q(t)$ 和 $\int_0^{60} C(t)Q(t) dt$ 的單位。若把時間以分鐘輸入而仍把 Q 當作每秒流量，會發生什麼錯誤？
6. **整合與失效報告**。一次受界限校準給出邊界解，最小奇異值很小，且固定步長程式回報 `step_rejected`。寫出一段不少於三項的可稽核報告內容，並說明為何不能直接宣稱校準成功。

習題解答

1. **解**。預測為

$$\begin{pmatrix} 1 \\ 0.8 \end{pmatrix} + \begin{pmatrix} 1 & 0.2 \\ 0.3 & 0.9 \end{pmatrix} \begin{pmatrix} 0.5 \\ 1 \end{pmatrix} = \begin{pmatrix} 1.7 \\ 1.85 \end{pmatrix} \text{ mg/L.}$$

因模型對參數仿射，擾動造成的變化精確等於

$$A(0) \begin{pmatrix} 0.02 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.02 \\ 0.006 \end{pmatrix} \text{ mg/L.}$$

參數無因次，因此 Jacobian 的輸出單位為 mg/L，擾動後輸出仍以該單位表示。

2. **解**。 $A(10) = \begin{pmatrix} 2 & 0.2 \\ 0.3 & 0.4 \end{pmatrix}$ ，所以

$$\det A(10) = 2(0.4) - 0.2(0.3) = 0.74 \neq 0.$$

該單一環境時刻的兩通道矩陣可逆。因此對本例的無雜訊仿射模型，若參考讀值相容，兩個參數唯一。這個結論不代表實際量測不受雜訊影響，也不保證其他非線性模型全域一對一。

3. 解。方程只提供 $\theta_1 + 2\theta_2 = d$ 一個條件。若 (a, b) 是一組解，則對任意實數 t ， $(a - 2t, b + t)$ 也滿足同一方程。其 Jacobian 為 1×2 矩陣 $(1, 2)$ ，秩為 1，低於參數數目 2，不滿列秩。因此存在不可辨識的參數方向，這筆讀值不能唯一決定兩個參數。
4. 解。每欄對應一個輸入座標方向的偏導，故需逐欄分別施加擾動。步長過大會使有限差分的截斷誤差增大；步長過小則可能使兩個幾乎相同的函數值相減而放大浮點捨入誤差。故不能只說步長越小越準；須結合尺度、精度、步長掃描與解析結果核對。
5. 解。 CQ 的單位是 mg/s ；以秒為積分變數積分後是 mg 。若 Q 仍按每秒解讀，時間卻以分鐘數值積分，數值會少一個 60 倍的換算因子。應把時間換成秒，或把率改寫成每分鐘，並在報告中標明。
6. 解。報告至少應記錄：邊界參數值及哪些界限活躍；參數界限與目標函數定義；尺度化方法及最小奇異值診斷；固定步長拒絕步驟的狀態；殘差與資料品質；未通過測試及下一步覆核要求。小奇異值代表參數可能對雜訊高度敏感，`step_rejected` 又表示所用迭代程序沒有接受試探步；兩者都不能略去。邊界解也必須依受限問題的條件判讀。因此應報告「校準程序未能以此證據確認成功」，而不是只憑一個輸出參數宣稱有效。

本章小結

感測校準的可信度不由單一最小損失決定。可稽核的證據鏈至少包括明確的模型與單位、具有適當秩的 Jacobian、對條件數和尺度的檢查、正確處理參數約束、可說明誤差界線的局部近似，以及符合量綱的時間積分。

對本章的仿射模型，滿列秩可證明無約束平方損失具有唯一全域極小點；這是一項有清楚假設的數學結論。中心差分、求解器狀態與有限取樣則只是對程式和特定資料的檢查，不能冒充微分性、全域唯一性或現場可靠性的證明。所有資料皆為合成資料，AI agent 僅作唯讀分析，不控制設備或改變養殖操作。

參考來源

- A1. Jiří Lebl, *Basic Analysis*，作者目錄與教材入口：<https://www.jirka.org/ra/>
- A2. MIT OpenCourseWare, *18.100A Real Analysis*：<https://ocw.mit.edu/courses/18-100a-real-analysis-fall-2020/>
- A3. MIT OpenCourseWare, *18.02SC Multivariable Calculus*：<https://ocw.mit.edu/courses/18-02sc-multivariable-calculus-fall-2010/>
- A4. JAX, *Autodiff Cookbook: JVP/VJP*，延伸參考：
https://docs.jax.dev/en/latest/notebooks/autodiff_cookbook.html
- A6. SciPy, `minimize` API，延伸參考：
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>

本章的核心程式僅使用 Python 與 NumPy，不要求 SciPy、JAX 或 GPU。參考來源提供延伸閱讀，不表示已逐條核對教材中的所有定理。

附錄：符號、證據與驗收索引

共同符號

- x 、 h ：輸入及擾動；數學上為 $n \times 1$ column向量。
- f ：從 R^n 到 R^m 的映射； Df 是線性導數， Jf 是其 $m \times n$ 矩陣。
- 梯度：標量函數的Euclidean直向量；其轉置表示標量導數。
- H ：Hessian； $C2$ 鄰域是常用的對稱充分條件。
- Jv 及 $J^T w$ ：分別為JVP與VJP的column表示。
- $c=0$ 、 $g \leq 0$ ：等式與不等式約束； $L=f+\lambda^T c$ 或加入 $\lambda^T g$ ，後者 $\lambda \geq 0$ 。
- 普通換變數用Jacobian行列式的絕對值；取向積分另處理符號。

驗收問題

公式在哪個域成立？需要幾階連續可微？條件是必要還是充分？例題位於內點還是邊界？是否有秩退化或零空間？局部結論能否推到全域？使用哪個範數？是否混合不同單位？有限維結論是否被誤用到函數空間？

數值測試至少包括解析對照、維度、有限輸入、退化情況與步長變化。觀測收斂階要有實際紀錄，未執行只能列預期。校準成功不等於物理Validation；模型審稿不代替人工數學審查。

檔案與限制

章稿、審稿、修補、原始事件及版本備份分開保存。`examples/analysis_lab.py` 是主編另寫的標準庫起步測試，不載入模型生成程式。40角色使用按章／部區分的session，角色數不是同時執行程序數，也不是作業系統沙箱。

參考來源

2026-10-05已取得A1作者目錄頁、A2／A3課程概要與A4～A6 API文件。未讀完教材PDF或完整課程，未執行外部程式，也不代表全卷定理逐條查證。A1的舊htmlv2路徑404，合併html入口未能擷取，故只把作者首頁標作已取得。JAX及SciPy為延伸參考，核心不要求JAX、自動微分框架或GPU；API線上版本可能不同於本機。

- [A1] Jiří Lebl：Basic Analysis（作者目錄與教材入口）
- [A2] MIT OCW 18.100A Real Analysis
- [A3] MIT OCW 18.02SC Multivariable Calculus
- [A4] JAX Autodiff Cookbook：JVP／VJP
- [A5] SciPy矩陣指數expm
- [A6] SciPy minimize參數與方法

出版與字型授權

本版由既有Markdown排版，未執行章內程式碼。字型：Noto Sans CJK TC（SIL Open Font License 1.1）；數學排版：KaTeX（MIT）。全文來源SHA-256：c6ee30159bc11991294cb72cd3c13c921d087ce3b5299e706db2d01a44c9ea74。

► 字型與數學排版授權全文