

從生成式 AI 到智慧水產養殖：線性代數、多模態與 Agent 實作

線性代數 × 生成式 AI × 多模態 × Agent × 水產養殖

20章 · 50,062 中文字


模型審稿完成，仍待人工審定。

模型審稿不等於人工數學驗證；所有養殖案例為合成教學資料。

內容版本：2026-10-01T10:43:17.556030

HTML／PDF 圖文出版版

本書的共同主軸



目錄

1. 導讀：先理解表示，再理解決策
2. 第01章 從生成式AI問題看見線性代數
3. 第02章 向量、內積與相似度
4. 第03章 矩陣與線性映射
5. 第04章 線性方程、消去法與秩
6. 第05章 子空間、基底與座標
7. 第06章 正交、投影與最小平方
8. 第07章 特徵值、對稱矩陣與穩定性
9. 第08章 奇異值分解與低秩近似
10. 第09章 共變異數、PCA與資料洩漏
11. 第10章 範數、條件數與正則化
12. 第11章 梯度、Jacobian與反向傳播
13. 第12章 Embedding、線性層與機率輸出
14. 第13章 注意力的矩陣運算
15. 第14章 低秩更新與LoRA
16. 第15章 潛在空間、VAE與擴散模型
17. 第16章 影像、文字與水質的共同表示
18. 第17章 時間序列、缺值與狀態估計
19. 第18章 Agent的檢索、記憶與工具介面
20. 第19章 風險、限制與人類覆核
21. 第20章 專題：可稽核的養殖決策輔助系統
22. 附錄：共用符號、資料與驗收清單
23. 參考來源

導讀：先理解表示，再理解決策

生成式人工智慧可以把一段描述接成下一段文字，把文字提示轉成影像，也能根據多種輸入提出下一步行動。這些能力容易讓人把「流暢」誤認成「理解」，把「能提出建議」誤認成「能安全執行」。本書選擇從線性代數開始，目的不是把每個模型都簡化成矩陣乘法，而是建立一套能逐步核對的語言：資料是什麼形狀？運算保留了什麼資訊？哪些假設沒有被檢查？當輸出有誤時，我們究竟能追查到哪一層？

全書以一座虛構的水產養殖池「池A」為共同場景。工作人員記錄水溫、溶氧與酸鹼值，攝影機提供水面畫面，值班日誌記下清潔、設備維護與人員觀察。讀者不需要有養殖背景；本書也不會替真實物種設定生存或操作閾值。場景的作用是讓抽象數學一直對應到資料、感測誤差、時間與責任，而不是給出可直接部署的養殖配方。

最初，池A只是幾個數字。我們把它們整理成向量，比較方向與距離，再學會用矩陣描述多筆量測和特徵轉換。接著，線性方程告訴我們何時能唯一解出未知數；秩與零空間則揭示資料不能告訴我們什麼。這一步十分重要：擁有更多欄位，不一定擁有更多獨立資訊。

到了投影、最小平方與矩陣分解，我們開始處理「答案不可能完全吻合資料」的情況。與其強求每筆量測都被解釋，不如明確定義誤差、比較可行模型並記錄限制。PCA與低秩近似能壓縮表示，但被丟掉的小變異不一定沒有安全意義。數值穩定性也不是程式細節；若微小輸入擾動造成巨大係數變化，再漂亮的公式都可能在現場失效。

生成式AI部分把這些觀念接到embedding、線性層、attention與低秩適配。你會看到向量與矩陣如何支撐模型，也會看到線性代數不能單獨解釋的地方：機率模型、非線性函數、資料選擇與訓練目的。讀者不需要先下載大型模型，就能用小型數值例觀察運算；理解三個token的attention，比不明所以地呼叫大型API更適合作為起點。

多模態部分把水質、影像與文字放回同一條資料路徑。不同模態具有不同單位、採樣頻率、延遲和缺值方式；把向量串接起來不代表問題已解決。模型必須說清楚如何對齊時間、如何處理缺失，以及什麼情況下應回報「資料不足」。特徵對齊與語義對齊也不是同一件事，相似分數不能直接當成健康診斷。

最後，agent利用檢索工具查找有來源的作業文件，整理觀察並提出待覆核的建議。本書刻意把建議與設備控制分開。讀者可以在模擬環境完成資料讀取、檢索、風險檢查與審批記錄，但所有真實增氧、投餌、加藥與水體管理仍需由專業人員制定規範並驗證。即使公式正確，感測器位置、物種差異或過時文件仍可能讓決策失效。

如何閱讀與驗證

建議依章節順序閱讀。每章先讀場景問題，自己完成手算，再對照推導與答案；程式實驗用來驗證計算，不是代替思考。遇到公式時先寫出每個物件的shape，再問乘法是否合法、假設是否成立、結果的單位是否合理。遇到圖表時則檢查它代表真實資料、合成資料，還是概念示意。

習題包括基本計算、觀念辨析與養殖應用。應用題通常不只有一個數字答案，而要求說清楚資料限制與判斷依據。若你可以寫出「不知道，因為缺少哪些資料」，而不是硬給一個結論，便已掌握本書重要的學習成果。

本書以Markdown為主，公式採LaTeX語法，原創圖表採本地SVG。 `examples/linalg_lab.py` 是由編輯端另行撰寫的基礎驗證程式；章節內模型生成的其他片段並不因此自動取得「已測試」資格。出版前仍應由人類教師檢查推導、例題、程式與來源。字數報告只計中文字元，不把長程式碼當作充足教學內容。

學習路徑

- 想補數學基礎：先完成第1～10章，能解釋解的存在性、投影、分解與數值誤差。
- 想理解生成式AI：在前述基礎上完成第11～15章，逐步核對張量形狀與非線性邊界。
- 想做多模態系統：接續第16～17章，重視時間對齊、資料切分與缺值。
- 想做agent：完成第18～20章，把來源、工具、人工覆核與可重現評估放進設計。

這些路徑不是互不相關的選修。全書的共同問題始終是：如何讓每個計算步驟都能被理解、被檢查，並在不確定時保留拒絕行動的能力？

第01章 從生成式AI問題看見線性代數

學習目標與先備知識

讀完本章，你應該能夠：用標量、向量、矩陣、張量描述一筆養殖資料的形狀（shape）與單位；把「模型輸出」和「真實現況」分開看待；並寫出第一個 $y = Wx$ 的最小數值例子。先備知識只要高中數學的座標與乘法，以及看得懂 for 迴圈與串列（list）。本章不預設你懂微積分、機率或深度學習，這些會在後面章節逐步補上。

全書用同一個虛構案例貫穿：虛構池A的水質感測器、水面影像與工作日誌。這套資料全是教學合成，不含任何真實物種的適用閾值，也不能拿去操作真實設備。閱讀時請把「這是用來練習符號的假資料」放在心上，不要把書中任何數字當成現場標準。

從池A提出問題

假設池A週邊有三種量測：水溫 `temperature_c`（攝氏）、溶氧 `do_mg_l`（mg/L）、酸鹼值 `ph`（無量綱）。某日感測器每十分鐘回報一次，於是「一個時間點」是一個長度為3的向量，「一整天」是一疊向量。管理員又上傳了一張水面影像，並在日誌寫下「池水看起來偏濁」。最後他們希望一個 agent 能讀懂這些材料，查詢標準作業程序（SOP），提出唯讀的檢查計畫。

要讓電腦處理這串問題，第一步不是選模型，而是寫**資料字典**：每一欄叫什麼、是什麼單位、形狀多大、缺值怎麼標。以下是池A的最小字典草稿。

名稱	型別	形狀	單位	備註
<code>temperature_c</code>	標量	1	攝氏	單一感測器讀值
<code>sensor_vec</code>	向量	3	混合	一筆時間點觀測 $[t, do, ph]$
<code>day_matrix</code>	矩陣	$n \times 3$	混合	每列一筆觀測
<code>image_patch</code>	張量	$H \times W \times C$	灰階或RGB	影像區塊
<code>log_token</code>	離散	序列	—	文字切詞
<code>tool_call</code>	結構化	dict	—	欄位依 SOP 而定，唯讀查詢參數

這張表本身就是線性代數：我們用「形狀」固定每一種資料可以被哪些運算接受，用「單位」避免把攝氏和 mg/L 直接相加。`tool_call` 那一列則提醒我們，文字與數值之外還有「動作」這種資料，它一樣要被結構化，才能被檢查與記錄。各種形狀如何階層式堆疊，見圖 `../figures/shapes.svg`。

概念與推導

****標量 (scalar) ****是單一數，例如 `do_mg_l = 6.2`。向量 (vector) 是一串數；本書一律約定向量為列向量 (column vector, 直向排列)，寫成 $\mathbf{x} \in \mathbb{R}^d$ ， d 是維度。若無特別說明， x 就代表直的柱狀，不是橫的列。這個約定看似吹毛求疵，卻是後面所有形狀檢查不出錯的基礎。

****矩陣 (matrix) ****是把數字排成二維表。 $W \in \mathbb{R}^{m \times d}$ 表示 m 列、 d 欄。當它作用在 $\mathbf{x} \in \mathbb{R}^d$ 上，得到

$$\mathbf{y} = W\mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^d, W \in \mathbb{R}^{m \times d}, \mathbf{y} \in \mathbb{R}^m.$$

形狀檢查是： $(m \times d)(d \times 1) = (m \times 1)$ ，中間的 d 必須一致。這條規則日後會反覆出現，請當成肌肉記憶。

為什麼是這樣乘？把 W 的第 i 列寫成 $\mathbf{w}_i^T$ ，則 $y_i = \mathbf{w}_i^T \mathbf{x}$ ，也就是「第 i 個輸出是輸入特徵的一組加權和」。若 W 的第二欄全是0，代表第二個感測特徵完全不影響輸出；若某一列是另一列的兩倍，兩項輸出就完全相關。換句話說，矩陣的列編碼了輸出、欄編碼了輸入，這種「列對輸出、欄對輸入」的讀法，是往後看懂注意力與線性層的關鍵。

張量 (tensor) 就是更高維的數字陣列。影像 $H \times W \times C$ 是三維張量；一個批次 (batch) 的感測資料是三維：batch $\times$ time $\times$ feature。以池A為例，若一天有 $T = 144$ 個十分鐘時間點、一批 $B = 7$ 天，則整批形狀是 $7 \times 144 \times 3$ ，索引 `X[b, t, k]` 表示第 b 天第 t 時的第 k 個量測。名稱嚇人，本質只是「多一層索引」。這裡要分清兩件事：張量的維數（有幾層索引，例如三維張量）與矩陣的秩 (rank)（線性獨立的方向數，後面章節才定義）是不同概念，初學時最容易把兩者混為一談。

批次寫法：把 n 筆觀測疊成 $X \in \mathbb{R}^{n \times d}$ ，每列一筆。同一組權重對整批做映射時，慣例寫成

$$\mathbf{Y} = XW^T, \quad X \in \mathbb{R}^{n \times d}, W \in \mathbb{R}^{m \times d}, \mathbf{Y} \in \mathbb{R}^{n \times m}.$$

這裡用轉置 W^T 把 W 從 $m \times d$ 變成 $d \times m$ ，使 $(n \times d)(d \times m) = (n \times m)$ 。這和逐筆算 $W\mathbf{x}$ 再疊起來的結果相同，原因是矩陣乘法對每一列獨立作用：輸出矩陣的第 i 列恰好等於 $W\mathbf{x}_i$ 的轉置。

最後要強調一句：**模型不是現實**。 $y = Wx$ 只是我們對世界的線性描述。真實池水的溶氧受光合作用、耗氧、溫度、對流等非線性與延遲影響；線性代數是骨架，不是完整真相。任何後續的 agent 建議都必須經人工覆核。

手算例題

令一個 2×3 的權重與一筆三維感測特徵為

$$W = \begin{bmatrix} 2 & -1 & 0 \\ 1 & 1 & 3 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

要算 $\mathbf{y} = W\mathbf{x}$ 。先確認形狀： $(2 \times 3)(3 \times 1) = (2 \times 1)$ ，合法。

第一列與 $\mathbf{x}$ 做內積： $2 \cdot 1 + (-1) \cdot 2 + 0 \cdot 3 = 2 - 2 + 0 = 0$ 。第二列與 $\mathbf{x}$ 做內積： $1 \cdot 1 + 1 \cdot 2 + 3 \cdot 3 = 1 + 2 + 9 = 12$ 。

所以

$$\mathbf{y} = \begin{bmatrix} 0 \\ 12 \end{bmatrix}.$$

若換成一整批兩筆， $X = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 1 \end{bmatrix}$ ，則 $Y = XW^T$ 。先寫 $W^T = \begin{bmatrix} 2 & 1 \\ -1 & 1 \\ 0 & 3 \end{bmatrix}$ ，再逐列乘：

第一筆： $[1, 2, 3] \cdot [2, -1, 0]^T = 0$ ，與 $[1, 2, 3] \cdot [1, 1, 3]^T = 12$ ；第二筆： $[0, 1, 1] \cdot [2, -1, 0]^T = -1$ ， $[0, 1, 1] \cdot [1, 1, 3]^T = 4$ 。故 $Y = \begin{bmatrix} 0 & 12 \\ -1 & 4 \end{bmatrix}$ ，形狀 2×2 ，與 XW^T 的預期一致。

這裡刻意每一步都寫出中間值，因為後面章節的梯度推導會需要你回頭核對這些小數字。

Python實驗

以下用 `numpy` 重現上面的計算。程式由讀者在自己的隔離環境執行；本書不代為執行，也不連任何真實設備。

```
import numpy as np
np.random.seed(42)

# 單筆: y = W @ x
W = np.array([[2, -1, 0],
              [1, 1, 3]], dtype=float)      # shape (2, 3)
x = np.array([[1], [2], [3]], dtype=float) # shape (3, 1) column vector, 直向排列

y = W @ x
print("W.shape =", W.shape, " x.shape =", x.shape, " y.shape =", y.shape)
print("y =\n", y)

# 批次: Y = X @ W.T
X = np.array([[1, 2, 3],
              [0, 1, 1]], dtype=float)      # shape (2, 3), 每列一筆
Y = X @ W.T
print("Y.shape =", Y.shape)
print("Y =\n", Y)
```

預期輸出（數值可人工核對）：

```
W.shape = (2, 3)  x.shape = (3, 1)  y.shape = (2, 1)
y =
[[ 0.]
 [12.]]
Y.shape = (2, 2)
Y =
```

```
[[ 0. 12.]  
 [-1.  4.]]
```

注意 `np.random.seed(42)` 只讓亂數可重現，**不代表統計結果可靠**；真正評估仍要靠資料切分與不確定性分析。

連回生成式AI、多模態與Agent

為什麼標量到矩陣值得先學？因為生成式AI的每個零件都能用這套符號寫出來。詞嵌入是查表得到向量；線性層就是 $W\mathbf{x}$ ；注意力的 Q、K、V 都是矩陣；影像與文字要對齊，靠的是把兩種特徵投影到同一空間後比相似度（對比學習的直覺）。到最後，一個 agent 要「檢索 SOP、呼叫工具、提出計畫」，中間仍是不斷的向量比較與矩陣乘法，只是外面包了一層決策流程（檢索增強與推理行動的架構見 R8、R7）。多模態融合的形狀約定見圖 [../figures/fusion.svg](#)，全書地圖見 [../figures/roadmap.svg](#)。

但要牢記分工：模型負責產生表示與候選建議，安全控制、劑量與投餌決策**不能**外包給模型。線性代數只是骨架，非線性、統計、因果推論與控制不可被省略，更不能假裝已證明。當 agent 說「建議提高增氧」時，那是一個待檢查的候選，不是已驗證的行動；可信控制鍵與人類覆核的位置見圖 [../figures/agent-safety.svg](#)。

常見錯誤與限制

第一，把矩陣乘法當可交換： AB 通常不等於 BA ，形狀也常常根本不能相乘。第二，混淆列與欄：中文的「行」容易歧義，本書一律叫**列（row）與欄／直行（column）**，向量預設是直的。第三，忽略單位：把 25（攝氏）和 6.2（mg/L）相加沒有物理意義。第四，把 seed 當萬靈丹；固定亂數只保證重現，不保證代表性。第五，把 $\mathbf{y} = W\mathbf{x}$ 的輸出當成事實，忘了它只是線性近似。

還有一類限制與本節主題直接相關：**線性模型無法表達飽和與交互作用**。真實溶氧對溫度的反應不是一條永久直線，模型在訓練分布之外可能嚴重失準。因此後續章節會談殘差、不確定性與可行性檢查，讓「模型輸出」永遠只是流程中的一環，而不是終點。

習題

習題1（基本計算） 令 $W = \begin{bmatrix} 1 & 0 & -2 \\ 3 & 1 & 1 \end{bmatrix}$ ， $\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 4 \end{bmatrix}$ ，求 $W\mathbf{x}$ 並標出形狀。

習題2（觀念） 若 $X \in \mathbb{R}^{5 \times 3}$ 、 $W \in \mathbb{R}^{4 \times 3}$ ，則 XW^T 的形狀為何？若改成 XW 可以嗎？為什麼？

習題3（養殖應用） 池A一日有三筆感測向量： $[25, 6.2, 7.4]$ 、 $[25, 6.1, 7.4]$ 、 $[31, 4.0, 7.0]$ （單位分別為攝氏、mg/L、無量綱）。若只把前兩筆相加再除以2，得到什麼？這個結果能不能直接用來判斷池水健康？請說明理由。

習題解答

習題1 形狀 $(2 \times 3)(3 \times 1) = (2 \times 1)$ 。第一列： $1 \cdot 2 + 0 \cdot 1 + (-2) \cdot 4 = 2 - 8 = -6$ ；第二列： $3 \cdot 2 + 1 \cdot 1 + 1 \cdot 4 = 6 + 1 + 4 = 11$ 。故 $W\mathbf{x} = [-6, 11]^T$ 。

習題2 $XW^T : (5 \times 3)(3 \times 4) = (5 \times 4)$ ，合法。 XW 需要 $(5 \times 3)(4 \times 3)$ ，中間 $3 \neq 4$ ，故不合法。轉置在此正是為了對齊內維度。

習題3 前兩筆平均為 $[(25 + 25)/2, (6.2 + 6.1)/2, (7.4 + 7.4)/2] = [25, 6.15, 7.4]$ 。這只是兩筆高度相似觀測的平均，取樣極小、未經標準化、未考慮不確定性，**不能**用來判斷健康；第三筆 $[31, 4.0, 7.0]$ 與前兩筆差異很大，更提醒我們不能只看平均。此外，本教材不提供任何真實物種的適用閾值，模型或平均數的輸出都不能代替養殖專業人員的現場判斷，也不能自動觸發投餌、加藥或增氧。

本章小結

本章建立了四個基本物件：標量、向量、矩陣、張量，以及它們的形狀與單位。核心式子 $y = Wx$ 與批次版 $Y = XW^T$ 貫穿全書，而「列對輸出、欄對輸入」是讀懂後續章節的鑰匙。最重要的一句話是：模型不是現實。往後我們會依序補上向量與內積、矩陣映射、消去法與秩，慢慢把虛構池A的資料串成一條可稽核的流程。

參考來源

- R1 : NumPy linear algebra reference
- R2 : Deep Learning, Chapter 2: Linear Algebra
- R3 : Attention Is All You Need
- R4 : Learning Transferable Visual Models From Natural Language Supervision
- R5 : LoRA: Low-Rank Adaptation of Large Language Models
- R6 : Denoising Diffusion Probabilistic Models
- R7 : ReAct: Synergizing Reasoning and Acting in Language Models
- R8 : Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

第02章 向量、內積與相似度

學習目標與先備知識

本章把一筆觀測表示成向量，建立理解 embedding、跨模態對齊與 Agent 檢索所需的幾何語言。讀完後，你應能計算向量加法、線性組合、歐幾里得範數、內積、夾角與餘弦相似度；解釋距離與相似度回答的問題有何不同；辨認零向量造成的例外；並區分「兩筆水質特徵相似」與「養殖狀態健康」。

先備知識只有實數四則運算、平方根與基本 Python。本書的單筆向量一律預設為列向量，例如 $x \in \mathbb{R}^d$ ，其矩陣形狀記為 $\text{shape}(x) = d \times 1$ 。若有多筆資料，才會組成批次矩陣，且每一列放一筆觀測。NumPy 的一維陣列形狀為 $(d,)$ ，沒有明確的列向量或行向量方向，本章用它簡潔地表示單筆向量。

從池A提出問題

虛構的池 A 每次觀測包含三項實體量：

$$r = \begin{bmatrix} \text{temperature_c} \\ \text{do_mg_l} \\ \text{ph} \end{bmatrix} \in \mathbb{R}^3, \quad \text{shape}(r) = 3 \times 1.$$

三個分量依序是攝氏溫度、溶氧濃度與無量綱的酸鹼值。它們的單位與數值尺度不同，例如溫度增加一個單位與溶氧增加一個單位並不代表相同變化。因此，不應直接把原始分量相加，也不宜在沒有縮放的情況下計算距離或相似度。

假設訓練時段中，第 j 個特徵的平均數與標準差分別為 μ_j 與 s_j 。當 $s_j > 0$ 時，可將原始值 r_j 標準化為

$$x_j = \frac{r_j - \mu_j}{s_j}.$$

此時 $x_j = 1$ 表示該值高於訓練平均一個訓練標準差， $x_j = -1$ 則表示低一個訓練標準差。 μ_j 與 s_j 必須只由訓練集估計；驗證集與測試集只能套用，不可重新計算。若 $s_j = 0$ ，代表訓練資料中的該欄沒有變化，公式會除以零。此時應依預先制定的資料規則移除該特徵或另行處理，而不是任意把結果設為零。

標準化後，我們可以比較池 A 兩個時刻相對於訓練基準的偏移模式。然而，模式相似不表示兩次觀測都健康：兩筆資料也可能以相似方向偏離正常範圍。健康判斷還需要物種、成長階段、時間、設備狀態與現場專業規範。本章資料皆為教學合成資料，不提供任何真實物種的適用閾值。

概念與推導

令 $x, y \in \mathbb{R}^d$ ，且 $\text{shape}(x) = \text{shape}(y) = d \times 1$ 。向量相等表示對應分量全部相等。向量加法逐分量進行：

$$x + y = \begin{bmatrix} x_1 + y_1 \\ \vdots \\ x_d + y_d \end{bmatrix} \in \mathbb{R}^d.$$

幾何上，可以先沿著 x 移動，再沿著 y 移動，終點就是 $x + y$ 。加法要求兩向量具有相同維度，而且對應位置應代表相同特徵。若一個向量的第一項是溫度，另一個向量的第一項是酸鹼值，即使維度相同，也不能直接視為可比較資料。

給定純量 $a, b \in \mathbb{R}$ ，向量

$$z = ax + by \in \mathbb{R}^d, \quad \text{shape}(z) = d \times 1$$

稱為 x, y 的線性組合。純量倍數改變長度，也可能改變方向：當 $a > 0$ 時， ax 與 x 同向；當 $a < 0$ 時，兩者反向；當 $a = 0$ 時，結果是零向量。線性組合是後續線性模型的核心，但「代數上可算」不等於「物理上有意義」。

向量的歐幾里得範數定義為

$$\|x\|_2 = \sqrt{x^\top x} = \sqrt{x_1^2 + \cdots + x_d^2}.$$

範數一定大於或等於零，而且 $\|x\|_2 = 0$ 當且僅當 x 是零向量。兩個向量端點之間的歐幾里得距離為

$$d(x, y) = \|x - y\|_2.$$

距離關心端點相隔多遠，因此同方向但長度差很多的向量仍可能距離很大。距離為零也當且僅當兩個向量完全相等。

內積定義為

$$x^\top y = \sum_{j=1}^d x_j y_j \in \mathbb{R}.$$

$x^\top$ 的形狀是 $1 \times d$ ，乘上形狀為 $d \times 1$ 的 y ，結果是純量。若對應分量多半同號，乘積傾向為正；若多半異號，乘積傾向為負。不過內積同時受方向與長度影響，不能單獨當成尺度無關的相似度。

當 x 與 y 都不是零向量時，內積具有幾何表示：

$$x^\top y = \|x\|_2 \|y\|_2 \cos \theta,$$

其中 $\theta \in [0, \pi]$ 是兩向量的夾角。整理可得餘弦相似度：

$$\cos_sim(x, y) = \frac{x^\top y}{\|x\|_2 \|y\|_2}.$$

也可以先把向量正規化為單位向量

$$\hat{x} = \frac{x}{\|x\|_2}, \quad \hat{y} = \frac{y}{\|y\|_2},$$

再計算 $\hat{x}^\top \hat{y}$ 。正規化後兩者的範數均為 1，因此可看出餘弦相似度比較的是方向，而不是原始長度。其值介於 -1 與 1 ：接近 1 表示同向，接近 0 表示近似正交，接近 -1 表示反向。

對單位向量還可推得距離與餘弦的關係：

$$\begin{aligned}\|\hat{x} - \hat{y}\|_2^2 &= (\hat{x} - \hat{y})^\top (\hat{x} - \hat{y}) \\ &= \hat{x}^\top \hat{x} - 2\hat{x}^\top \hat{y} + \hat{y}^\top \hat{y} \\ &= 2 - 2 \cos_sim(x, y).\end{aligned}$$

第一步使用範數定義，第二步展開乘法，最後利用兩個單位向量與自己的內積皆為 1。因此，資料都先正規化為單位長度時，較大的餘弦相似度對應較小的歐幾里得距離；未正規化時則不能直接作此推論。

若 $c > 0$ ，則 x 與 cx 的餘弦相似度為 1；若 $c < 0$ ，相似度為 -1 。但若任一向量是零向量，分母便為零，正規化、夾角與餘弦相似度都未定義。程式應回報例外或缺值，而不是靜默傳回零。

手算例題

假設池 A 兩筆標準化水質特徵為

$$x = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad y = \begin{bmatrix} 2 \\ -1 \\ 1 \end{bmatrix}, \quad x, y \in \mathbb{R}^3.$$

兩者均為 3×1 列向量，分量順序皆為溫度、溶氧與酸鹼值。先計算線性組合：

$$2x - y = \begin{bmatrix} 2 \\ -2 \\ 4 \end{bmatrix} - \begin{bmatrix} 2 \\ -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \\ 3 \end{bmatrix}.$$

兩向量的內積為

$$x^\top y = (1)(2) + (-1)(-1) + (2)(1) = 2 + 1 + 2 = 5.$$

兩個範數分別為

$$\|x\|_2 = \sqrt{1^2 + (-1)^2 + 2^2} = \sqrt{6},$$

$$\|y\|_2 = \sqrt{2^2 + (-1)^2 + 1^2} = \sqrt{6}.$$

所以餘弦相似度為

$$\cos_{\text{sim}}(x, y) = \frac{5}{\sqrt{6}\sqrt{6}} = \frac{5}{6} \approx 0.833.$$

夾角約為

$$\theta = \cos^{-1} \left(\frac{5}{6} \right) \approx 33.6^\circ.$$

再計算兩點的距離：

$$\|x - y\|_2 = \left\| \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} \right\|_2 = \sqrt{(-1)^2 + 0^2 + 1^2} = \sqrt{2}.$$

兩筆觀測的偏移方向頗相近，但並非完全相同。0.833 既不是健康機率，也不是安全分數。若訓練平均不適合目前情境，或感測器已漂移，再精確的相似度也可能缺乏決策價值。

Python實驗

以下程式要求輸入為相同長度的一維 NumPy 向量，並拒絕零向量。輸入是 `x=[1, -1, 2]` 與 `y=[2, -1, 1]`。

```
import numpy as np

def cosine_similarity(x, y):
    x = np.asarray(x, dtype=float)
    y = np.asarray(y, dtype=float)

    if x.ndim != 1 or y.ndim != 1:
        raise ValueError("輸入必須是一維向量")
    if x.shape != y.shape:
        raise ValueError("兩向量形狀必須相同")

    nx = np.linalg.norm(x)
    ny = np.linalg.norm(y)
    if nx == 0.0 or ny == 0.0:
        raise ValueError("零向量的餘弦相似度未定義")

    return float(np.dot(x, y) / (nx * ny))

x = np.array([1.0, -1.0, 2.0])
y = np.array([2.0, -1.0, 1.0])

print("distance =", np.linalg.norm(x - y))
print("cosine =", cosine_similarity(x, y))
```

預期輸出：

```
distance = 1.4142135623730951
```

cosine = 0.8333333333333335

讀者應在隔離環境執行。浮點運算的末位可能略有差異。真實資料流程還須保存特徵順序、單位、訓練集縮放參數、時間戳、感測器識別碼及缺值標記，否則相同形狀不代表相同語意。

連回生成式AI、多模態與Agent

生成式 AI 常將文字片段表示為高維向量，也就是 embedding。內積或餘弦相似度可用於找出幾何方向接近的文字表示；之後的注意力機制也會用內積比較查詢與鍵。然而，向量接近只反映模型學到的表示關係，不保證內容真實，也不等同模型已理解因果。

多模態系統可以把池 A 的感測資料、水面影像與工作日誌投影到共同空間，再比較相似度。不同模態即使最後維度相同，也不會自動具有共同語意；對齊能力仍取決於配對資料、訓練目標與適用範圍。

Agent 可以把目前狀態轉成查詢向量，檢索相關且有來源的 SOP。高相似文件只是候選資料，仍須檢查來源、版本、時效、設備與適用條件。完整流程還要進行資料有效性檢查並取得人工批准；本章示範不連接設備，也不產生投餌、加藥或增氧指令。

常見錯誤與限制

常見錯誤之一是把內積與餘弦相似度混為一談：內積同時受長度與方向影響，餘弦主要比較方向。第二是忽略單位、特徵順序與縮放來源，使數值較大的欄位不當地主導結果。第三是把零向量的相似度設為零，掩蓋數學上未定義及資料可能失效的事實。

另一個錯誤是把「標準化」與「正規化」混為一談。標準化逐一使用各特徵的訓練平均與標準差；正規化則將整個向量除以自己的範數。兩者目的不同，也可能依序同時使用。

此外，高相似度不代表健康、因果關係或操作安全。標準化會受離群值與訓練時段影響，餘弦相似度也不會自動發現感測漂移、過期資料或錯誤補值。線性代數只是表示與運算的骨架，不能取代統計、不確定性分析、非線性模型、因果推論及控制約束。

習題

- 基本計算：**令 $a = [1, 2]^T$ 、 $b = [3, -1]^T$ 。求 $a + b$ 、 $2a - b$ 、 $a^T b$ 與 $\|a\|_2$ 。
- 觀念題：**非零向量 u 與 $4u$ 的餘弦相似度是多少？兩者是否必定距離很近？請說明。
- 養殖應用題：**池 A 的當前標準化向量為 $q = [0, 0, 0]^T$ ，歷史紀錄為 $h = [1, -1, 1]^T$ 。能否計算兩者的餘弦相似度？能否只由 q 判定水質健康？
- 比較題：**令 $p = [1, 0]^T$ 、 $q = [3, 0]^T$ 、 $r = [1, 1]^T$ 。比較 p 與另外兩者的距離及餘弦相似度。

習題解答

1. $a + b = [4, 1]^T$, $2a - b = [-1, 5]^T$, $a^T b = 1$, $\|a\|_2 = \sqrt{5}$ 。
2. 相似度為 1，因為方向相同。距離是 $\|u - 4u\|_2 = 3\|u\|_2$ ，所以不一定很近。
3. 不能計算，因為 $\|q\|_2 = 0$ ，公式分母為零。零向量可能表示各值等於訓練平均，也可能源自缺值補零；沒有原始量測、時間與情境便不能判定健康。
4. $\|p - q\|_2 = 2$ ，餘弦相似度為 1； $\|p - r\|_2 = 1$ ，餘弦相似度為 $1/\sqrt{2}$ 。因此距離較近者不一定方向更相似。

本章小結

向量承載有固定順序的特徵，線性組合以係數混合向量，範數描述長度，內積連結分量運算與幾何方向。距離衡量端點差異，餘弦相似度比較方向，兩者不可互換；只有單位向量的距離才能直接由餘弦換算。餘弦對零向量未定義，也不能當成健康或安全分數。池 A 的資料必須先確認單位、縮放來源、時間與有效性，才能將相似度用於表示、檢索與多模態對齊。

參考來源

- [R1] NumPy linear algebra reference：本章 Python 範例所用的 `numpy.dot` 與 `numpy.linalg.norm` 介面參考。
- [R2] *Deep Learning*, Chapter 2: Linear Algebra：向量、範數與內積等線性代數背景參考。

第03章 矩陣與線性映射

學習目標與先備知識

上一章用向量描述一筆觀測，本章學習如何用矩陣把三維特徵轉成二維表示。讀完後，你應能檢查矩陣乘法的形狀、手算乘積與轉置，理解運算順序為何重要，並分辨線性映射和仿射映射。先備知識只有向量加法、純量乘法與基本 Python；不需要微積分。

本章遵循全書約定：單筆向量預設為**列向量**（column vector），寫成直立的一行。批次矩陣則把每筆觀測排成水平的一排，也就是一個 **row**。由於中文「行、列」在不同用法中容易混淆，下文談矩陣位置時會附上英文 row 或 column。

從池A提出問題

虛構池A記錄三項感測量：`temperature_c`（攝氏）、`do_mg_l`（溶氧，mg/L）與 `ph`（無量綱）。假設我們想讓模型把每筆三維特徵轉成二維表示，供後續與水面影像、工作日誌的表示銜接。應如何安排數字，才能讓同一套權重處理一筆或多筆觀測？

攝氏、mg/L 與無量綱數值不能因為都寫成數字，就直接視為可比較的尺度。本章只練習形狀與運算：例題輸入是假設已整理好的**教學合成特徵**，不是池A實測值，也不是任何物種的適用閾值。二維輸出的兩個座標只是計算結果，不自動代表水質優劣。

如果日後要對原始感測量做縮放，縮放方式也屬於模型流程的一部分。用資料估計平均值與標準差時，應只根據訓練資料估計，再將相同設定套用到驗證或測試資料；否則未來資料的資訊可能提前流入模型。本章的整數例題並未示範估計縮放參數，不能把其輸出解讀為經驗證的感測表示。

概念與推導

令單筆輸入 $x \in \mathbb{R}^3$ 為列向量，權重 $W \in \mathbb{R}^{2 \times 3}$ ，輸出 $y \in \mathbb{R}^2$ 。形狀 2×3 表示 W 有兩個水平 row、三個垂直 column。運算 $y = Wx$ 時，取 W 的每個 row，依序與 x 的三個分量相乘再相加。於是兩個 row 各產生一個數，組成二維列向量。

一般地，假設 $A \in \mathbb{R}^{m \times d}$ 、 $B \in \mathbb{R}^{d \times k}$ ，其中 m, d, k 為正整數，則

$$AB \in \mathbb{R}^{m \times k}, \quad (AB)_{ij} = \sum_{\ell=1}^d A_{i\ell} B_{\ell j}.$$

下標 i 指第 i 個 row， j 指第 j 個 column。相接的兩個 d 必須相等，因為每個乘積都要配對相同數量的分量；留下的 m 與 k 決定結果形狀。這是檢查乘法能否進行的第一步，還不是檢查模型是否合理的最後一步。

也可以把 W 想成一份固定的「配方」：每個輸出座標有自己的三個係數。輸入改變時，係數不變，三個輸入分量依係數重新組合。例如某個係數為零，表示該輸出座標的算式沒有直接使用對應分量；這不表示感測量在現實中不重要。權重的意義取決於特徵定義與取得權重的方法，單看矩陣中的正負號不足以判斷實際影響。

轉置把 row 與 column 互換。對 $W \in \mathbb{R}^{2 \times 3}$ ，有 $W^T \in \mathbb{R}^{3 \times 2}$ ，且 $(W^T)_{ij} = W_{ji}$ 。若把 n 筆三維觀測水平排列，每個 row 放一筆，得到 $X \in \mathbb{R}^{n \times 3}$ ，批次輸出便是

$$Y = XW^T \in \mathbb{R}^{n \times 2}.$$

取 X 的第 r 個 row 並轉置，得到單筆列向量 $x_r \in \mathbb{R}^3$ ； Y 的第 r 個 row 正是 $(Wx_r)^T$ 。因此單筆公式與批次公式使用同一組權重，只是存放資料的方向不同。若有偏移量 $b \in \mathbb{R}^2$ ，每筆都要加上同一個 b ，而不是只對批次中的第一筆相加。

矩陣乘法通常**不可交換**。例如令

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix} \quad (A, B \in \mathbb{R}^{2 \times 2}),$$

逐項配對可得

$$AB = \begin{bmatrix} 7 & 2 \\ 3 & 1 \end{bmatrix}, \quad BA = \begin{bmatrix} 1 & 2 \\ 3 & 7 \end{bmatrix}.$$

以左上角為例， AB 算的是 $1(1) + 2(3) = 7$ ， BA 算的卻是 $1(1) + 0(0) = 1$ 。順序改變了配對對象，結果便可能改變。若矩陣不是方形，交換後甚至可能因相接維度不符而無法相乘。

在連續映射中，靠近輸入的矩陣先作用。例如對合適形狀的列向量 x ， $A(Bx)$ 表示先做 B ，再做 A ，可寫成 $(AB)x$ ；若改成 $(BA)x$ ，兩個步驟的先後便顛倒。這與「先整理特徵再投影」和「先投影再整理」不一定等價的直覺相通。不過實際資料整理未必是線性映射，不能只憑這個比喻省略其定義。

不可交換不表示所有運算規則都失效。只要形狀相合，矩陣乘法仍有結合律，例如 $(AB)C = A(BC)$ ；也有分配律，例如 $A(u + v) = Au + Av$ 。結合律容許我們調整分組，卻不容許把 A 與 B 對調。單位矩陣 $I_d \in \mathbb{R}^{d \times d}$ 的對角線元素為 1、其餘為 0；對 $x \in \mathbb{R}^d$ ， $I_d x = x$ ，表示不改變輸入。這些規則有助於整理計算，但每次仍須先核對形狀。

轉置也會改變乘積的順序。若 $A \in \mathbb{R}^{m \times d}$ 、 $B \in \mathbb{R}^{d \times k}$ ，則

$$(AB)^T = B^T A^T \in \mathbb{R}^{k \times m}.$$

可以從元素檢查：左側第 i 個 row、第 j 個 column 是 $(AB)_{ji} = \sum_{\ell=1}^d A_{j\ell} B_{\ell i}$ ；右側同一位置是 $\sum_{\ell=1}^d (B^T)_{i\ell} (A^T)_{\ell j}$ ，兩式逐項相等。不能只把各矩陣加上轉置符號，卻保留原來順序。

最後要分清「能相乘」與「屬於哪種映射」。令 $f(x) = Wx$ 。對同維度向量 u, v 與純量 a, c ，

$$f(au + cv) = W(au + cv) = aWu + cWv = af(u) + cf(v).$$

這叫線性；特別取零向量便有 $f(0) = 0$ 。若加入 $b \in \mathbb{R}^2$ ，令 $g(x) = Wx + b$ ，則稱為仿射。當 $b \neq 0$ ， $g(0) = b \neq 0$ ；例如 $g(2x) = 2Wx + b$ ，但 $2g(x) = 2Wx + 2b$ ，兩者不相等。偏移量改變輸出起點，因此不能把這個完整映射稱為線性。

零向量測試是一個快速排除法：只要映射把零送到非零，就一定不線性；但把零送到零，仍不能單憑這一點斷言它線性，還須檢查加法與純量乘法是否保持。對本章的 Wx ，分配律提供了所需理由。這個區別有助於日後辨識模型中的不同運算，而不只是記住公式名稱。

手算例題

取教學權重與一筆三維特徵：

$$W = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 0 & 3 \end{bmatrix} \in \mathbb{R}^{2 \times 3}, \quad x_1 = \begin{bmatrix} 2 \\ 1 \\ 1 \end{bmatrix} \in \mathbb{R}^3.$$

先核對相接維度： $(2 \times 3)(3 \times 1)$ 可以相乘，結果是 2×1 。第一個輸出分量為 $1(2) + 2(1) + 0(1) = 4$ ；第二個為 $-1(2) + 0(1) + 3(1) = 1$ 。所以

$$Wx_1 = \begin{bmatrix} 4 \\ 1 \end{bmatrix} \in \mathbb{R}^2.$$

再取 $x_2 = (1, 0, 2)^T \in \mathbb{R}^3$ 。它的第一個分量是 $1(1) + 2(0) + 0(2) = 1$ ；第二個是 $-1(1) + 0(0) + 3(2) = 5$ ，故 $Wx_2 = (1, 5)^T$ 。

把兩筆輸入各放在一個水平 row：

$$X = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 0 & 2 \end{bmatrix} \in \mathbb{R}^{2 \times 3}, \quad W^T = \begin{bmatrix} 1 & -1 \\ 2 & 0 \\ 0 & 3 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

批次乘法的形狀是 $(2 \times 3)(3 \times 2) \rightarrow 2 \times 2$ ，逐筆結果排成

$$Y = XW^T = \begin{bmatrix} 4 & 1 \\ 1 & 5 \end{bmatrix} \in \mathbb{R}^{2 \times 2}.$$

例如右下角可獨立核對為 $1(-1) + 0(0) + 2(3) = 5$ 。Y 的兩個 row 對應兩筆觀測，兩個 column 對應兩個輸出座標；不要把「兩筆」誤認為「二維」。

若為每筆輸出加上同一個教學偏移量 $b = (1, -1)^T \in \mathbb{R}^2$ ，單筆結果由 $(4, 1)^T$ 變成 $(5, 0)^T$ ，另一筆由 $(1, 5)^T$ 變成 $(2, 4)^T$ 。批次結果則是把 $(1, -1)$ 分別加到 Y 的每個 row，形狀仍為 2×2 。偏移量改變數值，卻不會改變觀測筆數或輸出維度。

Python實驗

以下用 NumPy 表達相同運算。輸入是程式中的教學合成矩陣；預期輸出供讀者核對，可在隔離環境自行執行。

```
import numpy as np

W = np.array([[1, 2, 0], [-1, 0, 3]]) # (2, 3)
X = np.array([[2, 1, 1], [1, 0, 2]]) # (2, 3)
WT = W.T                               # (3, 2)
Y = X @ WT                             # (2, 2)

print(X.shape, WT.shape, Y.shape)
print(Y)
```

預期輸出：

```
(2, 3) (3, 2) (2, 2)
[[4 1]
 [1 5]]
```

@ 是矩陣乘法，不是逐項相乘。NumPy 中 `X[0]` 的形狀是 `(3,)`，沒有明示直立或水平；`W @ X[0]` 可得到兩個數，但教材推導仍以單筆列向量為準。先寫下數學形狀，再看程式輸出形狀，較不容易讓程式庫的表示方式掩蓋概念。

連回生成式AI、多模態與Agent

生成式AI中的線性層常用矩陣改變特徵維度；多模態系統也可能分別把文字、影像與感測資料轉為向量，再學習適合比較的表示。池A的三維感測特徵映成二維，只是這類運算的縮小示意。它沒有證明工作日誌與水面影像已經對齊，也沒有替二維座標賦予可靠的養殖意義。

在後續故事裡，特徵可能進入模型，模型再協助檢索有來源的作業程序（SOP），Agent 據此提出建議。然而從特徵到建議的每一步都可能有錯；資料有效性檢查和人工批准不能因矩陣運算正確就省略。本章示範不連真實設備，不產生投餌、加藥或增氧指令。

常見錯誤與限制

若 $X \in \mathbb{R}^{2 \times 3}$ 、 $W \in \mathbb{R}^{2 \times 3}$ ，直接寫 XW 會遇到相接維度 3 與 2 不同，乘法沒有定義；應依每個 row 一筆的約定寫 XW^T 。另一個錯誤是以為轉置會改變元素正負號：轉置只交換位置。還要避免把 AB 與 BA 視為同義，或把 $Wx + b$ 因為含有矩陣便稱為線性。

維度相合只保證運算可做，不保證輸入尺度、權重或解讀方式恰當。三維映至二維也可能讓不同輸入得到相同輸出；資訊是否遺失及如何描述，留待後續章節深入討論。線性代數是生成式AI的骨架之一，非線性、統計、因果推論與控制不能由本章公式取代。模型建議不能代替養殖專業，安全操作須由現場專業人員制

定。

習題

1. **基本計算**：沿用手算例題的 W ，令 $z = (0, 2, 1)^T$ 。求 Wz ，並標註輸出形狀。
2. **觀念**：若 $h(x) = Wx + b$ ，其中 $b = (1, 0)^T$ ， h 是否為線性映射？請用零向量檢查。
3. **養殖應用**：池A有四筆三維教學合成感測特徵，每個 row 一筆，組成 $X \in \mathbb{R}^{4 \times 3}$ ；投影權重為 $W \in \mathbb{R}^{2 \times 3}$ 。應寫 XW 還是 XW^T ？輸出形狀為何？它能否直接決定現場操作？

習題解答

1. 第一個分量為 $1(0) + 2(2) + 0(1) = 4$ ；第二個為 $-1(0) + 0(2) + 3(1) = 3$ 。故 $Wz = (4, 3)^T \in \mathbb{R}^2$ ，形狀為 2×1 。
2. 不是。 $h(0) = W0 + b = b = (1, 0)^T \neq 0$ ，不符合線性映射把零送到零的條件；它是仿射映射。
3. 應寫 XW^T 。因為 $W^T \in \mathbb{R}^{3 \times 2}$ ，所以 $(4 \times 3)(3 \times 2)$ 得到 $Y \in \mathbb{R}^{4 \times 2}$ 。這只是四筆資料的二維表示，不能直接決定現場操作；仍需檢查資料、參照適用程序並由人員批准。

本章小結

矩陣乘法沿相接維度配對：單筆列向量用 $y = Wx$ ，每個 row 一筆的批次用 $Y = XW^T$ 。轉置交換位置，乘法通常不可交換；結合律則只容許改變分組。 Wx 是線性映射， $Wx + b$ 在 $b \neq 0$ 時是仿射映射。算式正確是必要的起點，並非池A狀態或安全決策已獲證明。

參考來源

- R1：NumPy linear algebra reference，
<https://numpy.org/doc/stable/reference/routines.linalg.html>
- R2：Deep Learning, Chapter 2: Linear Algebra，
https://www.deeplearningbook.org/contents/linear_algebra.html

第04章 線性方程、消去法與秩

學習目標與先備知識

本章處理「已知部分觀測，想反推背後未知量」的線性問題。讀者需已熟悉第02章的列向量、內積與第03章的矩陣乘法、轉置。全書採用列向量：若 $x \in \mathbb{R}^d$ 、 $W \in \mathbb{R}^{m \times d}$ ，則 $y = Wx \in \mathbb{R}^m$ ；批次觀測 $X \in \mathbb{R}^{n \times d}$ 每列一筆觀測， n 為觀測筆數。本章先建立「線性方程組」的語言，再用高斯消去求小規模系統，最後用秩 (rank) 判斷解是無解、唯一解，還是無窮多解。

本章目標：能用增廣矩陣與初等列運算手算小規模系統；能說明主元、秩、自由變數的意義；能判斷感測器數據是否「可識別」。本節不預設微積分或機率知識。所有資料皆為教學合成，不提供真實物種適用閾值。

從池A提出問題

池A有溫度感測器 T_1 與溶氧感測器 D_1 、 D_2 。為校正漂移，假設感測器讀數與真值成線性關係，且讀數與真值同單位（溫度皆為攝氏 temperature_c、溶氧皆為 do_mg_l）。取兩組「已知真值」的溫度校正點：

- 第一組：真值 $\theta = 20$ 攝氏時， T_1 讀數 8；
- 第二組：真值 $\theta = 25$ 攝氏時， T_1 讀數 12。

把讀數寫成「斜率 $\times$ 真值 + 截距」： $T_1 = a_1\theta + b_1$ 。未知數是斜率與截距 a_1, b_1 ，兩組校正點各給一個方程，共兩個未知數、兩個方程。這是典型的線性方程組：已知係數與右端，求未知參數。

概念與推導

線性方程組。形如 $Ax = b$ 的方程組中， $A \in \mathbb{R}^{m \times n}$ 是係數矩陣， $x \in \mathbb{R}^n$ 是未知向量， $b \in \mathbb{R}^m$ 是常數項。把 A 與 b 併成增廣矩陣 $[A \mid b]$ （形狀 $m \times (n+1)$ ），可用「初等列運算」逐步化簡：交換兩列、某列乘非零常數、某列加上另一列的倍數。這些運算不改變解集合，因為它們相當於對增廣矩陣左乘可逆的初等矩陣，方程組兩邊同時做可逆線性組合，解集合保持不變。

高斯消去與主元。目標是化簡成列階梯形 (row echelon form)：每一非零列的第一個非零項（主元，pivot）比上一列更靠右，且主元下方全為零。若再將每個主元縮放成1，並讓主元上方也變零，即得簡化列階梯形 (reduced row echelon form)。主元所在的變數稱主元變數；沒有主元的變數稱自由變數 (free variable)，它們可任取，其餘變數由它們決定。這裡「列」指矩陣的 row，運算作用對象；變數對應的是係數矩陣的 column（行）。

秩與一致性。矩陣的秩是其列階梯形中非零列的數目，也等於主元個數。記 $r = \text{rank}(A)$ ， $r' = \text{rank}([A \mid b])$ 。判斷法則：

- 若 $r < r'$ ，系統不一致，無解（會推出 $0 = c \neq 0$ ）。

- 若 $r = r' = n$ (未知數個數)，解唯一。
- 若 $r = r' < n$ ，系統一致但有 $n - r$ 個自由變數，解有無窮多個。

為什麼自由參數個數是 $n - r$ 。 把 $Ax = b$ 化到列階梯形後，每個主元對應一個可被唯一解出的變數，剩餘 $n - r$ 個變數沒有主元，即自由變數。若系統一致，把自由變數當成參數，其餘主元變數可由它們唯一表示，因此解集合由 $n - r$ 個自由參數決定，是一個仿射集合 ($b \neq 0$ 時一般不是向量空間)，其維數為 $n - r$ 。若增廣矩陣多出一列主元 ($r' > r$)，代表某列化成 $0 = c \neq 0$ ，系統無解。直覺上：每個獨立方程消去一個自由度；獨立方程數不足以鎖定所有未知數時，剩下的自由度就是「不可識別」的部分——不同的未知數組合給出相同觀測，模型無法分辨。

手算例題

以校正 T_1 的方程組示範，未知數按 (a_1, b_1) 排列：

$$\begin{cases} 20a_1 + b_1 = 8 \\ 25a_1 + b_1 = 12 \end{cases} \quad \left[\begin{array}{cc|c} 20 & 1 & 8 \\ 25 & 1 & 12 \end{array} \right]$$

先消去兩列 a_1 的差異： $R_2 \leftarrow R_2 - R_1$ 得 $[5 \ 0 \ | \ 4]$ 。把此列除以 5 得 $R'_2 = [1 \ 0 \ | \ 0.8]$ ，即 $a_1 = 0.8$ 。再用 R'_2 消去第一列的 $20a_1$ ： $R_1 \leftarrow R_1 - 20R'_2 = [0 \ 1 \ | \ 8 - 20(0.8)] = [0 \ 1 \ | \ -8]$ ，即 $b_1 = -8$ 。完整簡化列階梯化為 $\begin{bmatrix} 1 & 0 & 0.8 \\ 0 & 1 & -8 \end{bmatrix}$ ，兩個變數皆為主元變數。

核對第二組： $25(0.8) + (-8) = 20 - 8 = 12$ ，成立。此 2×2 係數矩陣 $\begin{bmatrix} 20 & 1 \\ 25 & 1 \end{bmatrix}$ 的行列式 $20 - 25 = -5 \neq 0$ ，秩為 2，等於未知數個數，故唯一解 $(a_1, b_1) = (0.8, -8)$ 。

無解例。 讓兩列係數相同而右端不同： $\begin{bmatrix} 20 & 1 & 8 \\ 20 & 1 & 9 \end{bmatrix}$ 。 $R_2 \leftarrow R_2 - R_1 = [0 \ 0 \ | \ 1]$ ，即 $0 = 1$ ，矛盾。此增廣矩陣列階梯形有一列 $[0 \ 0 \ | \ 1]$ ， $r = 1$ 、 $r' = 2$ ，故無解。這正是感測器資料自相矛盾時的數學表現。

不可識別情形 (相依感測器)。 改看溶氧：兩支感測器 D_1, D_2 都校正到同一真值 δ (do_mg_l)，模型為 $D_1 = \delta + \epsilon_1$ 、 $D_2 = \delta + \epsilon_2$ ，其中 ϵ_1, ϵ_2 是未知固定偏移。現在加入「相依」條件： D_2 實際上是 D_1 加上固定偏移 0.3 mg/L，即 $D_2 = D_1 + 0.3$ ，故 $\epsilon_2 - \epsilon_1 = 0.3$ 。在同一時刻觀測 D_1, D_2 ，對未知 $x = (\delta, \epsilon_1, \epsilon_2)$ 寫出三條方程 (兩條讀值、一條相依)：

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} \delta \\ \epsilon_1 \\ \epsilon_2 \end{bmatrix} = \begin{bmatrix} D_1 \\ D_2 \\ 0.3 \end{bmatrix} \quad \text{rank} \begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & -1 & 1 \end{pmatrix} = 2$$

依列寫出： $R_1 = [1, 1, 0]$ 、 $R_2 = [1, 0, 1]$ 、 $R_3 = [0, -1, 1]$ ，且 $R_3 = R_2 - R_1$ ；右端也滿足 $0.3 = D_2 - D_1$ ，故第三列是前兩列的線性組合，獨立方程仍只有 2 列。對 3 個未知數，自由參數個數為 $3 - 2 = 1$ ： δ 與兩個偏移無法被分離，任意 δ 都可由調整 ϵ_1 (並隨之定 ϵ_2) 吸收，模型只能確定 $D_1 - D_2 = \epsilon_1 - \epsilon_2$ 這類組合，這就是秩不足造成的不可識別。要打破它，需引入獨立真值參考 (如標準溶液) 增加一條含 δ 的獨立方程，把有效秩提升到等於未知數個數。

Python實驗

以下用 NumPy 解 T_1 校立方程並檢查秩（請在隔離環境自行執行，本教材不在此宣告執行結果）：

```
import numpy as np

# 真值 theta=20、25 (攝氏) 對應 T1 讀數 8、12 (攝氏)
A = np.array([[20.0, 1.0],
              [25.0, 1.0]]) # shape (2,2)
b = np.array([8.0, 12.0]) # shape (2,)

print("rank(A) =", np.linalg.matrix_rank(A)) # 預期 2
x = np.linalg.solve(A, b) # 解 (a1, b1)
print("a1, b1 =", x) # 預期 [0.8, -8.0]
print("residual =", A @ x - b) # 預期 [0., 0.]
```

無解示範：兩列係數相同、右端不同（感測器自相矛盾）：

```
# 20*a + b = 8 且 20*a + b = 9
A2 = np.array([[20.0, 1.0],
               [20.0, 1.0]]) # shape (2,2)
b2 = np.array([8.0, 9.0]) # shape (2,)
Aug = np.hstack([A2, b2[:, None]]) # 增廣矩陣 shape (2,3)
print("rank(A2) =", np.linalg.matrix_rank(A2)) # 預期 1
print("rank(Aug) =", np.linalg.matrix_rank(Aug)) # 預期 2
# rank(A2) < rank(Aug) => 無解
```

相依感測器示範（一致但欠定、含相依方程）：兩支溶氧感測器在同一時刻觀測 $D_1 = 6.2$ 、 $D_2 = 6.5$ （滿足 $D_2 = D_1 + 0.3$ ），未知為 $(\delta, \epsilon_1, \epsilon_2)$ ：

```
B = np.array([[1.0, 1.0, 0.0], # D1 = delta + e1
              [1.0, 0.0, 1.0], # D2 = delta + e2
              [0.0, -1.0, 1.0]]) # e2 - e1 = 0.3 (相依) shape (3,3)
c = np.array([6.2, 6.5, 0.3]) # shape (3,)
print("rank(B) =", np.linalg.matrix_rank(B)) # 預期 2
sol = np.linalg.lstsq(B, c, rcond=None)
print("one solution:", sol[0]) # 無窮解中的一個；非唯一
print("check:", B @ sol[0] - c) # 預期近 [0., 0., 0.]
```

B 為 3×3 方陣但奇異（秩 2），`np.linalg.solve` 會失敗，應改用 `lstsq`。`lstsq` 回傳無窮解集中一個（最小範數）代表，約 $(4.23, 1.97, 2.27)$ ，代回 $B @ sol[0] - c$ 應近零；但換一個自由變數取值會得到另一組解，不是唯一真值。這正說明相依感測器使系統不可識別，秩不足時不應輸出確定結論。無解段以 `matrix_rank` 比較 $\text{rank}(A)$ 與 $\text{rank}([A \mid b])$ ，展示 $r < r'$ 的判準。

連回生成式AI、多模態與Agent

線性可識別性在多模態與 agent 場景反覆出現。Embedding 層與注意力中的線性投影（依全書契約，批次 $Q = XW_Q^T \in \mathbb{R}^{n \times d_k}$ ，其中 $X \in \mathbb{R}^{n \times d}$ 、 $W_Q \in \mathbb{R}^{d \times d_k}$ ）都是線性映射：當輸入特徵線性相依（例如兩支感測器永遠同步），對應參數無法由資料唯一決定，須靠正則化或先驗打破退化，與本節自由變數同構。具體

而言，參數能否被識別取決於訓練目標與資料設計，而非僅看層本身是否線性；秩不足的參數子空間不會改變輸出，梯度在其中不產生訊號。

對 pool A 的 agent 而言，感測融合先問「這些感測器是否提供獨立資訊」。若以 $X \in \mathbb{R}^{n \times d}$ 表示 n 筆觀測、 d 支感測器， $\text{rank}(X) < d$ 只能說明觀測特徵存在線性相依；某個水質狀態向量是否可識別，還要看具體觀測方程 $y = Hx$ 的係數矩陣 H 之秩是否等於狀態維數。當 H 秩不足，狀態不可識別，agent 應標記為資料不足，轉請人工覆核，而非輸出看似確定的建議。線性代數在此是骨架，但真實池受非線性、統計與因果因素影響，秩的判斷不能取代現場專業判斷，亦不構成任何投餌、加藥或增氧指令。

常見錯誤與限制

1. **把秩當成行列式**。只有方陣行列式非零才等價於滿秩；一般矩陣用列階梯形的非零列數判斷秩。
2. **混淆列與行**。本節列運算作用在矩陣的「列 (row)」上；變數對應係數矩陣的 column (行)，中文「行」有時指 column，本節凡指運算對象皆稱列，凡指變數對應欄皆稱行。
3. **用浮點直接判秩**。浮點有誤差，秩判斷需設容差 (NumPy `matrix_rank` 內含此機制)，不可用 `==0`。
4. **解出唯一解就當真實**。唯一解只在假設線性模型成立下表示可識別；模型本身是否成立需非線性與因果分析，不可省略。
5. **忽略單位**。真值與讀數須同單位；混用會造成方程不一致或參數單位錯亂。

習題

1. **基本計算**：解方程組 $\begin{cases} 2x + y = 5 \\ x - y = 1 \end{cases}$ ，寫出增廣矩陣、做連續高斯消去到列階梯形，並指出主元與秩。
2. **觀念**：若 $A \in \mathbb{R}^{3 \times 2}$ 且 $\text{rank}(A) = 2$ ，則 $Ax = b$ 對任意 b 是否一定有解？若存在解，是否唯一？說明。
3. **養殖應用**：pool A 兩支溶氧感測器在同一時刻觀測，模型為 $D_1 = \delta + \epsilon_1$ 、 $D_2 = \delta + \epsilon_2$ ，並已知 $D_2 = D_1 + 0.3$ 。未知向量 $x = (\delta, \epsilon_1, \epsilon_2)$ 。寫出含相依條件的 3×3 係數矩陣 B 與右端向量，求其秩，並說明 agent 應如何處理。

習題解答

1. 增廣矩陣 $\left[\begin{array}{cc|c} 2 & 1 & 5 \\ 1 & -1 & 1 \end{array} \right]$ 。先 $R_1 \leftarrow R_1 - 2R_2$ 得 $[0 \ 3 \ | \ 3]$ ；把此列除以 3 得 $R'_1 = [0 \ 1 \ | \ 1]$ ，即 $y = 1$ 。再 $R_2 \leftarrow R_2 + R'_1$ (原 $R_2 = [1 \ -1 \ | \ 1]$) 得 $[1 \ 0 \ | \ 2]$ ，即 $x = 2$ 。此時為 $\left[\begin{array}{cc|c} 0 & 1 & 1 \\ 1 & 0 & 2 \end{array} \right]$ ，交換兩列得列階梯形 $\left[\begin{array}{cc|c} 1 & 0 & 2 \\ 0 & 1 & 1 \end{array} \right]$ ，兩個變數皆為主元變數，秩 = 2，等於未知數個數，唯一解 $(2, 1)$ 。
2. A 是 3×2 ， $\text{rank}(A) = 2$ 。 $Ax = b$ 有解當且僅當 b 落在 A 的行空間 (column space)；對任意 $b \in \mathbb{R}^3$ 不保證在此行空間內，故不一定有解。但若存在解，因秩 = 2 = 未知數個數，自由參數個數為 $2 - 2 = 0$ ，解唯一。

3. 含相依條件的系統為 $\begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & -1 & 1 \end{bmatrix} x = \begin{bmatrix} D_1 \\ D_2 \\ 0.3 \end{bmatrix}$ ，第三列係數與右端皆為前兩列之差（ $R_3 = R_2 - R_1$ ），故 $\text{rank}(B) = 2 < 3$ ，系統欠定，自由參數個數為 1， δ 與偏移不可分離。agent 應標記「感測器相依、不可識別」，拒絕自動校正，轉請現場人員加入獨立真值參考。

本章小結

本章以 pool A 感測器校正為引，建立線性方程組、高斯消去、主元、秩與自由變數的語言，並給出一致性法則： $r < r'$ 無解、 $r = r' = n$ 唯一解、 $r = r' < n$ 無窮解，以及「一致系統的仿射解集合維數為 $n - r$ 」的推導。手算例題展示 2×2 解法、行列式判滿秩、一個無解例的增廣秩計算，再以「兩溶氧感測器同一時刻觀測且相依」說明秩不足造成不可識別：相依條件使第三列成前兩列之線性組合，獨立列仍只 2 列。Python 段以 `matrix_rank`、`solve` 與 `lstsq` 演示唯一解、無解（以 $r < r'$ 判準）與一致但欠定的差異，並說明奇異方陣不可用 `solve`。這些概念是後續正交投影、最小平方、條件數與 agent 資料有效性檢查的基礎：當線性骨架秩不足時，任何下游模型都應先標記資料不足並交由人工覆核，而非輸出偽確定結論，更不能自行下達控制指令。

參考來源

- R1：NumPy linear algebra reference（`matrix_rank`、`solve`、`lstsq` 函式）
- R2：Deep Learning, Chapter 2: Linear Algebra（線性系統與秩的基本框架）

第05章 子空間、基底與座標

學習目標與先備知識

本章要回答：一組向量能生成哪些向量？其中有沒有重複方向？如何用基底、維度與座標描述空間？我們會用池A的教學合成水質資料辨認冗餘特徵，並說明座標轉換何時保留資訊、何時造成資訊遺失。

先備知識是向量加法、數乘與矩陣乘法。向量預設為列向量（column vector，直向排列）；「列向量」在本書是固定複合詞，不由單字「列」推斷方向。矩陣位置則用橫列（row）與縱行（column）；以下以英文 column 向量指矩陣中的直向特徵，避免與 row 混淆。池A特徵包含 `temperature_c`（攝氏）、`do_mg_l`（溶氧 mg/L）與 `ph`（無量綱）；本章數值都是教學合成，不代表真實養殖閾值。

從池A提出問題

假設紀錄中除了溫度、溶氧、pH，又多存一欄「溶氧的兩倍」。欄位數從三個變成四個，但新增欄是否帶來新的資訊？要回答這個問題，我們需檢查特徵是否線性獨立，以及它們張成的空間有幾個獨立方向。

這種檢查可協助理解資料表示，但不能單獨判斷特徵是否有預測價值，也不能判斷水質是否適合養殖。秩較高不保證特徵有意義或資料品質良好。

概念與推導

給定向量 $v_1, \dots, v_k \in \mathbb{R}^d$ ，它們的**張成空間**是所有線性組合形成的集合：

$$\text{span}(v_1, \dots, v_k) = \left\{ \sum_{i=1}^k c_i v_i : c_i \in \mathbb{R} \right\}.$$

這個集合包含零向量：令所有係數為零即可得到。兩個線性組合相加，或將其中一個乘上純量，結果仍是線性組合，所以張成空間對加法與數乘封閉，因而是子空間。例如 $(1, 0)^T$ 與 $(0, 1)^T$ 張成整個 $\mathbb{R}^2$ ，因為任意 $(x, y)^T = x(1, 0)^T + y(0, 1)^T$ 。

若方程 $c_1 v_1 + \dots + c_k v_k = 0$ 只有 $c_1 = \dots = c_k = 0$ 這個解，這組向量稱為**線性獨立**；若有非零係數解，則稱為**線性相依**。相依表示至少一個向量能由其他向量組合出來，加入它不會擴大原有張成空間。例如若 $v_2 = 3v_1$ ，便有 $-3v_1 + v_2 = 0$ ，所以兩者相依。

若把 $v_1, \dots, v_k \in \mathbb{R}^d$ 放成矩陣 A 的各個 column，則 $A \in \mathbb{R}^{d \times k}$ ，線性組合寫成 $Ac = c_1 v_1 + \dots + c_k v_k$ ，其中 $c \in \mathbb{R}^k$ 。因此解 $Ac = 0$ ，只有零解才表示這些 column 向量獨立。排列方式會改變方程形狀，計算時須先確認向量放在矩陣哪個方向。

一組向量若線性獨立，且張成某個子空間，便是該子空間的**基底**。基底向量的數量稱為空間的**維度**。給定基底 $b_1, \dots, b_r$ ，若 $x = a_1 b_1 + \dots + a_r b_r$ ，係數 $a_1, \dots, a_r$ 就是 x 在這組基底下的座標。基底固定時座標唯一：若同一向量有兩組座標，相減後得到基底向量的線性組合等於零；基底獨立，係數差只能全為零。

對矩陣 $A \in \mathbb{R}^{m \times n}$ ，各 row 向量張成的子空間稱為**列 (row) 空間**，位於 $\mathbb{R}^n$ ；各 column 向量張成的子空間稱為**行 (column) 空間**，位於 $\mathbb{R}^m$ 。兩者維度相等，稱為矩陣的秩 $\text{rank}(A)$ 。初等列 (row) 運算保留列空間與秩，但可能改變行 (column) 空間；要求原矩陣行空間的基底，須取原矩陣中對應主元的 column 向量。

矩陣的**零空間**為 $\{x \in \mathbb{R}^n : Ax = 0\}$ ，其維度稱為零度 $\text{nullity}(A)$ 。秩零度定理為

$$\text{rank}(A) + \text{nullity}(A) = n.$$

輸入有 n 個座標方向，其中一些方向可能被 A 映成零；零度計數被消去的自由方向，秩計數仍可區分的方向。若解 $Ax = 0$ 有 q 個自由變數，零空間便有 q 個基底方向，故零度為 q 。

手算例題

池A有三筆教學合成觀測，每列一筆、每行一項特徵，矩陣為 $X \in \mathbb{R}^{3 \times 4}$ ：

$$X = \begin{bmatrix} 20 & 6 & 7 & 12 \\ 22 & 5 & 8 & 10 \\ 24 & 4 & 7 & 8 \end{bmatrix}.$$

四個特徵 column 向量記為 $v_1, v_2, v_3, v_4 \in \mathbb{R}^3$ ，依序代表溫度、溶氧、pH、兩倍溶氧。逐項可見

$$v_4 = (12, 10, 8)^T = 2(6, 5, 4)^T = 2v_2.$$

所以 $-2v_2 + v_4 = 0$ 是非零係數關係，四個 column 向量線性相依。

檢查前三個 column 向量。假設 $av_1 + bv_2 + cv_3 = 0$ 。用第二筆減第一筆、第三筆減第二筆，得到

$$2a - b + c = 0, \quad 2a - b - c = 0.$$

兩式相減得 $2c = 0$ ，故 $c = 0$ ，再由任一式得 $b = 2a$ 。代回第一筆方程：

$$20a + 6b + 7c = 20a + 12a + 0 = 32a = 0.$$

故 $a = 0$ ，進而 $b = c = 0$ 。前三個 column 向量線性獨立，四個 column 向量張成的行空間 (column space) 維度為 3；它位於 $\mathbb{R}^3$ ，不是位於 $\mathbb{R}^4$ 的列空間 (row space)。兩者維度同為矩陣秩 3。

再用零空間核對。令 $z = (z_1, z_2, z_3, z_4)^T \in \mathbb{R}^4$ 。由第四個特徵 column 向量等於第二個的兩倍，可知 $z_2 + 2z_4 = 0$ ；前三個 column 向量獨立，故另外有 $z_1 = z_3 = 0$ 。因此

$$z = t(0, -2, 0, 1)^T, \quad t \in \mathbb{R}.$$

直接代入可核對 $X(0, -2, 0, 1)^T = 0$ ，因為每筆的溶氧項與末欄相消。零空間由一個方向張成，零度為 1；故 $\text{rank}(X) + \text{nullity}(X) = 3 + 1 = 4$ ，等於輸入欄數。

Python實驗

以下 NumPy 程式檢查矩陣秩及兩倍溶氧欄的關係。輸入是上例的教學合成矩陣，預期輸出為秩 3，以及零向量差。程式供讀者在隔離環境執行。

```
import numpy as np

X = np.array([
    [20, 6, 7, 12],
    [22, 5, 8, 10],
    [24, 4, 7, 8],
], dtype=float)

print(np.linalg.matrix_rank(X))
print(X[:, 3] - 2 * X[:, 1])
```

預期輸出：

```
3
[0. 0. 0.]
```

浮點資料的秩會受數值容差影響；近似相依不等於精確相依。秩也不能直接解讀成特徵的重要性或水質評分。

連回生成式AI、多模態與Agent

池A的感測器、影像與工作日誌可經特徵處理形成模型輸入。若一個特徵只是另一個的倍數，新增欄位不會增加線性獨立方向。這能揭露精確冗餘，卻不能證明模型不需要其中任何一欄：尺度、雜訊及後續處理也會影響用途。秩描述線性結構，不直接描述因果或預測效果。

換基底可以用不同座標記錄同一向量。以兩個數值 x_1, x_2 為例，改用「和、差」座標：

$$\begin{bmatrix} s \\ d \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} s \\ d \end{bmatrix}.$$

輸入與輸出向量形狀皆為 2×1 ，轉換矩陣形狀為 2×2 。令轉換矩陣為 P ，可算得 $P^2 = 2I$ ，所以 $P^{-1} = \frac{1}{2}P$ 。例如 $(x_1, x_2)^T = (5, 3)^T$ ，則 $(s, d)^T = (8, 2)^T$ ；逆轉換給出 $x_1 = (8 + 2)/2 = 5$ 、 $x_2 = (8 - 2)/2 = 3$ 。轉換可逆，資訊保留。

若只留下和 $s = 8$ ，則 $(5, 3)$ 、 $(6, 2)$ 都有相同的和，卻有不同的差，無法唯一還原原數值。這是從二維輸入映到一維輸出，不同輸入會落到同一輸出，資訊因此遺失。

多模態模型會把感測器、影像和文字特徵映到表示空間。即使形狀相同，也不能因此認定語義相同；是否保留原始資訊，要看轉換是否可逆，以及模型保留哪些方向。池A流程中的特徵、模型、SOP檢索與Agent建議都需要資料有效性檢查，不能只看欄位數量。

冗餘檢查不是操作許可。示範不連真實設備，也不下投餌、加藥或增氧指令；安全操作須由現場專業人員制定，模型建議不能取代養殖專業。

常見錯誤與限制

多一個欄位不等於多一個獨立方向；要檢查線性獨立。列 (row) 空間與行 (column) 空間位於不同向量空間，但維度相同。秩零度定理中的 n 是矩陣欄數，也就是輸入維度，不是觀測筆數。本章 $X \in \mathbb{R}^{3 \times 4}$ ，輸入向量有四個座標，因此秩與零度相加為 4。

基底不唯一，座標依基底改變；若轉換可逆，同一向量仍可完整還原。只保留部分座標則可能遺失資訊。真實感測資料常有測量誤差，兩欄接近成比例不代表精確相依；即使數學上有冗餘，也不能只憑秩刪除特徵。

線性代數是生成式AI的骨架，非線性、統計、因果推論與控制不可省略。資料的線性依賴不等於實際因果關係，模型表示空間的維度也不等於它掌握的知識量。

習題

1. **基本計算：** $u = (1, 2)^T$ 、 $v = (3, 6)^T$ 是否線性獨立？它們張成的空間維度是多少？
2. **觀念：** 若 $A \in \mathbb{R}^{5 \times 3}$ 且秩為 2，其零空間維度是多少？能否單憑秩判斷模型預測準確？
3. **養殖應用：** 池A特徵為溫度、溶氧與兩倍溶氧。加入第三項後，獨立方向是否必定增加？它在零空間關係中代表什麼？
4. **座標與資訊：** 對 $x = (4, 1)^T$ ，計算和、差座標。若只保留和，能否唯一還原 x ？舉出另一個和相同的輸入。

習題解答

1. $v = 3u$ ，兩向量相依；其張成空間由非零向量 u 張成，維度為 1。
2. 秩零度定理給 $2 + \text{nullity}(A) = 3$ ，所以零空間維度為 1。不能；秩不描述預測誤差、目標或資料分布。
3. 不會增加。令 v_{do} 與 $v_{2\text{do}}$ 為特徵 column 向量，則 $-2v_{\text{do}} + v_{2\text{do}} = 0$ 。若 X 的欄依序儲存特徵，對應係數向量 c 滿足 $Xc = 0$ ；它表示特徵間的冗餘。
4. $s = 4 + 1 = 5$ 、 $d = 4 - 1 = 3$ ，座標為 $(5, 3)^T$ 。只保留和不能唯一還原，例如 $(3, 2)^T$ 也有和 5。

本章小結

張成空間收集所有線性組合；線性獨立排除可由其他向量組成的方向；基底是獨立且足以張成子空間的一組向量，基底數量就是維度。對 $A \in \mathbb{R}^{m \times n}$ ，列（row）空間位於 $\mathbb{R}^n$ ，行（column）空間位於 $\mathbb{R}^m$ ，兩者維度都是秩；零空間維度是零度，且秩加零度等於 n 。換基底若可逆便能還原座標，只保留部分資訊則可能無法還原。池A的冗餘特徵能用這些工具描述，但線性結構不等於預測能力或養殖安全判斷。

參考來源

線性代數主題與 NumPy 線性代數介面可參照給定來源 **R1**、**R2**。本章數值為教學合成，未用以驗證真實養殖決策。

第06章 正交、投影與最小平方

學習目標與先備知識

本章要建立四件事：第一，理解正交、正交基底與投影的幾何意義；第二，會用Gram-Schmidt把一組線性獨立向量變成正交歸一基底；第三，知道QR分解的概念，並用它解最小平方而不必顯式求逆；第四，理解正規方程 $A^\top A \hat{x} = A^\top y$ 的限制，知道何時該改用QR、SVD或正則化。先備知識只有：向量內積、矩陣乘法、線性組合與轉置。全程預設向量為column vector， $x \in \mathbb{R}^d$ ， $W \in \mathbb{R}^{m \times d}$ ， $y = Wx \in \mathbb{R}^m$ ；批次 $X \in \mathbb{R}^{n \times d}$ 以每列（row）一筆觀測， $Y = XW^\top$ 。本章只用到高中數學與基本Python，不預設微積分、機率或深度學習。

從池A提出問題

虛構養殖池A在三日同一時段記錄溶氧 do_mg_l 與時間 t （日）。所有資料皆為教學合成，不是真實物種適用閾值，也不代表任何現場安全範圍。資料字典為： t 是感測器時間， y 是溶氧量測， A 是設計矩陣。因為感測器有噪聲，三點不會正好落在一條直線上，所以我們想找一條直線 $\hat{y} = a + bt$ ，使三個預測值與量測值的殘差平方和最小。

線性代數把這個問題改寫為投影：量測向量 $y \in \mathbb{R}^3$ 是空間中的一點，而所有可能的直線 $a + bt$ 所形成的集合，是 A 的各個column（欄）所張成的column space S 。 S 是由 $(1, 1, 1)$ 與 $(0, 1, 2)$ 兩方向張成的二維平面。若 y 不在這個平面上，最佳直線就是 y 在 S 的投影。要理解這個「最近點」為何唯一、如何計算，正是本章主題。必須先說清楚：此擬合只描述這三筆模擬資料，不能推論因果，也不能作為投餌、加藥或增氧指令的依據。

概念與推導

設 $u_1, \dots, u_k \in \mathbb{R}^n$ 。若對所有 $i \neq j$ 都有 $u_i^\top u_j = 0$ ，稱這組向量正交；若再加上 $\|u_i\| = 1$ ，則稱為正交歸一組。正交組必線性獨立：若 $\sum c_i u_i = 0$ ，兩邊與 u_j 取內積得 $c_j \|u_j\|^2 = 0$ ，故 $c_j = 0$ 。這個性質是正交基底好用的根源——每個基底方向貢獻互不干擾。

投影的幾何直覺是「垂直落下」。若 $q_1, \dots, q_k$ 是正交歸一組，子空間 $S = \text{span}\{q_i\}$ ，則任意 $y \in \mathbb{R}^n$ 在 S 的投影為

$$\text{proj}_S(y) = \sum_{i=1}^k (q_i^\top y) q_i.$$

係數 $q_i^\top y$ 就是 y 沿 q_i 方向的分量。為什麼這是最佳近似？因為對任意 $s \in S$ ，

$$\|y - s\|^2 = \|y - \hat{y}\|^2 + \|\hat{y} - s\|^2,$$

其中 $\hat{y} = \text{proj}_S(y)$ ，且 $y - \hat{y}$ 與整個 S 正交。右邊第一項固定，第二項只能大於等於零，故 $s = \hat{y}$ 時距離最小，且此 $\hat{y}$ 唯一。這說明投影誤差下界只對該子空間內所有向量成立；若真實關係不在子空間中，換更小子空間或更大子空間都是模型選擇問題，本章無法單獨回答。

Gram-Schmidt 把線性獨立向量 $a_1, \dots, a_k$ 逐步正交化。先取 $u_1 = a_1$ ；對每個 $j \geq 2$ ，先減去已經在 $u_1, \dots, u_{j-1}$ 上的分量：

$$u_j = a_j - \sum_{i=1}^{j-1} \frac{q_i^\top a_j}{q_i^\top q_i} u_i,$$

再令 $q_j = u_j / \|u_j\|$ 。若分母用 $q_i^\top q_i$ ，即使 q_i 只正交未歸一也正確。把 $A = [a_1 \dots a_d] \in \mathbb{R}^{n \times d}$ 逐欄做此過程，就得到 $A = QR$ ，其中 $Q \in \mathbb{R}^{n \times d}$ 的 columns 正交歸一， $R \in \mathbb{R}^{d \times d}$ 是上三角且對角為正。 R 記錄每一步的歸一與投影係數，因此 QR 把原始欄轉成「方向清楚」的正交資訊[R1]。

最小平方問題：給 $A \in \mathbb{R}^{n \times d}$ 與 $y \in \mathbb{R}^n$ ，求 $x \in \mathbb{R}^d$ 使 $\|Ax - y\|_2^2$ 最小。假設 y 不在 column space 中；最佳近似 $\hat{y} = A\hat{x}$ 必是 y 在該子空間的投影，因此殘差 $r = y - A\hat{x}$ 要與 A 的每個 column 正交，即 $A^\top r = 0$ 。展開得正規方程

$$A^\top A \hat{x} = A^\top y.$$

若 A 的 columns 線性獨立， $A^\top A$ 對稱正定因而可逆，理論上 $\hat{x} = (A^\top A)^{-1} A^\top y$ ；但這是表示式，不是首選演算法。原因是條件數會被平方： $\kappa(A^\top A) = \kappa(A)^2$ ，當特徵高度相關或尺度差很大時，直接求逆會大幅放大浮點誤差與輸入擾動。較穩健的做法是先做 QR，再解上三角系統 $R\hat{x} = Q^\top y$ ； Q 是正交矩陣，不放大二範數。也可用 SVD 或 NumPy 的 `lstsq`，這些方法不依賴顯式求逆[R1,R2]。若 columns 線性相依， $\hat{x}$ 不唯一，必須移除冗餘特徵、加正則化或改用偽逆，並報告自由度。

手算例題

池A三日模擬量測： $t = (0, 1, 2)$ ， $y = (1, 2, 2)$ 。模型 $\hat{y} = a + bt$ ，所以設計矩陣與未知數為

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad x = \begin{bmatrix} a \\ b \end{bmatrix}.$$

第一欄是常數項(1, 1, 1)，第二欄是時間(0, 1, 2)。先計算兩個乘積：

$$A^\top A = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \quad A^\top y = \begin{bmatrix} 1 + 2 + 2 \\ 0 + 2 + 4 \end{bmatrix} = \begin{bmatrix} 5 \\ 6 \end{bmatrix}.$$

正規方程為

$$\begin{cases} 3a + 3b = 5, \\ 3a + 5b = 6. \end{cases}$$

兩式相減得 $2b = 1$ ，故 $b = 1/2$ ；代回第一式 $3a + 3/2 = 5$ ， $3a = 7/2$ ， $a = 7/6$ 。預測為

$$\hat{y} = \left(\frac{7}{6}, \frac{10}{6}, \frac{13}{6} \right).$$

殘差

$$y - \hat{y} = \left(-\frac{1}{6}, \frac{2}{6}, -\frac{1}{6} \right),$$

殘差平方和為 $1/36 + 4/36 + 1/36 = 6/36 = 1/6$ 。驗算 $A^\top r = 0$ ：第一分量 $(-1 + 2 - 1)/6 = 0$ ；第二分量 $(0 \cdot (-1) + 1 \cdot 2 + 2 \cdot (-1))/6 = 0$ ，符合正規方程的要求。

用Gram-Schmidt獨立核對：取 $a_1 = (1, 1, 1)$ ， $a_2 = (0, 1, 2)$ 。因為 a_1 已是正交方向，令 $u_1 = a_1$ 。 a_2 在 u_1 上的投影係數是 $(u_1^\top a_2)/(u_1^\top u_1) = 3/3 = 1$ ，所以 $u_2 = a_2 - u_1 = (-1, 0, 1)$ 。 y 在 $\text{span}\{u_1, u_2\}$ 的投影為

$$\frac{y^\top u_1}{u_1^\top u_1} u_1 + \frac{y^\top u_2}{u_2^\top u_2} u_2 = \frac{5}{3} (1, 1, 1) + \frac{1}{2} (-1, 0, 1) = \left(\frac{7}{6}, \frac{10}{6}, \frac{13}{6} \right),$$

與正規方程結果一致。這也示範正交的好處：兩個係數 $5/3$ 與 $1/2$ 各自獨立計算，不必解聯立方程。

Python實驗

以下片段在隔離環境以NumPy執行，不需安裝其他套件；輸入固定為上述三筆資料，輸出可人工核對。程式不以顯式求逆作為主要數值方法。

```
import numpy as np

t = np.array([0.0, 1.0, 2.0])
y = np.array([1.0, 2.0, 2.0])
A = np.column_stack([np.ones_like(t), t])

coef, residuals, rank, sv = np.linalg.lstsq(A, y, rcond=None)
pred = A @ coef
r = y - pred

print("coef =", np.round(coef, 4))
print("rank =", rank)
print("pred =", np.round(pred, 4))
print("SSE =", np.round(r @ r, 4))
print("norm(r) =", np.round(np.linalg.norm(r), 4))
```

預期輸出：

```
coef = [1.1667 0.5   ]
rank = 2
pred = [1.1667 1.6667 2.8333]
```

```
SSE = 0.1667
norm(r) = 0.4082
```

其中 $1.1667 \approx 7/6$ ， $1.6667 \approx 10/6$ ， $2.8333 \approx 13/6$ ， $SSE = 1/6$ ， $\|r\| = \sqrt{1/6} \approx 0.4082$ 。lstsq 回傳最小平方解，內部採用穩定分解。`residuals` 只有在特定條件下才給出殘差平方和，故本實驗直接計算 $r^\top r$ 較清楚，也避免對回傳值語意誤解。

連回生成式AI、多模態與Agent

正交與投影是生成式AI的骨架之一。詞嵌入或影像特徵都可看成向量，檢索時以內積或餘弦比較方向；注意力機制中的線性投影把輸入映到 Q, K, V 子空間，其中 $Q, K \in \mathbb{R}^{n \times d_k}$ 、 $V \in \mathbb{R}^{n \times d_v}$ ，softmax逐列形成加權平均[R3]。多模態對齊常把不同模態的特徵投影到共同空間，再以相似度配對，例如影像與文字的對比學習[R4]。低秩近似、LoRA與PCA都依賴SVD或QR這種由正交概念建立的分解[R5]。

在池A的Agent情境中，可以把當下感測向量投影到訓練時建立的表示，用於唯讀檢索SOP與提出工具計畫，並把檢索來源與信心程度一併呈現給人類[R8]。但要強調三點限制：投影相似不等於因果，也不等於健康或病害診斷；線性探針只是近似；Agent不應自動下投餌、加藥或增氧指令，必須由現場專業人員覆核。線性代數提供骨架，非線性、統計、因果推論與控制不可被省略或假裝已證明。

常見錯誤與限制

第一，看到 $(A^\top A)^{-1} A^\top y$ 就以為必須實際求逆；應優先QR或SVD，並檢查秩與條件數。第二，忘記最小平方的關鍵條件是殘差與column space正交，卻用平均絕對誤差代替，導致與投影不一致。第三，特徵單位不同或高度相關時 $A^\top A$ 可能病態，係數對少量擾動極敏感。第四，三筆資料的直線不提供區間估計；本章未引入機率模型，不能說「統計顯著」。第五，投影只是相對於選定子空間與基底的最佳近似，換基底或換特徵都會改變結果。第六，任何擬合都不能代替養殖專業與現場安全程序。第七，把訓練殘差小當成預測好；三點配兩參數本來就容易貼合，這不代表新時段可靠。第八，忽略欄的尺度差異：某特徵數值範圍遠大於另一個時，條件數會更差，宜先標準化，且標準化參數只能由訓練集估計，驗證與測試集只套用，否則會資料洩漏。第九，不要用單一固定seed當成統計可靠性保證。第十，若 A 的columns線性相依，解不唯一，必須明說自由度，不能任意挑一組解就宣稱是唯一模型。

習題

- 基本計算：對 $t = (0, 1, 2)$ 、 $y = (2, 2, 4)$ ，求最小平方直線 $\hat{y} = a + bt$ ，並算殘差平方和。
- 觀念：給 $A \in \mathbb{R}^{5 \times 3}$ 且columns線性獨立，說明 $A^\top A$ 為何可逆，並解釋為何用QR解最小平方通常比直接求 $(A^\top A)^{-1}$ 穩定。
- 養殖應用：池A量測 $t = (0, 1, 2)$ 的溶氧 $y = (1.0, 2.0, 2.0)$ 。若第三筆因校正改為2.2，重算 $\hat{y}$ 的斜率，並說明此變化為何不能直接當成真實池水惡化或改善的證據。

習題解答

1. 先算 $A^T A = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}$, $A^T y = \begin{bmatrix} 2+2+4 \\ 0+2+8 \end{bmatrix} = \begin{bmatrix} 8 \\ 10 \end{bmatrix}$ 。解 $3a + 3b = 8$ 、 $3a + 5b = 10$ ，相減得 $2b = 2$ ，所以 $b = 1$ ；代回 $3a + 3 = 8$ ， $a = 5/3$ 。預測 $\hat{y} = (5/3, 8/3, 11/3)$ 。殘差 $= (2 - 5/3, 2 - 8/3, 4 - 11/3) = (1/3, -2/3, 1/3)$ ，平方和 $= 1/9 + 4/9 + 1/9 = 6/9 = 2/3$ 。可驗算 $A^T r = 0$ 。
2. 若 A 的 columns 線性獨立，則 $Ax = 0$ 只有 $x = 0$ 。對任意 $z \neq 0$ ， $z^T A^T A z = \|Az\|^2 > 0$ ，故 $A^T A$ 對稱正定，因而可逆。直接求逆會把條件數平方，把浮點誤差與輸入擾動放大；QR 先做正交變換， Q 不放大二範數，解上三角系統 $R\hat{x} = Q^T y$ 通常更穩健，且可利用 A 是否滿秩來檢查病態。
3. 新資料 $y = (1.0, 2.0, 2.2)$ ， $A^T y = (5.2, 0 + 2.0 + 4.4) = (5.2, 6.4)$ 。方程 $3a + 3b = 5.2$ 、 $3a + 5b = 6.4$ ，相減得 $2b = 1.2$ ，所以 $b = 0.6$ 。原斜率 0.5，現為 0.6。這只是三筆合成量測與模型設定的變化：未考慮感測誤差、時序相關、其他水質變數與因果，也不能分辨是校正修正或真實變化，故不能宣稱池水真實惡化或改善，更不能據此自動調整設備。

本章小結

正交基底把投影化為係數相加，使每個方向互不干擾；Gram-Schmidt 提供由線性獨立向量建立正交基底的步驟，並導出 QR 分解；最小平方把擬合寫成投影，等價於正規方程 $A^T A \hat{x} = A^T y$ 。但計算時應避免顯式求逆，改用穩定分解，並檢查秩、條件數與殘差是否與 column space 正交。這些工具往後支撐 PCA、正則化、注意力與 Agent 檢索，但都只是在給定假設下的線性近似，不能取代統計、因果推論、控制與養殖專業判斷。

參考來源

[R1] NumPy linear algebra reference。[R2] Deep Learning, Chapter 2: Linear Algebra。[R3] Attention Is All You Need。[R4] Learning Transferable Visual Models From Natural Language Supervision。[R5] LoRA: Low-Rank Adaptation of Large Language Models。[R8] Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks。

第07章 特徵值、對稱矩陣與穩定性

學習目標與先備知識

本章把矩陣看成「沿某些特殊方向放大、縮小或反向」的線性映射。讀完後，讀者應能計算二階矩陣的特徵值與特徵向量，理解實對稱矩陣的譜定理，以二次型判斷正定或半正定，並用譜半徑分析離散線性動態。

先備知識包括矩陣乘法、轉置、行列式、線性獨立與正交。方陣可逆若且唯若其行列式非零；這項性質將用來推導特徵方程。所有向量預設為列向量。以下資料皆為教學合成資料，動態模型只描述特定資料附近的局部變化，不代表真實池況。

從池A提出問題

池A記錄 `temperature_c`、`do_mg_l` 與 `ph`。這些量具有不同單位，不能直接相加比較。本章假設它們已使用訓練集估計的平均數與標準差轉成無單位偏差；驗證與測試資料只能套用相同統計量。現在取兩個轉換後的特徵，組成狀態

$$x_t = \begin{bmatrix} x_{t,1} \\ x_{t,2} \end{bmatrix} \in \mathbb{R}^2,$$

其中 t 是離散時點。設定虛構局部模型

$$x_{t+1} = Ax_t, \quad A \in \mathbb{R}^{2 \times 2}.$$

矩陣通常會同時混合兩個座標，因此只觀察矩陣元素，不容易預測反覆更新的結果。我們希望找出經過 A 作用後方向不變、只有長度與正負改變的向量，再判斷偏差會消失、維持或放大。若另以 $x^T Ax$ 表示某種綜合偏差，也要知道它是否可能為負。這三個問題分別通往特徵向量、譜半徑與正定性。

概念與推導

對方陣 $A \in \mathbb{R}^{d \times d}$ ，若非零向量 $v \in \mathbb{R}^d$ 滿足

$$Av = \lambda v,$$

則 v 稱為特徵向量，純量 λ 稱為對應的特徵值。當 $\lambda > 1$ 時，該方向被放大；當 $0 < \lambda < 1$ 時被縮小；當 $\lambda < 0$ 時還會反向。零向量不能當特徵向量，因為它對每個 λ 都滿足等式，無法指出特殊方向。

移項可得

$$(A - \lambda I)v = 0,$$

其中 $I \in \mathbb{R}^{d \times d}$ 是單位矩陣。若 $A - \lambda I$ 可逆，兩邊左乘其逆矩陣便得到 $v = 0$ ，與定義矛盾。因此它必須不可逆，也就是

$$\det(A - \lambda I) = 0。$$

這是特徵方程。先解出 λ ，再將每個特徵值代回齊次方程，即可求出對應方向。

一般矩陣的特徵向量不一定足以組成基底；實對稱矩陣則有更好的結構。若 $A = A^T$ ，譜定理保證其特徵值皆為實數，並存在由完整正交單位特徵向量基底組成的矩陣

$$Q = [q_1, \dots, q_d] \in \mathbb{R}^{d \times d}, \quad Q^T Q = Q Q^T = I,$$

使得

$$A = Q \Lambda Q^T, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)。$$

這裡 Q 的第 i 個直欄 (column) 是 q_i 。對任意 $x \in \mathbb{R}^d$ ，令 $z = Q^T x$ ，便有 $x = Qz$ ，所以

$$Ax = Q \Lambda z。$$

幾何上， Q^T 先把向量改寫成特徵基底座標， Λ 分別縮放各座標， Q 再將結果轉回原座標。正交轉換不改變向量長度，因此伸縮完全由特徵值控制。

二次型是由向量與方陣產生的純量：

$$x^T A x \in \mathbb{R}。$$

對實對稱矩陣，代入 $x = Qz$ 可得

$$x^T A x = z^T Q^T Q \Lambda Q^T Q z = z^T \Lambda z = \sum_{i=1}^d \lambda_i z_i^2。$$

由於每個 $z_i^2 \geq 0$ ，若所有特徵值皆大於零，則每個 $x \neq 0$ 都滿足 $x^T A x > 0$ ，此時 A 為正定。若所有特徵值皆不小於零，則 $x^T A x \geq 0$ ，此時稱為半正定。半正定矩陣可含零特徵值，因此可能有非零向量使二次型等於零。

矩陣的譜半徑定義為

$$\rho(A) = \max_i |\lambda_i|。$$

對固定的離散線性系統，反覆代入可得

$$x_t = A^t x_0 \circ$$

若 A 可對角化為 $A = P\Lambda P^{-1}$ ，則 $A^t = P\Lambda^t P^{-1}$ ，每個特徵方向的分量乘上 λ_i^t 。更一般地，即使矩陣不可對角化，只要 $\rho(A) < 1$ ，仍有 $A^t x_0 \rightarrow 0$ 。不可對角化時可能出現乘著 λ_i^t 的多項式因子，不能只用獨立特徵方向描述過程。

若存在 $|\lambda_i| > 1$ ，沿其特徵方向的非零分量會放大；但初始向量若完全沒有該分量，軌跡未必顯示放大。當 $\rho(A) = 1$ 時更不能只靠譜半徑下結論。例如 $A = I$ 使狀態保持不變，而某些不可對角化矩陣即使特徵值皆為一，狀態仍可能逐步增長。

手算例題

考慮對稱矩陣

$$A = \begin{bmatrix} 0.8 & 0.1 \\ 0.1 & 0.8 \end{bmatrix} \circ$$

它可視為兩個標準化特徵之間的虛構局部更新，但係數不是生理機制。特徵方程為

$$\det(A - \lambda I) = \begin{vmatrix} 0.8 - \lambda & 0.1 \\ 0.1 & 0.8 - \lambda \end{vmatrix} = (0.8 - \lambda)^2 - 0.01 = 0 \circ$$

因此 $0.8 - \lambda = \pm 0.1$ ，得到

$$\lambda_1 = 0.9, \quad \lambda_2 = 0.7 \circ$$

對 $\lambda_1 = 0.9$ ，

$$(A - 0.9I)v = \begin{bmatrix} -0.1 & 0.1 \\ 0.1 & -0.1 \end{bmatrix} v = 0 \circ$$

所以兩個座標相等，可取單位特徵向量

$$q_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \circ$$

對 $\lambda_2 = 0.7$ ，方程要求兩座標互為相反數，可取

$$q_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \circ$$

兩者內積為零，故令

$$Q = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \Lambda = \begin{bmatrix} 0.9 & 0 \\ 0 & 0.7 \end{bmatrix},$$

便有 $A = Q\Lambda Q^T$ 。

取初始狀態 $x_0 = [2, 0]^T$ 。其特徵座標是

$$z_0 = Q^T x_0 = \begin{bmatrix} \sqrt{2} \\ \sqrt{2} \end{bmatrix}。$$

一步後先縮放為

$$z_1 = \Lambda z_0 = \begin{bmatrix} 0.9\sqrt{2} \\ 0.7\sqrt{2} \end{bmatrix},$$

再轉回原座標：

$$x_1 = Q z_1 = \begin{bmatrix} 1.6 \\ 0.2 \end{bmatrix}。$$

直接計算 Ax_0 也會得到同一結果。進一步地，

$$x_t = Q \begin{bmatrix} 0.9^t & 0 \\ 0 & 0.7^t \end{bmatrix} z_0。$$

因為 $\rho(A) = 0.9 < 1$ ，兩個分量最終都趨近零。又因兩個特徵值皆為正數， A 正定。例如

$$x_0^T A x_0 = [2, 0] \begin{bmatrix} 1.6 \\ 0.2 \end{bmatrix} = 3.2 > 0。$$

這只證明此矩陣的數學性質，不表示池A的實際環境會自行恢復穩定。

Python實驗

以下用 NumPy 的 `eigh` 計算實對稱矩陣的特徵分解，再比較重建結果與六個時點的狀態。回傳矩陣 `Q` 的每一個直欄 (column) 是一個特徵向量，不是每一橫列 (row)。

```
import numpy as np

A = np.array([[0.8, 0.1],
              [0.1, 0.8]])
x = np.array([2.0, 0.0]) # shape: (2,)

values, Q = np.linalg.eigh(A)
A_rebuilt = Q @ np.diag(values) @ Q.T

print(values)
```

```

print(np.round(Q.T @ Q, 6))
print(np.round(A_rebuilt, 6))

for t in range(6):
    print(t, np.round(x, 6))
    x = A @ x

```

預期輸出如下。不同環境可能回傳正負號相反的特徵向量，但 $Q\Lambda Q^T$ 與所代表的特徵方向不受影響。

```

[0.7 0.9]
[[1. 0.]
 [0. 1.]]
[[0.8 0.1]
 [0.1 0.8]]
0 [2. 0.]
1 [1.6 0.2]
2 [1.3 0.32]
3 [1.072 0.386]
4 [0.8962 0.416]
5 [0.75856 0.42258]

```

這段程式應由讀者在隔離環境執行，不連接感測器或設備。浮點輸出中的微小尾差也不應被解讀成池況差異。

連回生成式AI、多模態與Agent

生成式模型的線性層會反覆使用矩陣乘法。特徵分析可協助理解某個方陣沿哪些方向放大表示，但完整模型還包含偏置、非線性、正規化與注意力，不能用單一矩陣的譜取代整體分析。

池A的多模態流程可將感測資料、水面影像與工作日誌分別轉成特徵，再投影到共同表示。若某個線性轉換在少數方向上過度放大，小量輸入差異便可能在後續表示中變得突出；若特徵值接近零，某些方向的資訊則可能被壓縮。這只是代數線索，不等於語義正確或因果證據。

Agent 可以讀取模型摘要、檢索有來源的作業程序，提出唯讀檢查計畫，再把建議送交人工批准。即使局部模型的譜半徑小於一，也不能把「數學狀態收斂」翻譯成「真實池安全」，更不能據此自動投餌、加藥或啟動增氧設備。

常見錯誤與限制

特徵向量不是唯一的：若 v 是特徵向量，任何非零倍數 cv 仍是同方向的特徵向量。重複特徵值也可能對應多個線性獨立方向。只有方陣談自身的特徵值；一般長方形資料矩陣應使用後續介紹的奇異值分解。

並非每個實矩陣都有實特徵值，也不是每個方陣都能對角化。正定與特徵值的簡潔等價敘述以實對稱矩陣為前提。電腦算得的極小負特徵值有時來自浮點誤差，但不能在沒有誤差分析時任意改成零。

最後， $\rho(A) < 1$ 描述的是固定、無外加輸入的線性離散模型。真實池況還涉及感測漂移、缺值、天候、延遲、非線性、未觀測變數與人工作業。局部模型在資料範圍外可能失效，穩定性也不等於狀態符合任何真實物種需求。

習題

1. **基本計算**：求 $B = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ 的特徵值與兩個互相正交的單位特徵向量，並判斷 B 是否正定。
2. **觀念題**：某實對稱矩陣的特徵值為 4, 0, 2。它是正定、半正定，還是兩者皆非？它是否可逆？說明理由。
3. **養殖應用**：虛構池A的局部模型為 $x_{t+1} = Cx_t$ ，且 C 可對角化，特徵值為 0.6 與 1.05。求譜半徑，描述具有第二特徵方向非零分量時的長期行為，並說明為何不能直接據此下達設備指令。

習題解答

1. 特徵方程為 $(3 - \lambda)^2 - 1 = 0$ ，所以特徵值為 4 與 2。對應的單位特徵向量可取 $\frac{1}{\sqrt{2}}[1, 1]^T$ 與 $\frac{1}{\sqrt{2}}[1, -1]^T$ 。兩個特徵值都大於零，因此 B 正定。
2. 所有特徵值皆非負，所以矩陣半正定；因為含有零特徵值，所以不是正定。其行列式等於特徵值乘積 $4 \cdot 0 \cdot 2 = 0$ ，因此不可逆，且存在非零方向使二次型等於零。
3. $\rho(C) = \max(0.6, 1.05) = 1.05$ 。第一特徵方向的分量依 0.6^t 衰減；若初始狀態在第二特徵方向有非零分量，該分量依 1.05^t 放大，所以模型不具漸近穩定性。然而這只是合成資料附近的固定線性近似，沒有納入資料時效、擾動、非線性與設備限制。系統應先檢查資料有效性，再交由現場專業人員覆核。

本章小結

特徵向量指出線性映射中方向不變的軸，特徵值描述各軸的縮放與反向。實對稱矩陣具有完整的正交特徵向量基底，因此可作譜分解；其二次型也能由特徵值判斷正定或半正定。對固定離散線性系統， $\rho(A) < 1$ 保證 $A^t x_0$ 趨近零，但邊界情況與實務模型仍需額外分析。這些工具能解讀生成式與多模態模型的線性骨架，不能取代非線性建模、統計驗證、因果推論、控制設計與人工安全覆核。

參考來源

- [R1] NumPy linear algebra reference。
- [R2] *Deep Learning*, Chapter 2: Linear Algebra。

第08章 奇異值分解與低秩近似

學習目標與先備知識

一張灰階影像能否用較少的數字近似保存？本章將學會辨認奇異值分解的形狀、以奇異值判斷秩、計算截斷誤差，並評估影像壓縮的限制。先備知識是矩陣乘法、轉置、秩與正交投影；不需要微積分。

為避免「行、列」在中文裡有不同用法，下文談影像格線時稱橫向為「橫列」(row)、縱向為「直行」(column)； u_i 、 v_i 則一律是直立書寫的**列向量** (column vector)。

從池A提出問題

假設池A有一張**教學合成**的灰階水面圖。將像素亮度排成 $A \in \mathbb{R}^{h \times w}$ ： h 是橫列數， w 是直行數，數值越大表示越亮。若畫面有大片相似的明暗帶，逐格記錄可能包含重複資訊。我們希望用幾個簡單圖樣相加來近似A。

然而，「整體看起來相似」與「保留值得留意的細節」是兩個問題。假如某個局部圖樣只佔少數像素，刪去它對全圖誤差的影響可能很小，卻仍值得人工查看。本章只研究矩陣表示與壓縮誤差，不從影像推斷池內生物狀態。

概念與推導

令 $A \in \mathbb{R}^{m \times d}$ 為實矩陣， $p = \min(m, d)$ 。其精簡奇異值分解 (SVD) 為

$$A = U \Sigma V^T, \quad U \in \mathbb{R}^{m \times p}, \quad \Sigma \in \mathbb{R}^{p \times p}, \quad V \in \mathbb{R}^{d \times p}.$$

U 與 V 各自的列向量互相正交、長度為1，故 $U^T U = V^T V = I_p$ 。 Σ 是對角矩陣，其對角數字 $\sigma_1 \geq \dots \geq \sigma_p \geq 0$ 稱為奇異值。把乘法按對角位置展開：

$$A = \sum_{i=1}^p \sigma_i u_i v_i^T.$$

其中 $u_i \in \mathbb{R}^m$ 、 $v_i \in \mathbb{R}^d$ ，外積 $u_i v_i^T$ 的形狀是 $m \times d$ ，秩至多為1。非零奇異值的個數等於 $\text{rank}(A)$ 。直覺上， v_i 指定一個輸入方向； A 將它送往 u_i 方向，長度放大 σ_i 倍。這些方向彼此正交，讓各項的貢獻可以分開計算。

取 $0 \leq k \leq p$ ，只保留前 k 項：

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T, \quad \text{rank}(A_k) \leq k.$$

對任意矩陣 B ，Frobenius範數定義為 $\|B\|_F = \sqrt{\sum_{a,b} B_{ab}^2}$ ，即所有元素平方和的平方根。為何截斷誤差只需查看被捨棄的奇異值？令 $C_i = u_i v_i^T$ 。不同項 C_i 、 C_j 的對應元素乘積總和，等於 $(u_i^T u_j)(v_i^T v_j)$ ；當 $i \neq j$ 時，此值為零。每個 C_i 自身的元素平方和則是1。因此，將殘差 $A - A_k$ 逐項平方相加時，交叉項消失，得到

$$\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^p \sigma_i^2}.$$

在所有秩至多為 k 的矩陣中， A_k 使這項誤差最小。若用算子二範數衡量「單一單位輸入方向可能造成的最大輸出誤差」，當 $k < p$ 時，最佳誤差為 σ_{k+1} 。兩種誤差回答不同問題：前者累計所有格子的差異，後者關注最大的方向性偏差；兩者都不直接衡量養殖判讀品質。[R2]

如何選 k ？一種**描述性**指標是保留平方奇異值的比例。若 A 不是零矩陣，可定義

$$E_k = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^p \sigma_i^2}.$$

它表示原矩陣平方範數中有多少比例留在 A_k ，而不是「重要影像細節的保留率」。例如奇異值為4, 2時，保留一項的比例是 $16/(16+4) = 0.8$ ；仍有第二個方向的明暗差異被刪除。若矩陣全為零，分母也為零，這個比例便不適用；此時不必為了得到比例而任意補上一個數。實務上可比較不同 k 的重建圖、局部區域及用途，再決定可否接受壓縮，不能單憑固定比例宣布安全。

儲存 A_k 的兩組向量與奇異值，約需 $k(m+d+1)$ 個數；原矩陣需 md 個數。若前者不小於後者，單就數值數量已沒有壓縮效益。實際檔案大小還取決於編碼、數值精度與檔頭資訊。增加 k 通常降低重建誤差，卻增加儲存量；這是表示成本與近似程度的取捨，而非越小越好的競賽。

****SVD不是特徵分解。***特徵關係 $Av = \lambda v$ 要求 A 為方陣，並比較輸入與輸出是否沿同一方向；一般實方陣的特徵值甚至可能是負數或複數。SVD可處理長方矩陣，容許輸入方向 v_i 與輸出方向 u_i 不同，奇異值必為非負實數。兩者的聯繫是

$$A^T A v_i = \sigma_i^2 v_i, \quad A^T A \in \mathbb{R}^{d \times d}.$$

這個關係可由 $Av_i = \sigma_i u_i$ 及 $A^T u_i = \sigma_i v_i$ 接連相乘得到。因此，右奇異向量與對稱方陣 $A^T A$ 的特徵問題相關，但不能說「 A 的奇異值就是 A 的特徵值」。理解關係也不代表計算時必須先形成 $A^T A$ ；直接使用SVD介面即可。[R1]

手算例題

取 2×2 合成亮度矩陣

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

令 $v_1 = \frac{1}{\sqrt{2}}(1, 1)^T$ 、 $v_2 = \frac{1}{\sqrt{2}}(1, -1)^T$ 。兩向量內積為 $(1 - 1)/2 = 0$ ，長度都為1。逐項相乘：

$$Av_1 = \frac{1}{\sqrt{2}}(4, 4)^T = 4v_1, \quad Av_2 = \frac{1}{\sqrt{2}}(2, -2)^T = 2v_2.$$

在**這個對稱例子**，可取 $u_1 = v_1$ 、 $u_2 = v_2$ ，奇異值為4, 2。保留第一項：

$$A_1 = 4v_1v_1^T = 4 \begin{bmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

相減得 $A - A_1 = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$ ，所以 $\|A - A_1\|_F = \sqrt{1 + 1 + 1 + 1} = 2$ ，等於被捨棄的 σ_2 。原圖較亮的兩格變暗、較暗的兩格變亮，最後四格相同。即使保留了八成平方範數，原有的交錯明暗仍消失了；這正是整體指標不能取代觀看細節的例子。若改留兩項， $A_2 = A_1 + 2v_2v_2^T$ ，第二項恰好補回四格各自的明暗差，殘差為零；增加一項所換得的改善，在這個小例子中可以逐格核對。

Python實驗

以下只在記憶體中建立 4×4 合成灰階圖，供讀者於隔離環境自行執行；不讀取攝影機，也不連接設備。

`full_matrices=False` 取得精簡SVD；當影像不是方形時，前述 $m \times p$ 與 $d \times p$ 形狀尤其值得核對。本例沒有隨機抽樣，因此不需要設定 `seed=42`。

```
import numpy as np

A = np.array([[3., 1., 3., 1.],
              [1., 3., 1., 3.],
              [3., 1., 3., 1.],
              [1., 3., 1., 3.]])
U, s, Vt = np.linalg.svd(A, full_matrices=False)
k = 1
Ak = (U[:, :k] * s[:k]) @ Vt[:, k, :]
print(A.shape, U.shape, s.shape, Vt.shape)
print(np.round(s, 6))
print(np.round(Ak, 1))
print(round(np.linalg.norm(A - Ak, "fro"), 6))
```

輸入是程式內的 A 與 k=1；預期輸出為：

```
(4, 4) (4, 4) (4,) (4, 4)
[8. 4. 0. 0.]
[[2. 2. 2. 2.]
 [2. 2. 2. 2.]
 [2. 2. 2. 2.]
 [2. 2. 2. 2.]]
4.0
```

這張圖由兩種橫列圖樣重複組成，故只有兩個非零奇異值。若將 k 改為 2，理論上可重建原矩陣；但浮點運算的殘差未必恰好是零。同理，判斷數值秩須考慮容差，不能只檢查奇異值是否精確等於零。此處 $k = 1$ 需存 $1(4 + 4 + 1) = 9$ 個因子數值，少於原圖的 16 個；但小圖省下的數量有限，不能由此推定一般檔案一定更小。

連回生成式AI、多模態與Agent

低秩近似提供理解表示容量的起點：少量方向能保存矩陣的主要變化，卻可能捨棄微弱而關鍵的訊號。日後若將池A影像特徵與文字工作日誌，以及 `temperature_c`（攝氏）、`do_mg_l`（mg/L）、`ph`（無量綱）等合成感測資料結合，影像重建誤差不能替代跨模態核對。不同資料還有各自的時間、單位與缺值問題。

生成式AI或許能替壓縮圖寫出流暢描述，但流暢不等於觀察正確。池A的agent取得影像後，仍須檢查資料來源、時間與有效性，才能將其連同感測資料、日誌交給模型參考，並檢索有來源的SOP供人工覆核。SVD是表示工具；它沒有證明描述正確，更沒有完成統計、因果推論或安全控制。

常見錯誤與限制

奇異值大，只表示對指定矩陣誤差尺度貢獻大；細小的局部圖樣可能落在小奇異值項。 A_k 的元素也未必維持原亮度範圍：顯示軟體若將超界數值裁切，裁切又引入一項不同於SVD的誤差，應分開記錄。彩色影像也不能不加說明就當作本章的單一灰階矩陣；若分別壓縮各色彩通道，必須另行檢查重組後的色彩偏差，不能沿用灰階例子的結論。

還要區分「秩至多 k 」與「秩一定是 k 」：若保留的位置已有零奇異值，實際秩較小。若最小非零奇異值相對最大奇異值很小，某些方向的資訊便較容易受擾動影響；這與後續的條件數問題有關，但不能只憑一個小奇異值診斷影像來源有誤。最後，手算矩陣恰好對稱，不能假設一般影像也有 $u_i = v_i$ 。

習題

1. **基本計算**： $D = \text{diag}(5, 3, 0)$ 。取 $k = 1$ ，寫出 D_1 、 $\text{rank}(D)$ 及 $\|D - D_1\|_F$ 。
2. ****觀念**：******某長方矩陣的奇異值為 7, 2, 0。能否說它有特徵值 7, 2, 0？保留兩項的Frobenius誤差是多少？
3. ****養殖應用**：******池A合成影像壓縮後，全圖誤差很小，但人工關注的一小塊水面圖樣消失。能否直接用壓縮圖產生設備操作指令？提出兩項後續檢查。

習題解答

1. $D_1 = \text{diag}(5, 0, 0)$ ；非零奇異值有兩個，故秩為 2。差矩陣只有一個非零元素 3，誤差為 3。
2. 不能。長方矩陣本身沒有通常意義下的特徵值，奇異值也不等同特徵值。保留兩個非零項後只剩 0，誤差為 0。

3. 不能。先回看未壓縮原圖並核對取得時間與來源；再由現場人員比對同時段感測資料及觀察紀錄。模型建議不能代替養殖專業，也不應直接連接設備。

本章小結

SVD將矩陣拆成正交方向上的秩一項；奇異值決定各項對整體平方誤差的貢獻。截斷SVD能提供可計算的最佳低秩近似，但「重建得像」不等於「保留了判讀關鍵」。下一章將討論資料共同變化形成的方向，以及資料切分為何重要。

參考來源

- [R1] NumPy linear algebra reference： `numpy.linalg.svd` 與矩陣範數的介面參考。
<https://numpy.org/doc/stable/reference/routines.linalg.html>
- [R2] *Deep Learning*, Chapter 2: Linear Algebra：SVD與低秩表示的線性代數背景。
https://www.deeplearningbook.org/contents/linear_algebra.html

第09章 共變異數、PCA與資料洩漏

學習目標與先備知識

本章要學會三件事。第一，從中心化且標準化的訓練資料計算樣本共變異數，並理解它度量兩變數如何協同偏離平均。第二，用共變異數矩陣找出主成分，即資料變異最大的方向，並計算各主成分解釋的變異比例。第三，理解資料洩漏：若用測試日的平均或標準差去縮放訓練資料，等於把測試日的資訊提前帶入，評估就不再誠實。

你需要先懂向量、矩陣乘法、特徵值與對稱矩陣譜定理（第7章），以及奇異值分解（第8章）。本章假設讀者熟悉基本Python與NumPy，不需要微積分或機率理論。本章所有資料為教學合成，不提供真實物種適用閾值；PCA輸出不得直接觸發投餌、加藥或增氧，安全操作須由現場專業人員制定。

從池A提出問題

池A連續記錄溫度（攝氏）、溶氧（mg/L）與pH（無量綱）。假設前7天為訓練時段，第8天為測試時段。若要把三維特徵壓到一維以便畫圖或檢索，該選哪個方向？直覺是選「波動最大」的方向。但三個量綱不同，若未標準化，標準差較大的變數會主導共變異數矩陣，主成分方向可能反映量測尺度而非相對變異。另外，若把訓練加測試共8天的平均一起算，再用同一組統計量處理所有日子，測試日就偷偷參與了縮放器的決定，等於在考試前偷看考卷。本章的實驗規則：縮放器與PCA只用訓練時段擬合，測試日只套用。

概念與推導

設訓練批次 $X \in \mathbb{R}^{n \times d}$ ，其中 $n \geq 2$ 、 $d \geq 1$ ，每列一筆觀測；因為以下使用 $n - 1$ 作分母，只有一筆觀測時樣本標準差與共變異數未定義。定義第 i 筆觀測為 $x_i = X_{i,:}^T \in \mathbb{R}^d$ （列向量）。先求樣本平均 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \in \mathbb{R}^d$ ，再求訓練標準差 $\sigma_j = \sqrt{\frac{1}{n-1} \sum_i (x_{ij} - \bar{x}_j)^2}$ 。為避免零標準差導致除零，定義安全標準差 $\tilde{\sigma}_j = \sigma_j$ 若 $\sigma_j > 0$ ，否則 $\tilde{\sigma}_j = 1$ 。令 $\Sigma_{\text{safe}} = \text{diag}(\tilde{\sigma}_1, \dots, \tilde{\sigma}_d) \in \mathbb{R}^{d \times d}$ 。

中心化矩陣為 $Z = X - \mathbf{1}_n \bar{x}^T \in \mathbb{R}^{n \times d}$ ，其中 $\mathbf{1}_n$ 為 n 維全1列向量。標準化矩陣為 $X_s = Z \Sigma_{\text{safe}}^{-1} \in \mathbb{R}^{n \times d}$ ，每列一筆標準化觀測。因 Σ_{safe} 為對角矩陣且對角元非零， $\Sigma_{\text{safe}}^{-1} = \text{diag}(1/\tilde{\sigma}_1, \dots, 1/\tilde{\sigma}_d)$ 存在。

樣本共變異數矩陣為 $S = \frac{1}{n-1} X_s^T X_s \in \mathbb{R}^{d \times d}$ ，其 (j, k) 項為兩標準化變數的樣本共變異數。若不做標準化，直接用 Z 計算 $S_c = \frac{1}{n-1} Z^T Z$ ，則 S_c 是共變異數矩陣；對所有 $\sigma_j > 0$ 的欄位，標準化後的子矩陣等價於樣本相關矩陣；零變異欄應標記並通常自PCA移除，若保留shape則其對應列、欄皆為0，不解釋為相關係數。兩者PCA結果可能不同，因標準化消除了尺度效應。分母 $n - 1$ 是Bessel修正；在獨立同分布且母體二階矩有限的假設下， S_c 是母體共變異數矩陣的無偏估計（此統計論述為教材背景，非本章證明目標）。 S 對稱半正定，可用譜定理對角化： $S = U \Lambda U^T$ ，其中 $U \in \mathbb{R}^{d \times d}$ 正交， U 的第 j 欄即第 j 個主成分方向， $\Lambda = \text{diag}(\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d)$ 。若 λ_j 有重複值，對應特徵子空間維度大於1，主成分方向不唯一，任何正交基皆可。

第 k 個主成分解釋變異比例為 $\lambda_k / \sum_{j=1}^d \lambda_j$ ，前提為 $\sum_{j=1}^d \lambda_j > 0$ ；若總變異為0，PCA方向任意且解釋變異比例未定義。其幾何意義可從二次型推出：在所有單位向量 $u \in \mathbb{R}^d$ 中， $u^T S u$ 度量沿 u 方向的樣本變異。譜定理保證 S 的特徵向量構成正交基，且 $u^T S u$ 的極值恰在特徵方向取得，最大值對應 λ_1 。因此第一主成分就是使投影後樣本變異最大的方向。

資料洩漏的核心規則：所有統計量 ($\bar{x}$ 、 Σ_{safe} 、 S 、 U) 只從訓練時段估計。對單筆測試觀測 $x \in \mathbb{R}^d$ (列向量)，先標準化 $z = \Sigma_{\text{safe}}^{-1}(x - \bar{x}) \in \mathbb{R}^d$ ，再投影到前 k 個主成分 $t = U_k^T z \in \mathbb{R}^k$ ，其中 $U_k \in \mathbb{R}^{d \times k}$ 為前 k 欄。對批次測試 $X_{te} \in \mathbb{R}^{m \times d}$ ，標準化後投影為 $T = X_{te,s} U_k \in \mathbb{R}^{m \times k}$ 。測試日的統計量絕不能回灌到 $\bar{x}$ 、 Σ_{safe} 或 U 。

手算例題

先示範重複特徵值的退化情形。訓練集4筆、2維、已中心化： $(1, 1), (1, -1), (-1, 1), (-1, -1)$ ， $n = 4$ ， $\bar{x} = (0, 0)$ 。

$S_c = \frac{1}{3} \begin{pmatrix} 4 & 0 \\ 0 & 4 \end{pmatrix} = \begin{pmatrix} 4/3 & 0 \\ 0 & 4/3 \end{pmatrix}$ 。兩特徵值相同 $\lambda_1 = \lambda_2 = 4/3$ ，任一正交方向皆為主成分，方向不唯一。此例展示重複特徵值的退化情形，說明為何報告PCA時需檢查特徵值間距。注意各欄樣本變異為 $4/3$ 而非1，故此數據僅已中心化，未標準化。

再示範非退化的原尺度共變異數PCA (未標準化)。訓練集4筆： $(1, 2), (2, 4), (3, 3), (4, 5)$ ， $\bar{x} = (2.5, 3.5)$ 。中心化 Z 各列： $(-1.5, -1.5), (-0.5, 0.5), (0.5, -0.5), (1.5, 1.5)$ 。 $Z^T Z$ 的 $(1, 1)$ ： $2.25 + 0.25 + 0.25 + 2.25 = 5$ ； $(1, 2)$ ： $(-1.5)(-1.5) + (-0.5)(0.5) + (0.5)(-0.5) + (1.5)(1.5) = 2.25 - 0.25 - 0.25 + 2.25 = 4$ ； $(2, 2) = 5$ 。故 $S_c = \frac{1}{3} \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$ 。

特徵值： $\lambda_{1,2} = \frac{5 \pm 4}{3} = 3, \frac{1}{3}$ 。第一主成分方向 $\frac{1}{\sqrt{2}}(1, 1)$ 。解釋變異 = $\frac{3}{3+1/3} = \frac{3}{10/3} = \frac{9}{10} = 90\%$ 。

測試日新點 $(3, 4)$ 套用訓練統計量： $z = (3 - 2.5, 4 - 3.5) = (0.5, 0.5)$ ，投影 $t = \frac{1}{\sqrt{2}}(1, 1) \cdot (0.5, 0.5) = \frac{1}{\sqrt{2}} \approx 0.707$ 。若錯誤地改用含測試日的平均 (此處以4筆訓練加1筆測試示意)， $\bar{x}_{leak} = \frac{4}{5}(2.5, 3.5) + \frac{1}{5}(3, 4) = (2.6, 3.6)$ ，則 $z_{leak} = (0.4, 0.4)$ ，投影 $t_{leak} = \frac{0.8}{\sqrt{2}} \approx 0.566$ 。數值改變看似微小，但問題不在大小而在機制：統計量被測試日污染後，若訓練資料量越小、測試日影響越大，評估偏差越嚴重。此處恰因方向未變而差異有限，但一般情形特徵向量也會偏移。

Python實驗

```
import numpy as np
np.random.seed(42)
# 合成3維特徵: temperature_c, do_mg_l, ph (單位不同)
train = np.random.randn(30, 3) * np.array([1.0, 2.0, 0.5])
test = np.random.randn(5, 3) * np.array([1.0, 2.0, 0.5])

# 樣本共變異數要求至少兩筆；本例不接受缺值或無限值
if train.ndim != 2 or train.shape[0] < 2 or train.shape[1] < 1:
    raise ValueError("訓練資料須為至少兩筆、一個特徵的矩陣")
```

```

if not np.isfinite(train).all() or not np.isfinite(test).all():
    raise ValueError("需先處理缺值或非有限資料")

# 只用訓練集估計縮放器
mu_train = train.mean(axis=0)
sigma_train = train.std(axis=0, ddof=1)
sigma_safe = np.where(sigma_train == 0, 1.0, sigma_train) # 僅處理精確零標準差

# 標準化訓練與測試（測試只套用訓練統計量）
Xs_train = (train - mu_train) / sigma_safe
Xs_test = (test - mu_train) / sigma_safe

# 在標準化訓練資料上擬合PCA
S = Xs_train.T @ Xs_train / (len(train) - 1)
w, U = np.linalg.eigh(S)
idx = np.argsort(w)[::-1]
w, U = w[idx], U[:, idx]

# S來自標準化資料，無量綱；tol是數值容差，不是養殖安全閾值
# 容差隨矩陣維度與譜尺度調整，只容許捨入等級的負特徵值
scale = max(1.0, float(np.max(np.abs(w))))
tol = 32 * np.finfo(float).eps * len(w) * scale
if w.min() < -tol:
    raise ValueError("共變異數出現超出容差的負特徵值，應檢查資料與計算")
w = np.maximum(w, 0.0)
total_var = w.sum()
degenerate = total_var <= tol
if degenerate:
    print("警告：總變異為零或數值上過小，不報告解釋變異比例與投影")
    expl = np.full(len(w), np.nan)
else:
    expl = w / total_var

print("解釋變異:", np.round(expl, 4))
print("mu_train:", np.round(mu_train, 3))
print("sigma_train:", np.round(sigma_train, 3))

# 測試集投影到第一主成分
t_test = np.full(len(test), np.nan) if degenerate else Xs_test @ U[:, 0]
print("測試第一主成分:", np.round(t_test, 4))

```

輸入：固定seed=42的 $n = 30$ 訓練與 $n = 5$ 測試合成矩陣。預期輸出：本例非退化時，解釋變異 為三支數，和在浮點誤差內為1，第一支最大；mu_train 與 sigma_train 為三支數；測試第一主成分 為五支浮點數。讀者應在隔離環境執行以核對實際數值；seed固定只保證可重現，不保證統計可靠性。若總變異精確為零，解釋變異比例在數學上未定義；若僅是數值上過小，則本程式選擇不報告比例與投影。兩者都以 NaN 標記，不能當成正式比例。程式中 sigma_safe 僅處理算得標準差精確為零的欄位；接近零但非零的標準差仍可能放大雜訊，實務應依各特徵單位、量測精度設定並記錄容差，不能把同一絕對容差套到所有物理量。eigh 適用於對稱矩陣（見R1），特徵值排序需手動反轉因 eig 預設升序；總變異為零時已加入檢查。此實驗使用標準化後資料，等價於在相關矩陣上做PCA；若改用未標準化資料，則在共變異數矩陣上做PCA，結果可能不同。

連回生成式AI、多模態與Agent

池A的感測、水面影像與工作日誌各自有維度與變異尺度。PCA可用訓練時段把高維特徵壓到幾維潛在座標，供後續檢索（第18章）或對比學習（第16章）使用。對agent而言，若它在測試日才「決定」用哪組平均去縮放，就等於讓推理過程接觸答案。安全做法：縮放器與PCA在部署前凍結，agent只能呼叫，不能重估。這與第19章「缺值或過期資料先拒絕執行」的規則一致。PCA結果作為檢索或告警的輸入時，仍需人類覆核；線性投影不能替代因果推論或現場專業判斷。

常見錯誤與限制

一是未標準化直接算PCA：各欄標準差差異大時，標準差較大的變數會主導共變異數矩陣，主成分方向可能反映量測尺度而非相對變異。二是把 n 當成分母計算 S_e ：在指定假設下， S_e 不再是母體共變異數矩陣的無偏估計，需全書保持一致。三是用全資料（含測試）做中心化或求特徵向量，造成洩漏。四是混淆解釋變異與殘差最小化：90% 是第一主成分保留的總樣本變異比例；「最小化一維正交重建殘差平方和」是選取第一主成分方向的等價性質，兩者表述角度不同。五是忽略PCA只捕捉線性協變異，非線性結構（如時間週期、閾值效應）未必被捕捉。六是重複特徵值時主成分方向不唯一，報告結果應註明此限制。七是時間序列必須按時間切分（前段訓練、後段測試），不能隨機shuffle，否則未來資訊會滲入訓練。八是零變異欄未處理：若保留於PCA，對應特徵值為0，解釋變異計算需檢查分母非零；建議標記並移除。

習題

- 基本計算**：3筆2維標準化訓練資料 $(1, 0), (0, 1), (-1, -1)$ 。計算 $\bar{x}$ 、 S （分母 $n - 1$ ），並給出兩個特徵值、第一主成分方向（單位向量）與第一主成分解釋變異比例。
- 觀念**：池A按時間切分，前7天訓練、第8天測試。若你先用7天算出 $\bar{x}$ ，再發現第8天感測器有一筆漂移筆誤，若把修正後的第8天也併入資料重算 $\bar{x}$ ，會造成什麼問題？為何正確做法是保留訓練統計量不變，只修正測試集本身？
- 養殖應用**：池A某週標準化後，溫度與溶氧的共變異數接近0。請說明：(a) 第一主成分大概會落在哪個方向；(b) 這是否代表溫度與溶氧「獨立」；(c) 若PCA第一主成分解釋變異80%，agent是否可以用「80%」作為投餌或加藥的依據？

習題解答

- $\bar{x} = (0, 0)$ 。中心化 Z 即原資料。 $Z^T Z = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ ，交叉項為 $1(0) + 0(1) + (-1)(-1) = 1$ 。 $S = \frac{1}{2} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 1/2 \\ 1/2 & 1 \end{pmatrix}$ 。特徵值： $\lambda_{1,2} = 1 \pm \frac{1}{2} = \frac{3}{2}, \frac{1}{2}$ 。第一主成分方向 $\frac{1}{\sqrt{2}}(1, 1)$ （整體反號亦可）。解釋變異 $= \frac{3/2}{3/2+1/2} = \frac{3}{2} \cdot \frac{2}{4} = \frac{3}{4} = 75\%$ 。
- 修正第8天並重算 $\bar{x}$ 等於讓測試日的資訊改變訓練統計量，使訓練與測試共享被污染的參數，後續評估可能失真，不保證偏差一定向上；若僅重算原七天且未改資料，則不構成此處所說的洩漏。正確做法：訓練統計量在切分當下凍結；測試日筆誤只影響測試集本身，不回溯修改縮放器。若漂移嚴重，應標記該測試點為缺值或異常，而非回溯改訓練。

3. (a) 標準化後兩變數變異皆為1，共變異數接近0，故 $S \approx I$ ，特徵值接近但未必相等，第一主成分方向對小擾動敏感；精確相等時方向不唯一。(b) 不代表獨立。零或接近零共變異只表示線性不相關、線性關聯弱；除特定分布假設（如聯合Gaussian）外，不能從零共變異推出獨立，非線性或條件依賴仍可能存在。(c) 不可以。80%解釋變異是線性投影保留的變異比例，不是安全閾值或因果依據；投餌、加藥、增氧必須由現場專業人員依據完整診斷與SOP決定，agent只能提供參考建議。

本章小結

本章建立三條主軸：共變異數矩陣以標準化訓練資料與 $n - 1$ 分母度量協同變異；PCA透過對稱矩陣譜定理找出變異最大的方向與解釋變異比例；資料洩漏要求所有統計量只從訓練時段估計，測試日只套用。標準化處理不同量綱與零標準差欄位，是否標準化應依分析目的決定；時間序列按時間切分避免未來資訊滲入。共變異數PCA與相關矩陣PCA在尺度差異大時結果不同，選用哪種需依問題決定。這些是後續檢索、融合與agent安全判斷的基礎，但PCA只捕捉線性結構，不能替代因果推論、統計推論或現場專業判斷。

參考來源

- R1: NumPy linear algebra reference,
<https://numpy.org/doc/stable/reference/routines.linalg.html>（`eigh` 適用於對稱矩陣的特徵分解）
- R2: Deep Learning, Chapter 2: Linear Algebra,
https://www.deeplearningbook.org/contents/linear_algebra.html（對稱矩陣譜定理、二次型極值與特徵值分解的線性代數基礎）

第10章 範數、條件數與正則化

學習目標與先備知識

本章討論範數、條件數與 ridge 正則化，核心問題是：輸入或量測只改變一點，解或預測會改變多少？你將學會用條件數描述線性系統的敏感程度，並理解 ridge 如何限制係數、同時帶來偏差。

先備知識是向量、矩陣乘法、最小平方與共變異數。第8章介紹的奇異值有理解二範數條件數；第9章強調的資料切分則提醒我們，縮放所需的平均值與標準差只能用訓練集估計，再套用至驗證集與測試集。

從池A提出問題

池A的感測器記錄 temperature_c（攝氏）、do_mg_l（溶氧，mg/L）與 ph（無量綱）。令批次特徵矩陣 $X \in \mathbb{R}^{n \times d}$ ，每列是一筆觀測；係數 $w \in \mathbb{R}^d$ 是列向量，目標 $y \in \mathbb{R}^n$ 。模型預測為 Xw 。

若兩個感測器高度相關，模型可能難以判別它們各自對目標的貢獻。這時小幅量測擾動就可能令係數大幅改變，即使預測變化不大。池A的數值例和程式都是教學合成資料，不提供真實物種適用閾值，也不代表任何養殖操作建議。

概念與推導

向量 $x \in \mathbb{R}^d$ 的歐幾里得範數（ L_2 範數）為

$$\|x\|_2 = \sqrt{\sum_{j=1}^d x_j^2}.$$

它是向量到原點的距離。矩陣 $A \in \mathbb{R}^{m \times n}$ 的誘導二範數定義為

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

因此對所有 x ，都有 $\|Ax\|_2 \leq \|A\|_2 \|x\|_2$ 。矩陣範數衡量映射可能放大向量的程度。直觀上，若某個方向被矩陣拉長很多，該方向的輸入誤差也可能被放大；若某方向幾乎被壓扁，反過來求解時就可能對誤差特別敏感。

考慮可逆方陣 $A \in \mathbb{R}^{n \times n}$ 與方程 $Ax = b$ ，其中 $b \neq 0$ 。若右側變成 $b + \delta b$ ，新解與原解的差為 $\delta x = A^{-1} \delta b$ 。因為 $x = A^{-1}b$ ，使用範數不等式可得

$$\|\delta x\|_2 \leq \|A^{-1}\|_2 \|\delta b\|_2, \quad \|b\|_2 = \|Ax\|_2 \leq \|A\|_2 \|x\|_2.$$

當 A 可逆且 $b \neq 0$ 時， $x \neq 0$ ，所以可除以 $\|x\|_2$ 與 $\|b\|_2$ ，得到

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \|A\|_2 \|A^{-1}\|_2 \frac{\|\delta b\|_2}{\|b\|_2}.$$

此處固定 A ，只考慮右側 b 的擾動。定義

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2.$$

這是矩陣的二範數條件數，至少為 1。條件數越大，最壞情況的相對輸入誤差放大上界越大；它不是每次擾動都會達到的實際放大率。不可逆矩陣的條件數視為無限大。

在線性回歸中，ridge 選擇 $w \in \mathbb{R}^d$ 使

$$J(w) = \|Xw - y\|_2^2 + \lambda \|w\|_2^2, \quad \lambda > 0$$

最小。第一項是殘差平方和，第二項懲罰係數過大。展開平方項：

$$J(w) = w^\top X^\top X w - 2w^\top X^\top y + y^\top y + \lambda w^\top w.$$

不必先學微積分也能理解最小值條件：沿任意方向 $v \in \mathbb{R}^d$ 微調 w ，令新係數為 $w + tv$ 。展開 $J(w + tv)$ ，含 t 的一次項為

$$2t v^\top ((X^\top X + \lambda I)w - X^\top y),$$

另有一個與 t^2 成正比的非負項。若括號內向量不為零，就能選方向 v 使一次項為負。再選足夠小的正 t ，一次項的負值會大於非負的二次項，因此目標值下降。故最小值必須滿足

$$(X^\top X + \lambda I)w = X^\top y.$$

其中 $X^\top X \in \mathbb{R}^{d \times d}$ 、 $I \in \mathbb{R}^{d \times d}$ 、 $X^\top y \in \mathbb{R}^d$ 。對任意非零 $v \in \mathbb{R}^d$ ，

$$v^\top (X^\top X + \lambda I)v = \|Xv\|_2^2 + \lambda \|v\|_2^2 > 0,$$

所以左側矩陣正定且可逆。實作時宜用線性方程求解器，不必明算逆矩陣。

正則化通常使係數縮小，可能降低模型對資料偶然起伏的敏感度；但也可能引入偏差，使模型無法完全貼合資料。 λ 太小可能無法抑制不穩定，太大則可能壓低有用訊號。若模型過度追隨訓練資料的細節，預測在新資料上可能起伏較大；限制係數有時能降低這種變動，代價是引入一些系統性的偏差。這種偏差與變異的折衷應用驗證資料評估，而不是只看訓練誤差。

手算例題

令

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 0.1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 0.1 \end{bmatrix}, \quad \delta b = \begin{bmatrix} 0 \\ 0.01 \end{bmatrix}.$$

逐列求解 $Ax = b$ ：第一列給出 $x_1 = 1$ ，第二列給出 $0.1x_2 = 0.1$ ，所以 $x = (1, 1)^\top$ 。擾動後右側為 $(1, 0.11)^\top$ ，新解為 $(1, 1.1)^\top$ ，故 $\delta x = (0, 0.1)^\top$ 。

右側相對變化為

$$\frac{\|\delta b\|_2}{\|b\|_2} = \frac{0.01}{\sqrt{1^2 + 0.1^2}} \approx 0.00995.$$

解的相對變化為

$$\frac{\|\delta x\|_2}{\|x\|_2} = \frac{0.1}{\sqrt{1^2 + 1^2}} \approx 0.0707.$$

實際放大約為 $0.0707/0.00995 \approx 7.11$ 倍。此對角矩陣的奇異值是 1 與 0.1，所以 $\|A\|_2 = 1$ 、 $\|A^{-1}\|_2 = 10$ ，條件數為 10；實際放大小於最壞情況上界。小擾動落在矩陣較弱的方向，因此解的相對變化比右側大。

Python實驗

以下讓兩欄代理特徵高度相關，並對目標值加入一筆小擾動，比較普通最小平方的係數與預測。兩欄是無實體單位的合成代理特徵，不是直接混用攝氏與 mg/L。資料刻意設計得簡單，方便手動檢查；NumPy 的輸出是預期值，非程式已執行結果。

```
import numpy as np

np.set_printoptions(precision=3, suppress=True)

u = np.array([-2., -1., 0., 1., 2.])
s = np.array([1., -1., 1., -1., 1.])
eps = 0.01

X = np.column_stack([u, u + eps * s])
y0 = u.copy()
y1 = y0.copy()
y1[0] += 0.02 # 一筆目標值的小擾動

w0 = np.linalg.lstsq(X, y0, rcond=None)[0]
w1 = np.linalg.lstsq(X, y1, rcond=None)[0]
p0 = X @ w0
p1 = X @ w1

print("correlation:", np.corrcoef(X.T)[0, 1])
print("w before:", w0)
print("w after: ", w1)
print("prediction change:", p1 - p0)
```

預期輸出約為：

```
correlation: 1.0
w before: [1. 0.]
w after: [0.596 0.4 ]
prediction change: [ 0.012  0.      0.004 -0.008 -0.004]
```

相關係數顯示為 1.0 是因為輸出只保留三位小數，兩欄並非完全相同。原始目標 $y_0 = u$ 可由第一欄精確表示，因此係數為 (1, 0)。目標第一筆增加 0.02 後，係數約變為 (0.596, 0.400)，顯示兩個高度相關的特徵之間重新分配了係數；但預測最大改變只有 0.012。這說明係數可以明顯改變，而預測仍只小幅變動。相關特徵使分辨各欄貢獻變得困難，但擾動效果仍取決於擾動方向和資料形狀，不能只由相關係數推斷每次變化的大小。

實驗也比較了擾動前後的係數和預測，而非只看訓練誤差。若要比較 ridge，可在資料縮放、截距處理及 λ 選擇方式一致的條件下，求解 $(X^T X + \lambda I)w = X^T y$ ，再比較係數和預測。 λ 應由訓練資料以外的驗證資料選擇；不同特徵尺度會影響懲罰效果，縮放器只能在訓練集擬合。此處只示範一組擾動，不足以證明任何普遍的預測性能。

連回生成式AI、多模態與Agent

池A若加入水面影像特徵或工作日誌的文字表示，模型就同時接收感測、影像與文字欄位。新特徵可能提供新資訊，也可能重複已有資訊；若特徵高度相關或尺度差距很大，線性層的係數仍可能不穩。多模態融合不能只靠增加欄位，還需要檢查資料品質、訓練與驗證切分，以及各模態特徵的縮放方式。

生成式AI中的線性層也使用矩陣運算，因此範數和條件數有助理解數值穩定性。但線性代數只是生成式AI的骨架；非線性、統計、因果推論與控制不能由本章推導省略或假裝已證明。若Agent檢索SOP後提出建議，仍需檢查資料有效性並取得人工批准；示範不連接真實設備，也不下投餌、加藥或增氧指令。模型建議不能代替養殖專業，安全操作須由現場專業人員制定。

常見錯誤與限制

條件數大表示存在容易放大的方向，不代表任何輸入都會產生大誤差；條件數小也不保證量測正確或模型適用。相關特徵可能令係數難以辨識，即使模型預測尚穩定，也不宜把單一係數直接解讀為感測器的獨立影響。

ridge 的 λ 受特徵尺度影響。若對特徵做標準化，平均值與標準差只能用訓練集估計，驗證集和測試集只套用相同轉換。不要用測試集挑選 λ 或縮放方式，否則評估會洩漏測試資料資訊。

正則化不能修復錯誤單位、感測器校正問題、缺值或資料時間戳失效。池A的合成範例不涵蓋真實池況，不能推導物種閾值或安全操作。

習題

1. 基本計算： $A = \text{diag}(1, 0.2)$ 。求 $\|A\|_2$ 、 $\|A^{-1}\|_2$ 與 $\kappa_2(A)$ 。

2. **觀念**：ridge 目標中的 $\lambda \|w\|_2^2$ 對係數有何作用？為何不能只依訓練誤差選擇 λ ？
3. **池A應用**：兩個相關感測器生成的特徵欄近乎相同，普通最小平方係數對少量讀數擾動很敏感。提出一種可試的方法，以及一項不可省略的資料檢查。

習題解答

1. 最大奇異值是 1，最小奇異值是 0.2。因此 $\|A\|_2 = 1$ 、 $\|A^{-1}\|_2 = 5$ ，且 $\kappa_2(A) = 1 \times 5 = 5$ 。
2. 懲罰項使大係數付出較高代價，促使係數縮小。 λ 太大可能壓低有用訊號，太小則可能保留不穩定係數。訓練誤差不能衡量未見資料的表現，應用獨立驗證資料選擇 λ 。
3. 可試 ridge，使用訓練資料擬合，並以驗證資料選擇 λ ；再比較擾動前後係數與預測。還要檢查感測器單位、校正、缺值與時間有效性；正則化不能修復無效輸入。

本章小結

範數衡量向量或映射的大小；條件數描述線性方程最壞情形的相對誤差放大上界。高度相關的特徵可能使係數對小擾動敏感，而預測仍相近。ridge 以懲罰係數大小換取穩定性，代價是可能引入偏差。選擇正則化強度時，要使用恰當切分的驗證資料，也要先確認輸入資料有效。

參考來源

- R1：NumPy linear algebra reference，
<https://numpy.org/doc/stable/reference/routines.linalg.html>
- R2：Deep Learning, Chapter 2: Linear Algebra，
https://www.deeplearningbook.org/contents/linear_algebra.html

第11章 梯度、Jacobian與反向傳播

學習目標與先備知識

本章要從「導數」這個高中概念出發，推廣到多變數的偏導、梯度與 Jacobian，並用它解釋神經網路如何靠反向傳播，算出每個參數該往哪個方向調整。讀者只需要會多項式微分，以及第3章的向量與矩陣乘法。我們不預設你懂微積分全貌，也不預設深度學習背景；所有符號都會先定義。

讀完本章，你應該能：對一個平方損失的線性層手算梯度；說出梯度與 Jacobian 的形狀差異；用有限差分檢查自己算的梯度方向是否正確；理解反向傳播其實就是鏈式法則的矩陣化排程；並知道梯度只是「局部」資訊，不等於養殖決策。

向量一律視為列向量（column vector，直向排列），記作 $\mathbf{x} \in \mathbb{R}^d$ 。矩陣 $\mathbf{W} \in \mathbb{R}^{m \times d}$ ，線性層寫成 $\mathbf{y} = \mathbf{W}\mathbf{x} \in \mathbb{R}^m$ 。批次資料 $\mathbf{X} \in \mathbb{R}^{n \times d}$ ，每個 row（橫列）是一筆觀測，輸出 $\mathbf{Y} = \mathbf{X}\mathbf{W}^\top$ 。文中我們會反覆強調：哪個量是行、哪個量是列，以及每個符號的形狀，因為絕大多數手算錯誤都來自形狀沒對齊。

從池A提出問題

池A有一組虛構的感測器，每個時間點記錄溫度 temperature_c、溶氧 do_mg_l 與酸鹼值 ph 三個實數，用向量 $\mathbf{x} = (x_1, x_2, x_3)^\top$ 表示。假設我們想做一個極小的線性模型，把三個感測值映到兩個「隱藏分數」，例如 $\mathbf{y} = \mathbf{W}\mathbf{x}$ ，再由後續步驟判斷是否提醒人員注意。

要讓模型「接近」某個教學用的目標值 $\mathbf{t}$ ，就得定義一個誤差。最常見的是平方損失

$$L(\mathbf{W}) = \frac{1}{2} \|\mathbf{W}\mathbf{x} - \mathbf{t}\|_2^2.$$

問題來了： $\mathbf{W}$ 裡有 $m \times d$ 個數字， L 到底是哪一個參數的函數？該調哪個數字、往哪邊調、調多少？這正是梯度要回答的。我們不會連上池A設備，也不下任何投餌或增氧指令；這裡全部是紙上與合成資料的練習。

概念與推導

從純量導數橋接。對單變數函數 $f(x)$ ，導數 $f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$ 描述「 x 增加一點點時 f 變化多快」。多變數時，我們一次只動一個變數、其餘固定，這叫偏導：

$$\frac{\partial f}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(\dots, x_i + h, \dots) - f(\dots, x_i, \dots)}{h}.$$

把對每個變數的偏導排成一個向量，就是梯度

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_d} \right)^\top \in \mathbb{R}^d.$$

梯度指向函數上升最快的方向，第 i 個分量正是「只動 x_i 」的瞬時變化率。這是反向傳播最小的一塊磚。

Jacobian。若函數不是純量，而是向量值 $\mathbf{f} : \mathbb{R}^d \rightarrow \mathbb{R}^m$ ， m 個輸出各自對 d 個輸入偏導，排成 $m \times d$ 矩陣，就是 Jacobian：

$$\mathbf{J} = \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \in \mathbb{R}^{m \times d}, \quad J_{ij} = \frac{\partial f_i}{\partial x_j}.$$

對線性層 $\mathbf{y} = \mathbf{W}\mathbf{x}$ ，因為 $y_i = \sum_j W_{ij}x_j$ ，所以 $\partial y_i / \partial x_j = W_{ij}$ ，Jacobian 恰好等於 $\mathbf{W}$ ： $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{W}$ 。這個結果是後面鏈式法則的基本積木。

鏈式法則。若 $\mathbf{u} = g(\mathbf{x})$ 且 $L = h(\mathbf{u})$ ，則

$$\nabla_{\mathbf{x}} L = J_g(\mathbf{x})^\top \nabla_{\mathbf{u}} L \in \mathbb{R}^d.$$

本章梯度均為 column vector；對純量損失，後文的 $\partial L / \partial \mathbf{x}$ 也表示同一個梯度，而非 $1 \times d$ 的純量函數 Jacobian。純量函數的 Jacobian 是梯度的轉置，兩種表示不能混用。反向傳播由後往前，逐層以局部 Jacobian 的轉置作用於梯度。

形狀為什麼一定會對齊。假設 $\mathbf{u} \in \mathbb{R}^p$ 、 $\mathbf{x} \in \mathbb{R}^d$ ，則 $J_g = \partial \mathbf{u} / \partial \mathbf{x}$ 的形狀是 $p \times d$ ， $\nabla_{\mathbf{u}} L$ 為 $p \times 1$ 。兩者依上式相乘，形狀為 $(d \times p)(p \times 1) = d \times 1$ ，與 $\nabla_{\mathbf{x}} L$ 一致。你可以把這條「形狀帳」當成檢查推導的第一道關卡：只要中間維度接不起來，式子一定錯了。梯度對參數的形狀也遵循同一規則，例如 $\partial L / \partial \mathbf{W}$ 與 $\mathbf{W}$ 同是 $m \times d$ ，否則「參數減去學習率乘梯度」無法逐元素相減。

用一個純量兩層網路看「由後往前」。為了不讓矩陣符號蓋住直覺，先看純量版本： $h = w_1 x$ ， $y = w_2 h$ ， $L = \frac{1}{2}(y - t)^2$ 。由後往前算：

$$\frac{\partial L}{\partial y} = y - t, \quad \frac{\partial y}{\partial w_2} = h, \quad \frac{\partial y}{\partial h} = w_2, \quad \frac{\partial h}{\partial w_1} = x.$$

鏈式法則給 $\frac{\partial L}{\partial w_2} = (y - t)h$ 與 $\frac{\partial L}{\partial w_1} = (y - t)w_2 x$ 。注意對 w_1 的梯度裡含了 w_2 ：前層參數的梯度會用到後層的權重，這就是「由後往前」傳遞的實質。反向傳播不是新數學，而是把同一條鏈式法則針對每一層快取中間量、避免重複計算的工程化做法。

平方損失線性層的梯度推導。令 $L = \frac{1}{2} \|\mathbf{y} - \mathbf{t}\|_2^2$ ， $\mathbf{y} = \mathbf{W}\mathbf{x}$ 。先用鏈式法則把 L 對 $\mathbf{y}$ 求梯度： $\frac{\partial L}{\partial \mathbf{y}} = \mathbf{y} - \mathbf{t} \in \mathbb{R}^m$ 。再對參數 $\mathbf{W}$ ：因為 $y_i = \sum_j W_{ij}x_j$ ，

$$\frac{\partial L}{\partial W_{ij}} = \sum_k (y_k - t_k) \frac{\partial y_k}{\partial W_{ij}} = (y_i - t_i)x_j.$$

把所有 i, j 收集起來：

$$\frac{\partial L}{\partial \mathbf{W}} = (\mathbf{y} - \mathbf{t})\mathbf{x}^\top \in \mathbb{R}^{m \times d}.$$

同理對輸入 $\mathbf{x}$ ： $\partial L / \partial \mathbf{x} = \mathbf{W}^\top (\mathbf{y} - \mathbf{t}) \in \mathbb{R}^d$ 。注意外積 $(\mathbf{y} - \mathbf{t})\mathbf{x}^\top$ 的形狀與 $\mathbf{W}$ 一致，這不是巧合——梯度永遠和參數同形狀，才能「沿負梯度更新」。

手算例題

取 $d = 2$ 、 $m = 2$ ：

$$\mathbf{W} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{t} = \begin{bmatrix} 4 \\ 10 \end{bmatrix}.$$

前向。 $\mathbf{y} = \mathbf{W}\mathbf{x} = [1 \cdot 1 + 2 \cdot 2, 3 \cdot 1 + 4 \cdot 2]^\top = [5, 11]^\top$ 。誤差 $\mathbf{y} - \mathbf{t} = [1, 1]^\top$ ，損失 $L = \frac{1}{2}(1^2 + 1^2) = 1$ 。

梯度。 $\frac{\partial L}{\partial \mathbf{W}} = (\mathbf{y} - \mathbf{t})\mathbf{x}^\top = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 1 & 2 \end{bmatrix}$ 。對輸入 $\frac{\partial L}{\partial \mathbf{x}} = \mathbf{W}^\top (\mathbf{y} - \mathbf{t}) = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 6 \end{bmatrix}$ 。

有限差分核對。 只把 W_{11} 從 1 增加 $\varepsilon = 0.01$ ，其餘不動：新 $\mathbf{y} = [1.01 + 4, 11]^\top = [5.01, 11]^\top$ ，新損失 $L' = \frac{1}{2}(1.01^2 + 1^2) = 1.01005$ 。數值斜率 $\frac{L' - L}{\varepsilon} = \frac{0.01005}{0.01} = 1.005$ ，與解析值 $\partial L / \partial W_{11} = 1$ 在此近似下相符（差 0.005 來自 ε 非零，所以這是「近似」而非等號）。這說明手算的梯度方向正確。

Python實驗

以下片段只做算術，讀者請在隔離環境自行執行；教材不代為執行、不連任何設備。

```
import numpy as np

W = np.array([[1., 2.], [3., 4.]])
x = np.array([1., 2.])
t = np.array([4., 10.])

y = W @ x
L = 0.5 * np.sum((y - t) ** 2)

dW = np.outer(y - t, x)      # 解析梯度，形狀 (2,2)
dx = W.T @ (y - t)          # 對輸入的梯度，形狀 (2,)

eps = 1e-5
Wp = W.copy(); Wp[0, 0] += eps
Lp = 0.5 * np.sum((Wp @ x - t) ** 2)
num_dW00 = (Lp - L) / eps    # 對 W[0,0] 的數值斜率

print("L =", L)
print("dW =", dW.tolist())
print("dx =", dx.tolist())
print("num_dW00 =", num_dW00)
```

預期輸出（數值為本教材推導結果，供讀者核對）：

```
L = 1.0
dW = [[1.0, 2.0], [1.0, 2.0]]
dx = [4.0, 6.0]
num_dW00 = 1.000005
```

數值斜率 1.000005 與解析梯度 1.0 相去極小，差異反映 ε 造成的截斷誤差。若把 ε 改到 10^{-7} ，數值誤差可能因浮點相消而變大；實務常用中心差分 $(L(W_{ij} + \varepsilon) - L(W_{ij} - \varepsilon)) / (2\varepsilon)$ 來降低誤差。此處輸出尚未經人工執行驗證，讀者應自行跑一遍再採用。

連回生成式AI、多模態與Agent

生成式AI的訓練，本質是對一個非常大的損失函數做同樣的事：用鏈式法則把「每個參數對損失的偏導」一層層算出來，再一次更新。梯度與 Jacobian 是這個過程的語言：梯度告訴你純量損失對每個參數的方向，Jacobian 描述一層向量輸出對向量輸入的局部線性關係。反向傳播不是新數學，而是把本章的鏈式法則用矩陣乘法高效地由後往前排程。注意力、LoRA、擴散模型等後續章節，其可訓練參數的更新最終都回到這個骨架。

在池A的系統裡，感測器、水面影像與工作日誌會先變成特徵向量，再經過一層層線性（與非線性）轉換。檢索模組比較查詢與文件 embedding 的相似度，agent 再組裝建議。要注意：在函數可微且梯度非零時，負梯度是局部下降方向；足夠小的正步長才保證損失下降，它不保證真實池子的水質會改善，也不代表模型建議可以取代現場專業。非線性、統計與因果推論都是本章無法省略的部分，線性骨架只是起點。

常見錯誤與限制

第一，把梯度當成「答案」。梯度只是局部斜率，學習率太大會震盪、太小會停滯，這些需要另外的訓練理論解釋。第二，形狀錯亂： $\partial \mathbf{y} / \partial \mathbf{x}$ 是 $m \times d$ 的 Jacobian，而 $\partial L / \partial \mathbf{x}$ 是長度 d 的梯度，兩者不能混用。第三，有限差分只是檢查工具；當參數很多、函數有噪聲或不連續時，數值斜率會不可靠。第四，反向傳播需要函數可微；遇到不可微的激活函數（如 ReLU 在原點）時，實務上使用次梯度或近似處理，並非任意函數都能直接套用。第五，本章所有數值都是教學合成，並非真實池A資料，也不構成投餌、加藥或增氧的安全依據。

習題

習題1（基本計算）。 令 $\mathbf{W} = \begin{bmatrix} 2 & 0 \\ 1 & 3 \end{bmatrix}$ ， $\mathbf{x} = [1, 1]^\top$ ， $\mathbf{t} = [1, 5]^\top$ ，損失為 $\frac{1}{2} \|\mathbf{W}\mathbf{x} - \mathbf{t}\|_2^2$ 。求 $\partial L / \partial \mathbf{W}$ 與 $\partial L / \partial \mathbf{x}$ 。

習題2（觀念）。 為什麼對 $L = \frac{1}{2} \|\mathbf{W}\mathbf{x} - \mathbf{t}\|_2^2$ ，梯度 $\partial L / \partial \mathbf{W}$ 的形狀必定與 $\mathbf{W}$ 相同？若改用中心差分檢查梯度，你預期誤差會比單邊差分大還是小，為什麼？

習題3 (養殖應用)。池A想用一個線性層把三個標準化水質特徵 (x_1, x_2, x_3) 映到一個「注意分數」 y ，再與人工標記的教學目標 t 比較。設 $\mathbf{w} = [0.5, -0.2, 0.1]^\top \in \mathbb{R}^3$ 為權重向量， $y = \mathbf{w}^\top \mathbf{x}$ (即 $m = 1$)， $\mathbf{x} = [1, 0, 1]^\top$ ， $t = 0.5$ 。請寫出 L 、算出 $\partial L / \partial \mathbf{w}$ ，並說明這個分數為什麼不能直接當成病害診斷或投餌指令。

習題解答

習題1。 $\mathbf{y} = [2, 4]^\top$ ， $\mathbf{y} - \mathbf{t} = [1, -1]^\top$ ， $L = \frac{1}{2}(1 + 1) = 1$ 。外積 $\partial L / \partial \mathbf{W} = [1, -1]^\top [1, 1] = \begin{bmatrix} 1 & 1 \\ -1 & -1 \end{bmatrix}$ 。對輸入 $\partial L / \partial \mathbf{x} = \mathbf{W}^\top (\mathbf{y} - \mathbf{t}) = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} [1, -1]^\top = [1, -3]^\top$ 。可用 $\varepsilon = 0.01$ 對 W_{11} 核對：新 $L' = \frac{1}{2}(1.01^2 + 1) = 1.01005$ ，斜率 $1.005 \approx 1$ 。

習題2。梯度是「每個參數各自對損失的偏導」，每個參數對應一個分量，所以梯度矩陣的形狀永遠和參數一致； $\mathbf{W}$ 是 $m \times d$ ，梯度自然是 $m \times d$ 。中心差分用對稱兩點平均，截斷誤差通常是 $O(\varepsilon^2)$ ，單邊差分是 $O(\varepsilon)$ ，因此中心差分在小 ε 下誤差更小（但浮點相消風險仍需注意）。

習題3。 $y = \mathbf{w}^\top \mathbf{x} = 0.5 \cdot 1 + (-0.2) \cdot 0 + 0.1 \cdot 1 = 0.6$ ，誤差 $y - t = 0.1$ ， $L = \frac{1}{2}(0.1)^2 = 0.005$ 。梯度 $\nabla_{\mathbf{w}} L = (y - t)\mathbf{x} = 0.1 \cdot [1, 0, 1]^\top = [0.1, 0, 0.1]^\top$ ，與 $\mathbf{w}$ 同為 3×1 。這個「注意分數」只是一個教學線性層的輸出，沒有因果或診斷意義；缺少水質閾值來源、缺值檢查與人工覆核時，不能據此下任何投餌或加藥指令。

本章小結

本章從純量導數出發，建立偏導、梯度與 Jacobian，並用鏈式法則推導線性層平方損失的梯度。核心結論有四：梯度與參數同形狀、Jacobian 描述向量函數的局部線性關係、鏈式法則的形狀帳可以自我檢查、反向傳播是鏈式法則由後往前的矩陣化排程。有限差分可作為梯度檢查工具，但不是證明。所有數值皆為教學合成，模型輸出不能取代養殖專業。

參考來源

- [R1] NumPy linear algebra reference
- [R2] Deep Learning, Chapter 2: Linear Algebra

第12章 Embedding、線性層與機率輸出

學習目標與先備知識

本章沿著「詞元編號、向量表示、仿射分數、機率輸出」建立生成式模型的基本運算鏈。學完後，讀者應能用查表與矩陣乘法解釋 embedding，追蹤單筆及批次資料的形狀，手算仿射層、數值穩定 softmax 與交叉熵，並說明生成機率為何不等於操作安全性。

先備知識為矩陣乘法、轉置、指數與對數的基本概念，以及基礎 Python。所有單筆向量預設為列向量；批次矩陣則約定每列是一筆觀測。這兩種排法看似不同，實際上只是為了讓批次運算符合常見程式介面。

從池A提出問題

池 A 的虛構工作日誌包含「觀測」「溶氧」「正常」「檢查」「增氧」等詞。電腦無法直接把文字放進矩陣乘法，因此先將文字切成詞元，為每個詞元指定整數編號，再把編號映成固定維度的向量。這個向量稱為 embedding。

假設模型讀到「溶氧」，某個簡化輸出頭要在「正常」「檢查」「增氧」三類之間分配機率。分數較高表示模型依據訓練模式較偏好該輸出，並不表示模型已量測池水、理解養殖因果或驗證設備狀態。尤其「增氧」具有操作語意，即使機率最高，也只能當作待審查文字，不能轉成真實設備指令。

本章資料全為教學合成，不提供任何真實物種的適用閾值。完整流程仍須把池 A 的感測器、影像與日誌特徵交由模型處理，再檢索有來源的 SOP、檢查資料有效性，最後等待現場專業人員批准。

概念與推導

設詞彙表共有 V 個詞元，embedding 維度為 d 。定義嵌入矩陣

$$E \in \mathbb{R}^{V \times d},$$

其中第 i 列存放第 i 個詞元的表示。若輸入編號為 i ，查表就是取出該列，再依單筆向量慣例轉成列向量：

$$x = E_{i,:}^T \in \mathbb{R}^d.$$

這裡的「第 i 列」指矩陣橫向的一列，而 x 是直向排列的 column vector。為了看出查表也是線性代數，可定義獨熱向量 $e_i \in \mathbb{R}^V$ ：第 i 個元素為 1，其餘為 0。於是

$$x = E^T e_i, \quad E^T \in \mathbb{R}^{d \times V}.$$

矩陣乘法會保留 E^T 的第 i 欄，也就是 E 的第 i 列轉置。實作通常直接依編號取列，因為建立充滿零的獨熱向量既浪費記憶體，也沒有改變結果。embedding 的數值一般由訓練調整；單一座標通常沒有「溶氧」或「安全」這種固定人工意義。

若一次輸入 n 個詞元，查表後把各向量橫放成

$$X \in \mathbb{R}^{n \times d}.$$

此時每列對應一個詞元，每行對應一個表示座標。設輸出類別數為 m ，權重 $W \in \mathbb{R}^{m \times d}$ 、偏置 $b \in \mathbb{R}^m$ 。單筆仿射層為

$$z = Wx + b \in \mathbb{R}^m.$$

若 $b \neq 0$ ，此映射不是線性映射，因為 $f(0) = b \neq 0$ ；但它是線性映射加平移，所以稱為仿射映射。第 j 個輸出分數等於 W 第 j 列與 x 的加權組合，再加上 b_j 。

批次形式為

$$Z = XW^T + \mathbf{1}_n b^T \in \mathbb{R}^{n \times m},$$

其中 $\mathbf{1}_n \in \mathbb{R}^n$ 的元素皆為 1。 XW^T 的形狀是 $(n \times d)(d \times m) = (n \times m)$ ； $\mathbf{1}_n b^T$ 也是 $n \times m$ ，作用是讓每一筆資料都加上相同偏置。實務中的廣播語法只是省略顯式建立這個矩陣。

分數 z_j 可為任意實數，尚不能直接解讀為機率。softmax 定義為

$$p_j = \frac{\exp(z_j)}{\sum_{k=1}^m \exp(z_k)}, \quad \sum_{j=1}^m p_j = 1.$$

因為指數值為正，所以每個 p_j 皆為正，總和則因共同分母而等於 1。分數差距決定機率比例：

$$\frac{p_a}{p_b} = \exp(z_a - z_b).$$

若兩個分數相同，兩類機率也相同；分數增加一個單位不代表機率固定增加多少。若所有分數同加常數 a ，每個指數都同乘 $\exp(a)$ ，在分子與分母中相消，因此 softmax 不變。

直接計算很大的 $\exp(z_j)$ 可能溢位。令 $c = \max_j z_j$ ，改算

$$p_j = \frac{\exp(z_j - c)}{\sum_k \exp(z_k - c)}.$$

分子與分母同乘 $\exp(-c)$ ，所以結果不變。減去最大值後，最大的指數為 $\exp(0) = 1$ ，其他指數不超過 1，因此較穩定。批次資料必須對 Z 的每一列分別取最大值與做 softmax，不能把不同樣本混成一個分布。

若正確類別編號為 t ，且 t 有效、 $p_t > 0$ ，單筆交叉熵為

$$L = -\log p_t.$$

也可用目標獨熱向量 $q \in \mathbb{R}^m$ 表示，其中 $q_t = 1$ ，其餘為零：

$$L = -\sum_{j=1}^m q_j \log p_j = -\log p_t.$$

第一個等號會把各類的對數機率加權；因為只有正確類別的權重為一，最後只留下 p_t 。當 p_t 接近 1，損失接近 0；當 p_t 很小，損失很大。對 n 筆資料可取平均損失，但較小的訓練損失不保證面對新情境仍可靠。若正確類別遭遮罩而使 $p_t = 0$ ，則損失為無限大，該筆資料不能不加處理地照常訓練。

手算例題

建立三類輸出：0 = 「正常」、1 = 「檢查」、2 = 「增氧」。假設輸入詞元「溶氧」查表後得到

$$x = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad W = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 0 \\ 0 \\ -1 \end{bmatrix}.$$

形狀分別為 $x \in \mathbb{R}^2$ 、 $W \in \mathbb{R}^{3 \times 2}$ 、 $b \in \mathbb{R}^3$ 。逐列計算可得

$$Wx = \begin{bmatrix} 1 \cdot 1 + 0 \cdot 2 \\ 0 \cdot 1 + 1 \cdot 2 \\ 1 \cdot 1 + 1 \cdot 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

加入偏置後，

$$z = Wx + b = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

減去最大值 2，得到 $[-1, 0, 0]^T$ 。因為 $\exp(-1) \approx 0.3679$ ，分母為 $0.3679 + 1 + 1 = 2.3679$ ，所以

$$p \approx \begin{bmatrix} 0.3679/2.3679 \\ 1/2.3679 \\ 1/2.3679 \end{bmatrix} = \begin{bmatrix} 0.1554 \\ 0.4223 \\ 0.4223 \end{bmatrix}.$$

若正確類別是「檢查」，則

$$L = -\log(0.4223) \approx 0.862.$$

「檢查」與「增氧」同為最高機率，只表示兩者分數相同。若系統必須選一類，程式的平手處理規則可能影響結果；這更說明機率輸出不能直接取得設備控制權。

Python實驗

以下建立五詞輸入詞彙，但輸出只使用「正常」「檢查」「增氧」三類。這是一個獨立的三類分類頭，用來練習矩陣形狀；它不是完整詞彙表上的下一詞預測。

語義遮罩把「增氧」排除於唯讀摘要模式之外。遮罩只限制可輸出的類別，不會驗證剩餘文字是否正確。

```
import numpy as np

vocab = ["觀測", "溶氧", "正常", "檢查", "增氧"]
E = np.array([
    [1.0, 0.0],
    [1.0, 2.0],
    [0.0, 1.0],
    [0.5, 1.0],
    [1.5, 1.0],
])
W = np.array([[1, 0], [0, 1], [1, 1]], dtype=float)
b = np.array([0, 0, -1], dtype=float)
outputs = ["正常", "檢查", "增氧"]

ids = np.array([1, 3])      # 輸入：溶氧、檢查
X = E[ids]                  # shape (2, 2)
Z = X @ W.T + b             # shape (2, 3)

# 先拒絕模型產生的 NaN 或無限值
if not np.isfinite(Z).all():
    raise ValueError("分數含有無效數值")

allowed = np.array([True, True, False])
masked_Z = np.where(allowed[None, :], Z, -np.inf)

# 每一列都必須至少保留一個有限分數
valid_rows = np.any(np.isfinite(masked_Z), axis=1)
if not np.all(valid_rows):
    raise ValueError("至少一列沒有可用類別")

shifted = masked_Z - np.max(masked_Z, axis=1, keepdims=True)
exp_z = np.exp(shifted)
P = exp_z / exp_z.sum(axis=1, keepdims=True)

print(X.shape, masked_Z.shape, P.shape)
print(np.round(P, 4))
print([outputs[i] for i in np.argmax(P, axis=1)])
```

輸入詞元編號為 [1, 3]，預期輸出為：

```
(2, 2) (2, 3) (2, 3)
[[0.2689 0.7311 0.    ]
 [0.3775 0.6225 0.    ]]
['檢查', '檢查']
```

若某一系列的所有類別都被遮罩，該列最大值會是負無限大，負無限大減負無限大將產生 NaN。程式因此先逐列確認至少存在一個有限分數，也先拒絕原始分數中的無效值。實際系統仍須明確拒絕不合規請求，或提供經審核的安全回退類別，不能只依賴數值檢查。讀者可在隔離環境執行本段程式；它不連接任何真實設備。

連回生成式AI、多模態與Agent

生成式語言模型通常將大量詞元映成 embedding，經過多層非線性與注意力運算，再對完整輸出詞彙產生分數及 softmax 分布。本章的三類輸出頭只是縮小模型，不足以代表完整語言模型。[R3]

多模態系統可分別把池 A 的文字、影像及感測資料投影到可比較的表示空間；然而向量接近只表示模型所學表示相近，不保證實體條件相同。[R4] Agent 還可能依文字輸出選擇工具。安全介面應把唯讀查詢與設備控制分權，先檢查資料的新鮮度、缺值及單位，檢索有來源的 SOP，再由人員覆核。[R7][R8]

常見錯誤與限制

常見形狀錯誤是把批次公式寫成 XW ，但依本章約定，正確形式是 XW^T 。其他錯誤包括忘記非零偏置使映射成為仿射、把 softmax 跨所有批次一起計算、直接計算巨大指數，以及把列與行混用。

softmax 只正規化相對分數，不會自動校準可信度。最高機率很高時，模型仍可能因資料偏差、未知詞境或錯誤感測輸入而答錯。語義遮罩也可能漏掉同義詞、間接指令或新詞；它不能取代結構化權限、資料驗證與人工批准。embedding 與線性層是生成式 AI 的骨架，但非線性、統計、因果推論及控制問題仍不可省略。

習題

1. **基本計算**：令 $z = [2, 1]^T$ ，求穩定 softmax；若正確類別為第二類，再求交叉熵。
2. **形狀觀念**：若 $X \in \mathbb{R}^{4 \times 3}$ 、 $W \in \mathbb{R}^{5 \times 3}$ 、 $b \in \mathbb{R}^5$ ，寫出批次仿射公式及輸出形狀。
3. **查表觀念**：為何 embedding 查表可寫成矩陣乘法，實作卻通常不建立獨熱向量？
4. **養殖應用**：池 A 模型對「正常」「檢查」「加藥」輸出 $(0.1, 0.2, 0.7)$ 。Agent 是否應直接加藥？請提出至少兩項後續處理。

習題解答

1. 減去最大值 2 得 $[0, -1]^T$ ，因此

$$p \approx \frac{[1, 0.3679]^T}{1.3679} = [0.7311, 0.2689]^T.$$

損失為 $-\log(0.2689) \approx 1.313$ 。

2. 批次公式為

$$Z = XW^T + \mathbf{1}_4b^T.$$

因為 $(4 \times 3)(3 \times 5) = (4 \times 5)$ ，所以 $Z \in \mathbb{R}^{4 \times 5}$ ；每列是一筆資料的五類分數。

3. $E^T e_i$ 會選出 E^T 的第 i 欄，也就是 E 的第 i 列轉置。獨熱向量大多為零，直接依編號取列可節省記憶體與不必要的乘法。
4. 不應直接加藥。系統應先阻止受限工具呼叫，檢查感測器時間、缺值與單位，檢索經管理的 SOP，並把資料與建議交由現場專業人員覆核。0.7 只是模型輸出機率，不是有效性或安全證明。

本章小結

Embedding 把離散詞元轉成向量，仿射層以 $Wx + b$ 產生分數，softmax 把每筆分數轉成總和為一的分佈，交叉熵則衡量正確類別取得的機率。減去每列最大分數可提升數值穩定性；遮罩則能限制候選類別，但必須處理全列被遮罩的情形。這些運算支撐生成式 AI 的輸出機制，卻不能代替語意理解、資料有效性檢查、因果判斷或養殖專業決策。

參考來源

- [R1] NumPy linear algebra reference。
- [R2] *Deep Learning, Chapter 2: Linear Algebra*。
- [R3] *Attention Is All You Need*。
- [R4] *Learning Transferable Visual Models From Natural Language Supervision*。
- [R7] *ReAct: Synergizing Reasoning and Acting in Language Models*。
- [R8] *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*。

第13章 注意力的矩陣運算

學習目標與先備知識

讀完本章，你應能依矩陣形狀算出注意力分數、逐列正規化權重，並解釋遮罩如何限制可參考的位置。先備知識是矩陣乘法、轉置、內積與指數函數；不需要微積分。請記住：注意力權重描述模型如何混合表示，並不是資料真實性或養殖風險的機率。

從池A提出問題

虛構池A有感測紀錄、水面影像摘要與工作日誌。假設一段輸入文字依序為「池A」、「溶氧」、「紀錄」，模型處理「紀錄」時，該參考哪些詞？注意力提供一種由資料表示計算混合權重的方法。這三個詞只是教學用的合成符號，不含真實量測；若日後放入 `do_mg_l`（溶氧，mg/L），仍須另查量測時間、單位與資料有效性，不能只憑詞間權重判斷池況。

本章先算一層中的一個注意力頭，再看生成文字時為何需要遮罩。若把影像摘要也當成輸入項目，同樣可以排列成表示矩陣；然而能排進矩陣，不代表文字和影像已經正確對齊。

概念與推導

設共有 n 個項目，每項表示維度為 d 。雖然單個向量預設是列向量 $x \in \mathbb{R}^d$ ，批次矩陣 $X \in \mathbb{R}^{n \times d}$ 仍以**每列**（row）一項存放其轉置；「行（column）」則指垂直方向。令投影矩陣 $W_Q, W_K \in \mathbb{R}^{d_k \times d}$ 及 $W_V \in \mathbb{R}^{d_v \times d}$ ，則

$$Q = XW_Q^T, \quad K = XW_K^T \in \mathbb{R}^{n \times d_k}, \quad V = XW_V^T \in \mathbb{R}^{n \times d_v}.$$

Q 稱查詢、 K 稱鍵、 V 稱值。它們並非三份原始資料，而是同一批表示經不同投影後得到的矩陣。第 i 列的查詢與第 j 列的鍵做內積，得到「項目 i 參考項目 j 」的分數。把所有內積排起來，就是 $QK^T \in \mathbb{R}^{n \times n}$ ：其列對應發問者，其行對應被參考者。矩陣中的第 i, j 格只需取兩個長度同為 d_k 的向量相乘相加，因此鍵與查詢的維度必須相同；值向量則可以使用另一個維度 d_v 。

縮放後的分數為 $S = QK^T / \sqrt{d_k}$ 。除以 $\sqrt{d_k}$ 可減輕維度增加時內積量級變大的問題，但不能保證任何分數具有特定語義。對每列單獨套用 softmax：

$$A_{ij} = \frac{\exp(S_{ij})}{\sum_{t=1}^n \exp(S_{it})}, \quad A \in \mathbb{R}^{n \times n}, \quad O = AV \in \mathbb{R}^{n \times d_v}.$$

因此每列權重非負且總和為一；輸出第 i 列是各值向量依該列權重形成的加權和。權重即使加總為一，也不是「資料正確的機率」。softmax 是非線性運算，所以整個注意力並非單一線性映射。

若第 i 項不得查看第 j 項，就在softmax之前把該分數設為 $-\infty$ ，使其權重為零；實作時也可只對允許位置計算。每列至少要有一個允許位置。生成文字常用因果遮罩，只允許 $j \leq i$ ，避免目前位置偷看未來；理解整段已給文字時，則可視任務允許雙向參考。遮罩定義資訊流，不負責驗證資訊是否可靠。

多頭注意力把同一個 X 分別投影 h 次。若每頭的鍵維度為 d_k 、值維度為 d_v ，各頭得到 $n \times d_v$ 輸出；沿特徵方向串接後為 $n \times (hd_v)$ 。令串接結果為 $O \in \mathbb{R}^{n \times (hd_v)}$ ；若希望輸出回到 $n \times d$ ，定義 $W_O \in \mathbb{R}^{d \times (hd_v)}$ 並計算 $OW_O^\top$ ，沿用全書批次 $Y = XW^\top$ 的權重方向。這裡的乘法依然是「每列一項」的批次寫法。設計時常按頭分配特徵維度，但不必假設每頭的值維度都等於原始維度。多頭增加可學習的表示路徑，卻不保證每頭都學到不同或正確的關係。注意力的矩陣形式可對照來源[R3]；此處只推導本章使用的基本計算。

手算例題

令 $n = 3, d_k = d_v = 2$ ，直接給定已投影的矩陣；每列依序代表「池A」、「溶氧」、「紀錄」：

$$Q = K = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad V = \begin{bmatrix} 2 & 0 \\ 0 & 2 \\ 4 & 2 \end{bmatrix}.$$

三個矩陣都是 3×2 。先算內積表：第一個查詢與三個鍵的內積是 $(1, 0, 1)$ ；第二個是 $(0, 1, 0)$ ；第三個與第一個相同。因此

$$S = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}.$$

設 $a = \exp(1/\sqrt{2}) \approx 2.028$ 。若允許雙向查看，第一列的指數分數是 $(a, 1, a)$ ，總和 $2a + 1 \approx 5.056$ ，權重約為 $(0.401, 0.198, 0.401)$ 。第二列權重是 $(1, a, 1)/(a + 2) \approx (0.248, 0.503, 0.248)$ ，第三列同第一列。注意這些是逐列計算，不能把九個分數一起正規化。

以第一列輸出為例，保留未四捨五入的權重計算：

$$O_1 = \frac{a(2, 0) + (0, 2) + a(4, 2)}{2a + 1} = \left(\frac{6a}{2a + 1}, \frac{2 + 2a}{2a + 1} \right) \approx (2.407, 1.198).$$

現在改用因果遮罩。第一列只能看自己，輸出 $(2, 0)$ ；第二列只能看前兩項，權重為 $(1, a)/(1 + a) \approx (0.330, 0.670)$ ，輸出約 $(0.660, 1.340)$ 。第三列可看全部，仍約為 $(2.407, 1.198)$ 。同一組 Q, K, V ，僅改變可查看的位置，就改變了前兩項的結果；這正是區分逐字生成與整段理解時的重要差異。若只拿顯示為三位小數的權重再乘值，末位可能不同，因此應到最後一步才四捨五入。

Python實驗

以下程式只用Python標準庫重現因果遮罩的三列輸出。輸入為上例的 `q`、`k`、`v`；每次僅走訪不晚於目前位置的鍵，並先減去最大分數。由於分子與分母同時乘上相同的指數因子，權重不變，卻能避免不必要的數值放大。讀者可在隔離環境自行執行。

```
from math import exp, sqrt

q = [[1, 0], [0, 1], [1, 0]]
k = [[1, 0], [0, 1], [1, 0]]
v = [[2, 0], [0, 2], [4, 2]]
out = []

for i, query in enumerate(q):
    scores = [
        sum(x * y for x, y in zip(query, k[j])) / sqrt(2)
        for j in range(i + 1)
    ]
    peak = max(scores)
    weights = [exp(s - peak) for s in scores]
    total = sum(weights)
    weights = [w / total for w in weights]
    out.append([
        sum(weights[j] * v[j][c] for j in range(i + 1))
        for c in range(2)
    ])

for row in out:
    print([round(x, 3) for x in row])
```

預期輸出：

```
[2.0, 0.0]
[0.66, 1.34]
[2.407, 1.198]
```

連回生成式AI、多模態與Agent

生成式AI若依序產生工作日誌文字，因果遮罩讓每個位置只能利用當時可見的內容；模型生成的下一個詞仍需經其他層與輸出機制決定，不能把本例的 *O* 直接當作文字。處理已提供的紀錄以尋找上下文時，則可依任務採用雙向注意力。兩者不是「生成比較聰明」或「理解比較可靠」的分類，而是可用資訊的安排不同。

項目的順序也值得留意：單看本章給出的內積規則，並沒有告訴模型「昨日」與「今日」相隔多久。實際系統須另以位置或時間資訊表達先後，並避免把未來的紀錄放進當下決策可見的資料。即使遮罩正確，若輸入時已混入未來資訊，遮罩也無法替資料流程補救。

在池A的多模態流程中，水面影像摘要、感測特徵及日誌可經各自的表示方式進入後續模型。注意力能混合這些表示，卻無法自行證明影像拍攝時間與 `temperature_c`（攝氏）、`do_mg_l`（mg/L）、`ph`（無量綱）的讀值一致。Agent即使利用表示查得SOP，也應先核對來源與資料有效性，再提出供人工審核的建議；本

例不連接設備，也不產生投餌、加藥或增氧指令。

常見錯誤與限制

第一個常見錯誤是把 QK^T 寫成 KQ^T ：兩者雖可能都是 $n \times n$ ，但列所代表的查詢方向交換了。第二個是沿行正規化；本章每列才是一位查詢者對所有可用鍵的權重。第三個是先做softmax再遮罩：刪掉權重後，留下的權重總和不再必然為一，必須重新正規化。

另一個容易忽略的情況是整列都被遮住。此時沒有可參考的值，softmax分母也無法依一般定義計算；所以設計遮罩時，必須確保每個查詢至少能看一個鍵。注意力分數高，不等於詞間有因果關係，也不等於感測器可信。其投影由資料學得，結果受訓練資料、位置資訊與其他非線性層影響。尤其在養殖情境，缺值、過期紀錄或量測單位錯誤，不會因矩陣乘法而消失。線性代數提供運算骨架，不能替代統計檢查、因果判斷或現場專業決策。

習題

1. **基本計算**：令單一查詢 $q = (1, 0)$ ，兩個鍵為 $k_1 = (1, 0), k_2 = (0, 1)$ ，值為 $v_1 = (2, 0), v_2 = (0, 2)$ ，且 $d_k = 2$ 。算出縮放分數、softmax權重及輸出，答案取三位小數。
2. **觀念**：對長度四的序列使用因果遮罩時，第二列可以查看哪些位置？若把softmax改為對每一行計算，還能保證每個查詢的權重總和為一嗎？
3. **養殖應用**：池A日誌文字對一筆高注意力權重的溶氧紀錄作出回應，但該紀錄沒有時間戳記。能否把高權重當成執行建議的依據？寫出模型後續流程至少兩項必要檢查。

習題解答

1. 內積為 $1, 0$ ，縮放分數為 $(1/\sqrt{2}, 0)$ 。令 $a = \exp(1/\sqrt{2}) \approx 2.028$ ，權重為 $(a, 1)/(a + 1) \approx (0.670, 0.330)$ ；輸出為 $0.670(2, 0) + 0.330(0, 2) \approx (1.340, 0.660)$ 。
2. 以位置從一開始編號，第二列只能查看第一、第二位置。不能保證：對每一行正規化約束的是同一個鍵收到的權重，而不是同一個查詢送出的權重。
3. 不能。至少須確認紀錄時間與有效性、單位及感測器資料品質；還須查核SOP來源並交由現場專業人員批准。高權重只表示此模型在該次運算中如何混合表示。

本章小結

注意力先用 $QK^T/\sqrt{d_k}$ 形成查詢對鍵的分數，再以遮罩限定可見位置、逐列softmax，最後乘 V 形成混合表示。手算例顯示：相同矩陣在雙向與因果設定下，前兩項輸出不同。檢查形狀、列的方向和資料有效性，比單看權重大小更重要。

參考來源

- [R3] *Attention Is All You Need* , <https://arxiv.org/abs/1706.03762>
- [R2] *Deep Learning, Chapter 2: Linear Algebra* ,
https://www.deeplearningbook.org/contents/linear_algebra.html

第14章 低秩更新與LoRA

學習目標與先備知識

學完本章，你應能：

1. 寫出權重更新 $\Delta W = \frac{\alpha}{r} BA$ 的形狀： $A \in \mathbb{R}^{r \times d}$ 、 $B \in \mathbb{R}^{m \times r}$ 、 $\Delta W \in \mathbb{R}^{m \times d}$ ，並說明 $\text{rank}(\Delta W) \leq r$ 的來源。
2. 在固定 $W \in \mathbb{R}^{m \times d}$ 、低秩 r 與縮放因子 α 下，計算 LoRA 可訓練參數量 $r(m + d)$ 與原矩陣參數量 md 的比值。
3. 舉出一個「低秩更新改變了輸出，但知識仍可能錯誤」的例子，並說明需要哪些額外機制（檢索、資料有效性檢查、人工批准）來降低風險。

先備知識：矩陣乘法與轉置（第3章）、秩與零空間（第4、5章）、SVD 截斷與近似誤差（第8章）、線性層與 softmax（第12章）。本章不要求會訓練大型模型，只需要會數形狀、做參數計算、判斷輸入方向是否落在零空間。

從池A提出問題

池A 的系統（第1章資料字典）有一個「水質→風險詞」的線性層：輸入 $x \in \mathbb{R}^3$ 是 (temperature_c, do_mg_l, ph) 標準化後的列向量， $W \in \mathbb{R}^{4 \times 3}$ 把 3 維特徵映到 4 個風險詞上的 logit，再經 softmax 出分數（第12章）。四個詞依序為「正常」、「檢查增氧機」、「停投餌」、「人工覆核」。

現在想讓模型在夏季夜間、溶氧偏低時把「檢查增氧機」logit 推高、把「停投餌」logit 拉低。直覺做法是整體重訓 W 。問題：本例 W 只有 $4 \times 3 = 12$ 個參數，重訓尚可；但真實 LLM 的投影矩陣常有上億參數，整體重訓昂貴，且可能改變已學到的其他能力（稱「遺忘」，這是經驗動機，非本章命題）。我們想加的調整，在教學合成資料中常集中在少數有效方向上。這裡把「調整活在低維方向」當作 LoRA 的方法假設或經驗動機，而非線性代數定理：若情境需要的更新方向很多，低秩參數化就會系統性漏掉。

LoRA 的核心想法 (R5)：把更新寫成 $\Delta W = \frac{\alpha}{r} BA$ ，其中 $A \in \mathbb{R}^{r \times d}$ 、 $B \in \mathbb{R}^{m \times r}$ 、 $r \ll \min(m, d)$ 。只訓練 A, B ，凍結 W 。 A 是「輸入投影」，把 d 維輸入映到 r 維瓶頸； B 是「輸出展開」，把 r 維瓶頸映回 m 維輸出。

概念與推導

形狀與乘法鏈。設 $W \in \mathbb{R}^{m \times d}$ ，輸入 $x \in \mathbb{R}^d$ （列向量）。LoRA 把輸出改成

$$y = (W + \Delta W)x = Wx + \frac{\alpha}{r} BAx,$$

其中 $A \in \mathbb{R}^{r \times d}$ 、 $B \in \mathbb{R}^{m \times r}$ 。逐段看形狀： $Ax \in \mathbb{R}^r$ （ $r \times d$ 乘 $d \times 1$ ）， $B(Ax) \in \mathbb{R}^m$ （ $m \times r$ 乘 $r \times 1$ ）。所以 $\Delta W = \frac{\alpha}{r} BA \in \mathbb{R}^{m \times d}$ ，與 W 同形狀才能相加。乘法順序是 BA ：若誤把 A 寫成 $d \times r$ ，則 B （ $m \times r$ ）與 A （ $d \times r$ ）的內維 r 與 d 不符，除非偶然 $r = d$ ，否則乘法未定義。

秩上界。假設 $r > 0$ 、 $\alpha \neq 0$ ，則 $\text{rank}(\Delta W) = \text{rank}(BA)$ 。由第4章「乘積的秩不超過任一因子的秩」：

$$\text{rank}(\Delta W) \leq \min(\text{rank}(B), \text{rank}(A)) \leq r.$$

所以 ΔW 的行空間（column space）——所有可能輸出方向——最多佔 $\mathbb{R}^m$ 中 r 維子空間；由第5章秩零度定理， $\dim(\ker \Delta W) = d - \text{rank}(\Delta W) \geq d - r$ 。直覺：落在 $\ker(\Delta W)$ 的輸入方向不產生任何更新輸出，LoRA 對這些方向「沒有作用」。若真實需要的調整落在高維子空間，低秩會漏掉。

縮放因子。LoRA 論文（R5）常用 $\Delta W = \frac{\alpha}{r} BA$ 。 α 是超參數；除以 r 可調整不同 r 下的更新尺度，但穩定性仍取決於初始化與訓練，縮放本身不保證不會爆炸。本章數值例固定 $\alpha = 2$ 、 $r = 1$ ，故縮放係數 $\alpha/r = 2$ 。

參數量。原矩陣有 md 個參數；LoRA 只訓練 A 的 rd 個與 B 的 mr 個，合計 $r(m + d)$ 個（ W 凍結、不計入可訓練參數）。比值 $\frac{r(m+d)}{md}$ 。推理時仍要用 $W + \Delta W$ 輸出（或合併成 $W' = W + \Delta W$ ），記憶體佔用不一定減少；LoRA 的收益主要在「只訓練小參數、只存小更新」，不是推理記憶體自動下降。

為什麼「低秩」不等於「知識正確」。 ΔW 是對 logit 的線性偏移，只能做 BAx 這種線性加總，不能自行產生特徵間的乘積交互。若 A, B 在少量情境資料上擬合，它可能把某詞 logit 推高，但沒有「理解」何時適用。本例想推高「檢查增氧機」，但同一低秩更新可能同時把「正常」也推高、或把「停投餌」拉低到不合宜——而後者在夜間低溶氧時未必正確。正確知識需要：檢索有來源的 SOP（第18章，R8）、資料有效性檢查（第19章）、人工批准。線性代數只保證「更新是低秩、形狀相容」，不保證「更新是對的」。

手算例題

固定 $W \in \mathbb{R}^{4 \times 3}$ （凍結）， $r = 1$ ， $\alpha = 2$ 。令

$$A = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} \in \mathbb{R}^{1 \times 3}, \quad B = \begin{bmatrix} 0 \\ 1 \\ -1 \\ 2 \end{bmatrix} \in \mathbb{R}^{4 \times 1}.$$

A 只讀 temperature（第一維）； B 對四個詞的偏移係數依序為 $[0, 1, -1, 2]$ ，即「正常」不變、「檢查增氧機」推高、「停投餌」拉低、「人工覆核」大幅推高。

Step 1（形狀）。 $BA \in \mathbb{R}^{4 \times 3}$ （ 4×1 乘 1×3 ）， $\Delta W = \frac{\alpha}{r} BA = 2BA \in \mathbb{R}^{4 \times 3}$ ，與 W 同形狀。

$$\text{Step 2（計算 } BA\text{）}。BA = \begin{bmatrix} 0 \cdot 1 & 0 \cdot 0 & 0 \cdot 0 \\ 1 \cdot 1 & 1 \cdot 0 & 1 \cdot 0 \\ -1 \cdot 1 & -1 \cdot 0 & -1 \cdot 0 \\ 2 \cdot 1 & 2 \cdot 0 & 2 \cdot 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ -1 & 0 & 0 \\ 2 & 0 & 0 \end{bmatrix}。$$

$$\text{Step 3 } (\Delta W) \circ \Delta W = 2BA = \begin{bmatrix} 0 & 0 & 0 \\ 2 & 0 & 0 \\ -2 & 0 & 0 \\ 4 & 0 & 0 \end{bmatrix}。$$

Step 4 (秩與零空間)。 ΔW 只有第 1 欄 (column) 非零，其餘兩欄皆為 0，故 $\text{rank}(\Delta W) = 1 \leq r = 1$ 。
 零空間：解 $\Delta W x = 0$ ，即 $2x_1 = 0 \Rightarrow x_1 = 0$ ， x_2, x_3 自由，維度 $2 = d - r$ 。在此特定 $A = [1, 0, 0]$ 下，純 do、ph 方向位於零空間；固定 temperature、只改變 do 或 ph 時，LoRA 偏移不變。

Step 5 (參數量)。原 $W: 4 \times 3 = 12$ 。LoRA： $r(m + d) = 1 \times (4 + 3) = 7$ 。比值 $7/12 \approx 0.583$ 。本例 W 太小所以比例高；若 $m = d = 4096$ 、 $r = 8$ ，比值 $= \frac{8 \times 8192}{4096^2} \approx 0.0039$ ，約 0.39%。當 $r \geq \min(m, d)$ 時 BA 可表達任意更新 (滿秩)，但參數量 $r(m + d)$ 可能已超過 md ，仍是因子化訓練，不等於直接訓練 W 。

Step 6 (輸出偏移，純手算，與 Python 案例分離)。取 $x = [1, -0.5, 0]^T$ (temperature 高、do 偏低、ph 中性)。 $Ax = 1$ 。 $B(Ax) = B \cdot 1 = [0, 1, -1, 2]^T$ 。乘 $\alpha/r = 2$ 得偏移 $[0, 2, -2, 4]^T$ 。假設凍結 W 給出 $Wx = [0.1, 0.2, -0.3, 0.0]^T$ (手算假設值，非 Python 實算值)，則新 $\text{logit} = [0.1, 2.2, -2.3, 4.0]^T$ ：「檢查增氧機」與「人工覆核」被推高、「停投餌」被拉低、「正常」不變。注意「停投餌」被拉低在本情境未必正確——這是「低秩不保證知識正確」的具體表現： A 只看 temperature，無法區分「夜間低溶氧」與「白天高溫低溶氧」。

Python實驗

```
import numpy as np
np.random.seed(42)

# 固定 W: 4x3 (凍結)
W = np.array([
    [ 0.3, -0.2,  0.1],
    [ 0.1,  0.4, -0.1],
    [-0.2,  0.1,  0.3],
    [ 0.0,  0.2, -0.2],
])
m, d = W.shape
r, alpha = 1, 2

A = np.array([[1.0, 0.0, 0.0]]) # r x d = 1 x 3
B = np.array([[0.0], [1.0], [-1.0], [2.0]]) # m x r = 4 x 1

# ΔW = (alpha/r) B A
dW = (alpha / r) * (B @ A)
print("dW shape:", dW.shape) # (4, 3)
print("rank(ΔW):", np.linalg.matrix_rank(dW)) # 1
print("原參數:", m*d, "LoRA參數:", r*(m+d),
      "比值: {:.4f}".format(r*(m+d)/(m*d)))

# 推理: y = (W + ΔW) x
x = np.array([1.0, -0.5, 0.0])
y_orig = W @ x
y_lora = (W + dW) @ x
print("y_orig:", np.round(y_orig, 3))
```

```
print("y_lora:", np.round(y_lora, 3))
print("offset (should equal 2*B*A@x):", np.round(y_lora - y_orig, 3))
```

預期輸出（人工核對，非程式已執行）：

```
dW shape: (4, 3)
rank( $\Delta W$ ): 1
原參數: 12 LoRA參數: 7 比值: 0.5833
y_orig: [ 0.4 -0.1 -0.25 -0.1 ]
y_lora: [ 0.4 1.9 -2.25 3.9 ]
offset (should equal 2*B*A@x): [ 0. 2. -2. 4. ]
```

人工核對： $Wx = [0.3(1) - 0.2(-0.5) + 0.1(0), 0.1(1) + 0.4(-0.5) - 0.1(0), -0.2(1) + 0.1(-0.5) + 0.3(0), 0(1) + 0.2(-0.5) - 0.2(0)]^T = [0.4, -0.1, -0.25, -0.1]^T$ 。偏移 $2BAx = 2[0, 1, -1, 2]^T = [0, 2, -2, 4]^T$ 。相加得 $[0.4, 1.9, -2.25, 3.9]^T$ 。核對重點：**rank** 應為 1 ($\leq r$)；**offset** 只依賴 A, B, x ，與 W 具體數值無關。請讀者在隔離環境用 NumPy 執行；此程式不連接任何真實設備、不下載模型、不下達任何養殖指令。

連回生成式AI、多模態與Agent

- **生成式AI**：LLM 的每個 Transformer 層都有多個線性投影（Q/K/V/Output，第13章）。LoRA 可只訓練這些投影的 A, B ，凍結其餘權重（R5）。多模態模型（CLIP，R4）的投影層同理可加 LoRA 做情境微調。
- **多模態**：池A的水面影像 embedding 與文字 embedding 對齊後（第16章），可考慮在文字塔與影像塔選定線性層加低秩適配以減少可訓練參數；但要讓「低溶氧 + 水面異常」共同影響輸出，還須有讀取溶氧的輸入路徑、融合機制與相應訓練資料，不能只靠替兩塔加LoRA便保證成功。但影像與文字的「異常」語義仍靠前層非線性表示與配對資料，LoRA 本身不產生跨模態交互。
- **Agent**：第18章的 agent 用檢索（R8）拉出有來源的 SOP，再用 LoRA 微調過的模型生成建議。關鍵分離：LoRA 控制「模型傾向」，檢索控制「事實依據」，資料有效性與人工批准（第19章）控制「能不能執行」。三者缺一，低秩適配都可能產生看似合理但無來源的建議。

常見錯誤與限制

1. 以為 ΔW 能表達任意更新。不能： $\text{rank}(\Delta W) \leq r$ 。若需要的更新秩 $> r$ ，低秩適配會系統性漏掉部分方向（與第8章截斷 SVD 誤差同一機制）。
2. 把 r 調很大當作「無損」。 r 增大後參數比 $\frac{r(m+d)}{md}$ 接近或超過 1，失去 LoRA 的節約意義； $r \geq \min(m, d)$ 時可表達任意更新，但仍需額外情境資料才不會過擬合，且不等於直接訓練 W 。
3. 忽略縮放 α/r 。若不除 r ， r 改變時 B, A 的學習尺度不同，跨 r 比較或遷移會不穩定。
4. 把「logit 偏移符合預期」當「知識正確」。Step 6 顯示同一更新可能把「停投餌」拉低到不合宜。正確性依賴資料來源、情境條件（含交互特徵）與人工覆核，不是低秩結構能保證的。
5. **推理記憶體誤解**。推理仍需 $W + \Delta W$ （或合併後 W' ），記憶體不減；省的是訓練參數與梯度記憶體。

6. 形狀寫錯。若把 A 寫成 $d \times r$ ，則 BA 內維不符，通常未定義；本節採 $A \in \mathbb{R}^{r \times d}$ 、 $B \in \mathbb{R}^{m \times r}$ 、 $\Delta W = \frac{\alpha}{r} BA$ 。

習題

- (基本計算) 設 $W \in \mathbb{R}^{8 \times 6}$ ，LoRA $r = 2$ ， $\alpha = 4$ 。(a) 寫出 A, B 的形狀與 ΔW 的形狀；(b) 計算 LoRA 可訓練參數量與原 W 參數量的比值；(c) 若 $\text{rank}(A) = 1$ 、 $\text{rank}(B) = 2$ ， $\text{rank}(\Delta W)$ 最大為幾？為何？
- (觀念) 為什麼 $\text{rank}(\Delta W) \leq r$ 與「零空間維度至少 $d - r$ 」相關？若 $d = 3$ ， $r = 1$ ，零空間最小維度是幾？舉一個零空間方向，說明該方向上 LoRA 為何「完全沒作用」。
- (養殖應用) 池A想加 LoRA 讓「夏季夜間 + do_mg_l 低」提升「檢查增氧機」logit。若輸入只有 $x = [\text{temperature}, \text{do}, \text{ph}]^T$ 且 A 只使用 $[1, 0, 0]$ (temperature 成分)，請說明：(a) 此 A 為何無法區分「夜間低溶氧」與「白天高溫低溶氧」；(b) 建議如何改輸入特徵或 A, B ，或引入哪些其他機制（檢索/資料有效性/人工批准）來降低錯誤建議風險。

習題解答

- (a) $A \in \mathbb{R}^{2 \times 6}$ ， $B \in \mathbb{R}^{8 \times 2}$ ， $\Delta W = \frac{\alpha}{r} BA \in \mathbb{R}^{8 \times 6}$ 。(b) LoRA 參數 $= r(m + d) = 2(8 + 6) = 28$ ；原 $W = 8 \times 6 = 48$ ；比值 $= 28/48 \approx 0.583$ 。(c) $\text{rank}(BA) \leq \min(\text{rank}(B), \text{rank}(A)) = \min(2, 1) = 1$ ，故 $\text{rank}(\Delta W) \leq 1$ （縮放 $\alpha/r = 2$ 是非零常數，不改變秩）。限制來自 A 的秩只有 1：瓶頸只有一個有效方向。
- 由秩零度定理（第5章）， $\dim(\ker \Delta W) = d - \text{rank}(\Delta W) \geq d - r$ 。若 $d = 3$ ， $r = 1$ 時零空間最小維度 $= 2$ 。零空間方向例： $x = [0, 1, 0]^T$ (do 方向)。若 $A = [1, 0, 0]$ ，則 $Ax = 0$ ，故 $BAx = 0$ ，LoRA 對該輸入輸出零偏移——沿 do 方向的輸入變化完全不被此 LoRA 感知，更新「沒作用」。
- (a) $A = [1, 0, 0]$ 只讀 temperature， $Ax = x_1$ 與 do (x_2) 及「夜間」無關。若夜間低溶氧與白天高溫低溶氧的 temperature 相同、do 相同， Ax 相同，LoRA 給出相同偏移，無法用「夜間」條件區分；而「夜間 × 低溶氧」是交互作用，固定線性映射 BAx 只能做線性加總，不能自行產生乘積交互。應區分兩個問題：第一，do 是既有輸入方向，但 $e_2 = [0, 1, 0]^T \in \ker(A)$ ，所以此特定 A 把它消掉；可修改 A 讓更新讀取 do，不一定要提高 r 。第二，夜間指標根本不在目前三維輸入中，不能說它落入 $\ker(A)$ 。即使提高 r ，也無法可靠區分具有相同輸入但夜間標籤不同的樣本；必須先補上相關特徵或外部情境。兩者不能一概稱為秩不足。(b) 改法分層：(i) 輸入端加入「夜間」指標 $x_4 \in \{0, 1\}$ 與交互特徵 $x_5 = x_4 \cdot 1[\text{do 低}]$ （由資料管線預計算，非由 BA 產生），讓 A 能讀到 x_4, x_5 ；(ii) 擴充輸入後同步調整 W 與 A 的輸入維度，並重新設計或訓練基礎映射，不能直接把五維輸入送入原來三欄的 W 。先讓 A 讀取所需方向；只有需要更多獨立更新方向時，才考慮提高 r ，並用含夜/日情境的資料擬合 A, B ；(iii) 檢索 (R8) 拉出「夜間低溶氧」SOP 條目作為事實依據，LoRA 只調整生成傾向、事實由檢索提供；(iv) 資料有效性檢查（第19章）：若 do 感測器斷線或過期，agent 先拒絕執行；(v) 人工批准：增氧操作由現場專業人員依 SOP 制定與執行，模型不直接下指令。這些機制可降低部分風險，但風險是否可接受須由專業人員依實際評估驗證，本章不替現場決策負責。

本章小結

LoRA 把權重更新寫成 $\Delta W = \frac{\alpha}{r}BA$ ，其中 $A \in \mathbb{R}^{r \times d}$ 、 $B \in \mathbb{R}^{m \times r}$ ，用 $r(m+d)$ 個可訓練參數表達秩 $\leq r$ 的更新。固定 r 、且 m, d 兩維度共同增大時，參數比 $\frac{r(m+d)}{md}$ 會下降。形狀鏈 $x \xrightarrow{A} \mathbb{R}^r \xrightarrow{B} \mathbb{R}^m$ 讓 $\dim(\ker \Delta W) \geq d - r$ ，落在零空間的輸入方向不產生更新輸出。低秩結構只保證「參數少、更新方向受限、形狀相容」，不保證「知識正確」： BAx 是線性加總，不能自行產生交互，同一偏移可能在不同情境下對錯混雜。在池A的系統中，LoRA 控制模型傾向，必須與輸入端情境/交互特徵、檢索（R8）、資料有效性檢查與人工批准（第19章）組合，才能降低部分風險；風險是否可接受須由專業人員驗證。線性代數是生成式AI的骨架；非線性、統計、因果與控制仍不可省略或假裝已證明。

參考來源

- R5. LoRA: Low-Rank Adaptation of Large Language Models. <https://arxiv.org/abs/2106.09685>
- R8. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. <https://arxiv.org/abs/2005.11401>
- R4. Learning Transferable Visual Models From Natural Language Supervision. <https://arxiv.org/abs/2103.00020>
- R1. NumPy linear algebra reference. <https://numpy.org/doc/stable/reference/routines.linalg.html>
- R2. Deep Learning, Chapter 2: Linear Algebra. https://www.deeplearningbook.org/contents/linear_algebra.html

第15章 潛在空間、VAE與擴散模型

學習目標與先備知識

本章從向量和矩陣出發，理解生成模型如何表示不確定性，以及如何從隨機噪聲逐步還原資料。你不需要先懂微積分或深度學習：我們會以高中代數能處理的平均、平方與矩陣乘法搭起直覺，再指出哪些地方涉及機率與非線性學習。

讀完後，你應能解釋隨機向量的平均與共變異數，計算線性重參數化，並說明擴散模型的「加噪—去噪」觀點。也要記得：線性代數提供骨架，但生成模型還依賴機率假設、非線性函數和從資料學到的參數。

從池A提出問題

池A是虛構案例。感測器記錄水溫 `temperature_c`（攝氏）、溶氧 `do_mg_l`（mg/L）與酸鹼值 `ph`（無量綱）；另外還有水面影像和工作日誌。資料經過特徵抽取後，可形成向量，讓模型描述或生成可能的觀測樣貌。

例如，模型能否根據一段感測器特徵，生成看起來相近的水面影像？若資料帶有噪聲，模型又如何學會逐步移除噪聲？不能把生成內容當作池水真相：它是模型依訓練資料形成的表示或樣本，不是現場量測，也不會自動證明因果關係。

概念與推導

隨機向量與共變異數

固定一筆資料的向量是確定的；若向量可能取不同值，就把它視為隨機向量。先看只有兩種可能結果的簡單情形：若 z 以機率 $1/4$ 取 0、以機率 $3/4$ 取 4，其期望值就是加權平均：

$$\mathbb{E}[z] = \frac{1}{4}(0) + \frac{3}{4}(4) = 3.$$

期望值可以想成許多次依同一機率抽取後的長期平均，不保證每一次都恰好取到 3。變異數則是偏離平均的平方再取平均；本例為 $\frac{1}{4}(0-3)^2 + \frac{3}{4}(4-3)^2 = 3$ 。平方使偏高與偏低的偏差都成為非負數。

對向量而言，令 $z \in \mathbb{R}^d$ 為列向量、平均向量為 $\mu = \mathbb{E}[z]$ 。偏差向量 $z - \mu$ 描述一次取值相對平均的位置，其共變異數矩陣定義為

$$\Sigma = \mathbb{E}[(z - \mu)(z - \mu)^T] \in \mathbb{R}^{d \times d}.$$

矩陣乘積的第 i, j 項是兩個偏差分量相乘後取平均。對角線因此是各分量的變異數；非對角線是共變異數，描述兩個分量是否傾向一起偏高或一起偏低。共變異數反映線性共同變動，不單獨證明一個變量造成另一個變量改變。

若有 $n \geq 2$ 筆觀測 $z_1, \dots, z_n$ ，先算樣本平均 $\bar{z} = \frac{1}{n} \sum_{i=1}^n z_i$ ，樣本共變異數採用分母 $n - 1$ ：

$$S = \frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{z})(z_i - \bar{z})^T.$$

這是由有限樣本估計母體變異的常見方式；它與用所有可能結果定義的母體共變異數不是同一件事。分母 $n - 1$ 也是全書約定。

常見的簡化起點是標準高斯隨機向量 $\epsilon \sim \mathcal{N}(0, I)$ 。符號 $\mathcal{N}$ 表示高斯（常稱常態）分布；此處平均為零、共變異數為單位矩陣 I 。其對角線為 1、非對角線為 0，代表此設定下各分量不相關。這是模型假設，不是所有真實資料都符合的事實。

線性重參數化

設 $A \in \mathbb{R}^{m \times d}$ 、 $b \in \mathbb{R}^m$ ，且 $\epsilon \in \mathbb{R}^d$ 為列向量，定義

$$y = A\epsilon + b \in \mathbb{R}^m.$$

由期望的線性性， $\mathbb{E}[y] = A\mathbb{E}[\epsilon] + b$ 。若 ϵ 的平均為 0、共變異數為 I ，則

$$\text{Cov}(y) = A \text{Cov}(\epsilon) A^T = AA^T.$$

更一般地，若 x 的平均為 μ 、共變異數為 Σ ，而 $y = Ax + b$ ，則平均為 $A\mu + b$ 、共變異數為 $A\Sigma A^T$ 。平移 b 會改變平均；從 y 減去平均時，常數項相消，因此它不改變共變異數。矩陣 A 則會改變隨機點雲的方向與伸展程度。

變分自編碼器（VAE）以編碼器根據輸入預測潛在變量分布的參數，再抽取潛在向量交給解碼器重建資料。常見設計令編碼器輸出平均 μ 和逐維標準差 σ ，並寫成

$$z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

這裡 $\odot$ 表示逐分量相乘；若向量長度為 d ，則 $z, \mu, \sigma, \epsilon \in \mathbb{R}^d$ 。每個標準差都必須滿足 $\sigma_i \geq 0$ ；若要求每一維都有非零變異數，則取 $\sigma_i > 0$ 。在此高斯假設下， z 的共變異數為

$$\text{Cov}(z) = \text{diag}(\sigma_1^2, \dots, \sigma_d^2) \in \mathbb{R}^{d \times d}.$$

直覺上，先抽取標準噪聲，再依各維標準差縮放並平移，就得到所需的潛在樣本。這種寫法讓抽樣步驟成為對 μ 、 σ 可微的運算，訓練時便能把損失對參數的影響傳回編碼器。對角共變異數是常見簡化，不代表潛在因素必然互相獨立。

擴散的去噪視角

擴散模型先定義逐步加噪的過程，再訓練模型從含噪資料預測噪聲或還原訊號。以特徵向量 $x_0 \in \mathbb{R}^d$ 為例，一種常見的前向取樣形式是

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

x_t 與 ϵ 都是 d 維列向量； $\bar{\alpha}_t$ 是介於 0 與 1 的係數。在此處討論的加噪時間序列中，假設 $\bar{\alpha}_t$ 隨時間步 t 不增。係數越小，原資料的影響越弱，噪聲的影響越強。在每個 t ，依指定的 $\bar{\alpha}_t$ 抽取噪聲形成 x_t ；反向更新仍須另行學習。

訓練時，模型讀取 x_t 和時間步 t ，學習預測其中的噪聲或相關訊號。生成時則從噪聲起步，反覆使用學得的更新規則形成樣本。這不是單純對矩陣做逆運算：反向步驟要靠學到的模型，而且通常包含非線性網路、時間條件與訓練目標。前向加噪式能說明訊號如何混合，卻不是完整擴散訓練或反向生成規則。

手算例題

令二維標準噪聲 $\epsilon = (1, -1)^T$ ，取

$$A = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 2}, \quad b = \begin{bmatrix} 0 \\ 3 \end{bmatrix} \in \mathbb{R}^2.$$

先逐列相乘：第一列給 $2(1) + 0(-1) = 2$ ；第二列給 $1(1) + 1(-1) = 0$ 。因此

$$A\epsilon = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \quad y = A\epsilon + b = \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$

這是一次噪聲取值對應的輸出。若 ϵ 的平均為 0、共變異數為 I ，則整個輸出分布的平均為 b ，而不是剛才這次取值的 y 。其共變異數為

$$AA^T = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}.$$

第一個分量的變異數是 4，第二個是 2，兩者的共變異數是 2，所以映射後不再互不相關。平移 b 改變平均，並不改變這個矩陣。

Python實驗

下面用標準庫抽取兩個標準常態噪聲值，計算同一個線性映射。固定種子讓示範可重複；種子不是統計可靠性的保證。

```
import random

random.seed(42)
```

```

epsilon = [random.gauss(0, 1), random.gauss(0, 1)]

# y = A epsilon + b
A = [[2, 0], [1, 1]]
b = [0, 3]
y = [
    A[i][0] * epsilon[0] + A[i][1] * epsilon[1] + b[i]
    for i in range(2)
]

print("epsilon shape: (2,)")
print("y shape: (2,)")
print("epsilon:", epsilon)
print("y:", y)

```

輸入是由兩個隨機數構成的長度為 2 的向量；預期輸出包含兩行形狀標示，以及兩個長度為 2 的數值列表。讀者執行時，可逐項核對 $y_1 = 2\epsilon_1$ 、 $y_2 = \epsilon_1 + \epsilon_2 + 3$ 。例如若手動代入 $\epsilon = (1, -1)$ ，會得到 $y = (2, 3)$ ，與上面的手算一致。這只是代數檢查，不是程式執行結果；本實驗也不訓練VAE或擴散模型，不估計可靠的資料分布。

連回生成式AI、多模態與Agent

池A的感測器表格、影像與工作日誌可以各自形成特徵表示。模型可把特徵映到潛在空間，或學習在含噪特徵中預測噪聲。不同模態的向量即使形狀相同，也不保證語義對齊；對齊需要合適的資料與訓練目標。生成的水面影像或摘要不是新的感測紀錄。

Agent若要使用這些內容，仍須把生成結果和來源資料分開，檢索可追溯的SOP，檢查感測器資料有效性，再提出待人工審核的建議。此示例不連接真實設備、不下投餌、加藥或增氧指令。安全操作由現場專業人員制定，模型建議不能取代養殖專業判斷。

常見錯誤與限制

看到高斯分布公式，不代表資料一定服從高斯；它可能只是建模選擇。 AA^T 描述線性變換後的共變異數，不能完整描述池塘狀況，也不能說明因果關係。VAE抽樣與擴散去噪都包含非線性模型和學習程序，不能只靠矩陣公式重現。

此外，「去噪」不是保證找回某次觀測的唯一真值。多種乾淨資料都可能在加噪後產生相似的結果，模型輸出受訓練資料、假設和更新規則影響。生成結果即使看起來合理，也可能與現場不符；應查核原始資料來源、時間、缺值與模型限制，不可把合理外觀當成證據。

習題

1. **基本計算：** ϵ 的平均為零、共變異數為 I 。若 $A = \begin{bmatrix} 3 & 0 \end{bmatrix}$ 、 $y = A\epsilon + 1$ ，求 y 的平均與變異數。
2. **觀念：** 對 $y = Ax + b$ ，平移 b 會改變平均還是共變異數？為什麼？

3. **養殖應用**：池A的含噪水面影像被模型還原得很清楚，能否因此認定感測器數值正確，或直接批准現場操作？請說明理由。

習題解答

1. 平均為 1。變異數為 $AA^T = [3 \ 0][3 \ 0]^T = 9$ 。
2. b 改變平均，因為 $\mathbb{E}[y] = A\mathbb{E}[x] + b$ ；它不改變共變異數，因為從 y 減去平均時，常數項會相消。
3. 不能。還原影像是模型產生的結果，不是獨立感測證據；應另外檢查原始資料、時間與有效性，並由現場專業人員審核。生成模型不應自動下操作指令。

本章小結


期望是依機率加權的平均，變異數描述偏離平均的平方幅度，共變異數矩陣則記錄各分量的變異與共同變動。線性映射 $y = Ax + b$ 會把共變異數變為 $A\Sigma A^T$ 。VAE用重參數化把抽樣寫成噪聲的縮放和平移；擴散模型則用逐步加噪與學得的去噪更新生成樣本。這些公式揭示生成式AI的一部分線性代數骨架，但機率假設、非線性網路、資料品質、因果限制與人工覆核同樣不可缺少。

參考來源

- R2： *Deep Learning, Chapter 2: Linear Algebra*。
- R6： *Denoising Diffusion Probabilistic Models*。

第16章 影像、文字與水質的共同表示

多模態對齊不是簡單拼接



多模態融合示意

學習目標與先備知識

讀完本章，你應該能夠：把水面影像、工作日誌文字與水質感測資料，各自整理成「特徵矩陣」；用列向量（column vector，直向排列）與內積計算相似度；本章橫排的座標對僅為分量簡寫，不表示row vector；理解把不同模態投影到同一個共同空間的意義；說出特徵融合與對比學習的直覺，以及它們在資料配對與缺模態時的限制。這裡所謂的 embedding，就是「把一個物件（一張圖、一句話、一段感測視窗）轉換成一個實數向量」，使機器能用幾何方式比較它們。

先備知識來自前面章節：向量、內積與範數、矩陣乘法與轉置、投影與正交，以及奇異值分解的基本概念。你不需要先懂深度學習或微積分，只要記得「向量預設為列向量（column vector，直向排列）」這條全書共同約定： $x \in \mathbb{R}^d$ 、 $W \in \mathbb{R}^{m \times d}$ 、 $y = Wx \in \mathbb{R}^m$ ；批次資料 $X \in \mathbb{R}^{n \times d}$ 以每列為一筆觀測， $Y = XW^T$ 。務必分清「列」與「行」：每一列是一筆觀測，每一行是一個特徵座標。

從池A提出問題

池A同時有三種紀錄：水面影像、養殖人員寫下的工作日誌文字，以及感測器產生的溫度、溶氧、酸鹼值序列。我們想回答一個檢索問題：當某個時段感測讀數出現異常，系統能不能找出「曾經看過類似水面影像、也曾經被寫下類似描述」的歷史紀錄，供人員參考？問題在於，這三種資料的原始維度與單位都不同，不能直接把一張圖和一句話相減，也不能把溶氧值與文字向量並排比較。

我們可以把池A的資料字典整理成這樣：感測特徵 $x \in \mathbb{R}^p$ ，例如溫度、溶氧、酸鹼值， $p = 3$ ；影像 embedding $u \in \mathbb{R}^{d_i}$ ，由影像編碼器產生；文字 embedding $v \in \mathbb{R}^{d_t}$ ，由文字編碼器產生。三個維度 p, d_i, d_t 通常不同，這正是需要「共同表示」的原因：我們希望把它們放到同一個 d 維座標系裡，讓相似度可計算。以下所有數值皆為教學合成，不對應真實物種或真實閾值。

概念與推導

選投影矩陣

$$W_i \in \mathbb{R}^{d \times d_i}, \quad W_t \in \mathbb{R}^{d \times d_t},$$

把影像與文字映到同一個 d 維空間：

$$z_i = W_i u \in \mathbb{R}^d, \quad z_t = W_t v \in \mathbb{R}^d.$$

形狀檢查： $(d \times d_i)(d_i \times 1) = (d \times 1)$ ，維度吻合。直覺上，投影矩陣扮演「翻譯」的角色：它把各模態自己的座標軸，重新表達成共同空間裡的方向，使不同來源的向量可以放在一起比較。所謂「對齊」

(alignment)，就是讓不同模態中「描述同一件事」的向量彼此靠近。選擇線性投影，是因為線性映射便於分析疊加與維度，矩陣乘法也有明確的幾何意義；但真實編碼器往往是非線性的，這裡的線性投影只是把「共同表示」的骨架講清楚，並不代表整個模型就是線性的。

批次情形：影像的 embedding 矩陣 $X \in \mathbb{R}^{n \times d_i}$ ，則

$$Z_i = X W_i^\top \in \mathbb{R}^{n \times d}, \quad Z_t = X_t W_t^\top \in \mathbb{R}^{m \times d}.$$

用全書共同記法 $Y = X W^\top$ ，每列是一筆觀測，每欄是共同空間的一個座標。 n 筆影像對 m 筆文字，可以不同，因為檢索時通常「一批查詢」對「一批候選」。

投影後先做逐列標準化，避免向量長度主導相似度。令 $\hat{z} = z / \|z\|_2$ （先排除零向量）。於是相似度矩陣為

$$S = \hat{Z}_i \hat{Z}_t^\top \in \mathbb{R}^{n \times m}, \quad S_{jk} = \frac{z_i^{(j)} \cdot z_t^{(k)}}{\|z_i^{(j)}\| \|z_t^{(k)}\|}.$$

$S_{jk} \in [-1, 1]$ 是兩模態的餘弦相似度：值接近 1 表示方向幾乎相同，接近 -1 表示方向相反，接近 0 表示近乎正交。對比學習的直覺是：希望正配對的相似度高、負配對的低。一般相似度矩陣容許 $n \neq m$ ；以下 InfoNCE 公式另限定 $n = m \geq 1$ ，且第 j 張影像的正配對文字恰為第 j 筆，因此正配對位於對角線。對每一列做softmax：

$$L = -\frac{1}{n} \sum_{j=1}^n \log \frac{\exp(S_{jj}/\tau)}{\sum_{k=1}^m \exp(S_{jk}/\tau)},$$

其中 $\tau > 0$ 是溫度，控制分布尖銳程度。這只是目標函數的直覺，不保證學到因果或正確知識。融合 (fusion) 可簡單用串接 $h = [z_i; z_t] \in \mathbb{R}^{2d}$ ，或用凸組合 $h = \alpha z_i + (1 - \alpha) z_t$ ， $0 \leq \alpha \leq 1$ 。後者其實就是對兩個已對齊向量做加權平均，權重和為一。若某模態缺失，等價於把對應權重設為零；此時 h 仍落在共同空間，但只承載單一模態的資訊。這種「降級」必須在系統中留下紀錄，而不是默默執行，因為單模態表示承載的語義較少，不能假裝等同完整輸入。

手算例題

取共同空間 $d = 2$ ，為簡化令 $W_i = W_t = I$ ，即 embedding 已在共同空間。兩筆影像列向量為

$$a_1 = (3, 4), \quad a_2 = (4, -3); \quad b_1 = (3, 4), \quad b_2 = (3, -4).$$

先算範數： $\|a_1\| = \|b_1\| = 5$ ， $\|a_2\| = 5$ ， $\|b_2\| = \sqrt{9 + 16} = 5$ 。標準化：

$$\hat{a}_1 = (0.6, 0.8), \quad \hat{a}_2 = (0.8, -0.6), \quad \hat{b}_1 = (0.6, 0.8), \quad \hat{b}_2 = (0.6, -0.8).$$

逐項算內積：

$$S_{11} = 0.6 \cdot 0.6 + 0.8 \cdot 0.8 = 1, \quad S_{12} = 0.6 \cdot 0.6 + 0.8 \cdot (-0.8) = 0.36 - 0.64 = -0.28,$$

$$S_{21} = 0.8 \cdot 0.6 + (-0.6) \cdot 0.8 = 0.48 - 0.48 = 0, \quad S_{22} = 0.8 \cdot 0.6 + (-0.6) \cdot (-0.8) = 0.96.$$

所以

$$S = \begin{pmatrix} 1 & -0.28 \\ 0 & 0.96 \end{pmatrix}.$$

對角項明顯較高，符合「配對相似」的期待。再用 $\tau = 1$ 手算損失的第一列： $\exp(1) = 2.718$ 、 $\exp(-0.28) = 0.756$ ，和為 3.474，得機率 0.782 與 0.218。第二列： $\exp(0) = 1$ 、 $\exp(0.96) = 2.612$ ，和為 3.612，機率為 0.277 與 0.723。故

$$L = -\frac{1}{2}(\log 0.782 + \log 0.723) = -\frac{1}{2}(-0.246 - 0.324) = 0.285.$$

這裡第一列的配對機率 0.782 高於非配對的 0.218，表示模型把正確配對排在前面；損失 0.285 是把兩列的不確定程度平均後的結果，越小越好。

Python實驗

以下程式只用標準庫與 NumPy，需由讀者在隔離環境自行執行；本文不聲稱已執行。

```
import numpy as np
```

```

# 輸入：2 筆影像、2 筆文字的 2 維 embedding（每列一筆）
A = np.array([[3., 4.],
              [4., -3.]]) # 影像
B = np.array([[3., 4.],
              [3., -4.]]) # 文字

def rownorm(M):
    n = np.linalg.norm(M, axis=1, keepdims=True)
    return M / n # 逐列標準化

S = rownorm(A) @ rownorm(B).T # 相似度矩陣
print(A.shape, B.shape, S.shape)
print(np.round(S, 2))

# 對每一列做 softmax
def softmax_rows(S, tau=1.0):
    E = np.exp(S / tau - np.max(S / tau, axis=1, keepdims=True))
    return E / np.sum(E, axis=1, keepdims=True)

P = softmax_rows(S, tau=1.0)
print(np.round(P, 3))
print(np.round(-np.mean(np.log(np.diag(P))), 3))

```

預期輸出（小數四捨五入）：

```

(2, 2) (2, 2) (2, 2)
[[ 1.   -0.28]
 [ 0.    0.96]]
[[0.782 0.218]
 [0.277 0.723]]
0.285

```

形狀 (2, 2) 表示 2 筆影像對 2 筆文字；對角項是配對相似度。`softmax_rows` 先減去每列最大值再取指數，是數值穩定的寫法。若把 `A`、`B` 換成真實 embedding，記得先確認每列非零。

連回生成式AI、多模態與Agent

CLIP 這類雙塔模型正是用「影像編碼器 + 文字編碼器 + 共同空間 + 對比損失」把兩種模態對齊（R4）；檢索增強生成則用向量相似度取回文件再交給語言模型（R8）。在池A的 agent 情境，感測視窗先被切齊到固定長度，影像與日誌以同一時間戳配對；感測、影像、日誌被投影到同一表示後，agent 用餘弦檢索最接近的 SOP 片段，取前幾名（top-k）作為候選，再放進建議中。但請注意：向量檢索只回傳「相似」的候選，不是因果診斷，也不是安全判斷；任何投餌、加藥、增氧都必須由現場專業人員依規定決定。表示層的幾何接近，與真實池況的健康或安全，是兩件不同層次的事。若配對資料本身有偏，檢索結果也會跟著偏。

常見錯誤與限制

第一，忘記逐列標準化，會讓向量長度而非方向決定相似度。第二，零向量沒有方向，必須先排除或另行處理。第三，相似度高不等於健康或正確， S 只是表示層的幾何量測。第四，缺模態時直接補零，會產生誤導性的相似度，因為零向量與任何內容的內積都是零。第五，融合權重 α 若是人工指定，就不是統計證

據；它需要驗證時段的支持。第六，對比學習需要正確的配對資料；配對錯誤會把不相關內容拉近。第七，投影矩陣 W_i 、 W_t 通常是從訓練資料學得，測試集只套用，不能重估。本章所有資料皆為教學合成，不能用來推論真實物種的閾值或養殖收益。

習題

1. (基本計算) 設 $a_1 = (1, 0)$ 、 $a_2 = (0, 1)$ ， $b_1 = (2, 2)$ 、 $b_2 = (-2, 2)$ 。計算標準化後的 $\hat{a}$ 、 $\hat{b}$ ，以及 2×2 相似度矩陣 S 。2. (觀念) 為什麼投影到共同空間後還要逐列標準化？若某時段影像缺失、以零向量補上，會對相似度造成什麼問題？3. (養殖應用) 池A要把「感測異常時段」與「日誌描述」和「水面影像」配對。請描述一種建立配對資料的方式，以及時間切分時如何避免資料洩漏。

習題解答

1. $\|a_1\| = \|a_2\| = 1$ ，故 $\hat{a}_1 = (1, 0)$ 、 $\hat{a}_2 = (0, 1)$ 。 $\|b_1\| = \|b_2\| = \sqrt{8} \approx 2.828$ ，故 $\hat{b}_1 \approx (0.707, 0.707)$ 、 $\hat{b}_2 \approx (-0.707, 0.707)$ 。逐項內積得

$$S = \begin{pmatrix} 0.707 & -0.707 \\ 0.707 & 0.707 \end{pmatrix}.$$

第一列的配對值 0.707 大於非配對值 -0.707，分離良好。但第二列的非配對值 $S_{21} = 0.707$ 與配對值 $S_{22} = 0.707$ 相等，兩者無法區分，這提醒我們：並非每一組配對都會產生乾淨的對角線，配對關係與資料本身是否可分辨同樣重要。

- 標準化把比較限制在方向上，排除「長度」這個與語義未必相關的自由度，使餘弦只反映方向相似。零向量 $\hat{z} = 0/0$ 未定義；補零後與任何向量的相似度都為 0，會讓「缺資料」被誤讀成「與所有描述都不相似」，而不是「未知」，因此缺模態應明確標記，不可當成一般數值。
- 可以用同一時間窗把三模態綁成一組：感測視窗、該窗內的日誌段落、該窗的代表影像，構成配對樣本 (x, u, v) 。切分時必須以「時間」為單位，先切訓練、驗證、測試時段，再在各自時段內配對；不可用測試日統計量估計標準化參數或投影，否則造成洩漏。缺模態樣本要分開處理，不能靠補值製造假配對。

本章小結

不同模態原始維度不同，但可各自編碼後以 W_i 、 W_t 投影到共同 d 維空間，用 $S = \hat{Z}_i \hat{Z}_t^\top$ 比較相似度。對比學習以 softmax 拉高配對、壓低非配對；融合可用串接或加權，缺模態需明確標記。關鍵限制是：相似度不是因果或安全結論、缺模態不能補零了事、配對品質決定一切，而線性代數只是骨架，統計、因果與控制不可省略。

參考來源

R4 Learning Transferable Visual Models From Natural Language Supervision ; R8 Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ◦

第17章 時間序列、缺值與狀態估計

學習目標與先備知識

本章把池A的連續感測資料視為「部分可見的動態系統」。讀完後，讀者應能分辨隱藏狀態、感測觀測與量測誤差；寫出線性狀態空間模型並核對矩陣形狀；理解共變異數的預測與更新；以簡化的Kalman更新手算狀態估計；妥善表達缺值與不確定性；依時間先後切分訓練、驗證及測試資料。

先備知識包括矩陣乘法、轉置、平均與共變異數。此處可先把變異數理解為「誤差散布有多大」：數值越大，代表估計通常越不確定。共變異數則描述兩項誤差是否傾向一起增減。不要求微積分或完整機率理論。以下資料皆為教學合成，數字不是任何物種的適用閾值。

從池A提出問題

池A每小時記錄 `temperature_c`、`do_mg_l` 與 `ph`，另有水面影像及工作日誌。感測器讀值不等於池中真實狀態：儀器會受雜訊影響，也可能逐漸漂移或暫時斷線。例如真實溶氧可能平穩下降，但探頭偏差逐時增加，使讀值看似不變。

若斷線時直接填入零，模型會把「未知」誤認為實際的零；若以全資料平均補值，測試日又會滲入未來資訊。合理的問題不是「如何猜一個完整表格」，而是：根據截至時刻 t 已有的資料，我們對當下狀態知道多少，又有多不確定？

為維持因果順序，可把最早一段作訓練集，中段作驗證集，最後一段作測試集。平均值、標準差及模型參數只由訓練時段估計，之後固定套用。不能先把時間序列隨機打散再切分，否則未來池況可能間接協助預測過去。若任務是在時刻 t 即時估計，也不能使用 $t + 1$ 之後的影像或日誌。

概念與推導

依全書約定，所有狀態都是列向量（column vector）。令隱藏狀態 $x_t \in \mathbb{R}^{d \times 1}$ ，觀測 $y_t \in \mathbb{R}^{m \times 1}$ 。線性狀態空間模型為

$$x_t = Fx_{t-1} + w_t, \quad y_t = Hx_t + v_t。$$

其中 $F \in \mathbb{R}^{d \times d}$ 是狀態轉移矩陣， $H \in \mathbb{R}^{m \times d}$ 是觀測矩陣。因而 Fx_{t-1} 與 x_t 皆為 $d \times 1$ ， Hx_t 與 y_t 皆為 $m \times 1$ 。 $w_t \in \mathbb{R}^{d \times 1}$ 代表模型未描述的狀態變化， $v_t \in \mathbb{R}^{m \times 1}$ 代表量測誤差。

本章假設 w_t 與 v_t 平均為零、彼此不相關，且共變異數分別為 $Q \in \mathbb{R}^{d \times d}$ 及 $R \in \mathbb{R}^{m \times m}$ 。這些是為了建立簡化模型而採用的教學假設，不是線性代數自動證明的事實。

設上一時刻的估計為 $\hat{x}_{t-1|t-1}$ ，下標表示「估計時刻 $t - 1$ ，已使用截至 $t - 1$ 的資料」。定義估計誤差

$$e_{t-1} = x_{t-1} - \hat{x}_{t-1|t-1},$$

其共變異數為 $P_{t-1|t-1} \in \mathbb{R}^{d \times d}$ 。先只使用過去資訊預測：

$$\hat{x}_{t|t-1} = F\hat{x}_{t-1|t-1},$$

$$P_{t|t-1} = FP_{t-1|t-1}F^T + Q。$$

這個傳播式可由誤差理解。新預測誤差為

$$e_t = Fe_{t-1} + w_t。$$

本章進一步假設 e_{t-1} 與 w_t 不相關，而且兩者平均為零。展開 $e_t e_t^T$ 並取平均後，交叉共變異數項因「不相關」假設而為零，不是僅憑平均為零便能省略。因此留下 $FP_{t-1|t-1}F^T + Q$ 。若兩者相關，傳播式還須加入相應的交叉項。

P 的對角元素是各狀態誤差的變異數，非對角元素描述兩項誤差如何共同變動。因此即使估計值沒有變動，長時間未收到資料時，不確定性仍可持續增加。

收到觀測後，先計算創新，即實測與預測觀測的差：

$$r_t = y_t - H\hat{x}_{t|t-1} \in \mathbb{R}^{m \times 1}。$$

創新共變異數 $S_t \in \mathbb{R}^{m \times m}$ 與 Kalman 增益 $K_t \in \mathbb{R}^{d \times m}$ 為

$$S_t = HP_{t|t-1}H^T + R, \quad K_t = P_{t|t-1}H^T S_t^{-1}。$$

若 S_t 可逆，更新式為

$$\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t r_t,$$

$$P_{t|t} = (I - K_t H)P_{t|t-1}。$$

形狀上， $K_t r_t$ 是 $d \times 1$ 列向量，能與 $\hat{x}_{t|t-1}$ 相加； I 是 $d \times d$ 單位矩陣。逐項核對形狀可及早發現轉置方向或觀測矩陣選取錯誤。

預測很不確定而量測較可靠時， K_t 通常較大；量測誤差 R 較大時，更新較保守。實作通常以解線性方程取代顯式計算 S_t^{-1} 。上式是概念上簡潔的共變異數更新；有限精度運算中，可採較能維持對稱與半正定性的 Joseph 形式：

$$P_{t|t} = (I - K_t H)P_{t|t-1}(I - K_t H)^T + K_t R K_t^T。$$

若整筆觀測缺失，就跳過更新，令 $\hat{x}_{t|t} = \hat{x}_{t|t-1}$ 及 $P_{t|t} = P_{t|t-1}$ 。這不是補出真值，而是保留帶有不確定性的估計。若三個欄位中只有 pH 缺失，可取出可用的觀測分量，以及 H 的對應列（row）和 R 的對應列、行（column）再更新，不必丟棄整個時刻。

感測漂移也可納入狀態。例如

$$x_t = \begin{bmatrix} z_t \\ b_t \end{bmatrix}, \quad H = \begin{bmatrix} 1 & 1 \end{bmatrix}, \quad y_t = z_t + b_t + v_t,$$

其中 z_t 是真實量， b_t 是感測偏差。單次觀測只提供兩者的和，不能單獨辨認它們。即使累積歷史資料，能否分開仍取決於 F 、 Q 等動態假設。實務上可能需要校正紀錄、參考感測器或對偏差變動加上合理限制；增加狀態維度不會憑空增加資訊。

手算例題

考慮單一虛構溶氧狀態，故 $d = m = 1$ 。令 $F = H = 1$ ，前一步估計為 $\hat{x}_{t-1|t-1} = 6.0$ mg/L， $P_{t-1|t-1} = 0.25$ ，並令 $Q = 0.04$ 、 $R = 0.16$ 。新觀測為 $y_t = 6.5$ mg/L。

先預測：

$$\hat{x}_{t|t-1} = 1(6.0) = 6.0, \quad P_{t|t-1} = 1(0.25)1 + 0.04 = 0.29。$$

創新及其變異為

$$r_t = 6.5 - 1(6.0) = 0.5, \quad S_t = 1(0.29)1 + 0.16 = 0.45。$$

因此

$$K_t = \frac{0.29}{0.45} \approx 0.6444。$$

更新後的狀態估計為

$$\hat{x}_{t|t} = 6.0 + 0.6444(0.5) \approx 6.3222 \text{ mg/L},$$

不確定性則為

$$P_{t|t} = (1 - 0.6444)(0.29) \approx 0.1031。$$

估計值位於預測6.0與觀測6.5之間，且 P 由0.29降至約0.1031。若下一時刻斷線，就只做預測：估計仍為6.3222，但 P 增加為 $0.1031 + 0.04 = 0.1431$ 。數值未改變不代表資訊同樣可靠。

Python實驗

以下固定輸入模擬觀測逐漸偏高及中途斷線。`None` 表示未知，不等於零。這段程式可由讀者在隔離環境使用NumPy執行；下列輸出是依公式提供的預期結果。

```
import numpy as np

# 教學合成輸入：後段讀值偏高，中間兩次斷線
observations = [6.10, 6.25, None, None, 6.70]
F, H = 1.0, 1.0
Q, R = 0.04, 0.16
x, P = 6.0, 0.25

for t, y in enumerate(observations):
    x_pred = F * x
    P_pred = F * P * F + Q

    if y is None:
        x, P = x_pred, P_pred
        status = "missing"
    else:
        residual = y - H * x_pred
        S = H * P_pred * H + R
        K = P_pred * H / S
        x = x_pred + K * residual
        P = (1.0 - K * H) * P_pred
        status = "updated"

    print(t, status, round(x, 3), round(P, 3))
```

預期輸出：

```
0 updated 6.064 0.103
1 updated 6.108 0.076
2 missing 6.108 0.116
3 missing 6.108 0.156
4 updated 6.434 0.088
```

兩次斷線期間，估計沒有被假零值拉低， P 則逐步上升。觀測恢復後，模型更新估計並降低不確定性。後段較高讀值可能來自真實變化、漂移或兩者兼有；單憑這段程式無法判定。若另行隨機生成合成雜訊，可固定 `seed=42` 以便重現，但固定種子不是統計可靠性的保證。

若要評估模型，應先依時間切分資料，再只用訓練時段選擇初始值、 Q 、 R 及任何標準化統計量。驗證與測試期間只能沿時間向前更新，不能回頭利用後來觀測修正先前輸出；後者屬於離線平滑，不是本章的因果即時估計。

連回生成式AI、多模態與Agent

時間狀態可與影像、文字共同表示。影像模型輸出水面特徵，工作日誌模型輸出事件特徵，再與感測狀態、資料時間戳、缺值遮罩及 P 的摘要一同交給生成式AI。模型應看見「哪些資料缺失」及「估計有多不確定」，而不只是一組補齊後的數字。

Agent可先檢查資料有效期限，再檢索有來源的SOP、要求重新量測，或把附帶限制的建議送交人工批准。它不應把Kalman估計寫成真實量測，也不應直接控制投餌、加藥或增氧設備。狀態估計只是在假設下整理有限資訊，不能取代因果分析、非線性模型、現場知識與安全控制。

常見錯誤與限制

把缺值設為零會混淆未知與實際零；用後一天資料平滑今天，會破壞即時推論的因果限制。只輸出 $\hat{x}$ 而隱藏 P ，則使下游系統無法區分可靠觀測與長時間斷線後的推測。另一常見錯誤是忽略單位： P 的對角元素是變異數，其單位是原狀態單位的平方，並非可直接與狀態值相比的同一量。

線性模型可能錯配真實池況。 Q 與 R 設定不當、誤差彼此相關、突發事件、感測器飽和或未建模漂移，都可能造成過度自信。Kalman更新不是病害診斷，也不保證估計符合真實生物機制。若資料過期、單位不明或關鍵感測缺失，Agent應標示限制並交由現場專業人員處理。

習題

- 基本計算：**一維模型中 $F = H = 1$ ， $\hat{x}_{t-1|t-1} = 20$ ， $P_{t-1|t-1} = 1$ ， $Q = 0.5$ ， $R = 1.5$ ，且 $y_t = 23$ 。求預測值、預測變異數、 K_t 與更新值。
- 觀念題：**為何不能用整段資料的平均值填補測試期間的缺值？斷線時只沿用上一估計而不保存 P ，又少了什麼資訊？
- 養殖應用題：**池A連續三小時沒有 `do_mg_l` 觀測，但影像與日誌仍存在。說明狀態估計模組與Agent應如何表達及處理此情況。

習題解答

- 預測值為 $\hat{x}_{t|t-1} = 20$ ，預測變異數為 $P_{t|t-1} = 1 + 0.5 = 1.5$ 。所以 $S_t = 1.5 + 1.5 = 3$ ， $K_t = 1.5/3 = 0.5$ ，更新值為 $20 + 0.5(23 - 20) = 21.5$ 。
- 整段平均包含測試期間及其未來資訊，會造成資料洩漏，使評估過度樂觀。若不保存並傳播 P ，便遺失「斷線越久，估計通常越不確定」的資訊。
- 每小時仍執行狀態預測並加入 Q ，但跳過缺失的溶氧觀測更新，使相關不確定性逐步增加。影像與日誌可作獨立證據，不能冒充溶氧量測。Agent應標示斷線時段、最後觀測時間、估計值及不確定性，必要時要求人工檢查或重新量測，不自動下達設備操作。

本章小結

線性狀態空間模型以 F 描述狀態演變，以 H 連接隱藏狀態與觀測。Kalman概念在預測與更新之間平衡模型和感測資料，並用共變異數保存不確定性。缺值不能偽裝成零，時間切分也必須遵守先後順序。對池A而言，估計值、缺值遮罩、資料時效與不確定性應一起進入多模態系統及Agent的人工覆核流程。

參考來源

- [R1] NumPy linear algebra reference：本程式所用陣列與線性代數操作之參考。
- [R2] *Deep Learning*, Chapter 2: Linear Algebra：矩陣、轉置與共變異數等線性代數背景。本章的狀態估計公式則依前述教學假設逐步推導。

第18章 Agent的檢索、記憶與工具介面

學習目標與先備知識

本章要學會把查詢與文件表示成向量，計算相似度並選出前 k 筆候選；也要把池A的觀測、資料有效性與檢索來源放進結構化狀態。讀完後，你應能區分「找到相關文字」、「形成建議」與「獲准操作」三件事。

先備知識是列向量、內積、矩陣乘法與基本Python。列向量直立書寫；兩個等長向量的內積，是對應座標相乘後加總。不必先懂機率或深度學習。以下數值與紀錄全為教學合成，不是真實物種的適用閾值。

從池A提出問題

池A的感測器留下溫度與溶氧讀值，水面影像與工作日誌也提供線索。值班人員問：「這筆溶氧讀值似乎異常，應先查哪份作業程序？」Agent可以檢索有來源的SOP，整理待核對事項，並提出讀取歷史資料的計畫；它不能把一句生成的建議直接變成設備動作。

例如，較早的日誌寫著「感測器讀值不穩，先核對量測紀錄」，另一份文件談的是影像拍攝。兩份文字都可能含有「池A」，卻只有前者貼近問題。檢索的任務是縮小候選範圍，而不是判定池水是否安全。尤其資料若已過期或缺值，流暢的回答也無法補回可靠觀測。

概念與推導

設查詢的表示為列向量 $q \in \mathbb{R}^d$ ，第 i 份SOP的表示為 $s_i \in \mathbb{R}^d$ 。兩者座標必須由同一表示方法產生，否則逐項相乘沒有可比較的意義。將各文件的 s_i^T 疊成矩陣 $S \in \mathbb{R}^{N \times d}$ 的每一列；這裡共有 N 份文件，故

$$a = Sq \in \mathbb{R}^N, \quad a_i = s_i^T q。$$

第 i 個分數是文件與查詢的內積。若只想比較方向，可先將非零向量除以各自長度，得到餘弦分數

$$c_i = \frac{s_i^T q}{\|s_i\|_2 \|q\|_2}。$$

零向量沒有方向，不能套用此式。分數較高只表示在這套表示下較相近，並不表示SOP正確、最新，或適用於眼前的池況。

若同時有 n 個查詢，將每個查詢的轉置排成矩陣 $Q \in \mathbb{R}^{n \times d}$ ，每列一筆查詢。批次相似度矩陣為

$$C = QS^T \in \mathbb{R}^{n \times N}, \quad C_{ji} = q_j^T s_i。$$

其中 $q_j \in \mathbb{R}^d$ 是第 j 筆查詢； C 的第 j 列列出它對所有文件的分數，第 i 行則列出各查詢對第 i 份文件的分數。要算批次餘弦相似度，須先將每個非零查詢與文件向量各自正規化，再做同樣的矩陣乘法。不能直接把原始內積矩陣整體除以單一數值，因為各向量的長度未必相同。

矩陣乘法一次算出所有查詢與文件的配對分數，卻沒有替任何一筆查詢挑選文件。因此應沿著 C 的每一列各自排序，而不是把整張矩陣混在一起排名。排序結果還須連回原本的文件ID；若只留下分數、丟失欄位與文件的對應關係，就無法向讀者交代引用的是哪一份SOP。

對每筆查詢的分數分別排序，取最高的 k 筆，稱為 *top-k*。 k 是要檢視的候選數，不是可信度門檻；當 $k > N$ 時，最多也只能取得 N 筆。排序相同時，系統宜訂明固定規則，例如依文件ID排序，方便事後重現。每筆候選還應保留文件ID、版本、發布或更新日期及可供人查閱的來源位置。沒有來源的片段，即使分數最高，也不足以稱為「查到SOP」。

檢索與記憶相關，但不相同。對話摘要可以提醒Agent「剛才問過哪個感測器」，卻可能遺漏時間與否定詞；權威文件仍須重新查證。可把當次工作狀態記為一個結構化紀錄，而非只存一段自由文字，例如：

```
池別：池A
觀測：temperature_c、do_mg_l、ph
觀測時間：各欄各自記錄；缺值標為未知
影像：檔案ID與拍攝時間
問題：使用者原文
檢索：文件ID、版本、分數、來源
工具計畫：工具名稱、唯讀參數、待批准狀態
```

這不是單一數值向量：時間、單位、來源與「未知」各有不同意義。若為模型另做數值特徵，也不能把未知溶氧填成 0 而不加標記；0 是一個數值，不等於沒有量測。資料有效性檢查應獨立檢查時間、欄位與來源，再決定能否提供建議供人審閱。

手算例題

為方便手算，暫以兩個人工座標表示「量測核對」與「影像紀錄」；這不是實際語意模型。查詢 $q = (1, 0)^T$ ，三份合成文件為

$$s_1 = (3, 0)^T, \quad s_2 = (1, 1)^T, \quad s_3 = (0, 2)^T。$$

其中 $S \in \mathbb{R}^{3 \times 2}$ ，故

$$Sq = \begin{bmatrix} 3 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \\ 0 \end{bmatrix}。$$

直接用內積取 top-2 會選文件1、2。但文件1的長度是 3，文件2的長度是 $\sqrt{2}$ ，文件3的長度是 2；查詢長度為 1。逐一正規化後，餘弦分數變為 $3/(3 \cdot 1) = 1$ 、 $1/(\sqrt{2} \cdot 1) \approx 0.707$ 、 $0/(2 \cdot 1) = 0$ ，排序仍是1、2。這次排序沒有變，不代表正規化總是無影響：內積會受文件向量長度影響，選用哪種分數應先訂明。

若文件1其實是沒有版本資訊的筆記，檢索器仍可能給它最高分。正確後續是標示來源不足，要求查核正式文件，而非把「第一名」解讀成「可照做」。

Python實驗

以下程式只在記憶體中重現手算排序，不連接文件庫或設備。讀者可在隔離環境自行執行；輸入是程式內的查詢與三筆合成向量，預期輸出列於程式後。

```
from math import sqrt

query = [1.0, 0.0]
docs = {
    "SOP-01": [3.0, 0.0],
    "SOP-02": [1.0, 1.0],
    "SOP-03": [0.0, 2.0],
}

def norm(v):
    return sqrt(sum(x * x for x in v))

def cosine(a, b):
    if len(a) != len(b) or not a:
        raise ValueError("向量須非空且長度相同")
    na, nb = norm(a), norm(b)
    if na == 0 or nb == 0:
        raise ValueError("零向量沒有餘弦相似度")
    return sum(x * y for x, y in zip(a, b)) / (na * nb)

ranked = sorted(
    ((name, cosine(query, vec)) for name, vec in docs.items()),
    key=lambda item: (-item[1], item[0]),
)

for name, score in ranked[:2]:
    print(name, f"{score:.3f}")
```

預期輸出：

```
SOP-01 1.000
SOP-02 0.707
```

此處用精確零值檢查合成輸入；真實浮點資料還須訂明接近零的處理準則。程式只算相似度，沒有確認文件版本與適用條件，輸出仍待讀者自行核對。實際的唯讀檢索介面還須回傳來源欄位，並讓呼叫紀錄可供查閱。

連回生成式AI、多模態與Agent

生成式AI可以依檢索結果撰寫易讀摘要；水面影像、感測特徵與工作日誌也能形成多模態線索。然而各模態的時間可能不同，影像看起來相近也不能證實當下的溶氧讀值。向量檢索提供候選材料，不能取代觀測驗證或養殖專業判斷。

一份可審閱的Agent回覆可分成三層：先列出查得的SOP ID、版本與來源，再指出哪些觀測缺失或過期，最後提出**唯讀工具計畫**，例如「待批准後讀取指定時段的感測器歷史紀錄與校正紀錄」。工具介面應限制為明確的讀取項目、池別與時段，回傳資料也須附時間戳記。LLM產生的是計畫文字；是否允許讀取、資料是否有效，以及任何後續現場操作，都由可信的權限與審核流程另行決定。此處不連真實設備，也不產生投餌、加藥或增氧指令。

常見錯誤與限制

最常見的跳躍是把「相似」當成「適用」。向量可能因用詞接近而取回舊版程序，也可能漏掉措辭不同但重要的文件。 $\text{top-}k$ 沒有召回全部相關資料的保證；改變 k 、表示方法或文件集合，都可能改變排序。引用時應指向實際取回的文件，而不是讓模型補造來源。

另一個錯誤是把對話記憶當成感測器真值。摘要中的「昨天正常」不能證明今天正常；缺值不能默認為正常；不同時間的影像與量測也不能未經說明就合併。線性代數說明分數如何算出，卻不會證明文件可靠、判斷具有因果性，或控制動作安全。

習題

- 一、**基本計算**。令 $q = (0, 1)^T$ ， $s_1 = (0, 2)^T$ ， $s_2 = (1, 1)^T$ 。寫出以文件為列的矩陣 S 、 Sq ，並依餘弦分數選出 top-1 。
- 二、**觀念**。某文件餘弦分數最高，但缺少版本與來源位置。能否稱它是已核實的SOP？為什麼？
- 三、**養殖應用**。池A的 `do_mg_l` 缺值，影像拍攝時間也不明；使用者要求Agent「直接處理」。請寫出兩項應保留的狀態欄位，並提出一項合適的唯讀工具計畫。說明誰應決定後續操作。

習題解答

一、 $S = \begin{bmatrix} 0 & 2 \\ 1 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 2}$ ，所以 $Sq = (2, 1)^T$ 。兩筆餘弦分數依序為 1 與 $1/\sqrt{2}$ ， top-1 是文件1。

二、不能。分數只衡量表示向量的相近程度；缺版本與來源時，無法核對是否為正式、現行且適用的程序。

三、例如保留 `do_mg_l`：未知 與「影像拍攝時間：未知」，不可改寫成數值零或當前時間。可提出「待批准後唯讀查詢池A指定時段的感測器紀錄及影像中繼資料」。後續操作須由現場專業人員依有效資料與既定安全流程決定，模型建議不能代替批准。

本章小結

矩陣乘法讓多份文件與多筆查詢能計算成相似度矩陣， $\text{top-}k$ 則把每筆查詢的候選縮小到可查閱的數量。可稽核的Agent還需要來源、版本、時間與缺值狀態；檢索結果只供形成有根據的待審閱建議。唯讀工具計畫與可信控制分離，才不會讓一段生成文字越過資料檢查與人工批准。

參考來源

- R2： *Deep Learning, Chapter 2: Linear Algebra*（向量與矩陣概念）。
- R7： *ReAct: Synergizing Reasoning and Acting in Language Models*（Agent與工具互動的參考）。
- R8： *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*（檢索輔助生成的參考）。

第19章 風險、限制與人類覆核

學習目標與先備知識

本章把第18章的檢索與工具介面，放在一個更嚴格的目標下：agent 不能只生成文字，還要在資料缺損、資料過期或候選操作越界時停止，並把批准權交還現場專業人員。讀者應能用殘差理解觀測與訓練均值的偏差，用 Mahalanobis 距離理解尺度與相關結構如何影響「偏離幅度」，並用線性不等式界定候選操作的可行集合。先備知識包括第4章的秩與一致性、第7章的對稱正定矩陣、第9章的樣本共變異數與資料切分、第17章的缺值與時間切分，以及第18章的 agent 介面。本章不預設機率檢定、深度學習或自動控制；所有數值皆為教學合成，不提供真實物種閾值。

從池A提出問題

池A的流水線是：感測器與影像生成特徵，模型產生候選摘要，agent 檢索來源明確的 SOP，最後由人類批准。本節只取兩項感測： $temperature_c \in \mathbb{R}$ 與 $do_{mg/l} \in \mathbb{R}$ ，寫成列向量（column vector，直向） $\mathbf{x} \in \mathbb{R}^2$ ，shape 為 $(2, 1)$ 。訓練時段有 $n = 10$ 筆完整觀測，已算出均值 $\boldsymbol{\mu} \in \mathbb{R}^2$ 與樣本共變異數 $\Sigma \in \mathbb{R}^{2 \times 2}$ ，分母為 $n - 1$ 。

新資料進來時，agent 先做三類檢查。第一是資料有效性：若任一欄位缺值，或時間戳落在容許窗口外，agent 應拒絕執行，並以不同原因碼標記「缺值」或「過期／未來時間」，不得用零值、訓練均值或最近值悄悄補齊。第二是分布偏差：若資料完整，才計算它偏離訓練分布的 Mahalanobis 距離；高值只代表與訓練期不一致，不能等同病害診斷。第三是操作可行性：候選操作 δ 必須滿足由現場專業人員制定的線性限制 $A\delta \leq \mathbf{b}$ ；模型不能自行修改 A 或 $\mathbf{b}$ 。本章 Python 實驗只模擬檢查與候選建議，不連真實設備，也不發出投餌、加藥或增氧指令。

概念與推導

殘差定義為

$$\mathbf{r} = \mathbf{x} - \boldsymbol{\mu} \in \mathbb{R}^d,$$

shape 為 $(d, 1)$ 。它回答觀測比訓練均值多或少了多少。若只用歐氏範數 $\|\mathbf{r}\|^2 = \mathbf{r}^\top \mathbf{r}$ ，溫度偏 2 度與溶氧偏 2 mg/L 會被同等看待；但兩者的訓練方差不同，且可能相關，因此需要納入尺度與相關結構的距離。

Mahalanobis 距離平方定義為

$$d_M^2(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}),$$

其中 Σ 為 $d \times d$ 樣本共變異數矩陣。這裡的「 -1 」是矩陣逆，不是逐元素倒數。對實對稱矩陣，可逆的充要條件是 $\det(\Sigma) \neq 0$ ；對 $d = 2$ 共變異數矩陣，若對角變異數皆正且相關係數絕對值小於 1，則 $\det(\Sigma) > 0$ 。對樣本共變異數，還需注意：中心化後資料矩陣的秩必須達到 d ，因此 $n \geq d + 1$ 才可能不奇異；這是必要條件，不是充分條件，感測器高度相關時仍可能接近奇異。

幾何上， Σ 描述訓練資料的相關與尺度，形成橢圓方向；二次型中的 Σ^{-1} 依各主方向變異的倒數加權，使偏離幅度可比較；若要把殘差向量本身轉到單位共變異數尺度，則使用逆平方根 $\Sigma^{-1/2}$ ，或以下程式的 Cholesky 解法，而非直接稱 Σ^{-1} 是白化映射。若 Σ 奇異，存在非零 $\mathbf{v}$ 使 $\Sigma \mathbf{v} = 0$ ，也就是資料在某個組合方向沒有變異，此時 Σ^{-1} 不存在。可以改用偽逆 Σ^+ 定義廣義 Mahalanobis 距離：

$$\tilde{d}_M^2(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^+ (\mathbf{x} - \boldsymbol{\mu}).$$

但這個距離對零特徵值方向的偏差不懲罰，會低估那些方向的風險。教學上應把它視為「降維或合併冗餘感測」的信號，而不是完整異常判定。

線性限制採用一般形式

$$A\boldsymbol{\delta} \leq \mathbf{b},$$

其中 $\boldsymbol{\delta} \in \mathbb{R}^m$ 是候選操作的量， $A \in \mathbb{R}^{k \times m}$ ， $\mathbf{b} \in \mathbb{R}^k$ 。第 i 橫列 (row) 是一條線性不等式： $A_{i,:} \boldsymbol{\delta} \leq b_i$ 。可行集合為

$$\mathcal{F} = \{\boldsymbol{\delta} \in \mathbb{R}^m : A\boldsymbol{\delta} \leq \mathbf{b}\}.$$

例如現場人員可限制單項操作幅度與總資源量： $|\delta_1| \leq 2$ 、 $|\delta_2| \leq 3$ 、 $\delta_1 + \delta_2 \leq 4$ 。互斥、離散開關或時序邏輯不宜只靠連續變數線性不等式硬套；本章只處理能清楚寫成 $A\boldsymbol{\delta} \leq \mathbf{b}$ 的部分。若 $\mathcal{F} = \emptyset$ ，agent 應輸出「無可行候選」並停止，而不是放寬 $\mathbf{b}$ 。

手算例題

取 $d = 2$ ，訓練統計量

$$\boldsymbol{\mu} = \begin{pmatrix} 28 \\ 5.0 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 4 & -0.6 \\ -0.6 & 0.25 \end{pmatrix}.$$

先檢查可逆性：

$$\det(\Sigma) = 4(0.25) - (-0.6)^2 = 1 - 0.36 = 0.64 \neq 0.$$

對 2×2 矩陣，

$$\Sigma^{-1} = \frac{1}{0.64} \begin{pmatrix} 0.25 & 0.6 \\ 0.6 & 4 \end{pmatrix} = \begin{pmatrix} 0.390625 & 0.9375 \\ 0.9375 & 6.25 \end{pmatrix}.$$

新觀測 $\mathbf{x} = \begin{pmatrix} 33 \\ 2.0 \end{pmatrix}$ ，殘差

$$\mathbf{r} = \mathbf{x} - \boldsymbol{\mu} = \begin{pmatrix} 5 \\ -3 \end{pmatrix}.$$

計算 d_M^2 。先算 $\Sigma^{-1}\mathbf{r}$ ：

$$\Sigma^{-1}\mathbf{r} = \begin{pmatrix} 0.390625(5) + 0.9375(-3) \\ 0.9375(5) + 6.25(-3) \end{pmatrix} = \begin{pmatrix} 1.953125 - 2.8125 \\ 4.6875 - 18.75 \end{pmatrix} = \begin{pmatrix} -0.859375 \\ -14.0625 \end{pmatrix}.$$

再與 $\mathbf{r}$ 做內積：

$$d_M^2 = \mathbf{r}^\top \Sigma^{-1} \mathbf{r} = 5(-0.859375) + (-3)(-14.0625) = -4.296875 + 42.1875 = 37.890625.$$

這個數值本身尚不能判定「高低」；必須與事先制定、只用訓練／驗證時段擬合並經人工審核的比較規則相比較。在此，我們只把它作為觸發覆核的訊號，不作病害診斷。

接著檢查線性限制。設候選操作 $\boldsymbol{\delta} = \begin{pmatrix} 3.0 \\ 1.0 \end{pmatrix}$ ，限制寫成

$$A = \begin{pmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 1 \\ 0 & -1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 2 \\ 2 \\ 3 \\ 3 \\ 4 \end{pmatrix}.$$

五個橫列分別對應 $\delta_1 \leq 2$ 、 $-\delta_1 \leq 2$ 、 $\delta_2 \leq 3$ 、 $-\delta_2 \leq 3$ 、 $\delta_1 + \delta_2 \leq 4$ 。代入：

$$A\boldsymbol{\delta} = \begin{pmatrix} 3.0 \\ -3.0 \\ 1.0 \\ -1.0 \\ 4.0 \end{pmatrix}, \quad A\boldsymbol{\delta} - \mathbf{b} = \begin{pmatrix} 1.0 \\ -5.0 \\ -2.0 \\ -4.0 \\ 0.0 \end{pmatrix}.$$

第一橫列 $3.0 > 2$ 越界，因此 $\boldsymbol{\delta} \notin \mathcal{F}$ 。agent 應拒絕該候選，並回報「第一條限制超出上限」，而不是自行改成 2.5。

Python實驗

以下程式碼供讀者在隔離環境執行，使用 NumPy。它示範：缺值與時間戳的布林檢查、以 Cholesky 分解檢查正定性、Mahalanobis 距離、一般形式 $A\boldsymbol{\delta} \leq \mathbf{b}$ 的可行檢查。程式中的 $\mathbf{x}$ 、 $\boldsymbol{\mu}$ 、 $\boldsymbol{\delta}$ 與 $\mathbf{b}$ 分別使用

$$\mathbf{x}, \boldsymbol{\mu} \in \mathbb{R}^{d \times 1}, \quad \boldsymbol{\delta} \in \mathbb{R}^{m \times 1}, \quad \mathbf{b} \in \mathbb{R}^{k \times 1}.$$

本例 $d = 2$ 、 $m = 2$ 、 $k = 5$ 。

```

import numpy as np

np.random.seed(42)
np.set_printoptions(precision=4, suppress=True)

# 訓練統計量 (教學合成, 非真實閾值)
mu = np.array([[28.0],
                [5.0]])
Sigma = np.array([[4.0, -0.6],
                  [-0.6, 0.25]])

# 新資料與外部檢查輸入
x = np.array([[33.0],
              [2.0]])
invalid_x = x.shape != mu.shape or not np.isfinite(x).all()
obs_time = 100.0
now_time = 105.0
staleness_limit = 60.0

def finite_scalar(value):
    return (isinstance(value, (int, float, np.integer, np.floating))
            and not isinstance(value, (bool, np.bool_))
            and bool(np.isfinite(value)))

if invalid_x:
    print("status: reject")
    print("reason: invalid_shape_or_nonfinite_data")
elif not all(finite_scalar(v) for v in (obs_time, now_time, staleness_limit)):
    print("status: reject")
    print("reason: invalid_timestamp_or_window")
elif staleness_limit < 0:
    print("status: reject")
    print("reason: invalid_window")
elif obs_time > now_time or now_time - obs_time > staleness_limit:
    print("status: reject")
    print("reason: stale_or_future")
else:
    try:
        L = np.linalg.cholesky(Sigma)
        print("cholesky_ok=True")
    except np.linalg.LinAlgError:
        print("status: reject")
        print("reason: sigma_not_positive_definite")
        L = None

    if L is not None:
        r = x - mu
        # 解  $L y = r$ , 再解  $L^T x\_tmp = y$ , 等價於  $Sigma x\_tmp = r$ 
        y = np.linalg.solve(L, r)
        Sigma_inv_r = np.linalg.solve(L.T, y)
        d2 = float((r.T @ Sigma_inv_r)[0, 0])
        print(f"d_M^2={d2:.4f}")

        delta = np.array([[3.0],
                          [1.0]])
        A = np.array([[1, 0],
                      [-1, 0],
                      [0, 1],

```

```

        [0, -1],
        [1, 1]])
b = np.array([[2.0],
              [2.0],
              [3.0],
              [3.0],
              [4.0]])
margin = A @ delta - b
feasible = bool(np.all(margin <= 1e-12))
print(f"feasible={feasible}")
print(f"margin={margin.ravel()}")
if not np.isfinite(margin).all() or not np.isfinite(d2):
    print("status: reject")
    print("reason: nonfinite_calculation")
elif not feasible:
    print("status: reject")
    print("reason: constraint_violation")
    print("violated_rows:", (np.flatnonzero(margin.ravel() > 1e-12) + 1).tolist())
else:
    print("status: review_required")
# 所有分支均不回傳可執行操作；可行也不等於安全或已批准。

```

`violated_rows` 表示違反限制的橫列編號，從1開始計數。預期輸出：

```

cholesky_ok=True
d_M^2=37.8906
feasible=False
margin=[ 1. -5. -2. -4.  0.]
status: reject
reason: constraint_violation
violated_rows: [1]

```

若把 `x[1,0]` 改成 `np.nan`，程式輸出 `status: reject` 與 `reason:`

`invalid_shape_or_nonfinite_data`，無窮值亦同；時間戳為 `None`、字串、布林或非有限值時，先回報 `invalid_timestamp_or_window`，不進行時間相減；若把 `obs_time` 改成 `200.0`，程式輸出 `status: reject` 與 `reason: stale_or_future`。這裡用 Cholesky 分解檢查正定性，避免以行列式與矩陣範數直接比較造成量綱不一致。實務上若條件數很大，應標記近奇異並改用更穩健的分解。

連回生成式AI、多模態與Agent

本章在池A流水線設兩道檢查：輸入資料有效性先於模型生成，無效便不產生候選；候選限制檢查則在模型建議之後、人工批准之前，並再次核對資料是否仍有效且新鮮。兩道檢查都不得由模型略過；人工批准是後續獨立關卡，不表示可以先批准再補做有效性檢查。生成式模型可能把高 Mahalanobis 距離解釋成自然語言，例如「水質異常」；但線性代數只提供距離與越界資訊，不承擔生物因果判斷。多模態融合時，若影像模態缺值或感測時間戳過期，融合前的有效性檢查就應拒絕，不能把缺模態補零後再計算相似度。Agent 的角色因此是：檢索來源、整理候選、列出拒絕原因、把批准權留給現場專業人員。R7、R8 只支持 agent 推理、行動與檢索的背景，不證實任何養殖安全閾值。

建議與執行分離



agent安全檢查流程

常見錯誤與限制

第一，把異常分數當診斷。 d_M^2 高可能來自感測漂移、季節變化、訓練期不足或資料缺失，不能推論特定病原或操作必要。第二，忽略 Σ 的來源。 μ 與 Σ 必須只用訓練時段估計；若混入測試日或實際日資料，會高估穩定性。第三，假設 $n > d$ 就夠。樣本共變異數還需中心化資料具有足夠秩；感測器高度相關時仍可能奇異或接近奇異。第四，用廣義 Mahalanobis 距離隱藏零特徵值方向。 Σ^+ 方便計算，但會忽略冗餘方向上的偏差，應搭配降維或來源檢索使用。第五，把互斥或離散操作硬寫成連續線性不等式。若操作包含開關、順序或不可同時執行，需要更完整的約束模型，超出本章線性範圍。第六，agent 在越界時自動修補。可行集合為空時，正確行為是停止、回報原因並等待人類調整，而不是自行降低限制。

習題

習題1（基本計算）

池A兩維感測 $\mathbf{x} = (t, o)^\top$ 。訓練集得 $\mu = (30, 4.0)^\top$ ， $\Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 0.16 \end{pmatrix}$ 。新觀測 $\mathbf{x} = (32, 2.0)^\top$ 。

(a) 求 Σ^{-1} 。

(b) 算 d_M^2 。

(c) 若限制為 $|t - 30| \leq 3$ 且 $|o - 4.0| \leq 1.5$ ，寫成 $A\delta \leq \mathbf{b}$ 並判斷 $\delta = (2, -2)^\top$ 是否可行。

習題2（觀念）

為何 Σ 正定比「行列式不為零」更適合 Mahalanobis 距離的教學要求？若樣本共變異數 Σ 奇異，使用偽逆 Σ^+ 會帶來什麼解釋上的限制？

習題3 (養殖應用)

池A的 agent 設定：若 $d_M^2 > 10$ ，則自動把溶氧目標設為 6 mg/L 並執行增氧。請指出此設計在資料有效性、因果診斷與操作安全上的至少三處問題，並改寫成符合本章原則的「拒絕—回報—批准」流程。

習題解答

習題1

(a) Σ 為對角矩陣， $\Sigma^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & 6.25 \end{pmatrix}$ 。

(b) $\mathbf{r} = (2, -2)^\top$ ，

$$d_M^2 = (2 \quad -2) \begin{pmatrix} 1 & 0 \\ 0 & 6.25 \end{pmatrix} \begin{pmatrix} 2 \\ -2 \end{pmatrix} = 4 + 25 = 29.$$

(c)

$$\begin{pmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 1 \\ 0 & -1 \end{pmatrix} \boldsymbol{\delta} \leq \begin{pmatrix} 3 \\ 3 \\ 1.5 \\ 1.5 \end{pmatrix}.$$

代入 $\boldsymbol{\delta} = (2, -2)^\top$ 得

$$A\boldsymbol{\delta} = \begin{pmatrix} 2 \\ -2 \\ -2 \\ 2 \end{pmatrix}, \quad A\boldsymbol{\delta} - \mathbf{b} = \begin{pmatrix} -1 \\ -5 \\ -3.5 \\ 0.5 \end{pmatrix}.$$

第四橫列 $0.5 > 0$ ，故不可行。

習題2

Mahalanobis 距離要求 Σ^{-1} 存在，且對任何非零 $\mathbf{v}$ ， $\mathbf{v}^\top \Sigma^{-1} \mathbf{v} > 0$ ，這樣距離平方才非負且只在 $\mathbf{x} = \boldsymbol{\mu}$ 時為零。行列式不為零只保證可逆；對稱正定還保證特徵值皆正，避免出現負距離平方或異常的橢圓方向。若 Σ 奇異， Σ^+ 會把零特徵值方向的偏差不計入距離，等於假設那些方向「不重要」。但那些方向可能正是感測器共線或冗餘造成的資訊缺口，必須標記為低置信、降維、合併變數或請人類補充資料，不能直接當作正常。

習題3

(1) 缺值或過期未先拒絕：若 `domgl` 缺值，agent 不該用訓練均值或零值補齊後繼續計算。依本章程式，缺值（以NaN表示）或其他非有限觀測值應輸出 `status: reject` 與 `reason: invalid_shape_or_nonfinite_data`；時間戳本身有效但過期或在未來，則回報 `reason: stale_or_future`。時間戳缺失或非有效數值，先回報 `reason: invalid_timestamp_or_window`，不進行新鮮度計算。

(2) 把異常當診斷： $d_M^2 > 10$ 只表示與訓練期不一致，不能推出溶氧不足，更不能自動決定增氧；10 也不是

通用閾值。

(3) 自動執行目標濃度：把「溶氧目標 6 mg/L」當自動指令，忽略現場設備、量測延遲、人員批准與資源限制。應改為：agent 只生成候選操作 δ ，用 $A\delta \leq \mathbf{b}$ 檢查；若可行，輸出候選與來源；若不可行或資料缺損，停止並回報；由現場專業人員批准後才可能進入外部流程，而本章示範不連接設備。

本章小結

本章把風險控制拆成三個可檢查的線性代數步驟：殘差量化觀測與訓練均值的偏差；Mahalanobis 距離把尺度與相關結構納入偏差，但要求 Σ 可逆，奇異時可考慮偽逆，但須明示它忽略零特徵值方向的偏差；也可依問題降維、重新選擇特徵或調整共變異數估計方法，並重新驗證其假設，不能把任一替代法當作安全保證；線性限制 $A\delta \leq \mathbf{b}$ 界定候選操作的可行集合。異常分數不是病害診斷，缺值或過期資料應先拒絕，可行集合為空應停止。Agent 的價值在於檢索來源、整理候選、列出拒絕原因，而不是替代養殖專業或自動操作。

參考來源

- R1: NumPy linear algebra reference.
- R2: Deep Learning, Chapter 2: Linear Algebra.
- R7: ReAct: Synergizing Reasoning and Acting in Language Models.
- R8: Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.

第20章 專題：可稽核的養殖決策輔助系統

學習目標與先備知識

本章整合資料矩陣、投影、檢索、評估與誤差傳播，建立池A的純模擬決策輔助流程。你將追蹤資料如何成為待審建議，理解時間切分、測試、人工批准與回滾。只需會讀矩陣乘法及簡單Python。所有數值都是教學合成，不提供真實物種適用閾值，也不代表真實養殖操作規範。

從池A提出問題

池A的感測器記錄temperature_c（攝氏）、do_mg_l（溶氧mg/L）和ph（無量綱）；水面影像與工作日誌提供其他資訊。系統整理特徵、檢索有來源的SOP，再產生供人員檢查的摘要。它不是自動控制器：不連真實設備，不下投餌、加藥或增氧指令。

每筆資料應保留時間、來源、單位、缺值標記與版本。只有數字而沒有欄位名稱和單位，容易混淆量綱；影像沒有時間，也可能與另一時段的感測資料錯配。用識別碼連結原始紀錄與轉換結果，才便於追查問題。

概念與推導

令批次特徵矩陣 $X \in \mathbb{R}^{n \times d}$ ，每列是一筆觀測，每欄是一項特徵。三個感測欄位寫成 $X_s \in \mathbb{R}^{n \times 3}$ 。假設影像表示 $I \in \mathbb{R}^{n \times p}$ 、日誌表示 $L \in \mathbb{R}^{n \times q}$ ，且每一列皆對應同一時間窗；缺模態須明確標記，不能以零冒充觀測。時間對齊後，才可串接為 $X = [X_s \ I \ L] \in \mathbb{R}^{n \times (3+p+q)}$ 。

若線性映射矩陣 $W \in \mathbb{R}^{k \times d}$ ，則 $Z = XW^T \in \mathbb{R}^{n \times k}$ 。每列仍對應一筆觀測，每欄是投影後的表示。投影能轉換或壓縮表示，卻不保證資訊完整，也不等於理解池況。訓練出的 W 須與模型版本一起保存。

縮放器只用訓練集估計。對第 j 欄，訓練筆數 $n \geq 2$ 時，平均為 $\mu_j = \frac{1}{n} \sum_i x_{ij}$ ，樣本標準差為 $s_j = \sqrt{\frac{\sum_i (x_{ij} - \mu_j)^2}{n-1}}$ 。若 $s_j = 0$ ，該欄不能直接相除，須依預先規則移除、保留為常數或停止處理。其餘欄位標準化為 $(x_{ij} - \mu_j)/s_j$ 。驗證集、測試集只套用訓練所得的 μ_j, s_j 。若以測試資料重新估計，就像先偷看考題分布再評分，結果不再是獨立檢驗。

令查詢向量 $q \in \mathbb{R}^k$ 與SOP向量 $d_r \in \mathbb{R}^k$ 皆為非零列向量，餘弦相似度為 $s_r = \frac{q^T d_r}{\|q\| \|d_r\|}$ 。它比較方向，不判斷內容正確與否。按分數取前 K 筆候選供人工核對； K 是候選數，不是品質保證。候選要附文件識別碼、版本與原文段落。

時間序列若把相鄰量測隨機分進訓練與測試，模型可能因兩邊資料過於相似而顯得準確。較合適的模擬方式是按時間先後切出訓練、驗證、測試；驗證集用來選設定，測試集留到設定固定後評估。除預先選定的誤差，也要記錄缺值、過期、單位不符及超出訓練範圍的筆數。平均誤差小，不代表每筆都可靠。

若單筆輸入 $x \in \mathbb{R}^d$ 帶有誤差 δx ，投影誤差為 $\delta z = W \delta x$ 。對相容的向量範數及其誘導矩陣範數， $\|\delta z\| \leq \|W\| \|\delta x\|$ 。誘導矩陣範數描述矩陣在該向量長度度量下可能造成的最大放大。若 W 在某方向拉伸很大，小輸入誤差也可能變大，進而影響檢索排序。此上界不保證預測正確；非線性、統計波動、資料漂移與因果關係仍須另行評估。

手算例題

訓練集有三筆合成溫度 20, 22, 24 攝氏。平均為 $\mu = (20 + 22 + 24)/3 = 22$ 。樣本標準差以 $n - 1 = 2$ 為分母：

$$s = \sqrt{\frac{(20 - 22)^2 + (22 - 22)^2 + (24 - 22)^2}{2}} = \sqrt{\frac{4 + 0 + 4}{2}} = 2.$$

三筆標準化值依序為 $-1, 0, 1$ 。驗證值 23 只套用訓練統計量，得到 $(23 - 22)/2 = 0.5$ ；此例訓練筆數至少為 2，且 $s > 0$ 。

再令 $W = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$ 、輸入列向量 $x = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$ 。逐列相乘：

$$z = Wx = \begin{bmatrix} 2 + 1 \\ 2 - 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

若 $\delta x = \begin{bmatrix} 0.1 \\ 0 \end{bmatrix}$ ，則 $\delta z = W \delta x = \begin{bmatrix} 0.1 \\ 0.1 \end{bmatrix}$ 。一個欄位的偏差可能影響兩個表示欄位，後續相似度排序也可能改變。

Python實驗

程式示範樣本標準差、驗證縮放及欄位存在檢查。欄位檢查不代表時間未過期、單位正確或來源可信。依計算推得預期輸出為 0.5 和 True；此處不宣稱已執行。

```
# 輸入：訓練溫度 [20, 22, 24]，驗證溫度 23
train = [20.0, 22.0, 24.0]
validation = 23.0

mean = sum(train) / len(train)
variance = sum((x - mean) ** 2 for x in train) / (len(train) - 1)
std = variance ** 0.5
scaled = (validation - mean) / std

record = {"timestamp": "模擬時間", "unit": "攝氏", "source": "合成感測器"}
fields_present = all(record[key] for key in ("timestamp", "unit", "source"))

print(scaled)          # 預期：0.5
print(fields_present)  # 預期：True
```

以下合成紀錄串起輸入、投影、檢索、拒絕、人工決定與回滾；識別碼及數值只供教學核對，不是實際測試結果。單筆投影前查詢定義為列向量 $q_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \in \mathbb{R}^2$ ，兩欄依序代表合成感測特徵。令 $W = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \in \mathbb{R}^{2 \times 2}$ ，投影後查詢為 $q = Wq_0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 。候選SOP向量 $d_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 、 $d_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 也在同一投影後二維空間。兩者與 q 的內積皆為1； $\|q\| = \sqrt{2}$ ，而 $\|d_1\| = \|d_2\| = 1$ ，所以兩個餘弦分數都是 $1/\sqrt{2} \approx 0.707$ 。

檢索可以先在隔離的模擬流程中產生候選供稽核，但候選不得先當作可操作建議呈現。正式流程先檢查時間、單位、來源及新鮮度；任何必要檢查失敗，就停止呈現建議並轉人工查核。表中的 model-v2 是刻意注入的失效測試：它在檢查失敗後仍產生摘要，因此輸出被隔離，不能送交使用者作操作依據。

階段	可核對的模擬紀錄	稽核重點
建立與切分	seed=42；訓練區間第1至第6日、驗證第7至第8日、測試第9至第10日；測試2筆	保存日期區間與資料版本
擬合	訓練集擬合縮放器與 W ；驗證、測試只套用	固定seed便於重現，不保證統計可靠性
離線檢索	SOP-DEM0-03/v1分數0.707；SOP-DEM0-04/v1分數0.707	只供隔離測試核對，附上原文與版本
資料檢查	TEST-DEM0-01缺時間戳；TEST-DEM0-02欄位齊全，兩筆皆待檢查單位、來源及新鮮度	欄位存在檢查無效1筆；欄位齊全不等於有效
拒絕與覆核	正常流程不呈現建議；Reviewer-DEM0-01於T-review-01拒絕TEST-DEM0-01，理由為無法確認新鮮度	留下識別碼、決定與理由
失效與回滾	失效測試中model-v2仍輸出摘要；於T-rollback-01隔離model-v2，由Approver-DEM0-02核准切回model-v1	重送同筆資料後記錄拒絕摘要及檢查結果

此例沒有定義預測目標，因此預測誤差未評估，也不能由兩筆測試資料推論模型能力。表中的檢索分數只用來核對向量計算；正常流程在資料有效性檢查失敗時不呈現可操作摘要。回滾是停用失效版本並保留事件、批准及回滾後檢查紀錄，方便日後追溯。

連回生成式AI、多模態與Agent

感測、影像與日誌可以各自轉成向量，時間對齊後投影到共同維度比較。缺少模態時應明示並依規則拒絕或降級，而非假裝資訊存在。線性代數只是生成式AI的骨架，非線性、統計不確定性、語言生成誤差與因果問題不能省略。

Agent可呼叫唯讀檢索介面，回報候選SOP、文件版本、資料新鮮度與缺失欄位，產生待審摘要。檢索增強生成與推理一行動式設計是架構參考（R8、R7），不是養殖成效或安全性的證據。工具權限應採白名單：只讀模擬資料與文件，不修改設備狀態、不呼叫控制端點。摘要要分開呈現來源原文與模型推測。

常見錯誤與限制

把相似度當健康判斷、把相關性當因果，都是超出計算能支持的結論。隨機切分相鄰資料可能高估表現；用全資料估計縮放參數會造成資料洩漏；只看平均誤差可能掩蓋個別大錯。合成資料的測試不能證明真實池塘效果，也不能取代現場專業評估。

部署清單應確認：欄位、單位、時間與來源檢查；模型及SOP版本鎖定；資料切分可重現；評估與拒絕條件事先設定；工具唯讀且有白名單；失效時停止建議並交人員查核；批准或拒絕皆留識別碼、時間及理由；回滾版本保存並完成模擬演練。清單完成不等於決策已驗證。安全操作須由現場專業人員制定，模型建議不能取代養殖專業。

習題

1. **基本計算**：訓練集兩筆合成溶氧值為4, 6。求平均、樣本標準差，以及驗證值5的標準化結果。
2. **觀念**：為何不能用測試集估計縮放器？固定seed是否足以保證評估可靠？
3. **養殖應用**：資料缺少時間戳，但檢索找到相似SOP，系統應如何處理？回滾時至少記錄哪些資訊？

習題解答

1. 平均為 $(4 + 6)/2 = 5$ ；樣本標準差為 $\sqrt{[(4 - 5)^2 + (6 - 5)^2]/(2 - 1)} = \sqrt{2}$ ；標準化結果為 $(5 - 5)/\sqrt{2} = 0$ 。
2. 測試集只用來估計最終表現；以它估計縮放器會讓測試分布資訊滲入流程，造成評估偏差。固定seed讓部分隨機步驟可重現，卻不保證樣本具代表性或誤差夠小。
3. 停止呈現可操作建議，標示資料無效並交由人員查核；相似SOP不能補回時間資訊。回滾要記錄觸發原因、目前與目標版本、批准者、決定時間及回滾後檢查結果。

本章小結

池A的輔助流程須連結資料來源、單位、轉換、投影、檢索、測試與人工決定。訓練統計量不可偷看測試資料，輸入誤差也可能影響下游排序。純模擬演練應涵蓋時間切分、無效資料拒絕、唯讀權限、人工覆核及版本回滾。這不表示系統已連接設備、通過人工審查或驗證養殖成效。

參考來源

- R1：NumPy linear algebra reference，
<https://numpy.org/doc/stable/reference/routines.linalg.html>
- R7：ReAct: Synergizing Reasoning and Acting in Language Models，
<https://arxiv.org/abs/2210.03629>

- R8 : Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ,
<https://arxiv.org/abs/2005.11401>

附錄：共用符號、資料與驗收清單

符號速查

符號	意義	預設形狀
x	單筆特徵，column vector	$d \times 1$
X	每列row為一筆觀測	$n \times d$
W	線性映射	$m \times d$
$y = Wx$	單筆輸出	$m \times 1$
$Y = XW^T$	批次輸出	$n \times m$
μ	訓練資料平均向量	$d \times 1$
Σ	共變異數矩陣	$d \times d$
Q, K, V	注意力查詢、鍵、值	每章另外明示

中文「行、列」在不同教材慣例可能不同，因此本書搭配row與column標註。任何形狀衝突以章節明確定義和矩陣乘法規則為準，不靠名詞猜測。

合成資料說明

`data/pond_a_synthetic.csv` 是固定種子的教學合成資料，欄位包含timestamp、temperature_c、do_mg_l、ph及quality_flag。時間每十分鐘一筆；少量缺值以空欄位表示。數值只為示範資料處理，不代表某種魚蝦的適宜範圍、危險閾值或生理模型。攝影機與工作日誌在後續章節以小型示意資料呈現，不宣稱有真實現場影像。

讀取資料時先保存原始時間和品質旗標，不因為模型需要完整矩陣便悄悄補值。若使用平均值、插值或前值補齊，應標記方法與可用的歷史範圍，並防止未來資料洩漏。训练、驗證、測試的切分應依時間順序，不能把相鄰量測隨機打散後就宣稱具有跨日泛化能力。

專題交付驗收

1. 提供欄位字典、時間單位、物理單位和缺值規則。
2. 每個轉換都列出輸入與輸出shape，保存訓練時估計的參數。
3. 同時測試正常輸入、缺值、過期值、形狀錯誤及矛盾資料。
4. 每則agent建議附引用文件、版本、資料時間與不確定性說明。

5. 將工具分為唯讀與有副作用兩類，教材範例只使用唯讀或模擬工具。
6. 不把提示詞當作安全邊界；真實權限應由程式與現場流程控制。
7. 記錄拒絕執行與人工覆核的理由，提供可追查而非只求成功的測試報告。
8. 不把模型審稿或自動數值測試稱為完整專業驗證。

從教材到現場還缺什麼

真正部署仍需要物種與場域專家、設備與通訊工程、感測器校正、資安、維運、故障演練及責任界定。這些工作不能被一個向量分數或語言模型回覆取代。最安全的起點是先將系統限制在資料整理與建議展示，評估與現場人工流程的差異，再決定是否有理由進行更高風險的試驗。

參考來源

模型應依這些來源定位概念，不可宣稱所有章节論點都已獨立查證。

- [R1] NumPy linear algebra reference
- [R2] Deep Learning, Chapter 2: Linear Algebra
- [R3] Attention Is All You Need
- [R4] Learning Transferable Visual Models From Natural Language Supervision
- [R5] LoRA: Low-Rank Adaptation of Large Language Models
- [R6] Denoising Diffusion Probabilistic Models
- [R7] ReAct: Synergizing Reasoning and Acting in Language Models
- [R8] Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

出版與字型授權

本版由既有Markdown排版，未執行章內程式碼。字型：Noto Sans CJK TC（SIL Open Font License 1.1）；數學排版：KaTeX（MIT）。全文來源SHA-256：5f896d7b5efbee5c4e98f11e4883965b5929d6844a574a553cb5b5b09b3eeb64。

► [字型與數學排版授權全文](#)